中图分类号 学校代码 10224
密 级 公开 学 号 B18140101

東北農業大學

博士学位论文

基于多域特征融合的生猪咳嗽声识别方法研究

作 者 纪楠 导 师 沈维政 教授
学位类别 工学博士 所在学院 电气与信息学院
一级学科 农业工程 二级学科 农业电气化与自动化

二〇二三年六月

中国知网 https://www.cnki.net

Classified Index: Code:10224

Confidential (yes/no): no NO. B18140101

Dissertation for the Doctor Degree

Study on Pig Cough Sound Recognition Based on Muti-domain Feature Fusion

Candidate: Ji Nan

Supervisor: Prof. Shen Weizheng

Degree Category: Doctor of Science in Engineering

College: College of Electrical Engineering and Information

First level discipline: Agricultural Engineering

Second level discipline: Agricultural Electrification and Automation

Harbin China

June 2023

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 生猪咳嗽声特征提取研究现状.....3
1.2.2 生猪咳嗽声识别算法研究现状.....6
1.2.3 生猪叫声特征融合研究现状.....9
1.3 存在的问题与研究内容.....10
1.3.1 生猪咳嗽声识别存在的问题.....10
1.3.2 论文主要研究内容.....10
1.4 技术路线.....11
1.5 论文结构与章节安排.....14
2 猪舍内音频数据获取与预处理.....16
2.1 引言.....16
2.2 猪舍内音频数据获取.....16
2.2.1 音频数据采集环境.....16
2.2.2 音频数据分割与标记.....19
2.2.3 猪舍内音频数据集构建.....20
2.3 声音信号预处理.....22
2.3.1 预加重.....22
2.3.2 分帧.....22
2.3.3 加窗.....23
2.4 模型评估与评价指标.....24
2.4.1 模型评估方法.....24
2.4.2 模型评价指标.....26
2.5 本章小结.....28
3 基于传统声学特征融合的生猪咳嗽声识别.....29
3.1 引言.....29
3.2 传统声学特征提取.....29
3.2.1 时域特征.....30
3.2.2 频域特征.....30
3.2.3 倒谱域特征.....31
3.3 特征选择与解释.....34
3.3.1 基于 XGBoost-RFECV 的特征选择.....35
3.3.2 基于 XGBoost-SHAP 的特征解释.....37

中国知网 https://www.cnki.net

3.4 识别模型构建与优化.....38
3.4.1 机器学习模型构建.....38
3.4.2 参数设置与优化.....41
3.5 实验结果与分析.....42
3.5.1 实验设置.....42
3.5.2 特征选择实验结果与分析.....43
3.5.3 不同识别模型实验结果与分析.....46
3.6 本章小结.....49
4 基于时频图特征融合的生猪咳嗽声识别.....51
4.1 引言.....51
4.2 时频图构建.....52
4.2.1 短时傅里叶变换.....52
4.2.2 常数 Q 变换.....54
4.3 基于时频图的视觉特征提取.....56
4.3.1 局部二值模式.....56
4.3.2 方向梯度直方图.....59
4.3.3 基于核主成分分析的特征降维.....62
4.4 基于时频图的深度特征提取.....62
4.4.1 卷积神经网络模型构建.....63
4.4.2 基于单输入谱图特征层融合架构.....65
4.4.3 基于双谱图输入特征融合架构.....66
4.4.4 深度特征融合算法.....66
4.5 实验结果与分析.....68
4.5.1 实验设置.....68
4.5.2 视觉特征实验结果与分析.....68
4.5.3 深度特征实验结果与分析.....74
4.6 本章小结.....78
5 基于声学特征和时频图特征融合的生猪咳嗽声识别.....79
5.1 引言.....79
5.2 多域特征融合架构.....79
5.2.1 多域特征组合策略.....80
5.2.2 多域特征融合方式.....82
5.3 混合集成算法在不平衡数据集下的生猪咳嗽声识别.....83
5.3.1 集成学习模型.....83
5.3.2 混合集成算法.....84
5.4 实验结果与分析.....87
5.4.1 实验设置.....87
5.4.2 多域特征融合在平衡数据集下的实验结果与分析.....88

中国知网 https://www.cnki.net

5.4.3 多域特征融合在不平衡数据集下的实验结果与分析 95
5.4.4 混合集成算法在不平衡数据集下的实验结果与分析 101
5.5 本章小结.....106
6 总结与展望.....108
6.1 结论.....108
6.2 主要创新点.....109
6.3 展望.....109
参考文献.....111

中国知网 https://www.cnki.net

摘 要

我国生猪养殖业正面向集约化与规模化方向发展，这种现代化的生猪养殖模式极易诱发生猪呼吸道疾病，增加生猪疾病防控压力。咳嗽是生猪呼吸道疾病的主要临床症状之一，已成为呼吸道疾病监测的关键指标。目前，生猪咳嗽声监测主要是通过人工巡检的方式，然而这种传统的监测方式不仅耗时费力，且难以实现连续监测，极易发生漏检的情况，从而错过疾病的早期筛查阶段。音频分析技术在检测生猪咳嗽声方面具备充分的可行性和技术优势，因此，利用音频技术对猪舍内的声音信号进行采集、分析和处理，并从中有效识别生猪咳嗽声，对实现生猪群发性呼吸道疾病辅助预警具有重要意义。

当前，采用音频技术识别生猪咳嗽声存在以下问题：复杂猪舍环境下声音特征提取不充分、缺乏有效的特征选择与融合方法，同时缺少不平衡数据集下的生猪咳嗽声识别研究。为解决上述问题，本文在充分提取传统声学特征以及时频图特征的基础上，提出了不同域下的特征融合方法，并进一步提出混合集成算法以实现不平衡数据集下高精度的生猪咳嗽声识别。本文的主要工作如下：

（1）研究了基于传统声学特征融合的生猪咳嗽声识别方法。首先，提取猪舍内不同声音的多种传统声学特征，包括时域（均方根能量和过零率）、频域（频谱质心、频谱平坦度、频谱带宽、频谱滚降度、频谱对比度和频谱通量）和倒谱域特征（梅尔频率倒谱系数）。依据多种声学特征间的相关性及差异性，基于 XGBoost 的循环递归特征消除方法实现声学特征选择，同时，采用 XGBoost-SHAP 方法进行特征解释，探究不同域下特征间的关联及其对识别精度的影响。最后，采用网格搜索方法替代传统的参数经验判定优化分类器，对比支持向量机、K 邻近算法和随机森林三种不同机器学习算法下的生猪咳嗽声分类性能。研究发现，时域特征和倒谱域特征比频域特征在生猪咳嗽声识别中更具有影响力，其中，梅尔频率倒谱系数对提高生猪咳嗽声识别精度贡献度最高。与单一域下的梅尔频率倒谱系数相比，声学特征融合子集结合支持向量机识别生猪咳嗽声准确率为 94.46%，提高了 1.14%。

（2）研究了基于时频图特征融合的生猪咳嗽声识别方法。时频图能同时表达声音信号在时间和频率双重维度上的信息变化，因此，将原始声音信号转换为短时傅里叶变换和常数 Q 变换两种时频图，并在时频图基础上分别提取视觉特征和深度特征。1）为进一步增强对视觉特征的描述能力，通过改变（P，R）值提取不同图像分辨率下的局部二值模式，提出融合不同分辨率下的局部二值模式策略。同时，利用时频图颜色变化对方向梯度直方图特征的影响，提出融合 RGB 三通道和单通道下方向梯度直方图特征策略。结果表明，在多通道图像下融合方向梯度直方图特征，对生猪咳嗽声识别准确率达 93.98%，识别性能优于不同分辨率下的局部二值特征。2）为进一步挖掘声音时频域下的深度特征，构建了浅层卷积神经网络的特征提取模型，并结合该模型提出了单输入谱图的特征层融合和双谱图输入特征融合的两种架构，采用对位差值方法进行深度特征融合。结果表明，基于浅层卷积神经网络的生猪咳嗽声识别准确率优于 VGG16、VGG19 和 Resnet152 三种深度卷积神经网络，且模型计算时间远低于深度卷积神经网络，更适用于猪舍内少样本数据集下的生猪咳嗽声识别。与

中国知网 https://www.cnki.net

单输入谱图的特征层融合方法相比，双谱图深度特征融合方法对生猪咳嗽声识别性能更好，准确率达 94.51%，能够有效捕捉具有辨识度的舍内声音特征。

（3）研究了基于声学和时频图特征融合的生猪咳嗽声识别方法。首先，依据声学特征与时频图特征的互补性，结合多域特征的组合策略，提出了多域特征融合架构，并采用拼接融合、典型相关分析和平均集成决策三种融合方式进行对比分析。研究发现，声学特征与双谱图深度特征（Acoustic-TFRs fusion，A-TF）结合拼接融合方式识别生猪咳嗽声的准确率最佳，达到 97.57%，且模型耗时最短，表明该融合子集增强了舍内声音特征的表达能力，有效提高了生猪咳嗽声的识别精度。其次，通过降低生猪咳嗽声样本数量，增加非咳嗽声与咳嗽声的比值，将平衡数据集划分为轻度、中度及重度三个等级，构建了六组不平衡数据集。并将声学特征子集、双谱图深度特征以及融合后的 A-TF 子集在不平衡数据集上进行识别性能的对比分析。结果显示随着不平衡等级加深，A-TF 特征在六组不平衡数据集下均取得了最佳识别结果。尤其是在重度不平衡下，A-TF 的 F1 分数达到 90.36%，比声学特征和双谱图深度特征分别高出 8.89%和 8.31%。表明 A-TF 融合特征在数据倾斜程度加深的情况下展现出较强的鲁棒性，为猪舍内数据不平衡问题的研究提供了技术支撑。

（4）提出了一种混合集成学习的生猪咳嗽声识别算法。结合集成学习可以兼顾异构模型和同构模型之间差异性的特点，在保持基分类器性能稳定的前提下，设计差异化的多层基分类器组合，对基分类器输出结果进行二次采样和最终决策。在六组不平衡数据集上进行对比实验，该方法在六组不平衡数据集下识别性能均有不同程度的提升，在数据重度不平衡时，F1 分数提高至 92.19%，优于单一 SVM 算法和常规的数据平衡化算法。表明该方法可以克服单一算法的识别局限性，充分挖掘混合算法的优势，有效提高不平衡数据集下的模型整体的识别性能。

综上，提取多域特征并结合混合集成算法可以有效提高不平衡数据集下的生猪咳嗽声识别性能。本研究在一定程度上克服了不平衡数据集引起的精度下降的问题，对实现复杂猪舍声音环境下高精度的生猪咳嗽声识别具有一定的学术意义和应用价值，并为生猪群发性呼吸道疾病的早期监测提供了理论依据和技术支撑，为生猪健康养殖及精准化管理提供新思路。

关键词：生猪；咳嗽声识别；特征融合；音频检测；健康养殖；智慧畜牧

中国知网 https://www.cnki.net

Study on Recognition of Pig Cough Sound Based on Muti-domain Feature Fusion

Abstract

The modern pig farming industry is developing in the way of intensification, which is likely to induce pig respiratory diseases and to increase the pressure of pig disease prevention and control. As one of the main clinical symptoms of respiratory diseases in pigs, coughing has become a key indicator for monitoring of respiratory diseases. At present, pig cough monitoring is mainly conducted by manual inspection. However, the traditional monitoring method is not only time-consuming and laborious, but also difficult to achieve continuous monitoring and to miss the detection of disease in the early stage. Audio analysis technology has sufficient feasibility and technical advantages in detecting pig coughing sounds. For this reason, it is potential and effective to identify pig coughs from the sounds collected from commercial pig houses. It is of great importance to achieve the auxiliary early warning of herd respiratory diseases and thus reduce the infection rate of respiratory diseases in pig farms.

At present, the following issues exist in the application of audio technology to identify pig coughs: inadequate extraction of acoustic features in complex pig housing environments, lack of effective feature selection and fusion methods, and lack of research on pig cough recognition under unbalanced data sets. To overcome the above problems, this dissertation proposed a feature fusion method under different domains based on the extraction of traditional acoustic features and time-frequency representation features. Furthermore, a hybrid ensemble learning algorithm was proposed to achieve high-precision pig cough recognition under imbalanced datasets. The main work is as follows:

(1) Pig cough sound recognition method based on the fusion of traditional acoustic features was studied. Firstly, multiple traditional acoustic features in the time domain (root mean square energy and zero-crossing rate), frequency domain (spectral centroid, spectral flatness, spectral bandwidth, spectral roll-off, spectral contrast and spectral flux) and cepstrum spectral domain (Mel frequency cepstral coefficient, MFCC) of different sounds were extracted in pig barns. According to the correlation and difference between multiple acoustic features, a recursive feature elimination method based on XGBoost was proposed to realize acoustic feature selection. At the same time, feature interpretation based on XGBoost-SHAP method was used to deeply explore the correlation between features and its influence on recognition accuracy under different domains. A gridsearch method was used replace the traditional empirical determination of parameters to optimize the classifier and compare the performance of pig coughing sound classification under three different machine learning algorithms: support vector machine (SVM), K-Nearestneighbor

中国知网 https://www.cnki.net

algorithm (KNN) and random forest (RF). The results show that the time-domain features and cepstral domain features have stronger discrimination in the recognition of pig coughing sounds compared to the frequency domain features. The Mel frequency cepstral coefficients contributed the most to the model output. The acoustic feature fusion subset combined with support vector machine identified pig coughing sounds with an accuracy of 94.46%, an improvement of 1.14% compared to the Mel frequency cepstral coefficient in a single domain.

(2) Pig cough sound recognition based on the fusion of time-frequency representation features was investigated. Considering the compactness of information expression in both time and frequency dimensions, this paper further explores the two-dimensional time-frequency representation features were explored, including short-time Fourier transform (STFT) and constant Q transform (CQT). Then, the visual features and deep features of the time-frequency representations were further extracted. 1) To further enhance the description of visual features, the local binary patterns under different image resolutions were extracted by varying the (P, R) values. And the fused LBP under different resolutions was proposed. At the same time, the strategy of fusing the histogram of oriented gradient (HOG) features under three-channel and single-channel was proposed by using the effect of the colour channel of the time-frequency representation. The results show that the fusion of HOG under multi-channel images achieves an accuracy of 93.98% for pig cough recognition. 2) To further explore the deep features in the time-frequency domain, shallow convolutional neural network was constructed. Then, two feature fusion architectures based on single and bispectrogram input were proposed in combination with this model with the difference of element-wise method for deep feature fusion. The results show that the accuracy of pig cough recognition based on shallow convolutional neural networks outperforms that of three deep convolutional neural networks, VGG16, VGG19 and Resnet152. And the model computation time is much lower than that of deep convolutional neural networks, which is more suitable for pig cough recognition under small datasets in pig barns. Compared with the single-input spectrogram feature layer fusion method, the bispectrogram deep feature fusion method has better performance in pig cough recognition, with an accuracy of 94.51%. It can effectively capture the recognisable sound features in the barn.

(3) Pig cough sound recognition based on multi-feature fusion was investigated. First, for the balanced data set, fusion methods based on traditional acoustic features and time-frequency representation features were investigated to construct multiple fusion strategies based on three fusion architectures. Also, concatenation fusion, canonical correlation analysis, and decision fusion were applied in the three fusion architectures for further comparison and analysis. It is found that the combination of Acoustic-TFRs fusion (A-TF) achieves the best accuracy of 97.57% in identifying pig coughs, with the shortest time. It indicates that this fusion of feature subset can enhance the expression of sound features in pig house and effectively improve the recognition accuracy of pig cough sounds. Secondly, by reducing the number of pig cough sound samples and increasing the ratio of non-cough sounds by cough sounds, the balanced dataset was divided into

中国知网 https://www.cnki.net

three degree of imbalanced datasets: mild, moderate and severe degree of datasets. And six sets of imbalanced datasets were constructed under the three degrees. The three feature subset of acoustic features, deep features of bispectrogram and the fused A-TF subset were adopted for comparative analysis of recognition performance on the unbalanced dataset. The results show that as the imbalanced degree deepens, the A-TF features achieve the best recognition results on all six imbalanced datasets. In particular, the F1 score of A-TF reaches 90.36%, which is 8.89% and 8.31% higher than that of acoustic features and deep features of bispectrogram under severe imbalanced degree, respectively. It shows that the A-TF fusion features exhibit strong robustness under data skew, which provides technical support for the study of data imbalance problems in pig houses.

(4) A hybrid ensemble learning algorithm for pig cough recognition was proposed. Considering the differences between heterogeneous and homogeneous models among features, ensemble learning could be used to combine them together. Firstly, the method designed differentiated and multi-layer base classifiers for keeping the stable performance of the base classifiers. Secondly, it performed secondary sampling and final decision on the output results of base classifiers. Comparative experiments were conducted on six imbalanced datasets. The method shows different degrees of recognition performance could be improved under six imbalanced datasets. And the F1 score improved to 92.19% when the data was heavily imbalanced, outperforming both the single SVM algorithm and the conventional data balancing algorithm. It shows that the method can overcome the recognition limitations of certain algorithm, fully exploit the advantages of the ensemble algorithm, and effectively improve the overall recognition performance of the model under imbalanced data sets.

In summary, the extraction of multi-domain features and the combination of hybrid ensemble learning algorithms can effectively improve the performance of pig cough recognition in unbalanced datasets. To some extent, this study has overcome the problem of accuracy degradation caused by imbalanced datasets. Also, it is of academic significance and application value for achieving high accuracy pig cough recognition in complex pig housing sound environment. And it provides a theoretical basis and technical support for early monitoring of herd respiratory diseases in pigs. Overall, it provides a new idea for healthy pig breeding and precision management.

Key words: Pig; Cough sound recognition; Feature fusion; Audio detection; Healthy breeding; Smart livestock

Candidate: Ji Nan

中国知网 https://www.cnki.net

Specialty: Agricultural electrification and automation

Supervisor: Prof. Shen Weizheng

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景及意义

猪肉是我国消耗量最多的肉类，是家禽肉类消耗的 2 倍，牛羊肉的 4 倍，同时也占据肉类（猪，家禽，牛和羊）消耗总量的一半[1,2]。整体的猪肉消耗量仍在持续逐年增长，预计至 2029 年猪肉的总消耗量将达到 58277.44 千公吨。以上数据表明，我国对猪肉的巨大需求量正极大地推动着现代化养猪养殖业的发展。现代化生猪养殖业的主要特点是生产的集约化和规模化[3,4]。这两大特征有助于在固定的养殖范围内，增加生猪的养殖总量，从而提高生猪养殖场的经济效益。集约化养殖猪舍如图 1-1。在养殖方式加速转变的同时，猪场内环境的改变直接导致了生猪健康问题日益严重，尤其是呼吸道疾病的频发[5]。特别是我国北方地区秋冬季节早晚温度差异明显，为降低夜间低温对密闭式养殖环境下生猪健康的影响，养殖场通常选择不通风或者减少通风次数，导致了舍内氨气等有害气体浓度升高，恶劣的环境条件对猪只呼吸道产生刺激，极大地增加了生猪疾病的防控压力[6]。生猪的呼吸道疾病不仅降低了动物福利，也增加了动物抗生素的使用，从而影响猪肉质量。与此同时，呼吸道疾病的传染性强，发病率高，极易导致生猪死亡率的增加，对生猪养殖业造成巨大冲击。因此，有效监测猪舍内的生猪健康状况，实现生猪健康养殖，对促进高质量养猪业发展至关重要。



图 1-1 生猪集约化养殖方式[4]

Figure 1-1 Intensive environment for pig farming

猪舍内的声音环境较为复杂，不同状态下的生猪会发出不同种类的声音，这些声音反映生猪的健康状况[7]。其中，咳嗽是生猪呼吸系统疾病的主要症状之一，已被证明与呼吸系统疾病具有极高的相关性[8]。常见的生猪呼吸道疾病鉴别诊断情况如表 1-1，根据疾病的种类，分别从发病日龄、发病季节及临床症状三个主要方面进行鉴别区分。由表 1-1 可知，咳嗽声是生猪常见呼吸系统疾病临床症状的共有特征之一，已作为监测呼吸道疾病的关键性指标。

传统的健康监测方式是由兽医或猪场驻点的工作人员定期对猪的身体状况进行判定，包括猪舍内是否存在咳嗽声以及咳嗽声是否由呼吸道疾病引起。传统生猪监测方式具有简单且易于执行的优点。然而，其弊端同样明显，传统方式存在很强的主观性，极大的依赖于检测人员的个人技术、知识储备和工作经验，在一定程度上增大了检测误差[9]。此外，工作人员一般在相对固定的时间区间对舍内的生猪进行巡视检测，这种传统的监测方式不仅费时费力，

中国知网 https://www.cnki.net

且难以完成连续监测，极易发生漏检的情况，因而错过疾病的早期筛查阶段。所以，仅依赖于传统的人工检测方式难以实现对生猪呼吸道疾病的早期预警。当前，随着声音信号处理、图像处理及人工智能等相关计算机技术的快速发展，传统畜牧业正面向智慧畜牧加速转型。现代信息技术正逐步投入畜牧养殖中，以智能化的方式对动物生产过程进行监测、建模和管理。其中，音频分析技术在智能化养殖中应用日益广泛[10]。

表 1-1 常见生猪呼吸道疾病鉴别

Table 1-1 Differential diagnosis of common pig respiratory diseases

疾病名称	发病月龄	发病季节	临床症状
猪流行性感冒[11]	不同月龄	冬春多发	初期为干咳，后期为持续性咳嗽，食欲减退
猪蓝耳病[12]	2-4 月龄	冬春多发	咳嗽，呼吸困难，传染率死亡率高
猪气喘症[13]	1.5-3 月龄	冬春多发	咳嗽，伴随明显腹式呼吸，后期痉挛性咳嗽
猪肺疫[14]	不同月龄	夏秋多发	咳嗽，呼吸困难，流鼻涕，初便秘后腹泻
传染性胸膜肺炎[15]	3-5 月龄	夏秋多发	间歇性咳嗽，呼吸困难，腹泻和呕吐
猪瘟[15]	不同月龄	无季节性	咳嗽，呼吸增快

利用该技术对猪舍内声音监测的一大优势是其具有非侵入性[16]。通常情况下，声音监测设备被安装在猪舍内且距离猪身体有一定的距离，从而降低和避免猪只产生应激反应。此外，声音监测具有连续性，可对猪舍内声音进行全天实时监测[17]。同时，音频监测对光线和天气条件等并不敏感，且不受目标遮挡影响，舍内声音可在生猪舍内存在一定障碍物的情况下被监测和记录。因此，音频分析技术作为猪只监测方式，在生猪智能化养殖过程中具有充分的可行性。

利用音频分析技术提取声音特征，并对目标声音进行识别已广泛应用于人类语言环境及其他动物声音领域，然而针对生猪叫声特征的研究却相对较少。研究表明，不同物种的声音特质之间存在本质区别[18]，即不同的生物声音很大程度上决定了声音的特征不尽相同[19]。即便是特定物种的相同个体，尽管相同类型声音的发声原理相同，但在不同外界环境和生理情绪状态的影响下，所发出的声音也可能存在着较大差异。生猪的咳嗽声，其发声原理均为生猪收到外界条件刺激或情绪触发，呼吸道声门在短时间内突然收紧，大量肺内气体快速冲出声门缝隙释放压力而产生的声音[20,21]。咳嗽涉及整体呼吸道的反射，尽管发声原理相同，但是引起生猪咳嗽的诱因可能大不相同，例如流感引发的湿咳或猪舍环境变化引发的干咳等。由于引发咳嗽的诱因不同，其所呈现的声音信号也存在着范围较大的频率变化和特征差异[22]。因此，基于复杂难辨的客观情况，亟需优化猪舍内声音特征提取及分析手段，通过从复杂环境中捕捉最具有代表性的声音特征以实现对生猪咳嗽的精准识别，对生猪群发性呼吸道疾病的辅助预警，进而降低猪场内的呼吸道疾病感染率具有十分重要的意义，同时为后期进一步实现猪场的智能化在线监测和管理提供有效的技术支持。

综上所述，对复杂猪舍环境下的生猪咳嗽声进行充分的信息挖掘和提取十分必要，这直接影响生猪咳嗽声识别性能。而生猪咳嗽声的识别可为后期开发生猪咳嗽声实时监测和预警提供技术支持，对及时判定生猪健康状况以及进一步提高生猪生产效率等有重要的现实意义[23]。相比于畜牧养殖发达国家，我国生猪养殖技术在信息化和智能化应用上起步较晚，目

中国知网 https://www.cnki.net

前尚处于初期发展阶段[24]。距离达到精准畜牧业的目标仍有一段路程，需要投入更多的探索和尝试，加深基础理论技术研究并在猪舍实地环境下进一步实验，从而提供适合我国生猪产业可推广的理论依据和技术支撑[25]。

本研究在国家自然科学基金项目《生猪异常状态与声学感知模型构建及预警方法研究》（编号：32172784）以及财政部和农业农村部国家现代农业产业技术体系（编号：CARS35）资助下完成。

1.2 国内外研究现状

音频信号识别是指从声音中提取特定的特征，并利用这些特征来区分声音的类别。在不同应用场景及研究领域下，采用的特征提取方法和识别算法并不相同[26]。利用音频分析技术对生猪咳嗽声的识别研究始于二十一世纪初期，研究初期是在实验室猪舍环境可控的条件下，通过人工诱导促使生猪发出咳嗽声，进而完成对生猪咳嗽声的识别。在证实可以从各种声音中完成猪的咳嗽分类这一结论后，相关研究被转移到商业猪场环境中进一步展开。基于前人研究对生猪咳嗽声识别领域的贡献，2015 年至今[27]，国内关于生猪咳嗽声识别的相关研究逐步深入，并取得了一定的成果，生猪咳嗽声识别相关研究得到了快速的发展。如图 1-2 所示，生猪咳嗽声识别主要包括三个部分：数据获取、声音特征提取以及声音识别。

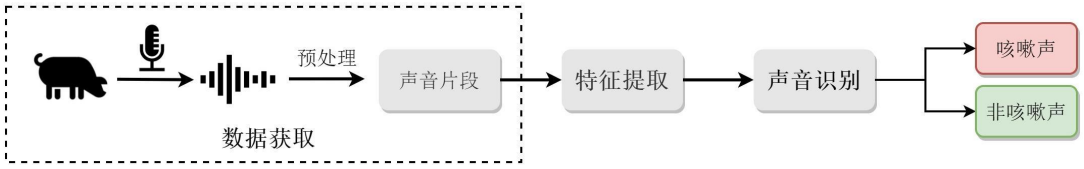


图 1-2 生猪咳嗽声识别流程图

Figure 1-2 Flowchart of pig cough recognition

数据获取是通过麦克风传感器等设备对猪舍内的声音信号进行采集并存储，并对原始声音数据进行相应的预处理以及声音标记；在数据获取的前期工作结束后，进一步从声音信号中提取有辨识度的声音特征，这一步骤对于实现高精度识别具有关键作用；最后，利用相应的识别算法对数据进行训练和分类。

基于音频分析技术的生猪咳嗽声识别研究已成为当下的研究热点，下面本文着重从生猪咳嗽声的特征提取、识别方法以及生猪叫声特征融合三部分阐述当前国内外研究现状。其中，生猪叫声是指在特定的情感环境或生理状态下生猪发出的声音[28]，包括但不仅限于生猪咳嗽声。一般情况下，生猪叫声的相关研究是基于不同的猪舍环境下展开，已考虑到不同的声学环境对研究的影响。因此，生猪叫声特征融合的相关研究提供了重要参考和借鉴意义。

1.2.1 生猪咳嗽声特征提取研究现状

特征传递声音的相关信息，体现不同声音间的差异性。声音特征的表现形式主要分为两种：一种是从声音信号中提取一维的声音特征，包括提取声音信号的时域、频域和倒谱域的特征[23,29]；另一种是将声学信号转为由声音的时间和频率构建的二维时频图[17,30]。不同域下

中国知网 https://www.cnki.net

的特征可以反映同一段声音的不同信息，因此对于多域特征的研究可以明确不同声音特征的表达能力和鉴别能力。

随着大数据时代下研究对象数据量的增加，特征提取带来了特征维度的增长。加之声音信号特征存在一定的稀疏性，所以将特征降维技术应用在特征提取过程中是十分必要的。降维技术通过压缩一段音频的表达内容，从而以更加紧凑的方式最大程度地体现声音的特性[31]。因此，该部分从特征提取和选择的角度出发，探究生猪咳嗽声特征提取研究过程，如图 1-3 所示。

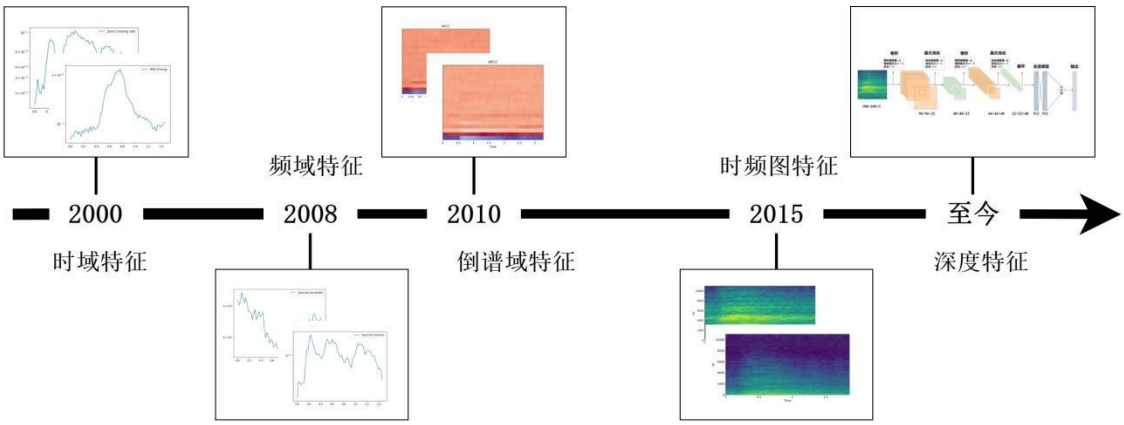


图 1-3 生猪咳嗽声特征提取发展过程

Figure 1-3 Evolution of feature extraction methods of pig cough sounds

时域特征是基本和简单的一维声学特征，它代表了信号在时间方面的变化。时域特征在音频分析领域的发展可以追溯到二十世纪五十年代[32]。直到二十一世纪初，比利时鲁汶大学展开了针对生猪咳嗽声识别的连续研究[33-35]，深入分析了生猪咳嗽声的时域特征，包括声音的持续时间、振幅、过零率以及基于能量的特征。持续时间是一种基于节奏的特征，它是在特定时间内存在一定规律的声音表示[36]。均方根能量是基于声音能量表达的特征之一，可用于测量声音的响度[37]。Ferrari 等人对比了生猪肺部感染引起的咳嗽声和吸入柠檬酸引起的咳嗽声，结果表明健康动物和感染动物咳嗽声的均方根值和持续时间存在显著差异。由于感染和炎症导致呼吸道阻塞，被感染的生猪咳嗽持续时间比健康状态下咳嗽时间更长，且健康猪咳嗽的均方根值高于感染性猪咳嗽的均方根值[33]。另一个基于能量的特征称为短时能量。由于声音信号是非静止的，即随着时间动态变化，因此，常通过基础的分帧方法将非平稳的声音信号转化为短小独立的准平稳信号。在分帧基础上，计算每一帧的短时能量[38]。Van 等人采用短时能量从连续的声音段中标记出单独的猪咳嗽声片段[39]。从商业猪舍环境下提取的声音不可避免的包含一定的噪声，而短时能量计算的是给定声音的时域信息，这也意味着短时能量特征也包含噪声。由于短时能量在噪声强度较高的情况下，其所计算的声音信号并不能准确的表示目标声音。因此，在实际应用中，常采用与过零率结合的双门限端点检测法对连续声音进行分割。过零率衡量的是在一定时间区间内一段声音信号穿过零值的次数，也是检测一段声音中的有声段与无声段的有效方式[40]。张振华等人采用短时能量和过零率的双门限端点检测方法，实现了对连续猪舍声音的检测，提取出猪的咳嗽声、打斗声、抽搐声以及饥饿声[20]。

中国知网 https://www.cnki.net

功率谱密度常被应用于早期生猪咳嗽声的频域特征提取。Van Hirtum 等人最初是采用功率谱密度从实验室的背景噪音中识别出由雾化柠檬酸引起的健康猪的咳嗽声[41]。验证了通过提取咳嗽声的功率谱密度区分咳嗽声的可行性之后，他们改变实验室内的氨气、灰尘和温度三项环境参数，再进一步验证咳嗽声在不同环境下的识别情况，结果表明功率谱可以从这三种环境下识别咳嗽声[42]。随后，Exadaktylos 等利用功率谱密度完成了健康猪的咳嗽声和感染疾病后发出的咳嗽声以及其他猪叫声的识别任务[43]。比利时研究学者在完成实验室条件下对猪的声音进行基础的分析后，Guarino 等学者在此基础上引入了频域特征，包括峰值频率和能量包络，并从实验室环境下迁移到商业猪场进行实验测试，进一步区分猪咳嗽声和猪舍内其他声音[44]。结果发现能量包络特征受噪声影响较大，易被环境噪声污染，当噪声信号的能量幅值高于目标信号的幅值，目标信号则不易被能量包络所检测[45,46]。而峰值频率作为一个信号的最大功率的指标，能较好地规避环境噪音干扰，Guarino 等研究结果表示感染猪咳嗽的平均峰值频率远低于健康猪，采用峰值频率可以有效区分感染猪和健康猪的咳嗽声[35]。

除了常用的时域和频域特征，倒谱域特征常被应用于猪舍内咳嗽声的分析和提取，包括基于梅尔频率倒谱系数和线性预测倒谱系数。梅尔频率倒谱系数（Mel Frequency Cepstral Coefficient，MFCC）是一种紧凑的特征表示，通常采用较低维度即可捕获一段声音的绝大部分相关信息。MFCC 由 Davis 和 Mermelstein 在 1980 年提出，已被广泛应用于音乐类型分类、语音增强、区分环境声音和动物声音识别等领域[47]。在对猪咳嗽声特征提取和识别中，Chung 等人采用 12 维 MFCC 特征向量应用于多种生猪消耗性疾病的研究中，通过提取商业猪场内的多种生猪咳嗽声的 MFCC 特征，对不同的生猪消耗性疾病进行分类[48]。Giesert 等人提取了前 20 个 MFCC 系数作为特征向量，用于区分生猪的感染性咳嗽[49]。为了获取更多的特征信息，熊梓奥在提取 MFCC 的过程中去掉离散余弦变换得到梅尔频谱系数识别生猪咳嗽声，并与 MFCC 的识别结果进行比较[50]。结果显示梅尔频谱系数的抗噪性较低，受噪声影响较大。随着特征维度的增加，降维技术逐渐成为特征提取过程中的必要处理步骤，其中主成分分析（Principal Component Analysis，PCA）是常用的降维方法，其核心是计算每一维特征的贡献率，以此对整体的数据进行降维。一般默认情况下，选择的特征累积贡献率达到 85%以上[51]。如 Wang 等采用 PCA 对猪舍提取的声音进行降维，设定 85%的累积贡献率可以提供足够的特征信息[52]。张海林对特征贡献率在 85%到 95%之间的特征进行分类结果对比，最终选择了 90%的贡献率作为 PCA 降维标准[11]。黎煊等通过计算特征参数维数与贡献率的关系，选择贡献率达 98.01%的特征参数维数作为生猪咳嗽声的代表特征[53]。

基于上述研究学者对生猪舍内声音的分析后，得出猪舍内不同声音间的特征存在较大差异。同时，时域特征和频域特征分别提供了声音在时间和频率尺度的变化，且只能体现单一维度下的特征信息。针对这一问题，时频图的表现形式对单一域上信息差异进行了弥补，并提供了时间和频率双重维度的变化。时频图是另一种表达声音特征的方式，其转换过程是将一维的音频信号通过不同的计算方式转换为二维的时频表示。这种方式有助于观察一段声音下的频率连续性以及趋势变化[54]。其中，线性短时傅里叶变换（Short-time Fourier transform，STFT）和梅尔短时傅里叶变换在生猪的声音识别中是常用的两种时频变换方式。其应用方式主要体现在以下两个方面：一是将时频图与深度学习模型相结合进行端到端的目标识别。

中国知网 https://www.cnki.net

这种端到端的方式，替代了手工选择特征的过程。例如，Yin 等人将猪舍内声音转换为 STFT 时频图，并结合 Alexnet 模型完成对生猪咳嗽声的分类[55]。HONG 等人采用 MnasNet 深度架构对生猪咳嗽声的 STFT 时频图进行识别[56]。耿艳利等将生猪咳嗽声、尖叫声和哼叫声转换为梅尔谱图应用到卷积神经网络（Convolutional Neural Network，CNN），并实现对这三类异常声音的识别[57]。另一种方式是，以深度学习模型作为特征提取器，提取时频图中的深度特征，再结合机器学习算法对时频图中获取的深度特征进行识别。在 Lee 等人的研究中，使用一个六层的 CNN 提取深度特征，并输入多层感知中进行分类[58]。在 Shen 等人的研究中，提取单层 CNN 特征，并将其与支持向量机（Support Vector Machine，SVM）分类器结合用于猪咳嗽的识别，结果显示该方法可以有效识别生猪咳嗽声[59]。综上，生猪咳嗽声特征提取相关研究受到了国内外学者的广泛关注，前人的研究为后续的生猪咳嗽声特征提取奠定了充分的研究基础，且多种特征已被用于提高生猪咳嗽声的表征能力。然而，从猪舍内提取的声音特征来自不同域下的多种声音特征，且不同特征参数识别结果具有一定差异。因此，对猪舍内声音特征进行更加深入的研究是当前的一个重要研究方向且具有较大的研究潜力。

1.2.2 生猪咳嗽声识别算法研究现状

音频识别是通过发现特征与特征之间的关联，将不同的音频特征区分成不同类的过程[60]。该过程主要包含两个阶段：一是分类算法尝试推导一个适用于目标训练数据组的模型，将不同类别特征作为音频数据集其他变量的函数；二是将先前推导的模型应用于新的未识别音频数据集，以确定每条录音的对应类。近年来，许多声学模型已被开发并应用于分析和识别猪的声音。其中主要涉及的方法包括数据统计分析、机器学习以及深度学习。虽然深度学习隶属于机器学习领域，但目前已将其作为独立研究模块。

统计分析是收集、探索和呈现大量数据以发现潜在规律和趋势的科学方法[61]，也是计算变量之间变化的经典方法。早期对生猪咳嗽声的分类基于统计方法分析，用来完成对猪的声音特征的基本研究。例如，单因素方差分析（ANOVA）是最常使用的统计分析方法[62]。已有多位学者采用单因素方差分析了包括生猪咳嗽声在内的舍内多种声音的时域和频域特征，来对不同声音进行分类和识别。其中，比利时学者使用单因素方差分析实现了患病猪咳嗽声和健康猪咳嗽声的识别分类[33,35]。随后，方差分析被韩国学者们进一步用于区分猪消瘦病[63]。其结果显示不同病毒引起的咳嗽声在音调强度上有明显差异。但该方法的一个局限性在于其适用性往往受到实验测试期间条件的限制。例如，ANOVA 要求相关变量在各组中正态分布，然而，在解决复杂声音分类问题时，常忽略假设数据分布，直接将其用于预测[51]。相比之下，机器学习为经典统计学中的数据建模技术提供了补充，并已成为处理复杂数据集的理想方法[51]。

机器学习在许多研究领域都表现出卓越的性能[64]，并已有多种机器学习算法被应用到生猪咳嗽声识别领域。研究初期，模糊 C 均值聚类被用来区分咳嗽声和非咳嗽[65]，通过该方法可以区分在不同的氨气、灰尘和温度下识别咳嗽与非咳嗽声[42]，并对疾病引起的咳嗽声和其他声音进行分类[43]。SVM 的核函数包含线性和非线性两大模式，使它能够被灵活地

中国知网 https://www.cnki.net

运用于猪叫声识别的各个领域。Lee 等基于 SVM 算法实现了对生猪消耗性疾病的检测[66]。Wang 等结合 SVM 实现了对不同空气质量下咳嗽声识别[52]。20 世纪 80 年代，学者们利用 HMM 实现了语音识别[67]。随着语音技术持续发展，2011 年开始被引入生猪咳嗽声研究中，Giesert 等首次将 HMM 用于区分不同病毒感染的猪咳嗽声[49]。近年来，国内学者张苏楠[68]、刘振宇[27]、龚永杰[69]均证明了 HMM 在生猪咳嗽声识别的可行性。机器学习的一大优势是灵活性强，对于特征选取和设定参数的准确性也提出了更高的要求[70]。研究人员往往需要对输入特征投入大量调试工作，以得出理想的预测结果，导致对机器学习算法的选择具有一定的局限性[71]。

深度学习是使用多层神经网络来进行机器学习的方法[72]。神经网络由大量被称为神经元的处理元素组成，通过神经元之间的相互作用共同解决音频数据识别问题。神经网络技术已被应用于音频数据模式的挖掘，并在原始数据中自动提取特征方面表现出巨大的潜力，经过不断地改进与发展，目前已逐步应用到猪舍内不同声音的研究中。早在二十世纪初，Moshou 等采用概率神经网络和多层感知机完成了生猪咳嗽与非咳嗽的二分类研究[73]，并实现了咳嗽声、金属声、呼噜声及背景噪声的四分类任务[74]。随后，引入和改进深度信念网络和 BP 神经网络，实现了猪咳嗽声的识别[75,76]。彭硕等在 HMM 基础上，引入深度神经网络（Deep Neural Network，DNN），构建 DNN-HMM 模型用于识别猪舍内产生的吃食声、发情声、病猪喘气声、嚎叫声以及哼哼声等各类声音[77]。深度神经网络的优点在于强大的模式识别能力，已成为众多学者开展不同种类动物声音研究的热门方法[78–80]。宋航等改进了 DenseNet 深度神经网络模型，采用 DenseNet-121、DenseNet-169 和 ResNet-34 三类神经网络分别对猪咳嗽声识别性能进行对比分析[81]。涂鼎将舍内不同声音转为 STFT 时频图并对典型的 CNN 模型 Alexnet 进行了微调，用以识别生猪的咳嗽声[82]。虽然 CNN 被证明可以有效识别声音的时频图，但由声学信号转为时频图的过程中会引入噪声等其他冗余特征信息，导致 CNN 识别性能受到干扰。为此，耿艳利等学者将注意力机制引入到 CNN 中进行优化，加强舍内声音信息的有效表达，进而完成对生猪咳嗽声等异常声音的识别[57]。针对舍内声音信号分帧而产生的相邻帧间的重叠性问题，沈明霞等人引入深层 CNN 模型和前馈序列记忆神经网络降低分帧预处理过程中产生的冗余性信息[83]。此外，对于递归神经网络（Recurrent Neural Network，RNN）模型以及长短期记忆网络、双向长短期记忆网络和门控循环单元等递归神经网络的变体模型也已被应用于猪咳嗽的识别[75,84,85]。应用深度学习模型可有效提升生猪咳嗽声的准确识别率，但由于深度神经网络依赖于大量数据对模型进行训练和修改，导致模拟和计算过程变得更为复杂。因而需要更大的计算能力和更高的硬件要求，这已成为限制猪舍内声音识别研究投入实际应用的因素之一。为了解决这个问题，研究人员尝试采用轻量级模型对生猪的声音进行分类。韩国学者 Hong 等采用 MnasNet 模型，以及国内学者苍岩等利用 MobileNetV2 的轻量级模型被用来对患有不同疾病的生猪叫声进行分类，其结果证明了轻量级的模型也能满足咳嗽声识别的需求[56,86]。综上所述，机器学习仍然是一种具有普适性及发展潜力的声音识别方法。

值得注意的是，针对生猪咳嗽声识别的研究，以往研究大多均是基于平衡数据集研究，尚未对不平衡数据集问题进行探索和讨论。然而，生猪咳嗽声识别问题可以看作是典型舍内不同声音类别的数据不平衡问题。已有研究表明杂交生猪在育肥阶段更易感染支原体肺炎

中国知网 https://www.cnki.net

[87]，而猪肺炎支原体被认为是引发猪呼吸道疾病的重要病原体，其较高的感染率极易导致生猪的产量降低。该病毒感染下的流行病学特点体现在育肥猪的急性发病情况较少，由于病毒在低温环境下存活时间长，导致生猪大多出现慢性或隐性症状，其临床特征为偶尔或者间歇性强度不等的咳嗽[88]。这一特性为早期监测病症带来了不小的挑战。由于生猪叫声是一种日常行为，猪舍环境下的声音种类较多，包括来自环境的声音以及生猪自身行为发出的声音[89]。因此，在复杂猪舍环境下针对生猪咳嗽声识别问题，极易出现咳嗽声与非咳嗽声样本数量不平衡的问题。临床咳嗽声的强度和数量受多种因素影响，如猪舍内环境条件和病毒感染严重程度等[90]。同时，Pessoa 等研究表明咳嗽声频率对直接评估呼吸道疾病是可行的，通过咳嗽声的水平差异可以提供生猪健康状况的客观信息[91]。总的来说，基于非平衡数据集下的生猪咳嗽声识别研究对早期发现和监测呼吸道疾病十分必要，且具有重要的研究参考价值。但目前，在生猪咳嗽声识别的相关研究鲜有提及。当前动物相关研究领域已针对类别不平问题展开了一定的研究，这些研究为生猪咳嗽声识别领域提供了重要参考价值。

类别不平衡是指数据集中样本类别的数据规模存在一定的倾斜，其中目标识别样本为整个数据集中的少数类样本，其余样本为多数类样本。目前，针对动物不平衡识别问题的研究大多数集中在数据层面的平衡化处理。常用的策略一般包括两种，第一种是下采样，删除多数类数据，使其更接近少数类的样本数[92]。下采样方法操作较为简单，通过减少数据集大小来降低实验时间以获得较快的运算速度；然而当部分样本从多数类中移除时，原数据集中可能包含的有用信息极易丢失[93]。Li 等人收集了奶牛在摄入草类饲料时产生的不同咀嚼声，针对声音种类的不平衡问题，其采用随机重组下采样的方式，进行平衡数据和不平衡数据的对比实验分析，并通过该方法提升了分类性能[94]。Anders 等人采用下采样算法解决黑猩猩在栖息地存在严重不平衡叫声的情况，有效的提高了叫声识别的性能[95]。第二种是上采样，通常是通过重复随机选择目标类别样本，使少数类的规模更接近多数类的规模。Zhang 等人收集了绒猴十种不同声音的录音，由于十种声音存在数据不平衡情况，为此采用随机上采样算法构建了平衡数据集以进行声音分类对比[96]。相关研究表明数据不平衡增加了建立可靠分类器的难度，因此研究人员针对平衡化算法不断被改进。例如 Chawla 等人提出了合成少数类上采样技术（Synthetic Minority Over-sampling Technique，SMOTE），其核心是沿着少数类样本与其所选择的临近样本之间，生成新的合成样本，这一算法是典型的上采样算法[97]。Sheryn 等人采用 SMOTE 算法平衡不同蛙类的不同叫声样本，结果表明基于 SMOTE 的 SVM 算法对不平衡的四类声音数据样本的在分类精度上得到了一定的提升[98]。Rafael 等采用 SMOTE 算法平衡肉牛放牧过程中的不同行为样本，结果显示采用平衡化算法与随机森林结合下可用提高对行为识别的总体精度[99]。但是由于原始的 SMOTE 易产生大量相同的样本，从而导致重新合成的新样本集质量有所下降，Borderline-SMOTE 在 SMOTE 算法基础上进行改进，选择贴近多数类样本的少类样本进行插值，以获得更清晰的样本间边界[100]。随后，Jin 等采用 Borderline-SMOTE 算法对数据集进行预处理解决生猪行为不平衡问题，其结果表明 Borderline-SMOTE 比传统的随机下采样算法取得的结果更优[101]。对不平衡数据问题采用基于数据层面的平衡化处理，在一定程度上降低了总体识别精度虚高的情况，同时提高了对目标少数类样本的识别精度。综上，针对不平衡问题带来的猪舍内生猪咳嗽声识别准确率下降的问题，还有待进一步研究。

中国知网 https://www.cnki.net

1.2.3 生猪叫声特征融合研究现状

特征融合是在融合前对原始信号所包含的信息进行抽取，对抽取的不同特征向量进行综合分析与选择，最后选择不同融合方式进行处理[102]。声音特征融合是指针对原始声音信号提取不同的特征信息并进行优化组合的过程。由于单一的声音特征信息难以对复杂猪舍环境下的生猪咳嗽声进行有效表达，不同学者探索和采用不同融合策略，通过增加声音特征的辨识度，以提高不同融合方法下的识别精度。

最常用的融合方式是直接对提取的声音特征进行拼接，并对组合后形成的特征子集进行识别。Liao 等从二维谱图特征角度出发，将色度、频谱对比度和色域组合为合成特征，再与 MFCC 和 Log 梅尔语谱图组合，形成全新的二维谱图作为生猪叫声的特征表示，用于识别家猪呼噜声、喂食声、饥饿发出的咕噜声以及惊吓发出的尖叫声[103]。张苏楠等提取猪舍内猪打架时发出的声音、饥饿状态下发出的声音、吃料声音、饥饿时看见食料发出的声音、咳嗽声、吃料呛住的声音以及小猪被压和抢奶的 8 种声音，采用线性预测分析系数（Linear predictive cepstral coefficient，LPCC）和 MFCC 拼接的方式组合成特征参数子集，用于猪舍内 8 种状态下声音的识别[68]。在此基础上，张苏楠进一步引入耳蜗滤波倒谱系数，将其与 MFCC 以及 LPCC 分别拼接组合成不同特征参数，完成对生猪咳嗽声和惊骇声的识别[4]。韩磊磊等从猪舍内打斗声、咳嗽声、喷嚏声、饥饿声和呛水声中，提取梅尔频率倒谱系数、短时能量和短时过零率并拼接特征，并改进其复合的特征参数，进而对这五种异常声音进行识别，结果表明组合特征优于单一特征的识别结果，其中对生猪咳嗽声识别结果最佳[104]。在倒谱域特征提取过程中，标准的倒谱域特征仅能反映声音的静态特性。为了反映声音的动态特征，研究学者将其一阶或二阶系数添加并组合为改进的声学特征。例如，王文静提取短时能量、过零率、频谱通量、频谱质心、频谱延展度以及 MFCC 及其差分特征进行组合，实现对生猪正常、受惊吓以及喂食声的识别[105]。Wang 等和龚永杰等人从每个咳嗽声样本中计算出 12 维原始系数和 12 维一阶差分系数，将二者结合最终得到 24 维的 MFCC 用于每个声音样本的特征代表，最后实现了不同猪舍条件下咳嗽声的有效识别[52,106]。此外，Zhao 等人将原始的 13 维 MFCC 和在 MFCC 提取一阶以及二阶差分系数的进行组合，最后得到 39 维 MFCC，完成对连续猪咳嗽声的识别[107]。张振华等人提取了包含 12 维原始的 LPCC 和 12 维一阶差分的 LPCC 系数，利用融合后的 24 维 LPCC 特征识别生猪干咳、湿咳和非咳嗽声[108]。

另外一种是采用特征融合理论进行计算，从多维特征向量进行筛选，保留一部分特征作为代表性的特征子集或采用特征变换形成一组新的特征表示。邵睿提取 MFCC 和 LPCC 并组合二者的差分特征，并采用 Fisher 特征选择方法对特征参数进一步选择，构建新的融合特征对生猪咳嗽声、发情声、嚎叫声、哼哼声以及进食声进行分类[109]。Cordeiro 等提取生猪叫声信号的能量、振幅、持续时长等 10 种特征后，采用 Wrapper 方法，先用信息增益法排序，再根据特征相关性进行特征选择[110]。Tallet 等提取猪仔的叫声特征，包含振幅、峰值、能量值等八种特征变量，并采用相关系数对特征变量进行特征选择[111]来区分猪仔的叫声类型。综上，不同融合方式对生猪咳嗽声识别影响的研究相对比较匮乏，生猪咳嗽声的特征融合策略和方式还需要深入探索，需要进一步加强对生猪咳嗽声融合方法在识别领域下的研究。

中国知网 https://www.cnki.net

1.3 存在的问题与研究内容

1.3.1 生猪咳嗽声识别存在的问题

针对生猪咳嗽声识别这一问题的探索和研究，国内外学者已取得了一定的研究进展和成果。然而，为了探索猪舍内声音数据包含的特征信息，充分挖掘和利用多域特征的差异性和互补性，当前的研究仍然存在一些问题亟待解决。

（1）尚未充分挖掘和提取声音特征有效信息

由于生猪的不同发声之间存在一定的特征相似性，这一点为声音识别带来一定的挑战。目前，现有工作尚未对猪舍环境下的生猪咳嗽声特征进行充分的挖掘和提取。猪舍内声音信号的特征提取较为单一，声音特征表达能力较弱，提取的声音特征所包含的信息存在一定的局限性，造成了对声音信号前期处理的片面性，极大地影响后期生猪咳嗽声的识别精度。因此，需要从多域特征的角度提取猪舍内的声音信息并探究特征间的相互作用，以增加声音特征的辨识度。

（2）缺乏有效的特征选择和融合方法

多域特征间存在一定的互补性，这一特性为提高复杂猪舍环境下生猪咳嗽声的识别精度，提供了一定的依据。然而当前的相关研究较少，缺乏对不同特征的有效选择和融合。特征种类的随机选择不可避免地对模型的识别精度和时间成本带来一定的影响。因此，需要对不同特征融合策略以及特征间融合方法进行对比和分析，以探索不同融合特征子集对模型识别精度的性能影响以及贡献程度。

（3）缺少不平衡数据集下的生猪咳嗽声识别方法研究

在复杂猪舍环境下，与获取非咳嗽声样本相比，获取生猪咳嗽声样本难度更大，往往产生咳嗽声和非咳嗽声样本不均衡的问题。而针对不平衡数据下的生猪咳嗽声识别对实现生猪呼吸道疾病的早期监测具有重要意义。目前，生猪咳嗽声识别研究大多基于平衡数据集，而对于非平衡数据集的研究较少。因此，构建舍内音频不平衡数据集，并在此基础上实现生猪咳嗽声有效识别并进一步提升识别精度，是目前亟待解决的关键问题。

1.3.2 论文主要研究内容

针对上述存在的问题，本文从多域特征融合的角度作为切入点，以提高面向非平衡数据集下的生猪咳嗽声识别精度为研究目标，展开生猪咳嗽声识别的相关研究。传统声学特征是从音频数据中手工提取的基于特定公式计算的原始特征，而时频图特征是通过将音频数据嵌入到适当特征空间来进行特征学习的方式。基于二者对声音特征的不同表达，首先分别研究传统的声学特征和时频图特征的选择与融合方法，充分挖掘和提取生猪舍内声音的有效信息；其次，针对多域特征如何选择和融合的问题，提出多种传统声学特征和时频图特征融合策略和融合方式；在上述研究的基础上，研究非平衡数据下生猪咳嗽声识别方法，以提高模型的泛化能力。主要研究内容概况如下：

（1）研究基于传统声学特征融合的生猪咳嗽声识别方法。首先，提取猪舍内不同声音

中国知网 https://www.cnki.net

的多种传统声学特征，包括时域（均方根能量和过零率）、频域（频谱质心、频谱平坦度、频谱带宽、频谱滚降度、频谱对比度和频谱通量）和倒谱域特征（梅尔频率倒谱系数）。依据多种声学特征间的相关性及差异性，基于 XGBoost 的循环递归特征消除方法实现声学特征选择，同时，采用 XGBoost-SHAP 方法进行特征解释，探究不同域下特征间的关联及其对识别精度的影响。最后，采用网格搜索方法替代传统的参数经验判定，进而优化分类器，对比支持向量机、K 邻近算法和随机森林三种不同机器学习算法下的生猪咳嗽声分类性能。

（2）研究基于时频图特征融合的生猪咳嗽声识别方法。时频图能同时表达声音信号在时间和频率双重维度上的信息变化，因此，将原始声音信号转换为短时傅里叶变换和常数 Q 变换两种时频图，并在时频图基础上分别提取视觉特征和深度特征。1）为进一步增强对视觉特征的描述能力，通过改变（P，R）值提取不同图像分辨率下的局部二值模式，并融合不同分辨率下的局部二值模式，提出融合不同分辨率下的局部二值模式策略；同时，利用时频图颜色变化对方向梯度直方图特征的影响，提出融合 RGB 三通道和单通道下的方向梯度直方图特征策略。2）为进一步挖掘声音时频域下的深度特征，构建浅层卷积神经网络的特征提取模型，并结合该模型提出单输入谱图的特征层融合和双谱图输入特征融合的两种架构；并将浅层卷积神经网络与迁移学习下的深度神经网络模型进行对比和分析；针对深度特征融合算法，研究多种基于对位元素的特征向量的融合方法，探究网络模型内的特征组合优化问题以及并行独立网络架构下的特征融合问题。

（3）研究基于声学特征和时频图特征融合的生猪咳嗽声识别。在上述基于平衡数据集下对传统声学特征和时频图特征的提取和融合的研究基础上，研究基于声学特征和时频图特征的融合方法。提出包括基于声学特征和视觉特征、深度特征融合以及三者共同融合的三种融合架构下的多种融合策略和融合方式，探究不同特征间融合对生猪咳嗽声识别精度相互作用，分析不同特征对识别结果的影响。同时，由于复杂猪舍环境下生猪咳嗽声与非咳嗽声不均衡问题，探究多特征融合策略在数据不平衡加深程度变化对生猪咳嗽声识别精度的影响。进而，针对非平衡数据集下的识别精度下降的问题，从特征层面对比分析不同特征融合策略在不平衡数据集下的识别性能，从算法层面提出混合集成算法，以优化模型并进一步加强对目标声音的识别准确性，提升模型在复杂声音环境下的鲁棒性。

1.4 技术路线

论文以生猪咳嗽声的传统声学特征、时频图特征到多域特征融合为研究主线，将包含时域、频域以及倒谱域的传统的声学特征描述拓展到时频图特征，最后将二者融合形成多域特征的不同组合，技术路线如图 1-4 所示。

（1）数据获取

猪舍内音频数据获取与预处理。本章重点阐述了猪舍内音频数据获取过程，包括音频数据采集环境、数据分割和标记以及数据集构建三部分。并对已构建的数据集进行相关的预处理操作，包括预加重、分帧和加窗。

（2）传统声学特征融合

针对单一声学特征信息表达不充分的问题，本文根据了声学特征间的相互关系，引入

中国知网 https://www.cnki.net

XGBoost-RFECV 和 XGBoost-SHAP 对时域（均方根能量和过零率）、频域（频谱质心、频谱平坦度、频谱带宽、频谱滚降度、频谱对比度和频谱通量）以及倒谱域特征（梅尔频率倒谱系数）进行特征选择、解释与融合，并对随机森林（RF），K 临近算法（KNN）和支持向量机（SVM）不同机器学习算法进行参数优化和选择。

（3）时频图特征融合

依据到时频图在时间和频率双重维度上信息表达的紧凑性和平稳性这一优势，将原始一维声学信号转为时频图特征，包括短时傅里叶变换（STFT）和常数 Q 变换（CQT）两种；在时频图基础上，进一步提取视觉特征和深度特征，并针对二者采用不同的特征融合策略和融合方式，以探究融合方法对生猪咳嗽声识别性能的影响。

视觉特征，包括局部二值模式（LBP）和方向梯度直方图（HOG）；期间，对比不同特征特征参数下对生猪咳嗽声识别的影响，并采用核主成分分析（KPCA）对高维的视觉特征进行降维操作；随后，通过改变（P，R）值提取不同图像分辨率下的局部二值模式，并融合不同分辨率下的局部二值模式，提出融合不同分辨率下的局部二值模式策略。同时，利用时频图颜色变化对方向梯度直方图特征的影响，提出融合 RGB 三通道和单通道下方向梯度直方图特征策略。

深度特征的提取是建立在本文构建的卷积神经网络（CNN）模型上，研究基于单输入的后端全连接层特征融合（Layer fusion）和基于双输入的深度特征融合（TFRs fusion）策略，并与迁移学习下的深度神经网络模型进行对比和分析；针对深度特征融合模块，研究多种基于对位元素（Element-wise）的特征向量的融合方法；进一步探究网络模型内的特征组合优化问题以及独立网络架构下的特征融合问题。

（4）多域特征融合

提出包括基于声学特征和视觉特征、深度特征融合以及二者共同融合的三种融合架构，在融合架构下组合多域特征融合策略；

结合早期、中期、后期融合方式探究不同特征间融合对生猪咳嗽声识别精度相互作用，分析不同特征对识别结果的影响，筛选最具有辨识度的特征子集；

从算法层面提出混合集成算法，并将其与其他数据层面平衡化算法进行对比和分析，以弥补单一识别算法带来的局限性，克服不平衡数据下识别精度下降的问题。

中国知网 https://www.cnki.net

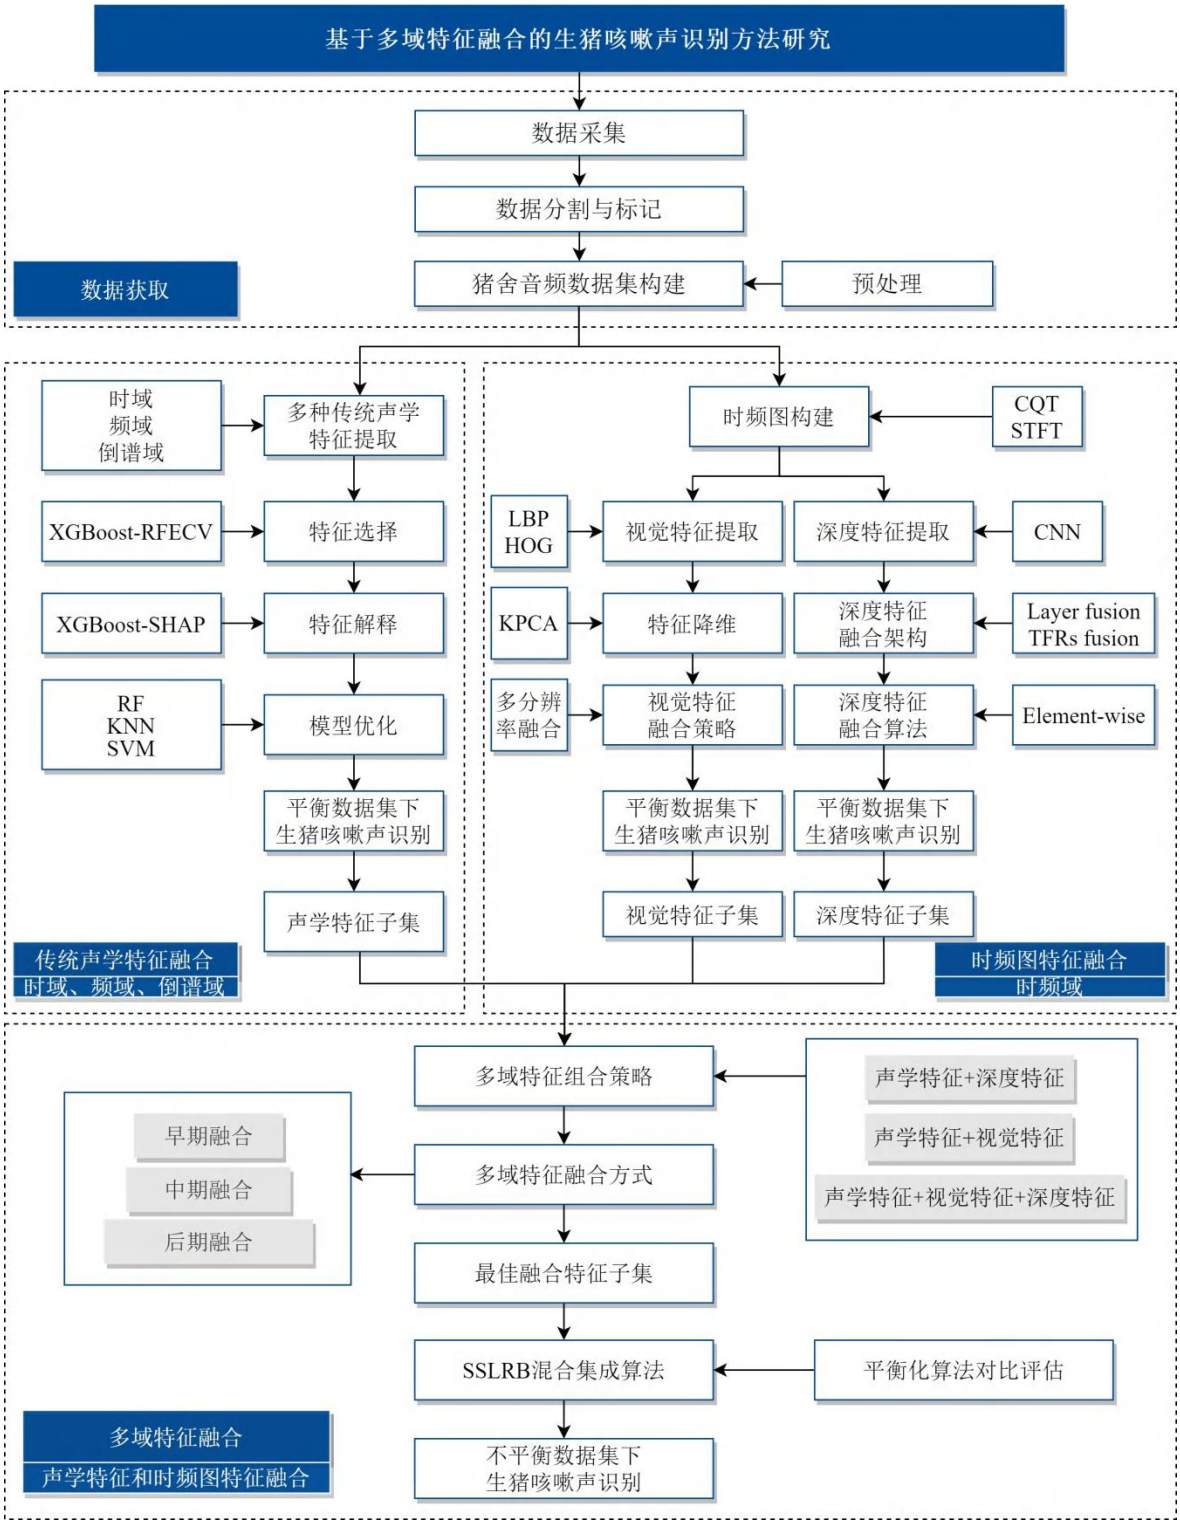


图 1-4 技术路线图

Figure 1-4 Schematic diagram of the technical flow

中国知网 https://www.cnki.net

1.5 论文结构与章节安排

本文分为六个章节，结构如图 1-5 所示，各个章节包含的内容如下：

第一章是绪论部分，这一部分主要介绍了本论文的相关研究背景与研究意义，回顾了生猪咳嗽声识别的研究历程，并在国内外研究现状的基础上，分析了当下生猪咳嗽声识别存在的主要问题，引出本文的研究目标和主要研究内容，最后简要概括本文的章节组织结构和每一章对应的研究内容。

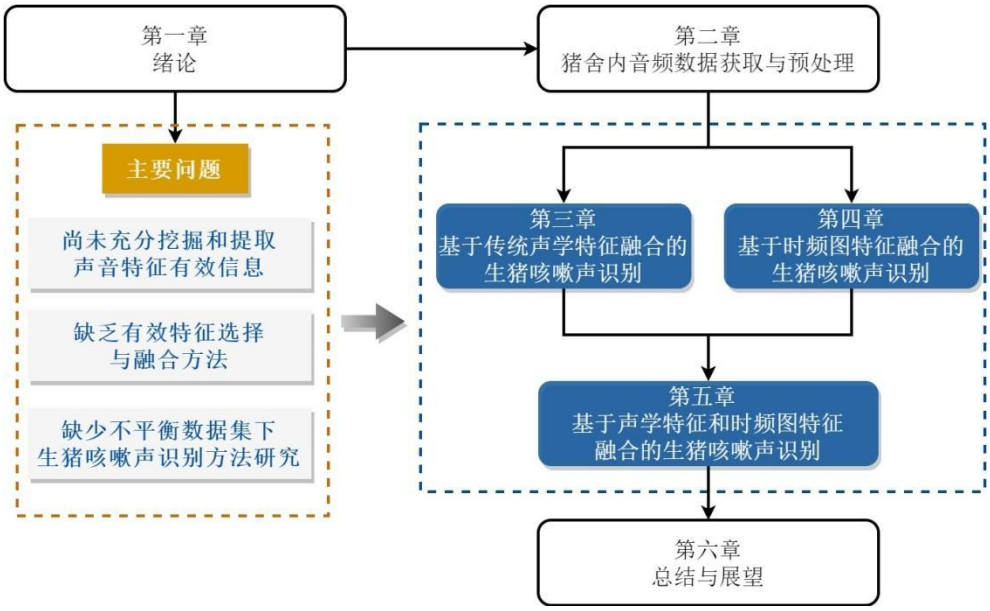


图 1-5 论文内容与章节安排

Figure 1-5 Research content and arrangement of sections

第二章是猪舍内音频数据获取与预处理。本章重点阐述了猪舍内音频数据获取过程，包括音频数据采集环境、数据分割和标记以及数据集构建三部分。并详细介绍了声音信号预处理的相关内容，包括预加重、分帧和加窗。最后，对模型评估方法和评价指标进行说明。

第三章为基于传统声学特征融合的生猪咳嗽声识别研究。本章深入探究了从声音的一维声学信号中提取多域下的声学特征，包括时域、频域和倒谱域特征。同时，对不同域下的特征进行特征选择与解释，筛选融合后的特征子集。最后，对三种不同的机器学习模型进行设置和优化，讨论不同特征子集对生猪咳嗽声识别性能的影响。

第四章为基于时频图特征融合的生猪咳嗽声识别研究。依据到时频图在时间和频率双重维度上信息表达的紧凑性和平稳性这一优势，本章将声学信号转为二维时频图对舍内声音进行时频域表示。并基于短时傅里叶变换和常数 Q 变换两种时频图进一步提取视觉特征和深度特征，并针对二者采用不同的特征融合策略和融合方式，以探究融合方法对生猪咳嗽声识别性能的影响，并进一步对比分析。

第五章为基于声学特征和时频图特征融合的生猪咳嗽声识别研究。本章的研究以第三章和第四章的研究内容为基础，对多域的特征融合策略进行挖掘。第三章和第四章的识别任务均是面向平衡数据集，由于复杂猪舍环境下存在的声音数据不平衡的问题，本章尝试采用基

中国知网 https://www.cnki.net

于声学特征和时频图特征融合的方式。提出包括基于声学特征和视觉特征、深度特征融合以及二者共同融合的三种融合架构，在融合架构下组合多域特征融合策略，结合早期、中期、后期融合方式探究不同特征间融合对生猪咳嗽声识别精度相互作用，分析不同特征对识别结果的影响，进而从特征层面研究不同融合策略在不平衡数据集下的识别性能，提取在复杂环境下具有鲁棒性的声音子集。并进一步从算法层面，研究混合集成模型，并与数据层面平衡化算法进行对比和分析，探究和加强不平衡数据下的生猪咳嗽声识别性能。

第六章为结论和展望。本章对论文的结论和创新点进行总结阐述，针对本研究的不足之处，结合本研究领域内的最新研究进展，对未来的研究方向进行展望和讨论。

中国知网 https://www.cnki.net

2 猪舍内音频数据获取与预处理

2.1 引言

获取猪舍内声音数据集是生猪咳嗽声识别的基础，同时，高质量的数据集构建是实现生猪咳嗽声高精度识别的先决条件[112]。从第一章内生猪咳嗽声识别的相关研究现状分析可知，由于生猪咳嗽声识别研究起步相对较晚，现阶段仍缺乏一个系统且较为全面的公共生猪叫声数据集。本课题使用的数据集是基于商业猪舍内采集数据构建的私有数据集。首先使用麦克风传感器获取猪舍内连续音频，而后由动物医学专家采用人工标记方式对连续音频数据集进行分割和标记，最终构建了猪舍内音频数据集。本章将着重阐述本课题数据集的采集与标记、数据集的预处理、模型评估方法和评价指标等内容。

2.2 猪舍内音频数据获取

2.2.1 音频数据采集环境

本文中音频数据采集实验地点为黑龙江省哈尔滨阿城区的某大型商业猪场，地理坐标地处东经 126°40′～127°39′，北纬 45°10′～45°50′。猪场冬季气候寒冷且干燥，漫长而寒冷，春季回暖快而多大风，季节性变化明显。寒温带大陆性季风气候，无霜期日数 162 天。数据采集点为养猪场内的某一育肥猪舍内，猪舍的平面示意图，如图 2-1 所示。



图 2-1 猪舍内平面示意图

Figure 2-1 Layout of the experimental pig house

猪舍的尺寸为 27.5m×13.7m×3.2m（长×宽×高），整个猪舍包含栅栏式猪栏 21 个，每个猪栏高 1.1m。其中，猪栏 1 到猪栏 12 的长宽为 4.15m×3.6m，猪栏 13 到猪栏 21 的长宽为 3.6m×2.75m。每个猪栏均由部分水泥地面和部分漏缝地板组成。舍内侧墙上安装有两个直径为 1.35m 的风机。实验猪舍内共有 128 头杂交生猪（东北民猪×大白猪，育肥期），个体平均重量为 60kg 左右，分布在 1-13 号栏中，图 2-1 每个猪栏中的数字为对应的生猪个数。

中国知网 https://www.cnki.net

育肥猪的呼吸道疾病的高发时间段在秋季末和冬春交替季节，此时气温变化较为明显，温差较大。本次实验数据采集的时间为哈尔滨冬春交替的四月（昼夜温差达 13℃），此时天气仍然处于较低温度状态下（夜间平均 2℃），因此，多数情况下，猪场仅在白天开启电风机，进行通风，一般间隔两小时通风一次，每次开启风机时长约 10~15 分钟，通风时会产生一定的通风背景噪音；夜间以保暖为主，不再开启风机。实验过程中，猪舍环境图如图 2-2 所示。每个栏中安置了一个采食槽，猪舍内部环境图如图 2-2 a)所示。实验中开启的风机状态如图所示 2-2 b)所示。7 号猪栏中的六头生猪俯视图，如图 2-2 c)所示。13 号栏中为单独安置的咳嗽症状较重的生猪，如图所示 2-2 d)所示。其他栏中均有不等数量的猪呈现不同程度的咳嗽。



a) 猪舍内部环境图

a) Internal environment of the pig house

b) 电风机开启状态

b) Electrical fan switched on

c) 7 号猪栏的俯视图

c) Top view of Pen 7 in barn

d) 13 号栏中生猪状态

d) Pig condition in Pen 13

图 2-2 猪舍环境图

Figure 2-2 Experimental environment of pig house

本文采用的音频采集设备为 LIQI LM320E 电容麦克风，采用驻极体音头，指向性包括心型和超心型，响应频率为 50 Hz~16000 Hz，灵敏度为-45dB±3dB，采用一节 1.5VAA 电池供电。由于实验条件限制，数据采集时将麦克风外置于 7 号猪栏靠近 13 号栏的外侧立式支架上，并将麦克风倒挂于距离地面 1.4 米处，距离猪后背 0.8 米左右。麦克风指向性选择心型指向性，麦克风的另一端连接到内置于笔记本的 Conexant Smart Audio HD 声卡，实时记

中国知网 https://www.cnki.net

录猪舍内声音。采样频率设定为 44.1kHz，采样精度为 16bit，所有采集到的音频数据均以.wav 格式保存。图 2-3 为实验中猪舍音频采集现场设备图，其中图 2-3 a)为笔记本音频采集的过程，图 2-3 b)为猪舍内麦克风安装位置。

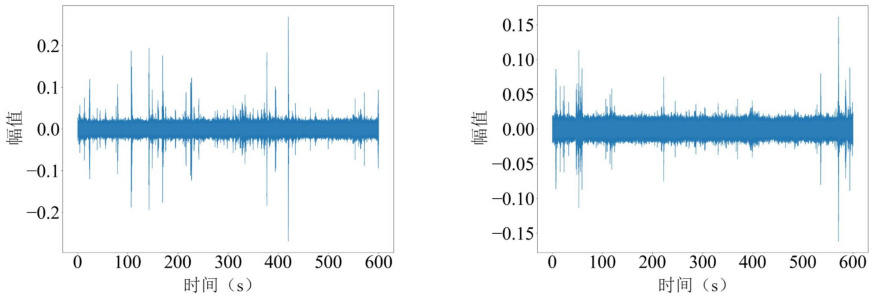


a) 笔记本音频采集的过程　　b) 舍内麦克风安装位置

a) The process of audio acquisition with laptop　　b) Installation position of the microphone

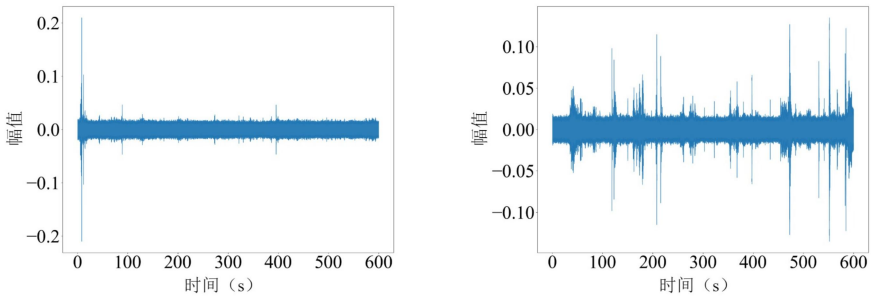
图 2-3 猪舍内音频采集现场图

Figure 2-3 Audio collection on-site in the pig house



a) 舍内风机开启状态　　b) 舍内风机关闭状态

a) Electrical fan switched on in pig house　　b) Electrical fan switched off in pig house



c) 夜间猪舍内安静状态　　d) 夜间猪舍内发声状态

c) Silent conditions at night in pig house　　d) Vocal condition at night in pig house

图 2-4 获取的部分原始声音段

Figure 2-4 Part of the acquired original sound segments

中国知网 https://www.cnki.net

本次实验数据采集过程共计 7 天，采集的连续声音段每 10 分钟保存为一个.wav 文件，共保存了 791 段.wav 文件。采集到的部分原始声音数据，如图 2-4 所示。日间下午猪舍内风机开启状态下的音频，如图 2-4 a)所示。图 2-4 b)表示日间下午猪舍内风机关闭状态下的音频。对比图 2-4 a)和图 2-4 b)可知，风机开启状态下采集的声音段干扰声音增多。图 2-4 c)表示夜间凌晨猪舍内安静状态下的音频，图 2-4 d)表示夜间猪舍内生猪发声状态下的音频。综上，原始数据中包含大量的多种干扰声音，且声音能量大小不一。同时，原始音频中包含大量的无声段，这对后续的咳嗽识别任务带来了很大的挑战。因此，对原始声音段进行分割和标记是十分必要的。

2.2.2 音频数据分割与标记

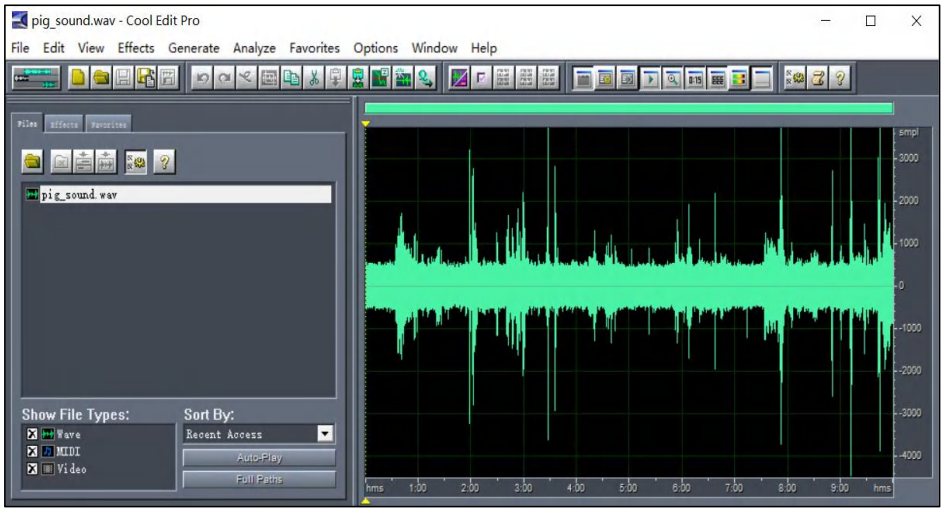
本文所采用的生猪咳嗽声识别方法基于独立声音片段，因此需要对连续的声音段进行数据分割和标记。数据分割[113]一般是指截取连续声音段中有声段的开始位置和结束位置，并将此段有声段保存成单独的音频文件。数据标记是对分割后的有声段标记标签，标签为每个声音片段标记声音所属类型。

数据分割和标记分为算法自动分割和手动分割两种方式。通常情况下，数据的自动分割和标记过程是基于输入的目标声音的特征进行处理来自动完成的。由于不同研究对象间的声音差异，自动分割和标记的算法并没有普适性，需要根据不同数据集进行开发和调整。当前，大多数自动分割均是针对人类语音或人类活动声学场景开发的。而当前缺乏对生猪舍内声音特征的探索，缺少具有鲁棒性的特征表示。同时，有关生猪舍内声音领域下缺乏开源公共的标准数据集，这导致对猪舍内音频数据自动化分割存在一定的难度。因此，本文选择手动分割的方式以保证数据分割的准确性和可靠性。

对于数据的标注过程，由动物医学专家通过人耳听觉判别及观察声音波形的视听双重确认进行人工标记。标记全程采用 Cool Edit Pro 声音处理软件，标记过程如图 2-5 所示。图 2-5 a)显示了总长为 10 分钟时猪舍内生猪发声状态下的音频。软件可以对横轴时间和纵轴幅度进行缩放，并可以播放声音和显示声音信号的语谱图。从声音波形上，可以快速直观的定位有声段，通过人耳听觉判断声音类型，然后对该声音片段进行分割、保存和标注。如图 2-5 b)所示，是对猪舍内生猪发声状态下音频进行分割的过程。图中显示的该声音片段在连续声音段中的开始时间、结束时间以及相应的时长，最后为声音的内容标记名称。由于振幅的突然下降会额外产生一定的噪音，在高频中显示出来。所以在人工切分音频时，使振幅应该在波形两边边缘逐渐下降，声音段的两端保持了一定的平稳下降度。

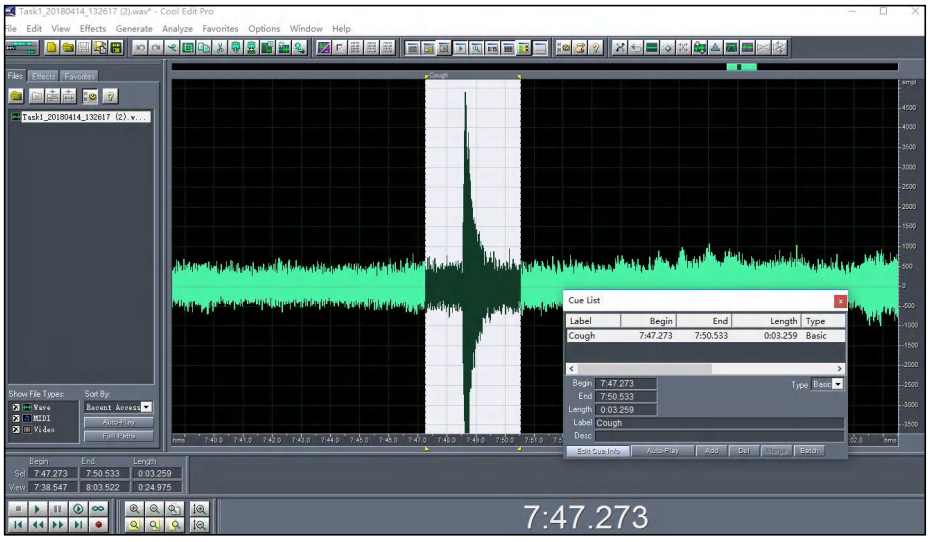
在实验过程中，通过调整笔记本麦克风音量，保证采集的声音信号不被削波且能获取到较为清晰的舍内的声音数据。由于部分舍内声音距离麦克风位置较远，可能存在远距离的声音信号无法被感知的情况，这些声音无法被麦克风捕获。本次实验的目的是获取猪舍内咳嗽声和非咳嗽声的声音样本并作为后续实验数据集。因此，在构建数据集时，只是对人耳可听见的且能分辨的咳嗽声和非咳嗽声进行分割和标记。对于舍内未采集到的咳嗽声，并不在研究范围内。

中国知网 https://www.cnki.net



a) 一段总长 10 分钟的连续声音段

a) A ten-minute audio recording in vocal condition



b) 音频分割和标记页面

b) Interface of audio segmentation and labelling

图 2-5 Cool Edit Pro 读取、分割和和标记声音片段过程

Figure 2-5 The process of reading and labeling sound recordings

2.2.3 猪舍内音频数据集构建

在上述采集的连续音频中，选取了其中的一部分数据进行了数据分割和标记。被标记的声音片段均为人耳可分辨的，标记后的各类声音样本如表 2-1 所示。人工共标注了 2546 个音频片段，包括咳嗽声 1273 个，非咳嗽声 1273 个。在非咳嗽声中，包括 957 个生猪其他叫声（尖叫声、嚎叫声、吃食声等生猪发出的叫声）；由于猪场的自动化程度较低，猪舍内的清扫方式仍采取人工清理，共收集 188 个铁锹清理地面的清理声；除此之外，还包含舍内常

中国知网 https://www.cnki.net

见的生猪饮水或人工冲清洗地面产生的流水声 100 个和 28 个猪场驻点工作人员的说话声。

表 2-1 生猪舍内样本数据集

Table 2-1 Dataset of different types of sounds collected from pig house

样本类别	样本总数	样本名称	样本数
咳嗽声	1273	咳嗽声	1273
非咳嗽声	1273	生猪叫声	957
		清理声	188
		水声	100
		人说话声	28

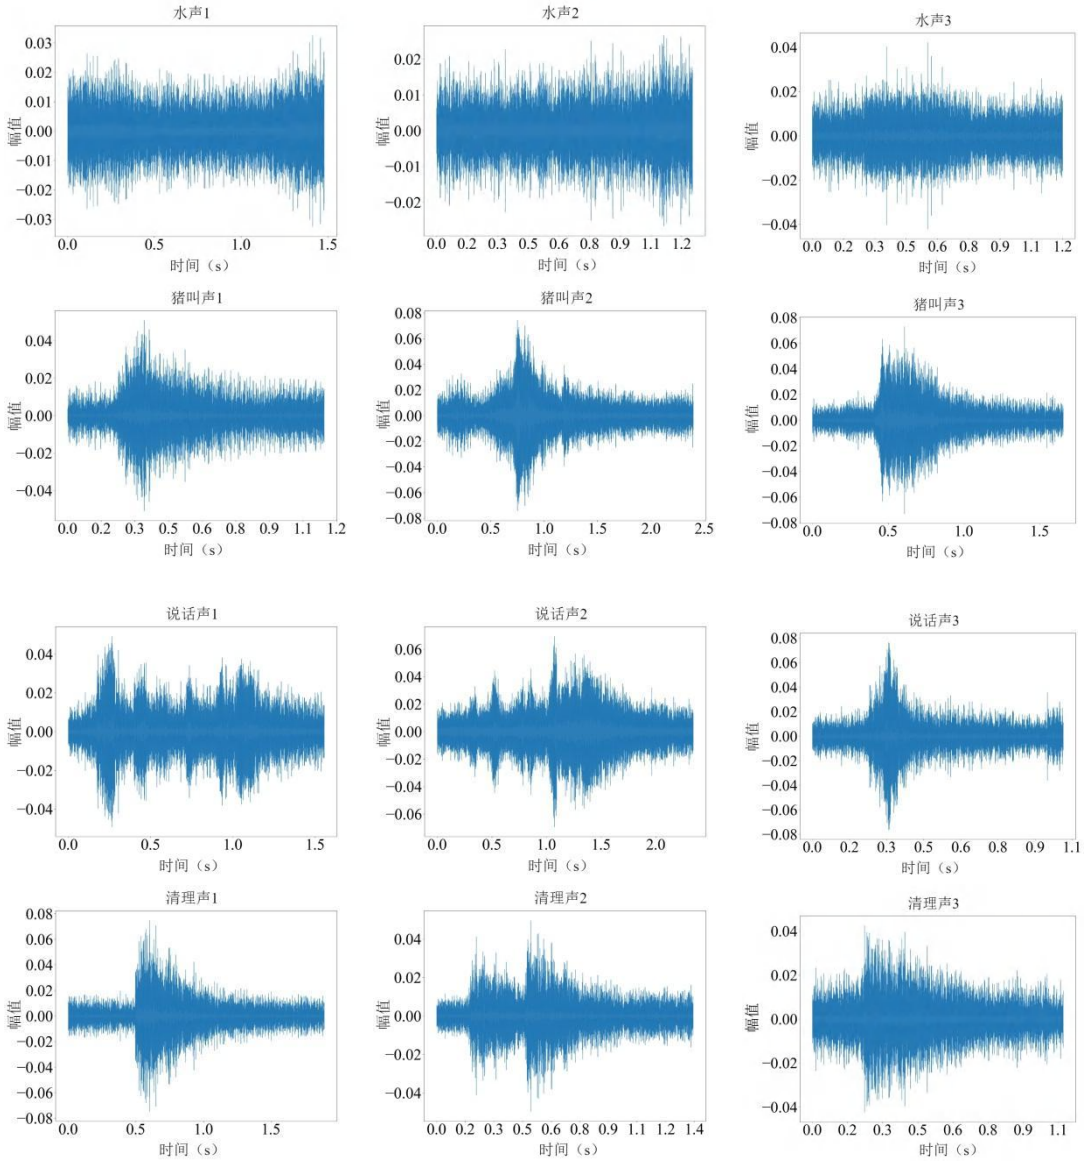


图 2-6 猪舍内非咳嗽的时域波形图

Figure 2-6 Time-to-amplitude waveform plots of noncough sounds

中国知网 https://www.cnki.net

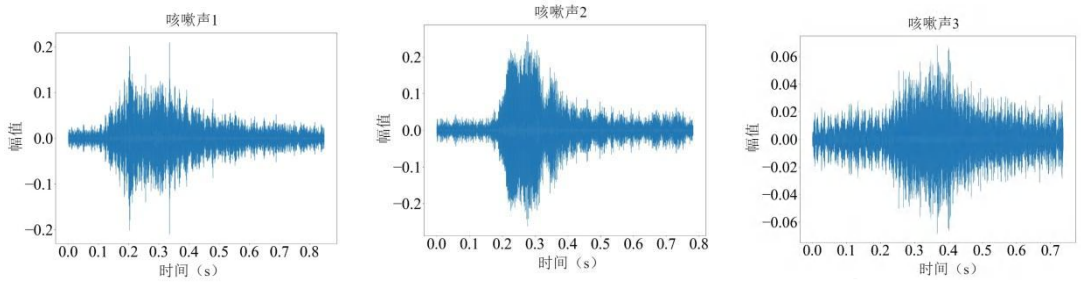


图 2-7 猪舍内生猪咳嗽声的时域波形图

Figure 2-7 Time-to-amplitude waveform plots of cough sounds

非咳嗽声和咳嗽声样本的时域波形如图 2-6 和图 2-7 所示。图 2-6 显示了四种不同的非咳嗽声的时域波形图。其中，水声波形相对较为均匀且平稳，其余三种波形图相似性较高。由图 2-7 可知，咳嗽声不同样本之间的时域波形图存在一定差异。综上，仅通过时域波形观察的方式，很难区分是何种声音类型，因此，需要对声音数据提取不同域下的特征进一步识别。

2.3 声音信号预处理

2.3.1 预加重

预加重是声音信号的预处理中的第一步，其可以提高声音高频区域的能量，这一点对于猪舍内的声音分析是十分有益的。因为，生猪叫声包括咳嗽声、尖叫声、嚎叫声等多种叫声信息，这些包含高频段声音信号的生猪叫声之间存在重要的差异性信息。预加重可以适度地减缓信号采集中出现的高频信息损失的情况。预加重的公式如下所示：

$$H(z) = 1-\alpha z^{-1} \tag{2-1}$$

式中，常数α是预加重系数α的取值范围通常为 $0.9 < \alpha < 1$。本论文进行预加重操作时，参数α的取值为 0.97。

2.3.2 分帧

分帧是将连续的声音信号分割成较短的帧信号的过程。声音信号中的频率随时间变化，具有时变且非稳态性，因此难以对其进行直接的分析。而声音信号在短时间内可以被看作是平稳且不变的。基于以上原因，将连续的原始声音信号划分为每一段准稳态的声音信号，其中的每一小段称为一帧。分帧后帧数f_n，计算如下：

$$f_n=\frac{N\text{-}overlap}{inc}=\frac{N\text{-}wlen}{inc}+1 \tag{2-2}$$

其中，$wlen$代表每一帧长所包含的样本数，其计算公式如下所示：

$$wlen=f_s\times length \tag{2-3}$$

其中，f_s（Frequency of sampling）代表声音信号的采样率，是指单位时间（每秒）从连续信号中提取出用来组成离散信号的采样点个数，赫兹（Hz）作为衡量单位，在本文中，采

中国知网 https://www.cnki.net

样率f_s设定为 44100Hz。$length$代表帧长，帧长通常为 20~40ms。由于 25ms 的时长默认为足以满足捕捉的每一帧内的信息，因此 25ms 设定为标准的帧长时间。同时，分帧时要保证每帧之间的联系，也就是相邻帧之间的动态性。因此，为了使相邻帧之间能够平稳地过渡，在分帧的过程中往往将相邻的两帧之间设定一个重叠部分（*overlap*），一般是指 *wlen* 和 *inc* 的差值。*inc* 代表帧移，表示相邻两帧之间的起止点的位移量。本文采用 50%帧长作为帧移量。*N* 一般表示为读入音频的长度，表示为 *N* 个采样点的声音信号。图 2-8 为生猪咳嗽声信号分帧示意图。

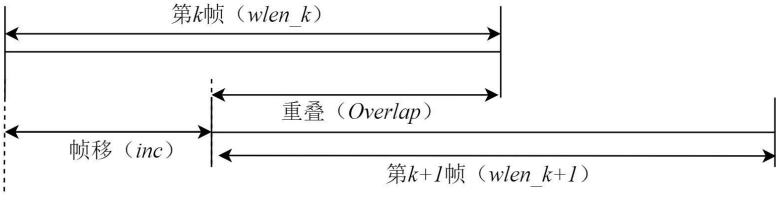


图 2-8 生猪咳嗽声信号分帧示意图

Figure 2-8 Framing schematic diagram of pig cough sound

2.3.3 加窗

在对原始的生猪舍内声音信号进行分帧后，每一帧的信号对应的频谱也随之变化。在整个声音信号变化的过程中，原始声音信号的基频能量被分散，导致了频谱泄露[114]。分帧数与频谱泄露程度呈现正相关，即划分帧数越多，频谱泄露情况越明显。为了减少频谱泄露，对每帧信号进行加窗。加窗函数$S_w(n)$计算公式如（2-4）所示：

$$S_w(n)=S(n)\times w(n) \tag{2-4}$$

其中，*S(n)*代表信号片段，$w(n)$代表窗函数。加窗的过程是指时间记录乘以一个有限长度的窗口。该窗口的振幅在边缘平滑变化并逐渐趋于零，使得波形的端点相遇，形成了一个没有尖锐过渡的连续波形。主瓣以时域信号的每个频率分量为中心，旁瓣接近零。旁瓣的高度表明窗函数对主瓣周围频率的影响。通常情况下，较低的旁瓣会减少测量中频谱的泄漏。窗函数的种类很多，要根据声音信号的不同特性而选择，常见的窗函数包括矩形窗、汉明窗和汉宁窗。

矩形窗（Rectangular window），即对原信号不应用任何窗函数，如公式（2-5）所示：

$$w(n)=\begin{cases}1, 0\le n\le N-1\\ 0 \quad\quad ,\text{其他}\end{cases} \tag{2-5}$$

汉明窗（Hamming window），是一个通过使用非零端点的凸起余弦形成的锥度，如公式（2-6）所示：

$$w(n)=\begin{cases}0.54-0.46\cos\left(\frac{2\pi n}{N-1}\right), 0\le n\le N-1\\ 0 \quad\quad\quad\quad\quad\quad ,\text{其他}\end{cases} \tag{2-6}$$

汉宁窗（Hanning window），是通过使用两端触及零的凸起余弦平方而形成的锥度，如公式（2-7）所示：

中国知网 https://www.cnki.net

$$w(n) = \begin{cases} 0.5\left(1-\cos\left(\frac{2\pi n}{N-1}\right)\right), 0 \le n \le N-1 \\ 0 \qquad\qquad , \text{其他} \end{cases} \tag{2-7}$$

公式（2-5）~（2-7）中，N为窗函数的窗长度。也就是输出窗口对应点的数量。当 N 取 2048 时，三种窗函数对比如图 2-9 所示。汉明和汉宁窗口函数都呈现正弦波的形状，这两个窗口都产生宽峰值和低旁瓣。相比于矩形窗，二者具有更好的频率分辨率。根据生猪舍内下的声音信号频率内容可知，在生猪咳嗽声识别任务中，舍内生猪叫声与生猪咳嗽声频率相近，属于强干扰信号。此时，选择旁瓣水平较低的窗函数更有利。汉宁窗在两端都接触到了零，消除了所有的不连续性。汉明窗并没有完全达到零，因此在信号中仍有轻微的不连续性。汉宁窗能更好地消除最近的旁瓣，但对其他旁瓣的消除效果较差。相比而言，汉宁窗主瓣加宽并降低，旁瓣则显著减小，由此可更好地减小频谱泄露，综上，本论文选定汉宁窗作为窗函数。

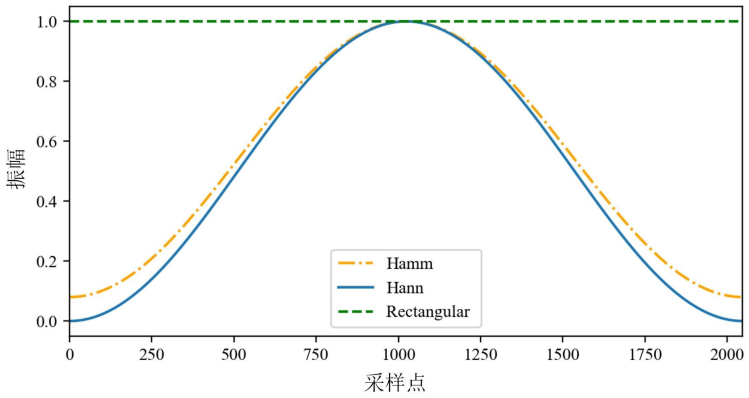


图 2-9 三种窗函数表示

Figure 2-9 Three types of window functions

2.4 模型评估与评价指标

2.4.1 模型评估方法

k折交叉验证（k-fold Cross Validation，CV）是常用的模型评估方法，该方法能够充分利用有限的数据来提高实验模型的泛化能力[115]。k折交叉验证侧重于将固定的数据集平均拆分成k个子集，设定$k-1$个子集作为模型的训练集，将不同训练集应用于经验设定参数的模型中，并预留第k个子集作为测试集，最终的实验结果取k次平均值。针对不同现实问题时，通常致力于寻找相对最佳的模型参数，使模型达到最佳的拟合效果。由此，在本研究中，引入内嵌交叉验证（Nested k-fold Cross Validation，NCV）对实验过程中的数据集进行划分[116]。内嵌交叉验证的原理在于内部的交叉验证保证分类器的最优参数选择以获得最佳的训练模型，而外部交叉验证保证了获取k组测试集，使结果在已选择的最佳模型下进行测试，最后，可以通过对比不同的测试结果来综合分析评价不同的算法，见算法 2-1 所示。

中国知网 https://www.cnki.net

算法 2-1 内嵌 k 折交叉验证算法
Algorithm2-1 Nested k-fold cross validation

输入：内置模型 M，数据训练集 D，超参数组合 P，外部交叉验证次数 j = 1,2，…k；内部交叉验证次数 i = 1，2…n；

输出：测试集子集 k 的平均值 Avg_best；

for j = 1,2，…k：
  对训练集 D 进一步划分为 D_{train} 训练子集和 D_{test} 测试集
    for i = 1，2…n：
      D_{train} 划分为内训练集 I_{train} 和内验证集 I_{test}
        for p = 1，2…P：
          使用超参数 p 在 I_{train} 上训练模型 M
        获取模型 M 在 I_{test} 预测误差
        End
        选择超参数组合 P 中最优超参数 p_best
    End
    最优超参数 p_best 训练 D_{train}
End
  将交叉验证 k 次的模型测试集 D_{test} 结果求平均
返回 Avg_best

图 2-10 显示了内嵌 3 折交叉验证的流程，步骤如下：

步骤（1）：使用 3 折交叉验证划分原始数据集，获得三组不同的测试和训练数据集，构建交叉验证外循环。

步骤（2）：针对外循环中的训练集，进一步使用 3 折交叉验证来获得不同的内训练数据集和内部验证集，此时内循环用于参数调整。

步骤（3）：使用内部数据的训练子集和验证子集调整和优化模型超参数，选择在验证子集上误差最小的参数集合。

步骤（4）：使用内循环调整后的超参数配置，在外部训练数据集上拟合，进而评估模型在外部测试集数据上的表现。对三个折叠外循环中的每一个子测试集重复（2）~（4）。

步骤（5）：最后，将三组测试集的结果取平均值。

相比于将整个数据按比例直接划分为训练和测试集，内嵌交叉验证的结果可以从多角度进行对比以使模型更具有鲁棒性。在寻找最优参数的同时，来尽量规避单一数据样本带来的欠拟合情况，以达到充分拟合实验数据并验证模型的精度。使用内部嵌套可以降低特征选择导致的外部折叠之间的信息泄漏，因此内部嵌套可以防止独立数据外部折叠产生的误差估计。

中国知网 https://www.cnki.net

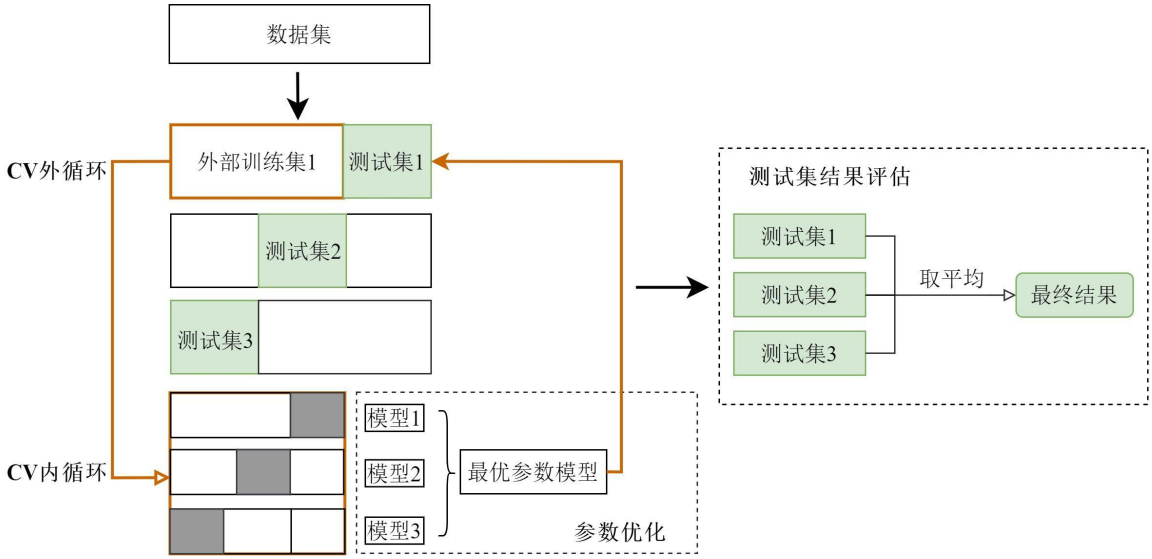


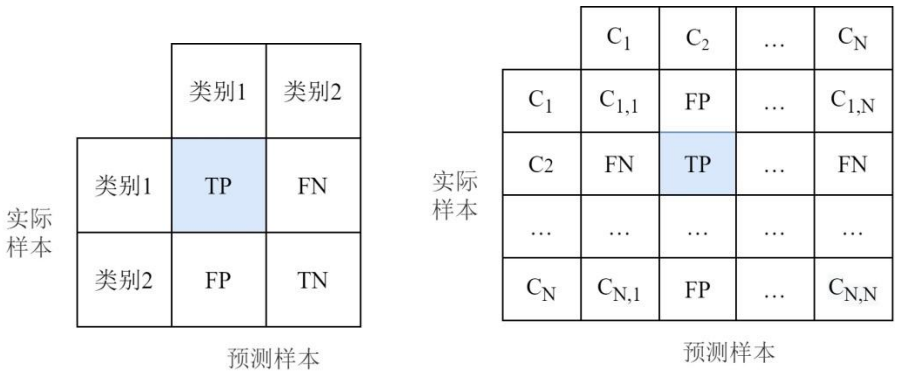
图 2-10 内嵌 3 折交叉验证示意图

Figure 2-10 Nested 3-fold cross validation diagram

2.4.2 模型评价指标

评价指标是衡量算法优劣的重要标识，不同的评价指标表达的含义侧重不同，多指标的共同评价方式能够更全面的对实验结果进行说明。本节中将介绍本研究中所采用的各项评价指标。

混淆矩阵[117]（Confusion Matrix，CM），又被称为误差矩阵，用$N \times N$的矩阵将实际类与预测类的结果表示出来。矩阵的每一列表示预测类的实例，其总数为预测该类别实例的数量。每一行表示实际类的实例，其总数为对应类别的实际数量。混淆矩阵显示了分类模型在进行预测时的混淆方式，可以对产生的错误样本的类型进行直观的显示，二分类和多分类问题的混淆矩阵如图 2-11 所示。



a) 二分类问题混淆矩阵　　b) 多分类问题混淆矩阵

a) Confusion matrix for two class　　b) Confusion matrix for mutil-class

图 2-11 混淆矩阵示意图

Figure 2-11 Confusion matrix diagram

中国知网 https://www.cnki.net

对于本文中咳嗽声与非咳嗽声的二分类问题，混淆矩阵的维数为 2×2。类别 1 是指生猪咳嗽声，类别 2 是指生猪舍内非咳嗽声。其中，TP（True Positive）为真阳性，表示生猪咳嗽声被正确分类的数量；FN（False Negative）为假阴性，表示生猪咳嗽声被错误分类成非咳嗽声的数量；FP（False Positive）为假阳性，表示非咳嗽声被错误分类成生猪咳嗽声的数量；TN（True Negative）为真阴性，表示非咳嗽声被正确分类的数量。

准确率（Accuracy），一般指模型的整体分类精度，表示正确识别咳嗽声与非咳嗽声的样本数占总体样本数量的比例。准确率越高，代表分类器的识别性能越好，其计算公式如（2-8）所示：

$$Accuracy=\frac{TP+TN}{TP+TN+FP+FN} \tag{2-8}$$

精准率（Precision），一般为分类器的查准率，表示在全部预测的生猪咳嗽声的样本中，实际为生猪咳嗽声的样本比例，计算公式如（2-9）所示：

$$Precision=\frac{TP}{TP+FP} \tag{2-9}$$

召回率（Recall），一般为分类器的查全率，表示在全部实际的生猪咳嗽声的样本中，被标记为生猪咳嗽声的样本比例，计算公式如（2-10）所示：

$$Recall=\frac{TP}{TP+FN} \tag{2-10}$$

F1 分数（F1-Score），一般是为了同时平衡召回率和精准率，计算公式如（2-11）所示：

$$F1\text{-}score=\frac{2\times Recall\times Precision}{Recall+Precision} \tag{2-11}$$

曲线下面积[118]（Area under the curve，AUC），一般包括接收者操作特征（Receiver Operating Characteristic，ROC）曲线和精度-召回曲线（Precision-recall，PR），即 ROC-AUC 和 PR-AUC。

ROC 曲线通常在X轴上标明假阳率（False Positive Rate，FPR），在Y轴上标明真阳率（True Positive Rate，TPR）。FPR 和 TPR 的计算如公式（2-12）和公式（2-13）所示：

$$FPR=\frac{FP}{FP+TN} \tag{2-12}$$

$$TPR=\frac{TP}{TP+FN} \tag{2-13}$$

根据 FPR 和 TPR 的值计算 ROC-AUC，如公式（2-14）所示：

$$ROC\text{-}AUC=\frac{1+TPR-FPR}{2} \tag{2-14}$$

PR-AUC 在每个阈值下达到的精度的加权平均值，召回率比前一个阈值的增加作为权重。其中$p(k)$和$r(k)$表示为第n阈值下的精准率和召回率，如公式（2-15）所示。PR 曲线显示了精确度和召回率之间的权衡。高 AUC 代表高召回率和高精确度。PR-AUC 和 ROC-AUC 是评估分类器输出质量的直观而有效的措施。AUC 的值越接近 1，说明模型性能越好。

$$PR\text{-}AUC=\sum_{k=1}^{n}p(k)\Delta r(k) \tag{2-15}$$

中国知网 https://www.cnki.net

在二类不平衡分类问题中，仅采用准确率作为模型的评价指标极易导致准确率的偏高，因为分类器优先于多数类。因此，在类别不平衡的情况下，采用几何平均值（G-mean），作为整体分类器的评价标准，G-mean 计算如公式（2-16）所示：

$$G\text{-}mean = \sqrt{Recall \times Spec} \tag{2-16}$$

其中，Recall 指代的是生猪咳嗽声的召回率，Spec 指代的是非咳嗽声的分类准确率，Spec 计算公式（2-17）如下所示：

$$Spec = \frac{TN}{FP+TN} \tag{2-17}$$

由计算公式可知，G-mean 一般同时兼顾咳嗽声和非咳嗽声的准确率。这意味着在类别不平衡时，即使预测模型对多数类样本进行了正确的分类，但对少数类目标样本的预测能力较差时，也会降低 G-mean 整体结果。

2.5 本章小结

本章围绕研究主体，详细阐述了生猪舍内数据采集环境、生猪舍内音频数据集的预处理和以及对原始声音标记后数据集的构建。

（1）对生猪舍内环境实地调研，根据舍内环境安装采集设备，并进行舍内原始音频采集。对生猪舍内的环境、采集现场情况进行描述，并详细阐述了研究对象和样本采集的情况。

（2）采用生猪舍内原始数据进行标记，并分割为独立声音片段。对舍内声音进行预加重、分帧和加窗。

（3）根据建立的数据集，阐述了模型评估方法和相应的评价指标。

中国知网 https://www.cnki.net

3 基于传统声学特征融合的生猪咳嗽声识别

3.1 引言

有效的特征表达是生猪咳嗽声准确识别的先决条件。但目前，对于生猪咳嗽声识别的研究，大都集中在识别算法上，而对于不同声学特征之间的性能表达与联系缺乏深入的探索和挖掘。以往研究中多是选择常用的一种或几种声学特征，且对于多种特征往往只是简单的拼接或组合，缺乏有效的特征筛选和特征融合方法，这种情况容易导致识别算法的泛化能力较弱，难以在大范围内进行推广和应用。

不同的声学特征从不同角度描述声音信号的特性，各个声学特征之间存在不同程度的相似性和差异性，如何选择具有代表性的、分类性能好的声学特征集合是需要解决的关键问题。声学特征之间存在着互补性[119]。基于这一原则，本章从原始音频数据中直接提取出传统的声学特征，从特征选择、特征降维和分类模型参数优化几个方面着手，研究基于声学特征融合的咳嗽声识别方法，挖掘不同声学特征之间的关联以及探索不同声学特征对模型识别精度的贡献度。

针对现阶段对猪舍内声音的声学特征信息提取和分析尚不充分的情况，本章使用第二章中获取的平衡数据集，研究不同域下的传统声学特征的选择和融合问题。首先，提取并分析多域下的声学特征，包括时域、频域和倒谱域的声学特征；针对多域特征间的特征重要性进一步选择和优化，并深入研究特征和分类器的相互作用，探索特征对分类结果的影响 进而对不同特征重要性进一步解释；最后，对多种机器学习算法的参数进行优化，使模型的学习能力最大化，进而提升模型的识别性能。本章重点研究内容与流程如图 3-1 所示。

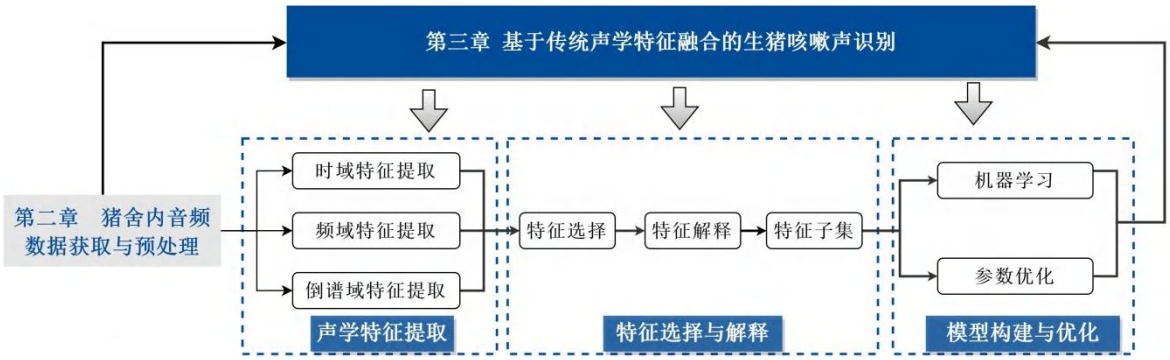


图 3-1 本章的主要研究内容及其与第 2 章逻辑关系

Figure 3-1 The main research content of this and relationship with Chapter 2

3.2 传统声学特征提取

传统声学特征一般是指从音频数据中手工提取特征，获取原始且直观的不同类型的声学特征。这些声学特征是根据特定识别任务选择和计算的低水平量的统计描述符。常见的传统声学特征包括时域特征、频域特征以及倒谱域特征。时域特征参数是声音信号的物理信息与

中国知网 https://www.cnki.net

随着时间变化的最直观的表达，能够反映实时的变化，具有特征提取方式简单的优势。声音信号在时间上的变化稳定性相对不高，复杂音频环境下的噪声增加导致了对不同声音的辨别力下降。因此，引入频域特征和倒谱域特征可以从声音信号的频率出发，进一步丰富声学的特征表达[120]。二者具有鲁棒性较高且稳定性较好的特点。基于以上不同域下的声学特征的特质，本节提取的传统声学特征包括来自时域的均方根能量和过零率；频域下的频谱质心、频谱平坦度、频谱带宽、频谱滚降度、频谱对比度和频谱通量；以及倒谱域下的梅尔频率倒谱系数[121]。

3.2.1 时域特征

本研究中采用的时域特征为均方根能量和过零率。均方根能量（Root mean square，RMS），这个指标衡量音频信号的音量水平[122]，计算声音样本振幅的平方之和的平方根。计算公式如（3-1）所示：

$$RMS = \sqrt{\frac{1}{N}\sum_{i=1}^{N} x(i)^2} = \sqrt{\frac{x^2 1 + x^2 2^{+\cdots+} x^2 N}{N}} \tag{3-1}$$

过零率（Zero-crossing rate，ZCR），指在给定的时间间隔内，信号的振幅过零的次数[40]。其计算公式如（3-2）所示：

$$ZCR = \frac{1}{2}\sum_{n=0}^{N-1} \left[\operatorname{sgn}\left(x(n)\right) - \operatorname{sgn}\left(x(n+1)\right)\right] \tag{3-2}$$

其中，$\operatorname{sgn}[x(n)]$公式如（3-3）所示：

$$\operatorname{sgn}[x(n)] = \begin{cases} 1, x(n) \geq 0 \\ -1, x(n) < 0 \end{cases} \tag{3-3}$$

3.2.2 频域特征

除了对声学引号的时域特征进行分析外，还可以通过傅里叶变化将其转换到频域上，进而观察和分析声音的频域特征[123]。$X(k)$代表声音信号$x(n)$的离散傅里叶变换（Discrete Fourier Transform，DFT），如公式（3-4）所示：

$$X(k) = \sum_{n=0}^{N-1} x(n) e^{-\frac{j2\pi kn}{N}}, k = 0, \ldots, N-1 \tag{3-4}$$

其中，$x(n)$代表声音信号，N代表总体的声音样本数。

频谱质心[124]（Spectral centroid，Centroid），通常与声音亮度的测量有关，更高的中心值表示更高的频率值。具有低沉的声音倾向于较多低频内容，则对应的谱质心相对较低；相反，具有明亮欢快特质的声音则多数集中在高频，谱质心相对较高。计算如公式（3-5）所示，其中，f_k代表第 k 个频率间隔的频率。

$$Centroid = \frac{\sum_{k=1}^{N-1} f_k |X(k)|}{\sum_{k=1}^{N-1} |X(k)|} \tag{3-5}$$

中国知网 https://www.cnki.net

频谱平坦度[125]（Spectral flatness，Flatness），有利于量化声音的调性，其测量方法是功率谱的几何平均值与算术平均值的比率。高的频谱平坦度值表明所有频谱带中的频谱功率量相似。计算如下所示：

$$Flatness = \frac{[\Pi_{k=0}^{N-1} X(k)]^{\frac{1}{N}}}{\frac{1}{N}\sum_{k=0}^{N-1} X(k)} \tag{3-6}$$

频谱带宽[126]（Spectral bandwidth，Bandwidth），表示上限和下限截止频率之间的差异。计算如下所示：

$$Bandwidth = \sqrt{\frac{\sum_{k=0}^{N-1} (k-SC)|X(k)|}{\sum_{k=0}^{N-1} |X(k)|^2}} \tag{3-7}$$

频谱滚降度[127]（Spectral roll-off，Rolloff），指的是每个时间段内$X(k)$的幅度分布的特定百分比θ集中在下面的频段。这里，θ被设定为 0.85。Rolloff 通常用于评估频谱形状的基本变化。计算如下所示：

$$Rolloff = \theta \sum_{k=1}^{N-1} |X(k)| \tag{3-8}$$

频谱对比度[128]（Spectral contrast，Contrast），原始频谱对比度特征估计每个子带的频谱峰值、谷值及其差异的强度。在本文中，频谱峰和频谱谷的强度分别由最大和最小值附近的平均值来估计以保证特征的稳定性。因此，引入邻域因子α来描述小邻域，默认设置为 0.02。其计算公式如下所示：

$$SC_k = \log\left\{\frac{1}{\alpha N}\sum_{i=1}^{\alpha N} x_{k,i}^{'}\right\} - \log\left\{\frac{1}{\alpha N}\sum_{i=1}^{\alpha N} x_{k,N-i+1}^{'}\right\} \tag{3-9}$$

频谱通量[129]（Spectral flux，Flux），是由频谱幅度矢量的平方帧与帧之间的差异计算而来。其提供了一个区域频谱变化水平的指标，是一种测量频谱幅度变化速度的方法。高频谱通量值表明频谱幅度的突然变化。其计算公式如下：

$$F_t = \sqrt{\frac{1}{N}\sum_{k=1}^{N} \left(\frac{X_t(k)}{E_t} - \frac{X_t(k)}{E_{t-1}}\right)^2} \tag{3-10}$$

其中n为采样样本序号，$n = 1,2,\ldots,N-1$。

3.2.3 倒谱域特征

梅尔频率倒谱系数[47]（Mel Frequency Cepstral Coefficient，MFCC），它是基于人类的听觉感知来获得独特的声音值。MFCC 是一种音频信号频谱的紧凑特征表示，通常由一组倒谱系数构成。MFCC 系数包含不同频带的速率变化信息。不同的系数也具体代表着不同的含义。如果系数存在正值，说明大部分的频谱能量都集中在低频区域。相反，如果系数存在负值，它代表大部分的能量集中在高频。音频信号提取 MFCC 的核心是计算功率谱，通过频谱来确定对应的频率；对计算出的功率谱，应用梅尔刻度滤波器组来提取频段，随后将对数滤波

中国知网 https://www.cnki.net

器组应用到每个梅尔频率，利用离散余弦变换去除重叠滤波器之间能量的关联性，最终得到MFCC。MFCC 特征提取主要过程如图 3-2 所示。

（1）声音信号预处理

这一部分已在文中的 2.3 节中对本文中声音数据的预处理过程做出了详细的说明。在对生猪舍内声音信号进行 MFCC 特征提取过程中，首先对声音信号进行预加重、分帧及加窗的预处理操作。预加重的目的是提升信号高频成分，弥补采集过程中导致的高频分量损失。分帧的主要作用将连续动态的声音信号分割成短时不变的稳态信号。加窗的主要目的是抵抗连续信号在分帧过程中的频谱泄露。后续的操作均是基于信号的每一帧进行计算。

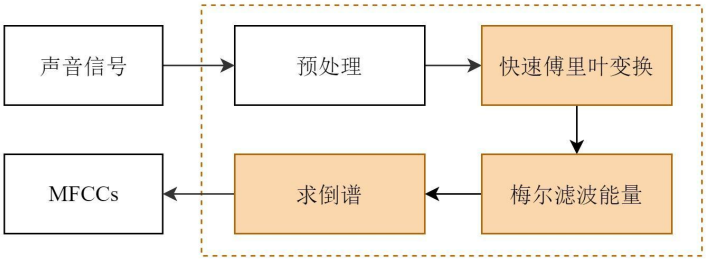


图 3-2 梅尔倒谱系数计算过程

Figure 3-2 Extraction process of MFCC

（2）快速傅里叶变换

针对于分帧后的信号，计算每一帧的功率谱，即对一个信号的频谱密度的估计，如图 3-3 所示。具体来说，本文对每一帧做一个快速傅里叶变换来计算频谱。

$$X(k)=\sum_{n=0}^{N-1}x(n)e^{-\frac{j2\pi kn}{N}},k=0,\ldots,N-1 \qquad (3\text{-}11)$$

其中，公式中，x代表声音信号，N代表总体的声音样本数。

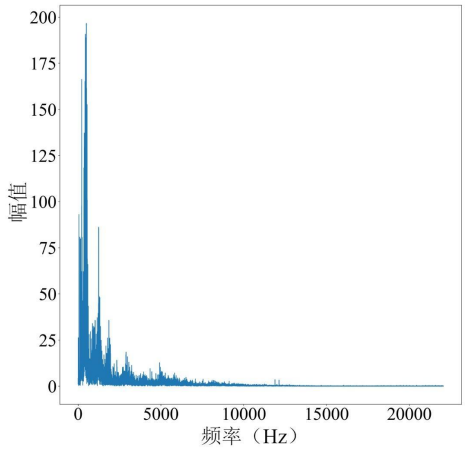


图 3-3 快速傅里叶变换

Figure 3-3 Fast Fourier transform

（3）计算梅尔滤波能量

声音设备对声音信号的测量值与人耳的听觉感知并不相同。对于人类来说，人内耳相当

中国知网 https://www.cnki.net

于一个非线性滤波器，所以实际感知具有非均匀性。感知的频率分辨率会随着声音信号频率的增加而降低。也就是说，人耳对高频率的声音信号敏感度降低。而梅尔刻度将对声音的感知频率与实际测量的频率联系起来，纳入这个刻度使声音特征的表达与人耳听到的声音更接近。梅尔频率与线性频率的对应关系如图 3-4 所示。二者计算公式如（3-12）所示：

$$F_{mel} = 2595\log\left(1+\frac{f}{700}\right) \tag{3-12}$$

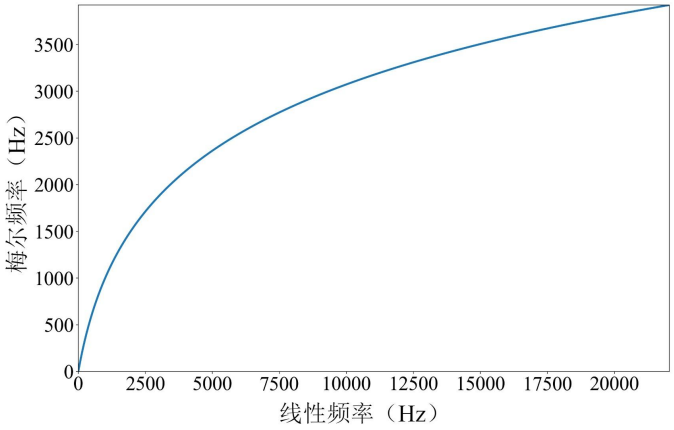


图 3-4 梅尔频率与线性频率的对应关系

Figure 3-4 Relationship between Mel and linear frequency

其中，F_{mel}代表人的感知频率，其单位为梅尔（Mel）；f代表实际频率，其单位为赫兹（Hz）。

计算梅尔滤波能量首要需设计梅尔滤波器组，其一般由多个三角滤波器组成。三角滤波器带通在高频率下更宽，以反映人类听力在高频率下的敏感性。具体来说，它在 1000 赫兹以下是线性间隔，之后变成对数。因此，采用三角滤波器来覆盖频率信息以模仿人类的感知。设其中心频率为$f(m)$，$m = 1,2$，……M。$f(m)$的获取过程如下所示：

$$f(m) = \left(\frac{N}{f}\right)\mathrm{F}_{mel}^{-1}\left(\mathrm{F}_{mel}\left(f_l + m\frac{\mathrm{F}_{mel}(f_h)-\mathrm{F}_{mel}(f_l)}{M+1}\right)\right) \tag{3-13}$$

其中，N代表的是进行傅里叶变换时的长度，f代表的是采样率，f_h和f_l分别代表滤波器频率范围中的最高频率和最低频率，F_{mel}代表的是梅尔频率，F_{mel}^{-1}是F_{mel}的逆函数。其中，F_{mel}满足式（3-12）中的函数关系。这个计算过程的流程：首先要选择一个下限和上限频率，即最高频率和最低频率。随即将上、下限频率转换为梅尔频率，实现梅尔转换。所有这些映射都是非线性的。在构成梅尔滤波器后，获取其响应频率，如（3-14）所示：

$$H_m(k) = \begin{cases} 0 & k < f(m-1) \\ \frac{k-f(m-1)}{f(m)-f(m-1)} & f(m-1) \le k \le f(m) \\ \frac{f(m+1)-k}{f(m+1)-f(m)} & f(m) < k \le f(m+1) \\ 0 & k > f(m+1) \end{cases} \tag{3-14}$$

在对梅尔滤波器设计后，计算梅尔滤波能量。其核心是计算谱线能量后进一步的计算梅尔滤波能量，将每个滤波器组与功率谱相乘，随后将系数相加，最终将获得滤波器器组的梅尔系数。

中国知网 https://www.cnki.net

在计算每一帧的梅尔滤波能量时，首先需要根据公式（3-15）计算出$X(i,k)$的谱线能量$E(i,k)$，即对 DFT 的输出进行平方，这反映了声音在每个频率的功率。

$$E(i,k) = [X(i,k)]^2 \quad (3\text{-}15)$$

然后利用公式（3-16）计算该谱线能量，应用这组三角形梅尔滤波器组，将其转换为梅尔功率谱，即梅尔滤波能量。

$$S(i,m) = \sum_{k=0}^{N-1} E(i,k)H_m(k), \quad 0 \le m \le M \quad (3\text{-}16)$$

其中，i代表的分帧之后的第i帧声音信号，k代表的是频域中的第k条谱线，M是该组梅尔滤波器组中滤波器的个数，$H_m(k)$是滤波器组的频域相应函数。其中，$H_m(k)$满足公式（3-14）所示的函数关系。

（4）计算对数的滤波器能量

从 Mel 滤波器库的输出中取对数，随即对求得的梅尔滤波能量取对数，然后进行离散余弦变换以去除重叠滤波器之间能量的关联性，得到梅尔频率倒谱系数 MFCC，如公式（3-17）所示。

$$mfcc(i,n) = \sqrt{\frac{2}{M}} \sum_{m=0}^{M-1} \log[S(i,m)] \cos\left(\frac{\pi n(2m-1)}{2M}\right) \quad (3\text{-}17)$$

公式（3-17）中，$S(i,m)$代表的是求得的梅尔滤波能量，M代表的是梅尔滤波器组中滤波器的个数，i代表的分帧之后的第i帧声音信号，n代表的是求得倒谱后的谱线，也就是 MFCC 的阶数。图 3-5 为 13 维生猪咳嗽声梅尔频率倒谱系数示意图。

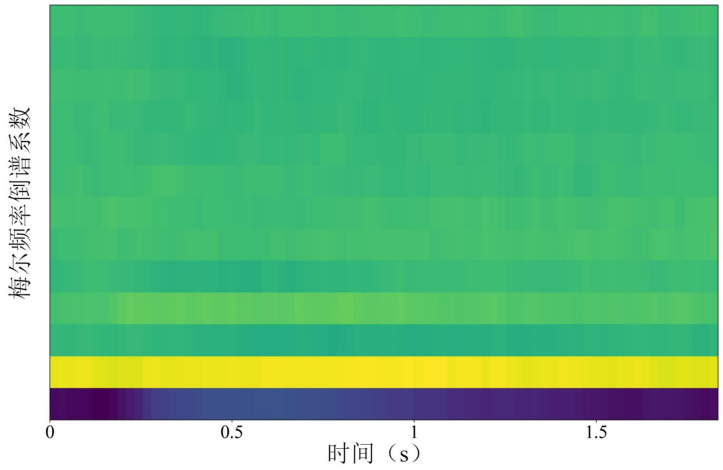


图 3-5 梅尔频率倒谱系数

Figure 3-5 Mel frequency cepstral coefficients

3.3 特征选择与解释

特征选择是指从原始特征集合中选择最具有代表性的特征子集的过程。尽管来自不同域下的声音特征所包含的信息各有不同，但来自同一声音信号提取的声音特征之间存在一定的关联。特征种类的增加带来特征维度的增加，同时引入了声音信息的干扰因素。因此，为了剔除特征间的冗余信息，改善特征数据质量，提高后期特征在分类算法上的分类性能，本文

中国知网 https://www.cnki.net

将基于 XGBoost 的递归特征消除（Recursive feature elimination with cross validation，RFECV）特征选择算法应用于生猪咳嗽声的特征选择，通过结合包裹式特征选择算法的优势，将 XGBoost 模型作为内嵌预测模型，并结合 SHAP（SHapley Additive exPlanations）法中的树模型解释器的优势，从多域提取的一维声学特征中选择最具代表性的咳嗽声声学特征子集并进行特征解释。

3.3.1 基于 XGBoost-RFECV 的特征选择

3.3.1.1 基于交叉验证的递归特征消除算法

递归特征消除（Recursive feature elimination，RFE）算法是一种包裹式的特征选择算法[130]。其特点是算法将某种机器学习算法嵌入共同训练，以得到每种特征的权重系数，来判定特征的重要性，以此进行模型识别能力的预测，最后返回最佳识别精度的特征个数。该算法的核心是每次预测模型分类精度时，将前一次特征重要性排序中最低的特征剔除掉，进行分类预测。所有的过程都是循环执行的，直到没有剩余的特征。最后，将最优的精度预测结果所对应的特征个数输出，进而构建最优特征组，以此通过降低特征个数而降低整体模型维度。在整个过程中采用交叉验证方式，进行 n 次不同列的特征子集的循环重复，期间选择交叉验证预测精度最高的特征组合，作为输出的最优特征子集。基于交叉验证的递归特征消除特征选择算法，如算法 3-1 所示：

算法 3-1 基于交叉验证的递归特征消除特征选择算法

Algorithm 3-1 Recursive feature elimination with cross validation

输入：F_i 个原始特征集 $i = 1，2\cdots f$ ，内置模型 M，数据训练集 D，交叉验证次数 $j = 1,2，\cdots n$；

输出：最优特征子集 F_best；

```
for j = 1,2，…n：
    对训练集 D 进一步划分为 D-1 个训练子集和 1 个测试集
    采用划分后的新训练集，训练特征集合 F_i
     for i = 1，2…f：
        取特征集合 F_i 中个特征 i 输入到模型 M 中
        计算 i 个特征的重要性
         获取模型预测结果
         删除特征重要性最低的特征
      end
end
将交叉验证 n 次的模型预测结果求平均，得到预测结果最佳的特征数量
返回 F_best
```

3.3.1.2 XGBoost 算法

在本研究中，选择 XGBoost 算法作为 RFECV 的内置模型，基于三个主要原因。首先，XGBoost 的核心是一种基于决策树的 Boosting 集成方法，是最流行的梯度增强机增强树算

中国知网 https://www.cnki.net

法之一。由于其解决问题的能力强，因此在工业上得到了广泛的应用[131]。其次，XGBoost更容易用于在CPU上执行的小数据集，且XGBoost不受多重共线性影响的这一特性[132]，使其可以在模型预测过程中保留初始所有声学特征，最大程度地降低舍内声音信号存在一定程度相似性带来的影响。最后，结合SHAP方法的树模型解释器的优势，共同对猪舍内声音的多种声学特征进行深入分析和讨论。

XGBoost在2016年被提出，其核心是基于树模型进行改进和优化，进而在模型的分类效率和准确性之间取达到平衡状态。其表达式如下所示：

$$\hat{y}_i = \sum_{i=1}^{k} f_k(x_i), f_k \in \mathcal{F} \tag{3-18}$$

其中，x_i为输入样本，模型中的决策树的数量为k，则$f_k(x_i)$为输入样本x_i在第k棵树的结果。其目标函数公式如下：

$$\text{obj}\,(t) = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \Omega\big(f(t)\big) \tag{3-19}$$

$$\Omega\big(f(t)\big) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} \omega_j^2 \tag{3-20}$$

其中，$l(y_i, \hat{y}_i)$是目标y_i和其预测值$\hat{y}_i$的损失函数。$\Omega(f(t))$是目标函数的正则项，其代表了整棵树的复杂度。γ是惩罚系数，其目的是通过控制叶节点数目以避免过度拟合。λ是正则化系数，T是叶节点总数，ω_j是叶节点的权重。正则项$\Omega(f(t)$的大小由叶节点的总数和权重的向量范数共同决定。生成新的决策树时，需要对前一次的预测残差进行拟合，并最小化损失函数。如下所示：

$$\hat{y}_i^t = \hat{y}_i^{t-1} + f_t(x_i) \tag{3-21}$$

得到新的目标函数如下所示：

$$\text{Obj}\,(t) = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{t-1} + f_t(x_i)\right) + \Omega f(t) \tag{3-22}$$

在此基础上，对目标函数应用泰勒级数，得到最终的目标函数：

$$\text{obj}\,(t) \cong \sum_{j=1}^{t} \left[G_j \omega_j + \frac{1}{2}\big(H_j + \lambda\big)\omega_j^2\right] + \gamma T + \text{ constant} \tag{3-23}$$

其中，$G_j = \sum_{i \in I_j} g_i$，$H_j = \sum_{i \in I_j} h_i$，$g_i$是目标函数的一阶导数，$h_i$是目标函数的二阶导数，$I_j$定义为每个叶节点上样本的集合$I_j = \{i | q(x_i) = j_i\}$。

基于XGBoost-RFECV递归特征消除特征选择方法，如图3-6所示。该内嵌预测模型的包裹式特征选择算法对于特征数据更具有灵活性、鲁棒性及泛化性，同时不易出现过拟合的现象。传统的XGBoost计算特征重要性采用三种常见的方法，包括F权重，Cover覆盖法以及Gain增益。其中，F权重是指XGBoost模型在训练时选择该特征值生成叶子节点的总次数。覆盖率指标是指特征分割的平均覆盖率，其中覆盖率定义为受分割影响的样本数。Gain增益意味着相应的特征对模型的相对贡献，其计算方法是将每个特征对模型中的每棵树的贡献都计算在内。XGBoost所提供的三种评估特征的重要性排序的方法侧重不同，而通常三种不同的计算方式会导致结果差异较大[133]。

中国知网 https://www.cnki.net

事实上，当模型改变且对某种特征仍然存在依赖时，这种特征的归属重要性不应减少，这一点可以保持特征重要性的一致性。另一方面，应当同时考虑所有特征重要性以及其对模型预测的重要性，这一点可以保证特征重要性的准确性。因此，在兼具一致性和准确性的基础上，本文进一步采用 SHAP 法进行特征解释。

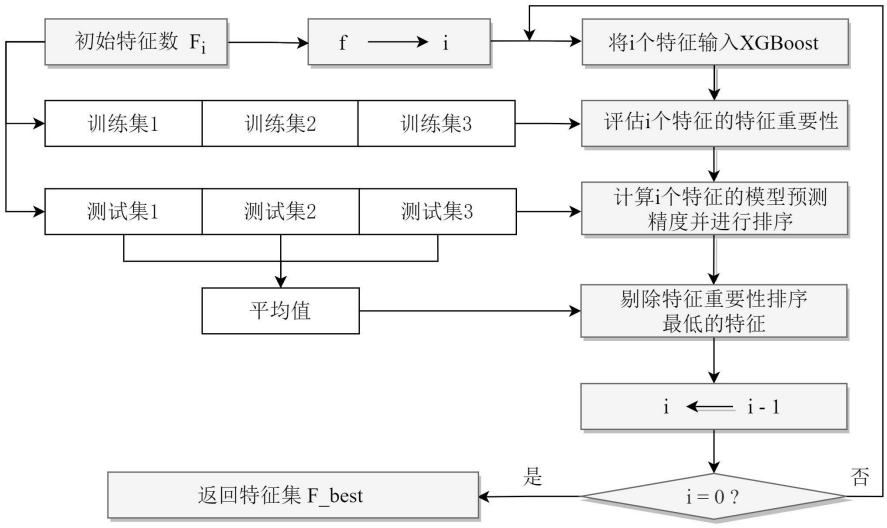


图 3-6 基于 XGBoost-RFECV 递归特征消除特征选择方法

Figure 3-6 Recursive feature elimination with cross validation based on XGBoost

3.3.2 基于 XGBoost-SHAP 的特征解释

Lundberg 和 Lee 提出的 SHAP 法是一种进一步解释单独特征重要性并理解机器学习模型的重要方法[134]。SHAP 是基于博弈理论上的最优 Shapley 值，而 Shapley 值是计算任何机器学习模型的单一预测特征贡献的解决方案。本文采用 SHAP 方法基于两大主要原因：一是 SHAP 符合公平性数学定义的特征属性方法，其具有坚实的理论基础。预测值在特征值中是公平分布的，有助于统一机器学习的可解释性。二是 SHAP 对基于树的模型的预测解释实现较快。

SHAP 的目标是通过计算每个特征对预测的贡献来解释一个实例x的预测。SHAP 解释方法从合作博弈理论中计算出 Shapley 值。合作博弈论是指多个个体分别提供各自的贡献，同时通过合作获取比单独行动更大的利益。此时，利用 Shapley 值提供了单一个体在合作中贡献大小，其计算公式如下所示：

$$\phi_i(v) = \sum_{S \in N} \frac{[(|S|-1)!(n-|S|)!]}{n!} \times [v(S) - v(S \setminus \{i\})] \tag{3-24}$$

其中，N代表n个特征组成的集合；S为部分成员组成的新的团队，S为N的子集，$v(S)$为团队S获得的利益；$\phi_i(v)$为第 i 个成员贡献大小，即对应的 Shapley 值。Shapley 值越大说明该成员在团队内贡献越大。将 Shapley 值用于解释机器学习模型中特征重要性的公式如下所示：

$$\phi_i(f, x') = \sum_{S \subseteq F\{x_i'\}} \frac{|S|!(M-|S|-1)!}{M!} \left[f\left(S \cup x_i'\right) - f(S) \right] \tag{3-25}$$

中国知网 https://www.cnki.net

其中，M为特征个数，F为所有的特征的集合，f为被解释的模型，$x^{'}$为被解释的特征向量的实例，$x_i^{'}$为特征向量合集中第i个特征，$F\{x_i^{'}\}$表示排除$x_i^{'}$的特征集合，S是$F\{i\}$的所有子集的组合，ϕ_i即第i个特征的 Shapley 值。

$$\emptyset_i(v)=\sum_{s\subseteq N\setminus\{i\}}\frac{|S|!(n-|S|-1)!}{n!}\big(v(S\cup\{i\})-v(s)\big) \tag{3-26}$$

其中，$v(s)$表示对S中特征值的预测，$\sum_{\mathrm{s\subseteq N\setminus\{i\}}}\frac{|\mathrm{S}|!(\mathrm{n}-|\mathrm{S}|-1)!}{\mathrm{n}!}$表示权重，$\big(v(S\cup\{i\})-v(s)\big)$表示新增特征$i$前后的变化值。通过对每个特征值的属性进行比较，进而对特征重要性进行排序。$\emptyset_i(v)$模型输出的贡献是基于某一特征与其他特征相比的边际贡献衡量的。

SHAP 带来的创新是 Shapley 值解释被表示为一个加法特征归属方法，即一个线性模型。SHAP 将该解释规定为：

$$g\big(z^{'}\big)=\phi_0+\sum_{j=1}^{M}\phi_j z_j^{'} \tag{3-27}$$

其中，g是解释模型。$z^{'}\in\{0,1\}^M$是联盟向量，也称之为简化特征。M是最大联盟数量，即特征个数。ϕ_j是每个特征j的特征属性，即 Shapley 值。$z^{'}$中的值为 1 时，意味着对应特征在解释模型中发挥作用，相反，当$z^{'}$值为 0 时，意味着该特征没有被解释。ϕ_0为基值。一般情况下，每一个实例都默认参与被解释的过程，此时所有的$z^{'}$都为 1，公式随即简化为：

$$g\big(x^{'}\big)=\phi_0+\sum_{j=1}^{M}\phi_j \tag{3-28}$$

基于 XGBoost-RFECV 特征选择方法，进一步采用 SHAP 法中的树模型解释器（TreeExplainer）对模型中的特征进行全局解释和局部解释。全局可解释性是基于完成数据集上的特征间的交互来解释模型决策结果，从而显示特征对模型结果的总体影响。SHAP 法通过计算特征集的每一个特征对模型结果的贡献，来进一步解释每个特征的重要性及解释模型判断结果。常规的特征重要性排序采用基于树模型内的信息增益法，这种方法的核心思想是依托于树根附近的特征比树叶附近分割的特征更重要这一思想。然而这种特征解释也引起了一定的偏见和模型最终性能误差。不仅如此，相比于单一的特征重要性排序，树形 SHAP 法在数学上相当于对所有可能的特征排序进行平均预测差异满足在输出每个样本特征影响力的基础上，进一步揭示特征影响的积极性和消极性。同时，SHAP 法通过查看特征间的相互影响来对特征子集结果进行局部解释，即一个特征与另一个特征对模型结果是提供补充信息还是干扰信息。由于一个特征和数据集之间变化的交互影响，所以 Shapley 值被用来强制执行一致性和准确性，这也是使用 SHAP 方法来解释全局特征的一大优势。

3.4 识别模型构建与优化

3.4.1 机器学习模型构建

近年来，得益于机器学习取得的技术突破[64]，其在不同研究领域下的识别准确性和应用性有了很大的提高。为了评估提取声音的声学特征的识别能力，本文将随机森林

中国知网 https://www.cnki.net

（Random forest，RF）、支持向量机（Support vector machine，SVM）[135]和 K-近邻算法（K-Nearest Neighbor，KNN）[136]应用于生猪咳嗽的识别任务。

3.4.1.1 随机森林

随机森林是最常见的 Bagging 集成学习方法之一，它由多个决策树的集合构成一个森林。Bagging 是一种基于自助采样法（bootstraping）的统计方法，通过独立地拟合数据来产生不同的数据集，进而形成一个集合模型。该方法采用随机替换抽样的方法，将训练集放回，生成新的训练子集；然后分别用不同的训练子集对单个分类器进行训练，最后将他们整合为一个整体。

决策树是一种基于树结构的分类模型。通常，决策树包含一个根节点和许多分支路径以及分支路径上的节点和分支路径的终点，称之为叶节点。在测试时，将测试样本从根节点开始，根据内部节点对应的判断条件，逐步找到一条能满足所有判断条件且能通往叶节点的分支路径，最终测试样本的类别即为其所到达的叶节点所属的类别。决策树的构造，算法过程如下：

步骤（1）：输入训练数据；

步骤（2）：构建根节点，将所有训练数据都放在根节点；

步骤（3）：从所有特征中选择一个最优划分特征，按照这一特征将训练数据集分割成子集；

步骤（4）：如果某个子集已经能够被基本属于同一类别，则构建叶节点，并将这个子集分到对应的叶节点；

步骤（5）：如果某个子集不具有基本属于同一类别的特性，则重复步骤（2）到步骤（4）；

步骤（6）：直到每个子集都被分到叶节点上，即每个子集都有了明确的类别，此时就构建了一颗决策树。

当在不同的数据集上训练模型时，Bagging 通过减少误差的差异来减少分类器的方差。这是由于训练数据的不同，导致各个模型的结果存在一定差异，然而这些误差在最终投票时在一定程度上被抵消。决策树是 Bagging 中基分类器的一个很好的选择，因为决策树相对复杂，可以在任何样本上实现零分类误差，但也带来了冗余和较大的计算量。

在此基础上，随机森林是基于 Bagging 的一种改进，随机森林中随机子空间方法减少了树之间的相关性，从而防止了过度拟合。随机森林重复地从数据集中有替换地选择数据，并在每个新的样本中建立一棵决策树。同时，决策树的每个节点只考在特征的随机子集上分割。在用随机森林进行分类的情况下，使用森林中的每一棵树来获得预测。随机森林算法更加高效，且更具鲁棒性，已在众多领域获得较为稳定和优异的表现。随机森林模型原理图，如图 3-7 所示。

中国知网 https://www.cnki.net

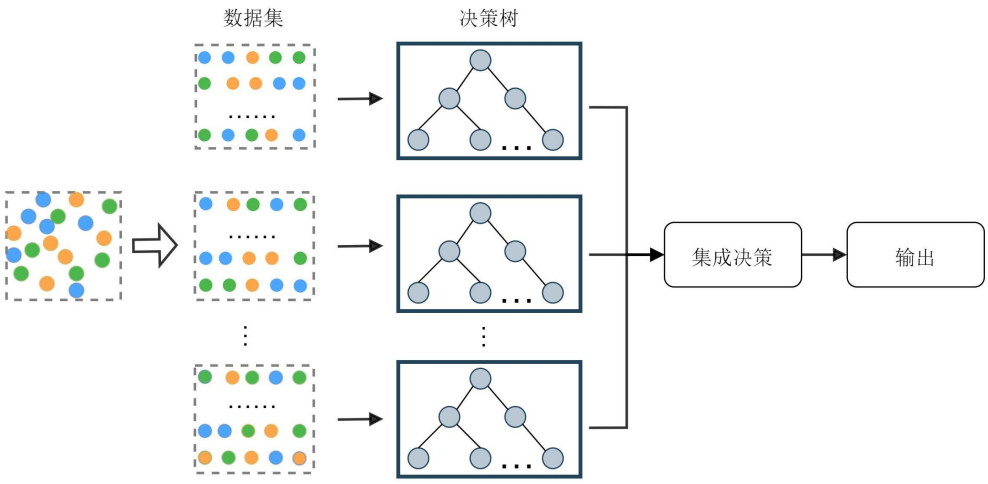


图 3-7 随机森林模型原理图

Figure 3-7 Schematic diagram of random forest

3.4.1.2 支持向量机

支持向量机是一种常见的用于分类问题的学习模型，已在许多现实问题中产生较好的效果。其算法核心是利用核函数创建决策边界将输入数据映射到高维空间，以实现数据的分类任务。如果数据点被绘制在一个二维图形中，那么决策边界被称为直线。然而，如果有两个以上的维度，这些被称为超平面。如图 3-8 所示，根据 SVM 算法，从两类中找到最接近直线的点，这些点被称为支持向量。随后，计算线和支持向量之间的距离，这个距离被称为边际。计算目标是使余量最大化，余量最大的超平面就是最优超平面。当数据线性不可分时，可以通过给数据增加一个额外的维度，使其成为线性可分离的，然后用数学变换将决策边界投射回原始维度来对数据进行分类。

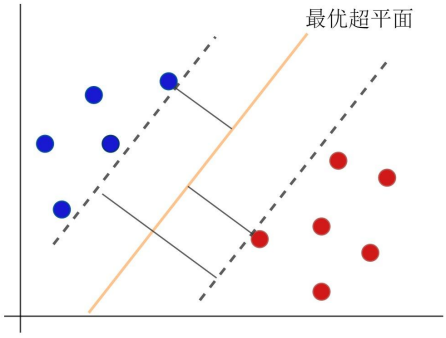


图 3-8 支持向量机模型示意图

Figure 3-8 Schematic diagram of SVM

惩罚系数（C）控制着平滑决策边界和正确分类训练点之间的权衡。大的 C 值意味着更多正确的训练点。同时，也意味着实验中选择更加复杂的决策曲线。核函数系数（gamma）定义了单个训练实例的影响有多大。如果 gamma 的值很高，那么决策边界就会依赖于离线

中国知网 https://www.cnki.net

很近的点，这实际上导致忽略了一些离决策边界很远的点。这是因为较近的点得到了更多的权重。另一方面，如果 gamma 值较低，即使是较远的点也得到了相当大的权重，进而得到一个更加线性的曲线。

SVM 在音频数据分类中既可应用于线性数据，也可应用于非线性数据。它使用非线性映射将音频训练数据转换为更高的维度。训练数据转换后，搜索线性理想隔离超平面[137]。SVM 分类器尝试利用不同类别之间的线性或非线性划分来划分音频数据空间。因此，在不同映射方式中，从中找到理想的边缘，然后用于分类，以提高训练和测试的速度[138]。

3.4.1.3 K 最邻近算法

K 最邻近算法是一种应用广泛的监督分类算法，它保留了所有的训练数据，其核心是通过计算输入样本和每个训练实例之间的相似度来进行预测和分类[139]。KNN 不对数据分布做任何假设，因此它是非参数性的，其常在决策边界非常不规则的分类情况下取得成功。KNN 算法过程如下：

步骤（1）：将每一个样本作为 1 个参考点；

步骤（2）：接收全部数据集，并对数据进行预处理；

步骤（3）：设置参数K，K为最临近的邻居点的数量。K值的最佳选择一般决定于原始数据的差异，即不同的数据对象，最佳的K值一般差异较大；

步骤（4）：计算待样本与已知样本之间距离，闵可夫斯基（Minkowski）距离测量法，找到点之间的距离；

步骤（5）：将获得距离结果从小到大排序；

步骤（6）：找到与样本最接近的K个点，然后通过多数投票对点进行分类。将最多归类样本作为一类，输出预测结果。

在 KNN 中，邻居数（K）是一个超参数，需要在建立模型时选择。可以把K看作是预测模型的一个控制变量。由于每个数据集都有它自己的需求，因此没有适合所有类型的数据集的最佳K值。一般情况下，在邻居数量少的情况下，噪音对结果的影响较大，而邻居数量多的情况下，计算成本高。同时，较小的K值是最灵活的拟合，这将有低偏差但高方差，而大量的K将有一个更平滑的决策边界，这意味着更低的方差但更高的偏差。因此，超参数K是 KNN 算法的关键。

3.4.2 参数设置与优化

由于机器学习算法以及原始数据集的目标分类任务的不同，为了提高算法的识别精度，配置和管理机器学习的参数是非常必要的。这个过程可以使用算法的默认值、参考以往研究的设置或在实验过程中手动设置，这往往依赖于研究人员的经验。为减少应用机器学习所需的人力，同时避免个人经验带来的局限性。目前可以通过超参数优化，作为另一种解决方案。其目的是通过评估独立测试集上的预测或运行交叉验证重采样方案，试图在候选配置的超参数搜索空间上最小化算法的预期泛化误差[140]。这一过程通过自动设置这些超参数来优化机器学习算法的性能，同时也在一定程度上提高了科学研究的可重复性。超参数优化是为给定算法找到最佳参数组合的过程。它由方程式表示如下：

中国知网 https://www.cnki.net

$$\lambda^* = \arg\max_{\lambda \in \Lambda} f(\lambda) \quad (3\text{-}29)$$

其中，Λ是超参数组合的空间，λ是定义域Λ中超参数的任意组合，$f(\lambda)$，$\lambda \in \Lambda$度量了超参数λ组合后机器学习系统的性能。性能通常定义为精度或使用任何其他指标。优化算法试图找到使$f(\lambda)$最大化的超参数$\lambda = \lambda^*$的组合。常用的超参数优化方法背后的思想是以某种方式限制搜索空间，使$\Lambda' \subset \Lambda$是超参数组合空间的一个合理大小的子集，随后通过穷尽搜索得到最佳构型$\lambda \in \Lambda'$。

网格搜索以一种系统的方式定义了Λ'，具体来说就是Λ中的一个网格。网格搜索是一种在搜索空间中搜索超参数的系统方法，它将创建所有可能的组合，而不管优化过程中元素的影响如何，所有参数都有相同的概率影响该过程[141]。基于网格搜索的优势，本文采用网格搜索方法为每个分类器选择最佳的分类器参数，它简单地在训练算法的超参数空间的给定子集上进行完全搜索。这也在一定程度上保证了参数搜索的覆盖性。由于机器学习算法参数空间可能包括一些参数具有实值或无限值的空间，因此需要指定边界以应用网格搜索。

本章中所用的机器学习算法涉及的关键参数的搜索范围如表 3-1 所示。SVM 的核函数（$kernel$）的选择主要锁定在线性核函数（$linear$）及非线性的 RBF 核函数（rbf）。KNN 的超参数$n_neighbors$，即 K 值的选择是算法的关键。对于 RF 的$n_estimators$超参数，它是算法在采取最大投票之前所建立的树的数量。一般来说，树的数量越多，性能就越好，预测就越稳定，但也会减慢计算速度。另一个重要的超参数是min_sample_leaf，这决定了分割一个内部节点所需的最小叶数。

表 3-1 不同分类器的主要参数设置

Table 3-1 Grid search of the main parameters for each classifier

模型	超参数范围
SVM	$Kernel$: ‘linear’, ‘rbf’; C:1, 10, 100; $Gamma$:0.1, 0.01,0.001;
KNN	$n_neighbors$: (1,50);
RF	$n_estimators$: (10,50); $min_samples_split$: (2,9);

3.5 实验结果与分析

3.5.1 实验设置

为提取不同的传统声学特征，选用 Librosa 0.8.1[142]工具箱，采样率为 44.1kHz。本研究训练模型基于 Intel(R) Core (TM) i7-10750H CPU 2.6GHz，RAM 16GB，NVIDIA GeForce GTX 1650 Ti GPU，64 位 Windows 10 操作系统。实验涉及相关数据分析和模型建立均使用 Python 3.7，Scikit-learn 在 PyCharm Community Edition 2020 软件环境中完成。实验结果的图表呈现采用 Matplotlib 3.3.1 及 Seaborn 0.11.1。

实验采用 2.2.3 中的舍内声音平衡数据集，其中咳嗽声与非咳嗽声的声音片段各占 50%，共计 2546 个舍内声音片段。2.4.1 节中的内嵌交叉验证方法对三种机器学习模型进行评估，

中国知网 https://www.cnki.net

实验结果为k次测试集结果的平均值。本节中测试结果的评价指标采用 2.4.2 中的准确率（Accuracy），精准率（Precision），召回率（Recall），F1 分数（F1-Score），采用百分制（%）的表现形式。除此之外，本章利用多分类混淆矩阵来进一步对比和验证不同声学特征子集在生猪咳嗽声识别任务中的性能。实验结果呈现分成两个主要部分，一是对传统声学特征选择的实验与分析，二是不同机器学习模型对生猪咳嗽声识别的实验和分析。

3.5.2 特征选择实验结果与分析

实验分成两部分：实验一基于 XGBoost-SHAP 对不同特征进行特征解释与分析；实验二基于 XGBoost-RFECV 进行特征选择与结果分析。

3.5.2.1 特征可解释性结果与分析

对特征重要性的评估是分类任务的关键部分。基于 XGBoost 的 RFECV 算法是根据特征值的重要性来进行特征子集的模型预测精度计算。本文使用 SHAP 树形解释器进行全局解释。

如图 3-9 所示，x 轴表示特征对于完整数据集在预测模型的全局平均值(|树形 SHAP|)，是每个特征变量的 SHAP 绝对值的平均值，并由高到低进行排序。相比于频域特征下提取的其他频谱信息，时域特征和倒谱域特征在特征影响力中占据重要地位。其中，ZCR 和 RMS 两种时域特征包含了大量重要的声音信息，这与单位帧内较高的幅值变化有关。MFCC 不同系数所包含的能量信息均占有较大特征影响力。同时，相比 MFCC5，RMS 对模型输出的贡献度次之。另外，特征 Flatness 和 Contrast 贡献度相近，Centroid 影响力最低。

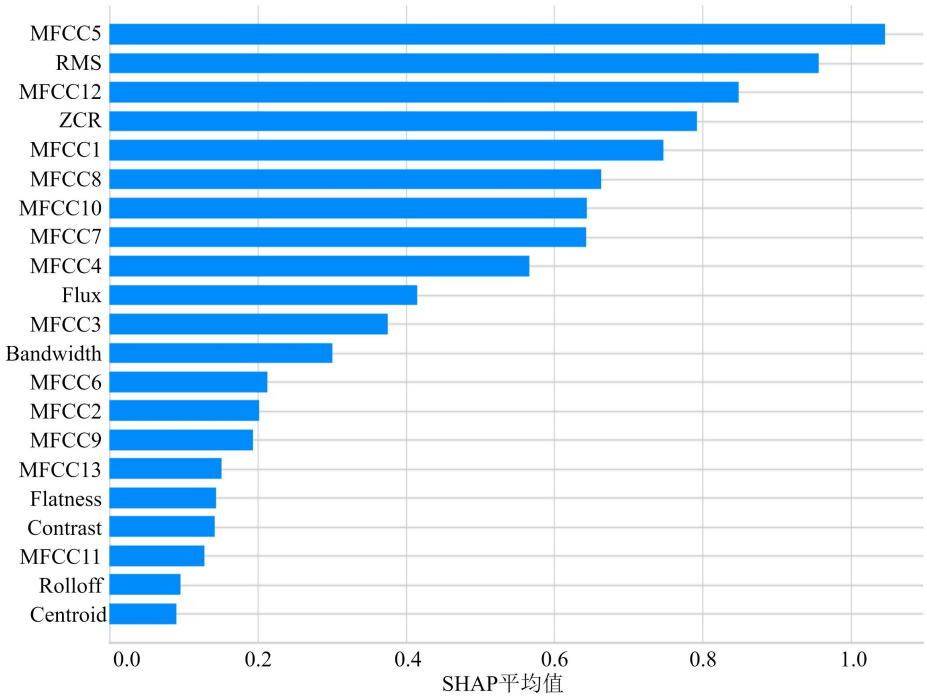


图 3-9 特征重要性排序

Figure 3-9 Ranking of the feature importance

中国知网 https://www.cnki.net

特征重要性是独立计算的，表示的是特征间的影响力大小，即各自的贡献值。为了深入了解不同特征对模型的内在影响，进一步解释不同特征对模型分类性能的影响。图 3-10 结合了特征重要性和特征影响两个要素。图上的每个点都是一个特征和一个实例的 Shapley 值。即为每个样本的每个特征样本描绘 SHAP 值。y 轴上的位置由特征重要性决定，x 轴上的位置由 Shapley 值决定。颜色代表该特征的价值，蓝色到红色表示从低到高。其中，x 轴代表不同特征变量对分类结果的影响。SHAP 值为正表示自变量和因变量之间存在积极影响，相应地，负值即代表消极影响。图中每个点代表一个样本，颜色代表特征的高低。

如图 3-10 所示，MFCC5 对模型影响最大。样本主要位于 y 轴右侧，这表明 MFCC5 的特征较大时，SHAP 为正，对模型分类有积极影响。同时，这也意味着 MFCC5 在提取的 13 个系数中包含了最多的咳嗽声的声音特征信息。与 RMS 的样本特征重要性点主要位于 y 轴左侧，这表明当 RMS 较大时，对模型分类产生负面影响。其蓝色样本位于 y 轴右侧，表明当特征值降低时，模型的分类精度反而会增加。也就是说，单一的 RMS 特征在能量值增大，即声音对应的频率较高时，模型识别易受到混淆，从而降低模型识别精度。最后，Centroid 的影响最小。值得注意的是，纵观 MFCC 不同系数下提取的特征值，以特征影响力较大的 MFCC12，MFCC1，MFCC8，MFCC10 和 MFCC4 为例，较低的 MFCC 特征值更有助于模型输出积极的结果，即对于生猪咳嗽声分类更有有效。由于，MFCC 系数包含不同频谱带的速率变化信息。如果一个频谱系数有一个正值，说明大部分的频谱能量都集中在低频区域。另一方面，如果一个频谱系数有一个负值，则代表大部分的频谱能量集中在高频。这说明高频能量的差异化表示更有助于区分猪舍内的生猪咳嗽声。SHAP 方法有效地梳理出了驱动模型性能的重要特征。

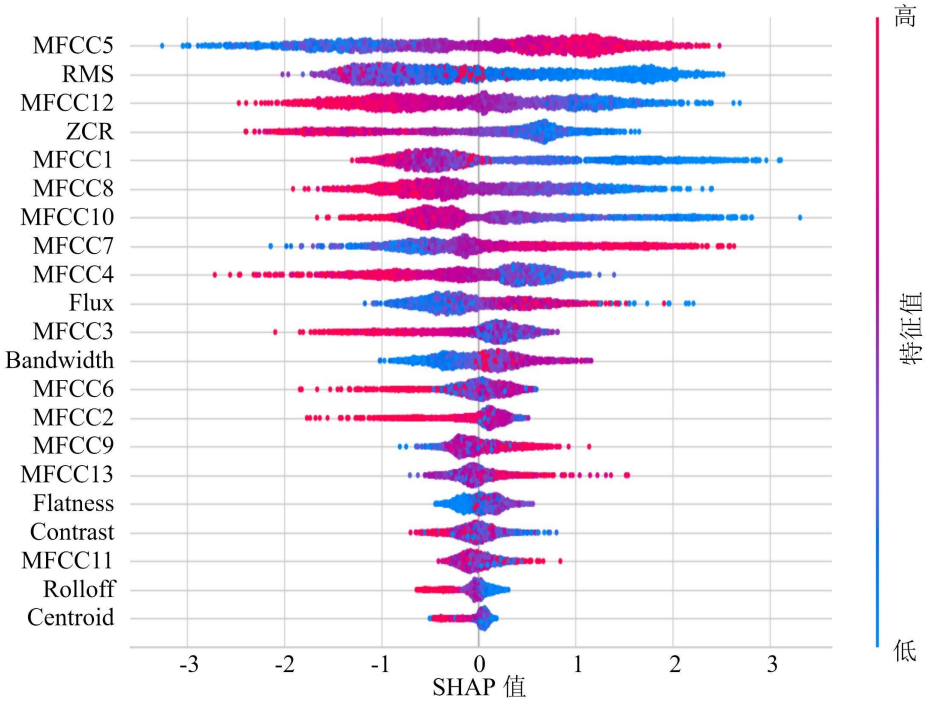


图 3-10 全部样本的 SHAP 值分布情况

Figure 3-10 Distribution of SHAP values for feature samples

中国知网 https://www.cnki.net

为了进一步探究特征类别之间的相互关系及对模型输出的影响，列举了不同特征交互性的 SHAP 分布图，Centroid 与 MFCC5 相互作用部分依赖图如 3-11 所示。该图意味着当声音特征的 Centroid 平均值在 2700Hz 以下，且声音的 MFCC5 平均特征值较高时，对生猪咳嗽声分类具有积极意义。而声音的 Centroid 特征值增大时，MFCC5 将对生猪咳嗽声识别产生负面影响。

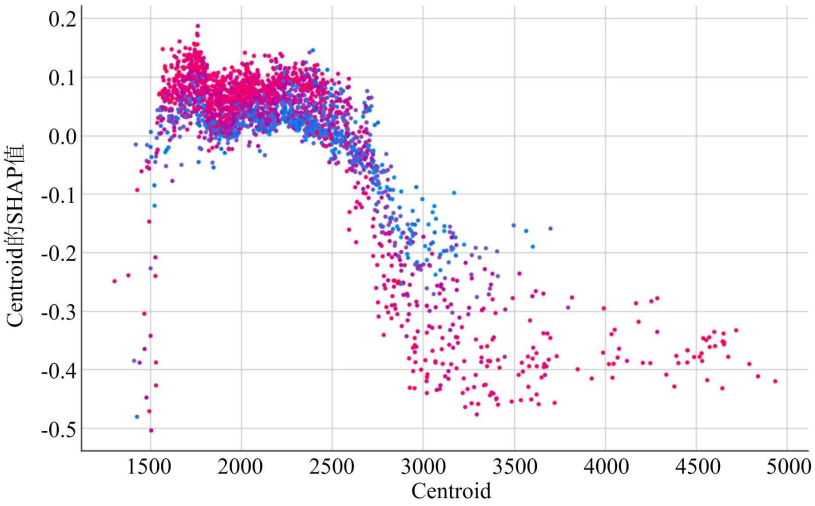


图 3-11 相互作用部分依赖图

Figure 3-11 SHAP feature dependence plot with interaction visualization

3.5.2.2 特征选择结果分析

图 3-12 中显示了基于 XGBoost-RFECV 的模型预测结果。图中根据 SHAP 法输出的特征重要性排序，依次递增逐渐添加特征，以构建动态特征子集，并针对特征子集进行模型验证。对不同的特征子集进行打分，并在该特征集上训练模型 XGBoost 并输出模型的预测分数。这里的 score 分数采用 F1 分数对模型预测结果进行评价。

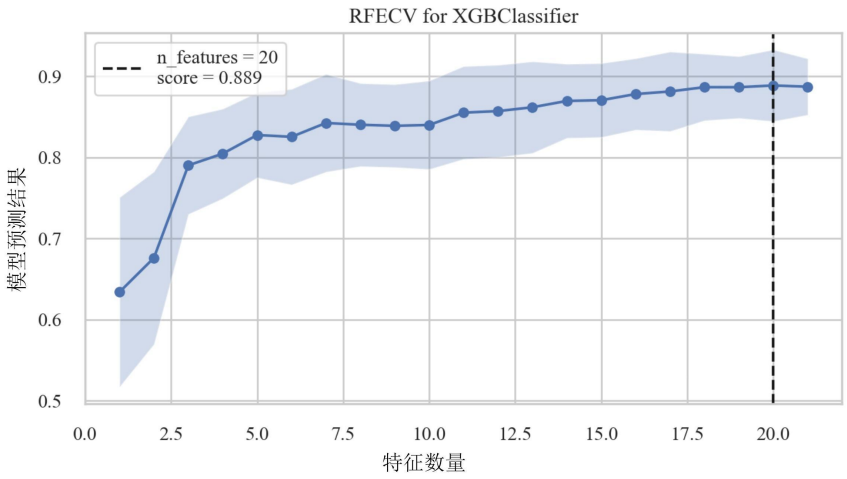


图 3-12 基于 XGBoost-RFECV 的特征选择结果

Figure 3-12 Predictive scores of recursive feature elimination with XGBoost

中国知网 https://www.cnki.net

由图 3-12 可知，当捕捉到前三个重要性较大的特征时，预测曲线跃升到较高的准确性。然后，随着更多的声学特征信息特征被添加到模型中，当特征数量超过 15 个后，整体模型预测分数缓慢提高，此时模型性能趋于饱和。当选择的特征数量达到 20 时，最高预测 F1 达到了 0.8890，此时模型预测结果最佳。当特征集合超过 20 时，模型精度趋于下降，总体准确率不再提高。因此，剔除频域特征下的 Centroid，将时域特征下的 ZCR 和 RMS、倒谱域下的 13 维的 MFCC 以及频域特征下的 Flux、Bandwidth、Flatness、Contrast 和 Rolloff 拼接融合形成 20 维的声学特征子集。该特征子集被判定为生猪舍内具有代表性的传统特征子集，下文简称 Acoustic。

3.5.3 不同识别模型实验结果与分析

实验分成两部分：实验一对比内嵌交叉验证中 k 值在不同识别模型下的识别结果；实验二对比不同声学特征子集下生猪咳嗽声识别性能。

3.5.3.1 内嵌交叉验证中*k*值对生猪咳嗽声识别结果的影响

针对不同的识别任务，机器学习算法间的 k 值、模型验证性能以及计算复杂度具有较大差异。因此，本节基于相同特征子集 Acoustic 下，探究 SVM、KNN 和 RF 在内嵌交叉验证中 k 值对生猪咳嗽声识别结果的影响。

表 3-2 显示了 SVM 在内嵌 k 折交叉验证下实验对比结果。内嵌交叉验证涉及内部（Inner_CV）和外部（Out_CV）两部分 k 值的选择，本文选取常见的三种 k 值进行对比分析，包括 k=3、k=5 和 k=10。由表可知，总体上来看，随着 k 值的增加，模型识别结果计算时间逐步增加，最大时间差可达 56.372s。同时，提高 k 值可以增加模型的预测精度，当 Out_CV 的 k=10 时，无论 Inner_CV 的 k 值如何变化，SVM 模型的模型识别性能趋于平稳，各项评价指标不再变化。准确率、F1、精准率以及召回率的平均值分别达到 95.13%、95.11%、95.50%和 94.75%。模型最优参数为核函数 RBF，C=1 和 Gamma=0.1。

表 3-2 SVM 在 k 折交叉验证下实验对比结果

Table 3-2 Cough recognition rates of SVM based on k fold cross validation

Out_CV	Inner_CV	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
k=3	k=3	94.46	94.45	94.72	94.19	3.476
	k=5	94.23	94.22	94.41	94.03	5.779
	k=10	94.46	94.45	94.72	94.19	11.184
k=5	k=3	94.54	94.54	94.43	94.66	7.769
	k=5	94.23	94.24	94.06	94.44	12.856
	k=10	94.82	94.82	94.83	94.82	24.987
k=10	k=3	95.13	95.11	95.50	94.75	18.698
	k=5	95.13	95.11	95.50	94.75	31.102
	k=10	95.13	95.11	95.50	94.75	59.848

中国知网 https://www.cnki.net

表 3-3 显示了 KNN 在内嵌 k 折交叉验证下实验对比结果。由表可知，当 Out_CV 和 Inner_CV 的 k 值都为 10 时，模型计算时间最长，达到 61.434s；此时，模型准确率和 F1 达到最佳，分别为 93.76%和 93.80%。模型最优参数为 n_neighbors=6。

表 3-3 KNN 在 k 折交叉验证下实验对比结果

Table 3-3 Cough recognition rates of KNN based on k fold cross validation

Out_CV	Inner_CV	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
k=3	k=3	92.85	94.45	92.93	92.02	9.735
	k=5	92.85	92.85	92.88	92.85	10.969
	k=10	92.85	92.85	92.88	92.85	12.311
k=5	k=3	93.64	93.64	93.69	93.64	21.232
	k=5	93.13	93.13	93.19	93.13	23.417
	k=10	93.64	93.64	93.69	93.64	26.066
k=10	k=3	93.56	93.61	92.86	94.45	51.069
	k=5	93.56	93.62	92.66	94.69	55.652
	k=10	93.76	93.80	93.17	94.52	61.434

表 3-4 显示了 RF 在内嵌 k 折交叉验证下实验对比结果。由表可知，当 Out_CV 和 Inner_CV 的 k 值都为 10 时，模型计算时间最长，达到 3221.054s；此时，模型准确率、F1 和召回率达到最佳，分别为 91.44%、91.47%和 91.84%。模型超参数最优结果为 min_samples_split=3，n_estimators=26。

表 3-4 RF 在 k 折交叉验证下实验对比结果

Table 3-4 Cough recognition rates of RF based on k fold cross validation

Out_CV	Inner_CV	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
k=3	k=3	91.16	91.16	91.17	91.16	181.151
	k=5	90.73	90.73	90.73	90.73	342.101
	k=10	91.16	91.16	91.17	91.16	745.983
k=5	k=3	91.24	91.24	91.26	91.24	334.602
	k=5	91.28	91.28	91.31	91.28	661.769
	k=10	91.32	91.32	91.35	91.32	1478.98
k=10	k=3	91.05	91.04	91.10	91.05	740.211
	k=5	91.60	91.62	91.23	92.07	1419.563
	k=10	91.44	91.47	91.15	91.84	3221.054

内嵌交叉验证的优势在于通过 Inner_CV 可以使模型参数最优化，以提高生猪咳嗽声的识别性能。但其也会成倍地提高模型的计算成本和运算时间，因此，在使用内嵌交叉验证的过程中，k 值的选择需要在模型计算时间和模型识别精度之间进行权衡和比较。

综合对比表 3-2、表 3-3 和表 3-4 的结果可知，对比三种机器学习算法，SVM 的识别结

中国知网 https://www.cnki.net

果优于 KNN 和 RF。对比 SVM 内外 10 折交叉验证和内外 3 折交叉验证下的识别结果，准确率从 94.46%提高到 95.13%，F1 分数从 94.45%提高到 95.11%，识别结果相近。然而，随着模型计算复杂度增加，内嵌交叉验证的时间计算成本剧增，RF 的模型计算时间由 181.151s 激增到 3221.054s。为了降低后续特征提取和对比过程中模型复杂度对评价结果的影响，采用内外 3 折内嵌交叉验证进行后续的实验对比分析。

3.5.3.2 对比不同声学特征子集下生猪咳嗽声识别性能

本节中将特征选择后的特征子集 Acoustic，与常用的两种声学特征 MFCC13 和 MFCC20 进行生猪咳嗽声识别性能的对比，结果如表 3-5 所示。

表 3-5 不同声学特征子集下生猪咳嗽声实验对比结果

Table 3-5 Comparision of cough recognition rates based on different acoustic feature set

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
Acoustic	94.46	94.45	94.72	94.19
MFCC13	93.32	93.37	92.80	93.95
MFCC20	93.83	93.87	93.50	94.26

对比表中 13 维的 MFCC 和 20 维的 MFCC 可知，相同倒谱域下的 MFCC 特征，随着特征维数的增加，多组评价指标的结果均有所增加，识别性能得到轻微提升。准确率由 93.32%提升至 93.83%，F1 分数由 93.37%提升至 93.87%。对比相同维度下的 MFCC20 和 Acoustic 特征子集，可以发现 Acoustic，通过融合 13 维的 MFCC 以及时域频域特征，能够更加有效的表达生猪咳嗽声的相关特征信息。在生猪咳嗽声的识别问题上获得更好的结果，主要集中在准确率、F1 分数、和精准率这三个评价指标上，分别达到 94.46%、94.45%和 94.72%。为进一步对比不同子集之间对于舍内声音识别性能的差异性，采用混淆矩阵进一步探究其对多种舍内声音的识别性能，三组特征子集混淆矩阵如图 3-13 所示。

尽管在表 3-4 的咳嗽声与非咳嗽声的识别任务中 MFCC20 的评价指标略优于 MFCC13，对比图 3-13 a)和 3-13 b)可知，MFCC20 在生猪咳嗽声和语音声的识别个数下降，由 404 个降低至 402 个。同时，将生猪咳嗽声误判为生猪叫声的个数增加，由 17 增加至 21。针对生猪叫声和清理声的正确识别个数增加。其中，生猪叫声由 266 增加至 274；清理声由 51 增加至 57。说明 MFCC20 维度增加引起了非咳嗽声识别数量的增加，进而提高了模型整体的识别结果。相比而言，MFCC13 更具有生猪咳嗽声的辨识度。

对比图 3-13 a)和 3-13 c)可知，本文经过特征选择的 Acoustic 特征子集，在咳嗽声的预测值个数不变的前提下，即仍是 404 个生猪咳嗽声。在清理声和生猪叫声的正确预测个数均有所增加。同时，在容易混淆的生猪咳嗽声和生猪叫声之间，二者的错误预测的个数均有所降低。综上，Acoustic 相比单一域下的 MFCC 特征，降低了对生猪舍内其他声音的误判率，在生猪咳嗽声特征判别中具有一定的优势。这也说明，为生猪咳嗽声手工提取传统声学特征并进一步筛选融合，在提高整体识别性能上具有一定的研究潜力。

中国知网 https://www.cnki.net



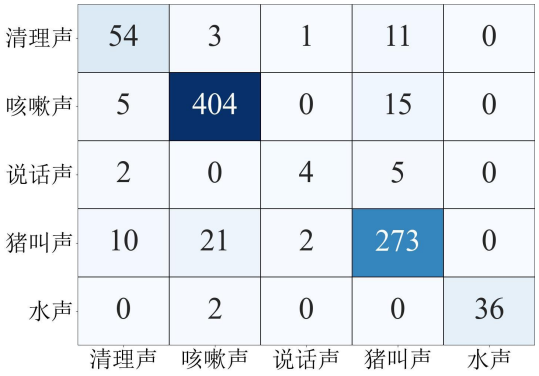
a) MFCC13 混淆矩阵结果

a) Confusion matrix on MFCC13



b) MFCC20 混淆矩阵结果

b) Confusion matrix on MFCC20



c) Acoustic 混淆矩阵结果

c) Confusion matrix on Acoustic

图 3-13 三组声学特征的混淆矩阵

Figure 3-13 Confusion matrix for three features

3.6 本章小结

本章探索时域、频域及倒谱域下的声学特征所包含的声音信息。单一特征域下的特征仅能反应单一角度下的声音变化，不能对同一种声音进行全面的表达，且不同特征间存在一定的信息差异，存在一定的互补性。通过融合不同域下的特征，可以提升对目标生猪咳嗽声的有效识别，提升了单一特征的信息表达能力。主要结论如下：

（1）探究了 XGBoost-SHAP 方法对不同特征的深入解释。以往在提取猪舍内声音特征时多采用人工经验设定，XGBoost-SHAP 深入到不同特征域下的多类特征。结果表明，相比于频域特征，时域特征和倒谱域特征在生猪咳嗽声识别过程中具有较强的辨识度。其中，梅尔频率倒谱系数对模型输出贡献度最高，时域特征下的均方根能量次之，频谱质心影响力最低。

中国知网 https://www.cnki.net

（2）探究了不同域下的声学特征的特征选择方法。将 XGBoost 的循环递归特征消除应用于生猪舍内声音特征的选择，以剔除冗余特征。实验结果表明，依据特征重要性排序，在逐步将单一特征融合到特征子集的过程中，预测模型的精度逐渐提高。时域特征下的 ZCR 和 RMS、倒谱域下的 13 维的 MFCC 以及频域特征下的 Flux、Bandwidth、Flatness、Contrast 和 Rolloff 共同拼接融合形成的特征子集 Acoustic，获得最佳模型预测精度。

（3）探究了不同特征子集对生猪咳嗽声识别性能的影响。采用网格搜索方法替代传统的算法参数的经验判定进而优化分类器，对比 SVM、KNN 和 RF 三种不同机器学习算法。根据实验结果可知，SVM 结合 Acoustic 特征子集获得最佳识别结果，识别准确率为 94.46%，优于 KNN 和 RF。同时，Acoustic 相比单一域下的 MFCC 特征，降低了对生猪舍内其他声音的误判率，在生猪咳嗽声特征判别中具有一定的优势。融合不同域下的传统声学特征能够充分结合声音不同维度下的信息，降低了随机特征融合对模型结果的干扰。

中国知网 https://www.cnki.net

4 基于时频图特征融合的生猪咳嗽声识别

4.1 引言

时频图是由时间和频率两个维度共同描述的声音表示方式[143]。针对于声音的非平稳性，将声音特征转成二维时频图可以保持声音的平移不变性，且二维时频图在时间和频率的双重维度上饱含更丰富和紧凑的声音信息[144]。其本质是将原始声音数据转换为适当的特征空间来进行对声音特征的表达。因此，将声音转为二维时频图已经成为声音处理领域下最具潜力和先进的研究趋势。然而，目前对于生猪叫声及舍内声音的时频图关注较少，少量研究仅基于短时傅里叶变换语谱图表示舍内声音[103]。仅仅基于单一的时频图研究是不够充分的，由于不同的时频图可以提供不同的声音信息，因此本章将采用两种代表性的时频图，包括短时傅里叶变换和常数 Q 变换，对生猪舍内的数据进行时频特征表示，深入挖掘两种时频图所包含的特征信息。

尽管时频图适合听觉内容分析，然而图中检测到的特定频率不能被判定为对应的特定声音。这是由于该频率的振幅可能是由任意数量的累积音频信号产生的，甚至是由音频之间复杂的相互关系产生的。这导致直接从时频图表示中很难区分重叠的音频信号。为此，更好的解决方式是从这些时频表示中进一步提取声音特征。基于图像提取特征的研究主要包括视觉特征以及深度特征提取两个方向。目前，基于卷积神经网络在声音识别领域的应用日益广泛[145]，其优势在于卷积神经网络模型强大的特征学习能力能够有效的提取紧凑的时频图特征。由于卷积神经网络的性能与训练样本量之间存在一定的关系，因此在数据样本有限的情况下，合理设置网络深度和宽度是值得研究的。此外，探索网络层的学习能力，并深入网络内对特征进行有效融合也是网络模型架构的必要关注点。本章与第二章的关联及本章主要研究内容如图 4-1 所示：

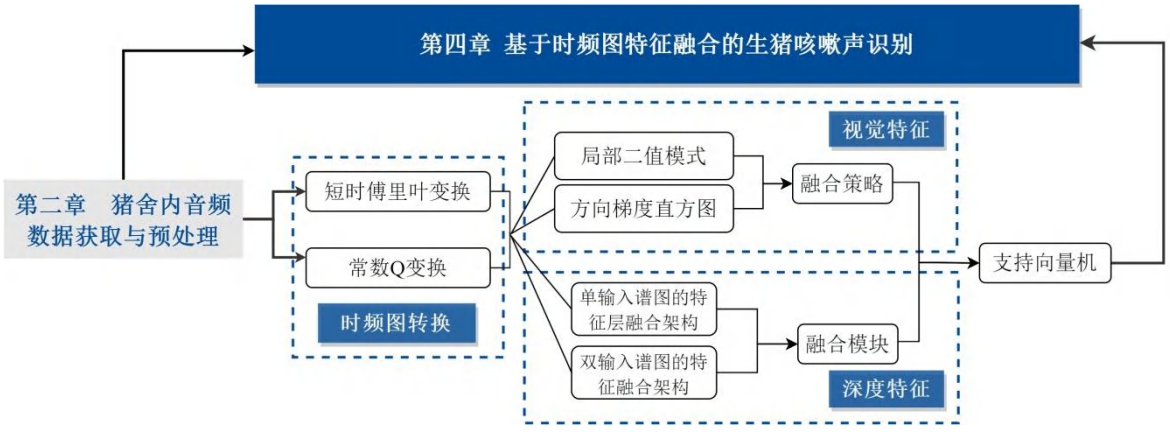


图 4-1 本章的主要研究内容与第 2 章逻辑关系

Figure 4-1 Cohesion diagram of chapter 2 and chapter 4

（1）基于前期第二章在商业猪舍内获取的舍内音频，包括生猪咳嗽声与非咳嗽声，将其由一维声音信号转换为二维的时频图。本章将采用两种代表性的时频图，包括短时傅里叶

中国知网 https://www.cnki.net

变换和常数 Q 变换，对生猪舍内的数据进行时频图特征表示，作为后续深入挖掘声音特征信息的原始谱图。

（2）在时频图基础上进一步提取局部二值模式（LBP）和方向梯度直方图（HOG）两种视觉特征。在提取视觉特征模块中，进一步探究基于 LBP 的多分辨率特征融合以及基于 HOG 的三通道 RGB 的时频图和灰度通道下的时频图特征融合。

（3）在时频图基础上进一步提取图像的深度特征。这里包括本章提出的浅层卷积神经网络以及基于迁移学习的深度卷积神经网络，并进行分类性能的对比和分析。同时，在基于本文构建的卷积神经网络下，提出基于单输入谱图的特征融合架构和基于双输入谱图的特征融合架构。在两种融合架构下进行不同融合策略的对比和进一步分析，探究不同的时频谱图融合，以及评估融合前后对模型识别性能的影响。

4.2 时频图构建

当下，提取音频特征的研究热点和趋势是通过构建不同的声音时频图以获取更高阶的声音特征[146,147]。利用特征的多样性，提供互补的听觉信息以区分复杂的声学环境下的目标声音是可行的[148,149]。本文将猪舍内声音信号转为短时傅里叶变换和常数 Q 变换两种时频图，对声音信号进行时频域的分析，下面将对这两种时频图进行阐述。

4.2.1 短时傅里叶变换

短时傅里叶变换（Short-time Fourier Transform，STFT）的核心是应用傅里叶变换来提取输入信号短时间内的局部频率内容，用于观察时间变化下对应的声音频率的高低变化。傅里叶变换是一种经典的频谱分析方法，该方法将信号分解成不同频率的分量，实现了信号从时域到频域的映射。短时傅里叶变换的过程：对于任一声音片段$x[n]$，将其划分为以帧为单位，每一帧经过窗函数$w[t]$的转换进行加窗分析，随后对帧内的频率采样点进行傅里叶变换，最后建立一种时间与频率的对应表示。计算过程如公式（4-1）所示。

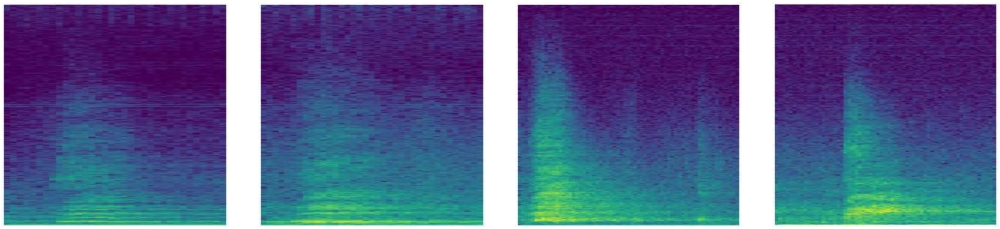
$$\mathrm{STFT}\,[F,T]=\sum_{n=1}^{N}x[n]\cdot w[t]e^{-\frac{j2\pi fn}{N}} \tag{4-1}$$

其中，$x[n]$代表窗口长度为N的音频信号，本文中$w[t]$选择汉宁窗函数。STFT 谱图的时分辨率（T）由跳长决定，频率分辨率（F）取决于窗口长度和音频信号的采样率。在短时傅里叶变换中，N越大，频率分辨率越高，时间分辨率越低；窗长N越小，频率分辨率越低，时间分辨率越高。一般来说，N是时间和频率分辨率之间的权衡，需要根据输入信号的各种特性进行调整。

图 4-2 显示了 N 为 2048 时，猪舍内五类声音的 STFT 时频图，包括生猪咳嗽声、生猪叫声、说话声、清理声以及水声。水平方面表示声音片段的时间变化，垂直方向表示频率由低到高的过程。

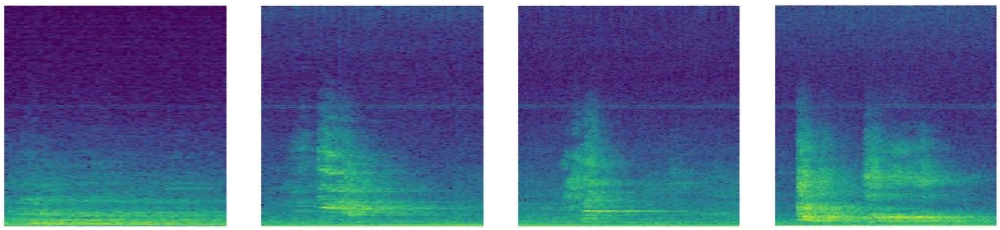
由于咳嗽声的类型不同，如干咳或湿咳等病理性差异，同类别的数据中也存在明显多样性，如图 4-2 a)。在猪舍环境下，生猪其他叫声图 4-2 b)和铁锹的清理声 4-2 d)属于易混淆声音类别，部分说话声和猪舍内的水声则相对容易识别，如图 4-2 c)和 4-2 e)。

中国知网 https://www.cnki.net



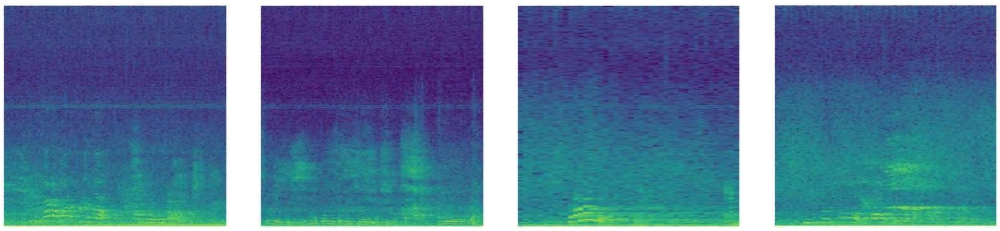
a) 咳嗽声短时傅里叶变换可视化

a) STFT spectrograms of cough sounds



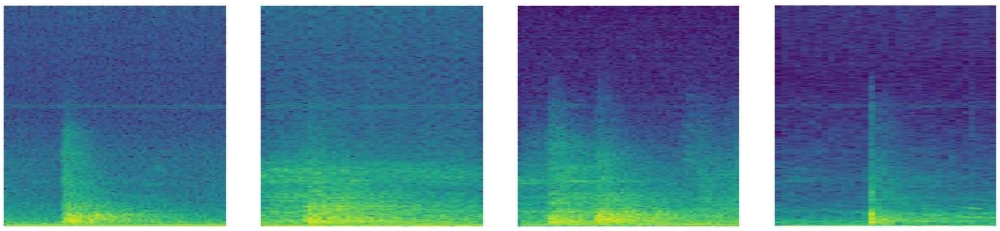
b) 猪叫声短时傅里叶变换可视化

b) STFT spectrograms of pig sounds



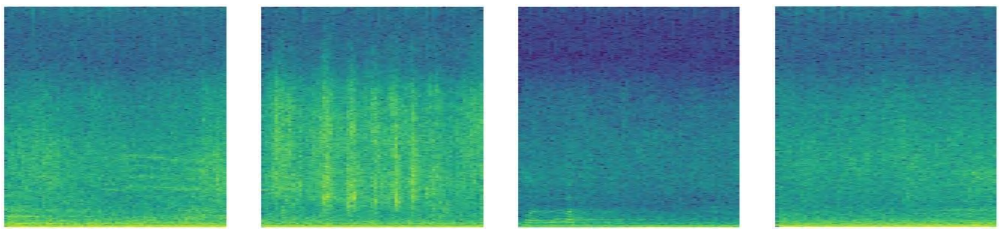
c) 说话声短时傅里叶变换可视化

c) STFT spectrograms of speech sounds



d) 清理声短时傅里叶变换可视化

d) STFT spectrograms of clear sounds



e) 水声短时傅里叶变换可视化

e) STFT spectrograms of water sounds

图 4-2 猪舍内五类声音短时傅里叶变换时频图可视化

Figure 4-2 STFT spectrograms of pig sounds including cough, scream, speech, clear and water

中国知网 https://www.cnki.net

在商业猪舍环境下，由于生猪养殖模式为集约化养殖，因此猪舍环境呈现群猪聚集性的特点。生猪的尖叫可能诱发其他相邻猪只的发声，因此舍内生猪的其他叫声包括尖叫声，嚎叫声等均属于高度易混淆声音类型，这些易混淆声音的共同点均是由于在声音频率方向的重叠性和相似性引起的。

4.2.2 常数 Q 变换

常数 Q 变换（Constant Q Transform，CQT）是一种用于音乐信号处理中的时频分析方法。1991 年，Brown 对 CQT 进行了改进，使得每个滤波器的中心频率成几何分布，从而遵循了西方音乐的十二平均律。十二平均律是指将一个八度音高平均分为 12 等分，每个等分成为一个半音。也就说，CQT 中每个滤波器相当于一个八度音阶的细分[150]。由于音高以指数规律分布，这导致在低频区音符的数量要多于高频区。采用固定窗长的时频分析对窗长的选择更加敏感，由于适应低频区频率分辨率的窗长，会导致高频区的频率解析过度，丢失时间分辨率。

CQT 的频谱中显示的频率分量呈指数规律，人耳听觉系统可以看作一个滤波器组，在约 500Hz 到 20kHz 的范围内其频率分辨率具有近似的常数 Q 性质[151]，也就是说 CQT 能符合人类的听觉特性。其计算过程如下所示。首先，常数Q值被定义为中心频率与带宽之比，如公式（4-2）所示。当中心频率f_k越小，带宽δf_k也越小。因此，CQT 对较低的频率具有较高的频率分辨率。而对于较高的频率，带宽较大，从而具有较高的时间分辨率。

$$Q = \frac{f_k}{\delta f_k} = \frac{f_k}{f_{k+1} - f_k} = \frac{1}{2^{\frac{1}{B}} - 1} \tag{4-2}$$

其中，f_k 是第k个滤波器的中心频率。

$$f_k = f_1 2^{\frac{k-1}{B}} \tag{4-3}$$

其中，f_1是最低频率子带的中心频率，B决定了每八度的滤波器数，这与Q的质量大小有关。$X^{CQT}(k)$代表常数Q变换的k分量，$x(n)$代表输入信号，$w(n,k)$是长度为N_k的窗口函数。

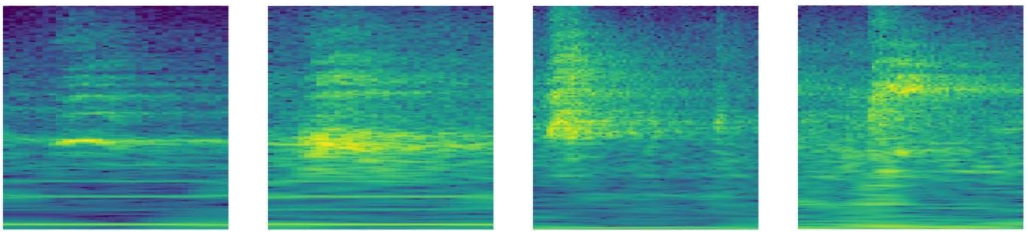
$$X^{CQT}(k) = \frac{1}{N_k} \sum_{n=0}^{N_k - 1} x(n) w(n,k) e^{-j\frac{2\pi Q n}{N_k}} \tag{4-4}$$

其中，

$$N_k = Q \frac{f_s}{f_k} \tag{4-5}$$

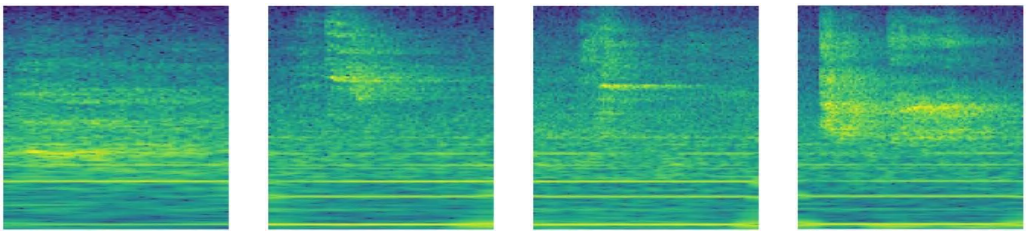
N_k表示随频率变化的窗口长度，f_s表示采样频率。如图 4-3 所示，显示了 B 设置为 32，f_1设置为 22.05Hz 下猪舍内五种声音的 CQT 时频图，包括生猪咳嗽声、生猪叫声、说话声、清理声以及水声。水平方面表示声音片段的时间变化，垂直方向表示频率由低到高的过程。由于猪舍内不同声音在高频方向上的能量分布差异较大。由图可知，相同种类声音下的 CQT 时频图存在一定差异，不同种类 CQT 时频图之间在高频之间差异较大。

中国知网 https://www.cnki.net



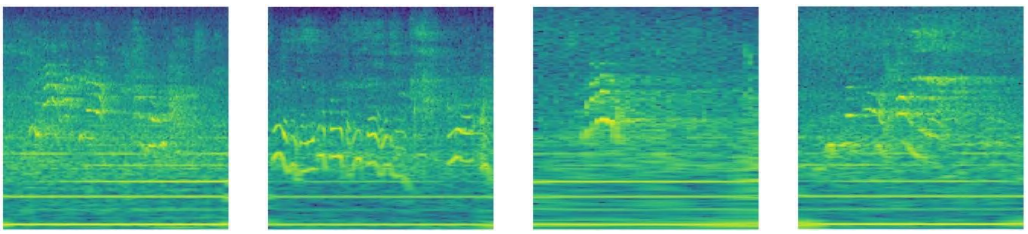
a) 咳嗽声常数 Q 变换可视化

a) CQT spectrograms of cough sounds



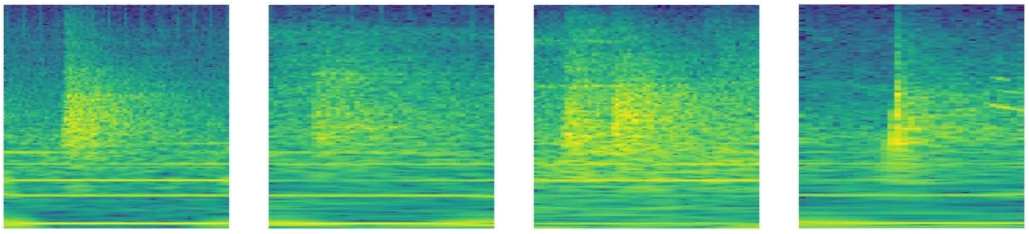
b) 猪叫声常数 Q 变换可视化

b) CQT spectrograms of pig sounds



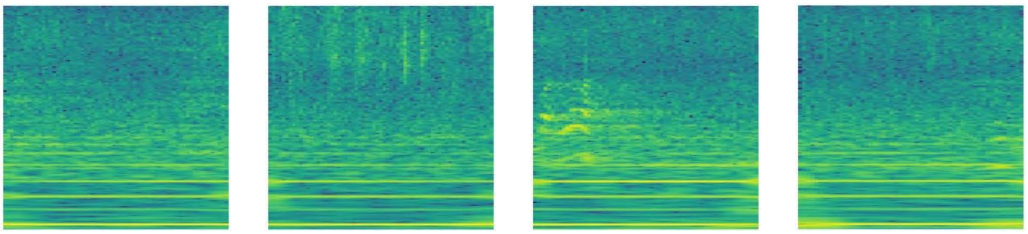
c) 说话声常数 Q 变换可视化

c) CQT spectrograms of speech sounds



d) 清理声常数 Q 变换可视化

b) CQT spectrograms of clear sounds



e) 水声常数 Q 变换可视化

e) CQT spectrograms of water sounds

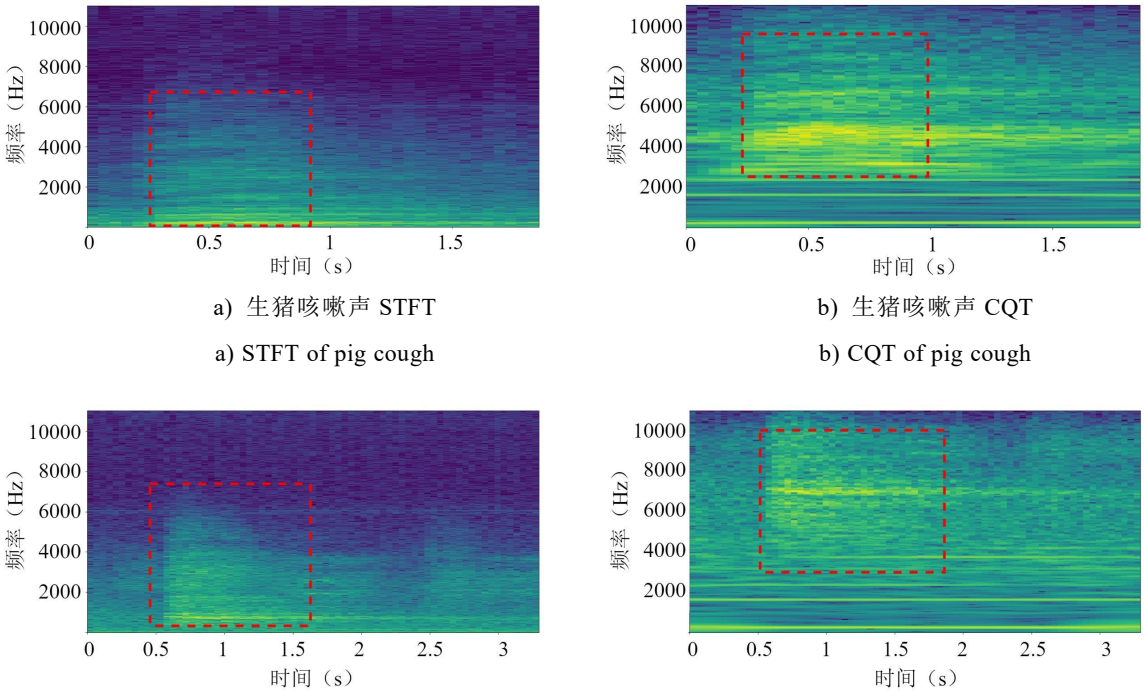
图 4-3 猪舍内五类声音常数 Q 变换时频图可视化

Figure 4-3 CQT spectrograms of pig sounds including cough, scream, speech, clear and water

中国知网 https://www.cnki.net

生猪叫声是猪舍内一种常见且典型的非咳嗽声，其声音频率以高频（5-10kHz）为主，而生猪咳嗽声的频率一般在 2.5kHz 到 8kHz 之间。基于猪舍内各种声音分量的特点，对比时频图可视化能更加直观的解释。图 4-4 为生猪咳嗽声与生猪尖叫声的 STFT 和 CQT 的时频图表示。

对比图 4-4 a)和图 4-4 b)中红色区域可知，CQT 时频图对于高频段生猪咳嗽声描述更加清晰，相比而言 STFT 时频图不足以检测到高频之间微小的差距，其对中低频段描述更加清晰。对比图 4-4 c)和图 4-4 d)具有相同的结果，这也说明了同一声音下的不同时频图表示差异较大。纵向进一步对比对比图 4-4 a)和图 4-4 c)，以及对比图 4-4 b)和图 4-4 d)，说明同一种时频图下的不同声音表达差异较大。这种差异化的时频图表现说明通过强化时频图上高频信息是增加生猪咳嗽声特征辨识度的有效途径。



a) 生猪咳嗽声 STFT

a) STFT of pig cough

b) 生猪咳嗽声 CQT

b) CQT of pig cough

c) 生猪尖叫声 STFT

c) STFT of pig scream

d) 生猪尖叫声 CQT

d) CQT of pig scream

图 4-4 生猪咳嗽声与生猪尖叫声时频图比较

Figure 4-4 Time frequency representations of cough and scream

4.3 基于时频图的视觉特征提取

4.3.1 局部二值模式

局部二值模式（Local Binary Pattern，LBP）是一种有效的用于分析图像纹理特征提取方法[152]，其计算过程如公式（4-6）所示：

中国知网 https://www.cnki.net

$$LBP_{P,R}=\sum_{p=0}^{P-1}s(g_{p,R}-g_c)2^p \tag{4-6}$$

LBP 兼顾了图像的每个像素，它是通过比较每个中心像素g_c和其相邻像素g_p的灰度值来计算的。这里，中心像素g_c和相邻像素g_p之间的距离用 R 表示。$s(g_{p,R}-g_c)$表示以中心像素g_c的灰度值为阈值，对邻域范围内像素点$g_{p,R}$进行灰度值比较并二值化后的结果。如公式（4-7）所示，结果被转换为 1 或 0 的二进制。

$$s(g_{p,R}-g_c)=\begin{cases}1, & if \quad g_{p,R}-g_c\geq 0\\ 0, & otherwise\end{cases} \tag{4-7}$$

LBP 描述子编码原理相对简单，具有图像灰度不变性等显著特点。LBP 编码计算过程如图 4-5 所示：

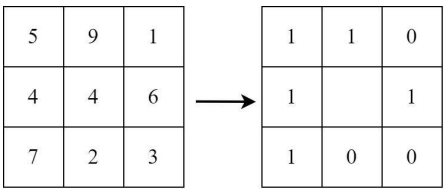
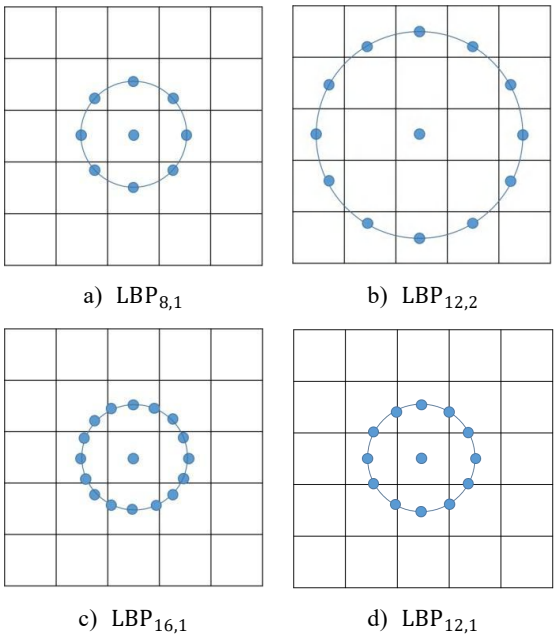


图 4-5 LBP 编码过程

Figure 4-5 LBP encoding process

原始 LBP 的缺点是不能捕获更大规模的纹理结构。为了解决这一问题，采用 LBP 算子提取不同尺度上的特征，也称为多分辨率特征。以（P,R）为代表中心点的最近相邻区域，在圆心距离为 R 的圆周围有 P 个采样点。通过改变 P 和 R 的值，引入了对 TFR 纹理模式的细粒度分析。本研究中，采用四组不同的（P,R）值来探索不同粗粒度下对生猪咳嗽声识别的影响，如图 4-6 所示。这四组（P,R）值包括（8,1）（12,2），（16,1）和（12,1）。



a) $LBP_{8,1}$　　b) $LBP_{12,2}$

c) $LBP_{16,1}$　　d) $LBP_{12,1}$

图 4-6 四组 LBP 特征描述符

Figure 4-6 Four LBP descriptors with $LBP_{8,1}$, $LBP_{12,2}$, $LBP_{16,1}$ and $LBP_{12,1}$

中国知网 https://www.cnki.net

为了使图像的 LBP 编码计算更加清晰的描述图像信息，一般情况下，将图像划分为m个子块$\{R_1, R_2, R_3, ...R_m\}$，逐一计算每个子块的直方图如公式（4-8）和（4-9）所示：

$$H_{i,j} = \sum_{x,y} Q\{f_l(x,y) = i\} Q\{(x,y) \in R_j\} \tag{4-8}$$

$$Q\{M\} = \begin{cases} 1, M = true \\ 0, M = False \end{cases}, i = 0,1,...,n-1, j = 0,1,...,m-1 \tag{4-9}$$

随后，将所有子直方图联级形成整图的 LBP 特征，如公式（4-10）所示：

$$H = [H_{i,j}], i = 0,1,...,n-1; j = 0,1,...,m-1 \tag{4-10}$$

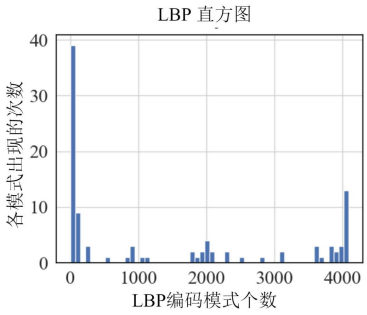
其中，$f_l(x,y)$为编码图像，n为 LBP 计算模式的总数。

图 4-7 为基于生猪咳嗽声的灰度 CQT 和 STFT 局部图像子块中提取的 LBP 特征，均采用 $LBP_{12,2}$ 计算方式。图 4-7 a)为生猪咳嗽声的灰度 CQT 时频图。图 4-7 b)和图 4-7 c)分别对应 4-7 a)中的 CQT 时频图中的蓝色图像子块和红色图像子块提取的 LBP 特征。图 4-7 d)为生猪咳嗽声的灰度 STFT 时频图。图 4-7 e)和图 4-7 f)分别对应 4-7 d)中的 STFT 时频图中的蓝色图像子块和红色图像子块提取的 LBP 特征。



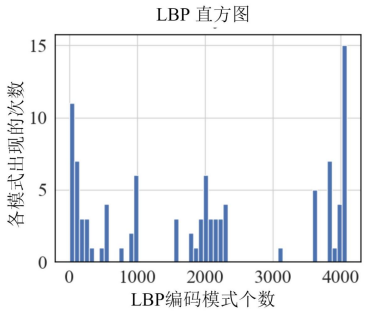
a) CQT 中的局部图像子块

a) Sub-blocks in grayscale CQT



b) 生猪咳嗽声的灰度 CQT 中蓝色子块 LBP 直方图

b) LBP histogram of blue sub-block in grayscale CQT of pig cough



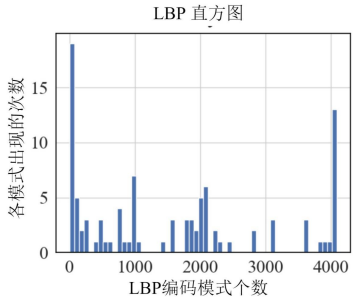
c) 生猪咳嗽声的灰度 CQT 中红色子块 LBP 直方图

c) LBP histogram of red sub-block in grayscale CQT of pig cough



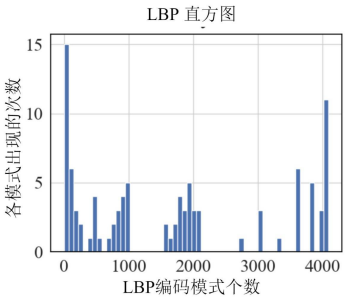
d) STFT 中的局部图像子块

d) Sub-blocks in grayscale STFT



e) 生猪咳嗽声的灰度 STFT 中蓝色子块 LBP 直方图

e) LBP histogram of blue sub-block in grayscale STFT of pig cough



f) 生猪咳嗽声的灰度 STFT 中红色子块 LBP 直方图

f) LBP histogram of red sub-block in grayscale STFT of pig cough

图 4-7 基于生猪咳嗽声的灰度 CQT 和 STFT 局部图像子块的 LBP 直方图

Figure 4-7 LBP histogram of sub-blocks based on grayscale CQT and STFT spectrograms

中国知网 https://www.cnki.net

为了捕捉位置信息以及直观地体现 LBP 特征在时频图上的分布差异，图中将 CQT 和 STFT 图像划分为相同大小的子块再进行特征计算，图 4-7 a)和 4-7 d)中的相同颜色的子块对应相同位置。各个子块的直方图中横坐标为 $LBP_{12,2}$ 编码模式的总数，纵坐标为该子块图像各模式出现的次数。由图 4-7 可知，生猪咳嗽声 CQT 和 STFT 时频图的局部图像子块的 LBP 直方图各不相同。对比图 4-7 b)和图 4-7 c)可知，CQT 的红色子块对应图像中生猪咳嗽的发声位置，黑白边缘对比更加清晰。对比图 4-7 e)和图 4-7 f)可知，LBP 特征可以捕捉图像纹理间的细微差异。对比图 4-7 b)和图 4-7 e)可知，不同时频图的同一位置子块的 LBP 直方图特征亦存在一定的差异性。

4.3.2 方向梯度直方图

方向梯度直方图（Histogram of Oriented Gradient，HOG），最初是由 Dalal 和 Triggs 提出的一种特征纹理描述子，常用于计算机视觉和图像处理中的目标检测任务。HOG 的基本思想是计算图像的局部像素梯度变化，来描述图像内容的边缘方向。一般情况下，图像对应的非同一区域内具有不同的方向和幅值，由此不同图像内容的边界像素被定义为边缘。边缘检测是对图像中每个像素强度的不连续部分作为提取点，通常沿着边缘走向的像素强度变化比较小，而垂直于边缘走向的像素强度变化则比较强，因此局部目标的外观和形状能够通过局部强度的梯度或边缘方向的密度分布进行描述。图形的边缘伴随着梯度变化，因此将其作为通过图形边缘检测并处理图像信息的特征提取方式。

由于原始声音信号转换的时频图兼顾了时域和频域的双重信息，而基于时频图提取方向直方图特征是根据时间和频率方向上的相邻方向梯度来计算的[153]，频率通常伴随时间一同变化，且频率方向根据声音内容波动而产生较大幅度的图像变化，这一点为沿时间轴捕捉音频信号的频率特征提供了一定的可行性和优势。提取 HOG 特征的主要步骤如下所示：

步骤（1）：将声音片段的原始彩色 CQT 谱图转换为灰度图像，从而降低图像颜色通道变化所造成的影响进而凸显图像的边缘特征，以提高从梯度图像中识别目标声音的效率。

步骤（2）：计算图像中每个像素（Pixels）的梯度（包括其大小和方向），以提取图像的边缘和轮廓中包含的有效信息。水平方向梯度的计算公式如（4-11）所示：

$$G_x(x,y) = H(x+1,y) - H(x-1,y) \tag{4-11}$$

垂直方向梯度的计算公式（4-12）所示：

$$G_y(x,y) = H(x,y+1) - H(x,y-1) \tag{4-12}$$

其中，$G_x(x,y)$为目标图像中像素(x,y)点处的水平方向梯度，$G_y(x,y)$为目标图像中像素(x,y)点处的垂直方向梯度。$H(x,y)$为对应像素点的像素值。相应的目标图像像素点(x,y)的梯度幅值可以通过公式来计算：

$$\mathrm{G(x,y)}=\sqrt{\mathrm{G_x(x,y)^2+G_y(x,y)^2}} \tag{4-13}$$

其中，相应的目标图像像素点(x,y)的梯度方向可以通过公式来计算：

$$\alpha(x,y) = \tan^{-1}\left(\frac{G_y(x,y)}{G_x(x,y)}\right) \tag{4-14}$$

中国知网 https://www.cnki.net

步骤（3）：图像被划分为互不重叠的小单元格（Cell），通过计算每个单元的梯度直方图，可以形成每个单元的描述符。在 Cell 中将梯度方向分布到 0 度到 180 度之间，将像素幅度作为权值进行投影，用梯度方向决定向哪个方向进行投影。方向箱子的数量（Nb. Orient）为 8 时，即 180 度范围内划分为 8 个方向，每个方向区间的间隔为 22.5 度。如图 4-8 所示。每个 Cell 共分为 8 个箱子数，也就是一个 Cell 的方向梯度直方图特征就是一个 8 维的特征向量。

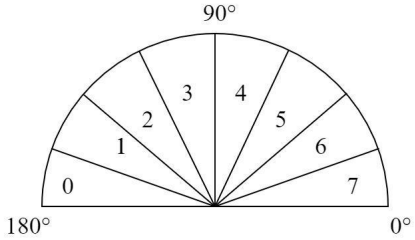


图 4-8 方向箱子数划分

Figure 4-8 Division of the number of orientation bins

步骤（4）：一般情况下，为了强化图像的特征表示，将目标图像区域内局部的 Cell 单元组成区域块（Block），相邻的 Block 之间会共享相同的 Cell，这样每个 Cell 都会在最终的特征向量中以不同的结果多次出现。然后通过 L2-Hys 对不同的 Block 块中的直方图向量进行归一化。L2-Hys 是一种使用 L2-norm 的方法，L2-norm 的公式如下：

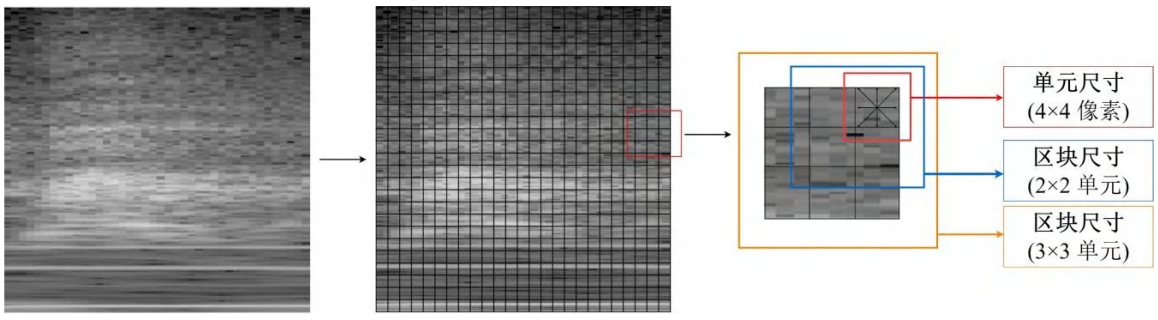
$$v \to v/\sqrt{\| v\|_2^2 + \varepsilon^2} \tag{4-15}$$

其最大值被限制在阈值以内，并被 L2-norm 重新规范化，如公式所示：

$$v \to v/(\| v\|_1 + \varepsilon) \tag{4-16}$$

其中，v表示归一化之前块内的直方图向量。

步骤（5）：最后，遵照由小及大的原则对图像特征进行遍历。具体来说，从左到右以及从上到下的顺序按照逐个 Cell 滑动对图像进行遍历形成以 Block 为单元的 HOG 特征向量，进而再按照相同的顺序遍历不同的 Block 组合成整个图像的 HOG 描述。



a) 生猪咳嗽声的灰度 CQT　　b) 25×25 划分图像　　c) 单元尺寸和块尺寸设置

a) Grayscale CQT of pig cough　　b) Splitted CQT with 25×25　　c) Setting of Cell and block size

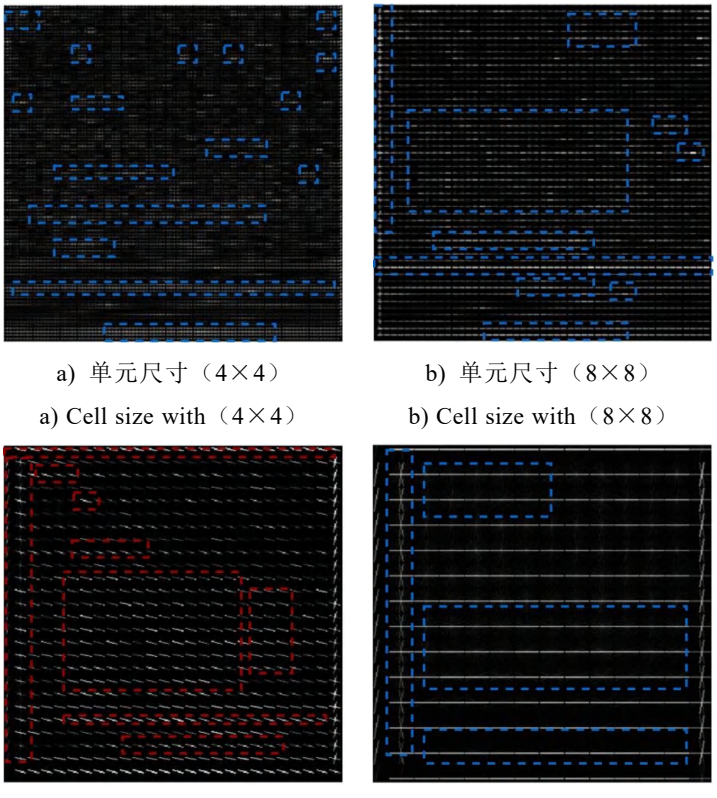
图 4-9 基于 CQT 的提取 HOG 特征流程图

Figure 4-9 Schematic representation of the HOG descriptor

中国知网 https://www.cnki.net

图 4-9 是基于灰度 CQT 提取 HOG 特征的流程。图 4-9 a)是大小为 $100 \times 100 \times 1$ 的生猪咳嗽声的灰度 CQT 时频图。在图 4-9 b)中，将 CQT 谱图划分为的 25×25 单元格。4-9 c)表示划分后的单元格大小为（4×4），并将单元格划分为 8 个方向；随后，将该时频图区域内局部的单元格大小组成区域块（Block），分别显示了（2×2）和（3×3）的两个不同的区块尺寸。方向箱子数量（Nb. Orient），一个单元的大小（Cell size）和每个区块（Block size）中的单元数是重要的特征描述参数，不同的参数对应构建具有差异化的 HOG 特征描述符。

基于 4-9 a)的灰度级 CQT 时频图，图 4-10 对四组 HOG 特征描述进行表示。图 4-10 a)-d)图中显示了在相同的 Nb. Orient 为 9 且 Block 大小为（2×2）时，Cell 大小为（4×4）、（8×8）、（16×16）和（32×32）的 HOG 特征描述。水平轴和垂直轴分别表示时间和频率。由图可知，HOG 描述符能够捕捉到时频图中的局部变化。相比于其他单元尺寸，当 Cell 大小为（16×16）时，显示出较强的特征描述能力。此外，时频图中的 HOG 特征对微小的时间和频率的平移是近似不变的，只能获得细微和离散的变化。因此，选择适当的 Cell 大小、Block 大小和 Nb. Orient 数量来提取特征是至关重要的，不同的 HOG 描述符对识别性能有直接影响。在本研究中，选择 Nb. Orient 值为 8 和 9；（3×3）和（2×2）被选为 Block 大小；Cell 大小被设定为（4×4）、（8×8）、（16×16）和（32×32），作为后续实验的对比参数，以探究不同的 HOG 描述符对生猪咳嗽声识别性能的影响。



a) 单元尺寸（4×4）　b) 单元尺寸（8×8）

a) Cell size with（4×4）　b) Cell size with（8×8）

c) 单元尺寸（16×16）　d) 单元尺寸（32×32）

c) Cell size with（16×16）　c) Cell size with（16×16）

图 4-10 基于单通道灰度 CQT 时频图的 HOG 特征描述

Figure 4-10 The gray-level CQT spectrogram and the corresponding HOG descriptors

中国知网 https://www.cnki.net

4.3.3 基于核主成分分析的特征降维

降维技术是指将具有高维度的原始数据集转化为较低维度且具有代表性的新数据集的方法。在降维过程中，在最大程度的保留数据原始含义的前提下，通过删除冗余、不相关且嘈杂的数据，来提高特征数据的质量，从而提升模型的性能，进一步降低模型的计算时间。主成分分析法（Principal Component Analysis，PCA）是一种常用的无监督的线性特征降维方法，通过确定数据的最大方差来生成主成分(Principal Components，PCs)的新特征集，但其受限于仅能处理数据中的线性成分，因此，本文采用核主成分分析[154]（Kernel Principal Component Analysis，KPCA）对视觉特征进行降维处理。

KPCA 是主成分分析的非线性处理，并将核函数应用于主成分分析法[155]。利用非线性映射函数Φ把输入空间R^D映射到某个高维特征空间R^N，并在特征空间中完成主成分分析，从而实现特征降维。

$$\Phi: R^D \to R^N \tag{4-17}$$

$$x \to \Phi(x) \tag{4-18}$$

该特征空间中的协方差矩阵计算为，

$$\Sigma_{\Phi(x)} = \frac{1}{N}\sum_{i=1}^{N} \Phi(x_i)\Phi(x_i)^T \tag{4-19}$$

然后对协方差矩阵进行特征分解，

$$\lambda V = \Sigma_{\Phi(x)} V = \frac{1}{N}\sum_{i=1}^{N} (\Phi(x_i).V)\Phi(x_i) \tag{4-20}$$

所有特征值非零的特征向量都必须在映射数据范围内，即$V \in \{\Phi(x_1), ..., \Phi(x_N)\}$，式中存在系数表示为$a_i$，$k = 1, ..., N$。

$$V = \sum_{i=1}^{N} a_i \, \Phi(x_i) \tag{4-21}$$

x_i代表第i个模式，V为特征向量。将V带入λV公式中，得到如下方程，

$$\lambda \sum_{i=1}^{N} \alpha_i\big(\Phi(x_k)\Phi(x_i)\big) = \frac{1}{N}\sum_{i=1}^{N} \alpha_i \left(\Phi(x_k)\sum_{j=1}^{N}\Big(\Phi\big(x_j\big)\Phi(x_i)\Big)\Phi\big(x_j\big)\right) \tag{4-22}$$

其中，$k = 1, ..., N$。利用核函数，将特征空间中的乘积简化为输入空间中的一个非线性函数（用ψ表示）。定义$N \times N$的核矩阵ψ，如下，

$$\Psi = \begin{pmatrix} \psi(x_1, x_1) & \psi(x_1, x_2) & \cdots & \psi(x_1, x_N) \\ \psi(x_2, x_1) & \psi(x_2, x_2) & \cdots & \psi(x_2, x_N) \\ \vdots & \vdots & \ddots & \vdots \\ \psi(x_N, x_1) & \psi(x_N, x_2) & \cdots & \psi(x_N, x_N) \end{pmatrix} \tag{4-23}$$

将投射映射的模式$\Phi(x)$到V^k的第kth 特征向量中，通过如下公式，

$$\Big(V^k.\Phi(x)\Big) = \sum_{i=1}^{M} \alpha_i^k\big(\Phi(x_i).\Phi(x)\big) = \sum_{i=1}^{M} \alpha_i^k \psi(x_i, x) \tag{4-24}$$

4.4 基于时频图的深度特征提取

从卷积神经网络（Convolutional Neural Network, CNN）的深层提取图像特征的过程被

中国知网 https://www.cnki.net

称为深层特征提取，而提取的特征被称为深度特征[156]。深度特征是由 CNN 得到的数字描述符，广泛应用于图像分类[157]。本部分将在猪舍内的时频图基础上，提取深度特征并应用于生猪咳嗽声识别。采用 CNN 提取时频图的深度特征具有一定的优势：一是 CNN 直接对时频图进行特征提取，无需额外的特征提取过程；二是在提取过程中，卷积呈现位置不变性，这意味着 CNN 在目标声音信号的时间和频率双重维度上具有一定的鲁棒性[30]。尽管在一系列机器学习识别任务中，卷积神经网络表现出了优于传统的手工设计提取的声学特征集的性能，但此类方法在商业猪舍的复杂音频环境下尚未得到广泛探索。综上，本章采用 CNN 架构来提取猪舍内生猪咳嗽声的深度特征。

4.4.1 卷积神经网络模型构建

典型的卷积神经网络，通常由输入层、卷积层、激活层、池化层和全连接层组成（Fully connected layer，FC）组成[158]。输入层被用于存储由声音信号转为时频图得到的矩阵，卷积层可以实现从原始输入中提取特征向量，池化层用于从提取的特征中筛选有效特征信息。因此，与提取传统声学特征方法相比，卷积神经网络的结构避免了从多种传统声学特征进行特征提取和手工选择的过程，实现了对时频图自适应的特征提取过程。

卷积层是 CNN 的核心层，作为整个卷积神经网络的特征提取器[159]。卷积层包含多个若干个卷积核。卷积操作是通过卷积核和输入矩阵的卷积运算来实现，卷积核按照一定的步长在整张时频图上扫描，扫描的结果作为下一层的特征矩阵，也就是输出特征图。卷积核数量的不同，对应卷积操作后提取的特征也存在一定的差异。卷积层具有强大的特征提取能力，并将获取的特征逐层传递使得感受野不断扩大。卷积层的输出特征表示，如公式（4-25）所示：

$$\alpha_j^l = \sigma\left(\sum_{i\in M_j} \alpha_i^{l-1} \times \kappa_j^l + \beta_j^l\right) \tag{4-25}$$

其中，α^l代表模型的输入；M_j表示输入特征集；×表示卷积操作；κ_j^l代表卷积核；在卷积操作过程中，β_j^l表示相应的偏置值；激活函数用σ表示，以增强模型的非线性。

激活层通过激活函数对输入数据进行处理，以增强神经网络模型的非线性，从而提升网络训练速度和鲁棒性。修正线性单元层（Rectified Linear Unit，ReLU）常被用于卷积神经网络中，得益于其能够防止梯度弥散，具备稀疏激活性，并且能够加快运算的特点。同时，由于参数之间的相互依赖性被降低，ReLU 函数能够有效地缓解模型过拟合现象。

池化层，也被称为降采样层，一般置于卷积层后，用于降低输入特征图的尺寸和网络模型参数。池化层具有平移不变性，不需要对参数进行学习，实现降低上一层特征图的维度，完成进一步的特征提取。池化层的设计有利于减少模型的训练时间，提升泛化能力。池化操作的过程，如公式（4-26）所示：

$$\alpha_{j-s}^l = f\left(w_j^l down\left(M_j^{l-1}\right) + \beta_j^l\right) \tag{4-26}$$

式中，$down(\cdot)$表示对上一层卷积层得到的特征进行池化，常采用最大池化计算。在函数$f(\cdot)$中，M_j、w_j^l和β_j^l分别表示特征图、权重和偏置。

全连接层，一般位于卷积神经网络的最后部分。在全连接层，特征图会失去前面网络层

中国知网 https://www.cnki.net

具有的空间拓扑结构，层的维度发生变化，被展平为特征向量。

训练卷积神经网络涉及到许多决策，这些决策涉及到架构（输入数据的格式、层的数量和大小、卷积核的大小等）和学习超参数（学习率、批量大小等），不同的识别任务所需的模型设置差异较大。关于卷积神经网络的架构设置，为了获得更好的性能，网络宽度（全连接层层的神经元数量，卷积层的卷积核数量）和网络深度（可训练层的数量）的选择十分关键[160]。已有研究表明，增加卷积核的数量可以获得更好的性能，但同时也降低了实验的运算速度。同时，合理的增加卷积核尺寸，可以掌握更丰富的图像结构信息，进而得到更好的实验结果。适当的网络层数也遵循同样的道理，即随着网络层数的增加，对图像信息的挖掘也实现了从低层次特征到高层次特征的逐层过渡。然而，层数增加不仅带来计算的复杂度，并随着提取信息量逐渐增多，也可能带来更多的干扰因素。

在经过 CNN 卷积层特征提取后，全连接层的接收域并没有覆盖图像的整个空间维度，其生成的特征对应于输入图像的一部分[161]。因此，全连接层的数量及其包含神经元的数量对于 CNN 模型的性能影响较大。与深层次的网络架构如 VGG[162]和 Resnet[163]相比，浅架构的卷积层产生的抽象特性相对较少。因此，浅层架构所需的全连接层的宽度和深度应适当增加[162,164]。浅层 CNN 架构的设计已在不同领域下的识别任务中凸显了一定的优势，尤其是在数据集样本规模有限的情况下[165–167]。

基于以上研究结果的启发，并结合本文实验数据集具有非公开和少样本数据集的两个特性，构建了浅层 CNN 模型，如图 4-11 所示。具体细节如下：将 100×100×3（像素×像素×通道数）的时频图作为模型的输入图像；模型共设置两个卷积层，第一个卷积层包含 32 个大小为 5×5 的卷积核；第二个卷积层包含 48 个卷积核，大小为 5×5；两层卷积层的步长均为 1，并设置大小为 2×2 的最大池化层和 ReLU 激活函数；最后，两个具有 512 个神经元的全连接层（FC）接收模型提取的特征向量。由于时域和频域包含不同的信息，所以选择二维卷积来提取频率和时间两个维度信息。

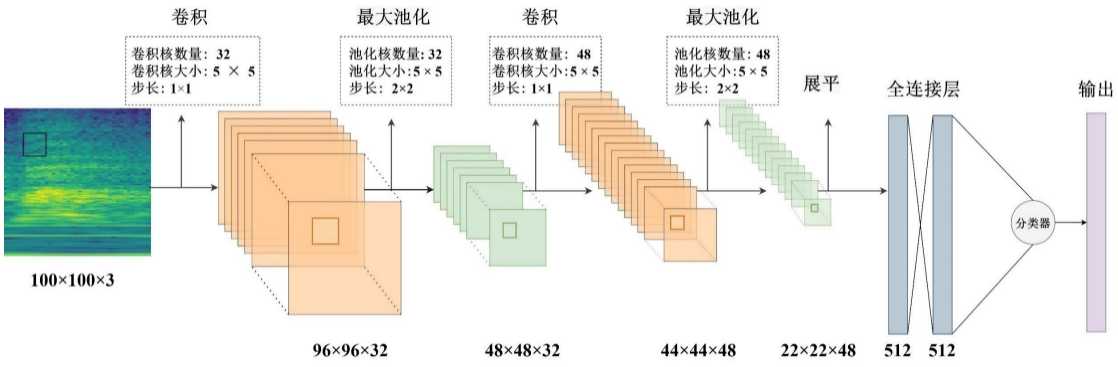


图 4-11 浅层卷积神经网络结构

Figure 4-11 Shallow convolutional neural network structure

表 4-1 显示了浅层 CNN 卷积神经网络的模型具体细节。输入层的图像尺寸为 100×100×3，整个过程不采用补零模式进行图像的下采样，因此特征图的大小逐渐减小。在两次最大池化后，最终得到 22×22×48 的特征图大小。最后通过展平层将三维特征图转换成了一维变量，将特征向量传递到两层全连接层，最后经过 Softmax 输出层。

中国知网 https://www.cnki.net

表 4-1 卷积神经网络结构参数设置

Table 4-1 Improved parameter settings of the CNN structure

类型	网络层参数	特征图大小
输入	-	100×100×3
卷积层	32，5×5，Relu，步长为 1	96×96×32
池化层	最大池化 2×2，步长为 2	48×48×32
卷积层	48，5×5，Relu，步长为 1	44×44×48
池化层	最大池化 2×2，步长为 2	22×22×48
展平	-	23232×1
全连接层 FC1	Relu	512×1
全连接层 FC2	Relu	512×1
输出	-	二分类-Softmax

4.4.2 基于单输入谱图特征层融合架构

将猪舍内声音转为时频图的过程中，不同声音之间的细微特征差异均被压缩在时频图中。卷积层在音频信号的谱图上应用一定数量的卷积核后生成特征图，随即池化层对特征图的尺寸进一步优化，在整个过程中谱图所包含的特征信息逐层被挖掘，并降低了模型处理时间。然而，由于卷积神经网络每一层均对原始时频图进行下采样，时频图中局部声音信息可能会遗失，从而导致基于全局时频图的特征提取能力有限。

为此，提出基于单输入谱图特征层融合架构，以提高深度特征在生猪咳嗽声识别任务中的辨识力，如图 4-12 所示。该模型核心流程包括采用浅层 CNN 架构对时频图进行特征挖掘，并采用 CNN 架构中的两层全连接层 FC1 和 FC2 输出的深度特征进一步输入融合模块，采用一定的融合策略进行特征融合，最后将融合后的深度特征输入到 SVM 中进行特征识别。

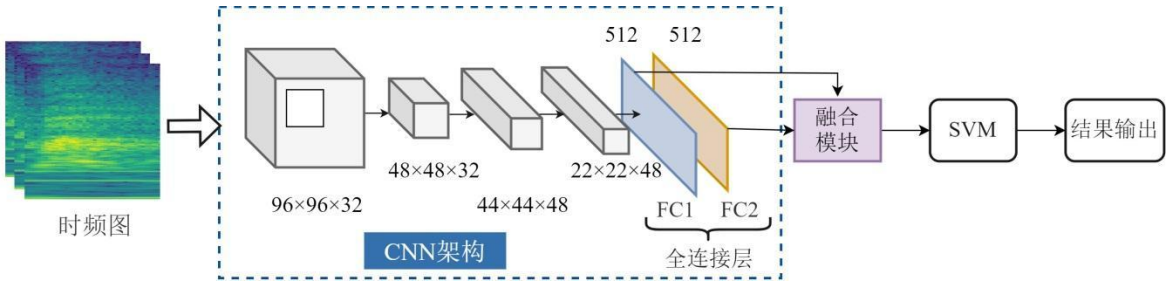


图 4-12 基于单时频图输入的特征融合架构

Figure 4-12 Feature fusion architecture based on certain TFR

模型的整体流程设置基于以下几个因素：首先，由于 CNN 对输入图像的敏感性，STFT 和 CQT 两种时频图均被独立输入到 CNN 模型中提取深度特征，以分析单一时频图下对生猪咳嗽声的表达性能；其次，尽管深度特征可以从 CNN 中的任一层获取[168]，但 CNN 初始层仅包含低阶的边缘信息且包含更多的噪声，而 CNN 深层特征具备较强的高阶抽象特征。

中国知网 https://www.cnki.net

同时，全连接层可以在最大程度上覆盖时频图中的有效信息，并固定维度输出深度特征且不受前端输入图片大小的影响。因此，从两层全连接层提取的全局特征进行层间融合；最后，依据 SVM 在样本数据量有限的情况下，具备较强的稳定性和鲁棒性的优势，选择 SVM 作为对比和分析不同域下声音特征的基线模型，将融合特征输入到 SVM 中进行特征性能的比较。

4.4.3 基于双谱图输入特征融合架构

在集约型生猪养殖环境下，舍内声音环境较为复杂，在这种情况下，通常面临高频和低频声音共存的情况，且声音之间存在一定的重叠性。基于对两种时频图的分析可知，STFT 时频图对中低频段的声音特征的描述较为清晰，CQT 时频图更善于捕捉高频段声音之间的细微差异。两种时频图特征从不同维度刻画声音信号特征，并包含一定的信息差异。为此，基于不同时频图之间的差异，并结合 CNN 提取深度特征的优势，提出基于双谱图输入特征融合架构，如图 4-13 所示。

首先，将 CQT 和 STFT 分别输入独立且并行的 CNN 网络提取深度特征；随后，两个独立 CNN 中的全连接层 FC1 输出的深度特征进行融合，形成新的特征向量；最后输入 SVM 进行对比分析。为了对比单输入谱图下的模型层融合性能和多输入下的谱图融合对生猪咳嗽声识别性能的影响，在双谱图输入的特征融合架构中，两个独立网络采用和单输入模型相同的卷积神经网络。该模型的核心是充分利用原始各自的优势和图像间的差异，基于不同原始图像数据分别训练模型并进行特征提取，随后不同特征间进行融合学习，以实现特征间的信息互补性。

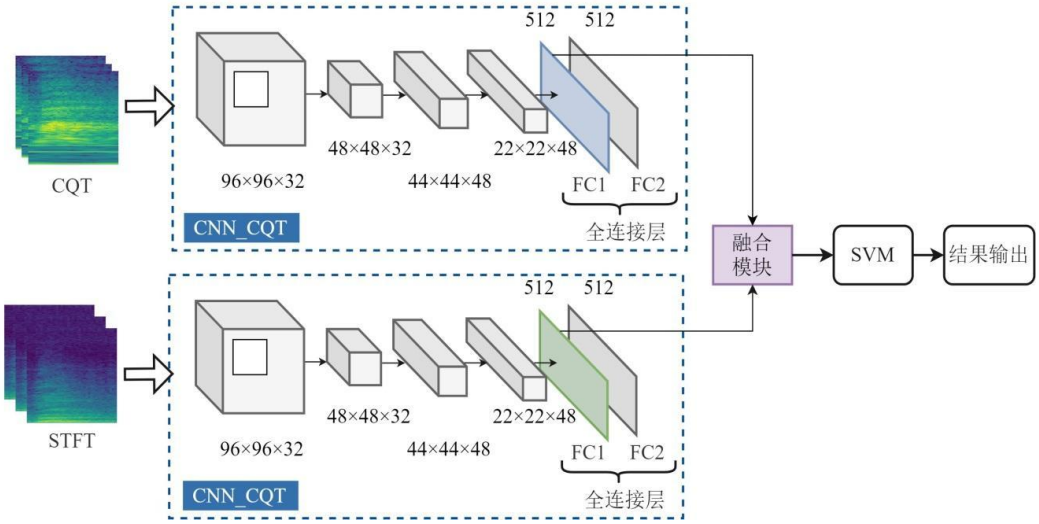


图 4-13 基于双谱图输入的特征融合架构

Figure 4-13 Feature fusion architecture based on bispectrogram input

4.4.4 深度特征融合算法

基于 CNN 提取深度特征是对输入图像逐层递进提取的过程，每层的特征图是由前一层

中国知网 https://www.cnki.net

的特征图中提取的，对应每一层的特征子图所包含的大小及信息是不同的[169]。CNN 中的特征图也被称为通道。跨通道的不同类型的信息对图像识别具有不同的贡献度，使 CNN 专注于学习更重要的特征，有利于增强深度特征的表征能力[168]。在以往的研究中，深度特征融合算法主要包括不同通道下的多尺度的特征融合以及添加特征通道两种方式，来学习图像内容的差异性。其中，多通道特征融合由于通道尺寸的差异需要对尺寸调整再进行特征融合，而添加通道的方式会增加 CNN 模型复杂度，进而影响模型的计算速度。

为此，本文研究卷积神经网络高阶特征的对位元素间的关系。相比于通道层面的特征融合方式，基于元素的计算方式是对高阶特征的二次学习和变换，组合形成更具有代表性的特征表达，其具有更快的计算速度。综上，如何有效地利用卷积神经网络中高阶的对位元素特征是充分挖掘深度特征的关键问题。

浅层 CNN 架构提取的深度特征，采用F_{FC1}和F_{FC2}表示。由于 CNN 架构的两层全连接层包含相同的神经元数量，因此，F_{FC1}和F_{FC2}的特征向量维度相同。同时，其代表融合模块内的两组输入特征向量，即$F_{FC}=[f_1,f_2,...f_{512}]$。

最常见的融合方式为向量拼接融合方式，该方式不受特征层大小的限制，更具有灵活性。其通过头尾拼接模式将两个特征沿通道维度连接起来，通过增加特征维度，形成特征向量的全局表达，如公式（4-27）所示：

$$F=Concat(F_{FC1},F_{FC2}) \tag{4-27}$$

基于元素的对位操作是指特征在通道和维度上同时对应，即特征向量间一一对应，以保持特征维度不变，从而形成一个全新的特征表示。其核心思想则是在不增加网络学习层，或者额外改变参数设置的前提下，通过挖掘元素间的特征关系，赋予新特征更多的信息，以提升网络的学习能力。

最具有代表性的是对位相加，如公式（4-28）所示：

$$F=F_{FC1}\oplus F_{FC2} \tag{4-28}$$

除此之外，对位乘积（Mul）也是基于元素的计算方式，如公式（4-29）所示：

$$F=F_{FC1}\otimes F_{FC2} \tag{4-29}$$

从基于对位操作的优势出发，本文试图获取深度特征向量的最大值和最小值，从而形成两组对位特征下的最大差异表示。f_{max}和f_{min}的核心是比较两组特征值，并返回一个新的特征表示，最终新的特征表示的对位数值下的最大值和最小值。最大值和最小值的获取如公式所示，本文提出的对位差值记作Sub，如公式所示。

$$F_A=f_{max}(F_{FC1},F_{FC2}) \tag{4-30}$$

$$F_I=f_{min}(F_{FC1},F_{FC2}) \tag{4-31}$$

$$Sub=F_A-F_I \tag{4-32}$$

本章提出的对位差值计算方式，其核心是通过分别计算两组不同数据向量之间的最大差异表示，从而寻找组间特征最具代表性的特征信息，从而形成最为显著的特征表达。因此，对位差值的融合方式相当于分别对两组特征向量进行优化，进而保留特征间的差异。针对两种不同的特征融合架构，将基于元素的对位计算和向量拼接两类融合方式进行对比，探索和分析内部特征融合方式对模型性能的影响。由于两种不同网络的输入端的时频图数据各有不同，两类方式可以在相同维度下采用不同对位操作的融合算子进行对比，亦可在不同维度下

中国知网 https://www.cnki.net

探索模型性能的差异性。

4.5 实验结果与分析

4.5.1 实验设置

本章实验采用 2.2.3 中的舍内声音平衡数据集，其中咳嗽声与非咳嗽声的声音片段各占 50%，共计 2546 个舍内声音片段。在声音片段转换为二维时频图的过程中，本文采用 Librosa 0.8.1[142]工具箱，单通道音频转换，采样率为 44.1kHz，且两种谱图统一颜色为 Viridis。由于尽管时频图是声音的图像特征表示形式，但与基于相机获取的自然图像具有一定的差异。自然图像可以在不改变图像内容信息的基础上进行旋转、缩放和拉伸等进行数据增强，然而时频图在单位时间上对应的频率差异代表着不同的声音信息，即包含着不同的声音含义。因此，本章实验中均是根据原始声音数据直接转换对应的时频图，不再进行插值缩放等其他数据增强操作。当依靠时频图作为其输入来提取特征时，其中一个关键因素是预处理步骤中产生的数据的分辨率。之前的一项研究表明，在利用 HOG 特征进行面部识别时，识别率不会随着图像分辨率的提高而提高[170]。因此，这启发本文选择 100×100 像素的图像尺寸，以减少本研究中整个实验过程的计算时间。计算时保持时频图大小固定，即 $100 \times 100 \times 3$。由于不同时频图窗长设置影响识别结果，采用长窗 2048 和短窗 1024 设置，共计长窗（2048）下 STFT 时频图和 CQT 时频图各 2546 张；短窗（1024）下 STFT 时频图和 CQT 时频图各 2546 张。

本研究训练分类模型基于 Intel(R) Core (TM) i7-10750H CPU 2.6GHz，RAM 16GB，NVIDIA GeForce GTX 1650 Ti GPU，64 位 Windows 10 操作系统。实验涉及相关数据分析和模型建立均使用 Python 3.7、Scikit-learn、TensorFlow 2.6.2 和 Keras 2.6.0 在 PyCharm Community Edition 2020 软件环境中完成。卷积神经网络模型使用的代价函数为交叉熵，并利用 Adam 算法优化网络训练过程，其初始学习率设置为 0.01，损失函数为交叉熵损失函数。实验结果的图表呈现采用 Matplotlib 3.3.1 及 Seaborn 0.11.1。

实验采用内嵌三折交叉验证方法并结合 SVM 对生猪咳嗽声识别性能进行评估，实验结果为三个测试集结果的平均值。本节中测试结果的评价指标采用 2.4.3 中的准确率（Accuracy），精准率（Precision），召回率（Recall），F1 分数（F1-Score），采用百分制（%）的表现形式。实验结果呈现分成两个主要部分，一是基于时频图提取视觉特征的实验与分析，二是基于时频图提取深度特征的实验与分析。

4.5.2 视觉特征实验结果与分析

实验分成五部分：实验一对比 STFT 和 CQT 时频图提取不同参数下 LBP 特征对生猪咳嗽声识别性能的影响；实验二分析 KPCA 降维算法对模型性能的影响；实验三分析 LBP 特征融合策略对模型性能的影响；实验四分析 HOG 特征参数对模型性能的影响；实验五分析 HOG 特征融合策略对模型性能的影响。

中国知网 https://www.cnki.net

4.5.2.1 基于 STFT 和 CQT 时频图提取 LBP 特征对模型识别性能的影响

（1）基于 STFT 时频图提取 LBP 特征对模型性能的影响

对于 STFT 时频图，对比长窗口（N=2048）和短窗口（N=1024）对生猪咳嗽声识别性能的影响。表 4-2 显示了 STFT 时频图在长窗和短窗下分别提取不同分辨率下 LBP 的生猪咳嗽声识别结果。

在 N 设置为 2048 的情况下，在 $LBP_{12,2}$ 时达到最佳，准确率达到 88.84%，F1 分数达到 90.68%。$LBP_{12,1}$ 和 $LBP_{8,1}$ 结果相近，$LBP_{8,1}$ 在 F1 分数和召回率上略优于 $LBP_{12,1}$，分别达到 90.20%和 90.73%。

在 N 设置为 1024 的情况下，$LBP_{12,2}$ 在准确率、F1 分数和精准度达到最佳，分别为 81.31%、84.49%和 85.05%。整体来看，在生猪咳嗽声识别任务中，长窗下的 STFT 提取 LBP 特征的识别性能优于短窗下的 STFT；$LBP_{12,2}$ 优于 $LBP_{16,1}$、$LBP_{12,1}$ 和 $LBP_{8,1}$。

表 4-2 基于 STFT 提取 LBP 视觉特征的生猪咳嗽声识别性能

Table 4-2 Pig cough classification results extracted from LBP based on STFT

时频图	$LBP_{P,R}$	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
STFT(N=2048)	$LBP_{16,1}$	87.89	90.01	90.07	89.95
STFT(N=2048)	$LBP_{12,1}$	88.04	90.16	89.99	90.34
STFT(N=2048)	$LBP_{12,2}$	88.84	90.68	91.83	89.56
STFT(N=2048)	$LBP_{8,1}$	88.04	90.20	89.68	90.73
STFT(N=1024)	$LBP_{16,1}$	77.28	81.52	80.43	82.64
STFT(N=1024)	$LBP_{12,1}$	78.78	82.82	81.36	84.33
STFT(N=1024)	$LBP_{12,2}$	81.31	84.49	85.05	83.94
STFT(N=1024)	$LBP_{8,1}$	78.70	82.66	81.66	83.68

（2）基于 CQT 时频图提取 LBP 特征对模型性能的影响

B 值的大小决定了 CQT 时频图的质量。实验中，B 设置为 32 和 64，f_1设置为 22.05Hz。表 4-3 显示了基于 CQT 时频图提取不同分辨率下的 LBP 的生猪咳嗽声识别结果。

在 B 设置为 32 和 64 时，$LBP_{12,2}$ 的识别性能均为最优结果，准确率分别为 89.70%和 78.62%，F1 分数分别为 91.21%和 82.56%。结果验证了 B 值的选择，影响时频图的输出质量，进而影响生猪咳嗽声识别精度。

此外，LBP 基于不同的（P,R）值提供了不同的识别精度。基于 B 为 32 时，四组 LBP 特征在识别准确率、F1 分数、精准度和召回率上最大值与最小值分别相差 2.92%、1.83%、3.19%以及 1.75%，结果差异较大。

对比表 4-2 和表 4-3 中 $LBP_{12,2}$ 下 STFT 和 CQT 的识别性能可知，CQT 在准确率、F1 分数以及召回率上均优于 STFT，分别高出 0.86%、0.53%以及 1.57%。STFT 在精准度上的结果为 91.83%，略优于 CQT 的 90.30%。从整体上看，CQT 性能略优于 STFT。这是由于相比于 STFT，CQT 时频图可以更加敏锐地捕捉生猪咳嗽声与生猪叫声等高频段声音间的特征差异，从而在整体上提升生猪咳嗽声的识别准确率。

中国知网 https://www.cnki.net

表 4-3 基于 CQT 提取 LBP 视觉特征的生猪咳嗽声识别性能

Table 4-3 Pig cough classification results extracted from LBP based on CQT

时频图	$LBP_{P,R}$	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
CQT(B=32)	$LBP_{16,1}$	86.78	89.38	87.11	89.38
CQT(B=32)	$LBP_{12,1}$	87.49	89.92	87.91	89.92
CQT(B=32)	$LBP_{12,2}$	89.70	91.21	90.30	91.13
CQT(B=32)	$LBP_{8,1}$	88.04	90.33	88.68	90.33
CQT(B=64)	$LBP_{16,1}$	77.99	82.06	81.12	82.06
CQT(B=64)	$LBP_{12,1}$	78.01	82.04	81.20	82.04
CQT(B=64)	$LBP_{12,2}$	78.62	82.56	81.71	82.56
CQT(B=64)	$LBP_{8,1}$	78.07	82.28	80.68	82.28

综合以上结果可知，CQT 时频图用于猪的咳嗽识别是可行的，且将其应用于商业猪舍条件下区分生猪咳嗽声具有一定的挖掘潜力。此外，从结果可知，调整构建 CQT 的参数对识别性能有明显的影响，生猪咳嗽识别的 F1 分数从 82.56%到 91.17%不等，受窗口长度影响较大，这意味着更大的窗口尺寸强调了频率分辨率在生猪咳嗽声识别中的重要性。同时，原始声音信号转为时频图这一步骤十分关键，这种高度依赖性对后期模型的识别结果是非常直观的。

4.5.2.2 KPCA 降维算法对模型性能的影响

为了对比分析降维算法对分类性能的影响，采用 CQT（B=32）提取的 $LBP_{12,2}$ 特征进行对比分析。关于 PCA 和 KPCA 降维算法的核心是，寻求最大化方差[171]，同时，一般情况下，默认数据特征方差的和，即累积解释方差需不少于 85%。本文中，降维算法采用选择累积方差贡献率为 95%。表 4-4 对比了未使用降维算法（None）、PCA 以及 KPCA 算法分类结果和模型分类计算时长。相比于 PCA 和 None，KPCA 在多种评价指标上均得到了有效提升。PCA 和 None 在识别性能上相近。相比于 PCA，使用 KPCA 在 SVM 分类器的精确度、F1 分数、精准度以及召回率分别提升了 2.25%、2.11%、2.54%以及 1.68%。同时，模型分类计算最快，较未经降维前的模型节省了一半的时间，从 48.355s 降至 23.561s。KPCA 降维算法对于提高训练集的质量是有益的，可以有效从初始数据中提取特征信息，从而使降维后的数据集更加紧凑，进而提升模型的识别精度并缩小模型的计算时间。这可能是由于 KPCA 更善于处理非线性数据，这一结论与 Farzana 等人在多组数据集中的实验结果一致[154]。

表 4-4 不同特征降维方法在生猪咳嗽声识别的结果对比

Table 4-4 Pig cough classification performance of original and reduced datasets

降维方法	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间（s）
KPCA	91.95	92.32	92.84	91.81	23.561
PCA	89.70	90.21	90.30	90.13	32.451
None	89.70	91.21	90.30	91.13	48.355

中国知网 https://www.cnki.net

4.5.2.3 LBP 特征融合策略对模型性能的影响

根据到 LBP 算子的本质可以提供图像的单位像素内的细粒度分析，因此本文通过对不同分辨率分析和融合来扩展和比较 LBP 特征的识别能力。实验基于 CQT 时频图提取的 $LBP_{12,2}$ 和 $LBP_{8,1}$ 两种特征，进一步分析多分辨率 LBP 的融合性能，结果如表 4-5 所示。

表 4-5 多分辨率下的 LBP 融合后生猪咳嗽声识别性能

Table 4-5 Pig cough classification results obtained by multiresolution analysis

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
$LBP_{12,2}$	91.95	92.32	92.84	91.81
$LBP_{12,2}$+$LBP_{12,2}$	91.85	92.24	92.67	91.81
$LBP_{12,2}$+$LBP_{8,1}$	90.87	92.05	90.50	91.27

由表可知，$LBP_{12,2}$+$LBP_{8,1}$ 多分辨率的 LBP 特征识别性能与单分辨率的 $LBP_{12,2}$ 特征识别性能相比，性能并未得到提升，反而识别性能呈现轻微下降。$LBP_{12,2}$+$LBP_{12,2}$ 优于 $LBP_{12,2}$+$LBP_{8,1}$，各项评价指标均所有提升。其中，召回率提升到 91.81%，与 $LBP_{12,2}$ 结果一致，模型整体准确率、F1 分数和精准率略低于 $LBP_{12,2}$。

进一步对比分析 $LBP_{12,2}$ 和 $LBP_{12,2}$+$LBP_{12,2}$ 两组特征子集对舍内五种声音的识别性能，如图 4-14 所示。由图可知，相比于 $LBP_{12,2}$，融合后的特征在生猪咳嗽声的正确识别个数减少，非咳嗽声正确识别数保持一致。



a) $LBP_{12,2}$ 混淆矩阵结果

a) Confusion matrix on $LBP_{12,2}$

b) $LBP_{12,2}$+$LBP_{12,2}$ 混淆矩阵结果

b) Confusion matrix on $LBP_{12,2}$+$LBP_{12,2}$

图 4-14 生猪咳嗽声与生猪尖叫声时频图

Figure 4-14 Time frequency representations of cough and scream

在本实验中提取时频图的全局的 LBP，全局 LBP 特征的优势是对整张时频图中的像素进行特征提取，然而这也直接导致了提取到的特征易包含噪声干扰。特别是当频段低于 2kHz 时，生猪咳嗽声和尖叫声的信号并不凸显，这可能是干扰后期模型识别的一项因素。另一方面，从多分辨率融合策略中提取的 LBP 特征并没有获得识别性能的提高。这可能是因为时频图中提取到的代表性特征信息的增强是以放大干扰因素为代价的。因此，在后续研究中仅采用 $LBP_{12,2}$ 与其他特征进一步融合和讨论。

中国知网 https://www.cnki.net

4.5.2.4 不同 HOG 特征参数对模型性能的影响

实验结果呈现了基于灰度 CQT 时频图下，单元格大小（Cell size）、块大小（Block size）和梯度方向箱子数（No. orient）不同参数提取 HOG 特征对生猪咳嗽声识别性能的影响。

（1）基于梯度方向箱子数分别为 8 时提取 HOG 视觉特征的生猪咳嗽声识别结果

表 4-6 显示了基于梯度方向箱子数分别为 8 时提取 HOG 视觉特征的生猪咳嗽声识别结果。基于相同方向箱子数的情况下，对比区块大小和单元格大小对识别任务的影响。

当区块大小为（3×3）时，与单元格大小（32×32）、（8×8）和（4×4）进行对比，单元格大小为（16×16）时，生猪咳嗽声识别性能最佳，准确率、F1 分数、精准率、召回率分别达到 93.67%、94.83%、93.49%以及 95.82%。

当区块大小为（2×2）时，与单元格大小（32×32）、（8×8）和（4×4）进行对比，单元格大小为（16×16）时，生猪咳嗽声识别性能最佳，准确率、F1 分数、精准率、召回率分别达到 93.67%、94.83%、93.57%以及 95.69%。

进一步对比单元格大小在（16×16）时，区块大小（3×3）和（2×2）下生猪咳嗽声识别结果。经对比，两种区块大小尺寸下，模型整体的识别准确率和 F1 分数一致；从精准率和召回率两个指标来看，与区块大小（3×3）相比，区块尺寸在（2×2）下精准率略高，提升了 0.08%；而召回率略低，下降了 0.13%。结果表明基于相同方向箱子数的情况下，与区块大小相比，单元格大小的变化对生猪咳嗽声识别结果更具有影响力。

表 4-6 基于方向箱子数为 8 时提取 HOG 视觉特征的生猪咳嗽声识别性能

Table 4-6 Pig cough classification results extracted from HOG based on No. orient 8

区块尺寸	单元格大小	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
(3×3)	(32×32)	93.19	94.42	93.32	94.91
(3×3)	(16×16)	93.67	94.83	93.49	95.82
(3×3)	(8×8)	93.19	94.44	93.36	95.43
(3×3)	(4×4)	92.16	93.66	92.31	95.43
(2×2)	(32×32)	93.59	94.75	93.62	95.43
(2×2)	(16×16)	93.67	94.83	93.57	95.69
(2×2)	(8×8)	93.59	94.76	93.72	95.56
(2×2)	(4×4)	93.59	94.78	93.82	95.95

（2）基于梯度方向箱子数分别为 9 时提取 HOG 视觉特征的生猪咳嗽声识别结果

表 4-7 显示了基于梯度方向箱子数分别为 9 时提取 HOG 视觉特征的生猪咳嗽声识别结果。当区块大小为（3×3）时，与单元格大小（32×32）、（8×8）和（4×4）进行对比，单元格大小为（16×16）时，生猪咳嗽声识别性能最佳，准确率、F1 分数、精准率、召回率分别达到 93.98%、95.08%、93.90%以及 95.95%。当区块大小为（2×2）时，与单元格大小（32×32）、（8×8）和（4×4）进行对比，单元格大小为（16×16）时，生猪咳嗽声识别性能最佳，准确率、F1 分数、精准率、召回率分别达到 94.06%、95.15%、93.89 以及 95.95%。

中国知网 https://www.cnki.net

表 4-7 基于方向箱子数为 9 时提取 HOG 视觉特征的生猪咳嗽声识别性能

Table 4-7 Pig cough classification results extracted from HOG based on No. orient 9

区块尺寸	单元格大小	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
(3×3)	(32×32)	93.35	94.55	93.33	95.04
(3×3)	(16×16)	93.98	95.08	93.90	95.95
(3×3)	(8×8)	93.27	94.51	93.08	95.56
(3×3)	(4×4)	92.32	93.77	92.28	95.30
(2×2)	(32×32)	93.67	94.83	93.65	95.69
(2×2)	(16×16)	94.06	95.15	93.89	95.95
(2×2)	(8×8)	93.59	94.76	93.65	95.69
(2×2)	(4×4)	92.72	94.07	92.88	95.30

进一步对比单元格大小在（16×16）时，区块大小（3×3）和（2×2）下生猪咳嗽声识别结果。结果表明基于相同方向箱子数的情况下，与区块大小相比，单元格大小的变化对生猪咳嗽声识别结果更具有影响力。同时，与表 4-6 中梯度方向箱子数为 8 相比，梯度方向箱子数为 9 时，单元大小为（16×16），块大小为（2×2）时，生猪咳嗽声识别结果略有提高，即 F1 分数达到 95.15%。因此，将梯度方向箱子数为 9 时，单元大小为（16×16），块大小为（2×2）作为后续特征融合的基础参数。

4.5.2.5 HOG 特征融合策略对模型性能的影响

在选择了参数后，进一步对比了相同参数下，红色（R）、绿色（G）和蓝色（B）的 RGB 三通道 CQT 时频图（HOG-Colour）的 HOG 特征以及二者融合的特征子集在猪咳嗽识别方面的性能，如表 4-8 所示。其中，HOG-Gray 代表从单通道的灰度 CQT 谱图中提取的 HOG。HOG-Gray+HOG-Colour 表示 HOG-Colour 和 HOG-Gray 拼接融合后的特征子集。

结果表明，HOG-Gray+HOG-Colour 与 HOG-Gray 的识别结果相近，均优于 HOG-Colour。与 HOG-Gray+HOG-Colour 相比，HOG-Gray 在准确率、F1 分数和召回率上略高，分别达到 94.06%、95.15%和 95.95%。

表 4-8 基于灰度图像和三通道彩色图像提取 HOG 特征的生猪咳嗽声识别性能

Table 4-8 Pig cough classification results of HOG features from grayscale and RGB TFRs

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
HOG-Gray	94.06	95.15	93.89	95.95
HOG-Colour	93.90	95.00	94.45	95.56
HOG-Gray+HOG-Colour	93.98	95.08	94.17	95.76

进一步对比分析 HOG-Gray 和 HOG-Gray+HOG-Colour 两种特征子集对舍内五种声音的识别性能，如图 4-15 所示。由图可知，相比于 HOG-Gray，融合后的特征在生猪咳嗽声的正确识别个数减少，非咳嗽声中的清理声和猪叫声正确识别个数增加。由此可知，融合后的特征并未得到进一步提升。综合以上结果分析，HOG-Colour 并没有提升生猪咳嗽声的识别

中国知网 https://www.cnki.net

性能。尽管 RGB 三通道的时频图比灰度时频图提供了更多的谱图信息，但其所包含的冗余信息也同时被表达和增强。因此，后续仅采用 HOG-Gray 与其它特征进一步的融合和讨论。



a)) HOG-Gray 混淆矩阵结果　　b) HOG-Gray+HOG-Colour 混淆矩阵结果

a) Confusion matrix on HOG-Gray　　b) Confusion matrix on HOG-Gray+HOG-Colour

图 4-15 两组 HOG 特征子集的混淆矩阵

Figure 4-15 Confusion matrix for two feature sets based on HOG

4.5.3 深度特征实验结果与分析

实验分成三部分：实验一基于浅层 CNN 提取特征对比实验；实验二浅层 CNN 网络与迁移学习下深度神经网络模型对比实验；实验三基于单输入谱图特征层融合与基于双谱图特征融合架构对比实验。

4.5.3.1 基于浅层 CNN 提取特征对比实验

表 4-9 显示了基于本文构建的 CNN 架构的全连接层（FC1）和全连接层（FC2）的深度特征在 SVM 上的识别性能，深度特征分别在 CQT 和 STFT 的单输入时频图上进行提取。由表可知：

CQT-FC1 的识别结果均优于 CQT-FC2，其中，识别准确率、F1 分数、精准率和召回率分别达到 92.94%、92.65%、94.03%和 93.33%。相比 STFT-FC2，STFT-FC1 在准确率、F1 分数和召回率上结果更好，分别达到 92.35%、93.21%和 92.68%。

综上，FC1 取得了比 FC2 更好的识别性能。同时，CQT 在识别方面的表现略优于 STFT，进一步证实了 CQT 具有充分的研究潜力，可以作为在复杂猪舍条件下识别猪咳嗽声的工具。

表 4-9 基于 CQT 和 STFT 全连接层特征提取的生猪咳嗽声识别性能

Table 4-9 Pig cough recognition performance of FC1 and FC2 extracted from CQT and STFT

时频图	全连接层	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
CQT	FC1	92.94	92.65	94.03	93.33
	FC2	91.56	92.61	92.30	91.95
STFT	FC1	92.35	93.21	92.16	92.68
	FC2	91.37	91.73	92.42	91.04

中国知网 https://www.cnki.net

4.5.3.2 浅层 CNN 网络与迁移学习下深度神经网络模型对比实验

迁移学习是指利用具有大量标签和已有知识的模型迁移应用到目标学习任务的领域的这一学习过程。目前广泛应用的迁移学习一般默认深度迁移学习，即基于深度神经网络模型的迁移学习过程。由于深度神经网络提取特征是由浅入深，且学习到的图像特征是由图像的线条轮廓等通用特征到高阶抽象表达特征的递进。根据这一特点，本章保持预训练模型的低层参数，只更新高层的权值来实现微调深度模型进行迁移。以此来获得预训练模型的泛化特征，降低重新学习的时间加快目标学习的训练速度。

VGG 通过堆叠层来学习深度信息，而 Resnet 通过残差学习实现从一层到另一层的快捷连接。这两种 CNN 架构为两类经典的深度网络，因此，为了对比不同深度网络提取特征对分类性能的影响，本节实验选取了不同深度的 VGG 网络（VGG16 和 VGG19）以及 Resnet152 网络与本文构建的浅层 CNN 网络进行对比。

在提取深度特征过程中，采用迁移学习方法来微调网络，用生猪咳嗽声和非咳嗽声样本对模型的全连接层和最终分类层进行重新训练，用训练好的模型提取深度特征。模型初始化参数基于 ImageNet 预训练权重。由于迁移学习模型的图像输入模型为 224×224×3 的 RGB 三通道图像，因此将时频图转换成固定的输入尺寸 224×224×3，并对图像数据进行归一化。同时，VGG16、VGG19 和 Resnet152 网络的最后一层均包含 1000 个神经元，所有的模型均保留原始网络中的特征提取部分，并在深度网络层特征提取后，采用模型最后一层全连接层的多神经元输入 SVM 分类器中进行生猪咳嗽声与非咳嗽声的识别。选择 SVM 分类器主要基于两个原因，一是为了进一步比较基于不同深度学习架构的特征提取器对分类性能的影响，二是为了评估深度神经网络和浅层神经网络的模型计算的时间成本。

（1）浅层 CNN 与迁移学习下提取深度特征的生猪咳嗽声识别性能对比

表 4-10 显示了不同 CNN 架构提取网络最后一层深度特征的生猪咳嗽声识别性能对比。由表可知，与 VGG19 相比，VGG16 提取深度特征后的模型识别整体准确度以及召回率略高，分别达到 90.85%和 94.57%；F1 分数和精准率略低，分别为 91.57%和 90.05%，总体上二者性能相当。相比而言，Resnet152 模型提取的深度特征在模型识别的整体准确率、F1 分数以及召回率上均低于 VGG16 和 VGG19。

相比于上面三种深度网络架构，浅层 CNN 架构在准确率、F1 分数以及精准率上性能更好，分别达到 91.56%、92.61%以及 92.30%，这也进一步印证了卷积神经网络中层深的选择对提取生猪咳嗽声的时频图特征有直接影响。

表 4-10 浅层 CNN 与迁移学习下提取深度特征的生猪咳嗽声识别性能对比

Table 4-10 Pig cough performance based on transfer learning compared to propsosed CNN

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
VGG16	90.85	91.75	90.50	94.57
VGG19	90.66	92.50	91.00	94.06
ResNet152	90.59	90.94	91.98	89.93
Proposed method	91.56	92.61	92.30	91.95

中国知网 https://www.cnki.net

（2）浅层 CNN 与迁移学习下提取深度特征的生猪咳嗽声识别时间对比

同时，实验还对比了不同网络提取深度特征的运行时间。图 4-16 对比了几种网络架构提取深度特征的时间。点和菱形标记分别表示不同模型架构下提取特征的平均时间和单次时间。浅层 CNN、VGG16、VGG19 和 ResNet152 四种模型提取深度特征时间平均值分别为 12.57s、197.25s、243.25 以及 234.97s。与深度神经网络架构的运行时间相比，时间差异较大。浅层 CNN 和 VGG19 提取特征所消耗差异超过 230.67s。总的来说，与复杂的神经网络相比，从本文构建的 CNN 中提取的深度特征在猪咳嗽识别的处理时间上具有绝对的优势。

Amiriparian 等人研究表明不同的 CNN 模型采用颜色各异的时频图会影响模型的识别结果[145]。本研究中的时频图仅使用了一种颜色（Viridis）作为时频图实验对比颜色，在后续的研究中，可以将其作为优化声音的时频图表示的一种方式，来探究其对生猪咳嗽声识别任务下的 CNN 模型的性能影响。由于，训练神经网络进行监督学习的主要挑战之一是需要大量的标记数据，可用于学习的数据集的大小直接影响监督模型的性能。本研究中实验基于手工标记的私人数据集，这也是限制深度模型分类性能的因素之一。

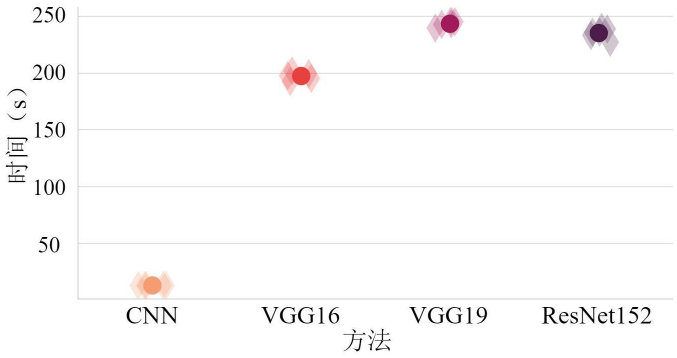


图 4-16 基于浅层 CNN 与迁移学习下提取深度特征的时间对比

Figure 4-16 Pointplots of computational time based on VGG, ResNet and proposed method

4.5.3.3 基于单输入谱图特征层融合与基于双谱图特征融合架构对比实验

下面分析一下不同融合算法对分类性能的影响。根据表 4-9 的结果，本文选择基于单输入的 CQT 谱图融合 FC1 和 FC2 的特征向量，研究层间融合（Layer Fusion，LF）。此外，基于 CQT 和 STFT 双谱图分别提取的 FC1 全连接层的输出特征进行融合，表示为谱图融合（TFRs Fusion，TF）。本文提出的对位差值（Sub）融合方式将对比于常见的五种融合算子，包括串行拼接操作（Concat）、加性操作（Add）、对位乘积（Mul）、以及最大值（Fmax）和最小值（Fmin）。

（1）基于单输入特征层融合策略对比的生猪咳嗽声识别性能

首先，将本文提出的对位差值和其他融合方式相比较，以评估不同融合方式的有效性。表 4-11 对比了单输入谱图融合构架中不同融合方式的识别结果。对比其他层间特征融合方式，对位差值（Sub）融合方式在生猪咳嗽声识别任务中各项指标取得最优结果，F1 达到 94.14%，召回率达到 93.43%。相比于未融合前的 FC1-CQT 特征，F1 提高了 1.49%。

中国知网 https://www.cnki.net

表 4-11 基于单输入特征层融合策略对比的生猪咳嗽声识别性能

Table 4-11 Pig cough recognition of layer fusion of FC1 and FC2 extracted from CQT

融合方式	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
LF(Add)	91.20	91.25	90.75	91.75
LF(Fmax)	91.27	91.36	90.51	92.22
LF(Fmin)	89.39	89.26	90.34	88.21
LF(Mul)	88.81	89.04	87.93	90.19
LF(Concat)	92.55	92.91	92.49	92.06
LF(Sub)	93.13	94.14	92.74	93.43

Concat 融合方式的识别性能略低于 Sub 融合方式，F1 达到 92.91%。采用其他四种层间融合方式后，识别性能不及未融合的结果，各项指标均有所下降。其中，对位乘积融合方式下降幅度最大。综上，经对比说明在单输入时频图特征提取深度特征过程中，深度特征的不同层之间的差异性特征能更好的描述不同声音信号的特征。

（2）基于双输入谱图特征融合的生猪咳嗽声识别性能

表 4-12 对比了双输入谱图特征融合构架中不同融合方式的识别结果。由表 4-12 中可以发现：

拼接融合方式的生猪咳嗽声识别性能达到最佳，F1 达到 94.74%；相比于未融合前的 FC1-CQT 特征，识别准确率提高了 2.09%。

对位差值融合方式识别准确率达到 93.52%，该方法与对位相加（Add）及对位最大化（Fmax）融合方式结果相当。

Fmin 和 Mul 的融合方式在生猪咳嗽声识别任务中的各项指标均有所下降，其中，Mul 融合方式的 F1 分数为 90.57%。

综上，经对比说明在双输入时频图特征提取深度特征过程中，增加不同时频图提取特征的多样性，能够有效的提升模型的识别能力。

表 4-12 基于双输入谱图特征融合的生猪咳嗽声识别性能

Table 4-12 Pig cough recognition performance of TFRs fusion extracted from CQT and STFT

融合方式	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)
TF(Add)	93.42	93.55	93.08	94.03
TF(Fmax)	93.36	93.39	92.92	93.87
TF(Fmin)	91.40	91.42	91.18	91.67
TF(Mul)	90.53	90.57	90.80	91.03
TF(Sub)	93.43	93.52	94.04	93.78
TF(Concat)	94.51	94.74	95.45	94.03

通过对比不同融合方式可以发现：不论是层融合还是谱图融合，特征乘积融合算子均取得最差的结果，这可能是在声音特征提取过程中，谱图提取特征本身具有一定的特征稀疏性。这一特性，在乘积融合计算方式下被放大，造成了不同层提取特征下的非零表示被归零，进

中国知网 https://www.cnki.net

而模糊了特征表示。

通过对比层融合和谱图融合两种架构可以发现：整体上来看，两种融合架构在合适的融合方式基础上均可以有效的提升模型的分类性能。相比于谱图融合，层融合的性能得到了轻微的改进，而谱图融合构架在整体性能上得到了较大的性能提升。

这说明从深度特征辨识度的角度出发，相比于层间特征，谱图特征融合对深度特征的性能高低影响较大。谱图特征融合的过程不仅选择了代表性层特征，更重要的是带来谱图间的图形差异，这些因素的叠加增强了特征的显著性，提升了特征分类的效果。

4.6 本章小结

本章针对商业猪舍内声音特征提取不充分的问题，从声音的二维时频角度出发，充分挖掘了舍内声音的两种时频图，包括短时傅里叶变换和常数 Q 变换。并基于时频图特征进一步提取声音的视觉特征，同时提出了一种浅层卷积神经网络架构完成对声音深度特征的提取，以实现对时频图特征的挖掘。本章的主要实验结果如下：

（1）探索不同时频图的参数对后期声音识别精度的影响。通过两种窗长的参数改变和对比，常数 Q 变换时频图略优于短时傅里叶变换。

（2）探索了基于局部二值模式和方向梯度直方图两种视觉特征融合策略。提出了基于不同分辨率的局部二值模型的特征融合和不同通道数的方向梯度直方图的特征融合。

（3）提出一种浅层卷积神经网络架构提取特征。在有限数据集下，浅层卷积神经网络略优于迁移学习下的深度神经网络，但时间成本远低于深度神经网络。同时，对比单谱图输入的层融合，基于双谱图输入的特征融合分类性能更优。

中国知网 https://www.cnki.net

5 基于声学特征和时频图特征融合的生猪咳嗽声识别

5.1 引言

在复杂猪舍环境下，杂交育肥猪只的呼吸道疾病的感染率较高，传播速度较快。但其急性发病情况较少，其早期临床特征为间接性强度不等的咳嗽。然而猪舍内群猪的声音环境较为复杂多样，这导致了猪舍内咳嗽声与非咳嗽声样本不均衡的问题。

在非平衡数据集下，一方面，导致了常规模型评价准则无法准确评估模型性能；另一方面，非平衡数据集分类导致模型的预测能力和泛化能力下降。这一特性为非平衡数据集下的生猪咳嗽声识别带来了不小的挑战。由此，如何在获取少量咳嗽声样本的条件下，建立高精度的咳嗽声识别模型对于生猪咳嗽声的早期监测具有非常重要的研究意义。

为此，本文提出基于多域融合的方法提高生猪咳嗽声特征辨识度，在此基础上，完成针对不平衡数据样本的生猪咳嗽声识别，提出混合集成算法进一步提高不平衡数据问题下的识别精度。本章与第 3、4 章结构关系如图 5-1 所示。

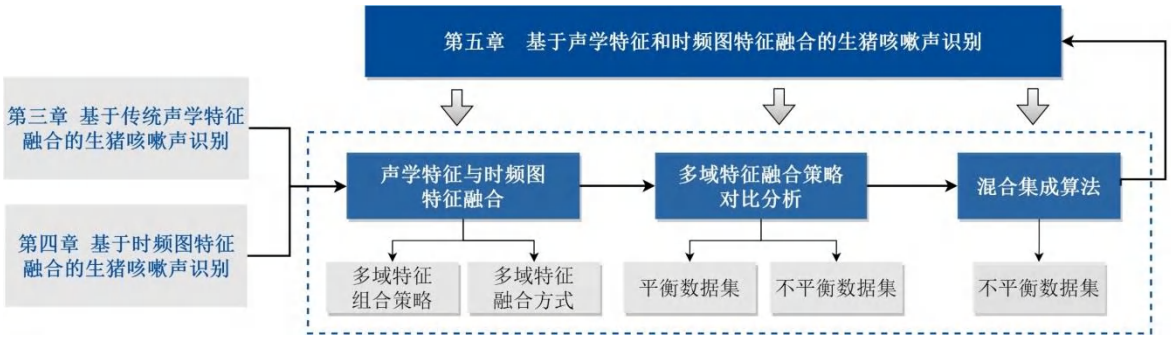


图 5-1 第五章主要研究内容与第 3、4 章关系

Figure 5-1 Diagram between this chapter and chapters 3 and 4

在第 3 章中，本研究从声音的一维声学信号中直接提取不同声音的声学特征并进行特征选择。第 4 章将声学信号转为二维时频图对舍内声音进行二维的声音表示，并基于两种不同的二维时频图进一步提取视觉特征和深度特征，在此基础上探究了基于时频图特征的融合。第 3 章和第 4 章的识别任务均是面向平衡数据集，由于到面向复杂猪舍环境下存在的声音数据不平衡问题，本章尝试采用基于声学特征和时频图特征融合的多域融合方式，从特征层面提高在不平衡数据集下的识别精度。在多域融合基础上，从算法层面，优化模型并进一步加强对目标声音的识别准确性，提升模型在复杂声音环境下的鲁棒性。

5.2 多域特征融合架构

声音的不同表示形式可以从不同维度传递多样的信息，结合不同维度下的异质信息可以进一步提供互补的特征信息。基于多特征融合理论，本文将声学特征和时频图特征进行融合。一方面，涵盖了原始声音数据的传统声音特征，另一方面时频图特征在时间和频率双重维度

中国知网 https://www.cnki.net

上包含更丰富和紧凑的特征信息。通过多特征融合从多域的角度对生猪咳嗽声进行有效表达，进而提升模型的泛化能力。

5.2.1 多域特征组合策略

本文提出的基于声学特征和时频图特征的融合架构示意图如图 5-2 所示。图中主干部分的特征提取过程基于第三章和第四章，特征子集选择声学特征子集和时频图特征的局部最优结果。声学特征子集（Acoustic）为第三章中经过特征选择后包括时域特征、频域特征以及来自倒谱域特征的梅尔频率倒谱系数在内的声学特征向量子集。视觉特征采用第四章中基于 CQT 提取的局部二值模式 $LBP_{12,2}$ 和灰度图像下提取的方向梯度直方图 HOG-Gray。深度特征采用第四章中基于单谱图最佳特征表示（FC1-CQT），以两种深度特征融合架构的最佳融合结果，即层融合（Layer fusion）和双谱图融合（TFRs fusion）。

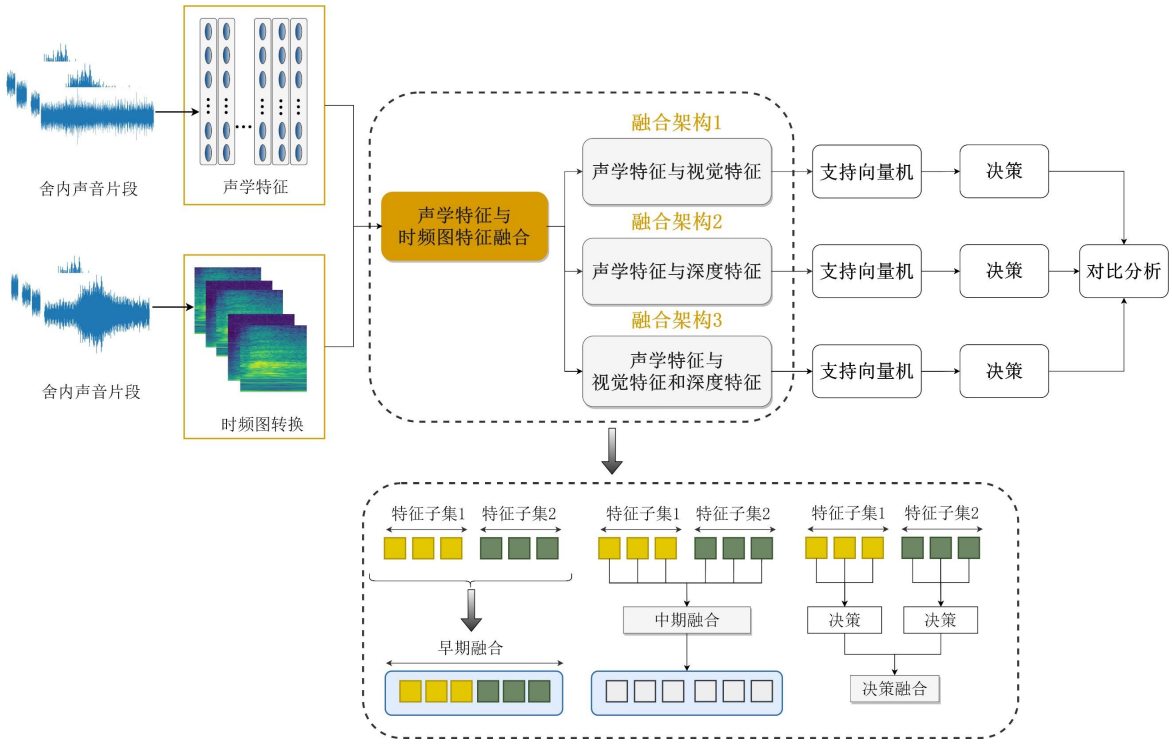


图 5-2 基于声学特征和时频图特征融合架构示意图

Figure 5-2 Diagram of acoustic and time-frequency feature fusionarchitecture

基于以上声学特征和时频图特征提取结果，为了有效地利用不同特征的互补性，本章主要提出三个基于特征级融合架构。

架构 1：基于声学特征和视觉特征融合架构；

架构 2：基于声学特征和深度特征融合架构；

架构 3：基于声学特征、视觉特征和深度特征融合架构。

表 5-1 显示了融合架构 1 和 2 的特征组合策略。架构 1 包括基于声学特征和最佳参数下的局部二值模式（Acoustic+$LBP_{12,2}$）、声学特征和最佳参数下的方向梯度直方图（Acoustic+

中国知网 https://www.cnki.net

HOG-Gray）、声学特征和两种视觉特征的融合（Acoustic+$LBP_{12,2}$+HOG-Gray）。架构 2 包括声学特征和基于单输入模型下提取的最佳深度特征融合（Acoustic+FC1-CQT）、声学特征和基于单输入层融合的特征结合（Acoustic+Layer fusion）以及声学特征和基于双输入的时频图特征融合（Acoustic+TFRs fusion）。最后将三类特征中的最优结果进行组合，构成了融合架构 3 的不同特征组合，如表 5-2 所示。

表 5-1 融合架构 1 和 2 的特征组合策略

Table 5-1 Different feature combination methods based on two feature fusion architecture

融合架构	特征组合	特征编号
声学特征+视觉特征	Acoustic+$LBP_{12,2}$	A+L
声学特征+视觉特征	Acoustic+HOG-Gray	A+H
声学特征+视觉特征	Acoustic+$LBP_{12,2}$+HOG-Gray	A+L+H
声学特征+深度特征	Acoustic+FC1-CQT	A+F
声学特征+深度特征	Acoustic+Layer fusion	A+LF
声学特征+深度特征	Acoustic+TFRs fusion	A+TF

表 5-2 融合架构 3 下的特征组合策略

Table 5-2 Different feature combination methods based on feature fusion architecture 3

融合架构	特征组合	特征编号
声学特征+视觉特征+深度特征	Acoustic+$LBP_{12,2}$+FC1-CQT	A+L+F
声学特征+视觉特征+深度特征	Acoustic+$LBP_{12,2}$+Layer fusion	A+L+LF
声学特征+视觉特征+深度特征	Acoustic+$LBP_{12,2}$+TFRs fusion	A+L+TF
声学特征+视觉特征+深度特征	Acoustic+HOG-Gray+FC1-CQT	A+H+F
声学特征+视觉特征+深度特征	Acoustic+HOG-Gray+Layer fusion	A+H+LF
声学特征+视觉特征+深度特征	Acoustic+HOG-Gray+TFRs fusion	A+H+TF
声学特征+视觉特征+深度特征	Acoustic+$LBP_{12,2}$+HOG-Gray+FC1-CQT	A+L+H+F
声学特征+视觉特征+深度特征	Acoustic+$LBP_{12,2}$+HOG-Gray+Layer fusion	A+L+H+LF
声学特征+视觉特征+深度特征	Acoustic+$LBP_{12,2}$+HOG-Gray+TFRs fusion	A+L+H+TF

在不同特征组合策略构建后，结合不同的融合方式输入 SVM 中进行生猪咳嗽声的识别，并进行多特征融合策略的对比分析。对于不平衡问题的研究，数据集度量方式尤其重要。研究证明通过合适的数据划分能够使模型性能得到有效评估，这对于开发可靠的基线模型和不同算法间的比较至关重要[172]。分层 K 折交叉验证的核心是，在传统 K 折交叉验证基础上在每个分组中确保两种类别比例与整个数据集的比例相同，即样本比例是对总体比例的无偏估计。尤其在对少数类样本进行抽样进行模型验证时，最大程度的规避了验证集仅包含单一种类样本的极端情况。分层交叉验证是传统交叉验证方法的延伸，同时结合第二章的中介绍的嵌套交叉验证对模型参数进行优化，二者相结合构成嵌套分层交叉验证（Nested stratified cross validation，NSCV），并将其作为不平衡数据研究和实验中的数据划分方式。

中国知网 https://www.cnki.net

5.2.2 多域特征融合方式

除了多特征间的组合策略，特征间的融合方式也是影响融合后模型性能的重要因素。不同特征数据间的组合模式可以在不同程度上增加特征信息。如图 5-2 所示，本文考虑了特征的拼接融合（早期融合）、典型相关分析特征融合（中期融合）以及决策级融合三种方式。

（1）拼接融合

拼接融合（Concatenation fusion），属于早期融合方式之一。串联组合直接将多个不同域的特征向量进行首尾拼接，组合成一个新的特征向量，不做额外的特征处理，其维数为组合前所有多域特征维数之和。假设α和β为猪舍内声音信号x在两个不同特征空间A和B的特征向量，即$\alpha \in$ A和$\beta \in$ B，对其进行串联，可得：

$$X_{concat=}\begin{pmatrix}\alpha\\ \beta\end{pmatrix} \tag{5-1}$$

由于拼接融合是将特征提取后的信息全部纳入模型对其进行识别，充分涵盖了不同数据的信息量，因此这种方式具有较高的保真性。此外，不同特征存在不同的关系，早期融合策略可以学习跨原始数据间的特征关系[173]。

（2）典型相关分析特征融合

典型相关分析(Canonical Correlation Analysis，CCA), 属于特征中期融合方式，其能够从总体上揭示两组数据之间的内在关系，将两组独立的特征向量进一步变换和分析后再进行融合[174]。假设样本数为n，两个特征向量$x \in R^P$，$y \in R^q$，则$X = [x_1, ..., x_n] \in R^{p\times n}$且$Y = [y_1, ..., y_n] \in R^{p\times n}$。CCA 的目标最大化公式如（5-2）所示：

$$J(w_x, w_y) = \frac{w_x^T C_{xy} w_y}{\sqrt{w_x^T C_{xx} w_x w_y^T C_{yy} w_y}} \tag{5-2}$$

其中，w_x，w_y分别表示两个特征向量的投影方向。$C_{xx} = XX^T$，$C_{yy} = YY^T$分别为X和Y的协方差矩阵。$C_{xy} = XY^T$为互协方差矩阵。一般情况下，假定

$$\text{s.t.}\ \begin{cases} w_x^{\mathrm{T}} C_{xx} w_x = 1 \\ w_y^{\mathrm{T}} C_{yy} w_y = 1 \end{cases} \tag{5-3}$$

上述问题可转化为约束下的最优化问题

$$max\ \ w_x^{\mathrm{T}} C_{xy} w_y \tag{5-4}$$

计算时构造拉格朗日等式,并将问题转化为变换矩阵$W_x \in R^{p\times l}$和$W_y \in R^{q\times l}$的特征值方程求解问题。可得，$Z_x = W_x^T X \in R^{l\times n}$，$Z_y = W_y^T Y \in R^{l\times n}$为变换后的特征，其中$l \le min\{p, q\}$，融合特征为$Z = [Z_x, Z_y] \in R^{2l\times n}$。

（3）决策级融合

决策级融合（Decision fusion），属于后期融合的一种方式，不再将学习到的特征合并，而是将单独的特征子集输入到识别模型的决策合并为最终决策[175]。本文设n个独立的特征子集用于生猪咳嗽声识别任务中，每个特征子集均是基于 SVM 方法进行决策，因而n个特征子集得到预测结果为$b_i = (b_1, b_2, ..., b_n)$。本文采用预测值取平均的方式，一般计算表达式如下：

中国知网 https://www.cnki.net

$$b = {}^{1}\!/_{n} \sum_{i=1}^{n} b_i \tag{5-5}$$

其中，b 表示求平均后的模型输出。在这种组合中，每个分类器的分数被平等地加权，权重均设置为${}^{1}\!/_{n}$，每种特征子集最终结果的输出贡献视为等同的。

5.3 混合集成算法在不平衡数据集下的生猪咳嗽声识别

5.3.1 集成学习模型

由于复杂猪舍环境下声音种类的多样化，传统的单一分类算法在识别任务中存在一定的局限性。集成学习使用多个基学习器进行组合学习，通过以某种方式集成多个分类器，并进行决策输出。集成学习包括同质和异构两种类型[176]。在同质模型中，分类过程中使用的所有模型都是相同的，模型之间通过样本的再次划分来影响识别结果。在异构模型中，每个模型的输入数据都相同，将不同的模型作为基分类器，以增加模型学习的多样性。集成学习中的 Bagging 和 Stacking 分别是典型的同质模型和异构模型。

Bagging 是由 Leo Breiman 在 1994 年提出的基于自助采样法（Bootstraping）的统计方法，也是典型的同质集成学习模型。假设有一个训练集 X，使用 Bootstraping 法，从原始数据中随机、均匀地抽取样本并进行替换，创建多个自助采样样本，这样每个新的自举样本将作为另一个几乎独立的数据集，从真实分布中提取出产生样本X_1，……，X_M。由于所有元素被选中的可能性都是一样的，因此每个元素被抽取的概率相同，这些样本被认定为具有代表性的样本。随后，对于每个自举样本，训练它独立的弱分类器$a_i(x)$，对所有单个独立的分类器的预测输出进行结合，通常默认采用多数投票法。Bagging 集成学习框架，如图 5-3 所示。

$$a(x) = \frac{1}{M} \sum_{i=1}^{M} a_i(x) \tag{5-6}$$

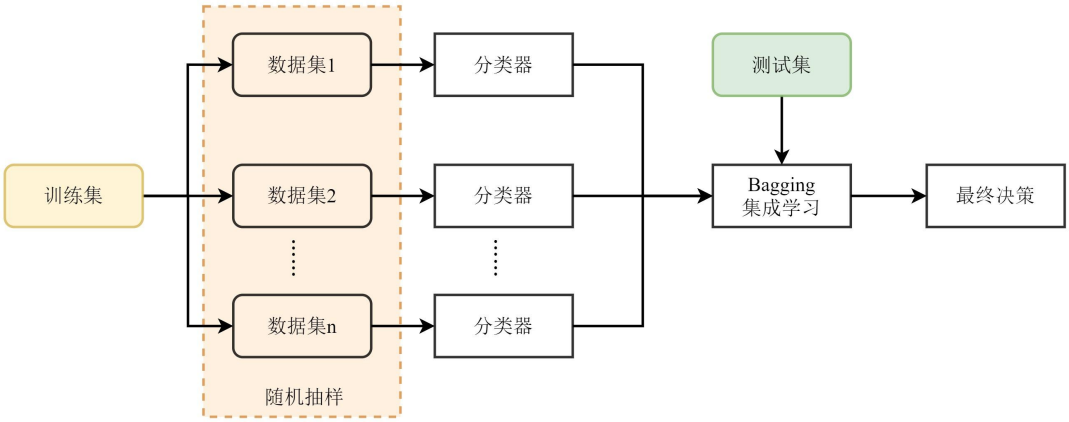


图 5-3 基于 Bagging 集成学习框架示意图

Figure 5-3 Diagram of bagging ensemble learning method

中国知网 https://www.cnki.net

在这个抽样过程中，不可避免的一些实例将被抽样多次，而其他实例将被忽略。因此，对于特定的子空间，分类器会有较高的分类准确率，而对于那些被忽略的部分，基分类器很难对其进行正确的分类。另外，Bagging 的学习性能取决于其基分类器的稳定性。

Stacking 是典型的异构集成学习模型，其采用两层框架结构，如图 5-4 所示。第一层由不同的机器学习模型组成，称为基分类器。不同的基分类器对输入数据进行输出预测。随后，将所有的输出预测组合作为第二层的新输入，第二层称为元分类器。在这个过程中，通过使用多种类型的基分类器，将它们组合成一个强分类器，以提高强分类器的泛化能力。

堆叠提高了分类输出模型的灵活性，进而在集成学习中得到了广泛的应用。堆叠集成算法兼顾了主分类器和元分类器的学习能力。与使用单一学习算法相比，堆叠泛化算法可以减少偏差，降低泛化误差。堆叠允许混合不同的异构算法或特定的参数的模型。然而，在构建组合模型的过程中，如何选择基分类器并充分发挥它们的有效性，以及如何选择最优的元分类器，都是值得关注的问题。针对不同的研究对象，为每个数据集找到元分类器和基分类器的最佳组合对最终输出结果十分重要[177]。

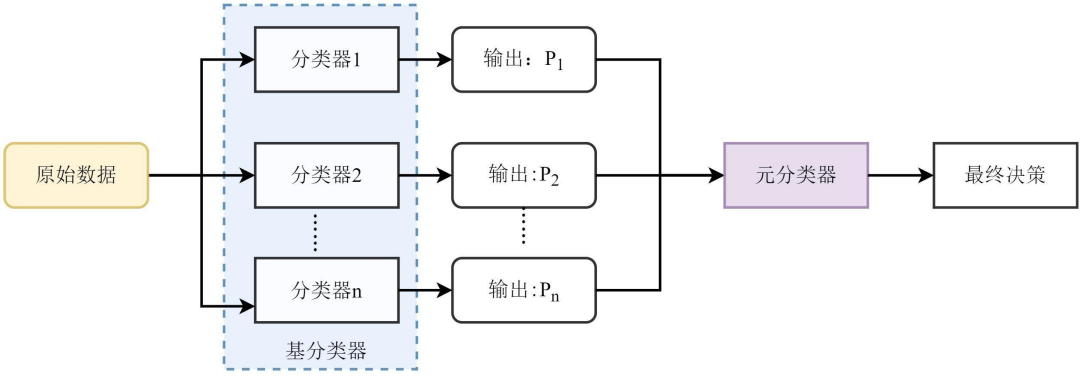


图 5-4 基于 Stacking 集成学习框架示意图

Figure 5-4 Diagram of stacking ensemble learning method

5.3.2 混合集成算法

从以上的分析可知，目前所描述的两种模型都依赖于多分类器选择和对数据的元学习。堆叠泛化集成算法可以兼并异构基分类器算法之间的差异化特性，而 Bagging 集成算法可以通过调整数据子集的选择，生成的二级同质模型强化模型的决策结果。得益于深度神经网络的启发，即适当增加神经网络层深度可以提高网络性能[178]，深度神经网络可以被视为分层分类器[179]。而相应的集成方法则是通过增加额外的分类器来增加模型的整体性能。

为实现不平衡数据下的生猪咳嗽声识别，并充分结合二者的优势，本节从两个角度出发：一是保持基分类器性能稳定的前提下，设计差异化的多层基分类器组合。二是将 Bagging 学习引入到堆叠算法中，来自基分类器子集的结果被提供给元分类器的集合。随后将来自元分类器的输出结合起来，以达到最终裁决，从而克服前期预测数据的不平衡性。在本节中，基于 SSLRB 混合集成算法框架图，如图 5-5 所示。由图可知，SSLRB 混合集成算法框架主要

中国知网 https://www.cnki.net

包括两部分：同构 SVM 堆叠模块（SVM-Stacking）以及基于随机上采样（ROS）的 Bagging 模式（LR-Bagging based on RandomOverSampler，LR-Bagging）。

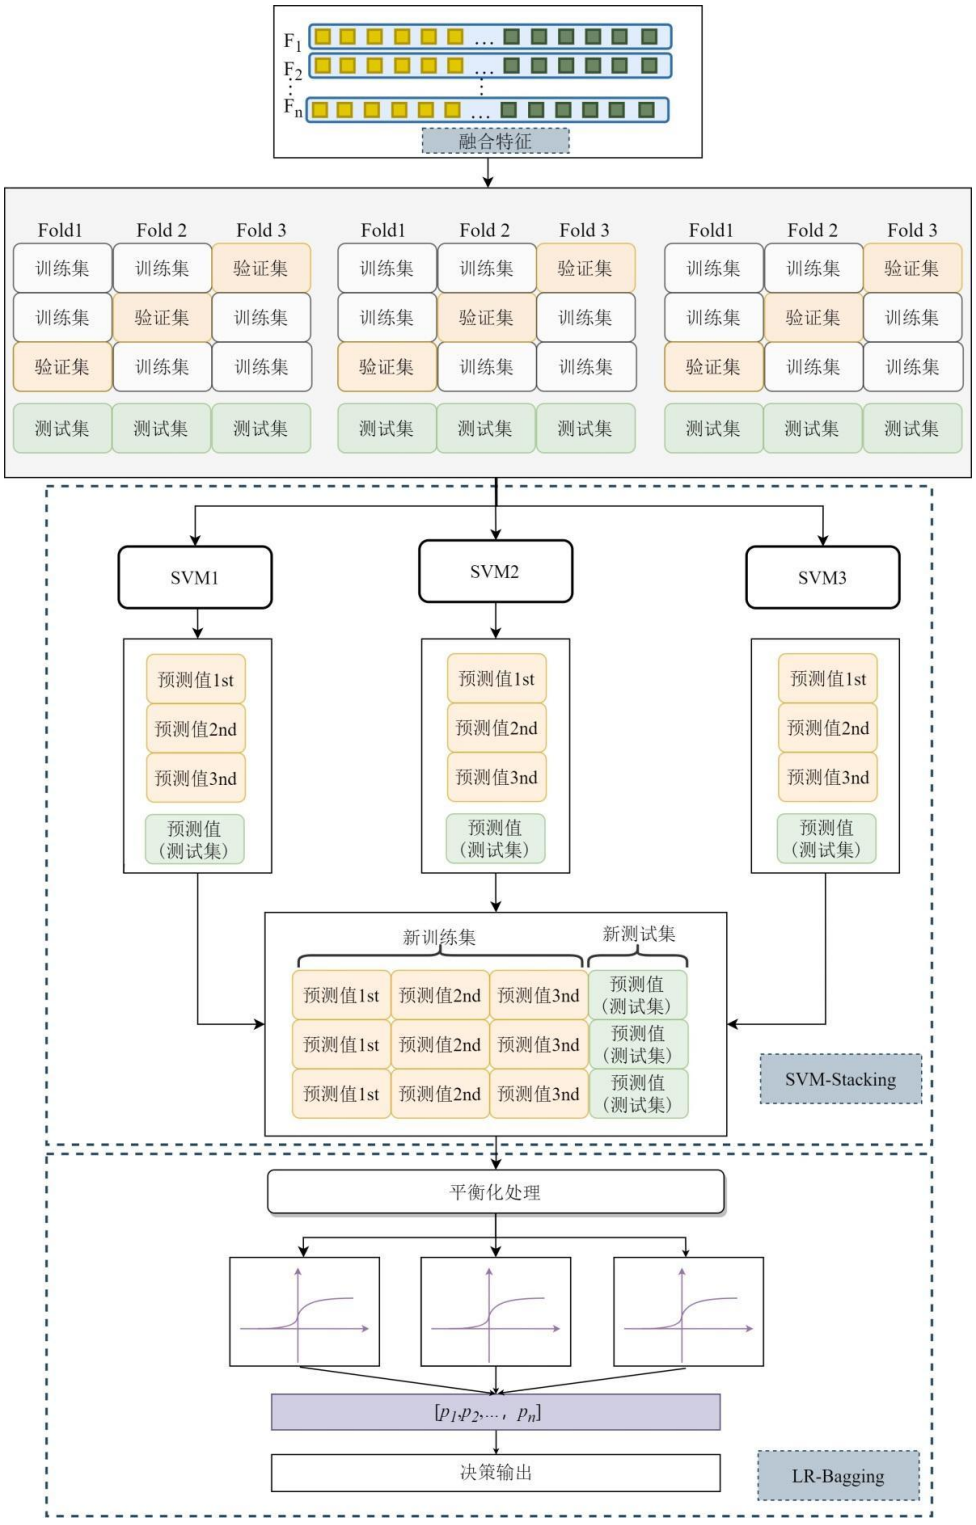


图 5-5 基于 SSLRB 混合集成算法框架图

Figure 5-5 Flowchart of SVM-Stacking with LR-bagging ensemble learning architecture

中国知网 https://www.cnki.net

（1）SSLRB 的第一层中的 SVM-Stacking 模块是选择不同参数下的 SVM 分类器作为模块的基分类器。SSLRB 框架学习的基分类器学习是重要阶段，在这一阶段，基学习器对原始数据进行预测，然后将每折测试集的预测结果传递给元学习模块以获得最终结果。集成叠层算法的重点在于每一个分类器的选择，分类器包含众多的参数，这种灵活性极易导致模型的不确定性。因此，泛化能力突出的 SVM 被选择作为叠层算法的基分类器。为尽可能固定每个分类器的性能，基分类器的参数选择相对最佳的搜索后的参数，包括 SVM_1（kernel='rbf', C=100, gamma=0.1）；SVM_2（kernel='rbf', C=100, gamma=0.01）以及 SVM_3（kernel='rbf', C=100, gamma=0.001）。SVM 的参数是上一节中基于网格优化对不同特征子集优化后的最佳参数。基于不同 SVM 参数的集成保证了不同程度 IR 比值下的分类性能，满足了模型整体性能的高度鲁棒性，同时保证模型间存在一定差异性的前提下减少了传统异构模型的时间消耗。

尽管交叉验证是评价分类性能的一种有效方法，但 Santos 等人研究表明合理划分原始数据作为训练集和测试集是不平衡问题研究中的关键步骤[180]，不良的使用交叉验证将导致结果过于乐观，尤其是在结合数据采样算法使用时。因此，本实验中每个基分类器均对原始数据集采用 3 折分层交叉验证，对每一折中的验证集进行结果的预测，生成三组预测值。这些预测值成为集成元学习模块的新训练集。而测试集对应分类器训练生成的预测值成为集成元学习模块新的测试集。SSLRB 算法中的样本随机抽取过程只针对训练集（K-1）数据部分。由于模型训练的过程不能代表测试环境，因此在交叉验证的每个迭代中，模型都是在趋于平衡的训练数据集上训练，同时保证了在各自折叠中不平衡的测试数据上应用测试。

（2）SSLRB 的第二层采用嵌入多个逻辑回归（Logistic Regression，LR）元学习器的 Bagging 算法进一步优化元分类器，并采用随机上采样对 SVM-Stacking 模块中生成的预测值进行平衡化处理，即对其中的少数类的样本进行随机采样来增加新的样本，最终共同决策。元学习者的选择决定了堆叠集合的性能高低，因为元学习者决定堆叠集合的最终预测。因此，本文将传统单一的元学习者优化为采用嵌入多个元学习者的 LR-Bagging 集成学习模块。

集成元学习模块的优化基于两点因素：其一，作为鲁棒性较强的线性分类器，LR 是不平衡分类问题中常用的元学习器[181]。逻辑回归是一种参数模型，从一组自变量中预测二元结果。其本质上是采用逻辑函数完成对[0,1]标签的输出。逻辑函数的定义如公式所示：

$$Sigmoid\ (z) = \frac{1}{1+\exp^{-z}} \tag{5-7}$$

在线性回归模型中，用一个线性方程对结果和特征之间的关系进行了建模，而逻辑回归是将结果的对数概率进行建模，如公式所示：

$$log\ \left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_f x_f \tag{5-8}$$

其中公式（5-9）是将 sigmoid 函数参数化，p表示模型的概率输出，β_0表示截距，$\{\beta_1 \ldots\ldots \beta_f\}$表示对应特征$\{x_1 \ldots\ldots x_f\}$的系数。

$$p = \frac{1}{1+\exp^{-\left(\beta_0+\beta_1 x_1+\beta_2 x_2+\ldots+\beta_f x_f\right)}} \tag{5-9}$$

中国知网 https://www.cnki.net

其二，Stacking 模型的体系结构决定了集成元学习模块学习阶段是基于上一层的学习结果并进行二次学习的过程。集成元学习模块的性能取决于每个嵌入的元学习者的性能，元学习者的精度越高，最终集成效果越好。由于类间先验分布的偏态和抽样偏差，对于这种不平衡的数据集在监督学习中对少数类预测常倾向于大多数类。为此，将 Bagging 嵌入到 Stacking 叠层模型中，采用 Bagging 可以满足不同比例下随机抽取二类样本，从而组合形成不同的样本集。并通过构建多个 LR，每个独立的 LR 使用不同的样本集进行学习和预测，并将 LR 的输出汇总，从而进行最终的预测。随着 LR 学习器的增加，整个集成元学习模块的多样性随之增加，进而达到提升整体性能的目的。模型最终预测结果如公式所示，$f^A(x_i)$ 的输出是多个元分类器 LR 预测概率$p^m(y_i|x_i)$的平均值集合。M 表示元分类器 LR 的数量。

$$f^A(x_i) = \frac{1}{M}\sum_{m=1}^{M} p^m(y_i|x_i) \tag{5-10}$$

5.4 实验结果与分析

5.4.1 实验设置

本研究训练分类模型基于 Intel(R) Core (TM) i7-10750H CPU 2.6GHz，RAM 16GB，NVIDIA GeForce GTX 1650 Ti GPU，64 位 Windows 10 操作系统。实验涉及相关数据分析和模型建立均使用 Python 3.7、Scikit-learn、TensorFlow 2.6.2 和 Keras 2.6.0 在 PyCharm Community Edition 2020 软件环境中完成。卷积神经网络模型使用的代价函数为交叉熵，并利用 Adam 算法优化网络训练过程，其初始学习率设置为 0.01，损失函数为交叉熵损失函数。实验结果的图表呈现采用 Matplotlib 3.3.1 及 Seaborn 0.11.1。

由于到在复杂猪舍内的咳嗽声识别问题中，咳嗽声与舍内非咳嗽声呈现不平衡状态。本课题不仅研究并讨论平衡数据集下（共计 2546 个声音片段，包括咳嗽声 1273 个和非咳嗽声 1273 个）的咳嗽声识别问题，还进一步将数据集划分并讨论类别不平衡问题。

类别不平衡是指在数据集中，样本类别之间的数据规模存在一定倾斜[182]。由于识别生猪咳嗽声为本研究的主体，因此本文主要针对二类不平衡问题，也就是咳嗽声为一类，非咳嗽声划为另一类。其中，少数类样本（$Minority$）是指为目标识别样本，即生猪咳嗽声；多数类样本（$Majority$）是指猪舍内的其他声音。一般根据不平衡比值（Imbalance rate，IR）来划分不同程度的不平衡问题，IR 值为多数类样本与少数类样本的比值[183]，即非咳嗽声与咳嗽声数量的比值。如公式所示：

$$IR = \frac{Majority}{Minority} \tag{5-11}$$

将不平衡问题划归为三种不平衡等级问题，即轻度不平衡问题，IR 值在 1.5-3 之间；中度不平衡问题，IR 值在 3-9 之间；严重类不平衡，即 IR 值为 10 以上的情况。也就是说，IR 值越大，代表两类数据的样本数量差异越明显。

为了评估类别不平衡的影响，本文通过随机删除[184]生猪咳嗽声样本，对数据样本进行等级重划分。这种方式保证了在相同非咳嗽声环境下的，复杂猪舍面临的咳嗽声数量不平衡

中国知网 https://www.cnki.net

情况。IR 比值参考以往文献[39-41,185]中的设置，进一步划分为六组不同 IR 数据集，实验方案如下表 5-3 所示。

表 5-3 不平衡数据集划分情况

Table 5-3 Dataset split by different IR ratios

数据集	不平衡等级	咳嗽声样本数	样本总数	不平衡比值（IR）
D1	轻度	849	2122	1.5
D2	轻度	468	1741	2.72
D3	中度	257	1530	4.95
D4	中度	141	1414	9.03
D5	重度	126	1399	10.10
D6	重度	96	1369	13.26

针对不平衡数据集研究，本章实验采用三折内嵌分层交叉验证模型进行评估。实验结果采用精准率（Precision）和召回率（Recall），F1 分数（F1-Score），几何平均准确率（G-mean）采用百分制（%）的表现形式。除此之外，进一步绘制接收者操作特征曲线下面积 ROC-AUC（Receiver operating characteristic- Area under the curve）以及精准召回曲线下面积 PR-AUC（Precision and Recall - Area under the curve）。AUC 值的区间范围是[0,1]，AUC 数值越大，说明模型的性能越好。实验结果呈现分成三个主要部分，一是多域特征融合在平衡数据集下的实验与分析，二是多域特征融合在不平衡数据集下的实验与分析，三是基于融合特征的混合集成算法的实验与分析。

5.4.2 多域特征融合在平衡数据集下的实验结果与分析

实验分成三部分：实验一基于融合架构 1 和 2 下的多组特征融合方式实验对比，探究拼接融合、典型相关分析特征融合及决策级融合三种融合方式对生猪咳嗽声识别性能的影响；实验二是选择最优融合方式后，对多组特征融合前后的性能进行对比分析；实验三是基于以上研究结果，进一步讨论融合架构 3 下的多组特征融合前后的性能对比分析，并从识别精度和模型计算时间评价融合特征子集在生猪咳嗽声识别上的有效性，进而筛选最佳特征子集。

5.4.2.1 基于融合架构 1 和 2 下的多组特征融合方式实验对比

（1）基于融合架构 1 和 2 下的多组特征拼接融合的生猪咳嗽声识别性能

表 5-4 显示了基于融合架构 1 和 2 下的多组特征拼接融合的生猪咳嗽声识别性能结果。对比融合架构 1（声学特征和视觉特征融合）下的三种特征组合：A+H 的各项评价指标均优于 A+L；对比 A+H，A+L+H 生猪咳嗽声识别的准确率、F1 分数和精准度得到了一定的提升，分别达到 97.80%、97.79%和 98.19%；模型计算时间增加了 206.283s。随着视觉特征种类增加，模型性能得到轻微的提升，然而更多特征引入带来的特征维度的增加，导致模型计算时间大幅度提升。

对比融合架构 2（声学特征和深度特征融合）下的三种特征组合，A+TF 取得了最佳的识别性能，准确率达 97.57%，低于 A+H（97.64%）和 A+L+H（97.80%）；A+TF 在召回率

中国知网 https://www.cnki.net

上优于其他特征子集，达 97.88%，这说明其在生猪咳嗽声的查全率上表现最好，这种融合更能获得较低的漏检率。对比 A+TF、A+H 和 A+L+H 这三种特征组合，模型计算时间差异较大，A+L+H 所需的时间最长 371.002s，A+H 不足其运算时间的一半，A+TF 消耗时间最短为 70.291s，表明声学特征与深度特征组合具有充分的挖掘潜力。

表 5-4 基于融合架构 1 和 2 下的多组特征拼接融合的生猪咳嗽声识别性能

Table 5-4 The results of pig cough recognition under architectures 1 and 2 with concatenation

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
A+L	96.03	96.04	96.12	95.99	170.207
A+H	97.64	97.64	97.88	97.40	164.764
A+L+H	97.80	97.79	98.19	97.40	371.002
A+F	96.90	96.89	97.01	96.78	44.406
A+LF	96.94	96.96	97.17	96.70	42.104
A+TF	97.57	97.57	97.27	97.88	70.291

（2）基于融合架构 1 和 2 下的多组特征 CCA 融合的生猪咳嗽声识别性能

表 5-5 为融合架构 1 和 2 下的多组特征 CCA 融合的生猪咳嗽声识别性能。由表可知，在融合架构 1 下，A+L+H 准确率达 95.55%，优于 A+L 和 A+H，模型整体计算时间达 264.799s；在融合架构 2 下，A+TF 融合策略优于其他融合策略，整体识别准确度得到 96.47%，其模型计算时间为 78.066s。

表 5-5 基于融合架构 1 和 2 下的多组特征 CCA 融合的生猪咳嗽声识别性能

Table 5-5 The results of pig cough recognition under architectures 1 and 2 with CCA

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
A+L	94.63	94.78	96.12	93.47	160.292
A+H	93.71	93.89	96.28	91.62	169.119
A+L+H	95.55	95.72	95.96	95.48	264.799
A+F	95.19	95.39	96.39	94.41	59.528
A+LF	94.60	94.79	96.53	93.11	60.134
A+TF	96.47	96.63	97.18	96.09	78.066

（3）基于融合架构 1 和 2 下的多组特征决策级融合的生猪咳嗽声识别性能

表 5-6 为基于融合架构 1 和 2 下的多组特征决策级融合的生猪咳嗽声识别性能。由表可知，多特征组合的决策级融合方式中，A+H 优于其他融合策略，识别准确度和 F1 分数分别获得了 95.01%和 95.22%；A+TF 融合策略次之，识别准确度和 F1 分数分别获得了 94.21%和 94.47%。二者相比，A+TF 所消耗的时间为 41.354s，远低于 A+H 的 141.415s。

综上，在融合架构 1 和 2 下，融合特征数量的增加在一定程度上提升了生猪咳嗽声识别性能。从融合架构 1 和融合架构 2 的融合策略上对比可知，与 Acoustic 融合的不同深度特征对应的特征提取和模型计算时间远低于视觉特征。

在三种融合方式中，拼接融合的性能优于 CCA 和决策级融合。这说明拼接融合增强了

中国知网 https://www.cnki.net

生猪咳嗽声的代表性特征。相比于拼接融合，CCA 相当于对特征再一次进行选择，在此过程中，降低了模型的维度进而缩短了模型计算时间，但也在一定程度上降低了模型的识别精度。下面将采用拼接融合进行多种特征融合前后的性能对比以及融合架构 3 下的识别性能。

表 5-6 基于融合架构 1 和 2 下的多组特征决策级融合的生猪咳嗽声识别性能

Table 5-6 The results of pig cough recognition under architectures 1 and 2 with late fusion

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
A+L	93.43	93.13	94.14	92.73	170.010
A+H	95.01	95.22	95.76	94.69	141.415
A+L+H	93.98	94.26	94.79	93.73	274.368
A+F	92.74	93.05	93.85	92.27	30.969
A+LF	93.47	93.79	94.11	93.48	32.289
A+TF	94.21	94.47	95.10	93.85	41.354

5.4.2.2 基于融合架构 1 和 2 下的多组特征融合性能对比分析

本节进一步探究特征融合前后不同特征组合在生猪咳嗽声分类整体正确率的变化,如图 5-6 所示。Fusion-no 和 Fusion-yes 分别表示特征融合前后的生猪咳嗽声识别的准确率。由图中发现，六组不同的特征在与声学特征拼接融合后均分类性能均得到了显著的提升。

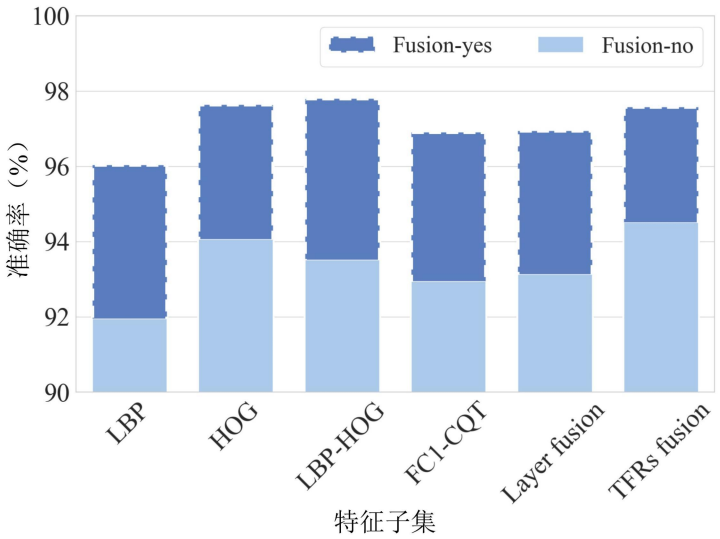


图 5-6 多组特征融合前后的柱状对比图

Figure 5-6 Barplots based on multi-features fusion combination

在视觉特征中，尽管 LBP 特征在分类准确率上表现相对较差，但在融合声学特征后，整体的特征子集在识别任务中提升最为明显，咳嗽声识别准确率由 91.95%提升到 96.03%，提升了 4.08%；HOG 特征融合前后的识别准确率由 94.06%提升到 97.64%，增加了 3.58%；LBP-HOG 与声学特征融合前后识别准确率由 93.51%提升至 97.80%，提升了 4.29%；在 HOG 融合基础上增加 LBP 特征，生猪咳嗽声的识别准确率提升了 0.16%。这表明即使个别

中国知网 https://www.cnki.net

特征表现不佳，当选择合适的互补的特征后，每一种特征类型都提供了互补的信息来促进分类。这种互补性应与特征各自的对不同声音的识别能力有关。

对比三组深度特征子集，TFRs fusion 与声学特征融合后的识别准确率优于 F1-CQT 和 Layer fusion，准确率达 97.57%；与声学特征融合后 FC1-CQT 明显缩小了深度特征子集间的性能差异，识别准确率由 92.94%提升到 96.90%；FC1-CQT 融合后的特征识别准确率与 TFRs fusion 融合后特征子集的分类准确率相差 0.67%。

根据以上结果，进一步分析 A+H、A+L+H 与 A+TF 三组特征对猪舍不同声音间的识别差异。三组特征子集的混淆矩阵，如图 5-7 所示。



a) A+H 混淆矩阵结果

a) Confusion matrix on Acoustic+HOG-Gray



b) A+L+H 混淆矩阵结果

b) Confusion matrix on Acoustic+L+H



c) A+TF 混淆矩阵

c) Confusion matrix on Acoustic+TFRs fusion

图 5-7 融合架构 1 和 2 下的三组融合特征的混淆矩阵

Figure 5-7 Confusion matrix for three feature sets based on feature fusion architecture 1 and 2

由图 5-7 a)可知，A+H 在咳嗽声正确识别个数为 415 个，低于其他两种融合特征。对比图 5-7 b)和图 5-7 c)可知，这两种融合特征对于生猪咳嗽声的正确判定个数是相同的，均为 416 个，二者对生猪咳嗽声的表达具有足够的辨识度。

针对非咳嗽声的识别中，生猪咳嗽声与生猪叫声为两类易混淆声音。图 5-7 a)中生猪叫声易被错误判定为清理声和生猪咳嗽声的均是 10，在误判总数中占据了 43.48%。对比图 5-

中国知网 https://www.cnki.net

7 a)，A+L+H 融合特征将二者的错误样本数量分别降低到 4 个和 8 个。对比图 5-7 a)和 5-7 c)可知，A+TF 提高了在清理声和人说话声的正确样本。在融合策略对比可知，A+TF 的识别性能优于其他融合策略。

综上，从时间复杂度和识别性能上来说，基于拼接融合的 A+TF 的拼接融合在融合架构 1 和 2 中性能最优。研究表明完全依靠声学或时频图特征不足以捕捉到足够的声音信息，一维声学特征与二维时频图特征分别包含了不同域下的声音特征信息。在生猪咳嗽声识别任务中，验证了不同音频模式下的提取的声音特征存在互补性。同时，结果显示相比于基于时频图的类内特征融合，声学特征与基于时频图特征的类间融合对模型分类结果的影响更大。

5.4.2.3 基于融合架构 3 下的多组特征融合性能对比分析

基于以上研究结论，表 5-7 显示了基于融合架构 3 下多组特征拼接融合的生猪咳嗽声识别性能。在 Acoustic+$LBP_{12,2}$ 特征的基础上进一步添加深度特征组成的 A+L+F、A+L+LF 和 A+L+TF 三种特征子集在生猪咳嗽声与非咳嗽声的识别任务中，各项评价指标均有所提升。其中，与 A+L+F 和 A+L+LF 相比，A+L+TF 准确率、F1 分数、精准率和召回率的结果更优，分别达到 97.56%、97.61%、97.25%和 97.49%。对比基于 Acoustic+HOG-Gray 添加深度特征组成的 A+H+F、A+H+LF 和 A+H+TF 三组特征子集，与 A+H+F 和 A+H+LF 相比，A+H+TF 的识别结果最佳，准确率、F1 分数、精准率和召回率分别达到 98.04%、98.04%、98.28%以及 97.80%。随着特征进一步添加，模型的识别性能在 A+L+H+TF 特征子集下的准确率、F1 和召回率达到最佳，分别为 98.08%、98.07%和 97.96%，同时模型计算时间达到 554.737s。

表 5-7 基于融合架构 3 下拼接融合的生猪咳嗽声识别性能

Table 5-7 The results of pig cough recognition under architectures 3 with concatenation fusion

特征子集	准确率 (%)	F1 分数 (%)	精准率 (%)	召回率 (%)	时间 (s)
A+L+F	97.45	97.45	97.58	97.33	257.83
A+L+LF	97.21	97.21	97.32	97.09	297.971
A+L+TF	97.56	97.61	97.25	97.49	312.880
A+H+F	97.68	97.68	98.03	97.33	238.667
A+H+LF	97.76	97.76	97.81	97.72	307.391
A+H+TF	98.04	98.04	98.28	97.80	314.014
A+L+H+F	97.76	97.75	98.18	97.33	495.456
A+L+H+LF	97.80	97.81	97.66	97.96	527.169
A+L+H+TF	98.08	98.07	98.20	97.96	554.737

为进一步探究不同特征子集对舍内生猪咳嗽声识别的差异，分析不同特征子集的混淆矩阵结果。由于融合架构 1 和 2 下的最优特征子集 A+TF 的识别性能优于 A+L+F、A+L+LF 和 A+L+TF 三种特征子集的识别结果，因此，仅分析其余六种特征子集的多类混淆矩阵结果。图 5-8 显示了 A+H+F、A+H+LF 和 A+H+TF 三种特征的混淆矩阵。

中国知网 https://www.cnki.net

对比图 5-8 a)-图 5-8 c)可知，A+H+F 和 A+H+LF 生猪咳嗽声的正确识别个数相同，均为 417，A+H+TF 对生猪咳嗽声识别个数增加，增至 418。针对非咳嗽声的识别中，A+H+LF 对说话声和猪叫声的正确判别数增加。这说明 A+H 添加 TF 融合后的特征子集对生猪咳嗽声的判别力更强，A+H 添加 LF 特征后对非咳嗽声中说话声和猪叫声的判别力更强。



a) A+H+F 混淆矩阵

a) Confusion matrix on A+H+F



b) A+H+LF 混淆矩阵

b) Confusion matrix on A+H+LF



c) A+H+TF 混淆矩阵

c) Confusion matrix on A+H+TF

图 5-8 融合架构 3 下的 A+H 与深度特征融合的混淆矩阵

Figure 5-8 Confusion matrix for A+H with deep features based on feature fusion architecture 3

图 5-9 显示了 A+L+H+F、A+L+H+LF 和 A+L+H+TF 三种特征子集的混淆矩阵。对比图 5-9 a)-图 5-9 b)可知，A+L+H+LF 对生猪咳嗽声、说话声和生猪叫声的正确分类数量均有所增加，整体的识别率增加。对比 5-9 b)-图 5-9 c)可知，A+L+H+TF 对咳嗽声的正确分类数量增加，非咳嗽声的正确识别个数不变。

总体来看，随着不同域下的特征种类增加，特征融合可以有效提升生猪咳嗽声的正确识别个数。同时，添加三种深度特征 F，LF，TF 均能有效增加生猪咳嗽声的正确识别个数，其中 TF 融合后识别性能最佳，可以有效表达猪舍内的生猪咳嗽声。相比于深度特征，融合视觉特征 $LBP_{12,2}$ 和 HOG-Gray 更善于区分生猪叫声和清理声等非咳嗽声。随着特征种类不断增加，生猪咳嗽声的正确判定个数增长较小并趋于平稳。

中国知网 https://www.cnki.net



a) A+L+H+F 混淆矩阵

a) Confusion matrix on A+L+H+F



b) A+L+H+LF 混淆矩阵

b) Confusion matrix on A+L+H+LF



c) A+L+H+TF 混淆矩阵

c) Confusion matrix on A+L+H+TF

图 5-9 融合架构 3 下的 A+L+H 与深度特征融合的混淆矩阵

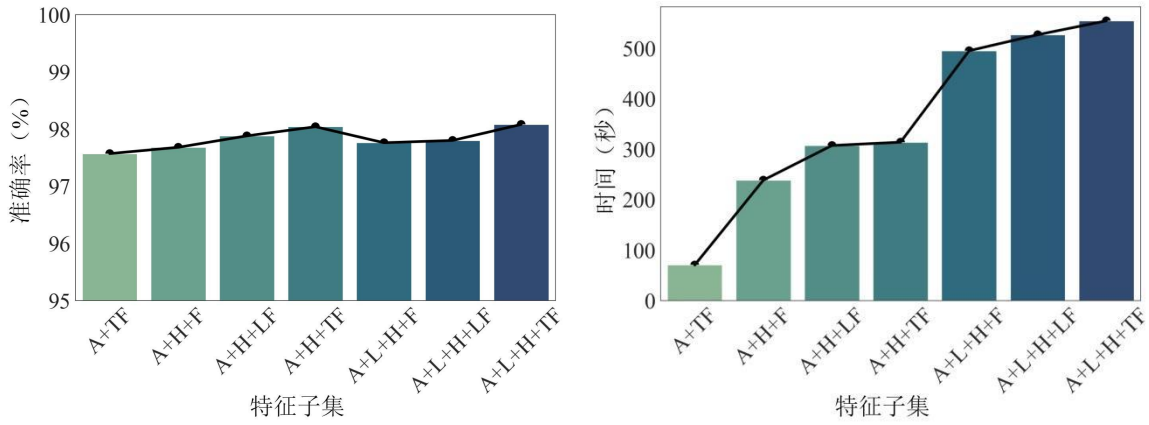
Figure 5-9 Confusion matrix for A+L+H with deep features based on feature fusion architecture 3

将融合架构 3 下的六组特征子集与融合架构 2 下的 A+TF 特征子集在生猪咳嗽声的识别性能和时间两方面进一步对比，如图 5-10 所示。

图 5-10 a)为多组融合特征子集的识别准确率。由图可知，特征融合的多样性提升了对生猪咳嗽声的识别性能，A+L+H+TF 下识别准确率为 98.08%，优于其他特征子集。相比于 A+TF，准确率提升了 0.51%。

对比图 5-10 b)可知，A+TF 和 A+L+H+TF 模型整体计算时间分别为 70.291s 和 554.737s。融合特征种类的增加导致融合后的特征子集维度也随之增加，因此，模型计算时间呈倍数增长。对比模型计算的时间，模型性能仅得到微小的提升。从识别精度和时间的双重权衡，A+TF 特征子集对生猪咳嗽声的辨识度最佳。同时，该融合特征子集的计算时间最低。因此，采用 A+TF 融合特征作为后续不平衡数据下研究的特征子集。

中国知网 https://www.cnki.net



a) 多组融合特征子集识别准确率　　b) 多组融合特征子集识别计算时间

a) Recognition accuracy of feature fusion subsets　　b) Computation time of feature fusion subsets

图 5-10 多组融合特征识别生猪咳嗽声性能与计算时间对比图

Figure 5-10 Accuracy and computational time of pig cough recognitionof multi-fusion features

5.4.3 多域特征融合在不平衡数据集下的实验结果与分析

以上研究已经对比和验证了在平衡数据集下的多种特征融合下生猪咳嗽声识别性能。由于考虑到复杂猪舍环境下声音不平衡的情况，本节将验证和讨论特征融合对不平衡比值（IR）下对生猪咳嗽声识别性能影响。基于以上特征融合的分析，选择基于声学特征和深度特征拼接融合（A+TF）后的特征子集 A-TFRs fusion 展开生猪咳嗽声非平衡数据集下的研究。

模型性能随 IR 值下降的变化程度可以反应相应输入特征的鲁棒性，因此，采用轻度 D1（IR=1.5）和 D2（IR=2.72）、中度 D3（IR=4.95）和 D4（IR=9.03）和重度数据集 D5（IR=10.10）和 D6（IR=13.26）共六组数据集，计算不同特征子集在不平衡数据集下的识别结果。

5.4.3.1 声学特征和深度特征融合在不平衡数据集下的实验对比

图 5-11 显示了声学特征和深度特征及其融合后的特征子集在不同 IR 值下的实验结果。图中包括三组特征代表：声学特征子集（Acoustic），深度特征子集（TFRs fusion）以及二者的特征融合子集（A-TFRs fusion，A-TF）。由图 5-11 中可知，随着生猪咳嗽声样本数量减少，不平衡比例（IR）逐渐增加，三种特征子集在 SVM 的识别性能均逐渐下降。

由图 5-11 a)可知，Acoustic 受不平衡比值影响最大，F1 分数由 93.26%降到 81.47%，下降了 11.79%；TFRs fusion 的 F1 分数由 92.34%降低至 82.05%，下降了 10.29%；A-TF 受不平衡比值的影响相对最小，F1 分数由 96.45%降到 90.36%，下降幅度为 6.09%。同时，可以发现数据在轻度（D1、D2）和中度不平衡比例（D3）下，Acoustic 的 F1 性能略高于 TFRs fusion。随着 IR 值增加，数据向重度不平衡倾斜时，Acoustic 的性能大幅下降，说明其不稳定性增加，易受到猪舍声音环境变化的影响，在舍内非咳嗽声大幅增加时，声学特征在多种声音的相近和重叠的复杂环境下辨识度降低。

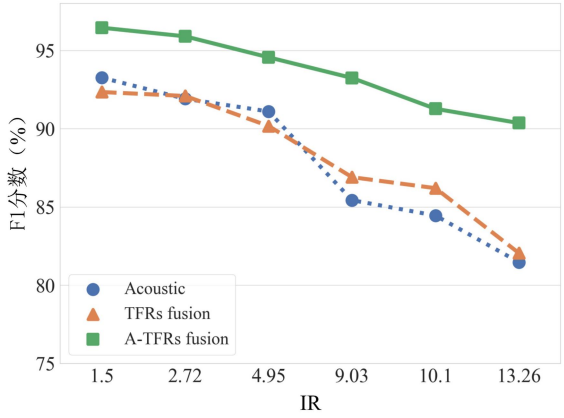
由图 5-11 b)可知，在 IR 值由小逐渐变大的情况下，A-TF 的识别结果波动最小，几何

中国知网 https://www.cnki.net

平均值由 97.09%下降到 93.29%，下降了 3.8%；Acoustic 的几何平均值由 94.34%下降到 88.39%，5.95%；TFRs fusion 的几何平均值由 94.03%下降至 87.35%，下降了 6.68。Acoustic 和 TFRs fusion 随着 IR 值增加均有所下降，Acoustic 下降幅度小于 TFRs fusion，这可能是由于 Acoustic 对非咳嗽声的判别能力较强，在类别不平衡时，提升了非咳嗽声的正确识别率，进而提升了几何平均值的结果。

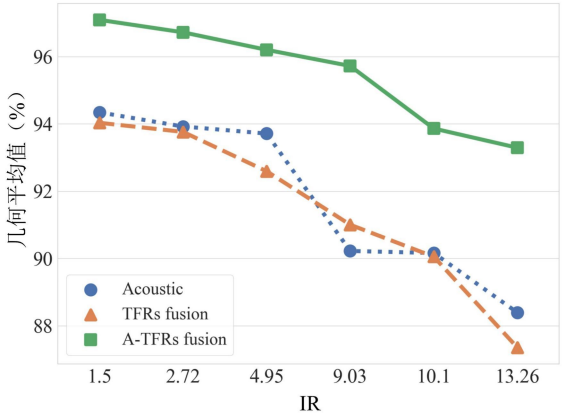
在图 5-11 c)中，Acoustic 的精准率指标伴随 IR 比值增加剧烈下降，由 94.19%下降到 83.93%，下降了 10.26%，这一结果也进一步说明了 Acoustic 在 IR 值增大时，对生猪咳嗽声的正确识别能力大幅下降。相比 Acoustic，TFRs fusion 对生猪咳嗽声的精准率更高。A+TF 的精准度由 96.80%下降至 93.41%，下降了 3.39%，优于其他特征子集。

在图 5-11 d)中，Acoustic、TFRs fusion 和 A-TF 的召回率分别下降了 14.36%、14.32%和 9.36%。说明轻度向重度不平衡程度加深时，生猪咳嗽声被错误分类成非咳嗽声的数量增加。A-TF 仍具有较强的辨识度。



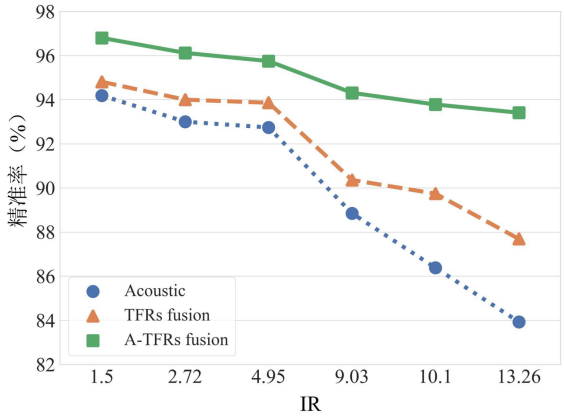
a) 三组特征子集 F1 结果

a) F1 score of three feature sets



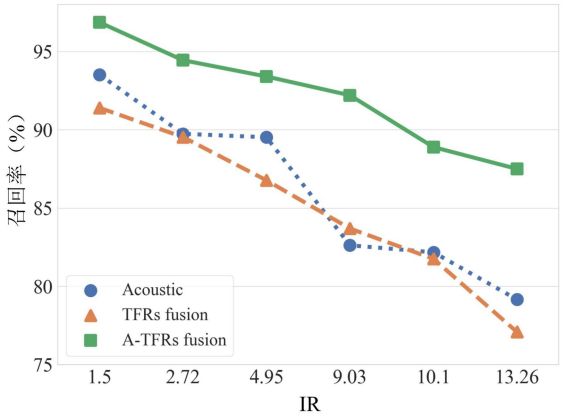
b) 三组特征子集几何平均准确率结果

b) G-mean result of three feature sets



c) 三组特征子集精准率结果

c) Precision result of three feature sets



d) 三组特征子集召回率结果

d) Recall result of three feature sets

图 5-11 声学特征和深度特征及其融合后的特征子集在不同 IR 值下的实验结果

Figure 5-11 The results of pig cough recognition with three feature sets based on different IR ratio

中国知网 https://www.cnki.net

综合比较可知，尽管 A-TF 的融合特征整体上逐渐下降，伴随不平衡程度加深但其稳定性这一优势随之凸显。A-TF 融合特征的鲁棒性更强，这说明声学特征和深度特征融合对抗不平衡数据集下更具有稳健性。在使用单一分类器的情况下，融合特征可以有效的提高在舍内咳嗽声比例较小的情况下识别生猪咳嗽声的精度。同时，基于 A-TF 特征融合，内嵌交叉验证中的内循环利用 GridSearch 选择 SVM 的最优核函数、C 和 gamma。经六组不同 IR 值下的计算，获得三种最优模型参数组合，分别是 SVM1（kernel='rbf', C=100, gamma=0.1）、SVM2（kernel='rbf', C=100, gamma=0.01）以及 SVM3（kernel='rbf', C=100, gamma=0.001）。

5.4.3.2 不同评估方法在不平衡数据集下的实验对比与分析

尽管为提升不平衡数据下的识别问题提供了特征层面的优化，但选择合适的性能评估方法也是后续从数据及算法层面研究的基础和关键。为此，进一步对比和计算 ROC-AUC 和 PR-AUC 两种评价方式。

ROC 曲线的形状与曲线下的面积有直接关系，即曲线下面积越大越贴近曲线左上角。X 轴代表假阳率，Y 轴代表真阳率。ROC-AUC 曲线显示生猪咳嗽声正确分类的比例（真阳率）与错误识别比例（假阳率）的变化过程。

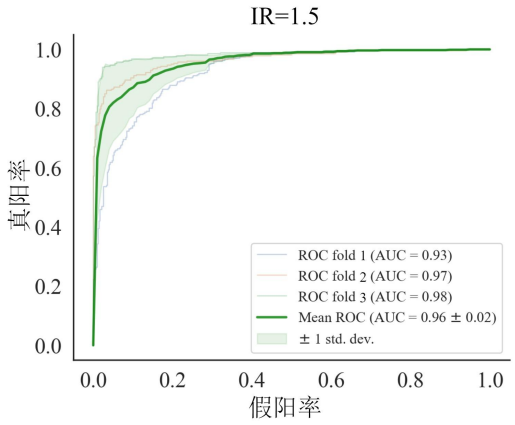
基于 A-TF 特征子集的不平衡数据集下生猪咳嗽声识别的 ROC-AUC 曲线如图 5-12 所示。图 5-12 a)-图 5-12 f)的六张子图分别由六种不同 IR 数据集下采用 3 折交叉验证下绘制。

整体上来说，ROC-AUC 曲线下面积随着 IR 值增加逐渐降低，标准差逐渐增大。由图 5-12 a)-图 5-12 e)可知，在 IR 为 1.5 时，生猪咳嗽声的 ROC-AUC 的值为 0.96±0.02。随着 IR 值增加至 10.10，生猪咳嗽声的 ROC-AUC 的值降低至 0.92±0.07。对比图 5-12 e)和 5-12 f)中的曲线变化可以发现，ROC-AUC 的值保持在 0.92±0.07 和 0.92±0.04。

当咳嗽声阳性样本与非咳嗽声阴性样本比例偏差较大时，数据比例呈现重度不平衡时，ROC 曲线可能对声音特征在算法上的性能表现过于乐观。当 IR 值不断增加，本实验中的咳嗽声数量减少而非咳嗽声样本的占比增加，此时，分类器倾向于多数类样本，进而增加了非咳嗽声识别率。当真阴性样本数增加，假阳性检测率随之降低。因此，当真阴性样本较多时导致 ROC-AUC 曲线下面积增大，从而引起对特征表达能力的误解。图 5-12 e)和 5-12 f)中 ROC-AUC 的值相近的另一原因，可能是由于咳嗽声样本数降低且分层交叉验证中每次样本分割时样本顺序被打乱，同时，内嵌交叉验证中的内循环引起分类器参数的随机性。声音样本的差异性以及分类器参数的不稳定共同导致了不同交叉验证次数下的实验结果。

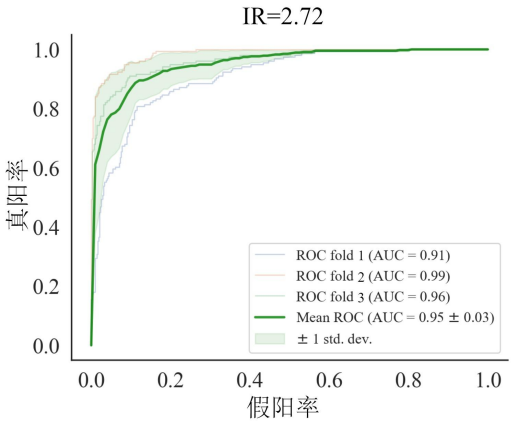
对比重度不平衡数据集 D5（IR=10.10）和 D6（IR=13.26）下 A-TF 融合特征的混淆矩阵可进一步解释图 5-12 e)和 5-12 f)中的曲线变化。混淆矩阵结果在舍内声音五分类任务上如图 5-13 所示。对比 5-13 a)和 5-13 b)可知，随着 IR 值增加，生猪咳嗽声被误判为生猪叫声的个数增加。同时，在其他非咳嗽声中，生猪叫声的正确识别个数由 317 个降低至 312 个，生猪叫声被误判成清理声的个数也随之增加。同时，生猪叫声也和生猪咳嗽声发生了混淆。对比两组 IR 值下的识别结果可知，除了水声与咳嗽声数据间的区分度较大，其他类型的声音数据均存在一定的错分情况。

中国知网 https://www.cnki.net



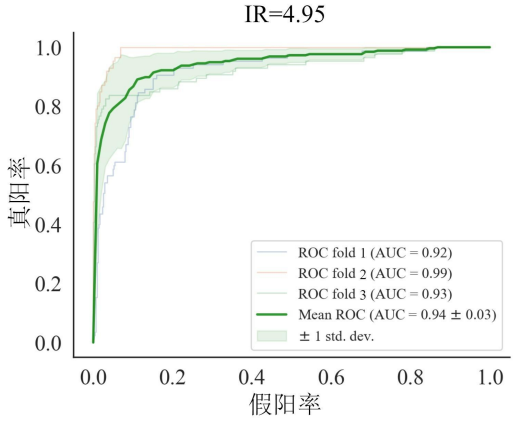
a) 数据集 D1 下的 ROC-AUC 结果

a) ROC-AUC results of dataset D1



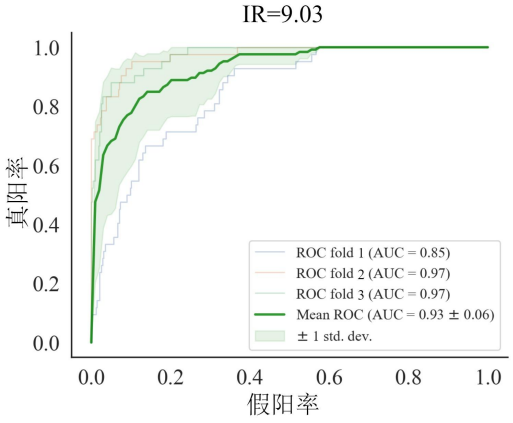
b) 数据集 D2 下的 ROC-AUC 结果

b) ROC-AUC results of dataset D2



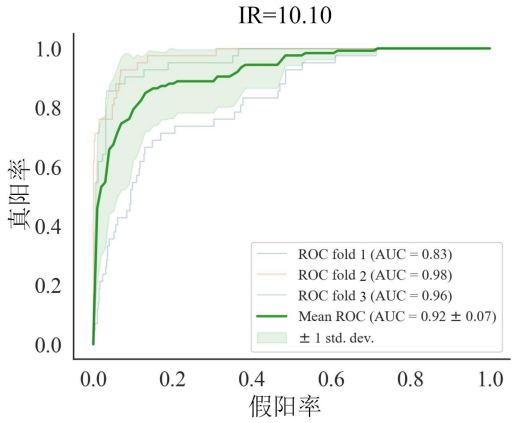
c) 数据集 D3 下的 ROC-AUC 结果

c) ROC-AUC results of dataset D3



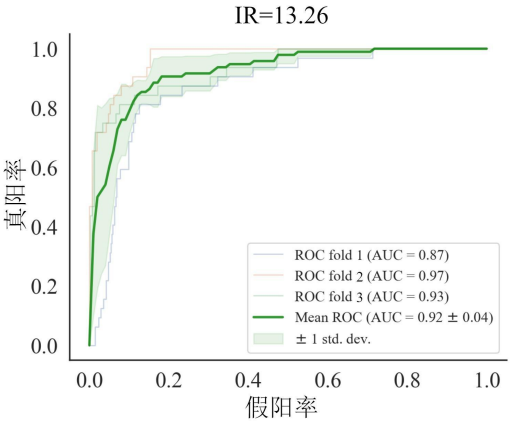
d) 数据集 D4 下的 ROC-AUC 结果

d) ROC-AUC results of dataset D4



e) 数据集 D5 下的 ROC-AUC

e) ROC-AUC results of dataset D5



f) 数据集 D6 下的 ROC-AUC

f) ROC-AUC results of dataset D6

图 5-12 基于声学特征和深度特征的融合特征在不同 IR 值下的操作曲线面积

Figure 5-12 ROC curves of A-TFRs features based on different IR ratio

中国知网 https://www.cnki.net



a) 数据集 D5 的混淆矩阵　　b) 数据集 D6 的混淆矩阵

a) Confusion matrix on dataset D5　　b) Confusion matrix on dataset D6

图 5-13 两组 IR 值下的混淆矩阵

Figure 5-13 Confusion matrix of A-TFRs features based on two IR ratios

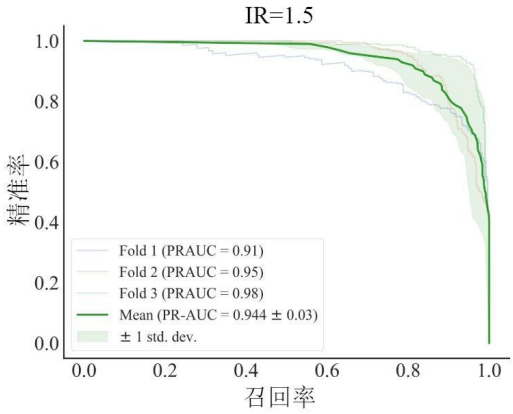
相比于 ROC-AUC，精准率（Precision）和召回率（Recall）构成的精准召回（PR）曲线常被应用于不平衡数据集下的二分类研究中。与 ROC-AUC 不同，PR-AUC 曲线图清晰的表达了分类器对不平衡数据集的敏感性，并对分类器实际性能进行准确直观的解释。

基于声学特征和深度特征的融合特征在不同 IR 值下的精准召回曲线如图 5-14 所示。图 5-14 a)-图 5-14 f)的六张子图分别由六种不同 IR 数据集下采用 3 折交叉验证下绘制。PR 曲线的形状与曲线下的面积有明显的直接关系，即曲线下面积越大越贴近曲线右上角。整体上来说，PR-AUC 曲线下面积随着 IR 值增加逐渐降低，标准差逐渐增大。由图 5-14 a)可知，在 IR 为 1.5 时，生猪咳嗽声的 PR-AUC 的值为 0.94±0.03。随着 IR 值增加至 13.26，如图 5-14 f)生猪咳嗽声的 PR-AUC 的值将至 0.80±0.09。

PR 曲线显示了识别精度和召回率之间的权衡。精准度的高低取决于非咳嗽声被错误分类成生猪咳嗽声的样本数量，召回率的高低取决于表示生猪咳嗽声被错误分类成非咳嗽声的样本数量。当类别非常不平衡时，PR 曲线是衡量预测性能高低的有效指标。

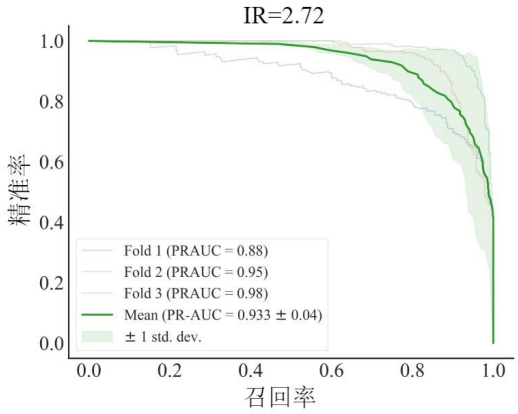
对比图 5-13 和 5-14 可知，ROC 曲线和 PR 曲线的较大差异，是由于在相同算法和特征的情况下，非咳嗽声数量远高于咳嗽声数量。此时，ROC 曲线的假阳性率变化较小，而 PR 曲线可以捕捉到大量非咳嗽声增加对算法性能的影响。因此，面对生猪舍内不平衡数据下的识别任务，相比于 ROC 曲线下更加乐观的结果，PR-AUC 曲线能够提供更加差异化的性能表示。

中国知网 https://www.cnki.net



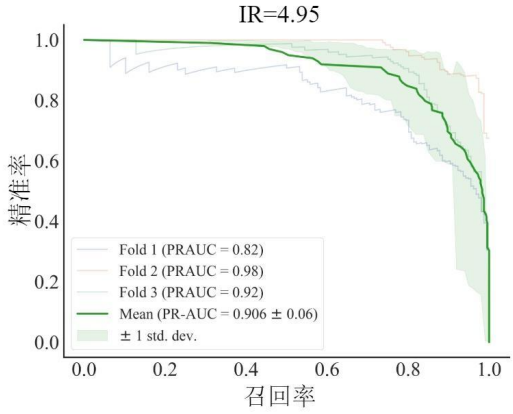
a) 数据集 D1 下的 PR-AUC 结果

a) PR-AUC results of dataset D1



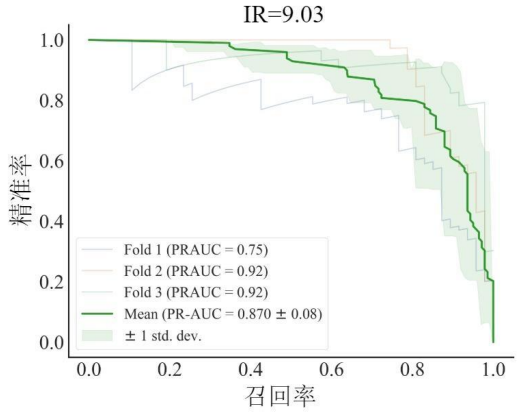
b) 数据集 D2 下的 PR-AUC 结果

b) PR-AUC results of dataset D2



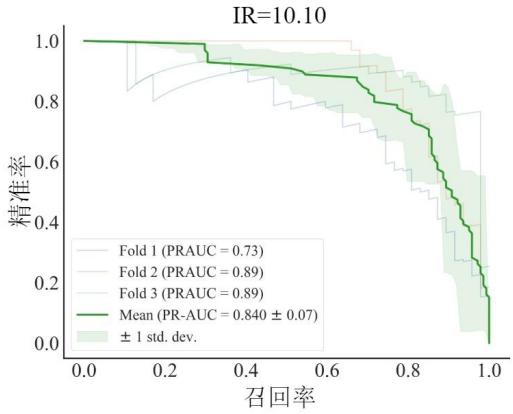
c) 数据集 D3 下的 PR-AUC 结果

c) PR-AUC results of dataset D3



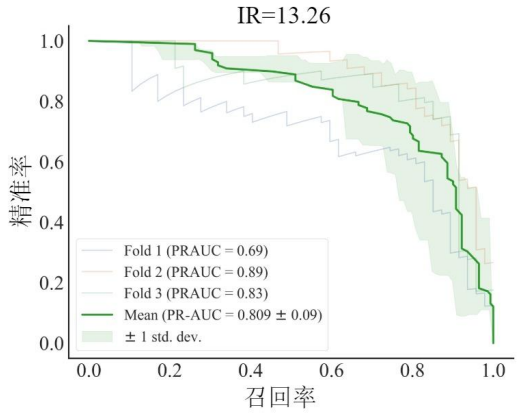
d) 数据集 D4 下的 PR-AUC 结果

d) PR-AUC results of dataset D4



e) 数据集 D5 下的 PR-AUC

e) PR-AUC results of dataset D5



f) 数据集 D6 下的 PR-AUC

f) PR-AUC results of dataset D6

图 5-14 基于声学特征和深度特征的融合特征在不同 IR 值下的精准召回曲线

Figure 5-14 Precision and Recall curves of A-TFRs features based on different IR ratio

此外，曲线下的面积 AUC 也是用作判定识别算法在特征空间表现的度量方式。图 5-15 对比了 ROC-AUC 和 PR-AUC 随着 IR 值变化的情况。对比不同 IR 值下的 ROC-AUC，A-TF

中国知网 https://www.cnki.net

融合特征的识别性能似乎受 IR 值增加影响较小。然而，在 PR-AUC 的对比下，可以直观的发现随着生猪咳嗽声的样本数降低，A-TF 融合特征在单一 SVM 分类器下的性能大幅降低。PR-AUC 在不平衡数据问题上的凸显了识别算法的敏感性。由此，进一步判定在特征层面改进的基础上，单一机器学习算法在舍内声音不平衡情况下提升识别性能具有一定的局限性。为此，后续进一步验证混合集成算法对不平衡数据集下识别精度的影响。

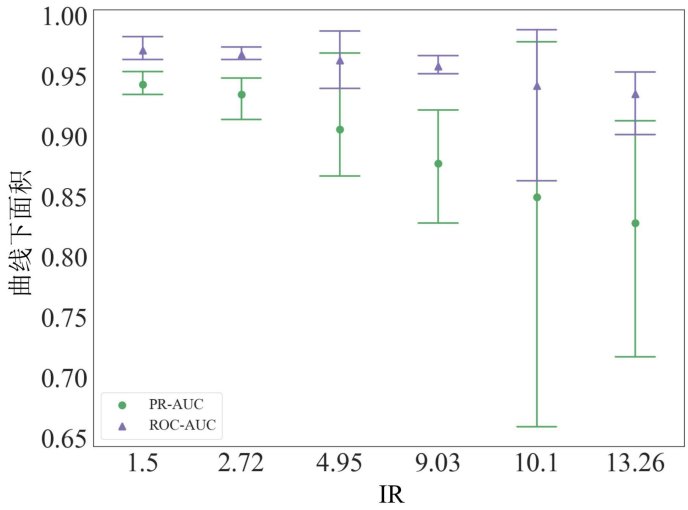


图 5-15 基于不同 IR 值下的接收者操作特征曲线面积和精度-召回曲线下面积对比

Figure 5-15 Comparision of ROC-AUC and PR-AUC based on different IR

5.4.4 混合集成算法在不平衡数据集下的实验结果与分析

实验分成两部分进行：实验一讨论 SSLRB 混合集成算法中不同参数对模型性能的影响；实验二将 SSLRB 混合集成算法与上采样、下采样和组合上下采样三类不同平衡化算法进行对比，分析不平衡数据集下生猪咳嗽声识别性能。

5.4.4.1 SSLRB 混合集成算法参数对模型性能的影响

本节根据 5.3 节提出的 SSLRB 集成算法，选择六组不同 IR 比值下的数据集，讨论模型 SSLRB 算法下的参数 C 的以及元分类器个数的实验性能。

（1）SSLRB 算法下的参数 C 对生猪咳嗽声识别的影响

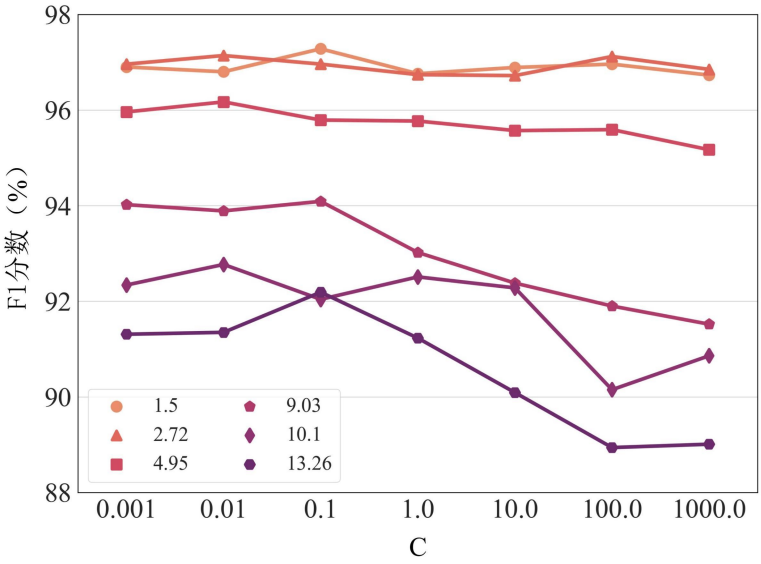
图 5-16 为内置 LR 个数为 3 时，不同参数 C 在多组 IR 值下的 SSLRB 生猪咳嗽声识别性能，图 5-16 a)和图 5-16 b)分别为生猪咳嗽声识别的 F1 分数和 PR-AUC 的值。实验中 C 的范围取{0.001,0.01,0.1,1,10,100,1000}，以对比分析 C 的不同设置对算法识别性能的影响。

由图 5-16 a)可知，在 IR 为 1.5、9.03、13.26 时，生猪咳嗽声的 F1 结果在参数 C 为 0.1 时达到最佳，分别为 97.28%、94.09%和 92.19%。在 IR 值为 2.72、4.95 和 10.10 时，生猪咳嗽声的 F1 结果在参数 C 为 0.01 时达到最佳，分别为 97.14%、96.17%和 92.77%。当 IR 值由 1.5 增大至 13.26，最佳参数下的 F1 结果降低了 5.09%。

由图 5-16 b)可知，随着 IR 值不断增大，F1 的结果随之降低。在 IR 为 1.5、9.03、13.26 时，生猪咳嗽声的 PR-AUC 的结果在参数 C 为 0.1 时达到最佳，分别为 95.43%、89.42%和

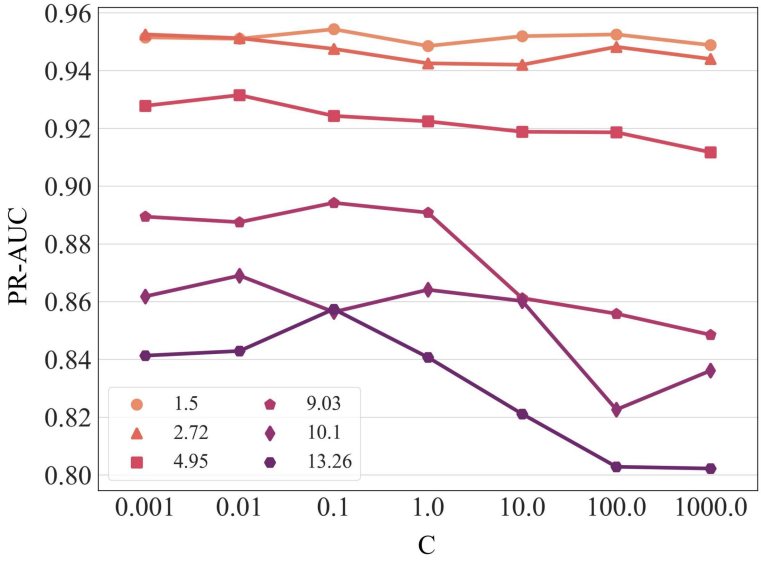
中国知网 https://www.cnki.net

85.74%。在 IR 值为 2.72、4.95 和 10.10 时，生猪咳嗽声的 F1 结果在参数 C 为 0.01 时达到最佳，分别为 95.12%、93.15%和 86.90%。当 IR 值由 1.5 增大至 13.26，最佳参数下的 PR-AUC 结果降低了 9.69%。



a) 不同参数 C 下的 F1 结果

a) F-score of different C values



b) 不同参数 C 下的 PR-AUC 结果

b) PR-AUC of different C values

图 5-16 不同参数 C 下的 SSLRB 的生猪咳嗽声识别性能

Figure 5-16 Recognition performance of SSLRB based on different parameter C

对比图 5-16 a)和图 5-10 b)可知，在 IR 值为 1.5 和 2.72 的两组轻度不平衡数据集下，参数 C 的变化对 F1 和 PR-AUC 的结果影响较小。相比于 F1 的结果，PR-AUC 对 C 的变化敏感度更高。当数据呈现中度和重度不平衡时，整体上而言，随着参数 C 的增大，模型识别

中国知网 https://www.cnki.net

结果均有所降低。当 C 处于 0.1 和 0.01 这两种情况下，模型识别结果优于其他参数。为此，进一步查看两种参数下的数据分布情况。

图 5-17 显示了参数 C 为 0.01 和 0.1 时对应的 F1 和 PR-AUC 的数据分布，并与六组不同 IR 比值数据集下的结果进行比较。图中显示了不同类别的数据散点图，图中呈现的数据点为每组数据集下运行的 5 次 3 折交叉验证下 F1 和 PR-AUC 的平均值。由图可知，与预期一致的是，IR 值不断增大时，F1（三角形）和 PR-AUC（圆形）的值均随之下降。当不平衡比值达到中度和严重不平衡时，二者下降幅度增大，其中 PR-AUC 受 IR 值影响更大。在参数 C 为 0.1（紫色）和 0.01（黄色）的数据分布上可以发现，在 IR 值较低时，即轻度不平衡情况下，二者分布均较为集中，当 IR 达到中度和重度不平衡时，C 为 0.01 时结果相对分布离散，相比之下，参数 C 为 0.1 时模型结果更加稳定。因此，将参数 C 固定为 0.1 作为后续实验模型的固定参数。

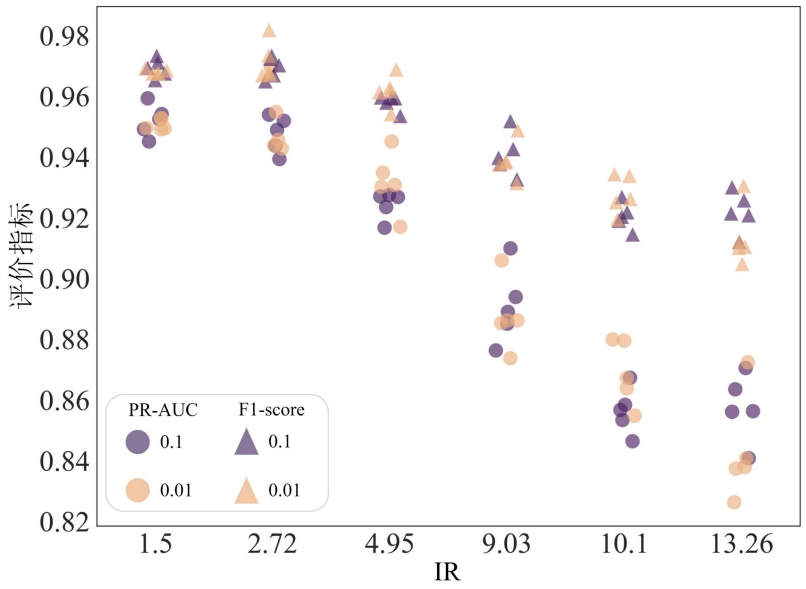


图 5-17 不同 IR 下的 SSLRB 的生猪咳嗽声识别 F1 和 PRAUC 值

Figure 5-17 Strip plot showing variations of the F1-score and PR-AUC by different IR values

（2）SSLRB 算法下的元分类器个数 M 对生猪咳嗽声识别的影响

本文实验过程中，在集成元学习模块中内置 LR 的个数决定了决策模块的规模，规模过小会降低模型的识别结果，模型过大对应增加了时间成本。因此，为了得到 SSLRB 模型中最优的元分类器个数 M，实验过程中，M 取值范围为{2,3,4,5,6,10,15,20,30,40,50}。图 5-18 显示了在数据重度不平衡 IR 比值在 13.26 的情况下，不同元分类器个数 M 对模型分类结果的性能比较。由图可知，在 M 取 3 时，模型的 F1 分数和 PRAUC 值达到最高，分别为 0.9219 和 0.8574。随着 M 个数的增加，模型的性能轻微下降并趋于平稳。这可能是由于 LR 的模型复杂度较低，导致较低的决策力，因此，模型个数增加对模型性能提升是有限的。这一结果表明 SSLRB 模型的整体性能对内置元分类器个数并不敏感，这表明可以通过使用少量分类器数量降低模型复杂度。因此，后续实验中，将 M 固定在 3。

中国知网 https://www.cnki.net

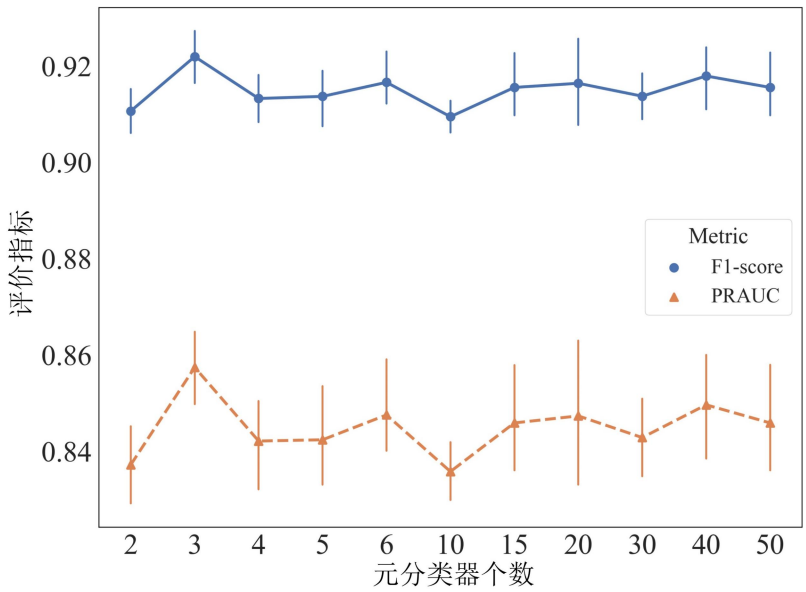


图 5-18 SSLRB 架构中 LR 元分类器内置个数的分类性能

Figure 5-18 F1-score and PRAUC of SSLRB with different M in LR classifier

5.4.4.2 SSLRB 混合集成算法与不同平衡化方法识别性能对比

为了充分对比和验证本文提出的 SSLRB 方法在不平衡数据集的分类性能，对比了 A-TF 未采用平衡化算法（Baseline）以及三大类数据层面平衡化方法作为对比，包括基于下采样算法：随机下采样（RUS）、NearMiss、ClusterCen 和 InstanceHardness；上采样算法：ROS、ADASYN、SMOTE、BorderlineSMOTE；以及组合上下采样的方法：SMOTEEN 和 SMOTETomek，这几种采样算法均采用默认值。

实验基于 3×3 折分层内嵌交叉验证，最终评价指标取每次迭代结果的平均值。在实验过程中，为反映出在平衡训练集下的最优模型应用到不平衡测试集的性能，本节将不同数据层面采样算法应用于每次交叉验证的训练集中，而非全部数据集。除此之外，本节将不同算法应用于六组不同 IR 的数据集上，来进一步对比不平衡比值的影响。

表 5-8 为 SSLRB 方法及其他对比方法在不平衡数据集上的 F1 的结果。SSLRB 方法有效提升了 A-TF 特征子集在单一 SVM 下的生猪咳嗽声识别性能。对比 Baseline 的 F1 分数可知，在六组 IR 值下分别提高了 0.84%（97.28%-96.44%）、1.1%（96.96%-95.88%）、1.3%（95.79%-94.49%）、0.86%（94.08%-93.22%）、1.51%（92.68%-91.17%）、1.85%（92.19%-90.34%）。

采用上采样算法识别生猪咳嗽声的 F1 分数均有所增加。在 IR 值为 1.5 时，ADASYN 的 F1 结果为 96.88%，仅次于 ROS 上采样算法（96.93%）；IR 增加至 2.72 时，ADASYN 优于 ROS，取得的最佳结果，二者 F1 分别为 96.96%和 96.85%；IR 值在 4.95 和 13.26 时，BorderlineSMOTE 取得了最优结果，F1 分别达到 96.03%和 91.60%；IR 值在 4.9.03 和 10.10 时，ADASYN 的 F1 优于其他上采样算法，分别达到 94.95%和 92.49%。

随着 IR 值的增加，采用下采样算法识别生猪咳嗽声的 F1 结果均有不同程度的下降。

中国知网 https://www.cnki.net

RUS、NearMiss、ClusterCen 和 InstanceHardness 四种下采样算法对比 Baseline，在 IR 值为 1.5 时，分别下降了 0.28%、0.10%、0.36%和 2.37%；在 IR 值为 13.26 时，分别下降了 32.60%、39.14%、27.39%和 36.23%。在组合平衡化算法中，SMOTETomek 在不同 IR 值下均优于 SMOTEEN；对比 Baseline，除了 IR 值为 13.26 时，SMOTETomek 的 F1 结果均得到了提升。

表 5-8 SSLRB 方法及其他对比方法在不同 IR 数据集上的 F1 分数（%）

Table 5-8 Comparision with SSLRB and other sampling methods of F1 score of pig cough recognition based on different IR dataset

算法类别	Algorithm	IR1.5	IR2.72	IR4.95	IR9.03	IR10.10	IR13.26
None	Baseline	96.44	95.88	94.49	93.22	91.17	90.34
下采样	RUS	96.16	94.48	91.48	74.06	67.63	57.74
	NearMiss	96.30	94.02	90.88	73.78	60.81	51.20
	ClusterCen	96.08	96.09	90.34	73.64	71.47	62.95
	InstanceHardness	94.07	89.77	83.91	65.44	55.35	54.11
上采样	ROS	96.93	96.85	95.14	93.94	91.54	90.58
	ADASYN	96.88	96.96	95.35	94.95	92.49	91.48
	SMOTE	96.67	96.75	95.87	93.75	92.35	90.46
	BorderlineSMOTE	96.80	96.69	96.03	93.52	91.91	91.60
组合采样	SMOTEEN	95.06	95.83	94.04	90.61	89.29	88.62
	SMOTETomek	96.77	97.31	95.32	95.56	91.99	91.46
混合集成	SSLRB	97.28	96.96	95.79	94.08	92.68	92.19

表 5-9 为 SSLRB 方法及其他对比方法在不平衡数据集上 PRAUC 的值。对比 Baseline 的 PR-AUC 值可知，随着 IR 值逐渐增大，PR-AUC 分别提高了 0.91%（0.9502-0.9429）、1.27%（0.9475-0.9348）、1.88%（0.9243-0.9055）、1.33%（0.8908-0.8775）、1.77%（0.8673-0.8496）、2.92%（0.8574-0.8282）。

采用上采样算法识别生猪咳嗽声 PR-AUC 的结果均有所增加。在 IR 值为 1.5、2.72、9.03 和 10.10 时，ADASYN 的识别结果优于其他上采样算法，PR-AUC 的结果分别为 95.22%、94.95%、90.66%和 86.64%。在 IR 值为 4.95 和 13.26 时，BorderlineSMOTE 取得了最优结果，PR-AUC 分别达到 93.02%和 84.88%。对比 Baseline 的结果，ADASYN 分别提高了 0.93%、1.47%、2.91%和 1.68%；BorderlineSMOTE 分别提高了 2.47%和 2.06%。

随着 IR 值的增加，采用下采样算法识别生猪咳嗽声的 PR-AUC 结果的下降幅度增大。其中，InstanceHardnes 识别性能最低；NearMiss 在 IR 值为 1.50 和 9.03 时，优于其他平衡化算法；RUS 在 IR 值为 4.95 时达到最佳，PR-AUC 为 0.8458。IR 为 2.72、10.10 和 13.26 时，ClusterCen 优于其他平衡化算法。在组合平衡化算法中，SMOTETomek 在不同 IR 值下均优于 SMOTEEN；对比 Baseline，SMOTETomek 在六组 IR 值数据集下 PR-AUC 的结果均得到了提升，分别提升了 0.73%、2.09%、1.27%、4%、0.72%、1.69%。

中国知网 https://www.cnki.net

表 5-9 SSLRB 方法及其他对比方法在不同 IR 数据集上的 PR-AUC 值

Table 5-9 Comparision SSLRB with other sampling methods of PRAUC of pig cough recognition based on different IR dataset

算法类别	Algorithm	IR1.5	IR2.72	IR4.95	IR9.03	IR10.10	IR13.26
None	Baseline	0.9429	0.9348	0.9055	0.8775	0.8496	0.8282
下采样	RUS	0.9371	0.9020	0.8458	0.5869	0.5079	0.4029
	NearMiss	0.9428	0.8956	0.8370	0.5946	0.4308	0.3346
	ClusterCen	0.9361	0.9290	0.8265	0.5807	0.5504	0.4355
	InstanceHardness	0.8954	0.8171	0.7265	0.4875	0.3819	0.3695
上采样	ROS	0.9562	0.9433	0.9180	0.9182	0.8719	0.8506
	ADASYN	0.9508	0.9479	0.9159	0.8887	0.8489	0.8308
	SMOTE	0.9522	0.9495	0.9188	0.9066	0.8664	0.8459
	BorderlineSMOTE	0.9482	0.9456	0.9283	0.8852	0.8628	0.8281
组合采样	SMOTEEN	0.9496	0.9462	0.9302	0.8822	0.8551	0.8488
	SMOTETomek	0.9200	0.9281	0.8911	0.8295	0.8060	0.7943
混合集成	SSLRB	0.9502	0.9557	0.9182	0.9175	0.8568	0.8451

综合对比表 5-8 和表 5-9 的结果可知，对比原始 A-TF 特征融合下的不平衡数据集（Baseline）的分类结果，上采样方法对生猪咳嗽声识别均有所提高，有利于缓解不平衡带来的负面性能，从而提升分类性能。上采样算法之间性能差异较小，无明显的优劣势。上采样结果相近，这是由于本文的不同 IR 值下的数据集是以确定非咳嗽声样本为基础，降低咳嗽声样本划分而成，这种情况下导致分层交叉验证下每组实验中非咳嗽声数量相近，进而得到相近的实验结果。鉴于上采样算法受制于多数类样本的数量，在复杂的猪场声音环境下，非咳嗽声样本的多样性和复杂性将成为上采样算法在咳嗽声识别性能的下降的关键因素之一。下采样算法不适合小基数的不平衡数据集，较差的实验结果是由于小样本数据的下采样直接导致了训练模型的极度过拟合状态，因而很难实现有效的识别。组合采样通过同时使用上采样和下采样可以获得比单一使用上采样或下采样更好的性能，但提升不明显。所有方法中，本章提出的 SSLRB 集成算法不同等级的数据集中均获得了相对更好的分类性能。SSLRB 优于上述方法的主要原因是 SSLRB 有效地结合了数据抽样、集成学习和逻辑回归。每个弱学习者的训练样本、超参数和特征都存在一定的差异性和多样性，充分利用各自的特性，集成学习的识别效果得到了一定的提高。

5.5 本章小结

本章主要面向不平衡数据集下的生猪咳嗽声识别问题，基于从商业猪舍中的生猪咳嗽声与非咳嗽声中提取声音的声学特征和时频图特征，通过将这两类声音特征进行不同融合策略的实验分析，并引入多分类器 SSLRB 集成学习以解决单一算法的不足，充分挖掘不同算法的优势，以提升不平衡数据集下的目标咳嗽声的识别精度。本章的主要实验结论如下：

中国知网 https://www.cnki.net

（1）提出了基于声学特征和时频图特征融合的多特征融合方法。现有的单一的声学特征或时频图特征不能充分满足对猪舍内复杂声音中高精度提取生猪咳嗽声的需求。通过对特征种类间的差异性表达，充分提取代表性的声音特征，在声学特征和时频图特征的多特征融合策略中，实验证明多组声学特征和时频图特征融合均有效的提升平衡数据集下的生猪咳嗽声识别准确度；同时，不同维度下的声音特征表达对生猪咳嗽声识别具有显著影响。

（2）探索了基于声学特征和深度特征（A-TF）的融合特征子集。本文提出 A-TF 融合特征在不平衡数据集比值 IR 增加的情况下，显示出较强的鲁棒性。相比于单一种类的特征融合，A-TF 融合特征降低了数据不平衡对声音特征的敏感度，进而提高了模型的识别性能。通过对比 ROC-AUC 和 PR-AUC 在生猪咳嗽声不平衡数据集下的识别结果对比分析，得出 PR-AUC 更适用于在重度不平衡比值下，作为模型识别结果的评价指标。

（3）提出了 SSLRB 集成判别算法。不同分类器在对特征判别性能上存在一定差异，通过构建同构支持向量机 SVM 的堆叠模型，并采用基于集成逻辑回归 LR 进行最终决策。进而在不平衡数据比值增加时，有效选择分类器间的判别优势进而提升模型的识别精度，抵消了不平衡数据集带来的负面影响。同时，结果显示针对现有的数据层面的采样算法，SSLRB 模型具有更强的鲁棒性和稳定性。

中国知网 https://www.cnki.net

6 总结与展望

6.1 结论

本研究结合音频分析技术，获取了商业猪舍内不同类别的声音数据，构建了猪舍内多组音频数据集，展开了平衡数据集与不平衡数据集下的生猪咳嗽声识别相关研究。根据不同域下声音特征的特质和优势，以及不同特征间的差异性及互补性，实现了基于传统声学特征融合、时频图特征融合、以及多域特征融合的生猪咳嗽声识别。论文的主要结论如下：

（1）针对商业猪舍内声音特征提取不充分的问题，研究了基于传统声学特征融合的生猪咳嗽声识别。引入 XGBoost-SHAP 和 XGBoost-RFECV 方法对猪舍内时域、频域和倒谱域的传统声学特征进行特征解释和选择，构建了以时域、频域以及倒谱域融合后的声学特征子集（Acoustic）。结果表明，时域特征和倒谱域特征比频域特征在生猪咳嗽声识别中更具有影响力。其中，梅尔频率倒谱系数（MFCC）对提高生猪咳嗽声识别精度贡献度最高，其次是时域特征下的均方根能量，频谱质心影响力最低。该声学特征子集能够充分体现不同域下的特征信息，结合 SVM 在咳嗽声与非咳嗽声平衡数据集下的识别准确率为 94.46%。相比以往经验设定的 20 维 MFCC 和 13 维 MFCC，分别高出 0.63%和 1.14%，相比单一域下的 MFCC 特征，Acoustic 特征子集降低了对生猪舍内其他声音的误判率，表明该特征子集可以更为准确地检测出复杂背景下的非咳嗽声，进而提升模型的整体识别精度。

（2）根据时频图在时间和频率双重维度上信息表达的紧凑性和平稳性，研究了基于时频图特征融合的生猪咳嗽声识别，构建了短时傅里叶变换和常数 Q 变换两种时频图，并在时频图基础上分别提取视觉特征和深度特征。实验结果表明，相比于短时傅里叶变换，常数 Q 变换对生猪咳嗽声的表达能力更强。在多通道图像下融合方向梯度直方图特征，对生猪咳嗽声识别准确率达 93.98%，识别性能优于不同分辨率下的局部二值特征。基于浅层卷积神经网络的生猪咳嗽声识别准确率为 92.56%，优于 VGG16、VGG19 和 Resnet152 三种深度卷积神经网络，且模型计算时间远低于深度卷积神经网络，更适用于猪舍内少样本数据集下的生猪咳嗽声识别。与单输入谱图的特征层融合方法相比，双谱图深度特征融合方法对生猪咳嗽声识别性能更好，准确率达 94.51%，能够有效捕捉更具有辨识度的舍内声音特征。

（3）依据声学特征与时频图特征的互补性，结合多域特征的组合策略，提出了声学和时频图特征的融合方法。研究发现，声学特征与双谱图深度特征（Acoustic-TFRs fusion，A-TF）结合拼接融合方式识别生猪咳嗽声的准确率达到 97.57%，且模型耗时最短，表明该融合子集增强了舍内声音特征的表达能力，显著提高了生猪咳嗽声的识别精度。其次，将声学特征子集、双谱图深度特征以及融合后的 A-TF 子集在六组不平衡数据集上进行识别性能的对比分析。结果显示随着不平衡等级加深，A-TF 特征在六组不平衡数据集下均取得了最佳识别结果。尤其是在重度不平衡下，A-TF 的 F1 分数达到 90.36%，比声学特征和双谱图深度特征分别高出 8.89%和 8.31%。表明 A-TF 融合特征在数据倾斜程度加深的情况下显示出较强的鲁棒性，为猪舍内数据不平衡问题的研究提供了技术支撑。

（4）提出了一种混合集成学习的生猪咳嗽声识别算法。该方法设计了差异化的多层基

中国知网 https://www.cnki.net

分类器组合，并对基分类器的输出结果进行二次采样和最终决策。在六组不平衡数据集上进行对比实验，结果显示，对比单一的 SVM 的识别性能，该方法在六组不平衡数据集下的 F1 分数均有所提升，分别提高了 0.84%（97.28%-96.44%）、1.1%（96.96%-95.88%）、1.3%（95.79%-94.49%）、0.86%（94.08%-93.22%）、1.51%（92.68%-91.17%）、1.85%（92.19%-90.34%）。表明该方法可以克服单一算法的识别局限性，充分挖掘混合算法的优势，有效提高了不平衡数据集下生猪咳嗽声识别性能。

6.2 主要创新点

（1）针对特征信息挖掘不充分的问题，构建了一种卷积神经网络作为特征提取模型，并结合该模型挖掘时频图下的深度特征，提出了基于双谱图深度特征融合方法。该方法能够有效捕捉猪舍内的声音特征，提高生猪咳嗽声的辨识度。

（2）针对舍内声音缺乏有效特征融合的问题，构建了以时域、频域以及倒谱域融合后的声学特征子集，并提出了一种基于声学和时频图特征融合的生猪咳嗽声识别方法。该方法可有效增强舍内声音特征表达能力、降低计算成本、显著提高平衡数据集下生猪咳嗽声识别精度。

（3）针对不平衡数据集下生猪咳嗽声识别精度低的问题，从特征层面，提出了声学和深度特征融合策略，该策略在数据倾斜程度加深的情况下展示出较强的鲁棒性；从算法层面，提出了一种混合集成算法，有效克服了类别不平衡带来识别精度下降的问题。

6.3 展望

本文聚焦于复杂猪舍环境下生猪咳嗽声识别，取得了一定的研究成果，但仍存在一些不足，需要进一步开展：

（1）扩充声音数据集

由于生猪在不同生产阶段、猪舍规模、外部环境、以及不同生理状态的个体差异很大，同时猪舍环境和个体身体状况的组合也影响了猪发声的差异性。因此，后期研究将收集不同种类、多个生长阶段以及不同猪舍环境下的生猪叫声，扩充舍内音频数据集。进一步验证现有模型并进行优化，提升模型的识别精准度和泛化性，以加强对不同猪舍情况下生猪咳嗽声监测的普适性。

除此之外，在咳嗽声样本的采集过程中，将实验室条件下已确诊呼吸道疾病的咳嗽与实际猪舍条件下采集的咳嗽声进行对比，丰富不同病因感染的呼吸道疾病咳嗽声样本。进一步区分环境引起的咳嗽声和呼吸道疾病引起的咳嗽声，以实现生猪呼吸道疾病的监测。

（2）样本标记和半监督学习

现有标记生猪声音片段的相关研究不足，大多数研究仍处于人工手动标记阶段。不可避免的是，手动标记不仅费时费力且高度依赖人工经验，不同专家标记存在一定的偏差。因此，在后续的工作中，应加强与动物医学研究领域的专家进一步合作，为生猪叫声制定相应的评价标准。

同时，由于实际采样过程中可以获得更多的无标记生猪舍内声音，因此，如何利用现有

中国知网 https://www.cnki.net

的已标记样本和大量未标记舍内声音样本进行半监督学习以提高复杂猪舍环境下的生猪咳嗽声识别性能将是后续研究的重点。

中国知网 https://www.cnki.net

参考文献

[1] 高观. 2022 年中国肉类产业的发展前景[J]. 肉类工业, 2022(2): 1-5.

[2] 2021 年生猪产业发展形势及 2022 年展望[J]. 中国畜牧业, 2022(3): 39-40.

[3] NORTON T, CHEN C, LARSEN M L V, et al. Review: precision livestock farming: building ‘digital representations’ to bring the animals closer to the farmer[J]. Animal, 2019, 13(12): 3009-3017.

[4] 张苏楠. 生猪异常行为多源监测及其信息融合方法的研究与应用[D]. 太原: 太原理工大学, 2020.

[5] RACEWICZ P, LUDWICZAK A, SKRZYPCZAK E, et al. Welfare health and productivity in commercial pig herds[J]. Animals, 2021, 11(4): 1176.

[6] 张军, 李柏立, 华利忠. 非洲猪瘟背景下秋冬季猪肺炎支原体的防控策略[J]. 今日养猪业, 2020(5): 24-27.

[7] MANTEUFFEL G, PUPPE B, SCHÖN P C. Vocalization of farm animals as a measure of welfare[J]. Applied Animal Behaviour Science, 2004, 88(1-2): 163-182.

[8] BENJAMIN M, YIK S. Precision livestock farming in swine welfare: a review for swine practitioners[J]. Animals, 2019, 9(4): 133.

[9] DAWKINS M S. Animal welfare and efficient farming: is conflict inevitable?[J]. Animal Production Science, 2017, 57(2): 201.

[10] TZANIDAKIS C, SIMITZIS P, ARVANITIS K, et al. An overview of the current trends in precision pig farming technologies[J]. Livestock Science, 2021, 249: 104530.

[11] 张海林. 梅山猪连续咳嗽声监测系统设计与实现[D]. 南京: 南京农业大学, 2020.

[12] 韩方东. 猪呼吸道疾病的诱发因素及鉴别诊断防治方法[J]. 农家参谋, 2022(19): 106-108.

[13] 姚宝安, 陈基萍. 猪呼吸系统传染性疾病的鉴别诊断[J]. 猪业科学, 2018, 35(7): 84-85.

[14] 刘麟. 常见猪呼吸系统疾病及其防控措施[J]. 兽医导刊, 2021(7): 14-15.

[15] 申红春. 猪场主要呼吸系统传染病及诊断[J]. 畜禽业, 2021, 32(2): 81+83.

[16] MCLOUGHLIN M P, STEWART R, MCELLIGOTT A G. Automated bioacoustics: methods in ecology and conservation and their potential for animal welfare monitoring[J]. Journal of The Royal Society Interface, 2019, 16(155): 20190225.

[17] SHARMA G, UMAPATHY K, KRISHNAN S. Trends in audio signal feature extraction methods[J]. Applied Acoustics, 2020, 158: 107020.

[18] K. V. S. N. R R, MONTGOMERY J, GARG S, et al. Bioacoustics data analysis – A taxonomy, survey and open challenges[J]. IEEE Access, 2020, 8: 57684-57708.

[19] BISHOP J C, FALZON G, TROTTER M, et al. Livestock vocalisation classification in farm soundscapes[J]. Computers and Electronics in Agriculture, 2019, 162: 531-542.

[20] 张振华. 基于音频分析技术的猪异常检测[D]. 太原: 太原理工大学, 2017.

[21] JAHNS G. Computational intelligence to recognize animal vocalization and diagnose

中国知网 https://www.cnki.net

animal health status[M]. MOEWES C, NÜRNBERGER A. Computational intelligence in intelligent data analysis: Vol. 445. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013: 239-249[2022-03-16].

[22] FERRARI S, SILVA M, GUARINO M, et al. Cough sound analysis to identify respiratory infection in pigs[J]. Computers and Electronics in Agriculture, 2008, 64(2): 318-325.

[23] 张曦宇, 宣传忠, 武佩, 等. 基于声信号的畜禽行为信息监测研究进展[J]. 黑龙江畜牧兽医, 2017(11): 63-68.

[24] 张国锋, 肖宛昂. 智慧畜牧业发展现状及趋势[J]. 中国国情国力, 2019(12): 33-35.

[25] 王瑞年. 养猪从业者如何看待人工智能养猪?[J]. 猪业科学, 2019, 36(04): 46-48.

[26] CHAKI J. Pattern analysis based acoustic signal processing: a survey of the state-of-art[J]. International Journal of Speech Technology, 2021, 24(4): 913-955.

[27] 刘振宇, 赫晓燕, 桑静, 等. 基于隐马尔可夫模型的猪咳嗽声音识别的研究[C]//中国畜牧兽医学会信息技术分会, 2015: 107-112.

[28] BRIEFER E F, SYPHERD C C R, LINHART P, et al. Classification of pig calls produced from birth to slaughter according to their emotional valence and context of production[J]. Scientific Reports, 2022, 12(1): 3409.

[29] MERCHAN F, GUERRA A, POVEDA H, et al. Bioacoustic classification of antillean manatee vocalization spectrograms using deep convolutional neural networks[J]. Applied Sciences, 2020, 10(9): 3286.

[30] KNIGHT E C, POO HERNANDEZ S, BAYNE E M, et al. Pre-processing spectrogram parameters improve the accuracy of bioacoustic classification using convolutional neural networks[J]. Bioacoustics, 2020, 29(3): 337-355.

[31] ZEBARI R, ABDULAZEEZ A, ZEEBAREE D, et al. A comprehensive review of dimensionality reduction techniques for feature selection and feature extraction[J]. Journal of Applied Science and Technology Trends, 2020, 1(2): 56-70.

[32] STEVENS K N. Autocorrelation analysis of speech sounds[J]. The Journal of the Acoustical Society of America, 1950, 22(6): 769-771.

[33] FERRARI S, SILVA M, SALA V, et al. Bioacoustics: a tool for diagnosis of respiratory pathologies in pig farms[J]. Journal of Agricultural Engineering, 2009, 40(1): 7-10.

[34] SILVA M, FERRARI S, COSTA A, et al. Cough localization for the detection of respiratory diseases in pig houses[J]. Computers and Electronics in Agriculture, 2008, 64(2): 286-292.

[35] S. FERRARI, M. SILVA, M. GUARINO, et al. Analysis of cough sounds for diagnosis of respiratory infections in intensive pig farming[J]. Transactions of the ASABE, 2008, 51(3): 1051-1055.

[36] FU Z, LU G, TING K M, et al. A survey of audio-based music classification and annotation[J]. IEEE Transactions on Multimedia, 2011, 13(2): 303-319.

[37] ER M B. A novel approach for classification of speech emotions based on deep and

中国知网 https://www.cnki.net

acoustic features[J]. IEEE Access, 2020, 8: 221640-221653.

[38] AL-SHOSHAN A I. Speech and music classification and separation: A review[J]. Journal of King Saud University - Engineering Sciences, 2006, 19(1): 95-132.

[39] BERCKMANS D. Automatic detection of chronic pig coughing from continuous registration in field situations[C]//3rd International Workshop MAVEBA, 2003: 251-254.

[40] KEDEM B. Spectral analysis and discrimination by zero-crossings[J]. Proceedings of the IEEE, 1986, 74(11): 1477-1493.

[41] VAN HIRTUM A, BERCKMANS D. Fuzzy approach for improved recognition of citric acid induced piglet coughing from continuous registration[J]. Journal of Sound and Vibration, 2003, 266(3): 677-686.

[42] VAN HIRTUM A, BERCKMANS D. Objective recognition of cough sound as biomarker for aerial pollutants: aerial pollutants and cough sound[J]. Indoor Air, 2004, 14(1): 10-15.

[43] EXADAKTYLOS V, SILVA M, AERTS J M, et al. Real-time recognition of sick pig cough sounds[J]. Computers and Electronics in Agriculture, 2008, 63(2): 207-214.

[44] GUARINO M, JANS P, COSTA A, et al. Field test of algorithm for automatic cough detection in pig houses[J]. Computers and Electronics in Agriculture, 2008, 62(1): 22-28.

[45] V EXADAKTYLOS, S FERRARI, M D SILVA, et al. A tool for labeling individual sounds from continuous recordings: An application to bio-acoustics[C]//2009 American Society of Agricultural and Biological Engineers, Reno, Nevada, 2009: 1-8.

[46] SILVA M, EXADAKTYLOS V, FERRARI S, et al. The influence of respiratory disease on the energy envelope dynamics of pig cough sounds[J]. Computers and Electronics in Agriculture, 2009, 69: 80-85.

[47] DAVIS S, MERMELSTEIN P. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1980, 28(4): 357-366.

[48] CHUNG Y, OH S, LEE J, et al. Automatic detection and recognition of pig wasting diseases using sound data in audio surveillance systems[J]. Sensors, 2013, 13(10): 12929-12942.

[49] GIESERT A L, BALKE W T, JAHNS G. Probabilistic analysis of coughs in pigs to diagnose respiratory infections[J]. 2011,61: 237-242.

[50] 熊梓奥. 育肥猪舍中的咳嗽声监测系统设计[D]. 哈尔滨: 哈尔滨工程大学, 2021.

[51] VALLETTA J J, TORNEY C, KINGS M, et al. Applications of machine learning in animal behaviour studies[J]. Animal Behaviour, 2017, 124: 203-220.

[52] WANG X, ZHAO X, HE Y, et al. Cough sound analysis to assess air quality in commercial weaner barns[J]. Computers and Electronics in Agriculture, 2019, 160: 8-13.

[53] 黎煊, 赵建, 高云, 等. 基于深度信念网络的猪咳嗽声识别[J]. 农业机械学报, 2018, 49(3): 179-186.

[54] GHORAANI B, KRISHNAN S. Time–frequency matrix feature extraction and

中国知网 https://www.cnki.net

classification of environmental audio signals[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2011, 19(7): 2197-2209.

[55] YIN Y, TU D, SHEN W, et al. Recognition of sick pig cough sounds based on convolutional neural network in field situations[J]. Information Processing in Agriculture, 2021, 8(3): 369-379.

[56] HONG M, AHN H, ATIF O, et al. Field-applicable pig anomaly detection system using vocalization for embedded board implementations[J]. Applied Sciences, 2020, 10(19): 6991.

[57] 耿艳利, 宋朋首, 林彦伯, 等. 采用改进 CNN 对生猪异常状态声音识别[J]. 农业工程学报, 2021, 37(20): 187-193.

[58] LEE J, CHOI Y, PARK D, et al. Sound noise-robust porcine wasting diseases detection and classification system using convolutional neural network[J]. The Journal of Korean Institute of Information Technology, 2018, 16(5): 1-13.

[59] SHEN W, TU D, YIN Y, et al. A new fusion feature based on convolutional neural network for pig cough recognition in field situations[J]. Information Processing in Agriculture, 2021, 8(4): 573-580.

[60] DEY N, ASHOUR A S, BORRA S. Classification in BioApps: automation of decision making[M]. Cham: Springer International Publishing, 2018.

[61] HÄRDLE W K, SIMAR L. Applied multivariate statistical analysis[M]. Berlin, Heidelberg: Springer Berlin Heidelberg, 2015.

[62] DOUGLAS C E, MICHAEL F A. On distribution-free multiple comparisons in the one-way analysis of variance[J]. Communications in Statistics - Theory and Methods, 1991, 20(1): 127-139.

[63] GUTIERREZ W M, KIM S, KIM D H, et al. Classification of porcine wasting diseases using sound analysis[J]. Asian-Australasian Journal of Animal Sciences, 2010, 23(8): 1096-1104.

[64] ZHANG J, WANG Y, MOLINO P, et al. Manifold: a model-agnostic framework for interpretation and diagnosis of machine learning models[J]. IEEE Transactions on Visualization and Computer Graphics, 2019, 25(1): 364-373.

[65] PAL N R, PAL K, KELLER J M, et al. A possibilistic fuzzy c-means clustering algorithm[J]. IEEE Transactions on Fuzzy Systems, 2005, 13(4): 517-530.

[66] LEE J, JIN L, PARK D, et al. Acoustic features for pig wasting disease detection[J]. IJIPM, 2015, 6(1):37-46.

[67] WILPON J G, RABINER L R. Application of hidden Markov models to automatic speech endpoint detection[J]. Computer Speech & Language, 1987, 2(3-4): 321-341.

[68] 张苏楠, 王芳, 阎高伟, 等. 基于隐马尔科夫模型的猪只状态自动识别技术[J]. 黑龙江畜牧兽医, 2016(21): 97-99+103+294.

[69] 龚永杰. 基于声音识别技术的猪咳嗽音识别方法的研究[D]. 武汉: 华中农业大学, 2018.

中国知网 https://www.cnki.net

[70] NEETHIRAJAN S. The role of sensors, big data and machine learning in modern animal farming[J]. Sensing and Bio-Sensing Research, 2020, 29: 100367.

[71] CHATZIMPARMPAS A, MARTINS R M, KUCHER K, et al. FeatureEnVi: visual analytics for feature engineering using stepwise selection and semi-automatic extraction approaches[J]. 2021, arXiv.2103.14539.

[72] PICZAK K J. Environmental sound classification with convolutional neural networks[C]//2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP). Boston, MA, USA: IEEE, 2015: 1-6.

[73] MOSHOU D, CHEDAD A, VAN HIRTUM A, et al. Neural recognition system for swine cough[J]. Mathematics and Computers in Simulation, 2001, 56(4-5): 475-487.

[74] D. MOSHOU, A. CHEDAD, A. VAN HIRTUM, et al. An intelligent alarm for early detection of swine epidemics based on neural networks[J]. Transactions of the ASAE, 2001, 44(1): 167-174.

[75] 赵建. 基于深度学习的猪咳嗽声识别[D]. 武汉: 华中农业大学, 2019.

[76] 孙浩楠, 仝志民, 谢秋菊, 等. 基于 BP 神经网络猪咳嗽声识别[J]. 中国农机化学报, 2022, 43(2): 148-154.

[77] 彭硕, 刘东阳, 时国龙, 等. 基于深度神经网络及隐马尔科夫模型的生猪状态音频识别[J]. 中国农业大学学报, 2022, 27(6): 172-181.

[78] XIE J, HU K, ZHU M, et al. Investigation of different CNN-based models for improved bird sound classification[J]. IEEE Access, 2019, 7: 175353-175361.

[79] FERNANDES M S, CORDEIRO W, RECAMONDE-MENDOZA M. Detecting aedes aegypti mosquitoes through audio classification with convolutional neural networks[J]. Computers in Biology and Medicine, 2021,129: 104152.

[80] KO K, PARK S, KO H. Convolutional feature vectors and support vector machine for animal sound classification[C]//2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC). Honolulu, HI: IEEE, 2018: 376-379.

[81] 宋航, 赵斌, 孙浩楠, 等. 基于 DenseNet 模型的猪咳嗽声识别算法研究[J]. 黑龙江畜牧兽医, 2022(20): 41-44+49.

[82] 涂鼎. 基于音频技术的生猪咳嗽声音识别方法研究[D]. 哈尔滨: 东北农业大学, 2020.

[83] 沈明霞, 王梦雨, 刘龙申, 等. 基于深度神经网络的猪咳嗽声识别方法[J]. 农业机械学报, 2022, 53(5): 257-266.

[84] 邵睿, 彭硕, 查文文, 等. 基于 BiLSTM 的生猪音频识别[J]. 合肥学院学报(综合版), 2022, 39(2): 113-119.

[85] 熊梓奥, 苍岩. 育肥猪舍中的猪叫声端点检测算法[J]. 应用科技, 2020, 47(5): 79-85.

[86] 苍岩, 罗顺元, 乔玉龙. 基于深层神经网络的猪声音分类[J]. 农业工程学报, 2020, 36(9): 195-204.

[87] RODRIGUES DA COSTA M, FITZGERALD R M, MANZANILLA E G, et al. A cross-

中国知网 https://www.cnki.net

sectional survey on respiratory disease in a cohort of Irish pig farms[J]. Irish Veterinary Journal, 2020, 73(1): 24.

[88] SIBILA M, PIETERS M, MOLITOR T, et al. Current perspectives on the diagnosis and epidemiology of Mycoplasma hyopneumoniae infection[J]. The Veterinary Journal, 2009, 181(3): 221-231.

[89] JI N, YIN Y, SHEN W, et al. Pig sound analysis: a measure of welfare[J]. Smart Agriculture, 2022, 4(2): 19-35.

[90] MAES D, SIBILA M, KUHNERT P, et al. Update on *Mycoplasma hyopneumoniae* infections in pigs: Knowledge gaps for improved disease control[J]. Transboundary and Emerging Diseases, 2018, 65: 110-124.

[91] PESSOA J, RODRIGUES DA COSTA M, GARCÍA MANZANILLA E, et al. Managing respiratory disease in finisher pigs: combining quantitative assessments of clinical signs and the prevalence of lung lesions at slaughter[J]. Preventive Veterinary Medicine, 2021, 186: 105208.

[92] BATISTA G E A P A, PRATI R C, MONARD M C. A study of the behavior of several methods for balancing machine learning training data[J]. ACM SIGKDD Explorations Newsletter, 2004, 6(1): 20-29.

[93] BARWICK J, LAMB D W, DOBOS R, et al. Identifying sheep activity from tri-axial acceleration signals using a moving window classification model[J]. Remote Sensing, 2020, 12(4): 646.

[94] LI G, XIONG Y, DU Q, et al. Classifying ingestive behavior of dairy cows via automatic sound recognition[J]. Sensors, 2021, 21(15): 5231.

[95] ANDERS F, KALAN A K, KÜHL H S, et al. Compensating class imbalance for acoustic chimpanzee detection with convolutional recurrent neural networks[J]. Ecological Informatics, 2021, 65: 101423.

[96] ZHANG Y J, HUANG J F, GONG N, et al. Automatic detection and classification of marmoset vocalizations using deep and recurrent neural networks[J]. The Journal of the Acoustical Society of America, 2018, 144(1): 478-487.

[97] CHAWLA N V, BOWYER K W, HALL L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321-357.

[98] BRODIE S, ALLEN-ANKINS S, TOWSEY M, et al. Automated species identification of frog choruses in environmental recordings using acoustic indices[J]. Ecological Indicators, 2020, 119: 106852.

[99] WATANABE R N, BERNARDES P A, ROMANZINI E P, et al. Strategy to predict high and low frequency behaviors using triaxial accelerometers in grazing of beef cattle[J]. Animals, 2021, 11(12): 3438.

[100] HAN H, WANG W Y, MAO B H. Borderline-SMOTE: a new over-sampling method in imbalanced data sets learning[J]. International conference on intelligent computing, 2005:

中国知网 https://www.cnki.net

878-887.

[101] JIN M, WANG C, JENSEN D B. Effect of de-noising by wavelet filtering and data augmentation by borderline SMOTE on the classification of imbalanced datasets of pig behavior[J]. Frontiers in Animal Science, 2021, 2: 666855.

[102] 王君逸. 基于多特征融合的交通车辆声信号识别方法研究[D]. 南昌: 华东交通大学, 2022.

[103] LIAO J, LI H, FENG A, et al. Domestic pig sound classification based on TransformerCNN[J]. Applied Intelligence, 2022: 1-17.

[104] 韩磊磊, 田建艳, 张苏楠, 等. 基于决策树支持向量机和模糊推理的生猪异常声音识别[J]. 畜牧与兽医, 2019, 51(3): 38-44.

[105] 王文静. 基于 CNN 的猪声音状态识别研究与应用[D]. 哈尔滨: 哈尔滨工程大学, 2019.

[106] 龚永杰, 黎煊, 高云, 等. 基于矢量量化的猪咳嗽声识别[J]. 华中农业大学学报, 2017, 36(3): 119-124.

[107] ZHAO J, LI X, LIU W, et al. DNN-HMM based acoustic model for continuous pig cough sound recognition[J]. International Journal of Agricultural and Biological Engineering, 2020, 13(3): 186-193.

[108] 张振华, 田建艳, 王芳, 等. 猪咳嗽声特征参数提取与识别的研究[J]. 黑龙江畜牧兽医, 2017(23): 18-22.

[109] 邵睿. 基于音频特征融合的生猪状态识别研究[D]. 合肥: 安徽农业大学, 2022.

[110] CORDEIRO A F da S, NÄÄS I de A, OLIVEIRA S R de M, et al. Efficiency of distinct data mining algorithms for classifying stress level in piglets from their vocalization[J]. Engenharia Agrícola, 2012, 32(2): 208-216.

[111] TALLET C, LINHART P, POLICHT R, et al. Encoding of situations in the vocal repertoire of piglets (Sus scrofa): a comparison of discrete and graded classifications[J]. PLoS ONE, 2013, 8(8): 1-13.

[112] ZHANG S, JAFARI O, NAGARKAR P. A survey on machine learning techniques for auto labeling of video, audio, and text data[J]. 2021. arXiv.2109.03784.

[113] MESAROS A, HEITTOLA T, VIRTANEN T, et al. Sound Event Detection: A tutorial[J]. IEEE Signal Processing Magazine, 2021, 38(5): 67-83.

[114] 蔚慧甜. 基于汉宁窗函数的滤波器的设计[J]. 传感器世界, 2011, 17(12): 27-29.

[115] RODRIGUEZ J D, PEREZ A, LOZANO J A. sensitivity analysis of k-fold cross validation in prediction error estimation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32(3): 569-575.

[116] WAINER J, CAWLEY G. Nested cross-validation when selecting classifiers is overzealous for most practical applications[J]. Expert Systems with Applications, 2021, 182: 115222.

[117] LUQUE A. The impact of class imbalance in classification performance metrics based on the binary confusion matrix[J]. Pattern Recognition, 2019, 91: 216-231.

[118] KNIGHT E C, HANNAH K C, FOLEY G J, et al. Recommendations for acoustic

中国知网 https://www.cnki.net

recognizer performance assessment with application to five common automated signal recognition programs[J]. Avian Conservation and Ecology, 2017, 12(2): art14.

[119] WANG Y, HAN K, WANG D. Acoustic features for classification based speech separation[J]. Interspeech ISCA's 13th Annual Conference Portland, OR 2012: 9-13.

[120] KE X, YUAN F, CHENG E. Integrated optimization of underwater acoustic ship-radiated noise recognition based on two-dimensional feature fusion[J]. Applied Acoustics, 2020, 159: 107057.

[121] MA B, GREER T, KNOX D, et al. A computational lens into how music characterizes genre in film[J]. PLOS ONE, 2021, 16(4): e0249957.

[122] XIE J, ZHU M. Handcrafted features and late fusion with deep learning for bird sound classification[J]. Ecological Informatics, 2019, 52: 74-81.

[123] WANG W, YUAN J, WANG B, et al. Robust classification of heart valve sound based on adaptive EMD and feature fusion[J]. PLOS ONE, 2022, 17(12): e0276264.

[124] FLORES-FUENTES W, RIVAS-LOPEZ M, SERGIYENKO O, et al. Combined application of power spectrum centroid and support vector machines for measurement improvement in optical scanning systems[J]. Signal Processing, 2014, 98: 37-51.

[125] MA Y, NISHIHARA A. Efficient voice activity detection algorithm using long-term spectral flatness measure[J]. EURASIP Journal on Audio, Speech, and Music Processing, 2013, 2013(1): 87.

[126] SHEN W, JI N, YIN Y, et al. Investigation of acoustic and visual features for pig cough classification[J]. Biosystems Engineering, 2022, 219: 281-293.

[127] LUZ J S, OLIVEIRA M C, ARAÚJO F H D, et al. Ensemble of handcrafted and deep features for urban sound classification[J]. Applied Acoustics, 2021, 175: 107819.

[128] DAN-NING JIANG, LIE LU, HONG-JIANG ZHANG, et al. Music type classification by spectral contrast feature[C]// IEEE International Conference on Multimedia and Expo. Lausanne, Switzerland: IEEE, 2002: 113-116.

[129] SADJADI S O, HANSEN J H L. Unsupervised Speech Activity Detection Using Voicing Measures and Perceptual Spectral Flux[J]. IEEE Signal Processing Letters, 2013, 20(3): 4.

[130] AKHTAR T, GILANI S O, MUSHTAQ Z, et al. Effective voting ensemble of homogenous ensembling with multiple attribute-selection approaches for improved identification of thyroid disorder[J]. Electronics, 2021, 10(23): 3026.

[131] DONG W, HUANG Y, LEHANE B, et al. XGBoost algorithm-based prediction of concrete electrical resistivity for structural health monitoring[J]. Automation in Construction, 2020, 114: 103155.

[132] 张旭. 基于机器学习的精细化可解释公共盗窃犯罪分布研究[D]. 广州: 广州大学, 2022.

[133] LUNDBERG S M, ERION G G, LEE S I. Consistent Individualized Feature Attribution for Tree Ensembles[J]. 2018. arXiv.1802.03888.

中国知网 https://www.cnki.net

[134] LUNDBERG S M, NAIR B, VAVILALA M S, et al. Explainable machine-learning predictions for the prevention of hypoxaemia during surgery[J]. Nature Biomedical Engineering, 2018, 2(10): 749-760.

[135] AMIRIPARIAN S, GERCZUK M, OTTL S, et al. Snore sound classification using image-based deep spectrum features[C]//Interspeech. ISCA, 2017: 3512-3516.

[136] KUMAR S, THIRUVENKADAM S. An analysis of the impact of spectral contrast feature in speech emotion recognition[J]. International Journal of Recent Contributions from Engineering, Science & IT (iJES), 2021, 9(2): 87.

[137] WANG Y, SHI F, CAO L, et al. Morphological segmentation analysis and texture-based support vector machines classification on mice liver fibrosis microscopic images[J]. Current Bioinformatics, 2019, 14(4): 282-294.

[138] ZEILER S, NICHELI R, MA N, et al. Robust audiovisual speech recognition using noise-adaptive linear discriminant analysis[C]//2016 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Shanghai: IEEE, 2016: 2797-2801.

[139] BONET-SOLÀ D, ALSINA-PAGÈS R M. A comparative survey of feature extraction and machine learning methods in diverse acoustic environments[J]. Sensors, 2021, 21(4): 1274.

[140] MARINOV D, KARAPETYAN D. Hyperparameter optimisation with early termination of poor performers[C]//2019 11th Computer Science and Electronic Engineering (CEEC). Colchester, United Kingdom: IEEE, 2019: 160-163.

[141] ALIBRAHIM H, LUDWIG S A. Hyperparameter optimization: comparing genetic algorithm against grid search and bayesian optimization[C]//2021 IEEE Congress on Evolutionary Computation (CEC). Kraków, Poland: IEEE, 2021: 1551-1559.

[142] MCFEE B, RAFFEL C, LIANG D, et al. librosa: audio and music signal analysis in python[C]//Python in Science Conference. Austin, Texas, 2015: 18-24.

[143] BEAUREGARD G T, HARISH M, WYSE L. Single pass spectrogram inversion[C]//2015 IEEE International Conference on Digital Signal Processing (DSP). Singapore: IEEE, 2015: 427-431.

[144] PHAM L, PHAN H, NGUYEN T, et al. Robust acoustic scene classification using a multi-spectrogram encoder-decoder framework[J]. Digital Signal Processing, 2021, 110: 102943.

[145] AMIRIPARIAN S, GERCZUK M, OTTL S, et al. Bag-of-deep-features: noise-robust deep feature representations for audio analysis[C]//2018 International Joint Conference on Neural Networks (IJCNN). Rio de Janeiro: IEEE, 2018: 1-7.

[146] XU L, WEI Z, ZAIDI S F A, et al. Speech enhancement based on nonnegative matrix factorization in constant-Q frequency domain[J]. Applied Acoustics, 2021, 174: 107732.

[147] NANNI L, MAGUOLO G, BRAHNAM S, et al. An ensemble of convolutional neural networks for audio classification[J]. Applied Sciences, 2021, 11(13): 5796.

[148] PHAM L, MCLOUGHLIN I, PHAN H, et al. A robust framework for acoustic scene classification[C]//Interspeech 2019. ISCA, 2019: 3634-3638.

中国知网 https://www.cnki.net

[149] QU Y, LI X, QIN Z, et al. Acoustic scene classification based on three-dimensional multi-channel feature-correlated deep learning networks[J]. Scientific Reports, 2022, 12(1): 13730.

[150] NISAR S, KHAN O U, TARIQ M. An efficient adaptive window size selection method for improving spectrogram visualization[J]. Computational Intelligence and Neuroscience, 2016, 2016: 1-13.

[151] SCHÖRKHUBER C, KLAPURI A. Constant-Q transform toolbox for music processing[C]//7th sound and music computing conference, Barcelona, Spain. 2010: 3-64.

[152] YANG B, CHEN S. A comparative study on local binary pattern (LBP) based face recognition: LBP histogram versus LBP image[J]. Neurocomputing, 2013, 120: 365-379.

[153] RAKOTOMAMONJY A, GASSO G. Histogram of gradients of time–frequency representations for audio scene classification[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2015, 23(1): 12.

[154] ANOWAR F, SADAOUI S, SELIM B. Conceptual and empirical comparison of dimensionality reduction algorithms (PCA, KPCA, LDA, MDS, SVD, LLE, ISOMAP, LE, ICA, t-SNE)[J]. Computer Science Review, 2021, 40: 100378.

[155] JIANG J, WU Z, XU M, et al. Comparing feature dimension reduction algorithms for GMM-SVM based speech emotion recognition[C]//2013 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference. Kaohsiung, Taiwan: IEEE, 2013: 1-4.

[156] CHANDOLA Y, VIRMANI J, BHADAURIA H S, et al. Hybrid computer-aided classification system design using lightweight end-to-end Pre-trained CNN-based deep feature extraction and PCA-SVM classifier for chest radiographs[M]. Deep Learning for Chest Radiographs. Elsevier, 2021: 197-204.

[157] PAUL R, LIU Y, LI Q, et al. Representation of deep features using radiologist defined semantic features[C]//2018 International Joint Conference on Neural Networks (IJCNN). Rio de Janeiro: IEEE, 2018: 1-7.

[158] 汤胜楠. 时频分析与卷积神经网络相融合的液压轴向柱塞泵智能故障诊断方法[D]. 镇江: 江苏大学, 2021.

[159] KUANG Y, WU Q, WANG Y, et al. Simplified inverse filter tracked affective acoustic signals classification incorporating deep convolutional neural networks[J]. Applied Soft Computing, 2020, 97: 106775.

[160] BASHA S H S, DUBEY S R, PULABAIGARI V, et al. Impact of fully connected layers on performance of convolutional neural networks for image classification[J]. Neurocomputing, 2020, 378: 112-119.

[161] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[162] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image

中国知网 https://www.cnki.net

recognition[J]. 2014. arXiv.1409.1556.

[163] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE, 2016: 770-778.

[164] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks [C]//Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, 2014: 818-833.

[165] HAMAD Q S, SAMMA H, SUANDI S A. Feature selection of pre-trained shallow CNN using the QLESCA optimizer: COVID-19 detection as a case study[J]. Applied Intelligence, 2023:1-23.

[166] LI J, XIE S, CHEN Z, et al. A shallow convolutional neural network for apple classification[J]. IEEE Access, 2020, 8: 111683-111692.

[167] JUNAID M, GHAFOOR M, HASSAN A, et al. Multi-feature view-based shallow convolutional neural network for road segmentation[J]. IEEE Access, 2020, 8: 36612-36623.

[168] HU Y, LI J, HUANG Y, et al. Channel-wise and spatial feature modulation network for single image super-resolution[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 30(11): 3911-3927.

[169] CHEN L, ZHANG H, XIAO J, et al. SCA-CNN: spatial and channel-wise attention in convolutional networks for image captioning[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 6298-6306.

[170] XIANG Z, TAN H, YE W. The excellent properties of a dense grid-based hog feature on face recognition compared to Gabor and LBP[J]. IEEE Access, 2018, 6: 29306-29319.

[171] ABDI H, WILLIAMS L J. Principal component analysis: principal component analysis[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2010, 2(4): 433-459.

[172] SINGH V, PENCINA M, EINSTEIN A J, et al. Impact of train/test sample regimen on performance estimate stability of machine learning in cardiovascular imaging[J]. Scientific Reports, 2021, 11(1): 14490.

[173] STAHLSCHMIDT S R, ULFENBORG B, SYNNERGREN J. Multimodal deep learning for biomedical data fusion: a review[J]. Briefings in Bioinformatics, 2022, 23(2): 1-15.

[174] SETUMIN S, AMINUDIN M F C, SUANDI S A. Canonical correlation analysis feature fusion with patch of interest: a dynamic local feature matching for face sketch image retrieval[J]. IEEE Access, 2020, 8: 137342-137355.

[175] ZHENG L, WANG S, TIAN L, et al. Query-adaptive late fusion for image search and person re-identification[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston, MA, USA: IEEE, 2015: 1741-1750.

[176] GUO Z, XU L, ALI ASGHARZADEHOLIAEE N. A homogeneous ensemble classifier for breast cancer detection using parameters tuning of mlp neural network[J]. Applied

中国知网 https://www.cnki.net

Artificial Intelligence, 2022, 36(1): 2031820.

[177] FOTOUHI S, ASADI S, KATTAN M W. A comprehensive data level analysis for cancer diagnosis on imbalanced data[J]. Journal of Biomedical Informatics, 2019, 90: 103089.

[178] MANNING C D. Computational linguistics and deep learning[J]. Computational Linguistics, 2015, 41(4): 701-707.

[179] GOLDBERG Y. A primer on neural network models for natural language processing[J]. Journal of Artificial Intelligence Research, 2016, 57: 345-420.

[180] SANTOS M S, SOARES J P, ABREU P H, et al. Cross-validation for imbalanced datasets: avoiding overoptimistic and overfitting approaches[J]. IEEE Computational Intelligence Magazine, 2018, 13(4): 59-76.

[181] ZIAN S, KAREEM S A, VARATHAN K D. An empirical evaluation of stacked ensembles with different meta-learners in imbalanced classification[J]. IEEE Access, 2021, 9: 87434-87452.

[182] FERNÁNDEZ A, GARCÍA S, DEL JESUS M J, et al. A study of the behaviour of linguistic fuzzy rule based classification systems in the framework of imbalanced data-sets[J]. Fuzzy Sets and Systems, 2008, 159(18): 2378-2398.

[183] GARCÍA V, SÁNCHEZ J S, MOLLINEDA R A. On the effectiveness of preprocessing methods when dealing with different levels of class imbalance[J]. Knowledge-Based Systems, 2012, 25(1): 13-21.

[184] HERLAND M, BAUDER R A, KHOSHGOFTAAR T M. The effects of class rarity on the evaluation of supervised healthcare fraud detection models[J]. Journal of Big Data, 2019, 6(1): 21.

[185] ZHANG S, TIAN J, BANERJEE A, et al. Automatic recognition of porcine abnormalities based on a sound detection and recognition system[J]. Transactions of the ASABE, 2019, 62(6): 1755-1765.

中国知网 https://www.cnki.net