分类号：_____ 密级：_____

UDC：_____ 编号：2021240527

雲南農業大學

全日制专业硕士学位论文

基于智能语音技术的猪只声音监测研究

Research of Pig Sound Monitoring Based on Intelligent Voice Technology

硕士研究生：谢杰

指导教师：周兵教授

申请学位类别：农业硕士

领域：农业工程与信息技术

培养学院：大数据学院

二O二三年五月

中国知网 https://www.cnki.net

摘要

猪肉已经成为了我国最主要的肉类粮食之一，对牢牢端稳中国人饭碗起着至关重要的作用，在生猪产量需求稳步增长的背景下，我国生猪养殖产业模式正朝着规模化、集约化、现代化方向发展，同时，也带来了一些新的挑战。例如规模化、集约化的养殖过程中存在猪只养殖空间缩小，养殖密度变大，通风情况不佳等现象，这无疑加剧了猪只患呼吸道病的风险，严重的极有可能导致猪只疫病的集中爆发。在密集化的生猪养殖场中对猪只进行呼吸道病的检测与预防是至关重要的，研究表明猪只咳嗽声是呼吸道病的早期临床症状之一，因此，研究如何通过对猪只声音监测来预警猪只疫病是实现生猪现代化养殖的关键问题与热点问题之一。传统监测方式是通过人工蹲点监测猪只咳嗽声来判断猪只健康状况以及疫病爆发风险，该手段费时、费力、效率低，还容易出现人畜共患病或其他影响猪只正常生长的情况，所以通过智能语音技术对猪只声音进行监测在疫病防控方面具有重大的意义。

本文首先调研分析了国内外关于猪只声音监测的研究现状，并以数据采集、数据预处理、特征提取、模型建立与优化为技术路线，开展猪只声音分类的研究，内容如下：

（1）猪只声音数据采集与处理。本研究的猪只声音数据来源于三个不同地方的生猪养殖场，在养殖专业人员指导下，对原始样本进行数据标注与样本切割，从 10 万余条原始数据中截取出了 10000 条目标样本，目标样本包括猪只的吃食声、饮水声、呼噜声、哼唧声、咳嗽声五类声音。对目标样本进行数据预处理，预处理包括预加重、分帧加窗以及滤波降噪。针对猪只声音样本中背景噪声，对比了谱减法、维纳滤波法以及小波分析法的降噪效果，选取维纳滤波法进行降噪。针对猪只声音样本中的特定噪声采用 FIR 滤波器进行降噪。

（2）猪只声音特征参数提取。本研究对猪只声音信号提取了四类特征参数，包括时域中的短时能量与短时过零率、频域中的功率谱密度、时频域中的语谱图以及倒谱域中的梅尔倒谱系数，通过对四类特征参数的提取、分析与对比，最后选取梅尔倒谱系数（MFCC）作为特征参数，并以 MFCC 作为本次研究分类模型的输入数据。

（3）猪只声音分类模型研究。本次研究基于猪只的五类声音数据集构建了支持向量机模型(SVM)、隐马尔科夫模型（HMM）、长短期记忆网络（LSTM）以及改进的长短期记忆网络（LSTMP）四种猪只声音分类模型，选取准确率作为模型效果评价指标，通

中国知网 https://www.cnki.net

过分层抽样方法将数据集划分训练集与测试集比例为 8：2，研究结果显示，SVM、HMM、LSTM、LSTMP 对猪只声音总的分类准确率分别为 87.83%、87.65%、90.49%、91.54%，均达到 85%以上，且以 LSTM 为基础的改进模型 LSTMP 高于 LSTM 本身分类准确率，改进后模型在分类效果上提升了约 1%，表明研究中采用的分类模型对猪只声音分类均可行且有效，LSTMP 较基础模型 LSTM 改进效果有一定提升。

（4）猪只声音分类模型优化。本研究采取了鲸鱼优化（WOA）、粒子群优化（PSO）以及量子花朵授粉优化（QFPA）三种智能优化算法，搭建了 WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 三个优化组合模型，研究结果显示，WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 对猪只声音总的分类准确率分别为 92.54%、92.77%、93.47%，三种优化组合模型均高于 LSTMP 模型分类准确率，证明三种模型优化方法是可行且有效，其中 QFPA-LSTMP 的分类准确率最佳。

结合上述猪只声音分类研究结果，我们基于 MATLAB GUI 设计了猪只声音分类可视化交互界面，为后期猪只声音在线实时监测奠定基础，同时本次研究结果也为猪只疫病预警提供新思路，研究结果将助力于智慧养殖技术提升，对生猪养殖产业的健康发展进行数字赋能。

关键字： 猪只声音；数据预处理；特征提取；分类模型；疫病预警；

中国知网 https://www.cnki.net

Research of Pig Sound Monitoring Based on Intelligent Voice Technology

JieXie

Directed by Bing Zhou

Abstract

Pork has become one of the most important meat grains in China, playing a vital role in stabilising the rice bowls of the Chinese people. Against the background of a steady increase in demand for pig production, China's pig breeding industry model is developing in the direction of scale, intensification and modernisation, which, at the same time, also brings some new challenges. For example, there are phenomena such as reduced pig breeding space, greater breeding density and poor ventilation in the process of large-scale and intensive farming, which undoubtedly intensifies the risk of pigs suffering from respiratory diseases and most likely leads to a concentrated outbreak of pig diseases in serious cases. The detection and prevention of respiratory diseases in intensive pig farms is crucial, and research shows that coughing is one of the early clinical signs of respiratory diseases, therefore, the study of how to monitor the sound of pigs to warn pigs of diseases is one of the key issues and hot issues in modern pig farming. The traditional method of monitoring pigs' coughs is to determine the health status of pigs and the risk of disease outbreaks, which is time-consuming, labour-intensive, inefficient and prone to zoonotic diseases and other conditions that affect the normal growth of pigs.

This paper first investigates and analyses the current status of research on pig sound monitoring at home and abroad, and carries out research on pig sound classification using

中国知网 https://www.cnki.net

data collection, data pre-processing, feature extraction, model building and optimization as the technical route, as follows:

(1) The collection and processing of pig sound data. Under the guidance of farming professionals, the original samples were labeled and cut, and 10,000 target samples were extracted from over 100,000 original data. The target samples included five types of sounds: eating, drinking, grunting, grunting and coughing. The target samples were pre-processed with pre-emphasis, frame addition and filtering to reduce noise. For the background noise in the pig sound samples, the noise reduction effects of spectral subtraction, Wiener filtering and wavelet analysis were compared, and Wiener filtering was selected for noise reduction. The FIR filter was used for noise reduction of specific noises in the pig samples.

(2) The parameters of pig sound are extracted. In this study, four types of feature parameters were extracted from the pig sound signal, including short-time energy and short-time transient rate in the time domain, power spectral density in the frequency domain, speech spectrogram in the time-frequency domain, and Mel's cepstrum coefficient in the cepstrum domain. The MFCC was used as the input data for the classification model.

(3) A study is conducted on pig sound classification models. In this study, four pig sound classification models were constructed based on five types of pig sound data sets: support vector machine model (SVM), hidden Markov model (HMM), long and short-term memory network (LSTM) and improved long and short-term memory network (LSTMP), and the accuracy rate was selected as the model effect evaluation index. The results of the study showed that the overall classification accuracy of SVM, HMM, LSTM and LSTMP for pig sounds was 87.83%, 87.65%, 90.49% and 91.54% respectively, which all reached above 85%, and the improved model LSTMP based on LSTM was higher than the classification accuracy of LSTM itself, and the improved model improved the classification effect by about This indicates that the classification models used in the study are all feasible and effective for classifying pig sounds, and that the LSTMP has improved somewhat over the base model LSTM.

(4) Optimization of pig sound classification models. In this study, three intelligent optimization algorithms, whale optimization (WOA), particle swarm optimization (PSO) and

中国知网 https://www.cnki.net

quantum flower pollination optimization (QFPA), were adopted to build three optimization combination models, WOA-LSTMP, PSO-LSTMP and QFPA-LSTMP, and the research results showed that WOA-LSTMP, PSO-LSTMP and QFPA-LSTMP were more accurate than The classification accuracies of WOA-LSTMP, PSO-LSTMP and QFPA-LSTMP were 92.54%, 92.77% and 93.47% respectively, and all three optimised combination models were higher than the classification accuracy of LSTMP model, which proved that the three models optimisation methods were feasible and effective, among which QFPA-LSTMP had the best classification accuracy.

A visual display of pig sound classification based on MATLAB GUI was designed, combined with the above pig sound classification research results, laying the foundation for online real-time monitoring of pig sound in the later stage. New ideas for pig disease early warning are provided by the research results, and the smart farming technology can be improved, and the healthy development of the pig farming industry can be digitally empowered.

Keywords: pig sounds; data pre-processing; feature extraction; classification models; epidemic early warning;

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....4
1.2 国内外研究现状.....5
1.2.1 国外研究现状.....6
1.2.2 国内研究现状.....7
1.3 研究内容.....10
1.4 技术路线.....11
1.5 论文组织结构.....12
第二章 猪只声音智能监测的相关理论.....13
2.1 猪只呼吸道系统疾病简介.....13
2.2 智能语音分类技术步骤.....14
2.2.1 语音数据预处理.....15
2.2.2 语音信号特征提取.....16
2.2.3 语音分类建模与训练.....16
2.3 支持向量机模型.....16
2.4 隐马尔科夫模型.....18
2.5 长短期记忆网络.....20
2.6 本章小结.....22
第三章 猪只声音采集及预处理.....23
3.1 猪只声音采集.....23
3.2 数据标注与样本切割.....26
3.2.1 数据标注.....26
3.2.2 样本切割.....27
3.3 预加重.....28
3.4 分帧加窗.....29
3.5 猪只声音滤波降噪.....32
3.5.1 猪只声音样本中背景噪声滤波处理.....33
3.5.2 猪只声音样本中特定噪声的滤波处理.....38
3.6 本章小结.....40
第四章 猪只声音信号特征参数提取.....41
4.1 引言.....41
4.2 猪只声音信号时域特征参数提取.....41

中国知网 https://www.cnki.net

4.3 猪只声音信号频域特征参数提取 43
4.4 猪只声音信号时频域特征参数提取 44
4.5 猪只声音信号倒谱域特征参数提取 47
4.6 猪只声音信号特征提取结果分析 51
4.7 本章小结.....51
第五章 猪只声音分类模型研究 52
5.1 引言.....52
5.2 基于支持向量机的猪只声音分类 52
5.3 基于隐马尔科夫的猪只声音分类 55
5.4 基于长短期记忆网络的猪只声音分类 58
5.5 基于改进长短期记忆网络的猪只声音分类 61
5.6 猪只声音分类模型构建结果分析 64
5.7 本章小结.....65
第六章 猪只声音分类模型优化 66
6.1 引言.....66
6.2 基于 WOA 算法的模型优化.....66
6.3 基于 PSO 算法的模型优化 70
6.4 基于 QFPA 算法的模型优化.....73
6.5 结果分析.....77
6.6 本章小结.....79
第七章 总结与展望 80
7.1 总结.....80
7.2 展望.....81
参考文献.....82

中国知网 https://www.cnki.net

第一章绪论

1.1 研究背景及意义

1.1.1 研究背景

根据美国农业部 2011-2021 年全球生猪产量分布数据，全球主要生猪生产国家依次为中国、欧盟、美国、俄罗斯以及巴西，其中中国生猪产量年平均约为 5000 万头，生猪出栏量在全球占比约为 50%左右。2019 年和 2020 年，受非洲猪瘟影响，全球生猪总产量呈现下降趋势且我国受猪瘟影响严重，具体数据呈现如图 1-1 所示。总而言之，目前我国猪肉总量约占世界总量的一半[1]，由于生猪养殖规模占全球市场份额巨大，因此生猪疫病极易造成养猪业蒙受巨大的经济损失。

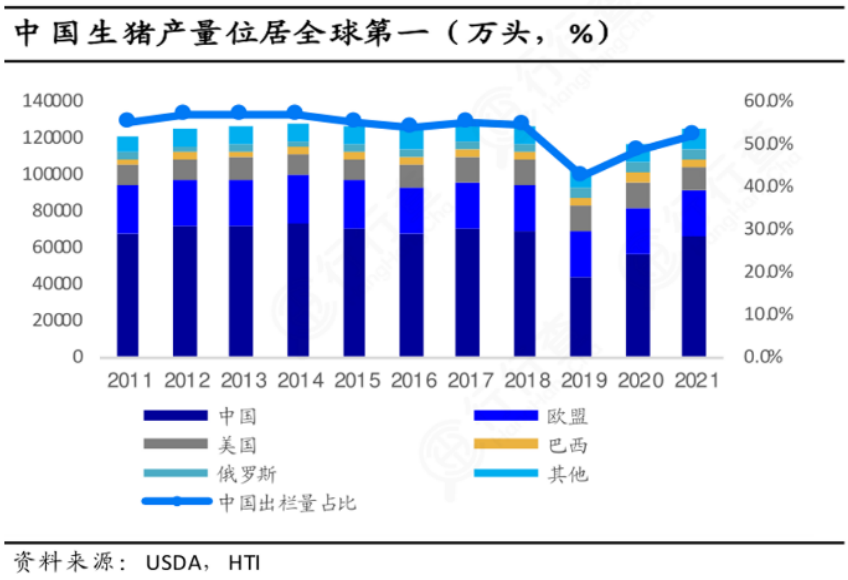


图 1-1 2011-2021 年全球生猪产量分布情况

Figure 1-1 Distribution of Global Pig Production in 2011-2021

猪肉是我国第一大肉类消费品，根据国家统计局和华西证券研究所对国内猪肉消费量统计情况，2012-2018 年，中国猪肉消费量维持在每年 5000 万吨以上，2019 年和 2020 年，受非洲猪瘟带来的产能下降和价格上升影响，禽肉和牛羊肉替代效应明显，导致猪肉消费降至 4000 万吨，2021 年，随着产能恢复和生猪价格下降，猪肉消费量重新恢复至 5296 万吨[2]，具体数据呈现如图 1-2 所示，yoy（year-on-year percentage）曲线含义为当期的数据较去年同期变动多少。总而言之，猪肉在我国肉类消费市场比重大，生猪疫病产生与爆发会使猪只出栏量下降，从而造成猪肉总产量减少，国内肉类消费日渐趋向多样化，但猪肉消费总体呈现稳步增长的态势[3]，会导致猪肉价格上升，

中国知网 https://www.cnki.net

生猪养殖大有可为。



图 1-22012-2021 年国内猪肉消费量

Figure 1-2 Domestic Pork Consumption in 2012-2021

生猪养殖过程中疫病防控对养猪业健康发展是至关重要，生猪疫病产生与爆发容易给养猪业带来如下影响：其一是生产效率下降，生猪疫病的发生会导致养殖场的生猪死亡率增加，从而影响到养猪业的生产效率，产生较大的经济损失；其二疫苗、消毒用品等使用量增加造成防控成本增加，为了保证生猪的健康，养殖场需要采取一系列的防疫措施，包括疫苗接种、环境卫生等，这些措施的实施需要增加一定的成本，对养殖场的经营造成负担；其三是养殖场规模变化，国内目前生猪散养户占比较高，受生猪疫病影响，将直接导致部分小规模散养户面临倒闭；其四猪肉价格波动与市场信心受挫，生猪疫病的发生会影响生猪市场的供需关系，导致猪肉价格的波动，如果生猪数量减少，市场供应不足，价格可能上涨，而如果生猪疫病突然大面积爆发，则会导致生猪供应过剩，价格可能下跌，如果疫情持续恶化，市场可能会出现猪肉抵制现象，从而进一步影响生猪养殖业的发展，所以生猪养殖疫病防控是当前养猪业健康发展需要研究的重点与热点。

一方面猪肉需求量的逐年稳步提升，另一方面针对现阶段生猪养殖过程中有关疫病防控、产能增长、控制成本等需求，使得我国生猪养殖模式正加速向规模化、集约化、智能化方向推进，但在提升生猪产能、降低养殖成本的同时也带来了一些挑战——规模化、集约化的养殖导致了猪只养殖空间缩小，养殖密度变大，使得通风情况趋

中国知网 https://www.cnki.net

向糟糕，加剧了猪只患呼吸道病的产生风险以及疫病爆发可能性。猪呼吸道病是生猪养殖业养殖效率下降的主要原因[4,5,6,7,8]，已成为各大养猪场最常见、危害最严重的疾病之一，其传染性较强，危害性较大，在养殖过程中极易会造成大范围的流行，从而对整个区域的生猪养殖造成较大的危害[9]。因此，在密集化的生猪养殖场中对猪只进行呼吸道病的检测与预防是至关重要。近年来我国各级政府部门也都相继出台了诸多关于生猪疫病防控与稳产等相关政策，如图 1-3 所示，该图为部分政策时间流图，主要介绍了政策时间、发布单位以及政策文件名称，政策具体内容如下。

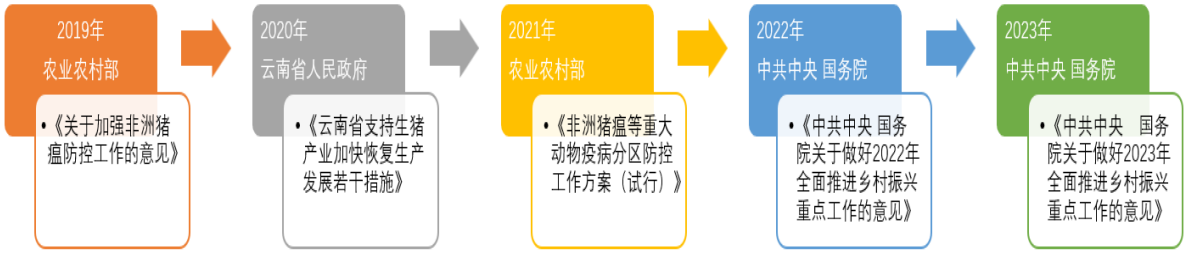


图 1-3 生猪产能与疫病防控等相关政策情况

Figure 1-3 Pig Production Capacity, Epidemic Prevention and Control and Other Relevant Policies

2019 年，《关于加强非洲猪瘟防控工作的意见》文件提出，制定实施分区防控方案，降低疫情跨区域传播风险，加强疫病监测预警方面的科学研究和技术支持力度[10]；2020 年，《云南省支持生猪产业加快恢复生产发展若干措施》文件提出，加快推进规模化养殖场建设，对生猪养殖过程中疫病防控等农机装备做到应补尽补[11]；2021 年，《非洲猪瘟等重大动物疫病分区防控工作方案（试行）》文件提出，分步完善实施生猪跨区、跨省“点对点”调运政策，必要时可允许检疫合格的生猪在大区间“点对点”调运，加强生猪疫病在运输环节中的传播的防控[12]；2022 年，《中共中央国务院关于做好 2022 年全面推进乡村振兴重点工作的意见》文件提出，稳定生猪生产长效性支持政策，稳定基础产能，防止生产大起大落，强化监测预警，适时调控基础产能，切实稳住生猪生产，确保非洲猪瘟防控[13]；2023 年，《中共中央国务院关于做好 2023 年全面推进乡村振兴重点工作的意见》文件提出，一是落实生猪稳产保供，强化以能繁母猪为主的生猪产能调控，二是健全基层动物疫病监测预警网络，抓好非洲猪瘟等重大动物疫病常态化防控和重点人兽共患病源头防控，三是推进畜禽规模化养殖场改造升级[14]。

中国知网 https://www.cnki.net

1.1.2 研究意义

猪呼吸道病是对猪呼吸系统疾病的统称，是危害全球养猪业的一类主要传染病，可引起猪只产能下降，导致养猪成本增加，经济效益降低，给养猪业造成重大经济损失。猪呼吸道病主要表现为呼吸道症状，具体为咳嗽、喘息、呼吸困难等症状[15]，猪只咳嗽往往是呼吸道病最常见、最明显的临床症状之一，且已被证明与呼吸系统病具有极高的相关性[16,17]。因此，可以通过对猪只咳嗽声的监测来进行猪只患病状况的判断。

传统猪咳嗽声监测方式主要由饲养员人工蹲点监测记录，这种方法简单易行，但存在着一些缺点，首先传统猪咳嗽声监测方式违反了生物安全防控规定，因为人工检查需要进入猪舍，很容易传染疾病，增加了病害的风险；其次，传统猪咳嗽声监测方式存在人为误判的问题，因为人对声音的判断受到主观因素及经验的影响，会出现误判[18]；此外，传统监测方式无法在全天候、全时段内对猪只声音进行监测，会漏检一些异常情况，且人力成本过大；加之，因呼吸道病的传播性强，当出现猪只患病情形，饲养员无法在第一时间采取隔离，密集养殖环境下极容易引起群体性感染，进而影响生猪出栏率[19]。总体而言，传统猪咳嗽声监测方式对生猪养殖产业的健康发展有一定的影响。

为了解决这些问题，基于现代信息技术的猪只智能声音监测方式应运而生，这种监测方式采用了人工智能、物联网、无线互联网、大数据等技术，利用智能算法对猪只声音进行监测，与传统方法相比，它具有以下优点：首先，利用物联网和无线互联网技术，可以实现完全遵守生物安全防控规定，相关人员不需要进入猪舍，有效减少疫病的传播风险；其次，利用人工智能和大数据分析技术，能够实现全天候、全时段内对猪只声音的监测，及时掌握猪只的状态和异常情况，提高养殖场的管理效率；最后，智能声音监测不受人为经验的影响，减少误判的可能性，提高监测数据的准确性。

综上所述，在规模化、集约化的生猪养殖场，通过饲养员人工监测记录猪只咳嗽声来判断猪只是否患呼吸道病的手段已无法确保猪只安全生长，同时会增加人畜共患病的感染风险，因此，探寻安全、便利、准确的猪只呼吸道疾病智能监测的手段来代替传统监测方式是目前生猪智慧养殖中有关疫病防控研究的热点和重点之一，有望进一步推动养殖业的转型升级，为保障食品安全和提高养殖效益做出贡献。

伴随智慧农业的推进，生猪智慧养殖技术在机器学习、物联网等新一代信息技术

中国知网 https://www.cnki.net

的融合下逐步兴起[20,21]，人们对动物状态信息数据的获取能力得到了提升，实现了对动物无接触式、高准确性的生理健康状况监测[22,23]。因此，将智能语音处理技术运用到猪只声音监测，实现猪只呼吸道病自动化、智能化监测具有良好技术背景，该方法对猪只呼吸系统病提供了必要的早期预警，有助于降低生猪养殖中料肉比水平（生猪料肉比 FCR 是衡量生猪饲养效率的指标，是指在同一饲养条件下所消耗的饲料重量与生长出的肉重之比），患病猪只与健康猪只在相同分量饲料摄入情况下，患病猪只长肉缓慢[24]；除此以外，减少猪只疫病可以提高猪只的生产效率和养殖效益，助于加速生猪养殖业的科学健康发展。从消费者的角度来看，猪只疫病减少对于食品安全和健康也是非常重要，猪只疫病较多，养殖场可能会使用大量抗生素和药物来控制疫病，这会导致养殖产品中残留药物的含量增加，对消费者的健康造成潜在威胁，且猪只疫病带来的猪肉供需结构改变，易加剧消费者消费压力。

本文研究受资助于云南省重大科技专项“云南省猪重要疫病防控技术体系构建及应用”（项目编号为：202102AE090007）。该项目的第四个课题是借助物联网、大数据、云计算、人工智能等技术，首先对生猪养殖环境进行实时监测，感知生物体征状态变化及生猪的运动轨迹；其次采用数据建模的方式，结合环境参数变化、生猪体温数据、行为检测、声音监测分析结果等作为关键参数，构建有效的算法，建立生猪健康模型；最后通过机器学习算法，不断优化模型和数据，构建针对生猪的疫病智能监测预警标准体系模型，旨在创建一套生猪健康状况评判模型，有效针对生猪疫病进行超前防范预警，最大程度上避免生猪疫病带来的损失。本文的研究工作是从猪只声音监测及分类的角度出发，构建基于智能语音技术的猪只声音分类模型，为猪只咳嗽声监测及猪只呼吸道疾病预警奠定基础。

1.2 国内外研究现状

通过人工智能、物联网、大数据等新一代信息技术在生猪疫病防控中进行广泛应用，可以提高防疫工作的效率和精准度。研究人员通过物联网设备对养殖场猪只进行声音数据采集，使用音频处理技术对猪只声音进行加工处理，构建基于智能语音技术的猪只声音监测模型，有利于生猪早期呼吸道病发现，改善生猪养殖中料肉比水平，提高出栏率，进而增长了养殖户经济收入。下面对相关国内外研究现状与发展趋势进行阐述。

中国知网 https://www.cnki.net

1.2.1 国外研究现状

国外学者对通过猪只声音信息监测去掌控其生理健康状况的研究起步较早，早在上个世纪八十年代末，JF Robertson 等人研发了一种在线猪只咳嗽声计数器，但受限于生猪养殖环境中其他声音的影响，使得咳嗽声识别准确率不高[25]。Berckmans 等人于 2004 年通过对猪只声音信号进行时域和频域的特征分析，提出了用欧氏距离平方的方法来检测猪咳嗽声音，实现了健康猪和患咳嗽症状病猪的分类，对畜禽的疾病监测有一定的意义[26]。V.Exadaktylos 等人于 2008 年提出了一种实时识别病猪咳嗽音的方法，对猪只声音信号进行频域特性分析，并改进提取特征方法，评估模糊 C 均值聚类在部分训练中的效果，并提供了能反映猪只咳嗽声特征的频率内容作为参考，猪咳嗽声的正确分类率为 85%，实现了猪咳嗽声音信号的分类[27]。Mitchell 等人于 2009 年研究了比利时长白与杜洛克仔猪杂交的咳嗽声，把多杀巴斯德杆菌感染的病猪和柠檬酸诱导的健康猪只作对比，发现两种咳嗽声的短时能量动态变化具有差异性，多杀巴斯德杆菌感染的病猪咳嗽的平均持续时间为 0.30s，柠檬酸诱导非感染咳嗽的平均持续时间为 0.21s[28]。韩国高丽大学与庆尚国立大学 Daihee Park 等人于 2013 年对三种原因引起的生猪咳嗽声进行识别分类，通过对猪声音信号进行 Mel 频率倒谱系数提取，并用支持向量数据描述和稀疏代表分类器作为检测器与分类器，对患有不同疾病的猪声音信号进行分类识别，实现了对应疾病与不同声音信号的匹配，分类准确率为 91%，这为养殖场猪的患病状况提供了有效参考[29]。韩国高丽大学 Chung Y 等人于 2014 年介绍了一种基于视频传感器的猪舍监测系统，该系统可以对猪舍内的声音进行实时监测，并将咳嗽声与其他声音进行区分，进而提供猪只健康状况的监测和预警[30]。Vandermeulen 等人于 2015 年探究了猪嚎叫声的功率、高频分量以及持续时间等时频特征与猪舍中其他声音的相同时频特征的区别，并以此为基础实现了一种基于时频特征和显示规则的猪嚎叫声检测方法[31]。Amit Banerjee 等人于 2019 年通过改进的谱减法算法对声音数据进行了降噪处理，提取了梅尔倒谱系数（MFCC）和子带谱质心（SSC）作为复合特征参数，使用支持向量数据描述（SVDD）来检测声学数据中的异常声音，构建反向传播神经网络（BPNN）对猪只的五种异常声音进行分类，实验结果表明，该系统的平均识别准确率分别为 95.4%[32]。Pessoa J 等人于 2019 年研究了自动记录猪只呼吸困难的声音信号与屠宰场检测到的肺部病变的关系，研究采用声学传感器记录猪只的咳嗽声和喘息声，并将数据与屠宰场的肺部病变结果进行比对，研究结果表明，声音信号监测

中国知网 https://www.cnki.net

可以有效地识别出猪只的呼吸困难状况，并与肺部病变结果有着显著的相关性[33]。TuomasOikarinen 等人于 2019 年阐述了一种端到端前向卷积神经网络，能够在嘈杂的环境中可靠地分类动物鸣叫声的来源和类型[34]。Nanni Loris 等人于 2020 年，提出了一种利用 Siamese 神经网络和聚类技术训练 SVMs 的动物音频自动分类方法，在两个动物音频数据集上进行评估：一个用于猫，另一个用于鸟类发声，研究成果可应用于多种动物音频数据集[35]。Alam Ahmad Hidayat 等人于 2021 年提取梅尔倒谱系数（MFCC），构建了卷积神经网络对鸟类声音进行分类[36]。Zachary J. Ruff 等人于 2021 年构建了基于声学特征的深度学习方法，去自动检测适应森林的鸟类和哺乳动物，达到较好识别结果[37]。Dae-Hyun Jung 等人于 2021 年提取梅尔倒谱系数（MFCC），构建卷积神经网络对牛声进行分类，并搭建了基于 web 的传感器数据获取平台[38]。Bravo Sanchez Francisco J 等人于 2021 年利用 SincNet 神经网络从原始声音波形中学习，实现了高效的动物声音分类，具有较高的精度和效率[39]。

1.2.2 国内研究现状

国内在规模化、自动化养殖方面的进程起步较晚，国外养殖的科技水平和生产管理能力都暂时优于我国，但近些年随着国家对智慧养殖推广力度的不断加强和养殖企业不断深化改革与资金补助加持，瞬速加快了我国规模化、自动化、智能化养殖进程，推动了猪只声音监测研究的发展，使得国内也有了越来越多的学者利用智能语音技术开展猪只声音监测研究，下面是对国内近五年相关研究进行的阐述。

龚永杰等人于 2018 年采集了长白猪的声音信息，并采用预处理、特征提取、识别模型构建等方法对数据进行处理，实现了猪咳嗽声的自动识别，主要构建了 VQ、SVM 和 HMM 识别模型，其平均识别率分别为 75.18%、85.11%、89.38%，通过对识别模型优化研究，使得平均综合识别率达到了 94.21%，研究结果表明，该方法能够有效地自动识别猪只的咳嗽声，为猪只健康管理提供了新的技术手段[40]。

王小帅等人于 2019 年采集了 84 只断奶仔猪的咳嗽音和四种重要的空气因素，即空气温度、相对湿度、氨浓度和粉尘浓度，采用梅尔倒谱系数（MFCC）、主成分分析（PCA）和支持向量机（SVM）融合模型对不同猪舍采集的声音样本的平均识别率达到 95%，结果表明，猪只咳嗽声分析可以为畜禽舍空气质量状况提供定性信息[41]。

王文静等人于 2019 年采集了猪只声音数据，利用预加重、分帧加窗、端点检测对数据进行预处理，并利用特征提取和集成学习算法构建了高效的猪只声音识别模型，

中国知网 https://www.cnki.net

与 SVM 模型相比，集成学习算法表现更优；针对异常声音识别率的问题，提出了 CNN 结合语谱图的猪只声音识别模型，最终识别率达到了 97.3%，可满足实际应用需求，有助于提高生物安全防控能力[42]。

赵建等人于 2019 年对 5 只正常和 5 只经兽医判定患呼吸道疾病的猪只进行声音信息数据的采集，构建了两类猪只声音识别系统，其中一类是基于深度信念网络的孤立词猪咳嗽声识别系统，另一类是基于双向长短时记忆网络的连续猪咳嗽声识别系统；通过特征参数维度优化和主成分分析法，猪咳嗽声识别率提高 1.68%，误识别率降低 0.62%，最终，两种系统的总识别率分别为 93.21%和 93.24%[43]。

韩磊磊等人于 2019 年对猪只声音数据进行采集，利用预加重、分帧加窗、端点检测对数据进行预处理，提取了四类特征参数，发现以 MFCC 及其一阶差分系数作为特征参数时识别效果最佳，搭建了 SVDD 和 SVM 模型，结果表明平均识别精度在 94%以上，平均查准率和平均查全率也都在 91%以上[44]。

苍岩等人于 2020 年对“三元猪”进行声音信息数据采集，对其进行预加重、分帧加窗、端点检测等预处理操作，提取预处理后声音数据的语谱图，利用 MobileNetV2 网络对猪只声音进行识别与分类，通过与支持向量机、随机森林、梯度提升决策树、极端随机树 4 种模型进行对比，验证了算法的有效性，异常声音分类识别精度达到 97.3%，该方法能够有效地达到异常声音分类效果[45]。

涂鼎等人于 2020 年采集猪只声音数据，对 8 只已确诊且频繁咳嗽的猪只进行研究。通过预处理和特征提取，构建了两种猪只咳嗽声识别模型。其中一种模型融合了梅尔频率倒谱系数及其一阶差分系数特征，准确率达到 97.81%。另一种基于语谱图的模型准确率为 94.76%。研究结果表明，对猪只声音数据进行预处理和特征提取能够提高猪只咳嗽声识别的准确率和精度[46]。

张海林等人于 2020 年采集了 5 只正常和 5 只患呼吸道疾病的梅山猪声音数据，通过预处理和特征提取，构建了以 MFCC 为输入的 SVM、SRC、LDC 及 LS-SVM 四种猪只咳嗽声识别分类模型，实验结果显示 LS-SVM 分类算法识别性能最优，识别准确率为 86.77%，针对连续的猪只声音信号数据，引入了 BLSTM-CTC 声学模型，对比分析后，BLSTM-CTC 声学模型整体上优于 LS-SVM 模型[47]。

李江丽等人于 2020 年采集猪只声音数据，对其进行谱减法去噪和分帧加窗等预处理，提取声音信号的梅尔频率倒谱系数及其一阶差分，构建了基于支持向量数据描述

中国知网 https://www.cnki.net

（SVDD）的猪只咳嗽声识别模型，结果表明:生猪咳嗽声识别方法的总识别率可达87.3%，利用相位变换算法计算麦克风信号之间的到达时间差值，并结合麦克风的几何位置得到声源位置估计值，最后得到的平均距离误差为0.52m[48]。

耿艳利等人于2021年采集了“长白猪”声音信息数据，利用谱减法进行去噪操作，使用预加重、分帧加窗、端点检测进行预处理，提取了梅尔谱图特征，搭建了基于卷积神经网络（CNN）的猪只声音分类模型，引入了注意力机制对卷积神经网络进行优化，实验结果表明，最优识别准确率达到94.46%[49]。

熊梓奥等人于2021年采集了猪只声音数据，利用归一化、预加重、分帧加窗等进行预处理，提取了猪只声音特征参数，构建了基于LSTM网络单元的端点检测模型和基于AM-GRU和MFCC的猪咳嗽声识别模型。模型采用注意力机制优化，解决了低信噪比下的性能缺陷和声音信号长度不一致问题[50]。

宋航等人于2022年对“长白猪”进行声音数据采集，并进行预处理，包括语音增强和端点检测，提取了MFCC特征参数，建立了基于DenseNet系列的猪只咳嗽声识别模型。经过对比研究发现DenseNet-121模型的识别效果最佳，猪只咳嗽声准确率为90.9%，识别时间为0.019s，这一研究为猪只健康监测提供了新的方法和技术支持[51]。

沈明霞等人于2022年采集了5只正常和5只患呼吸道疾病的梅山猪声音数据，通过谱减法进行去噪，提取了logFbank和MFCC两种特征参数，建立了基于CNNs的猪只咳嗽声识别模型。实验结果显示，以MFCC为特征的CNNs猪只咳嗽声识别模型准确率为97%、召回率为96%、F1值为98%，总体识别准确率为96.71%，且效果最佳。此外，验证了不同迭代次数对二分类模型结果影响最大误差率不会超过4%[52]。

孙浩楠等人于2022年采集了舍养猪只声音信号数据，利用预加重、数字滤波、端点检测技术进行了数据预处理，进行了声音信号的特征提取，分别构建了人工神经网络(ANN)、支持向量机(SVM)、动态时间规整（DTW）的猪咳嗽声识别模型并进行了模型优化，最后平均识别率达到85.17%，证明了该识别系统的有效性[53]。

综上所述，国内外研究学者对猪只声音监测在疫病防控中开展了一些研究，通过声音信号的采集、处理和分类，实现了一定的疫病监测与预警目的，这些研究成果不仅提高了生猪养殖的生产效率和经济效益，也为疫病防控提供了一些新的技术手段，一定程度上促进了养猪业的健康发展，但研究也存在一些不足。首先，在当前国内外研究中，有些研究者在获取生猪声音数据时，人为改善采集环境，脱离了实际猪舍，

中国知网 https://www.cnki.net

导致将研究成果应用于实际环境中，由于噪声干扰的种类、强度都比原有实验环境多和强，研究的成果无法推广使用；其次，由于在猪只声音监测研究方面暂时没有公开且官方认可数据库[54]，目前的研究中，均是研究者自己采集的数据，导致声音种类较少，用于研究的数据量种类不全、数量不大，也会导致研究成果普适性不足，继而推广受到影响。针对以上问题，本研究数据均来源于实际规模化生猪养殖基地，全天 24 小时设备在线监测数据，在数据采集方面不做特定选择，将实际猪舍生产中产生的各类声音均进行收集，尽可能改善研究普适性不足的问题。

1.3 研究内容

本研究以三元猪、长白猪两类猪只作为研究对象，通过录音设备采集猪只声音数据，利用语音处理技术对原始猪只声音数据进行预处理操作，提取并对比分析了猪只声音的不同特征参数提取方式，建立不同声音分类模型，对猪只声音进行分类研究，并对最佳猪只声音分类模型进行优化，以期为其它同类研究提供参考。

本文的主要研究内容如下：

（1）开展猪只声音数据采集研究。首先进行文献资料查询、猪场实地走访调查、咨询专家，了解实际开展研究的环境条件，例如猪舍外部环境、猪舍内部构造（包括猪栏分布、电路铺装、网络信号、排风设备与粪便清理设备位置等）、猪只基本状况与生活习性、饲养人员日常管理模式等。研究中，我们选择了三处采集地点，对猪只日常声音数据进行了采集，并依据数据采集情况进行了适当调整。

（2）开展猪只声音数据预处理。对原始声音段进行样本标注与切割，得到不同类别猪只声音数据，主要包括猪只哼哼声、呼噜声、吃食声、饮水声、咳嗽声五类声音，对目标样本进行数据预处理，预处理包括预加重、分帧加窗以及滤波降噪。

（3）开展猪只声音信号特征提取研究。对预处理好的猪只声音样本进行特征参数提取，包括时域中的短时能量与短时过零率、频域中的功率谱密度、时频域中的语谱图以及倒谱域中的梅尔倒谱系数，对各类方法提取的特征进行分析，选择适合本次研究的特征参数作为声音分类模型的特征参数。

（4）开展猪只声音分类模型研究。基于 MFCC 的特征数据输入，构建了支持向量机（SVM）、隐马尔科夫模型（HMM）、长短期记忆网络（LSTM）以及长短期记忆网络改进模型 LSTMP 对待识别样本进行分类，对分类结果进行对比分析，选取最优分类模型。

中国知网 https://www.cnki.net

（5）开展猪只声音分类模型优化研究。基于最优分类模型 LSTMP，进行智能模型优化，优化算法分别为鲸鱼优化（WOA）、粒子群优化（PSO）以及量子花朵授粉优化（QFPA），分别搭建了 WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 优化模型，对猪只声音分类，通过结果分析确定猪只声音分类的最优模型。最终设计并实现一个猪只声音分类可视化界面。

1.4 技术路线

根据上述的研究内容，制定了本次研究的技术路线，如图 1-4 所示。

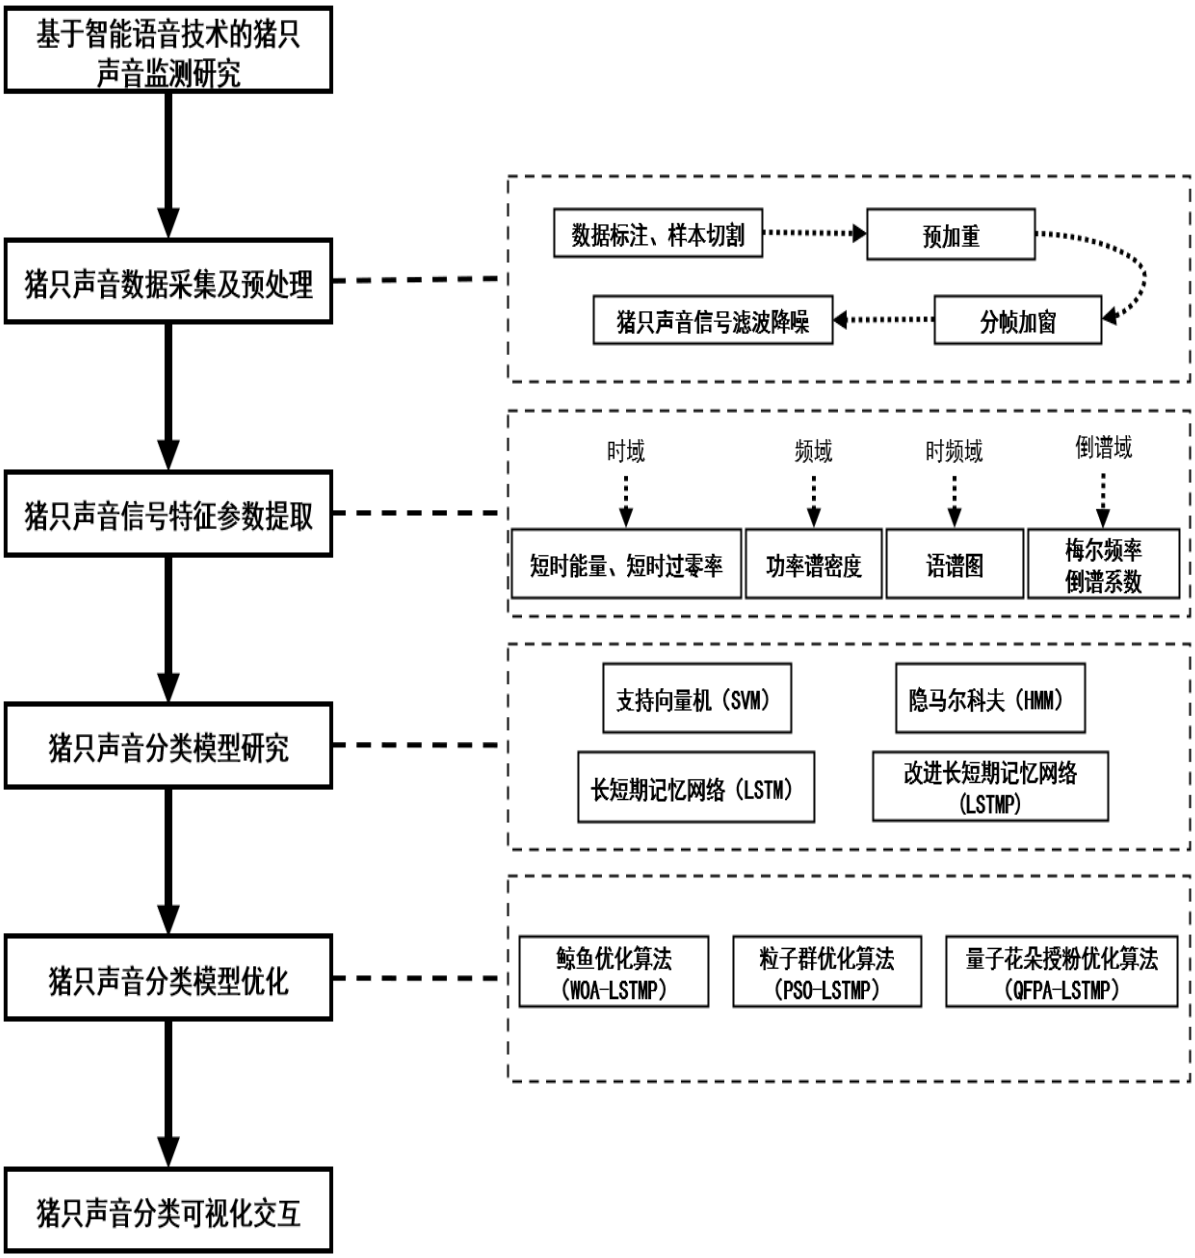


图 1-4 技术路线图

Figure 1-4 Technical Roadmap

中国知网 https://www.cnki.net

1.5 论文组织结构

本文具体章节结构如下：

第一章，绪论。详细阐述了本研究的课题来源、研究背景以及研究意义，然后概述了国内外研究学者对猪只声音监测研究，阐述了本文的研究内容、技术路线，最后介绍了本文组织结构。

第二章，猪只声音智能监测的相关理论。对猪只呼吸道系统疾病进行概述，对语音分类技术进行了介绍，包括语音数据预处理（语音分类前端技术）、语音数据特征提取以及语音分类模型。

第三章，猪只声音数据采集及预处理。首先阐述了猪只声音信号采集流程，对猪只原始声音数据种类及来源进行了介绍，然后讲述了原始声音数据标注与切割的过程，最后对研究中的猪只声音数据进行预处理，包括预加重、分帧加窗以及滤波降噪。

第四章，猪只声音信号特征参数提取。首先对猪只声音特征参数提取方法进行概述，然后依次研究了时域特征参数提取（短时能量与短时过零率）、频域特征参数提取（功率谱密度）、时频域特征参数提取（语谱图）、倒谱域特征参数提取（梅尔频率倒谱系数），最后对提取的特征参数结果进行分析，选择本次研究所选用的特征参数。

第五章，猪只声音分类模型研究。基于梅尔频率倒谱系数(MFCC)特征数据输入，构建支持向量机模型（SVM）、隐马尔科夫模型（HMM）、长短期记忆网络（LSTM）以及改进的长短期记忆网络（LSTMP）分别对样本进行分类，对四个模型的结果对比分析，选取最优分类模型。

第六章，猪只声音分类模型优化。根据最优分类模型 LSTMP，对模型选用了三种优化算法，并搭建了 WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 进行模型优化的组合，最后对优化后的结果进行比较分析，选取最优优化模型组合。

第七章，总结与展望。对全文研究工作进行总结概括，介绍猪只声音分类可视化界面的实现，同时针对后期工作提出了构想。

中国知网 https://www.cnki.net

第二章猪只声音智能监测的相关理论

2.1 猪只呼吸道系统疾病简介

当前我国生猪养殖正向规模化、集约化模式加速前进，生猪养殖规模持续扩大，在生猪养殖过程中疫病的发生几率有所提高，给生猪的正常生长发育造成了严重影响[55]。猪只呼吸道系统疾病是生猪养殖领域发生流行率相对较高的综合性传染性疾病，与猪只养殖周期和品种无关，任何年龄段、任何品种均能够发生，诊断和治疗难度较大[56]。猪只呼吸道系统疾病发病原因主要分为两个大类，其一是传染性因素感染，其二是非传染性感染，传染性因素主要包括病毒性传染、细菌性传染以及寄生虫三类，非传染性感染主要以人为因素和环境因素为主[57]。猪只呼吸道系统疾病的发病病因相对复杂，可能由单一因素引起，也可能是混合型感染，但是猪只呼吸道系统疾病在发病临床症状上具有相似性，其主要特征为咳嗽与气喘。

我们通过查阅国内外文献资料，与云南农业大学动物医学院专家研讨，总结了猪只常见呼吸道系统疾病的病症表现，如表 2-1 所示。

表 2-1 猪只常见呼吸道系统疾病的病症表现

Table 2-1 Symptoms and Manifestations of Common Respiratory Diseases in Pigs

疾病名称	病因类型	病症表现	其他
猪繁殖与呼吸障碍综合症（蓝耳病）	病毒性感染	妊娠母猪：咳嗽、体表发热、厌食和流产、木乃伊、死胎、弱仔； 仔猪：咳嗽、体温升高达 40℃以上、呼吸困难、食欲减退或废绝、腹泻、被毛粗乱、后腿及肌肉震颤、共济失调、渐进消瘦、眼睑水肿；	死亡率 60%～80%
猪圆环病毒病	病毒性感染	咳嗽、呼吸困难、逐渐消瘦。	死亡率 10%～30%
猪流行性感冒	病毒性感染	咳嗽、突然发热、呼吸困难、体温升高至 40～42℃、食欲废绝或减退、精神极度委顿、卧地不起、眼鼻流粘性分泌物。	死亡率 4%～10%
猪伪狂犬病	病毒性感染	咳嗽、体温升高至 41～41.5℃、精神沉郁、不吃、口角有大量泡沫或流出唾液、眼睑和嘴角水肿、呕吐或腹泻、肌肉震	死亡率 10%～20%

中国知网 https://www.cnki.net

		颤、运动障碍。	
非洲猪瘟	病毒性感染	咳嗽、心跳加快、呼吸困难、眼和鼻有浆液性或粘液性脓性分泌物、皮肤发绀。	急性死亡100%，慢性低于30%。
猪传染性胸膜肺炎	细菌性感染	阵咳且咳嗽粗吼、呼吸困难。	死亡率40%左右
猪链球菌病	细菌性感染	咳嗽、关节肿大、跛行等、体温高达42.5℃以上。	死亡率80%左右
猪肺疫	细菌性感染	咳嗽、分娩样呼吸(腹部突然收缩)、咽喉部极度肿胀、呼吸极度困难虚脱、高热(通常在42.2℃以上)。	死亡率50%左右
猪肺炎霉形体病（支原体肺炎、猪喘气病）	介于病毒与细菌之间的特殊病原体	咳嗽和喘气、病猪精神沉郁、呼吸加快、呈腹式、犬坐式呼吸、严重时张口呼吸、气喘吁吁。	低死亡率、高传染率
猪弓形虫病	寄生虫性感染	咳嗽、食欲减少或废绝、便秘、耳、唇及四肢下部或有淤血斑、呼吸快，口流白沫。	死亡率约64%
猪蛔虫病	寄生虫性感染	咳嗽、呼吸增快、被毛粗乱。	低死亡率、高传染率
猪肺丝虫病	寄生虫性感染	病猪阵发性咳嗽、呼吸急促、贫血。	死亡率30%左右

从上表可以看出，猪只咳嗽是大多数猪只呼吸道系统疾病重要的临床症状表现，为了及时对猪只呼吸道系统疾病进行监测预警，可以将猪只咳嗽声作为一个重要的监测指标，通过对猪只声音分类与咳嗽声监测可以预防猪只呼吸道系统疾病的爆发、传播以及辅助疾病治疗，提升生猪养殖户的经济效益。

2.2 智能语音分类技术步骤

智能语音技术是一门以声音为研究对象，利用计算机、传感器等数字化工具，收集声音数字信号并分析处理包含于其中的内容，从而获取需要检测目标的技术。智能语音技术主要研究方向包括语音前端处理、语音分类、语音识别、语音合成、声纹识别以及语音情感分析等，这些研究内容涉及了数字信号处理、语言学、声学、人工智

中国知网 https://www.cnki.net

能、情感学、自然语音处理、机器翻译等多门学科。

2.2.1 语音数据预处理

语音数据预处理（语音前端处理技术）是对语音信号进行分析之前，对其进行的预加重、数字滤波、分帧、加窗、端点检测等操作。这一系列操作的目的是为了尽可能减小因发声器官本身和由于采集语音信号设备所携带的混叠、高次谐波失真等因素造成的对语音信号质量的影响，语音信号的均匀和平滑可以保证后续参数特征提取高效，从而提高语音处理的质量，语音前端处理技术内容如图 2-1 所示。



图 2-1 语音前端处理技术内容

Figure 2-1 Voice Front-end Processing Technology Content

由于语音信号的能量在低频处大，高频处较小，会使得高频处信号不明显，造成高频信号传输困难[58]，并且高频部分受到衰减的程度会大于低频部分，所以为了弥补高频声音信号的损失，防止部分声音信息丢失[59]，引入了预加重对信号进行预处理。

由于在进行语音信号识别前首先采取傅里叶变化（FT），将语音信号由时域转换到频域空间，傅里叶变换是针对周期函数的，而语音信号频率是不断变化的，语音信号长时间的特征实际是非周期性，如果将长语音信号直接进行傅里叶变化，那么一般实验需要的近似良好的信号频率将难以获取，但是语音在短时间（约 10-30ms）内变化是平稳的，具有短时平稳性，因此可以将长语音截取为短的片段，进行短时分析，这些短段叫做分析帧[60]，将不定长的音频切分成固定长度小段的过程便是分帧操作。

由于在语音信号获取过程中极易受到噪声和其他干扰影响，在对采集的语音信号进行数模转换后，这些噪声和干扰会降低系统的性能，甚至会直接影响最后的实验结果，为了抑制各类噪声与干扰，提高信噪比，数字滤波技术也引入预处理的步骤中[61]。

由于分帧结束后每一帧的开始和结束都会出现间断，因此被分割的帧越多，与原始语音信号的误差就会越来越大。为了使分帧后的信号变得连续，每一帧都呈现出周

中国知网 https://www.cnki.net

期函数的特性，所以引入了加窗操作来解决这个问题。

由于携带有噪音的语音中包含多种片段：语音段、静音段、过渡段、噪声段等，需要准确的定位出语音段的开始点和结束点，所以预处理步骤中也引入端点检测来解决这个问题，端点检测完成后可以有效减少数据运算量和降低噪声干扰[62]，为后续语音处理也提供了极大帮助，但本文研究中采取人工进行样本标注和切割，故不需要进行端点检测处理。

2.2.2 语音信号特征提取

语音信号特征提取的本质是对声音信号进行一系列数学方法处理，去除不需要的信息，保留感兴趣的信息的过程[63]。在语音信号中，声音的特征参数是多样的，不同的信号呈现出的声学物理特征不一样，特征提取目的是根据语音信号波形提取到有效的声学特征，尽可能避免无效信息对数据处理工作繁杂度的增加和后期对语音分类的影响。

2.2.3 语音分类建模与训练

语音分类模型建立与训练的本质上是音频序列到时间序列转化的过程，即在给定语音输入的情况下，找到概率最大的时间序列。基于贝叶斯原理，可以把语音分类问题分解为给定时间序列出现这条语音的条件概率以及出现该条时间序列的先验概率，对条件概率建模所得模型即为声学模型，对出现该条时间序列的先验概率建模所得模型是语言模型[64]。声学模型实质就是对声学、语音学、环境的变量、说话人性别、口语等因素相互差异性的知识表达，声学模型在整个语音识别的过程中起到极大作用，因为只要机器知晓给定文字序列依次如何发音的，才能顺利和发音词典、语言模型相结合得到较好的分类性能。语言模型是用来预测时间序列产生的概率，目的是建立一个能够描述给定序列在语言中出现的概率的分布，其实质就是根据声学模型输出的结果，给定概率最大的时间序列。语言模型的性能基本取决于语料的质量与体量。

2.3 支持向量机模型

支持向量机（Support Vector Machine，SVM）最早由数学家 Vapnik 等人于 1995 年提出，属于有监督学习算法的一种，主要是用来解决模式识别领域中数据分类问题，SVM 在许多领域都得到了成功的应用，如语音识别、人脸识别、文本自动分类、车辆检测以及地理遥感图像分类等[65,66,67,68,69]，是机器学习中一种非常经典且极受欢迎的算法模型。

中国知网 https://www.cnki.net

SVM 的基本模型是定义在特征空间上的间隔最大的线性分类器，其学习策略就是使分割面的间隔最大，间隔最大使它有别于感知机；SVM 的核技巧使它成为实质上的非线性分类器。基本思路是利用核函数将样本空间投射到多维空间结构中，在多维空间中寻找一种最佳分类面，从而使各个类别的样本数据互相分离并且到分类平面的距离最大，从而解决在低维空间上无法分类的问题[70]。

支持向量机原理如图 2-2 所示，中间的红实线相当于分割线，左右与之平行的两条虚线构成中间的几何间隔，虚线上的样本点就是支持向量点，几何间隔外的样本点的损失 Cost=0，支持向量机只考虑支持向量点的损失，支持向量以外的点（也叫超越几何间隔的点）的损失规定为 0，不对总体损失构成影响。$w^T x+b=0$ 为超平面方程，$w^T x+b=1$ 与 $w^T x+b=-1$ 是与分隔超平面平行的平面，称为支撑超平面，W 为法向量，2d 是两个支撑超平面之间距离，称为间隔，这个间隔是 W 的函数，目的就是寻找这样的 W 使得间隔达到最大。

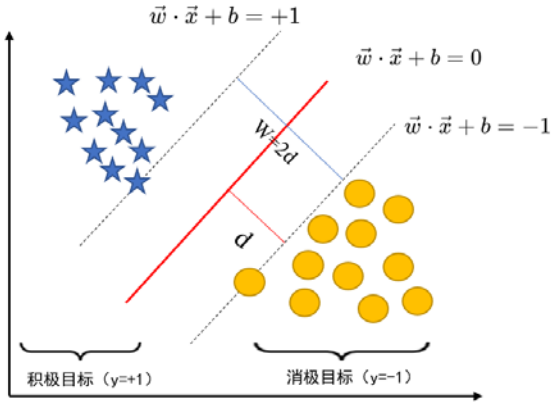


图 2-2 支持向量机原理分析

Figure 2-2PrincipleAnalysis of Support Vector Machine

使用支持向量机进行分类的三个核心步骤为：

①选取一个合适的数学函数作为核函数；

②使用核函数进行高维映射，数据点在映射后由原本的线性不可分变为线性可分。

③间隔最大化，用间隔作为度量分类效果的损失函数，最终找到能够让间隔最大的超平面，分类也就最终完成了。

工程中，需要分类的数据大多是非线性的、不可分的[71]，核函数便是将非线性数据转换成线性数据的重要手段，核函数实质为功能性函数，只要能在支持向量机中完

中国知网 https://www.cnki.net

成高维映射这一功能的数学函数都可以称为核函数，高维映射核心是映射，就是将原样本空间维度进行增加，把不可分的数据变成线性可分，达到最后样本进行分类的效果。

非线性 SVM 的进行分类算法流程如下：

输入：训练集 $T=(x_1,y_1),(x_2,y_2),...,(x_m,y_m)$，其中 x 为 n 维特征向量，$y\in\{-1,1\}$。

输出：分离超平面的参数 w^*,b^* 以及分类决策函数。

首先选择适当的核函数 $K(x,z)$ 和一个惩罚系数 C>0，构造约束优化问题：

$$\begin{cases}\min\limits_{a}\dfrac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j\,K(x_i,x_j)-\sum_{i=1}^{m}a_i\\ s.t.\sum_{i=1}^{m}\alpha_i y_i=0\\ 0\le\alpha_i\le C\end{cases}\tag{2-1}$$

然后使用 SMO 算法求解出最优解 $\alpha^*=(a_1^*,\alpha_2^*,...,\alpha_m^*)^T$，接着找出所有满足 $0<\alpha_s<C$ 对应的 S 个支持向量，对支持向量集合中的每个样本 (x_s,y_s) 通过如下式子（2-2）计算：

$$y_s(\sum_{i=1}^{m}a_i y_i K(x_i,x_s)+b)=1\tag{2-2}$$

计算出每个支持向量 (x_s,y_s) 对应的 b_s^*，即是：

$$b_s^*=y_s-\sum_{i=1}^{m}\alpha_i y_i K(x_i,x_s)\tag{2-3}$$

所有的 b_s^* 对应的平均值即为最终的 b^*：

$$b^*=\frac{1}{S}\sum_{i=1}^{S}b_s^*\tag{2-4}$$

最后构建决策函数：

$$f(x)=\mathrm{sign}(\sum_{i=1}^{m}a_i^* y_i K(x,x_i)+b^*)\tag{2-5}$$

2.4 隐马尔科夫模型

隐马尔科夫模型（Hidden Markov Model，HMM）是一种统计模型，用来描述一个隐含未知量的马尔可夫过程，马尔可夫过程是一类随机过程，它的原始模型是马尔科夫链，它是结构最简单的动态贝叶斯网，是一种著名的有向图模型，主要用于时序数据建模。在语音识别、自然语言处理等领域有广泛应用。

中国知网 https://www.cnki.net

HMM 总结起来就是“1、2、3”，即是 1 个元组，2 个假设，3 个问题。1 个元组指的是 HMM 的结构或要素，一般为一个三元组或者一个五元组，一个 HMM 常用一个 5 元组$\{N,M,\pi,A,B\}$表示，N 表示隐藏状态的数量；M 表示可观测状态的数量；$\pi=\{\pi_i\}$为初始状态概率，代表的是刚开始的时候各个隐藏状态的发生概率；$\mathrm{A}=\{\mathrm{a}_{ij}\}$为隐藏状态的转移矩阵，$N^*N$ 维矩阵，代表的是第一个状态到第二个状态发生的概率；$\mathbf{B}=\{\mathbf{b}_{ij}\}$为混淆矩阵，$N^*M$ 矩阵，代表的是处于某个隐状态的条件下，某个观测发生的概率，五元组比三元组多了一个可能的状态集合 N 和可能的观测集合 M，N 与 M 被认为是两个超参数，不需要训练，所以对于一个 N 和 M 固定的 HMM 来说，用 $\lambda=\{\pi,\mathbf{A},\mathbf{B}\}$ 三元组表示 HMM 参数。

2 个假设指的是 HMM 的齐次马尔可夫假设和观测独立假设，齐次马尔可夫假设实质就是 HMM 的任一时刻 t 的某一状态只依赖于其前一时刻的状态，与其它时刻的状态及观测无关，也与时刻 t 无关，将其用数学公式表示为：

$$P(i_{t+1}=q_i|\ i_t=q_j)=P(i_{t+1}=q_i|\ o_1,o_2,\ldots o_t,i_t=q_j) \tag{2-6}$$

t+1时刻的状态只依赖于 t 时刻的状态，与观测状态无关。观测独立假设实质就是任一时刻的观测只依赖于该时刻的马尔科夫链的状态，与其他观测及状态无关，将其用数学公式表示为：

$$P(o_{t+1}|\ i_{t+1}=q_i)=P(o_{t+1}|\ o_1,o_2,\ldots o_t,i_{t+1}=q_i) \tag{2-7}$$

t+1时刻的观测只依赖于 t+1时刻的马尔科夫链的状态，与其他观测状态无关。

3 个问题指的是 HMM 可以用来解决的三个基本问题——评估问题、学习问题、解码问题。

评估问题，实质为概率计算问题，主要是对某一事务的优劣进行判断，当给定 HMM 的参数、隐含状态、隐含状态数量以及可观察状态序列这几个条件，计算给定可观察状态序列的概率，检测观察到的结果和已知的是否一致。

学习问题，实质为参数估计问题，用已知的可见状态序列去估计 HMM 模型中的参数，使得在给定模型下可见状态序列出现的概率最大。

解码问题，实质为序列可能性问题，给定的可见状态序列下，求其最可能对应的

中国知网 https://www.cnki.net

隐含状态序列。目的在于获取一条最匹配的隐马尔科夫链。

HMM 的基本原理如下：

隐马尔科夫模型可描述为由看不见的隐藏层和看得见的观测层两层随机层构成的一个系统，其中可观测的元素发生的概率由看不见的状态层决定[72]。HMM 在实际应用中，通常使用维特比算法或前向-后向算法进行计算和预测。

2.5 长短期记忆网络

长短期记忆网络(Long Short-Term Memory，LSTM)是循环神经网络（Recurrent Neural Network，RNN）的变体，LSTM 主要应用于文本生成、机器翻译、语音识别、生成图像描述和视频标记等领域包括，与经典 RNN 相比能够有效捕捉到长序列之间的语义关联，缓解梯度消失或爆炸现象；LSTM 模型的核心思想是“细胞状态”，"细胞状态"类似于传送带，直接在整个链条上运行，只有一些少量的线互，信息损失相对较少，如图 2-3 所示，它的核心结构可以分为四个部分去解析：Inputgate（输入门）i_t、Forgetgate（遗忘门） f_t、Outputgate（输出门） o_t、细胞状态 C_t。

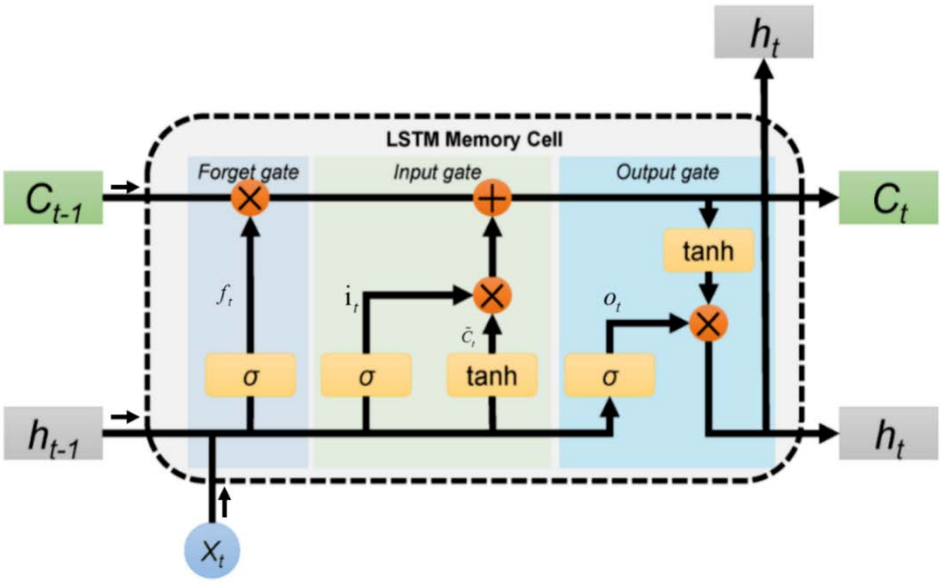


图 2-3LSTM 工作原理

Figure 2-3 Operating Principle of LSTM

在图 2-3 中，每一条黑色粗线都类似传输带进行向量传输，橙色的圆圈代表着一种运算操作，淡黄色矩形代表着学习到的神经网络层。根据 LSTM 工作原理图可知，首先，在 t 时刻 LSTM 有三个输入，分别是细胞状态 C_{t-1}、隐层状态 h_{t-1}、t 时刻输入向

中国知网 https://www.cnki.net

量 x_t；然后，细胞状态 C_{t-1} 的信息，一直在上面那条线上传递， t 时刻的隐层状态 h_t 与输入 x_t 会对 $\mathbf{C}_t$ 进行适当修改，然后传到下一时刻去，C_{t-1} 会参与 t 时刻输出 h_t 的计算，隐层状态 h_{t-1} 的信息，通过 LSTM 的“门”结构，对细胞状态进行修改，并且参与输出的计算；最后，输出两个，分别为细胞状态 $\mathbf{C}_t$ 、隐层状态 h_t 。

LSTM 通过门（gate）结构对细胞状态上的信息进行删除和增加，门实质是一种有选择的让信息通过的结构，由一个 Sigmoid 神经网络层和一个点乘运算组成，Sigmoid 函数常被用作神经网络的激活函数，将变量映射到 0,1 之间，LSTM 包含了三个 Sigmoid 门，用来保护和控制细胞状态（cell state）。

遗忘门（forget gate）主要是决定要从细胞状态中扔掉那部分信息。其原理公式为：

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right) \tag{2-8}$$

遗忘门重点关注于 h_{t-1} 和 x_t，并输出 0-1 之间的数字，并于 C_{t-1} 进行元素乘，1 代表信息完全保留，而 0 代表信息完全扔掉。

记忆门（updating gate）主要是决定从细胞状态中增加某些新的信息，记忆门包括两个部分，其一是 Sigmoid 层，作用是决定什么值是需要更新的；其二是 tanh 层，作用是创建一个新的候选值向量，生成候选记忆。其原理公式为：

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] + b_i\right) \tag{2-9}$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \tag{2-10}$$

在遗忘门中将 f_t 与 C_{t-1} 进行乘法运算，忘记已经不需要的历史信息，然后将 $i_t * \tilde{C}_t$ 加入，完成上下文信息更新。其原理公式为：

$$C_t = f_t * C_{t-1} + i_t * \widetilde{C}_t \tag{2-11}$$

输出门（Output gate）主要是根据细胞状态，确定输出值，首先，计算一个 sigmoid 层用于决定细胞状态中哪些信息用于输出，然后我们使用 tanh 对细胞状态进行元素级运算，映射到(-1,1)之间，然后元素乘于 sigmoid 层的输出，最终我们只输出我们决定输出的部分。其原理公式为：

$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right) \tag{2-12}$$

中国知网 https://www.cnki.net

$$h_t = o_t * \tanh\left(C_t\right) \quad (2\text{-}13)$$

LSTM 有进有出且当前的细胞信息（cell information）是通过 input gate 控制之后叠加的，而经典的 RNN 是叠乘，因此 LSTM 可以防止梯度消失或者爆炸，会比 RNN 更有优势。

2.6 本章小结

本章主要从猪只呼吸道系统疾病、智能语音技术、分类模型共三个部分进行了介绍。首先是猪只呼吸道系统疾病，系统总结了各类猪只呼吸道疾病发病原因、病症等，发现咳嗽是大多数呼吸道系统疾病的共性症状，可以通过对咳嗽声的识别与监测进行猪只呼吸道疾病预警；然后对智能语音处理技术进行了阐述，包括语音信号预处理的前端技术（预加重、分帧加窗、数字滤波降噪、端点检测）、语音信号特征提取技术、语音分类建模与训练；最后是对研究中用到的分类模型进行了具体的介绍，包括支持向量机模型、隐马尔科夫模型、长短期记忆网络，详细介绍了这些模型的原理、模型结构及优势。

中国知网 https://www.cnki.net

第三章猪只声音采集及预处理

3.1 猪只声音采集

本文数据来源于三处采集地点，数据采集使用海康音视频摄像头、联想录音笔搭配博雅麦克风以及信利和远程控制录音设备，采集到的声音数据以波形文件保存，数据存储格式为.wav，具体如表 3-1 所示。

表 3-1 猪只声音信息数据采集情况

Table 3-1 Pig Voice Information Data Collection

试验采集地点	试验猪只品种及猪只状态	试验采集设备	试验采集时间周期
云南省普洱市镇沅县小型生猪饲养基地	三元猪、育肥期	海康威视 C8W400 摄像头	2021 年 11 月-2022 年 1 月
湖北省恩施市白杨坪乡小型生猪饲养场	长白猪、育肥期	联想 D11 录音笔+博雅 M1 麦克风、信利和 F36C-顶配版	2022 年 7 月-2022 年 9 月、2022 年 12 月-2023 年 2 月
云南农业大学后山生猪养殖场	三元猪、育肥期	联想 D11 录音笔+博雅 M1 麦克风、信利和 F36C-顶配版	2022 年 11 月-2022 年 12 月、2023 年 3 月

第一个采集地点为云南省普洱市镇沅县小型生猪饲养基地，猪只品种为三元猪，三元猪是一种由长白种猪、大约克夏种猪和大白种猪杂交而成的猪种，被广泛养殖，该品种生猪在云南省养殖规模较大，养殖范围包括昆明、曲靖、玉溪、普洱、大理等地。本研究三元猪体重约为 70-80kg，猪只处于育肥期，猪只声音数据采集对象已经喂养达三个月，音视频信号数据采集设备为海康威 C8W400 摄像头，分辨率为 2650×1440（400 万像素），数据存储为.MP4 格式，采集完后将音频转换成了 WAV 格式进行存储，设备位于猪舍顶棚中央，以垂直向下的俯视角度对猪舍进行监控，高度距地面约 2.4 米，采集时间周期为 2021 年 11 月-2022 年 1 月。第一个数据采集现场与采集设备如图 3-1 所示。

中国知网 https://www.cnki.net



（a）生猪养殖厂现场采集效果　　（b）海康威视C8W400摄像头

(a) Effect of on-site collection in pig farms　　(b) Hikvision C8W400 camera

图 3-1 第一个数据采集现场与采集设备

Figure 3-1 First Data Collection Site and Equipment

第二个采集地点为湖北省恩施市白杨坪乡小型生猪饲养厂，猪只品种为长白猪，体重约为 70-80kg，猪只处于育肥期，猪只声音数据采集设备为联想 D11 录音笔与博雅 M1 麦克风组合、信利和 F36C-顶配版，录用笔设备位于猪栏饮水吸嘴上端约 0.3 米处、猪栏中心点且距离地面 1.5 米处，信利和远程控制录用设备位于猪栏水泥围墙上，采集时间周期为 2022 年 7 月-2022 年 9 月、2022 年 12 月-2023 年 2 月。第二个数据采集现场与采集设备如图 3-2 所示。



（a）生猪养殖厂现场采集效果

(a) Effect of on-site collection in pig farms





（b）联想D11录音笔、博雅M1麦克风　　（c）信利和F36C-顶配版

(b) Lenovo D11 recording pen, Boya M1 microphone　(c) Xinli and F36C-top configuration version

图 3-2 第二个数据采集现场与采集设备

Figure 3-2 Second Data Collection Site and Equipment

中国知网　https://www.cnki.net

第三个采集地点为云南农业大学后山生猪养殖场，猪只品种为三元猪，体重约为150-170kg，猪只处于育肥期，猪只声音数据采集设备为联想 D11 录音笔与博雅 M1 麦克风组合、信利和 F36C-顶配版，录用笔设备位于猪栏水泥围墙上，信利和远程控制录音设备位于猪栏前方窗户铁栏上且距离地面约 1.8 米处，采集时间周期为 2022 年 11 月-2022 年 12 月、2023 年 3 月。第三个数据采集现场如图 3-3 所示。



图 3-3 第三个数据采集现场与采集设备

Figure 3-3 3 Third Data Collection Site and Equipment

设置三个地点采集猪只声音数据有利于避免单一采集环境和对象造成实验结论缺乏普适性。完成录音设备安装与调试后，采取长期持续不断的数据采集方式进行研究，录音笔录音方式为持续录音，即是不论外界是否有声音信号，录音行为皆不中断，信利和远程控制录音设备的录音方式为声控录音，即是录音行为只发生在外界存在声音信号时候且每 15 秒、30 秒自动切割为独立样本。截至目前，将猪只声音数据截取成15 秒、30 秒的独立样本情况下，共采集到约 100000 个原始样本，统计结果如图 3-4 所示，原始猪只声音样本中含有猪只吃食声、打呼噜声、咳嗽声、哼唧叫声、喝水声五类目标样本以及其他声段，其他声段包括猪只喷嚏声、尖叫声、甩耳声以及猪只撞击猪舍铁栏声等。



图 3-4 原始猪只声音样本总量统计

Figure 3-4 Total Statistics of Raw Pig Sound Samples

中国知网 https://www.cnki.net

3.2 数据标注与样本切割

猪只声音数据采集过程中，样本会受到外部环境干扰，比如饲养人员对猪厂管理过程中掺杂的人声，猪舍风扇、粪便清扫的机械声，猪厂外部周边鸟鸣、蝉叫等非目标生物声音。除此以外，在 15 秒或 30 秒的独立样本中，并不是时时刻刻都充斥猪只声音信号，也存在部分空白的声段。所以，为了从原始猪只声音样本中提取到有效的目标样本信息，对后续研究做准备，需要对原始猪只声音样本进行数据标注与样本切割。

3.2.1 数据标注

本次数据标注工作是使用 Adobe Audition 软件开展的，主要通过人耳对原始猪只声音样本进行分辨并分配相应标签，其中样本中的无声空白片段标注为 Silent，杂声片段标注为 Noise，杂声即是没有含有猪只声音的片段。对原始猪只声音样本进行标注的效果如图 3-5 所示。

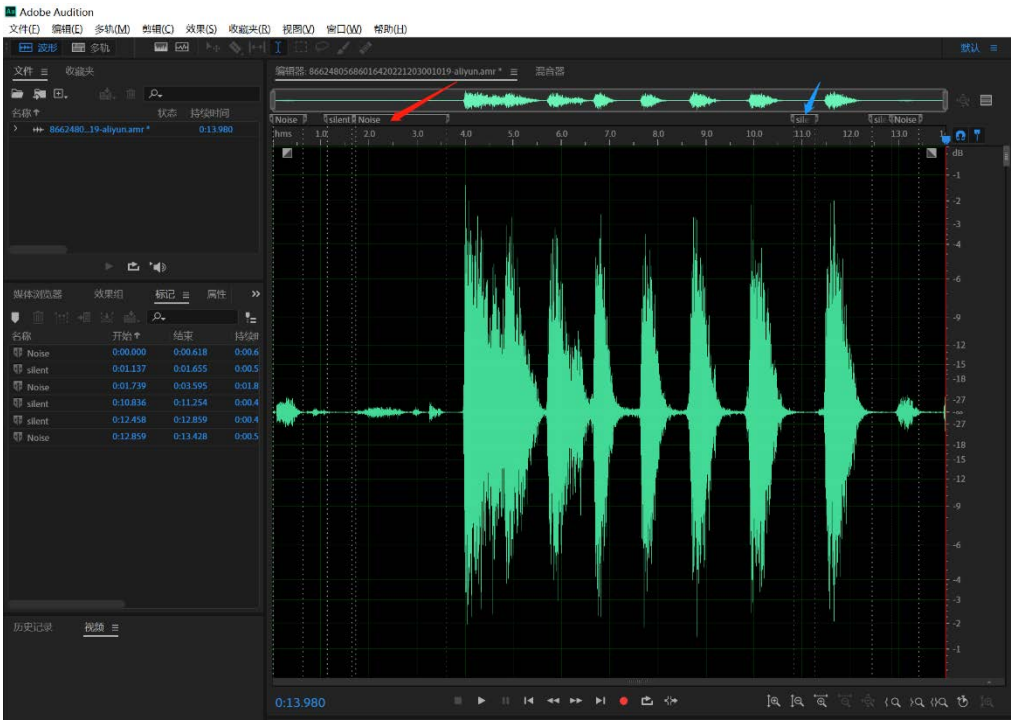


图 3-5 原始猪只声音样本标注效果

Figure 3-5 Labeling Effect of Original Pig Voice Samples

由图 3-5 可知，红色箭头指向杂声片段，蓝色箭头指向无声空白片段，除去标注区域，其他区域为有效样本信息片段。

中国知网 https://www.cnki.net

3.2.2 样本切割

由于一段猪只声音数据中可能存在多种状态下的声音，在样本标注的基础上，为了剥离出有效样本信息片段中不同类别的猪只声音，需要进一步对数据样本进行切割。本次研究中的猪只声音数据样本切割研究是通过云南农业大学动物医学院专业人员指导下进行声音辨别。样本切割使用 Adobe Audition 软件，目的是为了获取猪只吃食声、打呼噜声、咳嗽声、哼唧叫声、饮水声这五类猪只音频的标准声音，通过猪只声音数据样本切割一共获得了猪只吃食声 447 个、打呼噜声 555 个、咳嗽声 719 个、哼唧叫声 504 个、喝水声 609 个，各类音频的原始时域波形图如图 3-6 所示。

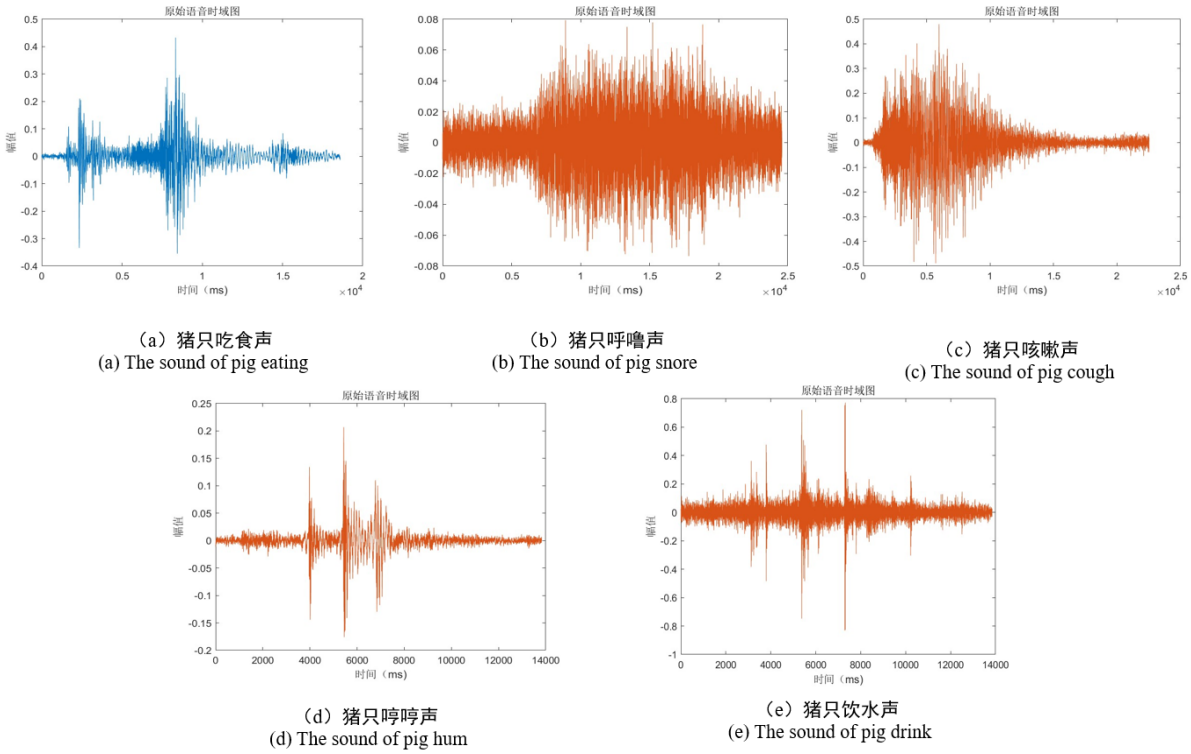


图 3-6 猪只五类音频时域波形

Figure 3-6 Pig Purring Pig Five Kinds of Audio Time Domain Waveform

经过数据采集研究和猪只声音数据样本标注与切割观察，本研究发现研究对象猪只在每天 7：00-19：00 时间段，处于活跃状态。约在 15：00-16：00 时间段，活跃度达到峰值，通常会出现频繁甩耳或互相撕咬、撞击等行为；20：00 之后猪只活动频率将逐渐下降直到处于睡眠状态。饲养员对猪只每天不少于三次喂食，分别为每天 8：00、11：00 以及 17：00。根据对猪只声音样本的反复听取和分析，目标样本集合中声音具有如下特征：猪只吃食的声音分为两种，一种为急促连续吃食时“劈里啪啦”的爆炸声，一种为咀嚼食物时“吧唧”声；猪睡觉打呼噜的声音一般呈现“呼呼呼，呼噜呼

中国知网 https://www.cnki.net

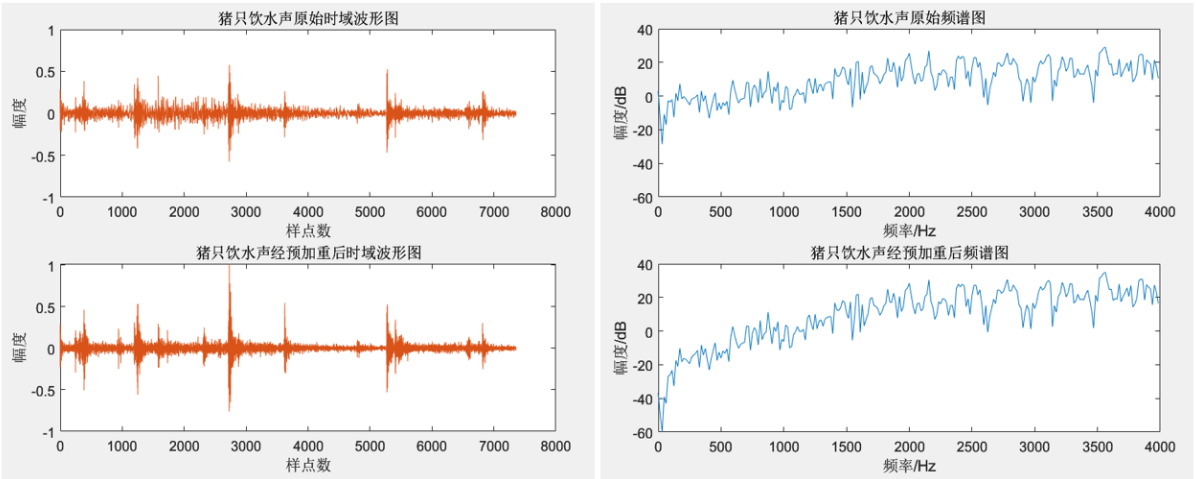
噜”声；猪只咳嗽时候，发出短、急促、爆的“咳咳”声，有时候为连续状态；猪只平时叫声一般呈现为一种“哼唧”声；猪只饮水的声音分为两种，一种为用吸嘴器喝水时候的“吱吱”声，一种为水槽喝水时候的“噗噜”声。完成猪只声音数据标准与样本切割后，研究需要对猪只声音数据进行预处理，本研究猪只声音数据预处理主要包括预加重、分帧加窗以及滤波降噪。

3.3 预加重

由于猪与人的发声原理类似，都是从肺开始，肺作为能量源，气流通过声带，引发周期性震动，能量经过咽、口腔、唇、舌，形成最后的声音，会存在唇辐射效应。口唇辐射对低频影响比较小，但对高频段影响比较大，为了消减这种影响，增强声音信号的高频部分，需要对猪只声音信号进行预加重。假设猪只声音信号的采样原始序列为 $x[n]$，经过预加重处理后的信号 $y[n]$ 如下式表示为：（α 是预加重系数，其取值范围 0.9-1）

$$y[n] = x[n] - \alpha x[n-1] \tag{3-1}$$

本研究预加重是通过高通滤波器完成，猪只的饮水声预加重前后时域波形图与频谱图的对比如图 3-7 所示。



（a）预加重前后猪只饮水声时域波形图对比
(a) Comparison of time-domain waveform of pig drinking water sound before and after pre aggravation

（b）预加重前后猪只饮水声频谱图对比
(b) Comparison of Sound Spectrum of Pig Drinking Water before and after Pre aggravation

图 3-7 预加重前后猪只饮水声时域波形图与频谱图对比

Figure 3-7 Comparison of Time-domain Waveform and Spectrum of Pig Drinking Water Sound Before and After Pre Aggravation

由图 3-7 可知，图 3-7（a）表示预加重前后猪只饮水声时域波形图的变化，图 3-7

中国知网 https://www.cnki.net

（b）表示预加重前后猪只饮水声频谱图的变化；由图 3-7（a）可知，预加重后猪只饮水声信号时域波形图幅值得到提升，该变化在信号采样点接近 3000 处特别明显，预加重之前猪只声音信号幅值未明显超越 0.5，预加重后猪只声音信号幅值明显超越 0.5；由图 3-7（b）可知，预加重后猪只饮水声信号频谱图中高频部分幅值得到提升，综上所述，对猪只声音信号进行预加重增强了高频信号，基本实现减少口唇辐射效应影响。

3.4 分帧加窗

猪只声音信号随着时间变化，信号频率是不断变化的，同时表现为非周期性，但其又具有短时平稳性特性，即声音信号在 10-30ms 内可以被认为是近似不变的，因此，可以将长的猪只声音信号截取为短的片段，进行短时分析，每个短段被称为“一帧”。分帧操作完成后，每一帧的开始和结束都会出现间断，因此，当分帧数越多，则原始猪只声音信号的误差就会越来越大，为了使分帧后的信号变得连续，每一帧都呈现出周期函数的特性，所以在分帧操作时，引入了加窗操作。

分帧加窗是同时进行的两个不同的操作，分帧将猪只声音信号分割为一些短段(帧)产生一个新的依赖于时间的序列，用于描述猪只声音信号的特征[73]，如图 3-8 所示为分帧操作过程，在分帧时，为了保证每组帧信号平滑过渡，消除分帧对帧间信号相关性的影响，分帧时将相邻帧间保留部分信息，进行重叠，重叠操作被称为帧移，本研究帧移为 10ms，帧长为 25ms。

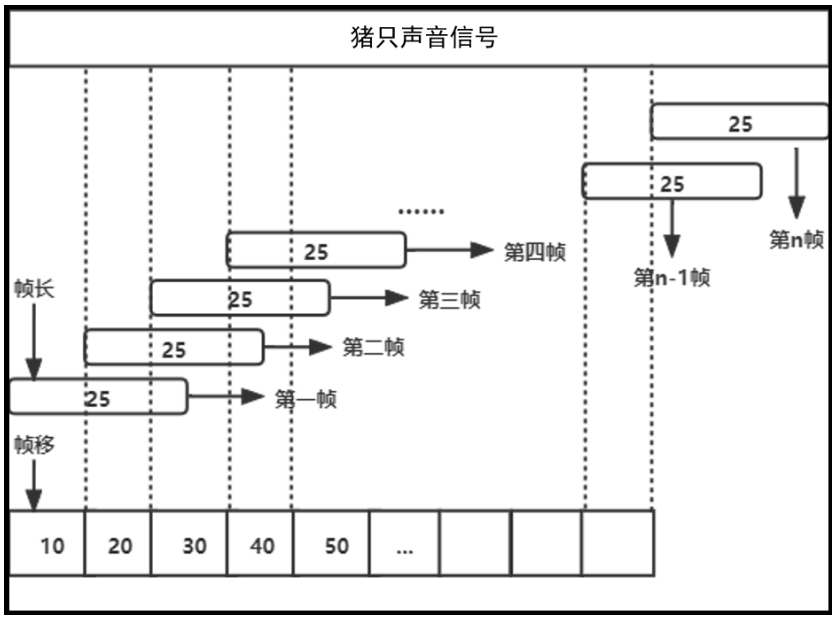


图 3-8 分帧操作

Figure 3-8 Frame Division Operation

中国知网 https://www.cnki.net

猪只声音信号分帧之后，会有一定概率发生频域信息遗漏，为了降低频谱丢失带来影响，本次研究还进行了加窗操作[74]，加窗即是将猪只声音信号序列 $x[n]$ 与窗函数 $w[n]$ 相乘，具体公式如下：

$$x_w(n) = x(n) * w(n) \tag{3-2}$$

式子（3-2）中，$x_w(n)$ 为分帧加窗后的猪只声音信号；为了降低因频域信息遗漏带来的猪只声音分类精准度的下降，加窗操作是至关重要的，与此同时，不同窗函数的选取对猪只声音信号的分析也很重要，常用的窗函数有矩形窗、汉宁窗及汉明窗等[75]。

矩形窗函数公式如下所示：

$$\omega(n) = \begin{cases} 1 & 0 \leqslant n \leqslant L-1 \\ 0 & \text{else} \end{cases} \tag{3-3}$$

矩形窗函数的幅值响应效果如图 3-9 所示：

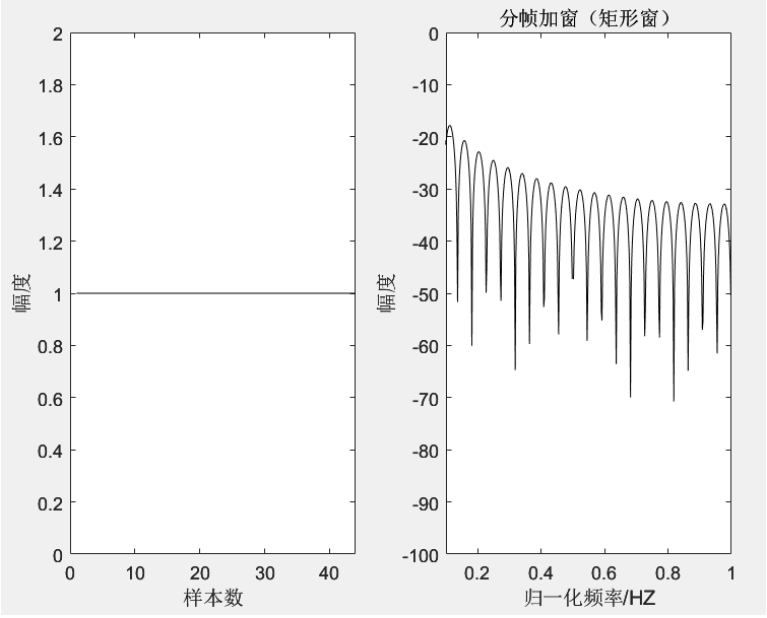


图 3-9 矩形窗函数幅值响应曲线

Figure 3-9 Amplitude Response Curve of Rectangular window function

由图 3-9 可知，矩形窗函数的幅值在窗口内为常数 1，表示窗口内的信号幅值不变，不进行衰减或增益，窗口外的幅值为 0，表示窗口外的信号被完全抑制，即不参与加窗处理；矩形窗函数的幅度响应曲线通常呈现为在频率轴上以周期性的方式重复的衰减谱，会产生频谱泄漏现象，导致在频谱分析等操作中对信号频率的精确估计产生误差。

中国知网 https://www.cnki.net

汉宁窗函数是一种常用的平滑窗函数，汉宁窗函数公式如下所示：

$$w(n)=\begin{cases}0.5\times[1-\cos(\frac{2\pi n}{L-1})] & 0\le n\le L-1\\ 0 & \text{else}\end{cases} \quad (3\text{-}4)$$

汉宁窗函数的幅值响应效果如图 3-10 所示：

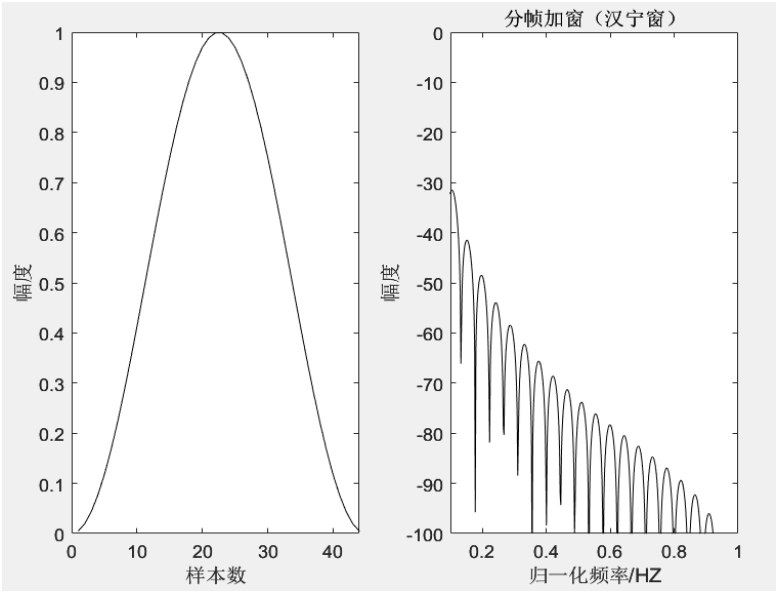


图 3-10 汉宁窗函数幅值响应曲线

Figure 3-10 Amplitude Response Curve of Hanning window function

由图 3-10 可知，汉宁窗函数的幅度响应通常在频率轴上呈现出较为平滑的曲线，旁瓣较低，意味着在时域上的平滑性较好，能够减小频谱估计中的频谱泄漏现象，主瓣宽度较宽，这会导致频率分辨率相对较低，不能够对频域上较接近的猪只声音信号进行准确区分，可能在频谱估计中丧失一些细节信息。

汉明窗函数也是一种常用的平滑窗函数，汉明窗函数公式如下所示：

$$w(n)=\begin{cases}0.54-0.48\times\cos(\frac{2\pi n}{L-1}) & 0\le n\le L-1\\ 0 & \text{else}\end{cases} \quad (3\text{-}5)$$

汉明窗函数的幅值响应效果如图 3-11 所示：

由图 3-11 可知，汉明窗函数的主瓣相对较宽，且呈现近似矩形的形状，意味着窗函数在时域上的平滑性较好，能够减小频谱估计中的频谱泄漏现象；汉明窗函数的旁瓣较低，比较接近零，尤其是在较远离主瓣的区域，这有助于减小频谱估计中的误差，使得估计的频谱能量较好地集中在主瓣内。

中国知网 https://www.cnki.net

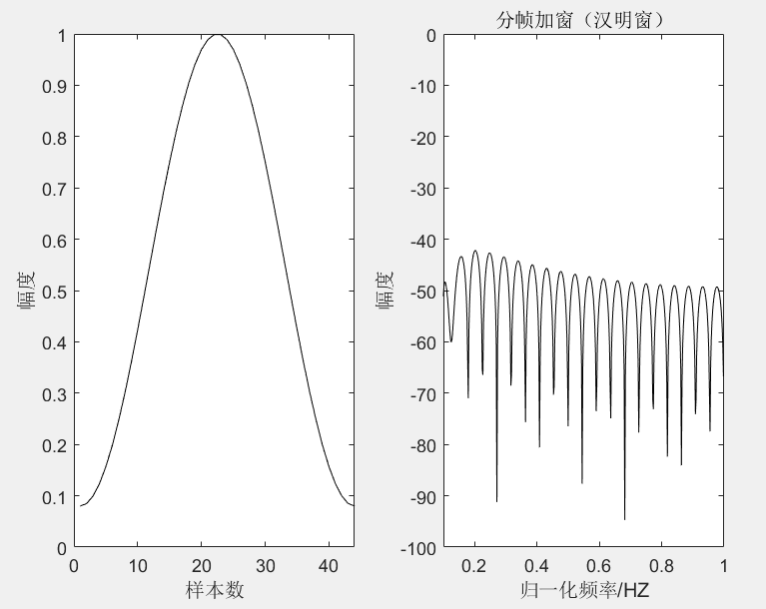


图 3-11 汉明窗函数幅值响应曲线

Figure 3-11Amplitude Response Curve of Hamming window function

由图 3-9、3-10、3-11 分析可知，矩形窗函数频谱泄漏现象较严重，对比汉宁窗函数与汉明窗函数，汉明窗可以更有效的减小旁瓣影响，且汉明窗函数主瓣较窄，可以较好的区分相邻猪只声音信号，使得猪只声音信号帧间连续性更佳，综上所述，本次研究选取了汉明窗函数作为分帧加窗操作时加窗的窗函数。

3.5 猪只声音滤波降噪

将录音设备放置在实际环境的猪舍里面进行猪只声音数据采集，不仅仅可以获取到猪只声音信号，也不可避免的掺杂了许许多多不同类别的噪声信号，当猪只声音样本中掺杂的噪声信号越来越多时，将会导致后面的分类模型精度越来越低，所以需要对猪只声音样本进行滤波降噪处理。对模拟信号进行滤波降噪时，首先经过模数转换器将待处理的模拟信号转换为数字信号，再经数字信号滤波器对待处理的数字信号进行滤波降噪处理，最后经数模转换器将处理过的数字信号转换为模拟信号，至此，即是完成了对猪只声音样本的滤波降噪处理，具体流程如图 3-12 所示。

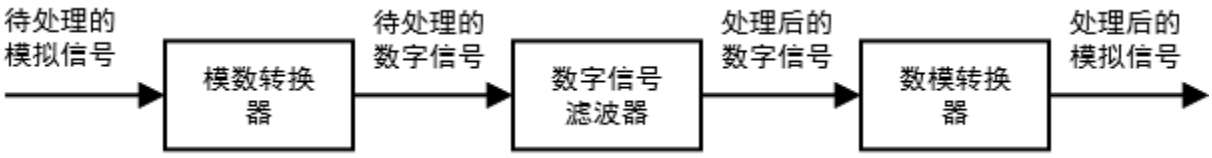


图 3-12 数字滤波实现流程

Figure 3-12 Implementation Process of Digital Filtering

中国知网 https://www.cnki.net

本研究进行滤波降噪时，主要针对两个类别的噪声信号进行滤波处理，一类是背景噪声滤波降噪，一类是猪只声音样本中特定噪声的滤波降噪；背景噪声指的是采集猪只声音信号时，持续性、连续性的噪声，例如，猪舍内的风扇声和猪饲料搅拌机声音、猪舍附件的蝉鸣声、鸟叫声以及饲养人员说话声等；特定猪只声音样本的噪声指的是对本次采集到的猪只饮水声滤波降噪处理。本次研究中，猪只饮水采取的是吸水嘴装置吸取，在采集猪只饮水声时，原始声音样本中含有猪只吸水声和其他杂声，使用对背景噪声进行滤波降噪的方法，容易将猪只吸水声滤掉，所以需要进行单独处理。

3.5.1 猪只声音样本中背景噪声滤波处理

本研究中背景噪声不等同于白噪声，白噪声是一种特殊的噪声，其频率范围在整个频谱内具有相等的能量，即在各个频率上具有相同的能量密度，而背景噪声则是在特定环境下存在的噪声，其频率和能量分布可以因环境、场景、设备等因素而异，对背景噪声处理常采取的办法有三种，其一是基于信号处理技术的噪声抑制，其二基于物理或工程手段的噪声消除，其三是基于目标信号的信号增强。本研究对猪只声音样本中背景噪声滤波处理采取了基于信号处理技术的噪声抑制，常见的噪声抑制方法包括谱减法、维纳滤波法以及小波分析法。滤波降噪完成后，选取信噪比（Signal to Noise Ratio，SNR）和均方根误差（Root Mean Square Error，RMSE）对这三类滤波降噪方法进行结果对比分析，根据分析结果选取适合本研究声音信号样本的背景噪声滤除的最佳方法。

（1）谱减法降噪

谱减法降噪被证明是一种高效的噪声抑制技术[76]，但是该方法假设目标声音信号与噪声信号是相互独立、不相关，通过对猪只声音数据采集过程和已有原始样本分析可知，猪只声音样本中的背景噪声是相互叠加而成，噪声与猪只声音是相互独立，所以，谱减法可以应用于猪只声音滤波降噪，谱减法滤波的工作流程如图 3-13 所示。

由图 3-13 可知，谱减法降噪核心是将猪只声音信号分帧后，经快速傅里叶变换从时域转换为频域，然后估计噪声谱，对噪声谱进行减去操作，完成谱减后进行相位处理，最后经逆傅里叶变换将频域转至时域，进行帧的重叠和合成，即完成了猪只声音谱减法去噪。

中国知网 https://www.cnki.net

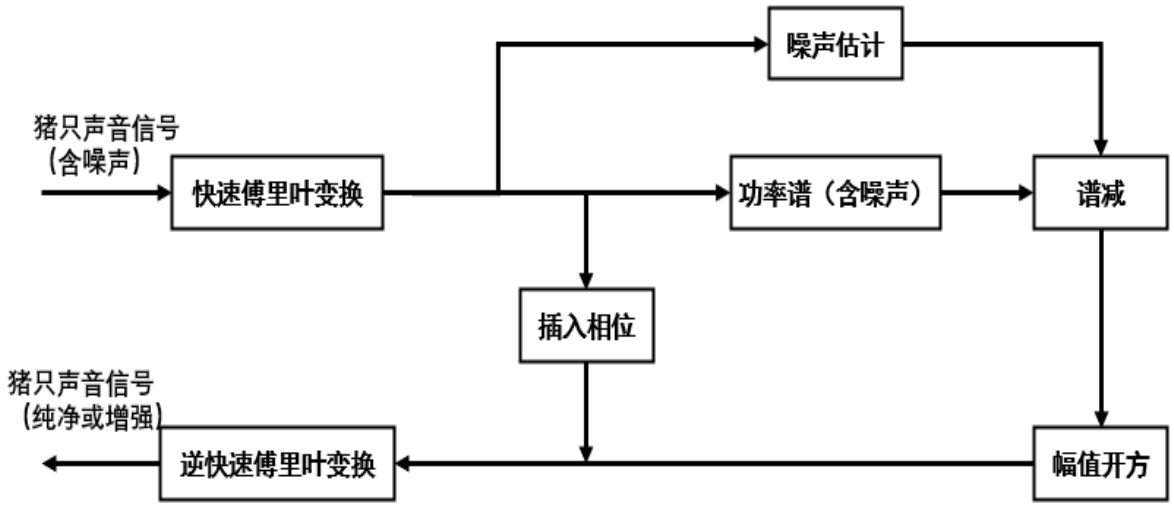


图 3-13 谱减法的工作流程

Figure 3-13 The Workflow of Spectral subtraction

设第 i 帧带噪猪只声音信号为 $y_i(m)$、纯净猪只声音信号为 $x_i(m)$，估计第 i 帧噪声信号序列为 $d_i(m)$，其中 m 为采样点的序号，$y_i(m)$、$x_i(m)$、$d_i(m)$ 快速傅里叶变换得到 $Y_i(m)$、$X_i(m)$、$D_i(m)$，则谱减公式如下：

$$|X_i(w)|^2=\begin{cases}|Y_i(w)|^2-\alpha|D(w)|^2, |Y_i(w)|^2>(\alpha+\beta)|D(w)|^2\\ \beta|D(w)^2|, |Y_i(w)|^2<(\alpha+\beta)|D(w)|^2\end{cases} \quad (3\text{-}6)$$

式子（3-6）中 α 为过减因子，β 为增益补偿因子，本研究中 $\alpha=4$、$\beta=0.001$。

$X_i(m)$ 经过逆傅里叶变换，得到了纯净的猪只声音信号序列 $x_i(m)$，将 $x_i(m)$ 信号序列中每帧进行重叠和合成，得到降噪后的猪只声音信号。

图 3-14 展示了猪只呼噜声通过谱减法滤波前后的时域波形图。

由图 3-14 可知，图中分为三个部分，第一行为猪只呼噜声的原始时域波形图，第二行为谱减法过程中噪声估计图示，第三行为谱减法滤波后时域波形图。图中红色方框框出的信号区域代表猪只呼噜声信号核心内容，对比谱减法滤波前后时域波形图可知，滤波后，红色方框内中时间区间为 1.2-1.4s 内波形幅值变化显著，红色方框外猪只声音信号的幅值有明显的减小。滤波前，因背景噪声的存在，振幅比较大，滤波后，背景噪声降低，振幅减小。综上所述，猪只的呼噜声通过谱减法滤波后对去除背景噪声是有效的。

中国知网 https://www.cnki.net

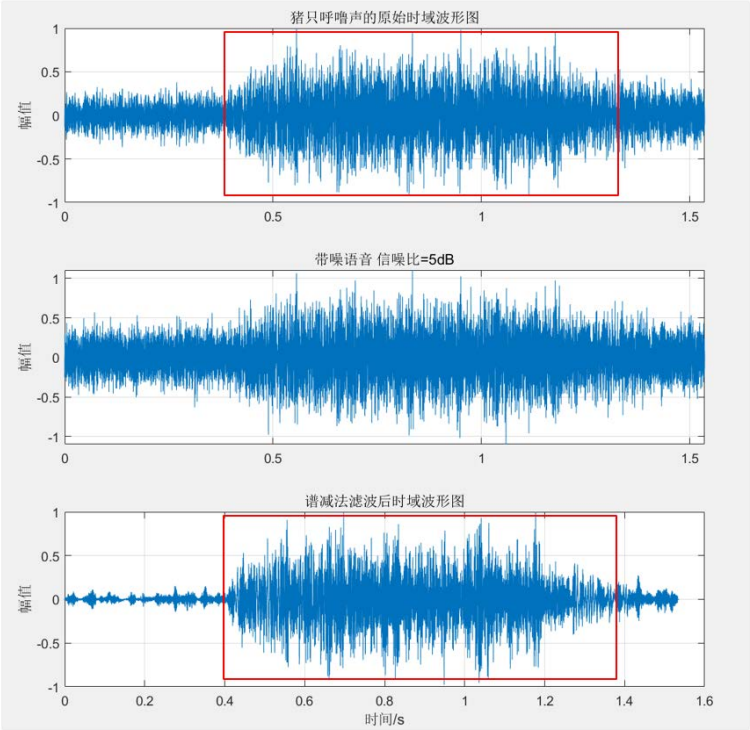


图 3-14 猪只呼噜声经过谱减法滤波前后时域波形图对比

Figure 3-14 Comparison of Time-domain Waveform of Pig Snoring before and afterSpectral subtraction Filtering

（2）维纳滤波法降噪

维纳滤波器被广泛应用于通信、军事等研究领域，主要作用是进行降噪处理[77]，维纳滤波可以看成是将带噪声的猪只声音信号 $x(n)$ 通过一个线性时不变的滤波器 $h(n)$ 进行处理，然后得到估计的猪只声音信号 $\hat{x}(n)$，估计的猪只声音信号与纯净的猪只声音信号之间存在误差 $e(n)$，能使误差最小化的最优滤波器便称为维纳滤波器，维纳滤波法降噪的工作流程如图 3-15 所示。

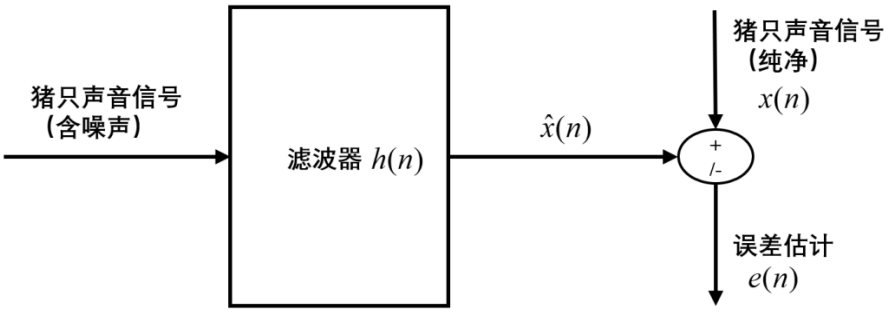


图 3-15 维纳滤波法的工作流程

Figure 3-15 The Workflow of Wiener filtering method

中国知网 https://www.cnki.net

误差 $e(n)$ 数学表示如下：

$$e(n) = x(n) - \hat{x}(n) \tag{3-7}$$

根据均方根误差标准，使得 Min（ $E[e(n)^2]$ ）取得最小值时，所得到的滤波器即是维纳滤波器。

图 3-16 展示了猪只的呼噜声通过维纳滤波法滤波前后的时域波形图。

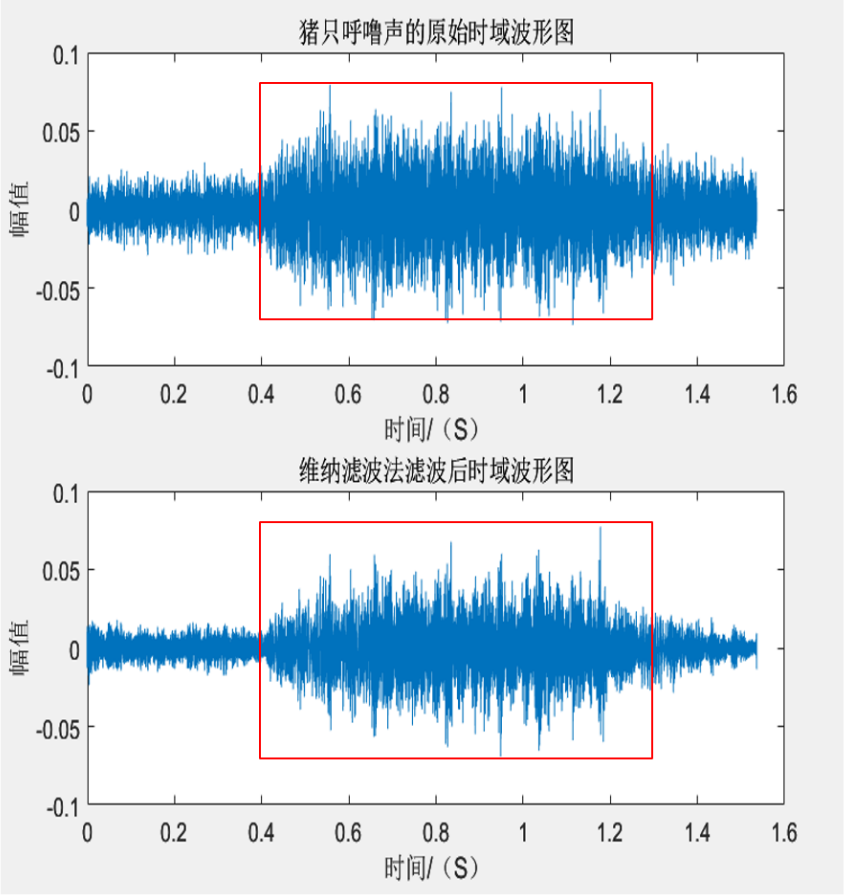


图 3-16 猪只呼噜声经过维纳滤波法滤波前后时域波形图对比

Figure 3-16 Comparison of Time-domain Waveforms of Pig Snoring before and after Wiener filtering

由图 3-16 可知，图中红色方框框出的信号区域代表猪只呼噜声信号核心内容，猪只呼噜声在经过维纳滤波法滤波后，首先是红色区域波形的振幅减小了，其次红色区域两端波形，滤波前，因背景噪声的存在，振幅比较大，经滤波后，背景噪声降低，振幅减小。综上所述，猪只呼噜声通过维纳滤波后对去除背景噪声是有效的。

（3）小波降噪

小波降噪基本思想是根据噪声与目标信号在不同频带上的小波分解系数具有不同强度分布的特点，将各频带上的噪声对应的小波系数去除，保留原始信号的小波分解

中国知网 https://www.cnki.net

系数，然后对处理后的系数进行小波重构，从而达到降噪的目的，小波降噪的工作流程如图 3-17 所示。

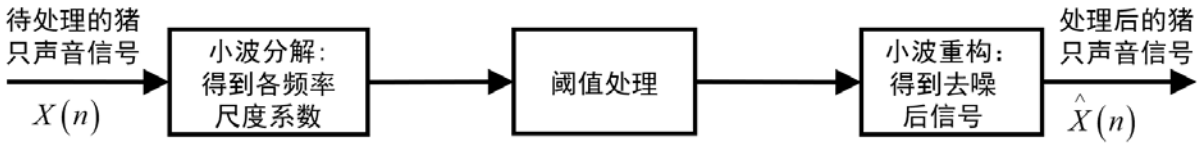


图 3-17 小波降噪实现步骤

Figure 3-17 Implementation Steps of Wavelet denoising

由图 3-17 可知，小波降噪核心是首先选择小波基函数对含有噪声的猪只声音信号进行小波分解，得到不同频带上的小波系数，然后通过小波系数估计不同尺度的噪声水平，根据估计的噪声水平进行阈值处理，将噪声系数置零或进行衰减，之后对已进行噪声系数衰减的猪只声音信号进行小波重构，得到降噪后的猪只声音信号。

图 3-18 展示了猪只的呼噜声通过小波分析法滤波前后的时域波形图。

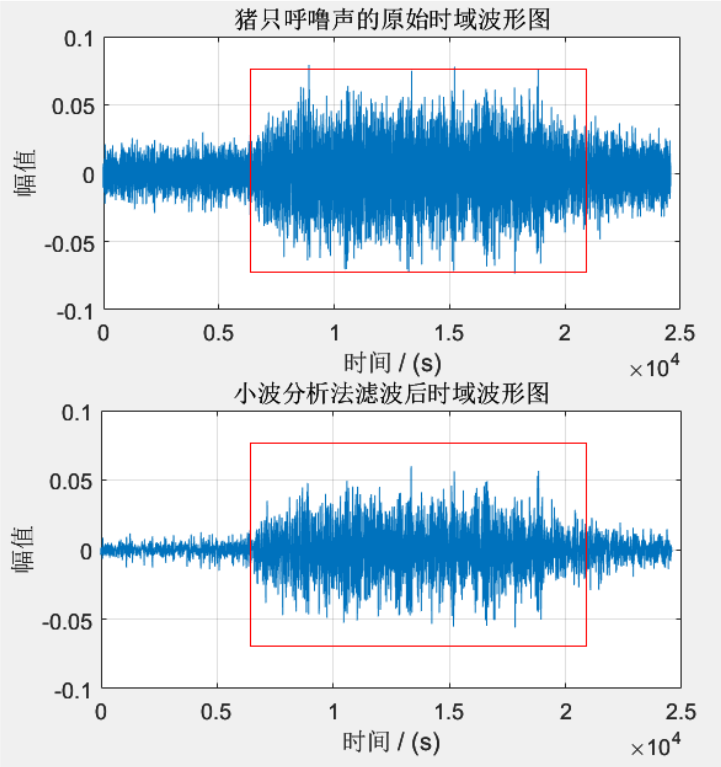


图 3-18 猪只呼噜声经过小波分析滤波前后时域波形图对比

Figure 3-18 Comparison of Time-domain Waveform of Pig Snoring before and afterWavelet analysis Filtering

由图 3-18 可知，图中红色方框框出的信号区域代表猪只呼噜声信号核心内容，猪只呼噜声在经过小波分析法滤波后，首先是红色区域波形的振幅减小了，表示尖锐的

中国知网 https://www.cnki.net

噪声得到了降低，其次红色区域两端波形，滤波前，因背景噪声的存在，振幅比较大，经滤波后，背景噪声降低，振幅减小。综上所述，猪只呼噜声通过小波分析法滤波后对去除背景噪声有效的。

（4）谱减法、维纳滤波法、小波分析法对背景声音滤波结果分析

本研究对猪只声音样本中背景噪声滤波处理的三种方法使用信噪比（SNR）和均方根误差（RMSE）指标来判定降噪效果。一般情况下，信号信噪比数值越大越好，表示信号与噪声之间的比例高，信号的质量高；对于均方根误差，则是数值越小越好，表示结果与真实值之间的平均偏差小，精度越高。表 3-2 展示了不同降噪方法对猪只咳嗽声进行滤波的 SNR、RMSE 指标比较，两类指标均保留了两位小数。

表 3-2 不同降噪方法评价指标

Table 3-2 Evaluation Indicators for Different Noise Removal Methods

评价指标	谱减法降噪	维纳滤波降噪	小波降噪
SNR	8.20	299.63	5.07
RMSE	12.08×10^{-4}	8.70×10^{-33}	8.33×10^{-6}

由表 3-2 可知，采用不同降噪方法对猪只咳嗽声降噪后，维纳滤波法的 SNR 值为 299.63，比谱减法和小波分析法 SNR 值大；维纳滤波法的 RMSE 值为 8.70×10^{-33}，比谱减法和小波分析法 RMSE 值小。综上所述，本研究选择维纳滤波法作为最优方法，对猪只声音样本中的背景噪声进行滤波处理。

3.5.2 猪只声音样本中特定噪声的滤波处理

本研究对于猪只声音样本中特定噪声的滤波处理，采用有限冲激响应（finite impulse response，FIR）滤波器进行处理。因为 FIR 滤波器的输出仅依赖于输入信号的有限数量的历史样本、实现流程简单[78]；另外该滤波器是线性相位，它能够保证由多个频率组成的信号在通过滤波器后，信号的波形不发生变化[79]。

FIR 的差分方程如下为：

$$y（n）=\sum_{k=0}^{M-1} b_k x(n-k) \qquad （3\text{-}8）$$

式子（3-8）中，$y(n)$ 是输出猪只声音信号的当前样本值，$x(n)$ 是输入猪只声音信号的当前样本值，b_k 是滤波器的系数，k 是滤波器的阶数，表示滤波器的历史输入样本的个数，M 为采样编号，将输出序列变换成系统的单位冲击响应 $h(n)$ 和输入信号的

中国知网 https://www.cnki.net

卷积形式，式子如下：

$$y(n)=\sum_{k=0}^{M-1}h(k)x(n-k) \tag{3-9}$$

根据式子（3-8）得到 FIR 数字滤波器的系统函数：

$$H(z)=\sum_{k=0}^{M-1}h(k)z^{-k} \tag{3-10}$$

窗函数法设计 FIR 滤波器核心是确定滤波器的单位取样响应 $h_d(n)$ 和选择 $\omega(n)$ 以及确认窗口长度，然后通过窗函数将 $h_d(n)$ 截断，式子如下：

$$h(n)=h_d(n)\omega(n) \tag{3-11}$$

得到 h(n) 的频域响应函数 $H(j\omega)$：

$$H(j\omega)=\sum_{n=0}^{N-1}h(n)e^{-j\omega n} \tag{3-12}$$

FIR 滤波器将当前时刻的输入信号与对应时刻的冲激响应系数相乘，然后将所有乘积相加得到输出信号，即是完成猪只声音信号滤波降噪处理。

图 3-19 展示了猪只饮水声经过 FIR 滤波器高通滤波前后的频谱图。由图 3-19 可知，猪只饮水声在通过 FIR 滤波器进行滤波后，猪只饮水声信号超过 4000Hz 的信息内容得到了保留，低于 4000Hz 部分被滤除。在对滤波后的猪只饮水声进行播放时，发现目标声音样本更加纯净，即本次猪只声音样本中特定噪声滤波处理达到预期的滤波效果。

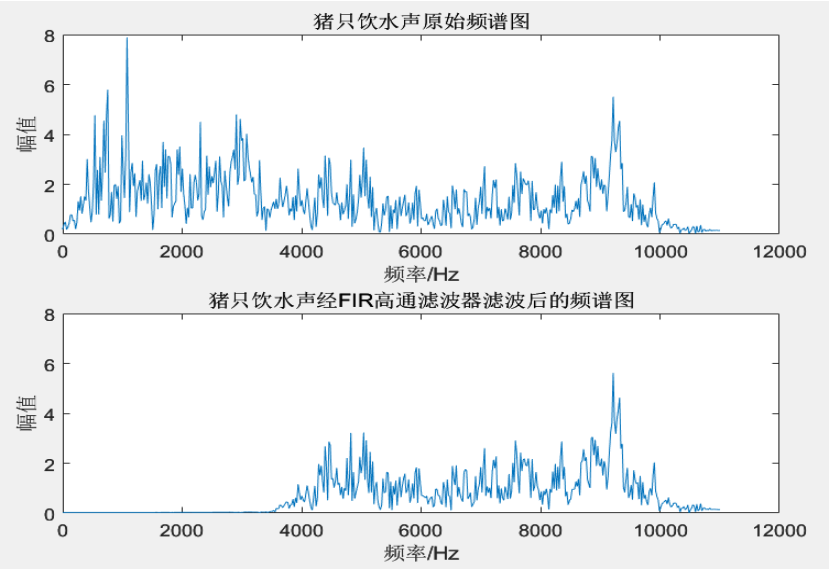


图 3-19 猪只饮水声经过 FIR 滤波器高通滤波前后频谱图对比

Figure 3-19 Comparison of Spectra of Pig Drinking Water Sound before and after High Pass Filtering with FIR Filter

中国知网 https://www.cnki.net

3.6 本章小结

本章介绍本次研究所使用的猪只声音数据采集情况，包括采集地点、采集对象猪只的品种、采集设备以及采集时间周期；然后在云南农业大学动物医学院专业人员的指导下，对猪只声音样本数据进行标注与切割，采用预加重、分帧加窗以及滤波降噪对声音样本进行有效的预处理。

本次研究共采集到猪只声音原始数据约 10 万余条，经过数据标注与样本切割，得到了猪只的吃食声、呼噜声、咳嗽声、哼唧声、饮水声等五类有效的目标声音样本，共计约 10000 条。后续章节将分别介绍声音特征提取及分类模型构建、改进、优化所做的工作。

中国知网 https://www.cnki.net

第四章猪只声音信号特征参数提取

4.1 引言

猪只声音信号是长度不定的时序信号，不适合直接作为传统机器学习算法的输入，经过预处理之后的猪只声音数据一般需要转换成特定的特征向量表示，这个过程被称为猪只声音信号的特征提取。猪只声音信号的特征参数有多种，不同的声音信号呈现出的声学物理特征不一样，特征提取目的是根据声音信号提取到有效的声学特征，尽可能避免信号中无效信息增加数据处理工作的繁杂度。本次研究工作主要针对猪只声音信号的时域、频域、时频域、倒谱域四类常见特征参数进行声音特征参数提取研究，具体如表 4-1 所示：

表 4-1 猪只声音信号特征参数及提取方法

Table 4-1 Common Feature Parameters and Extraction Methods for Sound Signals

特征参数	特征参数名称	提取方法
时域特征参数	短时能量 短时过零率	直接从信号中计算（观察）
频域特征参数	功率谱密度	傅里叶变换（FT）
时频域特征参数	语谱图	快速傅里叶变换（FFT） 功率谱密度 伪彩色显示
倒谱域特征参数	梅尔频率倒谱系数（MFCC）	快速傅里叶变换（FFT） 梅尔滤波器 对数运算 离散余弦变换

4.2 猪只声音信号时域特征参数提取

短时能量与短时过零率是对猪只声音信号进行时域特征分析的方法，也是最简单快速的方法，该方法是以时间为自变量，是任何声音信号最明显的、最典型的特征。

中国知网 https://www.cnki.net

（1）短时能量

短时能量在一定程度上反映了猪只声音信号的幅度变化，设第 n 帧猪只声音信号为 $x_n(m)$，其短时能量 E_n 计算公式如下：

$$E_n = \sum_{m=0}^{N-1} x^2(m) \tag{4-1}$$

使用幅值平方，对高幅值信号具有较大的敏感度，为了降低敏感度，定义短时平均幅度函数 M_n，计算公式如下：

$$M_n = \sum_{m=0}^{N-1} |x(m)| \tag{4-2}$$

（2）短时过零率

短时过零率表示一帧声音中信号波形穿过横轴（零点平）的次数，实质就是计算每帧声音信号幅值符号改变的总次数，如果相邻采样点的幅值符号是相同的，则没有发生过零点的情况，相反，如果相邻采样点幅值的符号发生了改变，那么表示声音信号发生了过零的情况，短时过零率的计算公式如下：

$$Z_n = \sum_{m=-\infty}^{\infty} |sgn[x(m)] - sgn[x(m-1)]| w(m) \tag{4-3}$$

$sgn[x(m)]$ 代表符号函数，$w(m)$ 代表窗函数，符号函数表达式为：

$$sgn[x(n)] = \begin{cases} 1 & x(n) \geq 0 \\ -1 & x(n) < 0 \end{cases} \tag{4-4}$$

猪只的哼唧声进行短时能量与短时过零率特征提取的检测结果，如图 4-1 所示。

由图 4-1 可知，图中共包含三个部分，第一行为猪只哼唧声的时域波形图，第二行为猪只哼唧声的短时能量分布情况，第三行为猪只哼唧声的短时过零率分布情况。短时能量图中能量变化表示相邻的帧信号间幅值变化情况，其中能量曲线的波峰较好的描述了时域波形图中幅值变化强烈情况；短时过零率图中帧数与幅值的变化曲线对应了时域波形图中波形过零点频次，图中曲线幅值越大表示波形穿越零点的频次越高，当信号时域波形图幅值变化大时，穿越零点的频次降低，在短时过零率图中表现为曲线呈下降趋势。

中国知网 https://www.cnki.net

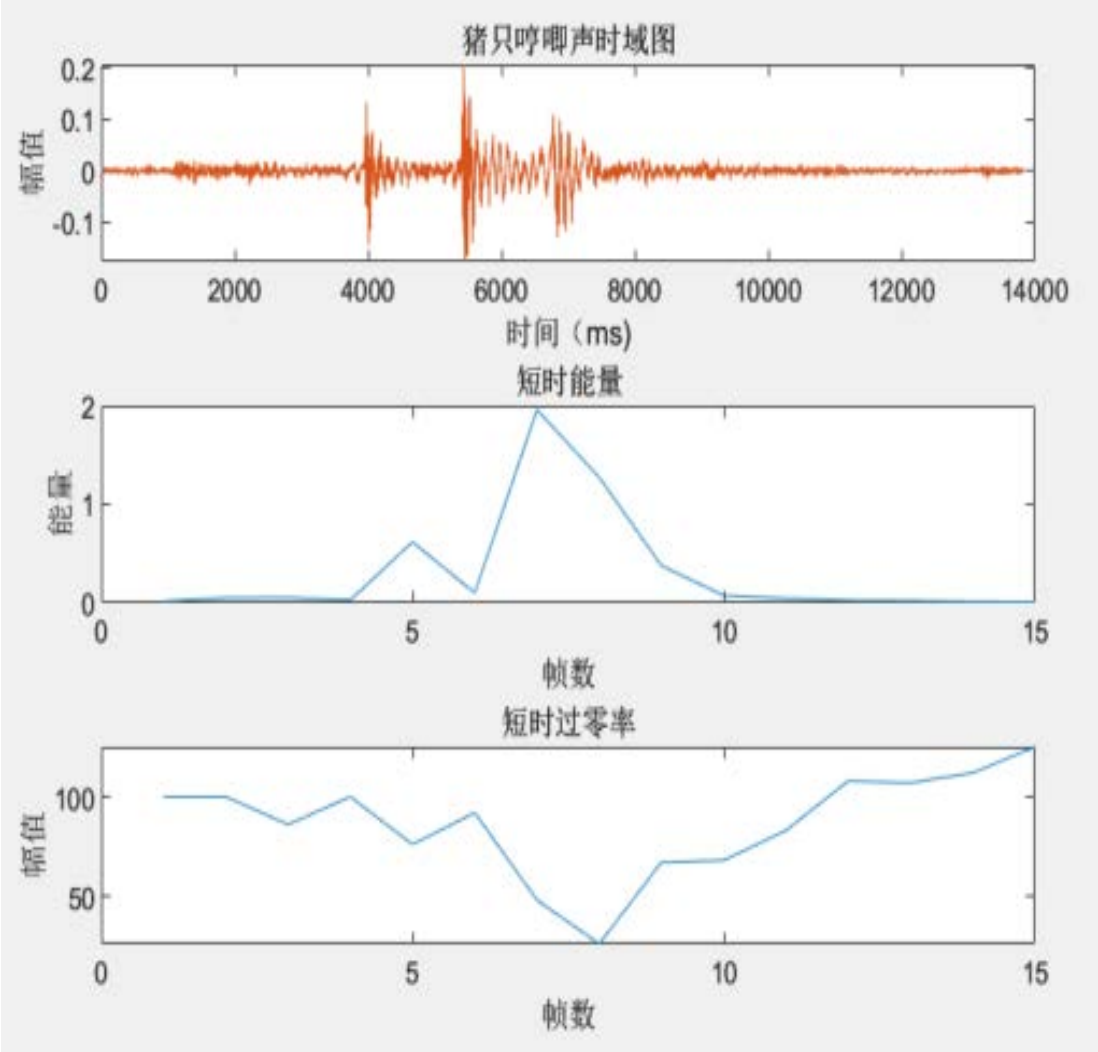


图 4-1 猪只哼唧声短时能量与短时过零率

Figure 4-1 The Short-term Energy andShort-term Zero-crossing Rate of Pig's Hum

4.3 猪只声音信号频域特征参数提取

功率谱密度图是对声音信号进行频域特征分析的方法，功率谱密度（Power Spectral Density，PSD）定义了信号或者时间序列的功率如何随频率分布，计算公式如下：

$$PSD(\omega) = |X(\omega)|^2/T \quad (4\text{-}5)$$

$X(\omega)$ 是信号的傅里叶变换，T 是信号的周期，图 4-2 展示了猪只哼唧声进行功率谱密度特征提取的结果。

由图 4-2 可知，图中共包含两个部分，图中第一行为猪只哼唧声的频谱图，第二行为猪只哼唧声的功率谱密度图。猪只哼唧声的功率谱密度图表示不同频率的功率谱密

中国知网 https://www.cnki.net

度值，反映了信号在该频率段上的能量强度，高功率谱密度值表示信号在该频率段上的能量较强，低功率谱密度值表示信号在该频率段上的能量较弱。

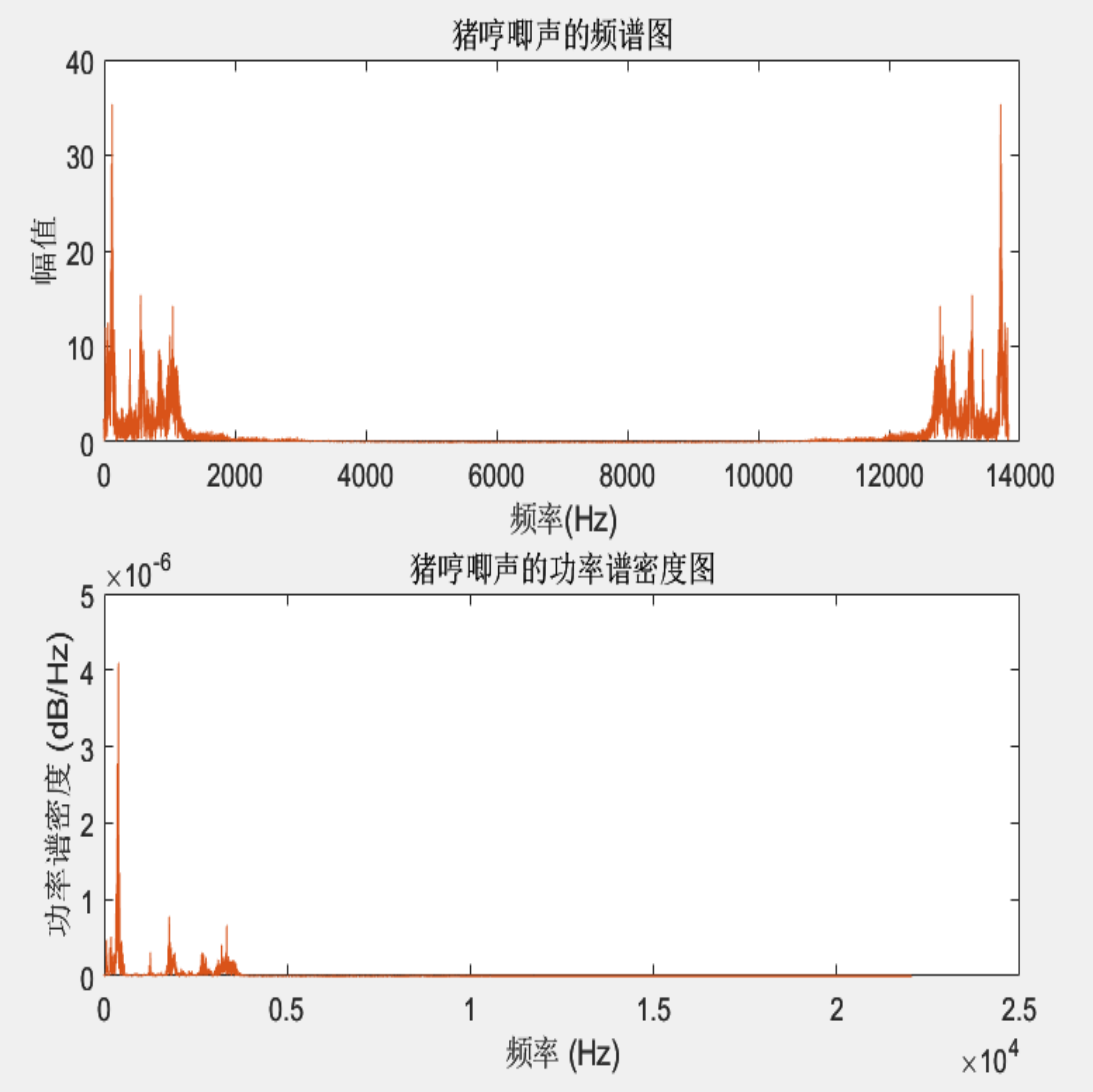


图 4-2 猪只哼唧声功率谱密度

Figure 4-2 The Power Spectral Density of Pig's Hum

4.4 猪只声音信号时频域特征参数提取

猪只声音信号是随机的，仅仅通过时域特征分析或是频域特征分析，无法得到时域和频域的综合信息，无法更加详细便利的描述声音信号的特征。为了同时研究声音信号的时域和频域信息，结合猪只声音在极短时间内处于平稳状态，本次研究尝试了用语谱图表示猪只声音信号的时频特性，语谱图是对声音信号进行时频域特征分析的方法，又称频谱分析视图，即声音的可视化表达。语谱图的横坐标是时间，纵坐标是频率，坐标点的值表示语音信号的能量，能量的强弱或能量值的大小通过颜色来表示，

中国知网 https://www.cnki.net

颜色越深表示该点的语音能量越强。

本次研究中猪只声音信号语谱图特征提取步骤如图 4-3 所示，分帧加窗详见本文 3.4 节，首先通过一个短时窗函数，然后利用快速傅里叶变换（FFT）计算该时间窗内的功率谱，之后移动该窗计算下一个窗内的功率谱，接着得到连续时间内的功率谱密度，最后通过功率谱伪彩色显示得到了语谱图[80]。

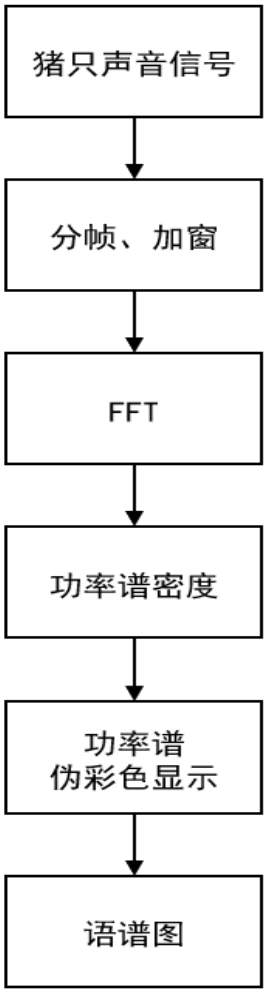
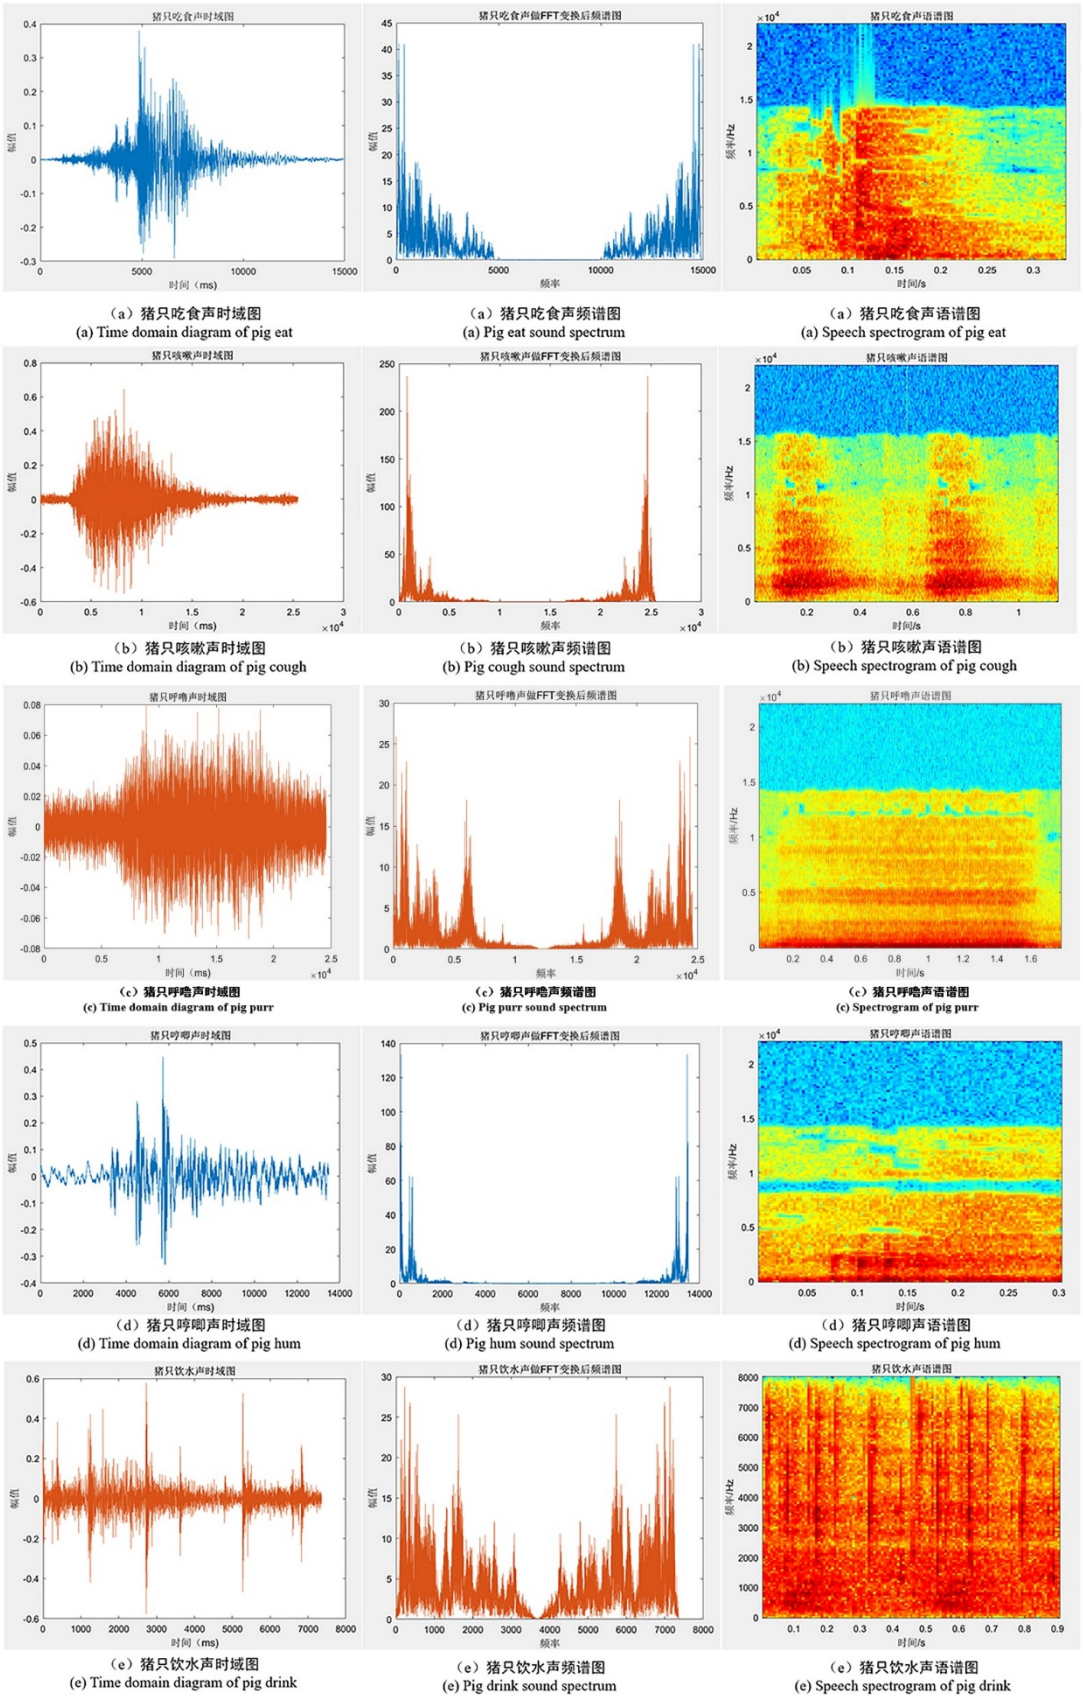


图 4-3 语谱图生成步骤

Figure 4-3 Generation Steps of Spectrogram

对猪只声音进行语谱图特征提取的结果如图 4-4 所示。图 4-4 分别展示了猪只吃食、咳嗽、呼噜、哼唧以及饮水等声音信号的时域图、频谱图、语谱图。其中语谱图把一维的声音信息转化为二维图像形式呈现，且二维图像表示出声音的三维信息，即时间、频率和能量。由语谱图中可以看到颜色较深的颜色表示较高的能量或功率谱密度，而较浅的颜色表示较低的能量或功率谱密度。

中国知网 https://www.cnki.net



（a）猪只吃食声时域图
(a) Time domain diagram of pig eat

（a）猪只吃食声频谱图
(a) Pig eat sound spectrum

（a）猪只吃食声语谱图
(a) Speech spectrogram of pig eat

（b）猪只咳嗽声时域图
(b) Time domain diagram of pig cough

（b）猪只咳嗽声频谱图
(b) Pig cough sound spectrum

（b）猪只咳嗽声语谱图
(b) Speech spectrogram of pig cough

（c）猪只呼噜声时域图
(c) Time domain diagram of pig purr

（c）猪只呼噜声频谱图
(c) Pig purr sound spectrum

（c）猪只呼噜声语谱图
(c) Spectrogram of pig purr

（d）猪只哼唧声时域图
(d) Time domain diagram of pig hum

（d）猪只哼唧声频谱图
(d) Pig hum sound spectrum

（d）猪只哼唧声语谱图
(d) Speech spectrogram of pig hum

（e）猪只饮水声时域图
(e) Time domain diagram of pig drink

（e）猪只饮水声频谱图
(e) Pig drink sound spectrum

（e）猪只饮水声语谱图
(e) Speech spectrogram of pig drink

图 4-4 猪只声音时域图、频谱图、语谱图

Figure 4-4 Time Domain Diagram, Spectrum Diagram and Spectrogram of Pig Voice

中国知网 https://www.cnki.net

4.5 猪只声音信号倒谱域特征参数提取

梅尔频率倒谱系数（Mel Frequency Cepstral Coefficients，MFCC）是倒谱域特征参数之一，具有计算简单、识别性高、噪声的对抗性强等优点[81]。倒谱是信号经过对数运算后再进行傅立叶逆变换的频谱。倒谱在信号处理中有着广泛的应用，它的主要功能是线性分离两个或多个卷积信号。Mel 倒谱系数是在 Mel 标度频率域提取出来的倒谱参数，Mel 标度描述了人耳频率的非线性特性，它与线性频率的关系可用下式近似表示：

$$Mel(f)=2595\times\lg(1+\frac{f}{700}) \tag{4-6}$$

其 Mel 频率与线性频率的关系图如图 4-5 所示：

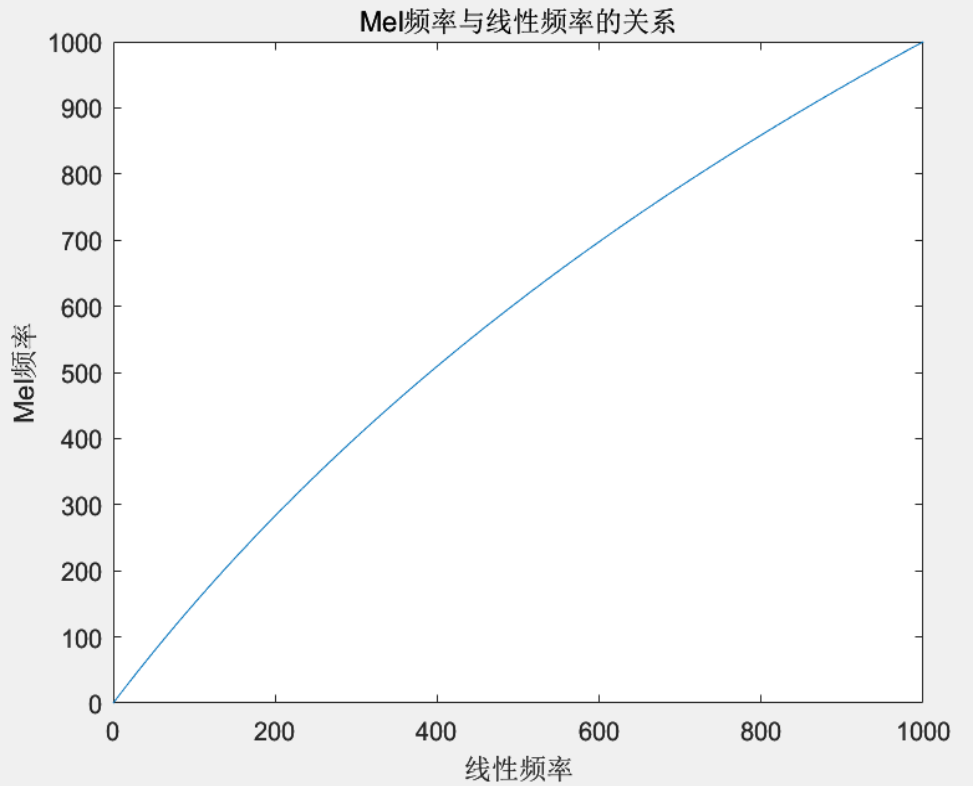


图 4-5Mel 频率与线性频率的关系

Figure 4-5 Relationship between Mel frequency and linear frequency

由图 4-5 可知，其中低频区域的对应关系较为接近，而高频区域的对应关系较为疏远。

猪只声音信号的 MFCC 参数具体提取流程如图 4-6 所示：

中国知网 https://www.cnki.net

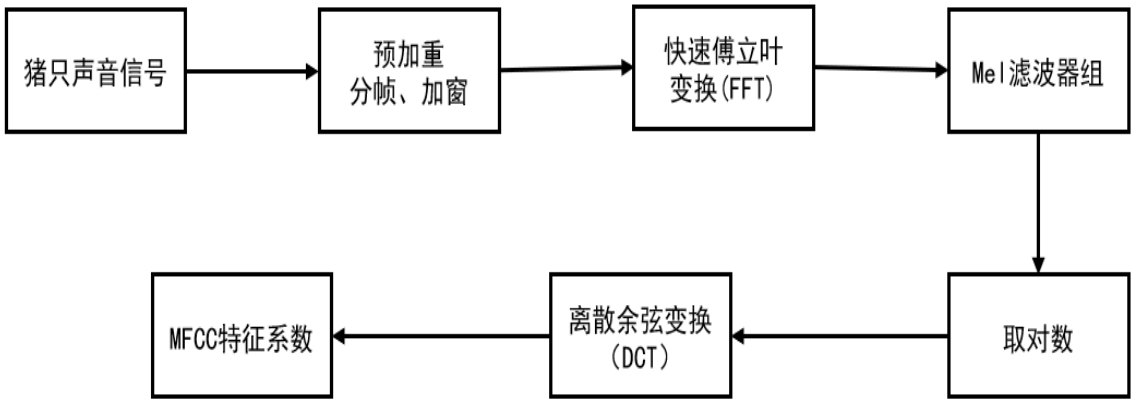


图 4-6Mel 倒谱系数提取流程

Figure 4-6 Mel CepstrumCoefficient Extraction Process

（1）预加重、分帧、加窗

猪只声音信号的预加重、分帧、加窗等处理操作如第三章第 3、4 小节所述，这里的声音信号我们选取了 25ms 片段，帧移为 10ms，窗函数选用汉明窗。

（2）快速傅里叶变换（FFT）

研究采用快速傅里叶变换得到每帧的频谱。其公式表示为：

$$Y_i(p) = FFT\left[X_{\mathrm{i}}(\mathrm{m})\right] \tag{4-7}$$

其中 i 表示帧编号，$X_{\mathrm{i}}(\mathrm{m})$ 表示第 i 帧猪只声音信号，$Y_i(p)$ 表示第 i 帧猪只声音信号的频谱能量，然后再对语音信号的频谱取模平方得到语音信号的功率谱 $E_i(k)$，其公式表示为：

$$E_i(k) = \left|Y_i(p)\right|^2 \tag{4-8}$$

（3）Mel 滤波器组、计算梅尔滤波器能量

本研究选用三角滤波器组，该滤波器组有如下特点：在高频部分，它的带宽比较宽，相对分布比较稀疏，对应的频率分辨率也比较低；在低频部分，与高频部分恰恰相反。Mel 滤波器组选择三角滤波器组的主要目的有两点，一是对频谱进行平滑化，消除谐波的作用，突显原先语音的共振峰；二是降低运算量。在设计这组滤波器时，一般为了使彼此相邻滤波器的过渡带能够有定的重叠，常常把彼此相邻两个滤波器的中心频率作为中间那个滤波器的低点频率[82]。Mel 滤波器组结构如图 4-7 所示：

中国知网 https://www.cnki.net

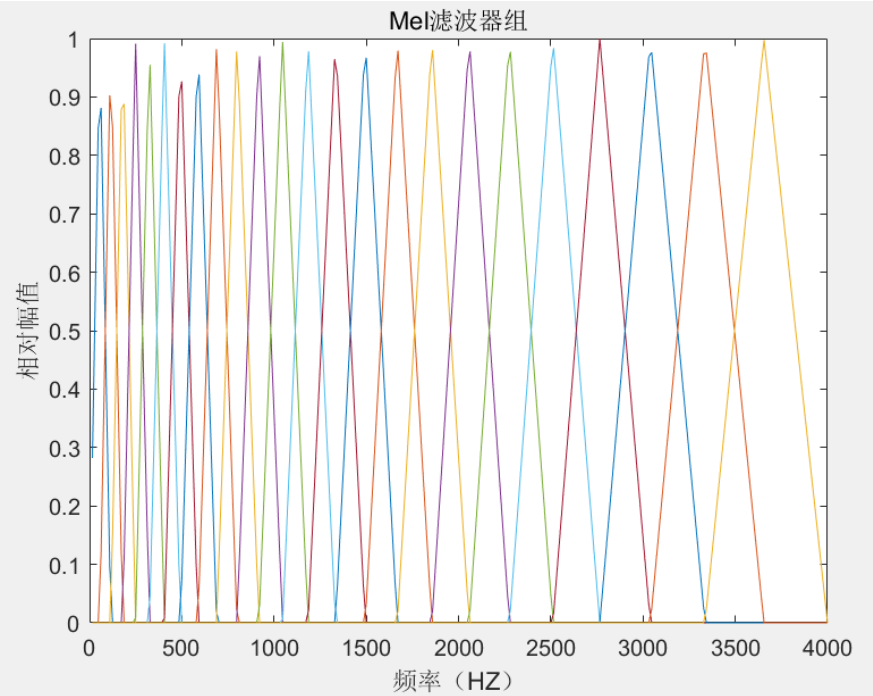


图 4-7Mel 滤波器组结构

Figure 4-7 Mel filter bank structure

由图 4-7 可知，有 24 个三角形频率响应，可以从图中三角尖角数量看出，三角滤波器的频率响应定义为：

$$H_m[k]=\begin{cases}0 & ,k<f(m-1)\\ \dfrac{2（k-f(m-1)）}{（f（m+1）-f（m-1））（f(m)-f(m-1)）} & ,f(m-1)\le k<f(m)\\ \dfrac{2（f(m+1)-k）}{（f(m+1)-f(m-1)）（f(m)-f(m-1)）} & ,f(m)\le k\le f(m+1)\\ 0 & ,k>f(m+1)\end{cases} \tag{4-9}$$

使用 Mel 滤波器组对 $E_i(k)$ 计算得到声音信号在 Mel 频域的能量 $S_i(m)$，其公式为：

$$S_{\mathrm{i}}(m)=\sum_{k=0}^{N-1}E_i(k)H_m(k),\quad 0\le m\le M \tag{4-10}$$

其中，m 表示第 m 个滤波器。

（4）计算各个滤波器组输出的对数能量 $s(m)$：其公式如下：

$$s(m)=\ln\left(S_{\mathrm{i}}(m)\right),0\le m\le M \tag{4-11}$$

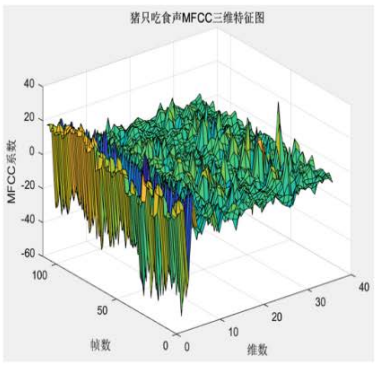
（5）离散余弦变换（DCT）

中国知网 https://www.cnki.net

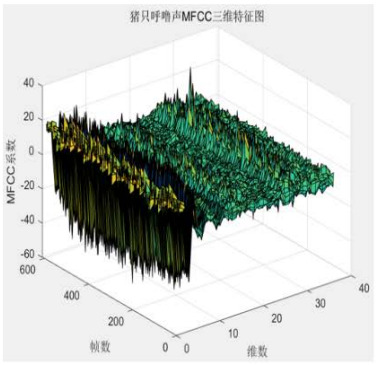
将（4）中对数能量$s(m)$代入离散余弦变换C（n）中，计算出 L 阶的梅尔倒谱系数的特征参数，其公式如下：

$$C(n)=\sum_{m=0}^{N-1}S(m)cos(\frac{\pi n(m-0.5)}{Q}),n=1,2,\ldots,L \qquad (4\text{-}12)$$

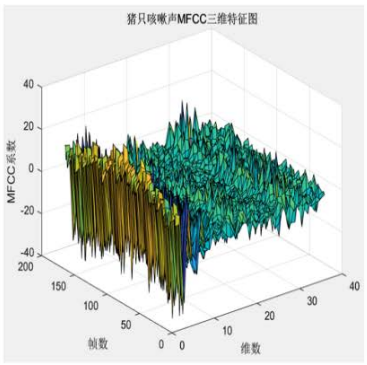
其中 Q 为滤波器个数，在这里取最大值 24，如图 4-8 所示，图为对猪只声音提取 MFCC 后，MFCC 三维特征展示。



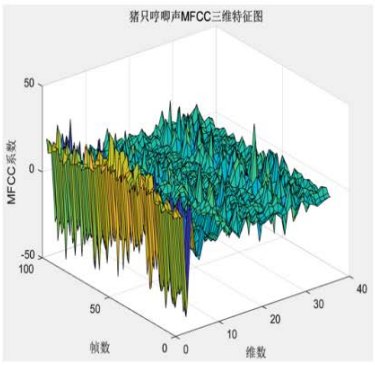
（a）猪只吃食声MFCC三维特征
(a) Three-dimensional MFCC characteristics of pig eat



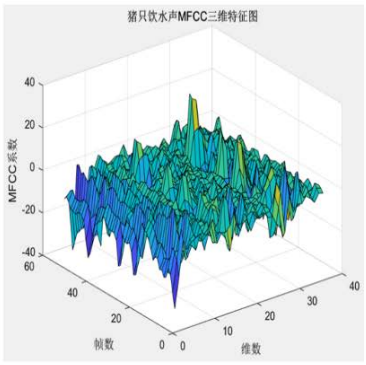
（b）猪只呼噜声MFCC三维特征
(b) Three-dimensional MFCC characteristics of pig snore



（c）猪只咳嗽声MFCC三维特征
(c) Three-dimensional MFCC characteristics of pig cough



（d）猪只哼唧声MFCC三维特征
(d) Three-dimensional MFCC characteristics of pig hum



（e）猪只饮水声MFCC三维特征
(e) Three-dimensional MFCC characteristics of pig drink

图 4-8 猪只声音 MFCC 三维特征

Figure 4-8 Three-dimensional MFCC Characteristics of Pig Voice

图 4-8 分别为猪只吃食、呼噜、咳嗽、哼唧以及饮水声音信号的 MFCC 特征参数图，可以通过颜色和深度展示信号在不同维度下能量分布情况，其中 X 轴表示猪只声音信号分帧的帧数，Y 轴表示 MFCC 特征的维数，Z 轴表示猪只声音信号的 MFCC 系数（MFCC 系数即猪只声音信号的倒谱值），图中 MFCC 的维数为 36 维，猪只声音在不同的维度中的 MFCC 系数不同，较好的反映了猪只声音样本的声道特性。

中国知网 https://www.cnki.net

4.6 猪只声音信号特征提取结果分析

前述的猪只声音信号时域特征主要是直接从信号中计算所得，时域特征参数主要是记录声学物理特性随时间变化情况，优点是简单易理解，但对相似声音区分性弱。猪只声音信号频域特征主要是通过对信号进行傅里叶变换得到的特征，优点是能够提供信号在不同频率上的能量分布信息，对信号的频率特性有较好的描述能力，缺点是对信号的时序信息较为模糊，无法完全还原信号的时域形态。猪只声音时频域特征主要是通过快速傅里叶变换等方法得到特征，同时考虑信号在时域和频域上的特性，优点是能够在时域和频域上提供更为详细和全面的信息，但计算复杂度较高，可能需要较长的计算时间和存储空间，且后续大多采取基于图像的声音分类研究，忽略了语谱图的时序信息。倒谱域特征主要是采取基于人耳感知特性，通过快速傅里叶变换、Mel 滤波器、对数运算以及离散余弦变换等方法得到特征，优点是鲁棒性较好，通过对频谱进行离散余弦变换得到倒谱系数，有效降低特征维度，减少计算复杂度和存储开销以及对声音信号的共振峰频率和带宽信息具有较好的提取效果，对声音分类任务具有较高的性能。

通过对比时域、频域、时频域以及倒谱域特征参数的优缺点，结合本次研究的猪只声音数据样本时间跨度较小的特点，可以有效的避免 MFCC 作为特征参数的缺点，所以，研究选取了 MFCC 作为猪只声音信号的特征参数。

4.7 本章小结

本章首先概述了猪只声音信号特征参数提取缘由，然后对猪只声音样本的时域、频域、时频域以及倒谱域对应的特征参数分别进行了提取展示，其中时域提取了短时能量与短时过零率，频域提取了功率谱密度，时频域提取了语谱图，倒谱域提取了梅尔倒谱系数，通过各个领域的声音信号特征提取结果进行分析，最后选取了 MFCC 作为本次研究的猪只声音分类的特征参数。在下一章，我们将对猪只声音信号进行分类模型构建工作进行介绍。

中国知网 https://www.cnki.net

第五章猪只声音分类模型研究

5.1 引言

声音的分类识别是声音信号处理的一个热点问题，它在各个行业领域有着重要的应用，如：导航、辅助机器人技术、移动设备服务、辅助聋人和老年人、监督和安全等领域。声音数据可以获取视觉捕捉不到的信息，同时声音数据获取不受限于光线，也无需在视线范围内，数据所需的存储空间比视频图像信号小得多。目前音频分类和识别的研究大部分集中在语音识别和音乐、语音的分类上。常用的声音分类算法有支持向量机（SVM）、K 最近邻（KNN)、高斯混合模型（GMM）、隐马尔科夫模型（HMM）、长短期记忆网络（LSTM）等。其中 KNN 及 GMM 以其实现的简单性及较高的分类准确性得到广泛的应用。但它们的缺陷是需要大的存储空间，边界分类误差较大。本文以猪只声音信号的梅尔倒谱系数作为特征参数输入分类模型，构建基于支持向量机模型、隐马尔科夫模型、长短期记忆网络以及改进的长短期记忆网络对猪只声音进行分类，为了准确的评价各类模型的分类性能，研究中评价指标选择了准确率（Accuracy)指标作为评价参数，包括模型的训练集、测试集总的分类准确率和每个声音类别的分类准确率，具体计算公式如下：

$$\text{Accuracy} = \frac{\text{TN} + \text{TP}}{\text{FP} + \text{TN} + \text{TP} + \text{FN}} \tag{5-1}$$

其式子（5-1）中，TP 是真阳性、FP 是假阳性、FN 是假阴性、TN 是真阴性，本研究使用混淆矩阵表示声音分类的情况。

5.2 基于支持向量机的猪只声音分类

在构建 SVM 对猪只声音进行分类研究时，首先提取了已经预处理完成的猪只声音样本数据，然后对样本进行分层抽样，按照训练集比测试集为 8：2 进行划分，对五类猪只声音打标签，数据集划分情况如表 5-1 所示；

中国知网 https://www.cnki.net

表 5-1SVM 模型数据集情况

Table 5-1 Data set of SVM model

声音类型	标签	样本量	训练集	测试集
猪只吃食声	类别 1	448 个	335 个	113 个
猪只饮水声	类别 2	609 个	495 个	114 个
猪只打呼噜声	类别 3	555 个	442 个	113 个
猪只哼唧声	类别 4	504 个	391 个	113 个
猪只咳嗽声	类别 5	719 个	605 个	114 个

然后，以 MFCC 特征参数作为模型的输入，定义了最优超平面、寻找间隔最大化的超平面、选择核函数，之后将训练集数据输入到 SVM 中进行训练和求解，模型训练完成后，将测试集数据输入到生成的模型中进行分类计算，最后将训练集和测试集中得到的各类别混淆矩阵和总的分类准确率进行输出，如图 5-1 为猪只声音分类的 SVM 模型构建流程。

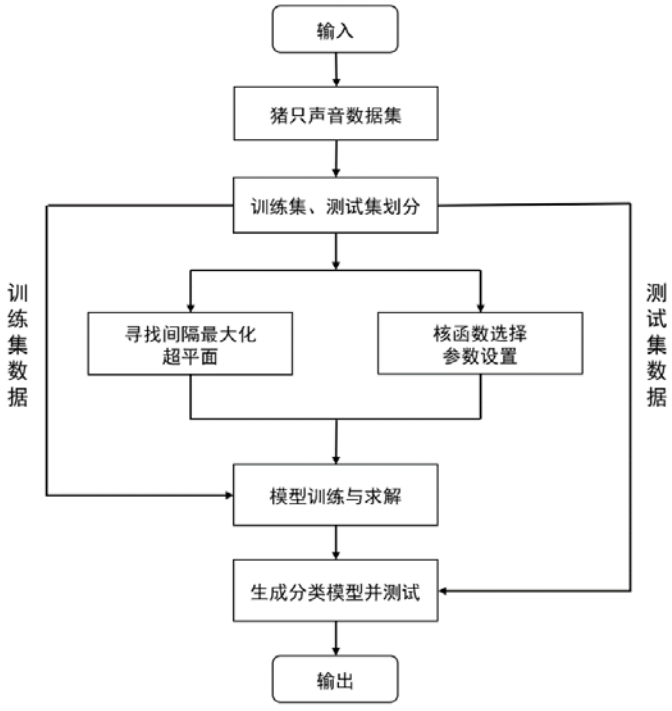


图 5-1SVM 模型构建流程

Figure 5-1 SVM Model Construction process

中国知网 https://www.cnki.net

支持向量机中常见核函数主要包括线性核函数、多项式核函数、高斯核函数、sigmoid 核函数以及径向基核函数等，在实际的应用中，关于核函数的选择主要依据所需要的分类任务和所用的数据集去决定[83]。本研究 SVM 模型选取的核函数是径向基核函数，径向基核函数可以将非线性的数据映射到高维空间中，使得原本不可分的数据变得可分，提高了模型的准确率。

为了使支持向量机得到最佳的分类效果，实现泛化能力最强，模型中有两个参数至关重要，分别是惩罚因子 C 和核函数宽度 g，惩罚因子 C 是用于调整模型对于训练误差和模型的复杂度之间的权衡，C 越小，对于训练误差的惩罚就越小，模型的复杂度就越低，可能会出现欠拟合的情况；C 越大，对于训练误差的惩罚就越大，模型的复杂度就越高，可能会出现过拟合的情况，因此，根据实际问题的特点和要求，需要根据数据集的复杂程度，选择合适的惩罚因子 C 值，本研究 C 值最终取值为 891.4438。核函数宽度 g 是径向基函数的带宽参数，用于控制支持向量机模型的复杂度和泛化能力，调节带宽参数 g 可以影响模型在新数据上的预测结果，需要在模型的训练中进行合理的调参，不合适的 g 值很容易导致过拟合或欠拟合的问题，本研究 g 值最终取 0.00156。

当 SVM 模型选择径向基核函数时，在惩罚因子 C 值取 891.4438，核函数宽度 g 值取 0.00156，构建猪只声音分类模型，其训练集的准确率为 88.67%，测试集的准确率为 87.83%，基本实现有效分类的效果，如图 5-2 为猪只各个声音类型训练集的准确率和混淆矩阵，图 5-3 为测试集的准确率和混淆矩阵。



图 5-2SVM 模型训练集各类别准确率混淆矩阵

Figure 5-2 Accuracy Confusion Matrix of Each Category of SVM Model Training Set

中国知网 https://www.cnki.net

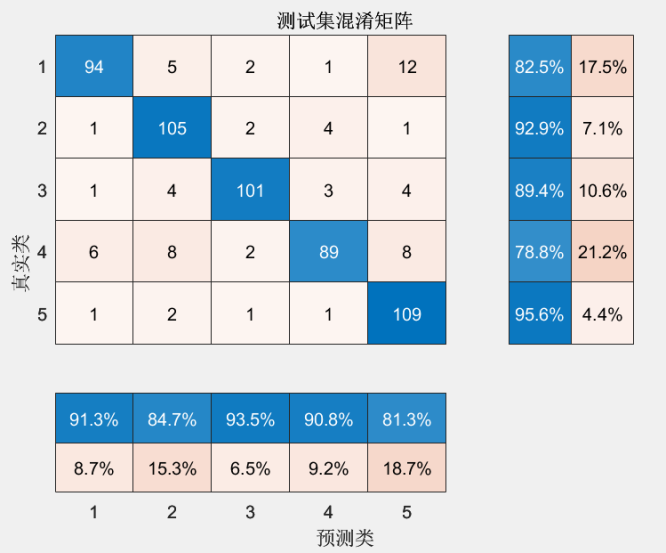


图 5-3SVM 模型测试集各类别准确率混淆矩阵

Figure 5-3 Accuracy Confusion Matrix of Each Category of SVM Model Test Set

在图 5-2、5-3 中，真实类别是每类猪只声音类别的实际样本数，蓝色对角线是分类模型在每类猪只声音类别的正确分类样本数，网格方框的颜色与值的大小有关，从混淆矩阵直观看出，模型在各个类别猪只声音分类均达到基本效果，基于支持向量机的猪只声音分类研究中，猪只咳嗽声分类准确率最佳，猪只哼唧声分类效果较其它类别准确率欠佳。

5.3 基于隐马尔科夫的猪只声音分类

本次研究中 HMM 对猪只声音分类所使用的数据集以及训练集、测试集划分情况与 SVM 模型一致，详见前一小节。在构建 HMM 对猪只声音进行分类研究时，首先是以 MFCC 特征参数作为模型的输入，然后进行 HMM 模型参数初始化，包括对声音隐藏状态数、初始转移概率矩阵的设置、对每个状态的特征向量进行 K 均值聚类得到每个状态混合正态分布以及指定其正态高斯概率密度函数（Normal Gaussian Probability Density Function，NGPDF）的个数等，之后设置模型最大迭代次数，接着进行 HMM 模型学习，主要包括使用 Baum-Welch 算法进行参数重估以及使用 Veterbi 算法对联合概率进行计算，检验 HMM 是否收敛，收敛则输出 HMM 模型的最优参数，进行声音识别。图 5-4 为 HMM 模型构建流程。

中国知网 https://www.cnki.net

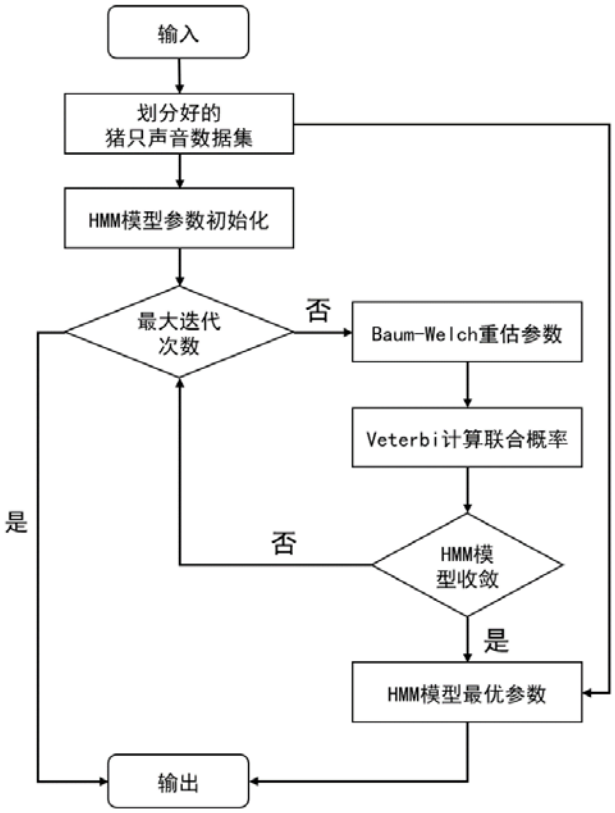


图 5-4 HMM 模型构建流程

Figure 5-4 HMM model construction process

HMM 模型参数设置主要包括 HMM 模型参数初始化过程中声音隐藏状态数的设置和初始转移概率矩阵设置以及对每个状态的特征向量进行 K 均值聚类得到每个状态混合正态分布以及指定其正态高斯概率密度函数的个数、迭代次数的设置。

声音隐藏状态数表示猪只声音信号在时间序列上的不同的状态数，在 HMM 模型中声音隐藏状态数的选择取决于所需的模型精度、允许的计算复杂度以及可用的数据量等因素，声音隐藏状态数越多，模型的精度越高，但是计算复杂度也会加大。本研究共有五类猪只声音类型，共约 10000 个样本，且差异明显，所以将声音隐藏状态数设置的较高，其取值为 100。设置初始概率的长度与状态数相同，首元素为 1，其他元素为 0。

初始转移矩阵的设置与声音隐藏状态数有关，在 HMM 模型中，初始转移矩阵表示从一个隐藏状态转移到其他隐藏状态的概率，声音隐藏状态数越多，则需要设置合适的初始转移矩阵，以保证模型训练的准确性和精度，所以，当声音隐藏状态数设置为 100 时，本研究初始转移矩阵需要设置为 99*99 矩阵，每行总值为 1 且不变，初始转移矩阵每行总值为 1 是为了确保状态转移的完备性和唯一性，这样可以确保从一个

中国知网 https://www.cnki.net

隐藏状态到另一个隐藏状态的转移概率总和为 1，即每时间必定处于某一个状态，避免出现识别意义不清或无意义的情况，从而增加了模型的准确性和可靠性。

对每个状态的特征向量进行 K 均值聚类得到每个状态混合正态分布以及指定其正态高斯概率密度函数的个数，HMM 对每个状态的特征向量进行 K 均值聚类的原因是为了降低特征向量的维度，并且能够更好地提取数据中的重要特征，从而提高模型的准确性和可靠性。设计正态高斯概率密度函数个数的具体要求取决于数据集的质量和大小，如果数据集较大且具有较好的质量，则可以选择较多的正态高斯概率密度函数，否则应该选择较少的数量来避免出现过拟合问题，本研究数据量约 10000 个，且已完成预处理操作，所以将正态高斯概率密度函数设置为 5 个较为合适。

在 HMM 模型中，迭代次数应该足够大，以确保模型可以收敛，并且在迭代后可以检查模型的性能来确定是否需要进一步迭代，本研究通过反复调整，确定其迭代次数为 60。

在模型构建完成，对猪只声音样本数据集进行分类 HMM 分类模型构建后，其训练集的准确率为 90.96%，测试集的准确率为 87.65%，实现有效的分类效果，图 5-5 为猪只各个声音类型的训练集准确率和混淆矩阵，图 5-6 为测试集准确率和混淆矩阵。

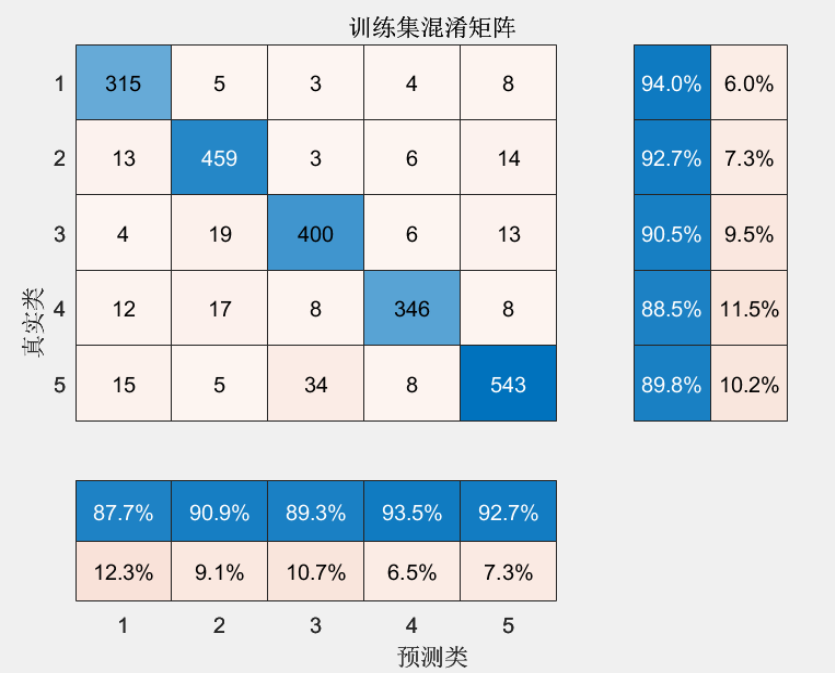


图 5-5 HMM 模型训练集各类别准确率混淆矩阵

Figure 5-5 HMM Model Training Set Accuracy Confusion Matrix of Each Category

中国知网 https://www.cnki.net

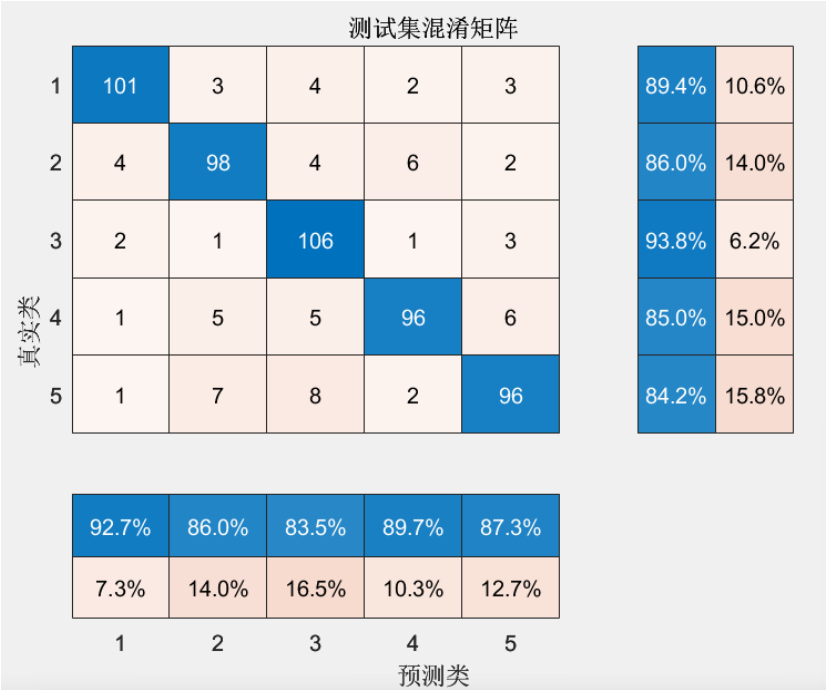


图 5-6 HMM 模型测试集各类别准确率混淆矩阵

Figure 5-6 Accuracy Confusion Matrix of Each Category of HMM Model Test Set

由图 5-5、5-6 的混淆矩阵可知，模型在各个类别猪只声音分类均达到分类效果，其中，猪只呼噜声分类准确率最佳，猪只咳嗽声准确率不如其它类别。

5.4 基于长短期记忆网络的猪只声音分类

LSTM 网络结构是一种循环神经网络结构，包含输入模块、输入门、遗忘门、输出门和输出模块等模块，其中，输入模块负责读取输入数据，遗忘门负责维护以前的状态信息，输入门负责将新状态信息叠加到遗忘门上，输出门负责过滤掉无用信息，最终输出模块将筛选好的信息输出。

LSTM 分类算法模型具体的实现流程可以概括为以下几个步骤：首先对划分好的训练集与测试集进行数据预处理，包括数据清洗、去除噪声和缺失数据处理等；然后，对数据进行特征提取和选择，以便能够更好地训练模型；再次，确定模型的网络结构和参数，常用的网络结构包括单层 LSTM 模型、多层 LSTM 模型等；最后，进行模型的训练和评估，训练采用基于梯度下降等优化算法，本次研究的评价指标选取准确率指标。LSTM 原理流程见本文 2.5 节。本研究 LSTM 分类模型结构如图 5-7 所示，其包含了以下几层：一个接受序列输入数据的 input layer，一个具有 128 个隐含层节点并输出最后一个时间序列结果的 LSTM 层，一个全连接层，一个基于 Softmax 的分类层，模型的目的是为输入的猪只声音序列数据确定一个正确的标签或类别。

中国知网 https://www.cnki.net

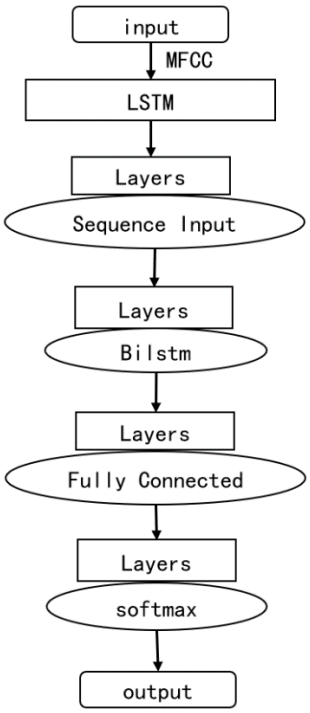


图 5-7 LSTM 分类模型结构

Figure 5-7 LSTM Classification Model Structure

LSTM 模型参数设置包括输入数据处理方式、网络结构选择、激活函数和损失函数设定、优化器选择、学习率设定，同时，还需根据具体的应用场景和数据特点来进行参数调整和优化，以得到更好的分类效果。

本次研究是将 MFCC 特征参数序列化作为模型的输入，然后使用 LSTM 的网络结构对猪只声音序列数据进行建模和分类。LSTM 可以前向传递的同时反向传递信息，同时兼顾过去和未来的信息。

常用的 LSTM 优化器包括 SGD、Adagrad、Adadelta、Adam 等，选择优化器主要考虑模型的收敛速度和效果，经过对数据样本进行多次实验，本次研究中 LSTM 网络选择 Adam 优化器。该优化器的损失函数为交叉熵损失函数。另外设置学习率为 0.01、梯度截断阈值为 1，最大的训练轮数为 200，miniBatchSize 为 126，除此之外，还指定了 GPU 作为运行设备、设定了输入序列的最长长度，并且训练数据的顺序不改变。

LSTM 算法的激活函数一般采用 tanh 函数、sigmoid 函数、softmax 函数。本次研究选择 softmax 函数作为模型激活函数，因为 softmax 函数适用于多分类问题，此外，softmax 函数与交叉熵损失函数一起使用可以避免数值溢出的问题。

最终，LSTM 模型对猪只声音样本数据集进行分类模型构建后，其训练集的准确

中国知网 https://www.cnki.net

率为 92.99%，测试集的准确率为 90.49%，分类效果较好，如图 5-8 为猪只各个声音类型训练集的准确率和混淆矩阵，5-9 为测试集的准确率和混淆矩阵，图 5-10 展示了 LSTM 模型训练过程中损失值与准确率变化情况。

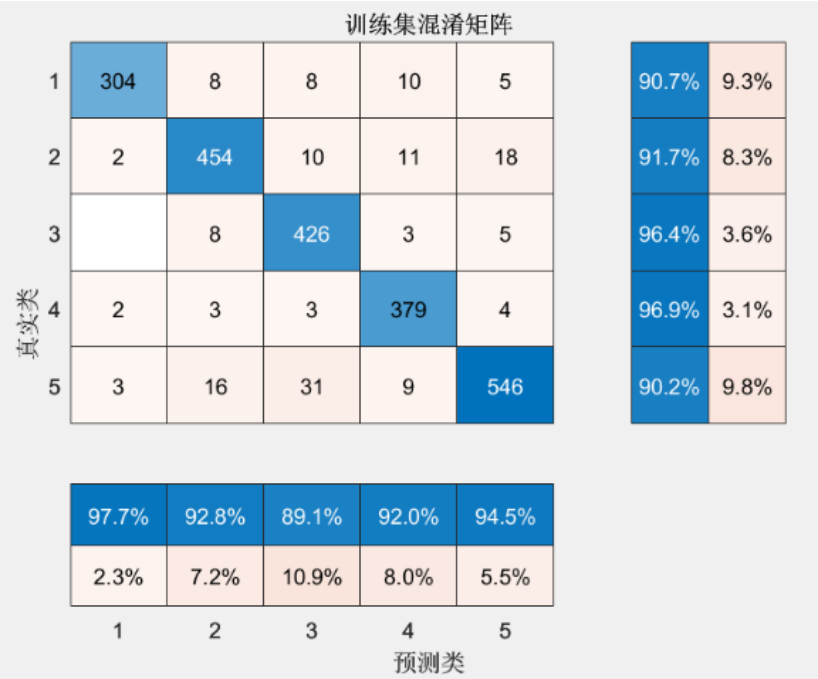


图 5-8 LSTM 模型训练集各类别准确率混淆矩阵

Figure 5-8 Accuracy Confusion Matrix of Each Category of LSTM Model Training Set

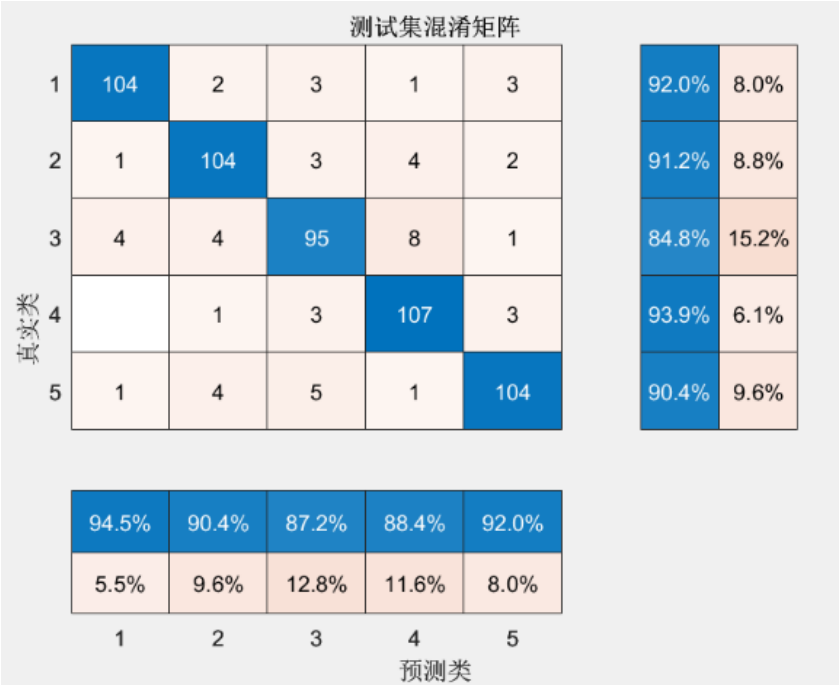


图 5-9 LSTM 模型训练集各类别准确率混淆矩阵

Figure 5-9 Accuracy Confusion Matrix of Each Category of LSTM Model Training Set

中国知网 https://www.cnki.net

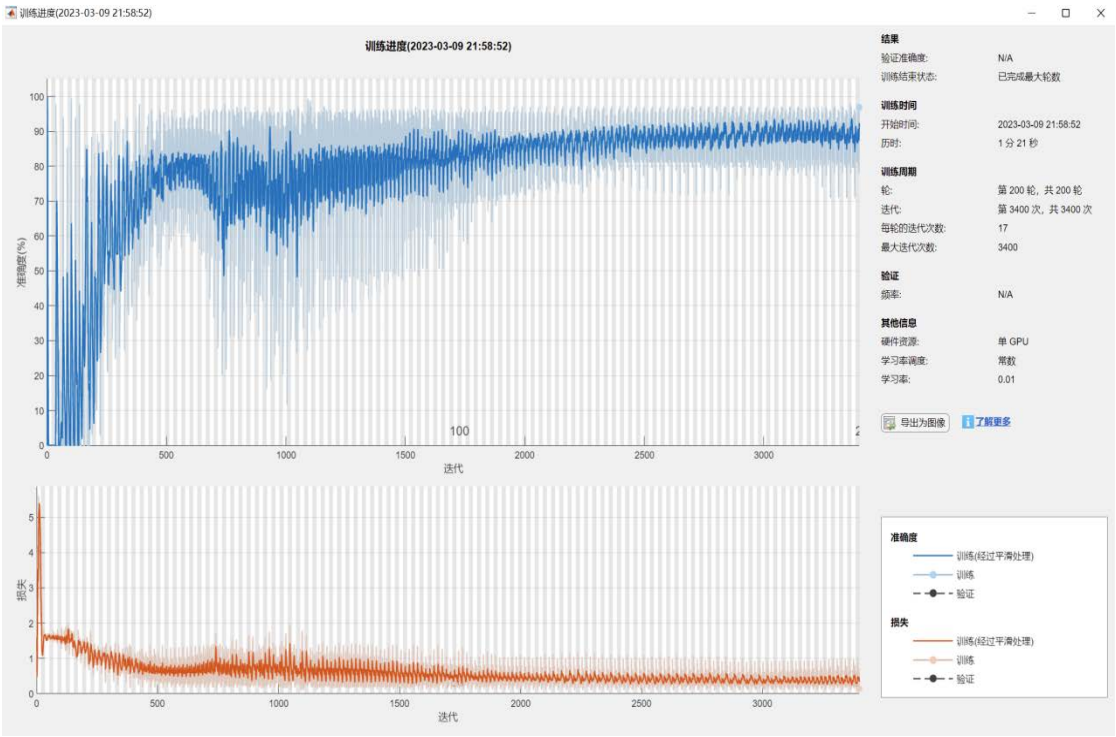


图 5-10 LSTM 模型损失值、准确率曲线

Figure 5-10 Loss Value and Accuracy Curve of LSTM Model

由图 5-8、5-9 的混淆矩阵可知，模型在各个类别猪只声音分类均实现有效的分类效果，其中，猪只哼唧声分类准确率最佳，猪只呼噜声较其它类别略有不足；由图 5-10 可知，本次 LSTM 训练共历时 1 分 21 秒，进行了 200 轮，迭代 3400 次，约在 2500 次迭代时，模型分类准确率趋于收敛。

5.5 基于改进长短期记忆网络的猪只声音分类

用 LSTM 模型进行猪只声音样本分类研究中，在各个门中有大量的计算，设计算神经网络中的参数数目为N，此时输入门、输出门和单元状态输入的权矩阵维数为$ni*nc$，上一次权矩阵维数为$nc*nc$，连接到神经网络输出的输出矩阵维数为$no*nc$，其中ni和no分别为输入和输出的维数nc，为记忆单元数，即得到下式：

$$N_{\mathrm{LSTM}}=3\times ni\times nc+3\times nc\times nc+no\times nc \tag{5-2}$$

随着我们的增加nc，N_{LSTM}将迅速增大，因此，增加存储单元的数目来增加存储量代价很大，而存储单元数目越小识别率越低，因此我们采用了一种改进的长短期记忆网络（LSTMP）结构对原有的 LSTM 模型进行替代，LSTMP 模型通过对高维度的信息进行降维，减小细胞单元的维度，从而减小相关参数矩阵的参数数目，不仅提高

中国知网 https://www.cnki.net

了识别率，而且有效地减少了计算量。LSTMP 模型在 LSTM 的基础上加入了门控机制，即增加了门控线性单元（Gated Linear Units），LSTMP 模型也具有输入门、遗忘门、细胞状态和输出门，这些结构的设计可以控制网络在信息传输和遗忘方面的能力，此外，LSTMP 模型还增加了一个用于控制当前输入在网络中传播的门控模块。这个模块包括一个门控单元和一个非线性变换，可以提高 LSTM 模型在处理时序数据时的表现。

图 5-11 为 LSTMP 工作原理，LSTMP 在工作原理上较 LSTM 增加了一个 Projection 层，是为了减少计算量，它的作用和全连接层很像，就是对输出向量做一下压缩，从而能把高纬度的信息降维，减小 cell unit 的维度，从而减小相关参数矩阵的参数数目[84]。

本研究构建的 LSTMP 层包含 16 个隐藏单元，输出层有 5 个标签种类，全连接层将 LSTMP 层的输出转换为标签种类的概率分布，softmax 层将该概率分布进行归一化，分类层将最终的预测结果与真实标签进行比较计算误差，训练时，采用随机梯度下降法（sgdm）进行优化，初始学习率设置为 0.01，学习率每隔 10 个 epoch 下降一次，最大训练轮数为 200，每次使用 126 个样本进行训练。

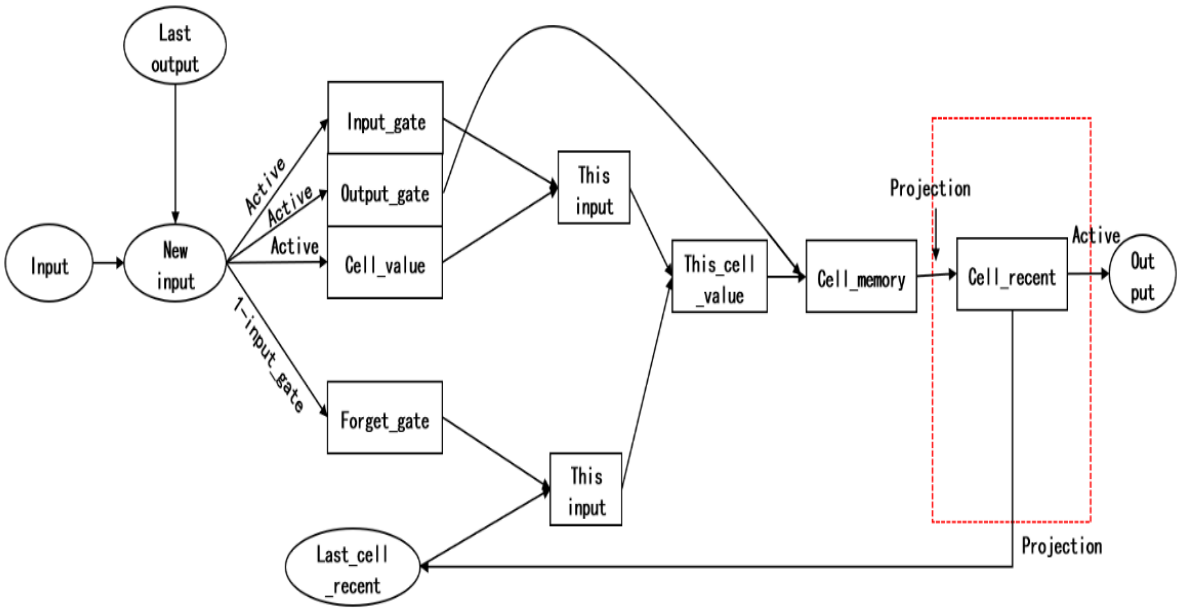


图 5-11 LSTMP 工作原理

Figure 5-11 Operating Principle of LSTMP

本次研究中，LSTMP 模型对猪只声音样本训练集的准确率为 93.43%，测试集的准确率为 91.53%，分类效果较好，图 5-12 及图 5-13 分别呈现了猪只各个声音类型的训练集、测试集准确率及混淆矩阵，图 5-14 为 LSTMP 模型训练过程中损失值与准确率

中国知网 https://www.cnki.net

变化情况。

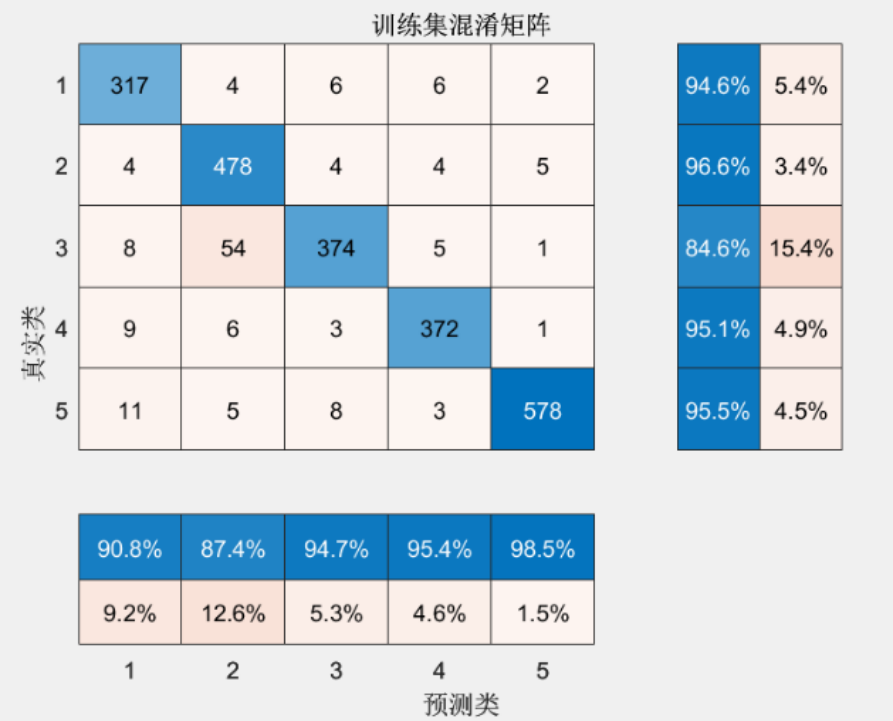


图 5-12 LSTMP 模型训练集各类别准确率混淆矩阵

Figure 5-12 Accuracy Confusion Matrix of Each Category of LSTMP Model Training Set

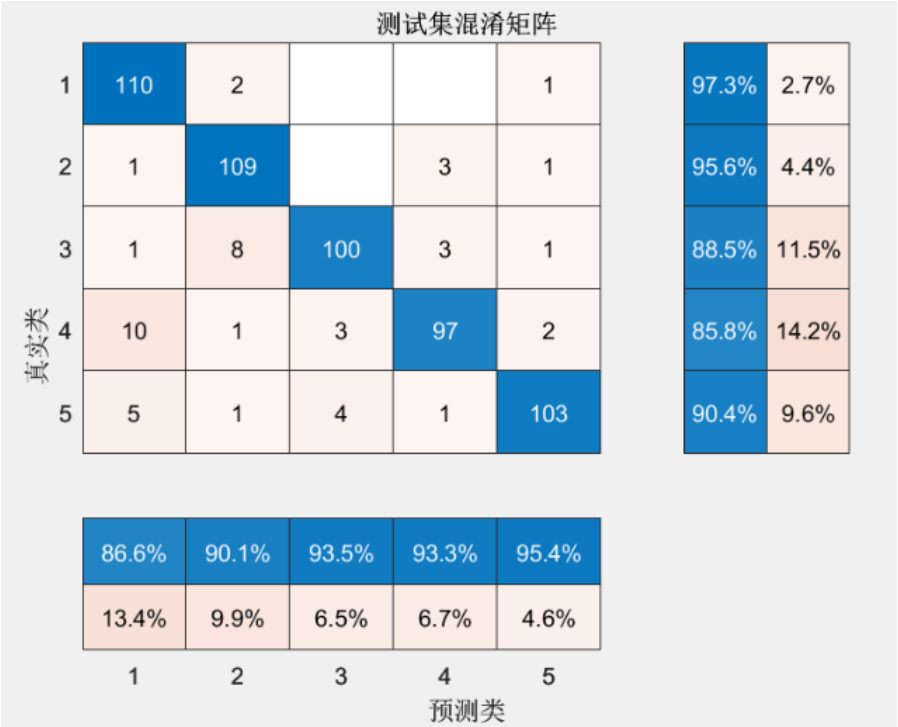


图 5-13 LSTMP 模型训练集各类别准确率混淆矩阵

Figure 5-13 Accuracy Confusion Matrix of Each Category of LSTMP Model Training Set

中国知网 https://www.cnki.net

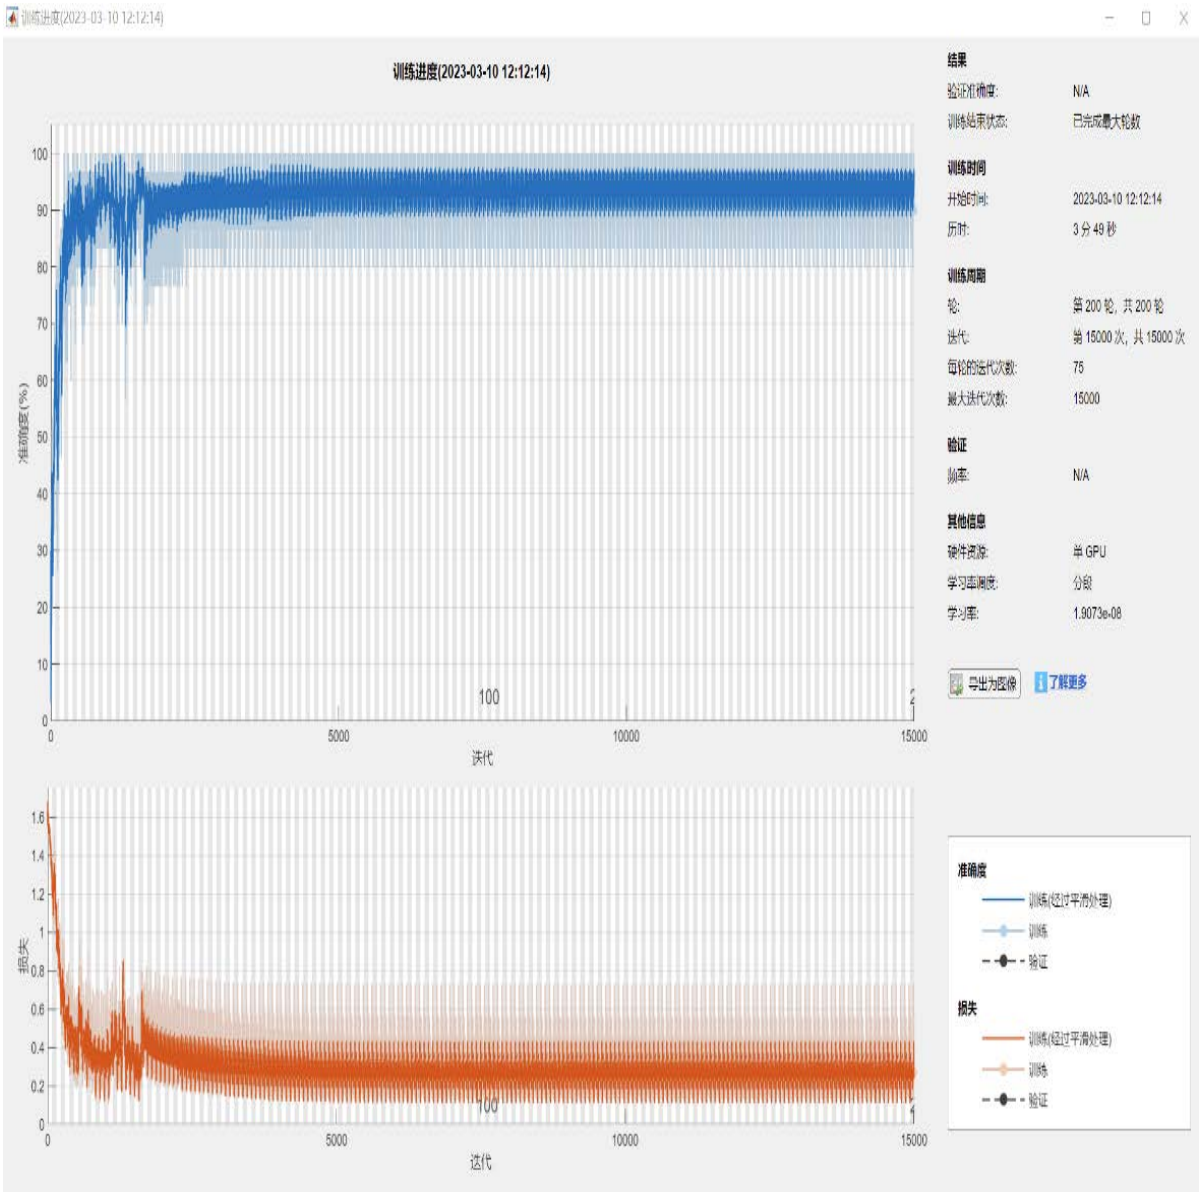


图 5-14 LSTMP 模型损失值、准确率曲线

Figure 5-14 LSTMP Model Loss Value and Accuracy Curve

由图 5-12 及图 5-13 的混淆矩阵可以看出，LSTMP 模型在各个类别猪只声音分类均达到较好分类效果。由图 5-14 可知，LSTM 训练共历时 3 分 49 秒，一共进行了 200 轮，迭代了 15000 次，在接近 5000 次迭代时，模型分类准确率趋于收敛。

5.6 猪只声音分类模型构建结果分析

表 5-2 为 SVM、HMM、LSTM、LSTMP 对猪只声音分类模型构建的效果对比，表中数据包括训练集总的分类准确率、测试集总的分类准确率、测试集猪只吃食声准确率、测试集猪只饮水声准确率、测试集猪只呼噜声准确率、测试集猪只哼唧声准确率、测试集猪只咳嗽声准确率。

中国知网 https://www.cnki.net

表 5-2 SVM、HMM、LSTM、LSTMP 模型结果对比

Table 5-2 Comparison of Results between SVM, HMM, LSTM, and LSTMP Models

模型	训练集总准确率	测试集总准确率	测试集吃食声准确率	测试集饮水声准确率	测试集呼噜声准确率	测试集哼唧声准确率	测试集咳嗽声准确率
SVM	88.67%	87.83%	82.50%	92.90%	89.40%	78.80%	95.60%
HMM	90.96%	87.65%	89.40%	86.00%	93.80%	85.00%	84.20%
LSTM	92.99%	90.49%	92.00%	91.20%	84.80%	93.90%	90.40%
LSTMP	93.43%	91.54%	97.30%	95.60%	88.50%	85.80%	90.40%

从上述表格的各个模型构建结果，我们可以看到：SVM、HMM、LSTM、LSTMP 四个模型对猪只声音分类的训练集、测试集的总准确率都达到 85%以上，其中，LSTMP 训练集总准确率最高，为 93.43%，SVM 训练集总准确率最低 88.67%，LSTMP 测试集总准确率最高，为 91.54%，HMM 测试集总准确率最低 87.65%，结果表明 SVM、HMM、LSTM、LSTMP 在对猪只声音分类均为有效分类。其中，SVM 模型对猪只声音分类研究中，测试集中猪只咳嗽声准确率为 95.60%，测试集中猪只哼唧声准确率为 78.8%，两者极差为 16.8%，即 SVM 对不同类别猪只声音分类差异性大；LSTMP 的分类准确率高于 LSTM，表明改进后模型在分类效果上提升了约 1%，模型改进是可行且有效；LSTMP 模型在对猪只声音分类研究中，较 SVM、HMM、LSTM 模型具有更优的性能。

5.7 本章小结

本章首先阐述了几种常见的声音信号分类模型，然后介绍了本次研究选择的支持向量机、隐马尔科夫、长短期记忆网络以及改进的长短期记忆网络四类分类模型对猪只声音分类的结果，选取准确率作为模型评价指标，通过对四类分类模型结果进行比较分析，最后得到了本次研究的猪只声音样本分类最优模型为 LSTMP。接下来，我们将采用不同的优化算法对该模型参数进行优化。

中国知网 https://www.cnki.net

第六章猪只声音分类模型优化

6.1 引言

鉴于前面章节已经找到了本次研究的猪只声音样本的分类模型为改进的长短期记忆网络，本章的工作则是对该模型进行优化，模型优化的目的是改进模型的性能，一般可以提升模型准确率、增强泛化能量、加快模型训练速度、提升效率、降低模型的资源消耗以及改进模型的可解释性等。目前常用的优化算法约有几十种，例如：梯度下降算法（GD）、遗传算法（GA）、粒子群优化算法（PSO）、鲸鱼优化算法（WOA）、灰狼优化算法（GWO）、麻雀优化算法（SSA）以及量子花朵授粉优化算法（QFPA）等等，本次研究采用 WOA、PSO 以及 QFPA 对 LSTMP 模型进行优化。

6.2 基于 WOA 算法的模型优化

鲸鱼优化算法 (whale optimization algorithm，WOA)是 2016 年由澳大利亚格里菲斯大学的 Mirjalili 等提出的一种新的群体智能优化算法，其优点在于操作简单，调整的参数少以及拥有较强的全局搜索能力。

鲸鱼优化算法是模仿自然界中鲸鱼捕食行为的新型群体智能优化算法，而鲸鱼的捕食行为主要分为 3 类：其一是包围猎物；其二是发泡网攻击；其三是搜索捕食。

鲸鱼靠近猎物过程中存在两种捕食行为，分别如下：

其一包围猎物，鲸鱼在狩猎时，猎物所在位置被定义为最佳位置，鲸鱼会通过收缩环绕和螺旋来改变自身的位置，式子如下：

$$D = |CX^*(t) - X(t)| \tag{6-1}$$

$$X(t+1) = X^*(t) - A \times D \tag{6-2}$$

其中，t 为当前的迭代次数，X 为位置向量，$X^*(t)$ 为截至时间 t 最优的鲸鱼位置向量，A、C 分别表示 2 个控制参数向量，D 为衡量位置的参数；其中 A、C 为：

$$\boldsymbol{A} = 2a \cdot \boldsymbol{r} - a \tag{6-3}$$

$$\boldsymbol{C} = 2 \cdot \boldsymbol{r} \tag{6-4}$$

$$\mathbf{a} = 2 - \frac{2\mathbf{t}}{\mathbf{T_{max}}} \tag{6-5}$$

其中，r 是（0，1）中的随机数，t 是当前的迭代次数，$\mathbf{T_{max}}$ 为最大迭代次数，a 的

中国知网 https://www.cnki.net

值从 2 线性降至 0。

其二发泡网攻击，气泡网捕食时，鲸鱼与猎物间的位置更新用对数螺旋方程表达：

$$X\left(t+1\right)=D'\times \mathrm{e}^{\mathrm{bl}}\times\cos\left(2\pi \mathrm{l}\right)+X^{*}\left(t\right) \quad (6\text{-}6)$$

$$D'=\left|\ \mathrm{x}^{*}(\mathrm{t})\text{-}X(\mathrm{t})\right| \quad (6\text{-}7)$$

其中，D'表示当前搜索对象与当前最优解的距离，b 表示螺旋形状参数，l 是值域为[-1，1]均匀分布的随机数。

综上对两种行为进行的概率均取 0.5，即得到如下公式：

$$X(t+1)=\begin{cases} X^{*}(t)-A\cdot D & p<0.5 \\ D^{l}\cdot e^{kl}\cdot\cos(2\pi l)+X^{*}(t) & p\geq 0.5 \end{cases} \quad (6\text{-}8)$$

为保证所有鲸鱼能在解空间中充分搜索，WOA 优化算法根据鲸鱼彼此之间的距离来更新位置，达到随机搜索的目的，其数学表达式如下：

$$D''=\left|\ C\times \mathrm{X}_{\mathrm{rand}}(\mathrm{t})-\mathrm{X}(\mathrm{t})\right| \quad (6\text{-}9)$$

$$X\left(t+1\right)=X_{rand}\left(t\right)-A\times D'' \quad (6\text{-}10)$$

其中，D''表示当前搜索个体域随机个体的距离，$X_{rand}(t)$表示当前随机个体的位置。

鲸鱼更新位置的方式是由控制参数向量|A|来决定，当|A|≥1 时，则通过搜索的方式来寻求全局最优解，当|A|<1 时，则选择收缩环绕的方式来寻求最优解。

WAO 优化算法具体实现步骤如下：

S1 是初始化种群.随机生成一定数量的鲸鱼个体作为初始种群；

S2 是计算适应度，根据问题的优化目标，计算每个鲸鱼个体的适应度值，作为评价其优劣的指标；

S3 是更新鲸鱼位置，根据当前适应度值和历史最优适应度值，更新每个鲸鱼个体的位置。通常使用鲸鱼个体之间的位置差值和一定的权重来更新位置，从而实现个体位置的变化；

S4 是更新全局最优解，根据更新后的鲸鱼个体位置，更新全局最优解，即找到当前种群中适应度值最好的鲸鱼个体；

S5 是更新鲸鱼速度，根据更新后的鲸鱼个体位置和全局最优解的位置，更新每个

中国知网 https://www.cnki.net

鲸鱼个体的速度。通常使用一定的加速度公式来计算速度的变化；

S6 是重复迭代，重复步骤 3 和步骤 4，直到满足停止准则，如达到预定的迭代次数或达到设定的收敛精度；

S7 是输出最优解，最终输出找到的全局最优解，即在优化问题中找到的近似最优解。

算法流程图如图 6-1 所示。

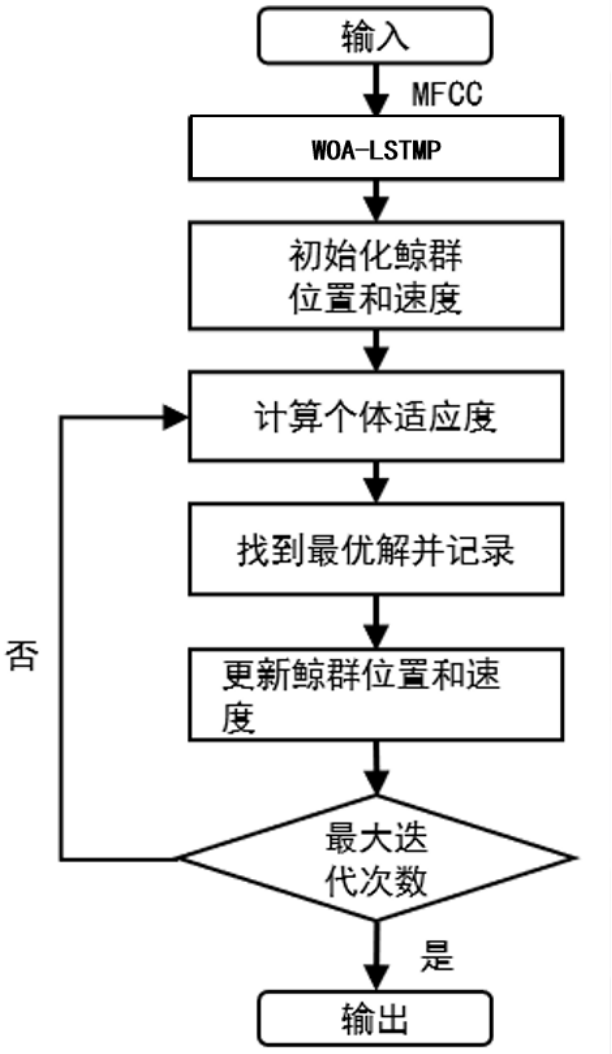


图 6-1 WOA 算法流程图

Figure 6-1Algorithm Flow Chart of WOA

本次研究的猪只声音样本采用 WOA-LSTMP 模型进行建模后，训练集的准确率为 96.96%，测试集的准确率为 92.42%，分类效果得到有效提升，图 6-2 及 6-3 分别为猪只各个声音类型的训练集及测试集的准确率及混淆矩阵。图 6-4 为 WOA-LSTMP 模型训练过程中损失值与准确率变化情况。

中国知网 https://www.cnki.net

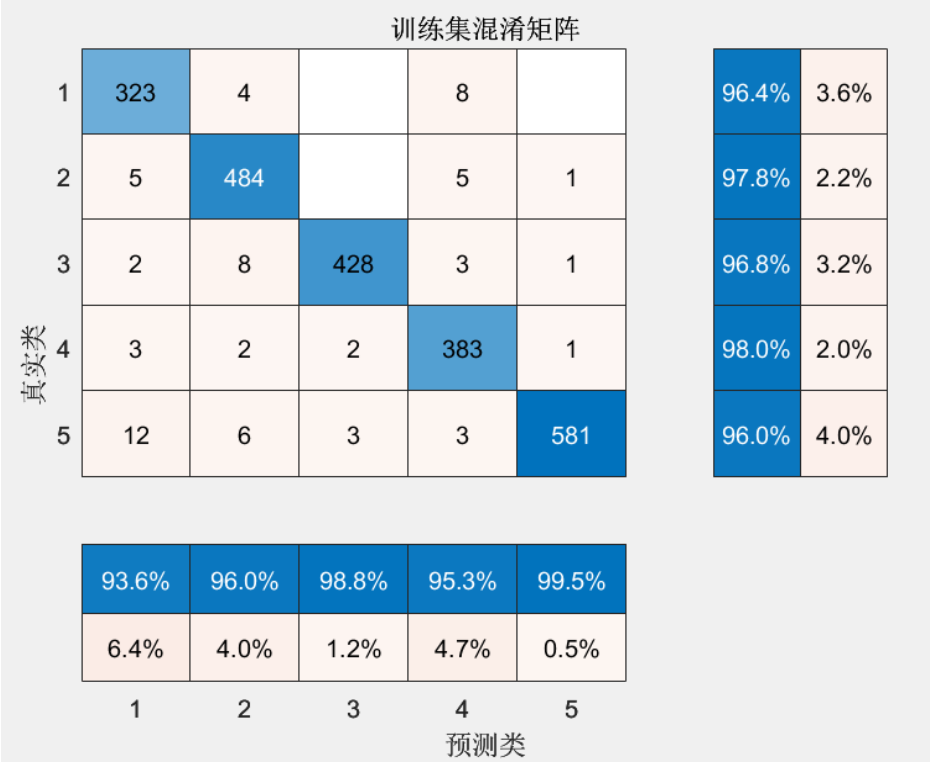


图 6-2 WOA-LSTMP 模型训练集准确率及混淆矩阵

Figure 6-2 Accuracy Confusion Matrix of Each Category of WOA-LSTMP Model Training Set

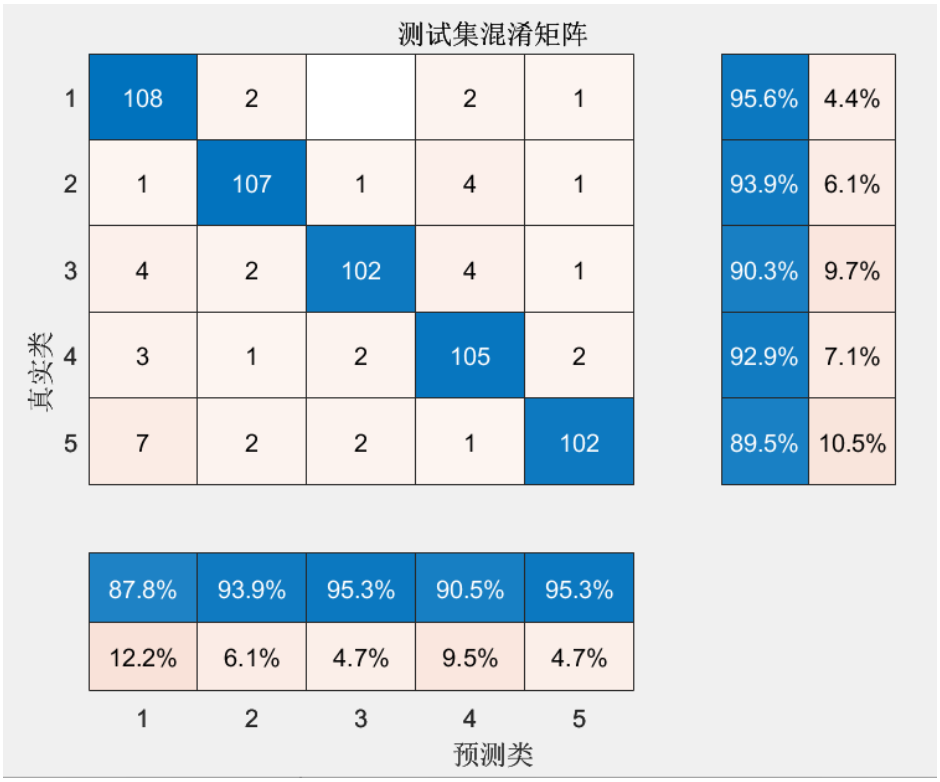


图 6-3 WOA-LSTMP 模型训练集准确率及混淆矩阵

Figure 6-3 Accuracy Confusion Matrix of Each Category of WOA-LSTMP Model Training Set

中国知网 https://www.cnki.net

由图 6-2、6-3 的混淆矩阵直观看出，模型在各个类别猪只声音分类效果均有效提升。

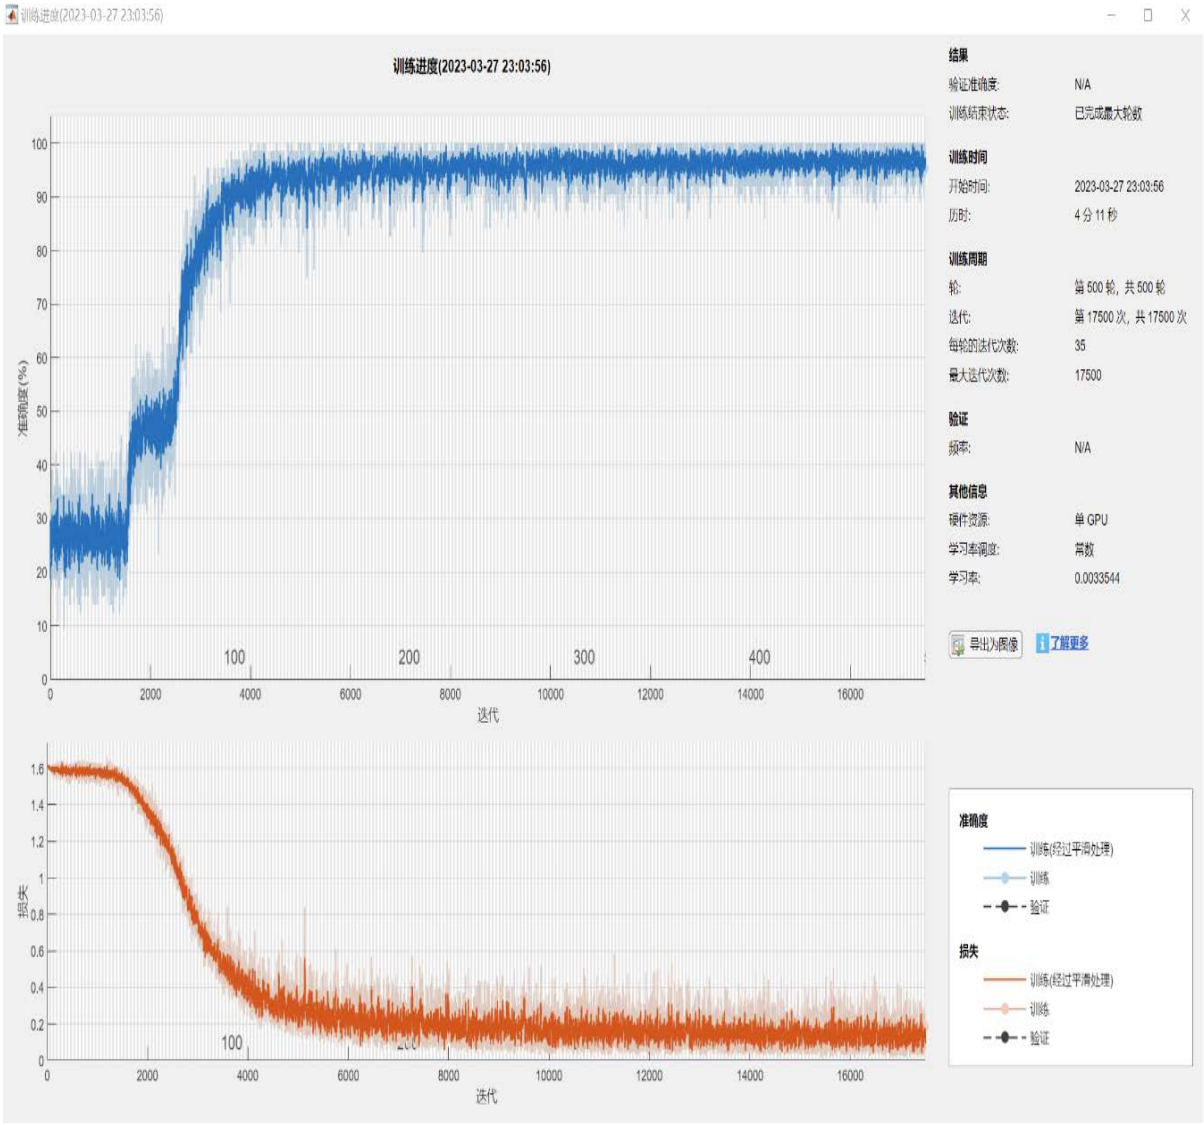


图 6-4 WOA-LSTMP 模型损失值、准确率曲线

Figure 6-4 WOA-LSTMP Model Loss Value and Accuracy Curve

由图 6-4 可知，WOA-LSTMP 训练共历时 4 分 11 秒，一共进行了 500 轮，迭代了 17500 次，约在 14000 次迭代时，模型分类准确率趋于收敛。

6.3 基于 PSO 算法的模型优化

PSO 是粒子群优化算法（Particle Swarm Optimization，PSO），该算法也是一种基于群体智能的优化算法，由 Eberhart 和 Kennedy 于 1995 年提出。PSO 算法最初是通过对鸟群集体行为的研究而发展起来的，其核心思想是通过模拟鸟群的“跟随”和“认知”行为，来寻找问题的最优解，基本原理如表 6-1 所示。

中国知网 https://www.cnki.net

表 6-1 鸟群觅食与粒子群优化算法的基本定义对照

Table 6-1 Comparison of Basic Definitions of Bird Feeding and Particle Swarm Optimization Algorithm

鸟群觅食	粒子群优化算法
鸟群	搜索空间的一组有效解（定义：种群规模 N）
觅食空间	问题的搜索空间（定义：维数 D）
飞行速度	解的速度向量
所处位置	解的位置向量
个体认知、群体协作	每个粒子根据自己历史最优位置和群体的全局最优位置更新速度和位置
找到食物	输出全局最优解

PSO 算法通过比较每个粒子位置的适应度函数值，逐步更新每个粒子的运动方向和速度，从而逐步寻找全局最优解。具体流程如下：

S1 是初始化粒子群的位置和速度，并将个体的历史最优 pBest 设为当前位置，群体中的最优个体作为当前的 gBest；

S2 是计算每个粒子的适应度函数值；

S3 是更新每个粒子的速度和位置，即如果当前适应度函数值优于历史最优值，则更新 pBest，如果当前适应度函数值优于全局历史最优值，则更新 gBest；

S4 是根据迭代次数或停止条件判断，继续迭代或结束。

在更新速度和位置时，PSO 算法引入了两个重要参数，分别是学习因子和惯性因子，学习因子用于控制粒子跟随群体最好位置的程度，惯性因子用于控制粒子自身历史速度对位置更新的影响，不同的学习因子和惯性因子组合会影响算法的性能和搜索效果。

PSO-LSTMP 模型对猪只声音样本数据集进行分类建模后，其训练集的准确率为 97.88%，测试集的准确率为 92.77%，分类效果也获得有效提升，图 6-5 及 6-6 分别为猪只各个声音类型的训练集、测试集准确率和混淆矩阵。图 6-7 为 PSO-LSTMP 模型训练过程中损失值与准确率变化情况。

我们由图 6-5 及 6-6 的混淆矩阵直观看出，模型在各个类别猪只声音分类中均实现分类效果提升。

中国知网 https://www.cnki.net

由图 6-7 可知，PSO-LSTM 训练共历时 8 分 9 秒，一共进行了 500 轮，迭代了 17500 次，约在 6000 次迭代时，模型分类准确率趋于收敛。

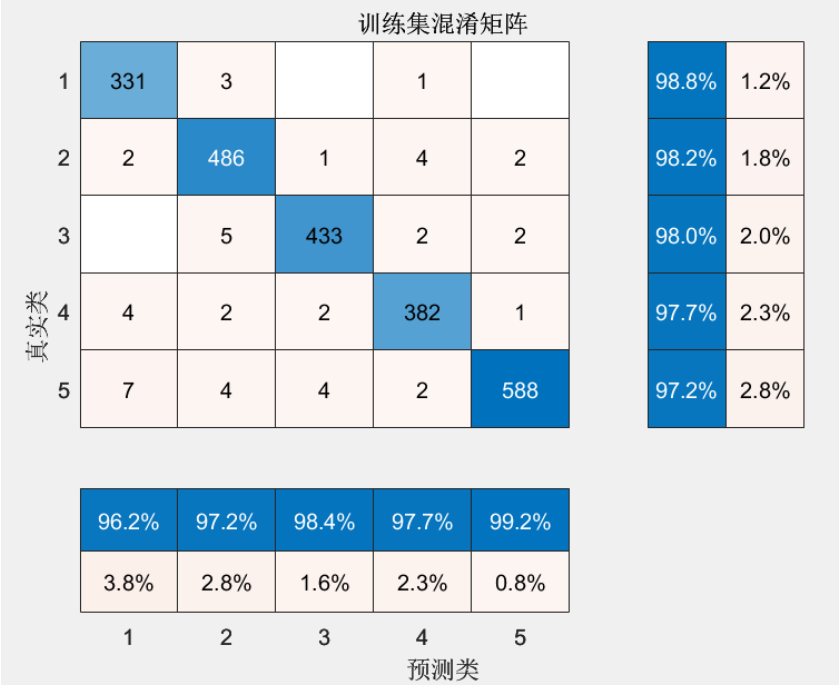


图 6-5 PSO-LSTMP 模型训练集准确率及混淆矩阵

Figure 6-5 Accuracy Confusion Matrix of Each Category of PSO-LSTMP Model Training Set

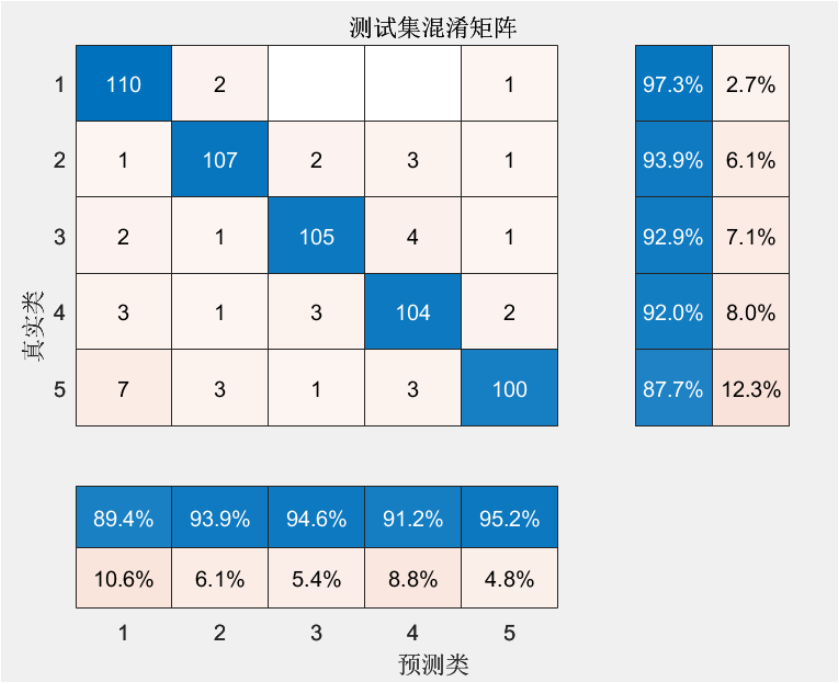


图 6-6 PSO-LSTMP 模型训练集准确率及混淆矩阵

Figure 6-6 Accuracy Confusion Matrix of Each Category of PSO-LSTMP Model Training Set

中国知网 https://www.cnki.net

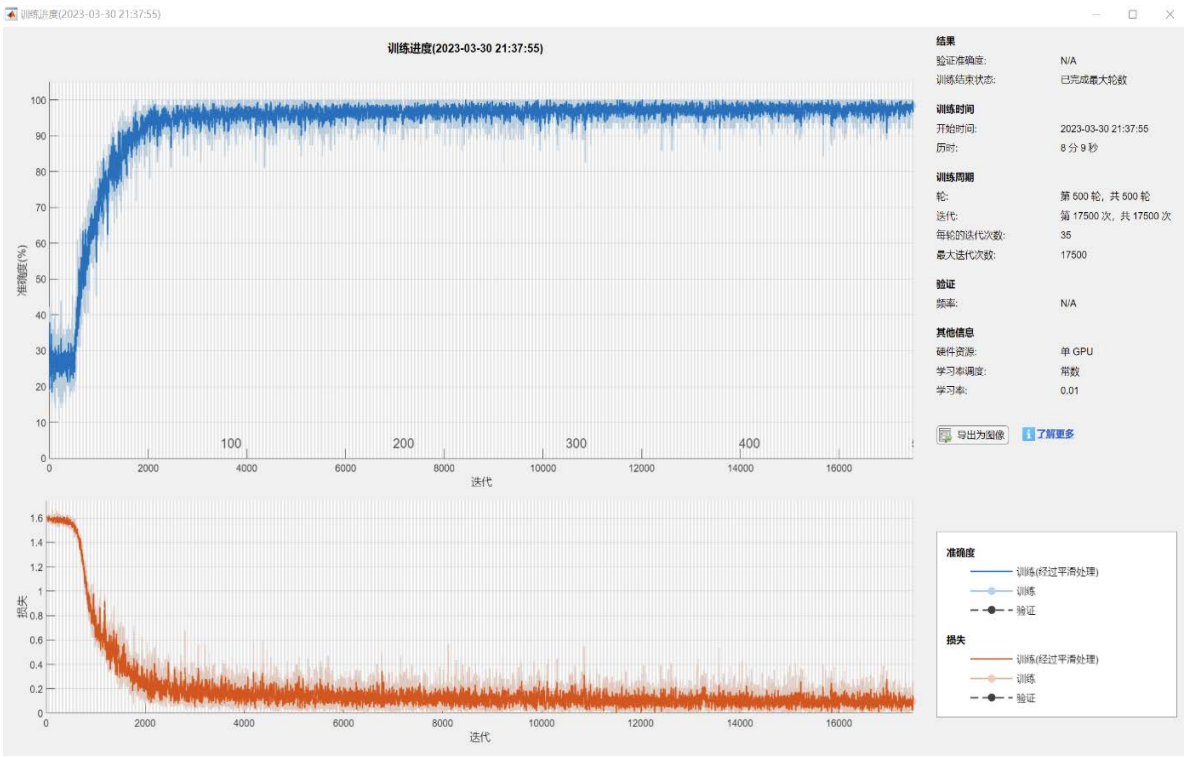


图 6-7 PSO-LSTMP 模型损失值、准确率曲线

Figure 6-7 PSO-LSTMP Model Loss Value and Accuracy Curve

6.4 基于 QFPA 算法的模型优化

量子花朵授粉优化算法（Quantum-behaved Flower Pollination Algorithm，QFPA）是一种启发式优化算法，灵感来源于植物受精的过程，该算法基于量子力学中的行为，即采用量子位和量子门的方法进行量子态的表示、演化和测量，通过花朵的授粉过程来实现最优解的搜索，与其他优化算法相比，QFPA 能够有效地避免陷入局部最优解。

量子系统是基于量子力学理论的物理系统，用量子比特代替传统计算中的二进制比特，具有并行计算、量子纠缠、量子迷惑等特别性质，可用于高效处理大规模数据和优化问题。

量子空间内，量子花朵空间的花朵状态用波函数 $\varphi(x,t)$ 去描述，d 维空间的第 i 个花朵的位置表示为：

$$X_i(t)=(x_{i1},x_{i2},\cdots,x_{in}) \tag{6-11}$$

建立可变的 δ 势阱场使花朵在局部点 $p(p_1,p_2,\cdots,p_d)$ 具有聚集态，δ 势阱场可以用于模拟量子空间中的粒子行为，并可用于量子计算和量子模拟，以一定的概率密度

中国知网 https://www.cnki.net

$|\varphi(x,t)|^2$ 出现在空间任何点，使花朵可以在整个可行解空间进行搜索，但又不会发散到无穷处[85]。如图 6-8 所示，QFPA 算法的具体工作流程如下：

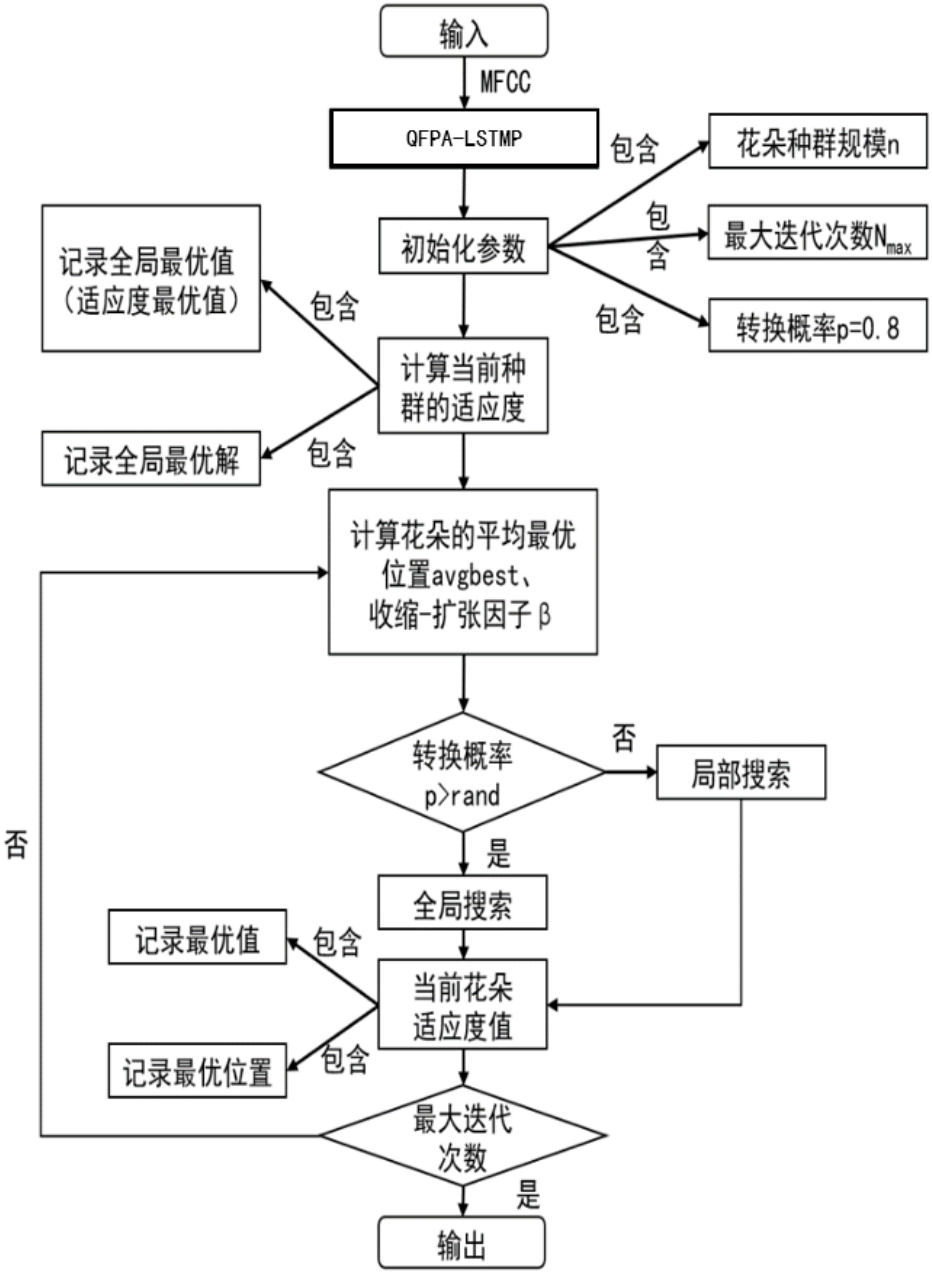


图 6-8 QFPA 工作原理

Figure 6-8 QFPA Working Steps

上述流程中的输入数据，在本次研究中采用猪只声音信号频域表示，并使用 MFCC 转换音频特征，将这些特征序列化后成为 QFPA-LSTMP 网络的输入。接下来对优化模型的参数初始化，包括花朵种群规模、最大迭代次数以及转换概率，研究中 QFPA 优化模型种群数量 n 设置为 30，优化模型最大迭代次数 N_{max} 设置为 10，转换概

中国知网 https://www.cnki.net

率 p 设置为 0.8，然后计算当前种群的适应度，并记录全局最优值以及得出全局最优解，接着计算花朵的平均最优位置 avgbest 和收缩-扩张因子 β，其计算公式如下：

$$\text{avgbest}=\frac{1}{n}\sum_{i=1}^{n}p_i(t)=\left[\frac{1}{n}\sum_{i=1}^{n}p_{i1}(t),\frac{1}{n}\sum_{i=1}^{n}p_{i2}(t),\cdots,\frac{1}{n}\sum_{i=1}^{n}p_{il}(t)\right] \quad (6\text{-}12)$$

$$\beta=(1-0.5)\frac{N_{\max}-t}{N_{\max}}+0.5 \quad (6\text{-}13)$$

之后得出 δ 势阱的特征长度，δ 势阱的特征长度被定义为一个无量纲的参数，其值与势垒高度和宽度有关，这个特征长度是解析求解波函数的关键参数之一，其公式如下：

$$L(t)=2\beta\left|\ \text{avgbest}-x(t)\right| \quad (6\text{-}14)$$

在进行全局搜索时，为了让花朵能收敛到局部点 p,计算出花朵局部吸引因子 q，其公式如下：

$$q=\alpha x(t)+(1-\alpha)x_{\text{best}} \quad (6\text{-}15)$$

其中，$\alpha\in[0,1]$，x_{best} 表示在种群中目前最优位置；使用蒙特卡罗方法，花朵位置的迭代方程为：

$$X(t+1)=q+L(t)\ln\frac{1}{v}=q+2\beta\left|\ \text{avgbest}-x(t)\right|\ln\frac{1}{v} \quad (6\text{-}16)$$

其中，$v=\text{rand}(0,1)$，当种群进行局部搜索时，局部吸引因子为种群当前的最优位置，最后进行结束条件判断。

QFPA-LSTMP 模型对猪只声音样本数据集进行分类模型构建后，其训练集的准确率为 95.46%，测试集的准确率为 93.47%，分类效果均得到有效提升。图 6-9 及 6-10 分别为猪只各个声音类型的训练集、测试集准确率和混淆矩阵。图 6-11 为 QFPA-LSTMP 模型训练过程中损失值与准确率变化情况。

由图 6-9 及 6-10 的混淆矩阵可以看到，模型在各个类别猪只声音分类均实现分类效果的有效提升。

中国知网 https://www.cnki.net

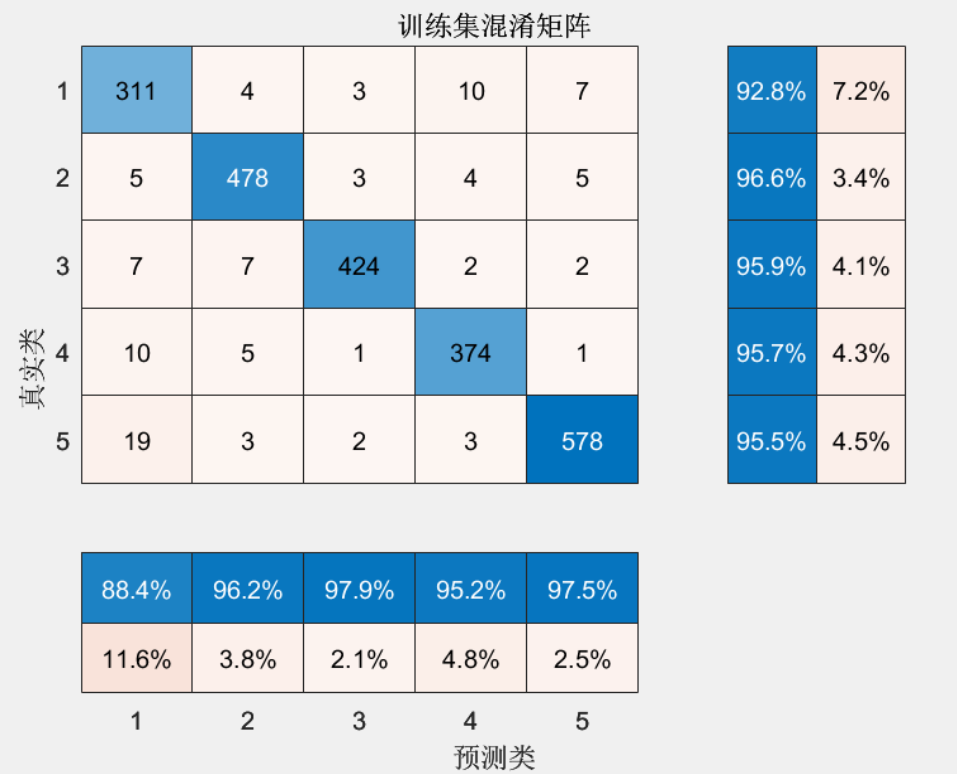


图 6-9 QFPA-LSTMP 模型训练集准确率及混淆矩阵

Figure 6-9 Accuracy Confusion Matrix of Each Category of QFPA-LSTMP Model Training Set

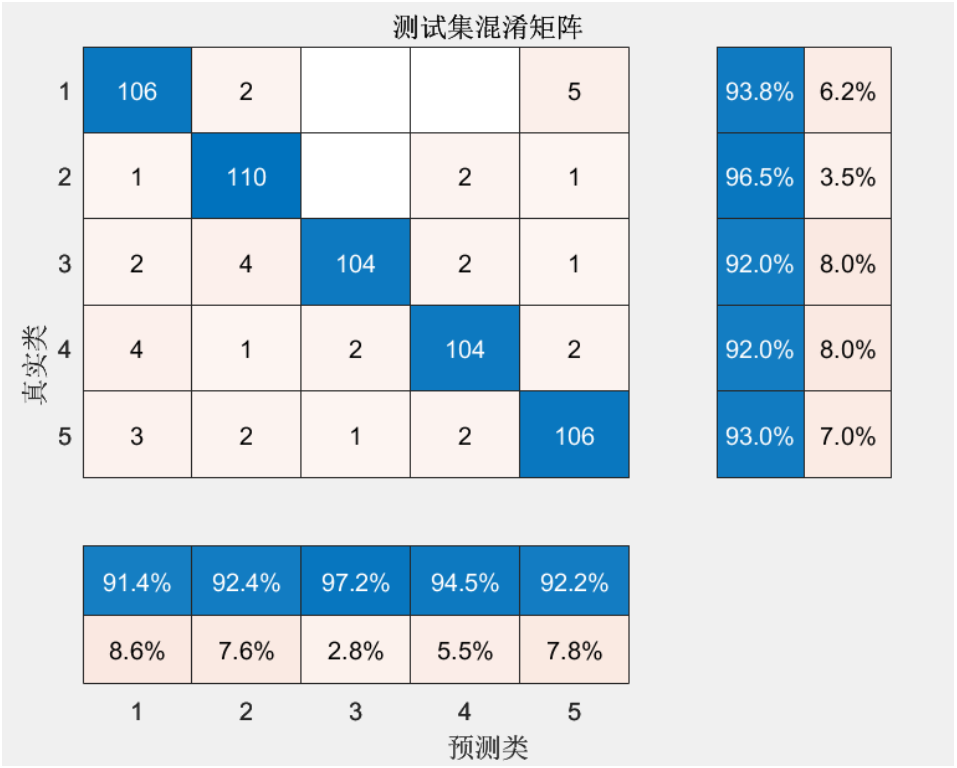


图 6-10 QFPA-LSTMP 模型训练集准确率及混淆矩阵

Figure 6-10 Accuracy Confusion Matrix of Each Category of QFPA-LSTMP Model Training Set

中国知网 https://www.cnki.net

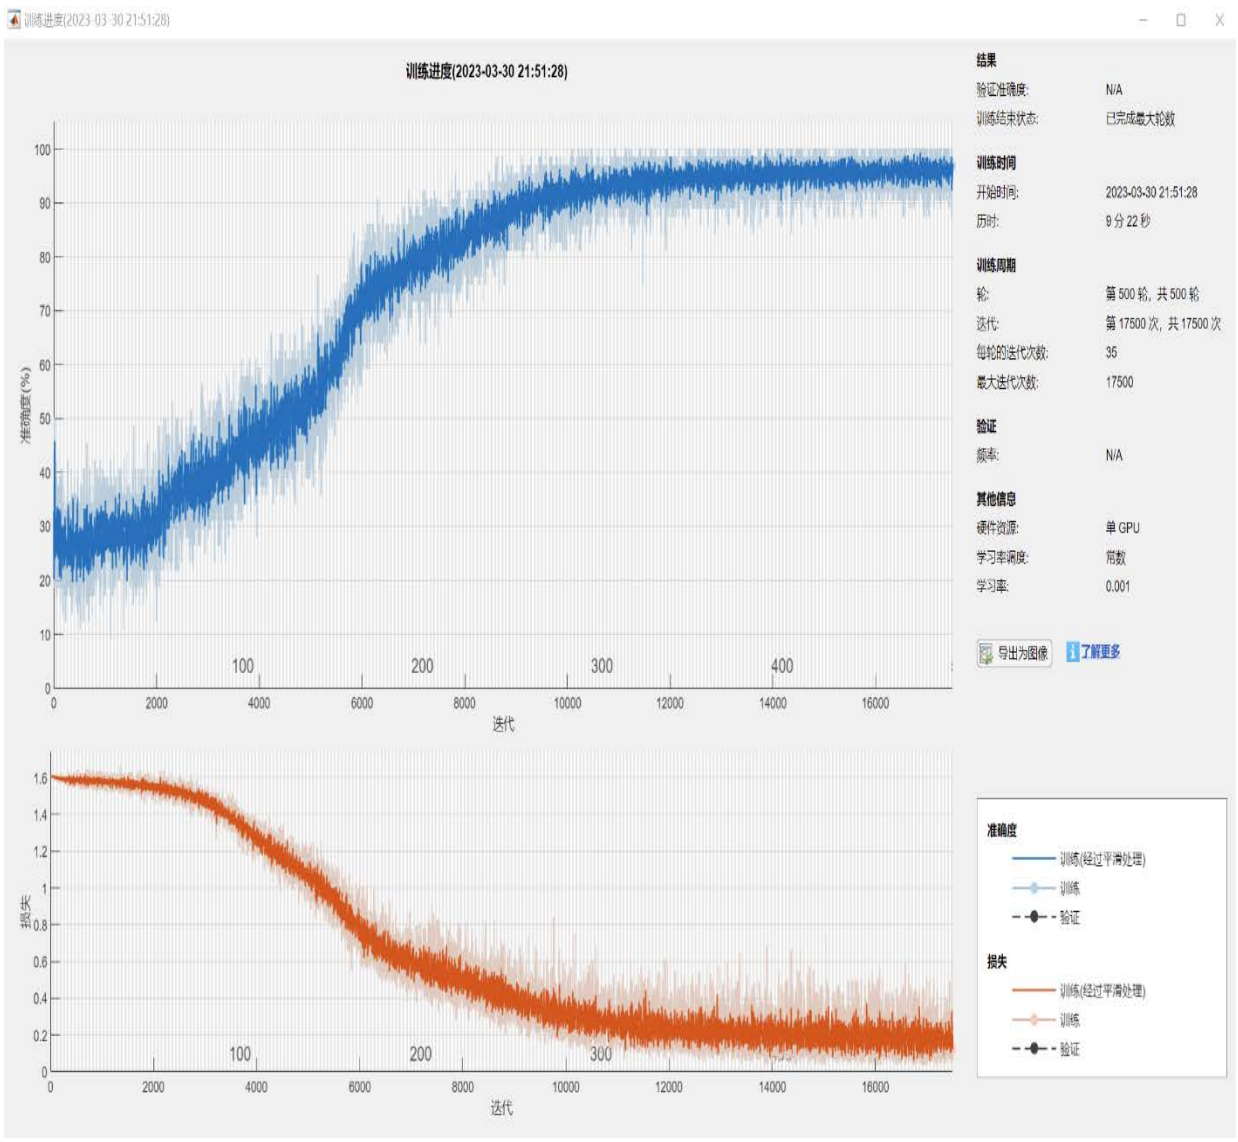


图 6-11 QFPA-LSTMP 模型损失值、准确率曲线

Figure 6-11 QFPA-LSTMP Model Loss Value and Accuracy Curve

6.5 结果分析

模型优化效果分析，一般从优化目标的达成程度、算法收敛速度、稳定性、参数设置等方面进行比较和评价。本次研究中对改进模型 LSTMP 优化效果评价采用对目标的达成程度进行对比分析，目标的达成程度即分类效果，三种优化算法的最终结果如表 6-2 所示，表中包含了 LSTMP、WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 模型对各个猪只声音数据集的分类结果对比，分别是训练集总准确率、测试集总准确率、测试集猪只吃食声准确率、测试集猪只饮水声准确率、测试集猪只呼噜声准确率、测试集猪只哼唧声准确率、测试集猪只咳嗽声准确率。

中国知网 https://www.cnki.net

表 6-2 LSTMP、WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 模型结果

Table 6-2 Results of LSTMP, WOA-LSTMP, PSO-LSTMP, QFPA-LSTMP Model

模型	训练集总准确率	测试集总准确率	测试集吃食声准确率	测试集饮水声准确率	测试集呼噜声准确率	测试集哼唧声准确率	测试集咳嗽声准确率
LSTMP	93.43%	91.54%	97.30%	95.60%	88.50%	85.80%	90.40%
WOA-LSTMP	96.96%	92.42%	95.60%	93.90%	90.30%	92.90%	89.50%
PSO-LSTMP	97.88%	92.77%	97.30%	93.90%	92.90%	92.00%	87.70%
QFPA-LSTMP	95.46%	93.47%	93.80%	96.50%	92.00%	92.00%	93.00%

通过上表的结果分析，可知：WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 三个模型对猪只声音分类的训练集、测试集的总准确率都达到 85%以上，其中，WOA-LSTMP 模型测试集总准确率为 92.42%、PSO-LSTMP 模型测试集总准确率为 92.77%、QFPA-LSTMP 模型测试集总准确率为 93.47%，结果表明 WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 在对猪只声音分类的研究上均为有效的分类结果，同时三种优化算法对 LSTMP 模型的准确率实现了提升，证明三种优化算法对猪只声音分类模型优化均是可行的。

QFPA-LSTMP 测试集总准确率为 93.47%，高于 WOA-LSTMP、PSO-LSTMP 输出结果的准确率，并且在猪只咳嗽声的分类准确率上表现最佳。

上述结果中，QFPA-LSTMP 测试集总准确率为 93.47%，高于 WOA-LSTMP、PSO-LSTMP 输出结果的准确率，并且在猪只咳嗽声的分类准确率上表现最佳。因此，本研究最终推荐采用 QFPA-LSTMP 组合模型进行猪只声音的分类。

为了较好展示研究成果，我们基于 Matlab GUI 设计了一个猪只声音分类可视化交互界面。该界面主要包括三个模块，分别为数据预处理、分类模型训练以及猪只声音识别显示，显示区域主要是显示分类过程中猪只声音的时域波形图和 MFCC 特征参数提取后的三维显示，最终输出猪只声音的分类结果，可视化交互界面如图 6-12 所示。

中国知网 https://www.cnki.net

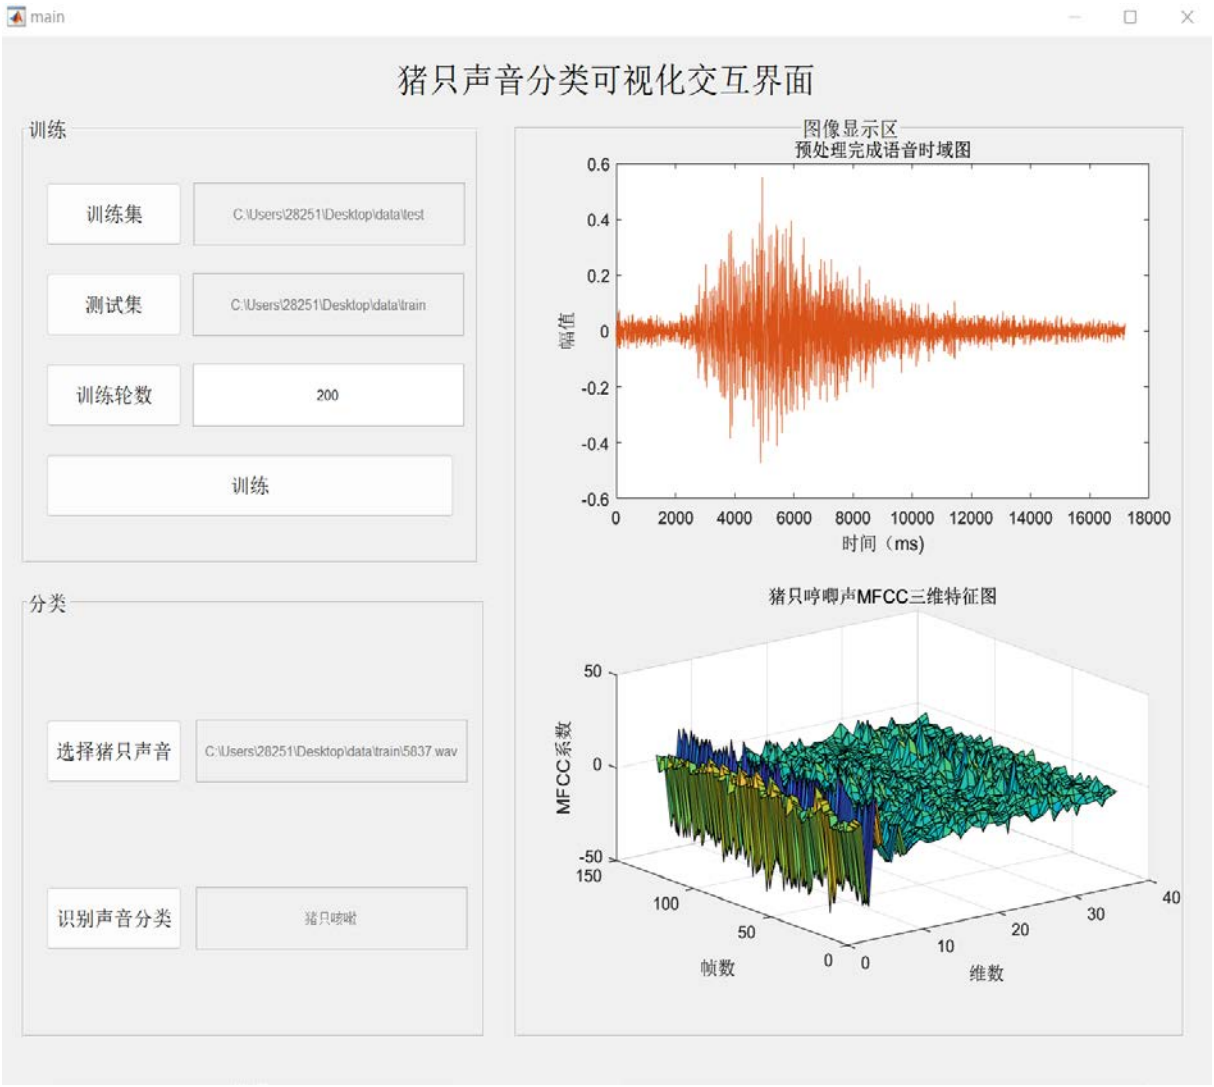


图 6-12 猪只声音分类可视化交互界面展示

Figure 6-12Visualization and Interactive Interface for Pig Vocalization Classification

6.6 本章小结

本章主要对基于猪只声音分类最优模型 LSTMP 进行智能算法的模型优化，选取了三种智能优化算法，分别是 WOA、PSO 以及 QFPA，用三种算法分别与 LSTMP 模型进行组合，构建了 WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 三个优化分类算法模型，并与 LSTMP 模型分类结果进行对比，发现 QFPA-LSTMP 组合模型分类效果最佳，并设计了基于 Matlab GUI 的猪只声音分类可视化交互界面，为后期猪只声音在线实时监测奠定基础，同时本次研究结果也为猪只疫病预警提供新思路，为从事相关研究的学者提供参考。

中国知网 https://www.cnki.net

第七章总结与展望

7.1 总结

当前，生猪养殖产业正快速向规模化、智能化、精细化方向转型，保障猪只健康成长是养殖户、企业最关注的事情之一，在养殖过程中健康监测工作占比也日益凸显。传统猪只健康监测一般采取人工监测的方式，该方式鉴定猪只疫病效率低下，操作费时费力且容易引起人畜共患病情况等，本文基于智能语音技术对猪只声音分类进行研究，为后期实现猪只实时在线声音监测与疫病预警奠定基础。本次研究的主要内容与成果如下：

（1）实现猪只声音数据集的采集与处理。本次研究中使用的猪只声音数据集来源于三个不同地方的生猪养殖场，在生猪养殖及疾病防治的专业人员指导下，对原始数据样本进行了数据标注与样本切割，分别从 10 万余条原始数据中截取出了 5 类共 10000 条目标样本，目标样本包括猪只吃食声、饮水声、呼噜声、哼唧声、咳嗽声；对目标样本数据完成数据预处理工作，预处理步骤包括预加重、分帧加窗以及滤波降噪，针对猪只声音样本中背景噪声，通过对比谱减法、维纳滤波法以及小波降噪效果，选取了维纳滤波法降噪，而针对样本中特定尖锐的噪声选取 FIR 滤波器进行降噪。

（2）实现猪只声音信号特征参数提取。本次研究分别对猪只声音信号提取了四类特征参数，分别是时域中的短时能量与短时过零率、频域中的功率谱密度、时频域中的语谱图以及倒谱域中的梅尔倒谱系数，通过对四类特征参数的提取对比分析，选取 MFCC 作为本次分类研究的特征参数，并以 MFCC 参数作为后面分类模型的输入数据。

（3）开展猪只声音分类模型研究。本次研究基于前述的 5 类猪只声音样本分别构建了 SVM、HMM、LSTM 以及 LSTMP 四种猪只声音分类模型，采用准确率作为模型效果的评价指标，应用分层抽样方法将数据集划分为训练集与测试集的比例满足 8：2，研究结果显示，SVM、HMM、LSTM、LSTMP 对猪只声音总的分类准确率分别为 87.83%、87.65%、90.49%、91.54%，均超过 85%，分类模型均可行且有效，其中 LSTMP 的分类效果最佳。

（4）对猪只声音分类模型智能优化算法进行研究。本次研究采取了 WOA、PSO 以及 QFPA 三种智能优化算法与 LSTMP 组合，搭建了 WOA-LSTMP、PSO-LSTMP、QFPA-LSTMP 三个优化分类模型，研究结果显示，WOA-LSTMP、PSO-LSTM、QFPA-LSTMP 对猪只声音总的分类准确率分别为 92.54%、92.77%、93.47%，三种智能

中国知网 https://www.cnki.net

优化算法组合后的模型均高于单一的 LSTMP 模型分类准确率，证明三种智能优化算法对 LSTMP 模型优化均可行且有效，其中 QFPA-LSTMP 的组合效果最佳，并基于 Matlab GUI 设计开发了猪只声音分类可视化交互界面。

7.2 展望

本次研究在猪只声音分类方面虽然取得了一定的研究进展，但依旧存在不足，在未来的研究中仍有需要进一步深入开展如下工作：

（1）扩充猪只声音的数据集。由于本次研究采集到的有效样本数量不足、生猪种类较少，缺少对公猪、母猪的区分，同时也没有各类病猪的声音数据，在将来需前往更多养殖环境，针对不同状态的猪只进行声音信号的采集，特别是病猪的声音样本，与此同时，由于猪只实际声音来源不同，背景噪声不同，泛化能力有待提升，后续研究将进一步提高现有模型的泛化性、鲁棒性，增强模型分类效果，同时能够对病猪的咳嗽声做有效的监测；

（2）在本次研究中，考虑研究周期较短，对猪只声音样本进行选择时，仅选择了单一声样本进行识别，在未来研究中，需克服或解决混叠样本的处理。

（3）进一步与兽医学专家进行深入交流研讨，研究猪只各类传染性疾病与猪只声音之间存在的潜在规律，实现通过猪只声音实时监测辨析猪只疾病、疫病状况，减少养殖户的损失。

（4）采用前沿的现代信息技术结合研究成果，设计并实现猪只声音在线实时监测系统，对养殖场的猪只声音自动完成采集、样本端点检测、样本分割、预处理、降噪、特征提取、分类等工作。

（5）应用大量的猪只声音样本集，通过建模对猪只行为、情感进行分析，改善生猪福利，实现健康、智能化养殖。

中国知网 https://www.cnki.net

参考文献

[1]郭惠武.中国猪肉消费现状和趋势分析[J].今日养猪业,2018,No.106(04):56-63

[2]中国统计年鉴编委会.中国统计年[M].中国统计出版社,2022.

[3]陶炜煜，张剑波.“十三五”以来中国生猪市场形势分析与展望[J].农业展望,2018，10:9-12.

[4]Aarnink A, Wagemans M. Ammonia volatilization and dust concentration as affected by ventilation systems in houses for fattening pigs. Trans ASAE 1997;40(4):1161–70.

[5]Wang X, Zhang Y, Zhao LY. Effect of ventilation rate on dust spatial distribution in a mechanically ventilated airspace.Trans ASAE 2000;43(6):1877–84.

[6]Wathes CM, Jones JB, Kristensen HH, Jones E. Aversion of pigsand domestic fowl to atmospheric ammonia. Trans ASAE.2002;45(5):4289–303.

[7]Pijpers A, Schoevers EJ, Van Gogh H. The influence of diseaseon feed and water consumption and on pharmacokinetics oforally administered oxytetracycline in pigs. J Anim Sci1991;69(7):2947–54.

[8]Greiner LL, Stahly TS, Stabel TJ. Quantitative relationship ofsystemic virus concentration on growth and immuneresponse in pigs. J Anim Sci 2000;78(10).

[9]朱志刚.生猪呼吸道疾病的预防与治疗[J].中国动物保健,2023,25(01):15-16.

[10]国务院办公厅.国务院办公厅关于加强非洲猪瘟防控工作的意见[N].农业农村部官网，2019-7-15.

[11]云南省人民政府. 云南省支持生猪产业加快恢复生产发展若干措施[N]. 云南省人民政府官网，2020-6-9.

[12]中华人民共和国农业农村部.非洲猪瘟等重大动物疫病分区防控工作方案（试行）[N].农业农村部官网，2021-4-16.

[13]中国共产党中央委员会国务院.中共中央国务院关于做好 2022 年全面推进乡村振兴重点工作的意见[N].人民日报，2022-2-22.

[14]中国共产党中央委员会国务院.中共中央国务院关于做好 2023 年全面推进乡村振兴重点工作的意见[N].人民日报，2023-2-13.

[15]谭克达,王春丽,肖惠慈,王世杰.猪呼吸道疾病的预防和治疗方法分析[J].中国畜牧业,2022,(22):119-120.

[16]Ferrari S, Silva M, Guarino M, et al. Analysis of cough sounds for diagnosis of respiratory infections in intensive pig farming[J]. Transactions of the ASABE,2008,51(3):1051-1055.

[17]Van Hirtum A, Berckmans D. Objective recognition of cough-sound as biomarker for aerial

中国知网 https://www.cnki.net

pollutants[C]//2002 ASAE Annual Meeting. American Society of Agricultural and Biological Engineers, 2002: 1.

[18]Aerts J-M, Jans P, Halloy D, et al. Labeling of Cough from Pigs for On-line Disease Monitoring by Sound Analysis[J]. Transactions of the ASAE, 2005, 48(1):351-354.

[19]李影. 几种引发猪咳嗽疾病的临床诊断[J]. 吉林畜牧兽医, 2018, 39(07):14+17.

[20]韩佳伟, 朱文颖, 张博, 赵春江, 杨信廷. 装备与信息协同促进现代智慧农业发展研究[J]. 中国工程科学, 2022, 24(01):55-63.

[21]赵春江. 智慧农业的发展现状与未来展望[J]. 华南农业大学学报, 2021, 42(06):1-7.

[22]汪开英, 赵晓洋, 何勇. 畜禽行为及生理信息的无损监测技术研究进展[J]. 农业工程学报, 2017, 33(20):197-209.

[23]Moura D J, Silva W T, Naas I A, et al. Real time computer stress monitoring of piglets using vocalization analysis[J]. Computer and Electronics in Agriculture,2008,64(1):11-18.

[24]苏信锋. 影响肉猪料肉比的因素[J]. 中国畜牧兽医文摘, 2016, 32(06):220.

[25]JF Robertson, JB enzie Assessment of a cough counter for pigs[J].Farm Building Progress, 1989,95:25-28.

[26]Van Hirtum A, Berckmans D. Objective recognition of cough sound as biomarker for aerial pollutants[J]. Indoor Air,2004,14(1):10-15.

[27]V. Exadaktylos, M. Silva, J.-M. Aerts, et al. Real-time recognition of sickpig cough sounds[J]. Computers and Electronics in Agriculture, 2008,63(2):207-214.

[28]Mitchell S, Vasileios E, Sara F, et al. The influence of respiratory disease on the energy envelope dynamics of pig cough sounds[J]. Computers and Electronics in Agriculture, 2009, 69(1): 80-85.

[29]Chung Y，Oh S，Lee J，et al. Automatic detection and recongnition of pig wasting diseases using sound data in audio surveillance systems. [J]. Sensors,2013,13(10):12929-12942.

[30]Chung Y, Kim H, Lee H, et al. A cost-effective pigsty monitoring system based on a video sensor[J]. KSII Transactions on Internet and Information Systems (TIIS), 2014, 8(4): 1481-1498.

[31]Vandermeulen J, Bahr C, Tullo E, et al. Discerning Pig Screams in Production Environments[J]. PloS One, 2015, 10(4).

[32]Zhang Sunan, Tian Jianyan, Banerjee Amit, et al. Automatic Recognition of Porcine Abnormalities Based on a Sound Detection and Recognition System[J]. Transactions of the ASABE, 2019,

中国知网 https://www.cnki.net

62(6):1755-1765.

[33]Pessoa J, da Costa M, Manzanilla E, et al. Relationship between automatic records of pig respiratory distress on farm and the prevalence of lung lesions at slaughter[J]. Precision Livestock Farming'19, 2019: 520-525.

[34]OikarinenTuomas, Srinivasan Karthik, Meisner Olivia, et al. Deep convolutional network for animal sound classification and source attribution using dual audio recordings.[J]. The Journal of the Acoustical Society of America, 2019, 145(2):654.

[35]Nanni Loris, Brahnam Sheryl, Lumini Alessandra, et al. Animal Sound Classification Using Dissimilarity Spaces[J]. APPLIED SCIENCES-BASEL, 2020, 10(23).

[36]HidayatAlam Ahmad, CenggoroTjengWawan, Pardamean Bens, et al. Convolutional Neural Networks for Scops Owl Sound Classification[J]. Procedia Computer Science, 2021, 179:81-87.

[37]Ruff Zachary J., Lesmeister Damon B., Appel Cara L., et al. Workflow and convolutional neural network for automated identification of animal sounds[J]. Ecological Indicators, 2021, 124.

[38]Jung DaeHyun, Kim Na Yeon, Moon Sang Ho, et al. Deep Learning-Based Cattle Vocal Classification Model and Real-Time Livestock Monitoring System with Noise Filtering[J]. Animals, 2021, 11(2):357-357.

[39]Bravo Sanchez Francisco J, Hossain Md Rahat, English Nathan B, et al. Bioacoustic classification of avian calls from raw sound waveforms with an open-source deep learning architecture.[J]. Scientific reports, 2021, 11(1):15733-15733.

[40]龚永杰.基于声音识别技术的猪咳嗽音识别方法的研究[D].华中农业大学,2018.

[41]Xiaoshuai Wang, Xiaoyang Zhao, Yong He, et al. Cough sound analysis to assess air quality in commercial weaner barns[J]. Computers and Electronics in Agriculture, 2019, 160:8-13.

[42]王文静.基于 CNN 的猪声音状态识别研究与应用[D].哈尔滨工程大学,2019.

[43]赵建.基于深度学习的猪咳嗽声识别[D].华中农业大学,2019.

[44]韩磊磊.基于支持向量机的生猪异常声音识别与监测系统[D].太原理工大学,2019.

[45]苍岩,罗顺元,乔玉龙.基于深层神经网络的猪声音分类[J].农业工程学报,2020,36(09):195-204.

[46]涂鼎.基于音频技术的生猪咳嗽声音识别方法研究[D].东北农业大学,2020.

[47]张海林.梅山猪连续咳嗽声监测系统设计与实现[D].南京农业大学,2020.

中国知网 https://www.cnki.net

[48]李江丽,田建艳,张苏楠.生猪咳嗽声识别与定位方法的研究[J].黑龙江畜牧兽医,2020(14):36-41+150.

[49]耿艳利,宋朋首,林彦伯,季燕凯,杨淑才.采用改进 CNN 对生猪异常状态声音识别[J].农业工程学报,2021,37(20):187-193.

[50]熊梓奥.育肥猪舍中的咳嗽声监测系统设计[D].哈尔滨工程大学,2021.

[51]宋航,赵斌,孙浩楠,王淞,李普,马永财.基于 DenseNet 模型的猪咳嗽声识别算法研究[J].黑龙江畜牧兽医,2022(20):41-44+49.

[52]沈明霞,王梦雨,刘龙申,陈佳,太猛,张伟.基于深度神经网络的猪咳嗽声识别方法[J].农业机械学报,2022,53(05):257-266.

[53]孙浩楠.舍养猪咳嗽声特征参数提取与识别方法研究[D].黑龙江八一农垦大学,2022.

[54]黎煊,赵建,高云等.基于深度信念网络的猪咳嗽声识别［J］.农业机械学报，2018,49(3).

[55]吴化君.猪呼吸道疾病的预防和治疗方法研究[J].农家参谋,2022(13):117-119.

[56]张扬忠.猪呼吸道疾病的诊断与防治[J].农业工程技术,2022,42(26):75+77.

[57]孙丰强.猪呼吸道疾病预防及治疗对策[J].畜牧兽医科学（电子版）,2022.

[58]芦建文,赵楠.声音识别技术在设备故障检测中的应用研究[J].包钢科技,2022,48(03):86-89.

[59]薛珊,李广青,吕琼莹,毛逸维.基于卷积神经网络的反无人机系统声音识别方法[J].工程科学学报,2020,42(11):1516-1524.

[60]蔡尚.自动语音识别中的噪声鲁棒性特征提取方法研究[D].北京:中国科学院研究生院,2012.

[61]张一杨,秦会斌.数字滤波技术的现状与发展[J].物联网技术,2017,7(05):37-40.

[62]王阳.基于深度学习的多人语音识别研究[D].北方工业大学,2022.

[63]张丽君.公共场所异常声音识别算法设计与研究[D].重庆:重庆大学,2017.

[64]吴俊峰. RNN-DNN 语音识别系统研究及其应用[D].华南理工大学,2018.

[65]何小萍.改进的支持向量机分类算法在语音识别中的应用研究[D].太原理工大学,2013.

[66]Yu C, Jinxu L, Fudong Z, et al. Comparative study on face recognition based on SVM of one-against-one and one-against-res methods[C]//2014 8th International Conference on Future Generation Communication and Networking. IEEE, 2014: 104-107.

[67]Pratama B Y, Sarno R. Personality classification based on Twitter text using Naive Bayes, KNN and SVM[C]//2015 International Conference on Data and Software Engineering (ICoDSE). IEEE, 2015: 170-174.

中国知网 https://www.cnki.net

[68]Kosaka N, Ohashi G. Vision-based nighttime vehicle detection using CenSurE and SVM[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(5): 2599-2608.

[69]王振武, 孙佳骏, 于忠义等.基于支持向量机的遥感图像分类研究综述[J]. 计算机科学, 2016, 43(9): 11-17, 31.

[70]刘士佳.基于 PSO 优化支持向量机的图像分类研究[D].大连理工大学,2022.

[71]郑豫.基于支持向量机和 BP 神经网络的油气管道泄漏检测方法研究[D].浙江海洋大学,2022.

[72]黄家芳.隐马尔科夫模型的参数估计及其在新闻分类中的应用[D].杭州电子科技大学,2020.

[73]W.Gin-Der and L.Chin-Teng, Word boundary detection with meI-scale frequency bank in noisy environment[C], IEEE Transactions on Speech and Audio Processing, 8:541-552, 2000.

[74]高玉东.基于深度学习的开关柜放电声音识别的研究[D].沈阳工业大学,2019.

[75]Hamming R W.Error Detecting and Error Correcting Codes[J].Bell System Technical Journal,2014,29(2):147-149.

[76]苑文续,贾明娜,陈吴,刘祥,韩鸿雁.基于谱减法与小波分析的电缆局部放电信号降噪方法[J].现代电子技术,2021,44(19):71-75.

[77]杜社会,肖启国,罗昌友,杨辉,王金江.基于 AR 模型的维纳滤波器设计分析[J].信息技术与信息化,2020(09):159-161.

[78]黄春燕,景妮洁,祝红梅.语音信号的 MATLAB 分析与处理[J]. 计算机科学,2018,45(z1): 555-558.

[79]石小磊,阎东.基于 FPGA 的数字滤波器设计与仿真[J].铁道机车与动车,2022(06):21-24+39+5.

[80]李富强,万红,黄俊杰.基于 MATLAB 的语谱图显示与分析[J].微计算机信息,2005(20):172-174.

[81]柏顺,颜夕宏,张生平,陈建飞,张胜.基于梅尔频率倒谱系数与短时能量的低信噪比语音端点检测[J].南京师大学报(自然科学版),2021,44(02):117-120.

[82]高宝锋. 基于梅尔频率倒谱系数的掌纹识别的研究[D].西北大学,2012.

[83]伊佳聪. 基于粒子群优化算法的 SVM 分类器参数寻优算法的研究[D].吉林大学,2022.

[84]Peddinti V， Wang Y， Povey D， et al. Low Latency Acoustic Modeling Using Temporal Convolution and LSTMs [J].IEEE Signal Processing Letters，2017（99）：1.

[85]段艳明,肖辉辉.基于量子行为的花朵授粉算法[J].兰州理工大学学报,2016,42(03):88-95.

中国知网 https://www.cnki.net