分类号 S126
学 号 2019112036

南京農業大學

硕 士 学 位 论 文

基于深度神经网络的猪只咳嗽声识别预警系统设计与实现

王梦雨

指导教师 沈明霞

学科门类 工学

一级学科 农业工程

二级学科 农业电气化与自动化

研究方向 机器视觉与图像处理

答辩日期 二〇二二年五月二十八日

中国知网 https://www.cnki.net

Design and Implementation of Pig Cough Sound Recognition and Early Warning System Based on Deep Neural Network

By

WANG MENGYU

A Thesis

Presented to Nanjing Agricultural University

in Partial Fulfillment of the Requirements

for the Degree of

Master of Engineering

in

Agricultural Electrification and Automation

Supervised by

Professor SHEN MINGXIA

Nanjing Agricultural University

Nanjing, China

May, 2022

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 课题来源.....1
1.2 研究背景及意义.....1
1.3 国内外研究现状.....2
1.3.1 畜禽声音识别技术国内外研究现状.....2
1.3.2 猪只咳嗽声识别技术国内外研究现状.....6
1.3.3 存在的问题.....9
1.4 研究内容和技术路线.....9
1.4.1 研究目标.....9
1.4.2 研究内容.....9
1.4.3 技术路线.....10
1.5 本章小结.....11
第二章 实验音频数据采集与预处理.....13
2.1 猪舍音频数据获取.....13
2.1.1 音频数据采集.....13
2.2 深度学习环境搭建.....14
2.2.1 PyTorch 框架搭建.....14
2.3 猪只音频数据预处理.....15
2.3.1 有效声音段获取.....15
2.3.2 改进谱减法去噪.....16
2.3.3 双门限法端点检测.....19
2.4 猪只音频数据集制作.....21
2.4.1 数据标注.....21
2.4.2 数据集划分.....22
2.5 本章小结.....22
第三章 基于深度学习的猪只声音特征参数提取.....25
3.1 音频特征提取算法.....25
3.1.1 音频特征分类.....26
3.1.2 基于深度学习的特征提取算法.....26
3.2 猪只声音信号特征参数提取.....27
3.2.1 实验步骤.....27
3.3 实验结果分析.....34
3.4 本章小结.....35
第四章 基于深度神经网络的猪只咳嗽声识别模型.....37

中国知网 https://www.cnki.net

4.1 猪只咳嗽声识别模型整体设计 37
4.2 基于 CNNs 算法的猪只咳嗽声识别模型 38
4.2.1 CNNs 模型网络结构设计.....38
4.2.2 CNNs 模型参数设置.....41
4.2.3 CNNs 模型损失函数.....41
4.3 基于 DFSMN 算法的猪只咳嗽声识别模型.....41
4.3.1 DFSMN 模型网络结构设计.....41
4.3.2 DFSMN 模型参数设置.....44
4.4 模型二分类实验结果与对比分析 44
4.4.1 实验步骤.....44
4.4.2 评价指标.....45
4.4.3 实验结果分析.....46
4.5 模型四分类实验结果与对比分析 49
4.5.1 CNNs 模型性能分析.....49
4.5.2 DFSMN 模型性能分析.....52
4.5.3 实验结果分析.....55
4.6 本章小结.....56
第五章 猪只咳嗽声识别预警系统软件平台设计与实现 57
5.1 猪只咳嗽声识别预警系统软件平台设计 57
5.1.1 系统软件平台开发环境配置.....57
5.1.2 系统软件平台开发流程.....58
5.1.3 系统软件平台功能模块设计.....58
5.2 数据库设计.....59
5.3 中间件设计.....61
5.3.1 中间件功能分析.....61
5.3.2 中间件功能实现.....62
5.4 猪只咳嗽声识别预警系统软件平台实现 63
5.4.1 WEB 设计与实现.....63
5.4.2 WEB 后台研发集成.....65
5.4.3 系统功能测试.....65
5.4.4 系统服务器端部署.....69
5.5 本章小结.....70
第六章 总结与展望 71
6.1 总结.....71
6.2 展望.....72
参考文献.....73

中国知网 https://www.cnki.net

基于深度神经网络的猪只咳嗽声识别预警系统设计与实现

摘要

畜牧业是中国农业的支柱产业，现代畜禽养殖业正向规模化、集约化和自动化发展，生猪养殖作为畜禽养殖产业的重要一部分，关系着国计民生。在猪只精准养殖中，影响猪只生产性能的呼吸道疾病难于防治且传染快速，诸如感染肺部炎症、患喘气病等，咳嗽又是患呼吸道疾病猪只的主要早期病症之一，如何快速监测猪只的咳嗽声并对猪只早期呼吸道疾病预警是现代生猪养殖业关注的热点问题之一。

目前现代养殖场内对猪只的健康状况监测主要依靠有经验的饲养员根据猪只的发声及体式姿态判断其健康状况，该方式劳动强度大、主观性强，存在漏检或检查不及时等情况。同时，人工方法监测猪只的咳嗽患病情况效率低下，同时会引起猪只不同程度的应激反应，对后续猪只疾病的诊疗造成不良影响。声音信号识别技术以其无接触、响应快速等优点，被越来越多地应用于畜禽养殖动物生理生长状况监测等精准养殖领域。为此，本文研究并设计了可实际应用的猪只咳嗽声识别预警系统，为生猪福利养殖中猪只呼吸道疾病的早期判断提供理论依据和技术支持。

本研究对采集到的猪只声音信号做预处理、特征参数提取操作后采用基于深度神经网络的猪只咳嗽声识别模型能有效区分猪只咳嗽声及其它干扰噪声，同时，结合模型调用研发猪只咳嗽声识别预警系统平台，主要研究内容和结论包括：

（1）构建猪只咳嗽声识别系统孤立词语料库：音频采集环境为猪舍内 2 个长度均为 2.4m、宽度为 1.6m、高度为 0.9m 的隔离区域，语料库构建对象均为 2～3 月龄、体重 50±5kg 的 5 只健康猪只与 5 只患病猪只。首先利用音频处理软件 Adobe Audition (AU)采用人工标记的方式进行录音数据有声段截取，共截取包括咳嗽声、呼噜声、鸣叫声及喷嚏声在内的猪只原始声音样本 536 段，对比不同降噪、端点检测方法后通过谱减法去噪、双门限端点检测得到最终语料库。包含咳嗽声样本 1058 个，其它声音样本 420 个，其中喷嚏声 184 个，鸣叫声 121 个，呼噜声 115 个。声音样本数据验证集和测试集数目分别设置为本类声音样本个数的 10%，每次实验随机选取，剩余样本设置为训练集。

（2）猪只声音信号特征参数（logFBank，MFCC）提取：对比分析 4 种声音信号的时域和频域特征图发现不同声音信号的语谱图存在明显差异，预加重系数设置为 0.97，采样频率设置为 48KHz，帧长设置为 25ms，帧迭设置为 10ms 后分别提取 4 种

中国知网 https://www.cnki.net

声音信号的64维滤波器组(Log_filter bank, logFBank)特征以及128维梅尔频率倒谱系数(Mel Frequency Cepstral Coefficents, MFCC)特征，分别与其一阶及二级差分组合作为卷积神经网络和前馈序列记忆神经网络的咳嗽声识别模型的输入，进行两种模型二分类及四分类识别训练。

（3）基于深度神经网络（CNNs，DFSMN）的猪只咳嗽声分类识别模型研究：将提取到的4种声音信号的logFBank和MFCC特征及它们的一阶、二阶差分组合构建的三维数组分别作为卷积神经网络(Convolutional Neural Networks, CNNs)和深层前馈序列记忆神经网络(Deep Feedforward Sequential Memory Networks, DFSMN)模型的输入，共实现4种模型进行猪只咳嗽声及其它声音的二分类识别以及不同声音的四分类识别，对比不同特征提取方法以及不同迭代次数对模型效果的影响。实验结果表明，以MFCC作为特征输入的CNNs咳嗽声识别模型效果较优，测试集上咳嗽声识别精确率为97%，召回率为96%，F1值为98%，综合平均准确率为96.71%。

（4）猪只咳嗽声识别预警系统设计与实现：利用中间软件实时获取拾音器音频数据流并将音频保存至深度学习机的文件夹中，采用深度学习算法分割大段音频使其达到猪只咳嗽声识别模型调用条件，调用模型将咳嗽声识别结果存储至云服务器的MySQL数据库中。同时采用SpringBoot + Vue + Ngnix搭建猪只咳嗽声识别预警系统软件平台，实现猪舍与猪只信息客户端展示及猪只咳嗽声预警等功能，为养殖人员提供更加便捷高效的管理系统，提高养殖生产效率。

关键词：生猪养殖；声音识别；滤波器组；梅尔频率倒谱系数；卷积神经网络；前馈序列记忆神经网络

中国知网 https://www.cnki.net

DESIGN AND IMPLEMENTATION OF PIG COUGH SOUND RECOGNITION AND EARLY WARNING SYSTEM BASED ON DEEP NEURAL NETWORK

ABSTRACT

Livestock farming is the pillar industry of China's agriculture. Modern livestock and poultry breeding industry is developing towards scale, intensification and automation. As an important part of livestock and poultry breeding industry, pig breeding affects the national economy and the people's livelihood. In the precision breeding of pigs, respiratory diseases that affect the production capacity of pigs are difficult to prevent and cure, and spreads rapidly, such as lung inflammation, wheezing, and so on. Most importantly, cough is one of the main early symptoms of respiratory diseases, how to quickly monitor the cough sound of pigs and give early warning of respiratory diseases is one of the hot issues in modern pig breeding industry.

At present, the health monitoring of pigs in modern farms mainly depends on experienced breeders to judge their health status according to their vocalization and postures. which is labor-intensive, strong subjective, missed inspection and untimely inspection. Meanwhile, it is inefficient to monitor the prevalence of cough in pigs by artificial methods, which will cause varying degrees of stress response in pigs and have an adverse impact on the subsequent diagnosis and treatment of pig diseases. With the advantages of non-contact and rapid response, acoustic signal recognition technology is more and more used in the field of precision breeding, such as monitoring the physiological growth of animals in livestock and poultry breeding. Therefor, this paper studied and designed a practical pig cough sound recognition and warning system, so as to provide theoretical basis and technical support for the early judgment of pig respiratory diseases in pig welfare breeding.

In this paper, the pig cough recognition model based on deep neural network can effectively distinguish the pig cough sounds and other interference noises after preprocessing and extracting the characteristic parameters. At the same time, combined with the model, the pig cough sound recognition and warning system platform was developed. The main research contents and conclusions include:

中国知网 https://www.cnki.net

(1) **Construction of isolated word database of pig cough recognition system:** The audio collection environment was two isolated areas with a length of 2.4m, a width of 1.6m and a height of 0.9m in the piggery. The corpus was constructed from 5 healthy pigs and 5 sick pigs aged 2 to 3 months with the body weight of 50 ± 5kg. Firstly, the audio processing software Adobe Audition (AU) was used to intercept the sound segment of recorded data in the way of manual marking. A total of 536 original pig sound samples including cough, snore, songs and sneeze were intercepted. After comparing different noise reduction and endpoint detection methods, the final corpus was obtained by spectral subtraction denoising and double-threshold endpoint detection. There were 1058 cough sound samples and 420 other sound samples, including 184 sneezing sounds, 121 songs and 115 snoring sounds. The number of validation set and test set was respectively set to 10% of the number of sound samples of this type. Samples were randomly selected for each experiment and the remaining samples were set as training sets.

(2) **Characteristic parameters (logFBank, MFCC) extraction of pig sound signal:** By comparing and analyzing the time domain and frequency domain characteristic diagrams of the four kinds of sounds, it was found that there were obvious differences in the spectrograms of different sound signals. In this paper the pre-emphasis coefficient was set as 0.97, the sampling frequency was set as 48KHz, the frame length was set as 25ms, and the frame overlap was set as 10ms, the 64-dimension filter bank (Log_filter Bank, logFBank) and 128-dimension Mel Frequency Cepstral Coefficents (MFCC) features of the four sound signals were extracted respectively, with the combination of first-order and second-order differences as the input of Convolutional Neural Networks (CNNs) and Feedforward Sequential Memory Neural Networks (DFSMN), the binary classification and quad-classification recognition training of the two models were carried out.

(3) **Research on classification and recognition model of pig cough sound based on deep neural networks (CNNs, DFSMN):** The three-dimensional array constructed by combining the logFBank and MFCC features of the extracted four kinds of sound signals with their first-order and second-order variances was used as the input of CNNs and DFSMN models. A total of four models were realized for the two classification recognition of pig cough and other sounds and the four classification recognition of different sounds, the effects of different feature extraction methods and different iterations on the model were compared. Experimental results showed that the CNNs model with MFCC as the feature input had better effect to recognize pig cough sound, and the recognition accuracy of cough

中国知网 https://www.cnki.net

sound in the test set was 97%, recall rate was 96%, F1-score was 98%, and the combined average accuracy was 96.71%.

(4) **Design and implementation of pig cough recognition and early warning system:** Using the intermediate software to obtain the audio data stream of the pickup in real time and save the audio to the folder of the deep learning machine. The deep learning algorithm was used to segment a large section of audio to meet the call conditions of pig cough recognition model. The cough recognition results were stored in MySQL database by invoking the model. At the same time, Springboot + Vue + Ngnix was used to build the software platform of pig cough recognition and early warning system to realize the functions of pig house, pig information display in the client software and pig cough early warning. This system can provide convenient and efficient management system for breeding personnel, and improve breeding production efficiency.

KEY WORDS: Pig breeding; Voice recognition; Log_filter Bank; Mel Frequency Cepstrum Coefficient; Convolutional Neural Networks; Feedforward Sequential Memory Neural Networks

中国知网 https://www.cnki.net

第一章 绪论

1.1 课题来源

本课题来源于江苏省重点研发计划（现代农业）重点项目——“畜禽精准养殖信息感知关键技术与智慧管理大数据平台研究与示范”（项目编号：BE2019382）。

1.2 研究背景及意义

畜牧业的产值占农业总产值三分之一左右，近年来仍然呈现逐步增长的态势[1]。中国工程院的研究表明，我国的畜牧业产值截至2035年将占农业总产值的52%左右，有望成为农业领域的第一大产业[2]。在《2018年畜牧业工作要点》中，农业农村部提到“推动畜牧业在农业中率先实现现代化，是畜牧业助力‘农业强’的重大责任”[3]。畜牧业的机械化改革发展也备受党中央国务院的关注，在《国务院关于加快推进农业机械化和农机装备产业转型升级的指导意见》中有指出，畜牧养殖领域到2025年的机械化率达到50%左右[4]。

作为我国的畜牧业重要组成部分，生猪养殖产业在我国经济发展中占重要地位[5]。据相关资料显示，2020年之前，我国能繁母猪存栏头数为4161万头，生猪产能继续恢复，到2021年6月，各个大型养猪企业育肥猪出栏率同比翻番，1-5月份进出口猪肉达到196万吨，同期增长13.7%[6]。我国猪肉消费量在2001年为4051万吨，在2017年上升至5457万吨，年平均增长率1.88%，占世界猪肉消费总量的比重在16年内由48.4%上升至49.1%[7-8]。

在生猪养殖领域，影响猪只生产性能的原因包括呼吸道疾病感染，传染性强且扩散迅速[9]，对养殖场经济造成巨大影响，所以呼吸道疾病诊疗是生猪养殖的工作基础[10]。而猪只的咳嗽症状又是呼吸道疾病为数不多的显要早期症状之一，识别咳嗽声有助于早期呼吸道疾病预警。目前检查猪只异常的方法主要有人为蹲点、人工巡视、手工记录等，上述方法虽然简单易操作，但会消耗大量的人力成本，而且数据主观性强，监测准确度难以保证[11]。近年来，随着深度学习、语音识别、计算机网络技术的高速发展，越来越多的专家学者在畜禽养殖领域应用声音识别等技术研究猪只等动物的生理生长状况，为畜禽福利养殖注入新鲜活力。

在互联网+、大数据与云计算等信息技术高速发展的今天，养殖领域也出现大规模数据增长现象[12-16]，且数据源众多、形式多样复杂。因此，从多源数据以及计算方式和实际需求出发构建出高层次抽象模型，是畜禽智慧养殖领域目前讨论众多的问题

中国知网 https://www.cnki.net

[17-18]。而深度学习以其可用于分析计算大规模数据量的特点，被广泛应用于医学影像分析、农作物识别、人脸识别等领域[19-23]。近年来，在畜禽养殖领域的动物声音识别方面也取得了一定成就[24-27]。

在生猪养殖领域，隐马尔可夫(HMM)、深层神经网络(CNNs)、双向长短时记忆网络(BLSVM)等深度神经网络模型也被广泛应用于猪只咳嗽声识别[28-31]，其主要优势在于：1) 利用计算机算法辅助决策提高精确度，同时减轻劳动力；2) 非接触式监测避免猪只应激反应；3) 提高生猪养殖福利水平，促进生产管理向自动化、智能化、精准化方向发展，降低疾病传染风险。综上，基于深度神经网络的猪只咳嗽声识别预警系统设计与实现对猪只健康养殖、企业增收和行业技术进步都意义重大。

1.3 国内外研究现状

音频处理技术早在 1980s 初开始发展，音频去噪方法、特征的提取以及声音分类、识别算法等发展迅速，具有广阔的应用前景和发展潜力。近年来随着机器学习、深度学习的发展，也为音频识别技术的提升提供了各种可能。

1.3.1 畜禽声音识别技术国内外研究现状

近年来，除了对猪只声音的研究，国内外学者利用畜禽声音识别技术在其它畜禽疾病预警、行为监测、发情检测等方面的估测也取得了一定的成效。

1.3.1.1 鸡只的声音识别研究现状

国外学者针对鸡只声音识别相关的研究包括：

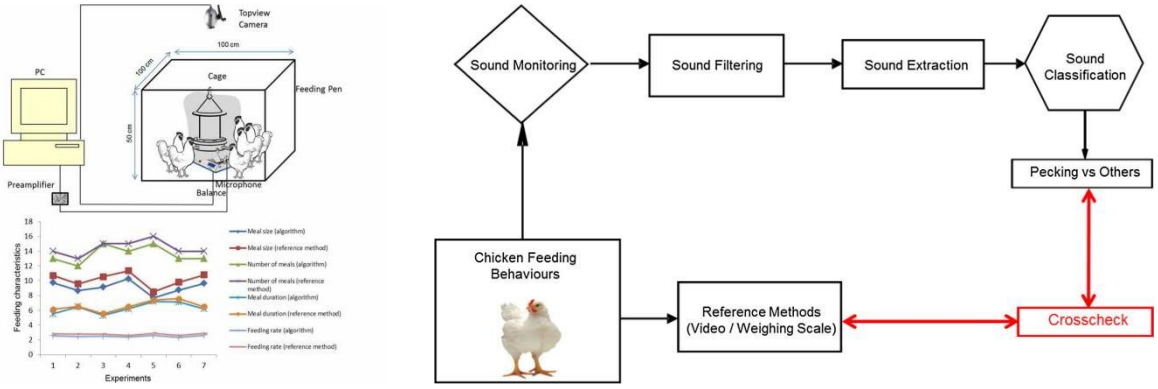
(1) 鸡只异常声音与疾病之间的关系研究：欧洲荷语区鲁汶大学 Carpentier[32]等人在圈养环境下对 51 只病鸡的喷嚏声进行采集，截取到 763 个喷嚏声，利用谱减法对原始声音信号进行过滤，并以较高能量对其进行分割，利用时域波形和特征图计算特征值后进行声音分类，算法精度为 88.4%，灵敏度为 66.7%。

(2) 鸡只啄食声估测采食量等相关信息：土耳其 Canakkale Onsekiz Mart 大学 Aydin[33]等人研究了肉鸡的餐量、餐期、日餐量、饲喂率与其啄食声之间的关系，实验结果表明，该方法能正确监测 90%的餐量、95%的餐时、94%的日餐数和 89%的摄食率。如图 1-1 为研究的数据采集装置以及声音处理流程图。

国内学者针对鸡只声音识别相关的研究包括：

(1) 鸡只声音的去噪、识别研究：农业农村部设施农业工程重点实验室曹晏飞[34]等人以去噪为目的，研究了海兰褐蛋鸡的叫声以及风机噪声时频特征，结果表明产蛋声音频率在 400-2500HZ，噪声频率维持在 600HZ 以下，无线脉冲响应滤波器的滤波效果较好。华南农业大学张铁民[35]等人在复杂环境中提取鸡的声音，计算声音信号短

中国知网 https://www.cnki.net



（a）肉鸡摄食声采集装置　　（b）声音信号处理流程

图 1-1 鸡只摄食率与啄食声等的关系研究

Fig.1-1 The study on the relationship between feeding rate and feeding sound of chickens

时能量、过零率后，利用 T-S 模糊神经网络进行特征训练识别，结果显示隶属度个数为2、钟形函数模糊神经网络对3种鸡声音特征组成的3组测试集灵敏度分别为75.47%、76.92%和 80.39%，特异性为 80.85%、72.92%和 79.59%，正确率为 78%、75%和 80%。如图 1-2 为其研究的音频采集场景图。



（a）试验所使用的鸡笼　　（b）录音笔放置情况

图 1-2 音频采集环境

Fig.1-2 The environment of audio collection

(2) 鸡只声音识别与疾病对应关系研究：CAS-D 成员 Rizwan[36]等人对比分析了一种极限学习机(ELM)和支持向量机(SVM)分类器来检测鸡的啰音。利用包含健康及患病鸡的标记数据进行训练和测试分类器，分类器输入特征为 Mel 尺度的光谱特征。然后对健康和生病的鸡只进行 25 天的连续记录，产生的检测率与病程相对应，由此实现家禽呼吸道疾病自动化早期监测。华南农业大学 Junduan[37]等人研究鸡只的叫声与禽流感之间的关系，提取鸡只声音的短时自相关函数，确定其 Mel 倒频谱系数，接着用二值分类支持向量机(SVM)进行训练，根据测试集的实验结果，该方法的准确率在 84%～90%之间。南京农业大学秦伏亮[38]等人利用基于 MMSE 的谱减降噪法对白羽肉鸡咳嗽及其他声音数据进行去噪，提取了 WMFCC 特征，构建了 GMM-HMM 模型，

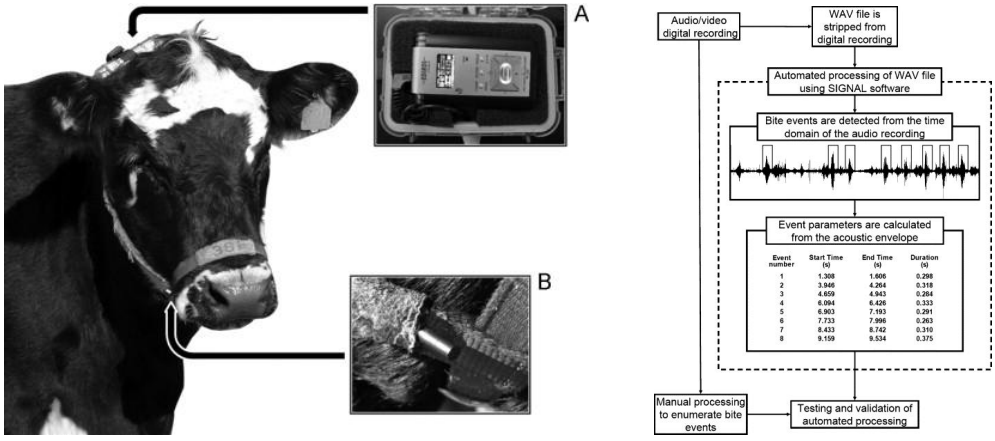
中国知网 https://www.cnki.net

在隐状态数为 3，高斯元的个数为 3 时，正确率为 98.7%。杨稷[39]等人根据鸡只声音的功率谱密度曲线，利用 OC-SVM 对截取的声音有效片段进行识别。最后分析了啄食的次数与进食量之间的关系，啄食次数计算准确率为 94.58%，采食量计算准确率为 91.37%。

1.3.1.2 牛的声音识别研究现状

国外学者针对牛的声音识别相关研究包括：

(1) 牛的进食声与采食量等的关系研究：美国农业部 M.Clapham[40]等人利用宽频率声学麦克风采集声音信号，自建的采集系统测量出牛采食事件的声音参数，例如持续进食时间、声音的振幅、频谱和能量等信息，进一步地进行事件分类，并为采食量模型提供输入参数，该宽带声学分析法能够准确和自动地识别长时间内的吞咽事件。如图 1-3 为其音频采集系统及音频处理流程。美国加州大学 Laca[41]等人研究了牛采食不同种类的草皮时咀嚼和咬在声学特征上的差异，并通过咀嚼声的总能量通量密度和每次咀嚼的能量通量密度和平均咀嚼声强度可以准确地预测采食量。



（a）音频采集系统　　（b）自动化处理测试和验证程序示意图

图 1-3 牛声音与采食事件关系研究

Fig.1-3 Study on the relationship between cattle sound and feeding events

(2) 牛的咳嗽声与对应疾病早期诊断研究：比利时鲁汶大学 Vandermeulen[42]等人开发了一种自动小牛咳嗽监测仪用于人工饲养奶牛 BRD 早期预警。咳嗽检测算法的灵敏度为 50.3%，特异性为 99.2%，精密度为 87.5%。意大利 S.Ferrari[43]等人将奶牛的咳嗽声与牛场中常见的金属声比较，结果表明咳嗽声和金属碰撞声的差异表现在长度以及振幅和基频方面，该研究说明牛的咳嗽声和其它声音特征具有显著差异，可以作为一种非侵入性诊断方法用于幼畜呼吸道疾病的诊疗。

(3) 牛的不同声信号与其行为之间的关系研究：荷兰赫尔托根博什应用科学大学 G.H.Meen[44]等人研究牛的叫声和牛的行为之间是否存在相关性，构建包括躺卧和反刍、进食相关行为、社交互动、性相关行为、压力相关行为和剩余行为的行为学图。统计

中国知网 https://www.cnki.net

分析显示，撒谎和反刍时的呼叫频率与其他行为时的呼叫频率(83 ± 4.3 Hz)有显著差异(298 ± 8.0 Hz)，成年的奶牛叫声最大频率值低于小母牛的叫声频率值。为健全奶牛管理工具的使用提供了一个立足点。

(4) 依据牛的声音信号进行个体差异识别研究：澳大利亚新英格兰大学C.Bishop[45]等人提取羊、牛、玛瑞玛牧羊犬的Mel频率倒谱系数和基于离散小波变换的特征，使用了支持向量机进行分类，准确率达到99.29%，95.78%，99.67%，结果表明基于DWT的特征生成速度显著加快(执行时间减少14.81%～15.38%)。印度国家乳品研究所Yajuvendra[46]等人证实了一群杂交牛的不同个体发出的声音信号的各种声学特征存在显著差异。在音高(平均值和范围)、共振峰、脉冲数、破音程度、闪烁和平均噪声与谐波比(%)方面每头奶牛都有显著差异。因此，这些特征可以被认为是合适的声学特征，以区分单个奶牛和其群体。

(5) 牛的声音识别与发情行为之间对应关系研究：韩国庆尚大学Chung[47]等人研究了韩国本土奶牛的声音数据与发情行为之间的关系，采用降维处理的Mel频谱倒谱系数以及支持向量机作为早期异常状况检测器，准确率达到94%。韩国庆尚大学Seong[48]等人探究了韩国本土奶牛的发声特征与发情及饲喂时预期发声的差异，通过比较奶牛的叫声持续时间、共振峰、强度等音频特征，表明奶牛发声可以作为奶牛不同生理状况的一个指标。

1.3.1.3 羊的声音识别研究现状

国内学者针对羊的声音识别相关研究包括：

内蒙古农业大学刘艳秋[49]等人为了研究母羊在生产、寻羔等行为下声音信号的不同特征，对声音信号进行时频域分析后，提取了信号的主峰频率、持续时间以及基因周期等特征参数，结果表明母羊叫声信号的三种应激行为有明显差异。同校宣传忠[50]等人为研究杜泊羊的咳嗽声信号提出了改进MFCC提取方法，输入HMM模型训练，识别率、误识别率和总识别率分别为86.23%、7.17%和88.43%。通过BP神经网络改善HMM模型，识别率为92.54%、5.37%和95.04%。其团队成员还采用共振峰-BP网络进行羊的发声识别，正确识别率为85.3%[51]。

对国内外畜禽声音识别技术进行分析与总结得到：

(1) 早期在畜禽声音识别领域大多采用经典的声学分析算法，声学分析的主要步骤也被概括为声音信号预处理，声音特征提取与分类识别算法三大步骤。由于生产环境的多变性，采集到的声信号中往往存在不同的环境噪声，减小噪声干扰对提高猪只咳嗽声等信号的识别能力具有重要的作用。预处理主要工作是通过数字信号滤波或者语音增强对除目标声音以外的噪声进行去噪处理。小波滤波、小波包滤波、谱减法、MMSE谱减法、经验模态分解等都是常见的语音增强算法[52-53]。声音的特征参数是指

中国知网 https://www.cnki.net

反映声音信号实质性特性的一组数，通常特征提取分为时域和频域两大类分析法。最常见的声音特征参数以及特征提取算法有过零率(Zero Crossing Rate, ZCR)、线性预测分析(Linear Prediction Coefficients, LPC)、滤波器组系数(Log_filter bank, logFBank)、Mel 频率倒谱系数(Mel Frequency Ceptral Coefficients, MFCC)、WMFCC 特征等[54]。如图 1-4 为 Mel 频率倒谱系数的提取流程图。

(2) 声音分类识别算法是声音信号处理的最后一步，学者们也进行了大量研究，声音分类方法有动态时间规划(Dynamic Time Warping, DTW)、支持向量机(SVM)、模糊 C 均值聚类及其改进算法、优化的竞争算法、特征参数归一法、自适应稀疏分解算法、稀疏表示分类(SRC)等[55]。

(3) 基于传统机器学习的咳嗽声识别算法研究，原始的输入信号通常只经过一层处理，模型结构简单且易于学习，在较为复杂的信号处理方面具有局限性[56-59]。有关专家学者已将高斯混合模型(GMM)、隐马尔科夫模型(HMM)、人工神经网络(ANN)等算法应用于畜禽养殖领域，都取得了一定成果。

(4) 近年来，随着深度学习技术的发展进步，大量研究表明基于深度神经网络的模型在解决较为复杂且数据量大的分类问题上比传统的机器学习分类模型效果更为突出。其中，卷积神经网络是最常见也是应用最广的算法之一，在图像目标识别领域被广泛应用，以其优越的性能，近年来在声音分类识别领域也取得了不小的进步。其中以双向的长短时记忆网络(BLSTM)为代表的算法被诸多学者应用在连续声音变化规律学习方面，同时结合连接时序分类(CTC)算法达到了端到端声音识别目的[60]。

1.3.2 猪只咳嗽声识别技术国内外研究现状

其它禽类动物的声音识别研究对猪只异常声音识别具有参考价值，本节针对国内外猪只咳嗽声研究进行归纳总结。

1.3.2.1 猪只咳嗽声识别技术国外研究现状

国外学者对猪只咳嗽声的研究早于国内，早在上个世纪 80 年代，国外学者就在生猪福利养殖领域展开探索[61]，利用声音识别技术为养殖人员提供参考信息，帮助识别异常情况，为深入开展生猪健康养殖研究提供了一个新思路。

英国兰开斯特大学 V. Exadaktylos[62]等人使用模糊 C 均值聚类的方法识别咳嗽声，以应用程序的方式实现了实时识别猪只咳嗽声，加快诊断和治疗过程，提高猪只的养殖福利。比利时学者 Silva[63]等人就如何在猪场稳定条件下定位咳嗽猪只的位置展开研究，提出了一种根据几个麦克风的声信号到达时间的差异定位咳嗽声的算法。Silva[64]等人为证实猪只呼吸道系统疾病与猪只咳嗽声相关，从猪只咳嗽声能量包络的动力学出发，依然采用病猪及柠檬酸诱导咳嗽两种声信号对比，结果表明病理性咳嗽

中国知网 https://www.cnki.net

影响咳嗽声持续时间，为肺部状况变化对咳嗽声产生影响的理论提供了支持。

比利时鲁汶大学 Chedad[65]等人构建了室内音频采集系统储存音频数据，同时研究了一种 PNN 神经网络用以区分猪只的咳嗽声和呼噜声，咳嗽声识别正确率达到 91%。并指出如果咳嗽声能被及时发现，就有利于疫病的早期治疗。意大利学者 Ferrari[66]等人以肺部感染的猪只的咳嗽声和吸入柠檬酸导致的猪只的咳嗽声作对比研究，以此来作为诊断肺炎等常见呼吸道疾病的前提，研究发现传染性和非传染性咳嗽声在均方根、峰值频率和持续时间以及连续咳嗽之间的间隔之间都存在明显差异，并成功搭建咳嗽声自动监测识别系统，此举使得猪只咳嗽声识别系统迈出了一大步。韩国学者 Aerts[67]等人为了更客观和自动化地监测猪舍中的猪只呼吸道疾病，研究设计了一种正确标记咳嗽数据的试验方法，首先采用人工观察视听记录猪只咳嗽和用音箱设备记录咳嗽声数目进行对比，结果发现人工记录的咳嗽声比仪器识别的咳嗽声少了将近 94%，他们由此提出观察者如何通过软件来改善识别结果，也表明采用人工智能技术进行咳嗽声识别的重要性。

综上所述，国外的学者较早开始了猪只咳嗽声与呼吸系统疾病之间关系的研究，并从咳嗽声如何采集处理、如何利用神经网络来识别咳嗽声以及如何在复杂猪舍真实环境下应用咳嗽声自动识别系统等方面开展了研究，为后续研究提供了参考思路。

1.3.2.2 猪只咳嗽声识别技术国内研究现状

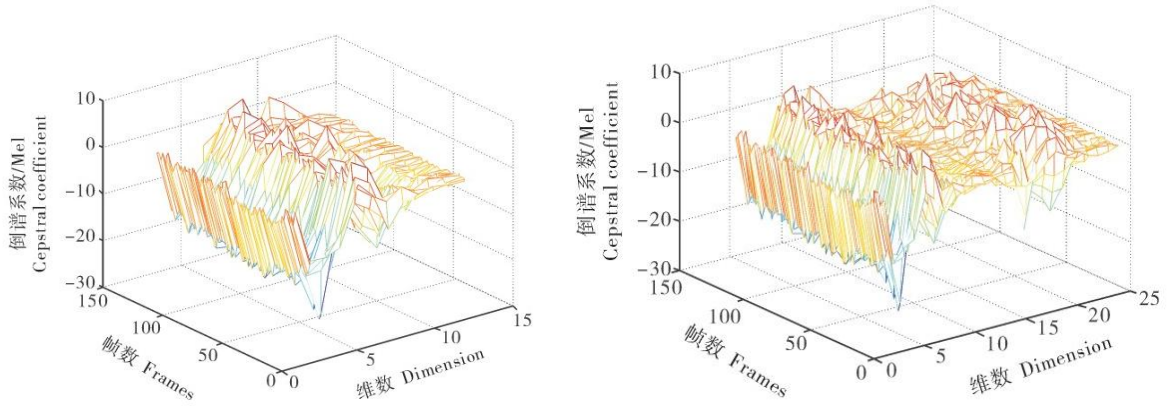
近年来受到非洲猪瘟以及新冠疫情的影响，可以看到为了尽可能减轻猪瘟造成的影响，防疫措施更加严格。为了避免各类人员进出猪舍，减少人畜接触交叉感染的风险，可通过远程监控形式识别猪只异常情况，实现及时反馈。采集猪舍音频数据进行处理，识别其中存在的咳嗽声等有助于发现例如呼吸道疾病等异常情况，所以快速有效的咳嗽声识别算法是呼吸道疾病检测的研究基础。相较于国外，国内猪只咳嗽声研究起步较晚，但是其研究的广度和深度在最近几年都取得了长足发展。

2015 年，南京农业大学徐亚妮[68]等人提取梅山母猪声音信号的功率谱密度后利用模糊 C 均值聚类改进方法，对梅山猪的咳嗽声与尖叫声进行聚类分析，最终取得了较好的分类效果。同年，以山西农业大学为代表的团队，刘振宇[69]等人提出了以 HMM 算法识别猪只咳嗽的方案，经养猪场试验验证，此方法可以较高速度识别咳嗽声。2016 年，马辉栋[70]等人将重点放在端点检测算法上，着重解决长音频中识别咳嗽声的问题。2017 年，董红松[71]等人为了去除猪场音频数据中较多的低频风扇噪声干扰，提出了基于离散余弦变换(Discrete Cosine Transform, DCT)的增强算法对含噪猪只咳嗽声进行处理。

2018 年之后，以华中农业大学为代表的团队，赵建[72]等人利用基于小波阈值的多窗谱维纳算法对猪只连续声音去噪后获得实验语料，提取了 39 维 Mel 频率倒谱系数，

中国知网 https://www.cnki.net

最后建立了基于深度神经网络-隐马尔科夫(DNN-HMM)的猪只咳嗽声识别模型。龚永杰[73]首先提取了猪只声音的 Mel 频率倒谱系数后建立了 HMM-SVN 模型，利用 PSO 进行优化，对 4 个基分类器进行融合，识别率为 94.21%。如图 1-4 为其研究的 Mel 倒谱系数改进前后对比图。



（a）标准 Mel 倒谱系数　　（b）改进的 Mel 倒谱系数

图 1-4 Mel 倒谱系数改进前后对比图

Fig.1-4 Comparison of Mel cepstrum coefficients before and after improvement

张振华[74]等人采用机器学习的方法，分别构建了基于不同特征提取(LPCC、MFCC)的隐马尔可夫(HMM)模型和矢量量化(VQ)等模型识别猪只咳嗽声，系统的性能得以改善。黎煊[75-76]等人分别提出了基于 DBN、BLSVM-CTC 的猪只咳嗽声识别模型，后者还利用五折交叉验证进行试验，最终目标识别率达到 92.40%，误识别率为 3.55%，总识别率为 93.77%。YIN Yanling[77]等人提出了一种基于 AlexNet 模型和谱图特征的分类算法，综合平均准确率达到 96.8%，F1 值达到 96.2%。SHEN Weizheng[78]等人通过将 MFCC 与多层 CNN 融合得到 MFCC-CNNs 特征，综合平均准确率为 96.6%，最后利用 Softmax 和线性支持向量机(SVM)进行分类后，咳嗽识别准确率分别提高 7.21%和 3.86%，F1 值分别提高 10.37%和 5.21%。

综上所述，虽然我国对猪只咳嗽声的研究起步晚于国外，但随着猪只福利养殖观念的普及及国家政策的大力支持，以我国高校为主的畜禽养殖团队在以深度学习技术为基础的猪只咳嗽声识别方面取得了巨大成效，可以为生猪福利养殖中猪只呼吸道疾病的早期判断提供理论依据和技术支持，并在以工程落地为主的猪只咳嗽声自动预警系统研制方面取得了一定的成果，可以预测不久的将来以科技为手段的猪场智能化疾病预警系统将被广泛推广应用，届时不仅能降低养殖成本，解放生产力，增加猪场经济效益，还能提高猪只卫生福利。

中国知网 https://www.cnki.net

1.3.3 存在的问题

目前对猪只咳嗽声的研究取得了一定的成效，但在咳嗽声识别性能上仍需进一步优化，大致存在以下几个问题：

（1）现有的咳嗽声识别算法在模型参数设置上依靠经验判断，检测速度以及准确率还有待进一步提高。

（2）基于人工截取咳嗽声等音频信息进行模型训练，底层工作量大，同时对音频采集环境要求高，模型应用于规模化复杂养殖场景还需进一步研究。

（3）现有猪只咳嗽声识别预警系统大多通过远程网站发布，优化音频信息等的中间传输环节将大大提高系统的性能。

1.4 研究内容和技术路线

1.4.1 研究目标

本文围绕猪只现代规模化养殖领域关键技术，针对现在畜禽养殖自动化和集约化水平欠佳，信息采集的实时性、准确性和可靠性较差，畜禽养殖领域异常预警信息发布不及时，无法实现精准化管理等问题，以猪只为受益主体，以数据挖掘为核心，以自动化、网络信息平台分析管控为推手，对生猪养殖领域中的猪只咳嗽声识别计数，为猪只早期呼吸道疾病提供预警支持。

1.4.2 研究内容

根据猪只咳嗽声识别研究中存在的问题，在查阅国内外音频识别技术、猪只相关咳嗽声识别技术以及深层神经网络模型算法的相关论文报告的基础上，确定了研究方案的可行性，如图 1-5 为咳嗽声识别预警系统总体架构图。本研究的主要内容包括：

（1）制作猪只咳嗽声识别模型训练所用的包含咳嗽声、噜噜声、喷嚏声以及鸣叫声在内的数据集语料库，划分数据集，搭建模型训练所用的深度学习环境，初步构建模型框架，方便后续猪只咳嗽声识别的研究。

（2）猪只声音信号预处理与声音特征参数提取方法研究。研究从长音频中获取有效声音数据的方法，通过人工标记法获取有声段后对比研究几种声音去噪方法，主要针对谱减法，从而减小无关信息的干扰，研究对比几种声音端点检测算法，主要针对基于双门限的端点检测法，最终得到有效声音样本。在此基础上研究猪只声音信号的 logFBank 及 MFCC 两种特征提取方法，为后续声音特征输入猪只咳嗽声识别模型做准备。

（3）基于深度神经网络的猪只咳嗽声识别算法研究。构建两种深度神经网络模

中国知网 https://www.cnki.net

型，研究两种特征参数与两类神经网络模型结合的 logFBank-CNNs、logFBank-DFSMN、MFCC-CNNs、MFCC-DFSMN 咳嗽声和其它声音识别的二分类以及四分类识别模型性能，研究模型训练的迭代次数以及不同特征对模型分类性能的影响，通过对比实验测试集上的精确度、召回率、F1 值等模型评价指标选取最适用于实际生产的模型。

（4）搭建猪只咳嗽声识别预警系统平台。使用网络拾音器实时获取音频数据流并保存于适宜深度神经网络模型运行的 Linux 服务器中，定制猪只咳嗽声识别系统专用数据库，实现模型数据远程云服务器数据库存储，利用 SpringBoot + Vue + Nginx 框架开发系统软件平台，实现猪只个体生理生长信息展示与咳嗽声监测预警系统主要功能。

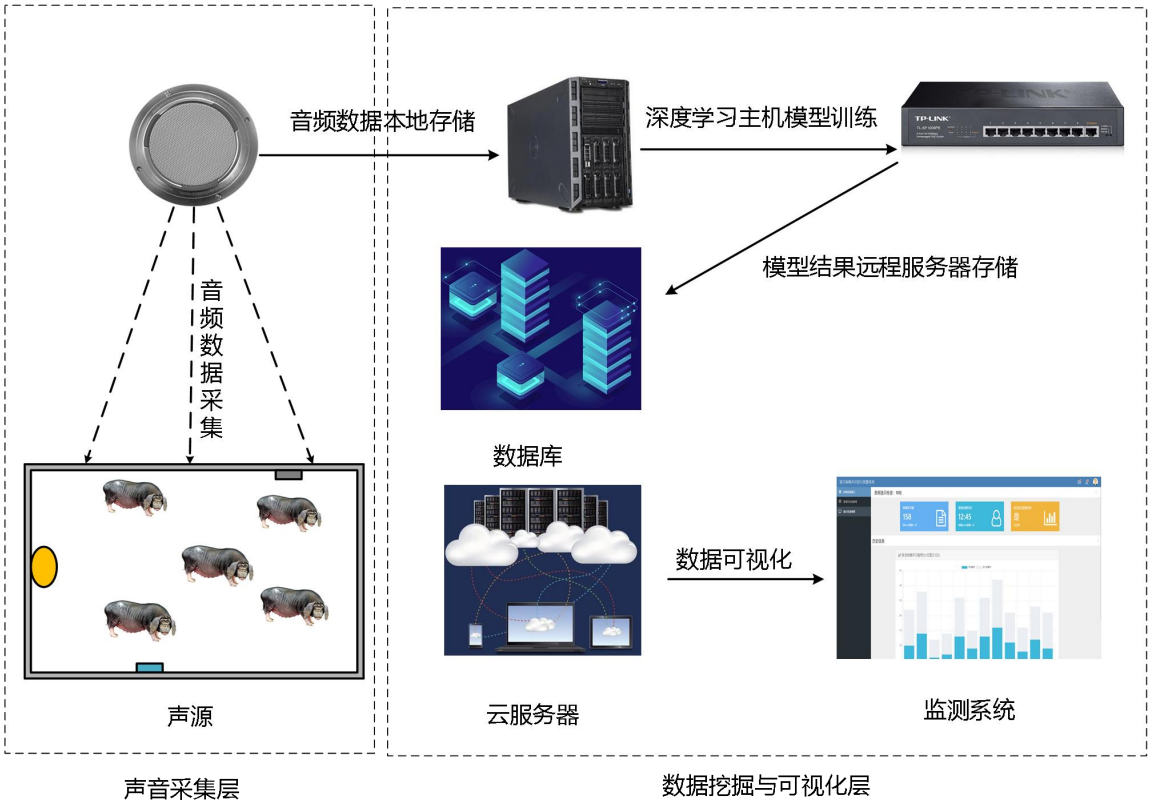


图 1-5 系统整体架构图

Fig.1-5 The overall system architecture

1.4.3 技术路线

本文旨在探索并改善相关猪只咳嗽声识别预警的研究，更充分获取猪只信息，为智能畜禽养殖提供更加精准高效的监测识别方法，以满足畜牧业养殖智能自动化监测管理需求。本研究是包括实地调研、理论研究、算法模型设计与实现、实验验证及平台展示等内容的综合性课题，如图 1-6 所示为针对本文的研究内容确定的总体技术路

中国知网 https://www.cnki.net

线。

采用基于音视频监控技术的猪场音频采集硬件系统与网络架构进行猪舍内音频数据的采集与存储，运用基于 PyTorch 的音频特征提取算法与深度神经网络构建猪只咳嗽声识别模型，分析检验算法模型在训练集、验证集以及测试数据集上的性能指标后选取识别性能最优模型，结合猪只咳嗽声识别预警系统软件平台实现猪只无接触式的咳嗽声识别预警与猪场数据可视化展示，减少人工巡检带来的人力消耗，提升猪场的自动化程度以及猪只的养殖福利。

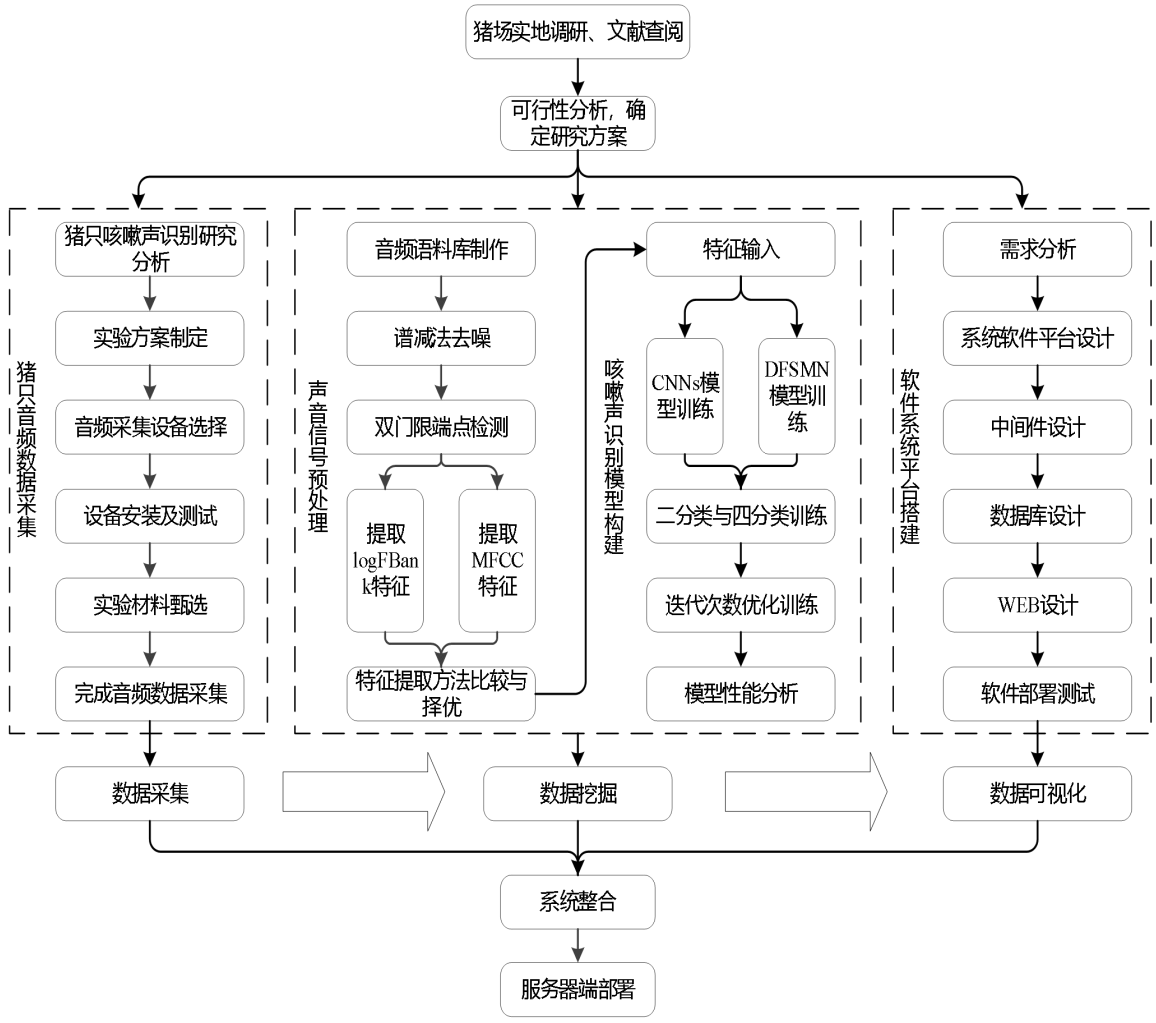


图 1-6 技术路线图

Fig.1-6 The technology roadmap

1.5 本章小结

本章节主要阐述了课题的来源、研究背景以及意义，叙述了国内外畜禽养殖领域

中国知网 https://www.cnki.net

的声音识别现状，重点分析了猪只咳嗽声识别领域相关的研究，针对目前猪只咳嗽声识别预警系统存在的某些问题，确定了本课题的研究内容和技术路线。

中国知网 https://www.cnki.net

第二章 实验音频数据采集与预处理

在猪只声信号的分类识别过程中，高质量的音频数据是实现声音识别的基础。本章研究的主要内容是根据猪舍环境实际情况，采集猪舍内音频数据，制作猪只有效音频数据训练集、验证集、测试集，为此设计并搭建猪只声音采集与处理软硬件平台，安装研究所需要的深度学习环境与框架，最终获得了包括猪只咳嗽声在内的四种声音样本数据，为后续猪只咳嗽声分类识别研究做准备。

2.1 猪舍音频数据获取

本文采用基于音频监控系统的猪舍音频采集平台进行猪只声音数据获取，数据预处理以及数据集制作，音频采集硬件系统中使用的录音设备为 HD-B-1001 高保真网络拾音器，该设备安装简单、读取数据便捷，可快速开展实验，缩短研究周期，为后续研究的改进方案奠定基础。数据预处理将猪只有效音频数据划分为“咳嗽声”、“噜噜声”、“喷嚏声”、“鸣叫声”4 种标签并制作数据集用于后续猪只咳嗽声识别模型训练与评价。

2.1.1 音频数据采集

本文研究开展期间恰逢非洲猪瘟以及新冠疫情影响，为了避免人畜共患病，进出各大养殖场严格受限，使得现场实验开展较为困难。

实验所用音频数据于 2018 年 6 月 2 日至 2018 年 6 月 10 日在江苏农博园梅山猪育种中心采集。选取均为 2～3 月龄、体重 50 ± 5kg 的 5 只健康猪只与 5 只患病猪只作为实验对象，其中 5 只健康猪只无异常状况、无咳嗽症状，患病猪只体温升高至 40.5℃，表现为咳嗽、连续性咳嗽，呼吸增快，经过专业饲养人员诊断为患呼吸道疾病。

实验猪舍分为 2 个长度为 2.4m、宽度为 1.6m、高度为 0.9m 的隔离区域。在实验舍内安装录音装置，该型号稳定性好，能在潮湿、灰尘多的猪舍内使用。其最大内存 16GB，音频储存格式为 wav，采样的精确度设置为 16 bit 位、频率设置为 48KHz，录音数据每 2h 保存为一个录音文件，以年-月-日-时-分-秒格式命名。实验设计硬件平台选用网络拾音器实时获取音频数据流通过网线传输至本地深度学习服务器，如图 2-1 所示为平台硬件系统采集装置。猪舍养殖区音频数据采集设备安装示意图如图 2-2 所示。分别将患病猪只及健康猪只放置在两个相邻猪舍内，录音装置分别安装于猪舍内距离地面高度约 1.6m 处。

中国知网 https://www.cnki.net



（a）拾音器　　（b）交换机　　（c）深度学习主机

图 2-1 硬件采集装置

Fig.2-1 The hardware acquisition device

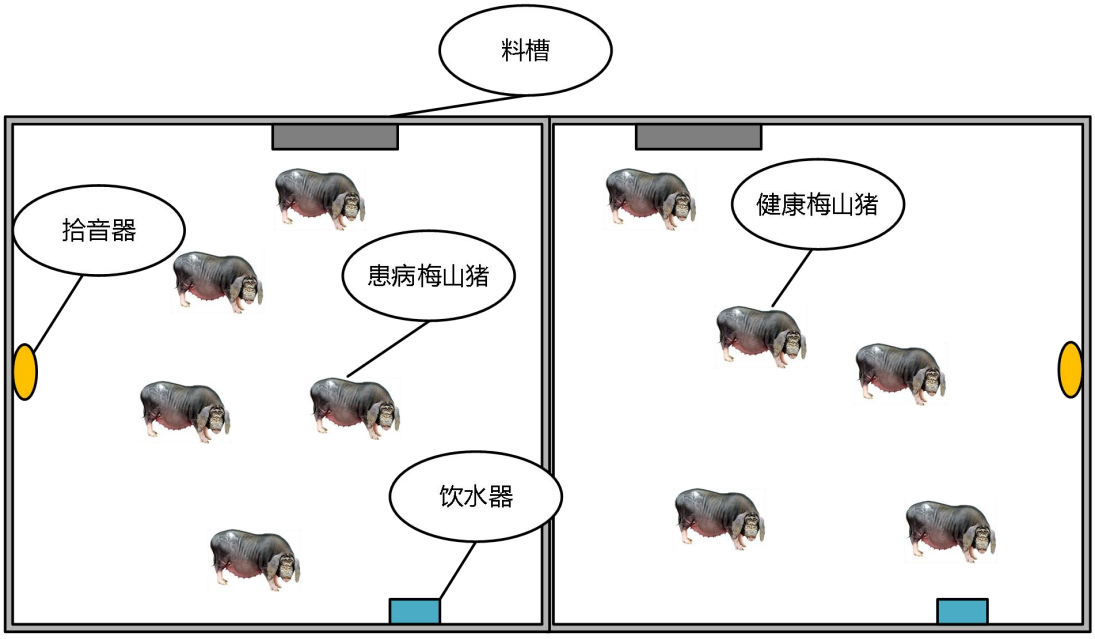


图 2-2 猪舍养殖区音频采集设备安装示意图

Fig.2-2 Schematic diagram of piggery audio acquisition equipment installation

2.2 深度学习环境搭建

研究开始之前搭建所需的深度学习环境是必要的，本研究所涉及算法均基于 PyTorch 深度学习开发库。基于深度神经网络处理大量音频数据以及运行深度学习模型对计算机的要求较高，实验环境为配置有 1 块 GTX1080Ti 显卡，内存 31.1GB，2 块 Xeon Gold 5118CPU 的工作站。

2.2.1 PyTorch 框架搭建

PyTorch 框架主要运用于对自然语言的处理，可以实现 GPU 加速，支持动态神经网络。本研究选择 Linux 环境中 python 版本号为 3.6.10，Anaconda 版本号为 3.0，PyTorch

中国知网 https://www.cnki.net

版本号为 1.7.0，torchvision 版本号为 0.4.0，cuda 版本号为 10.1。深度学习环境版本对应关系如表 2-1 所示。

表 2-1 实验环境版本对应关系表

Tab.2-1 Corresponding table of experimental environment version

环境	版本
python	3.6.10
Anaconda	3.0
PyTorch	1.7.0
torchvision	0.4.0
cuda	10.1

2.3 猪只音频数据预处理

数据预处理主要包括对获取的原始音频数据进行有效声音段分割以及通过去噪与端点检测算法选择高质量数据为后续特征提取与模型训练做准备。如图 2-3 所示为猪只音频数据预处理流程图。第一步将获取到的大段音频数据采用人工截取的方法获取有效声音段，主要方法详见本章第 2.3.1 小节，截取猪只咳嗽、鸣叫、喷嚏、呼噜声四种声音数据，并进行归类，初步截取后利用噪声处理算法进行去噪处理，经过去噪后的每段音频数据中仍然包含空白段，再利用端点检测算法进行端点检测制作最终数据集。

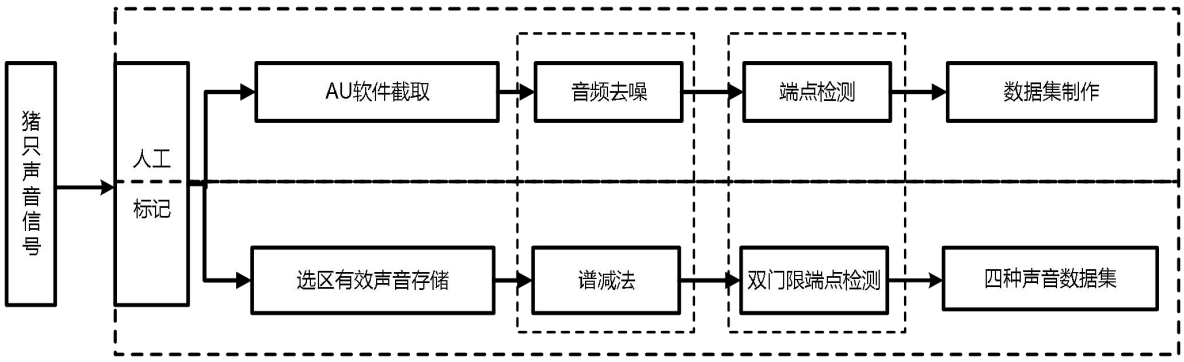


图 2-3 猪只音频数据预处理流程图

Fig.2-3 Flowchart of pig audio data preprocessing

2.3.1 有效声音段获取

录音数据以 2 小时段保存为一条音频数据，通常存在大段空白无效录音数据，每条录音数据根据对应时间进行初次听音筛选，猪只咳嗽声在夜晚时间段明显增多且咳嗽声较清晰，可筛选掉大段无用音频。通过请教专业养殖人员来区分猪只发出的不同声音，听音发现采集到的猪舍音频主要包含猪只的咳嗽、鸣叫、喷嚏、呼噜声等可用

中国知网 https://www.cnki.net

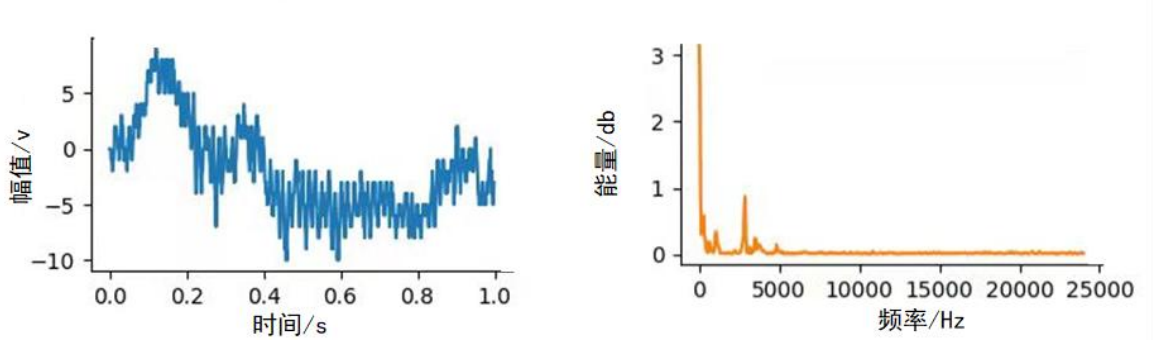
数据以及人声、金属器皿碰撞等其它环境噪声，将猪只的声音标注为可用声音，其它环境噪声标注为无用声，使用音频处理软件 Adobe Audition (AU)对初筛后的音频数据进行有效声音段截取。主要方法为首次听音过程中记下有效声音开始和结束的时间点，运用 AU 自带的截取音频段功能（选取/视图位置）截取音频后将选区根据声音类别另存至已经创建好的分类文件夹中待后续处理。此步骤获取到的声音数据中包含咳嗽、连续咳嗽等存在间隔段的声音。共截取到包含猪只咳嗽声在内的有效声音 536 段。

2.3.2 改进谱减法去噪

2.3.2.1 猪舍环境噪声分析

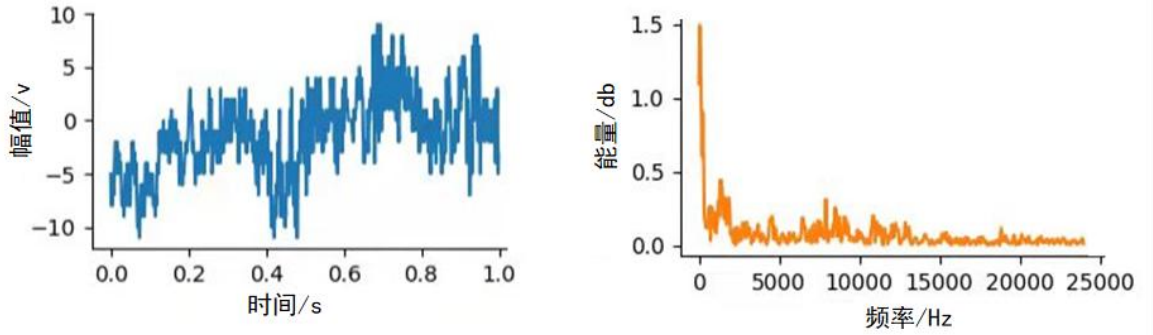
音频去噪方法主要包括滤波去噪与声音信号增强去噪两大类，传统的滤波器例如低通、高通是通过某些确定性规则或门限来获取，若目标信号与噪声信号主要频率段不相重合，可以选择滤波器去噪；声音增强去噪方法主要是对声音信号的每个频率点进行抑制降噪处理，包括谱减法、小波去噪等，若目标信号与噪声信号相互重叠，可以选取声音增强去噪法。

猪舍环境中往往存在低频干扰噪声，为了优化含噪猪只声音信号，分别分析了猪只不同声音信号和噪声信号的时频域特征。频谱可以反映不同声音信号频率方面的内容，如图 2-4 为猪只咳嗽声、呼噜声、鸣叫声和喷嚏声 4 种声音的时间信号以及对应的振幅强度。通过对比猪只 4 种声音信号的频谱图可以发现，不同声音的振幅强度分布有所不同，猪只咳嗽声和鸣叫声的能量在不同频率范围内分布相似，主要分布在 100 ~ 5000Hz 以内（图 2-4a，c），呼噜声与咳嗽声和鸣叫声相比分布更为均匀，主要分布于 200 ~ 10000Hz 以内（图 2-4b），而环境噪声的能量主要集中在 0 ~ 600Hz 以内（图 2-5b），与猪只声音频段有所重叠。由此可见，数字滤波器对猪只声音信号去噪效果欠佳[79]，所以本文采用改进后的谱减法（基于多窗谱的谱减法）实现猪只音频去噪。

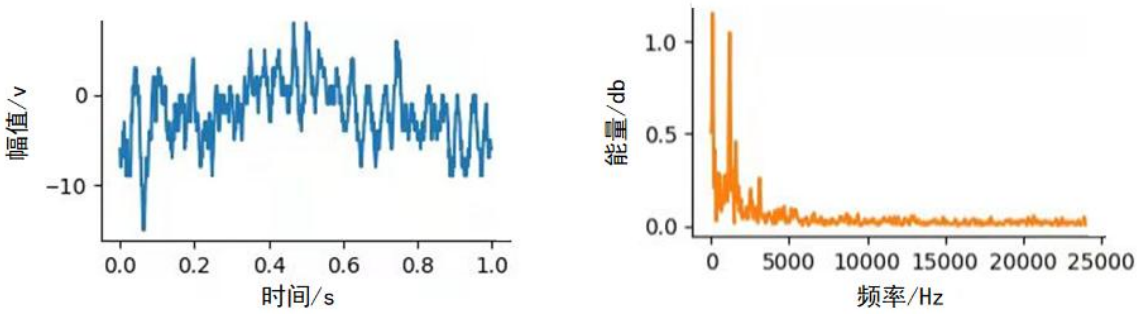


（a）咳嗽声时间信号及频谱图

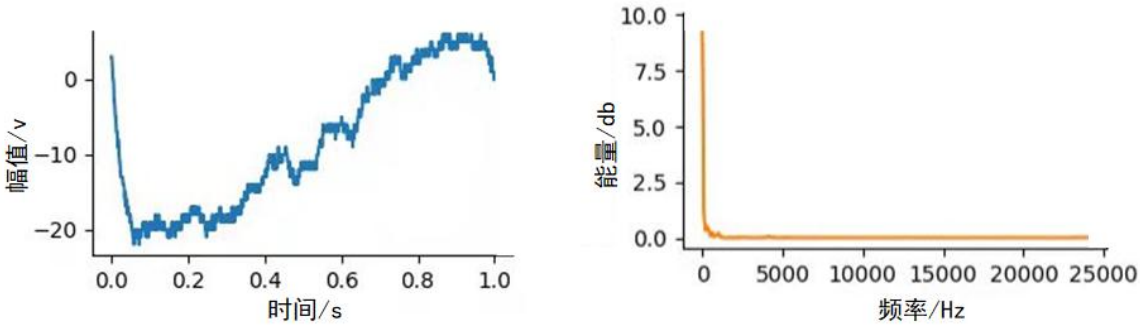
中国知网 https://www.cnki.net



（b）呼噜声时间信号及频谱图



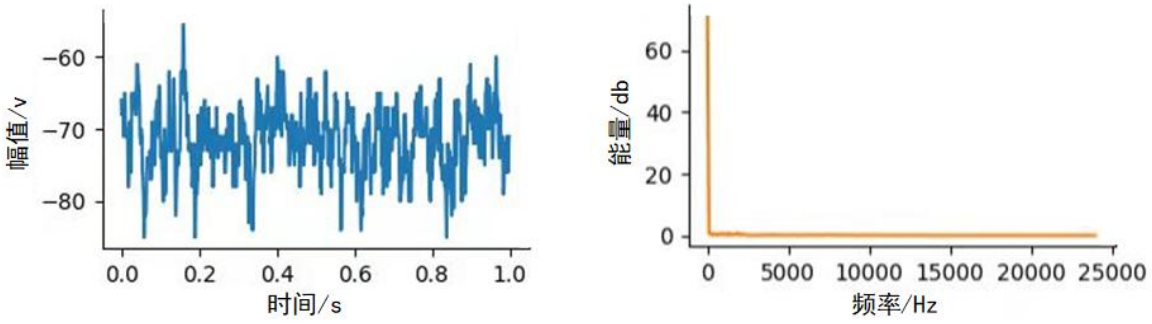
（c）鸣叫声时间信号及频谱图



（d）喷嚏声时间信号及频谱图

图 2-4 猪只声音信号

Fig.2-4 The pig sound signals



（a）噪声时间信号　　（b）噪声频谱图

图 2-5 猪舍环境噪声

Fig.2-5 The piggery environmental noise

中国知网 https://www.cnki.net

2.3.2.2 基于多窗谱的谱减法去噪

谱减法作为频域去噪方法，假设噪声信号为加性，得出噪声频谱以后，从原带噪谱中减去噪声频谱，获得纯净的目标谱估计，利用傅里叶反变换加上原信号的相位信息获得纯净的原始信号[80-81]。传统谱减法存在音乐噪声，本文采用基于多窗谱估计的改进谱减法[82-83]进行猪只声音去噪处理。

多窗谱的定义如式 2-1 所示，N 表示数据窗的个数，2-2 所示 S^{mt} 为第 i 个数据窗的谱，M 表示序列长度，$x(n)$ 表示数据序列；$a_i(n)$ 表示第 i 个数据窗的函数，其可以满足多个数据窗相互之间正交，如式 2-3 所示。

$$S^{mt}(w)=\frac{1}{N}\sum_{i=0}^{N-1}S_i^{mt}(w) \tag{2-1}$$

$$S_i^{mt}(w)=\left|\sum_{n=0}^{M-1}a_i(n)x(n)e^{-jnw}\right|^2 \tag{2-2}$$

$$\begin{cases}\sum a_k(n)a_k(n)=0 & k\neq j\\ \sum a_k(n)a_j(n)=1 & k=j\end{cases} \tag{2-3}$$

假设含噪猪只声音信号为 $x(n)$，加窗分帧操作后第 i 帧信号表示为 $x_i(n)$，对 $x_i(n)$ 作 FFT 后，获得其幅度及相位谱如式 2-4 所示，式中 $|X_i(k)|$ 为幅度谱，相位谱 $\theta_i(k)=\arctan\left[\frac{\mathrm{Im}(X_i(k))}{\mathrm{Re}(X_i(k))}\right]$。

$$X_i(k)=\sum_{m=0}^{N-1}x_i(m)\exp(-j\frac{2\pi mk}{N}) \qquad k=0,1,...,N-1 \tag{2-4}$$

通过帧间平滑处理后得到平均幅度谱如式 2-5 所示，式中 $2M+1$ 示从第 i 帧开始前后各取 M 帧，对 $2M+1$ 帧平均。

$$|\dot{x}_i(k)|=\frac{1}{2M+1}\sum_{j=-M}^{M}|X_{i+j}(k)| \tag{2-5}$$

计算功率谱密度 $P(k,i)$，帧间平滑处理得到 $P_y(k,i)$，根据 $P_y(k,i)$ 算出含噪声音段的 $P_n(k)$，如式 2-6 所示，式中 $PMTM$ 为对声音信号采取多窗谱功率谱密度估计。

$$P(k,i)=PMTM\left[x_i(m)\right] \tag{2-6}$$

$$P_y(k,i)=\frac{1}{2M+1}\sum_{-M}^{M}P(k,i+j) \tag{2-7}$$

$$P_n(k)=\frac{1}{NIS}\sum_{i=1}^{NIS}P_y(k,i) \tag{2-8}$$

利用谱减关系计算增益因子 $g(k,i)$，从而得到谱减后的幅度值如式 2-9 所示，式中 α 表示过减因子，β 表示增益补偿因子。

$$g(k,i)=\begin{cases}(P_y(k,i)-\alpha P_n(k))/P_y(k,i) & P_y(k,i)-\alpha P_n(k)\geq 0\\ \beta P_n(k)/P_y(k,i) & P_y(k,i)-\alpha P_n(k)<0\end{cases} \tag{2-9}$$

中国知网 https://www.cnki.net

$$\left|\dot{X}_i(k)\right| = g(k,i) \times \left|\dot{X}_i(k)\right| \tag{2-10}$$

如图2-6所示为谱减法处理音频时长为10s的连续咳嗽声降噪效果的波形对比图，由2-6b可以发现该方法滤波后对噪声消除效果良好，并用人耳试听进一步验证，猪只的原始声音样本并无失真。

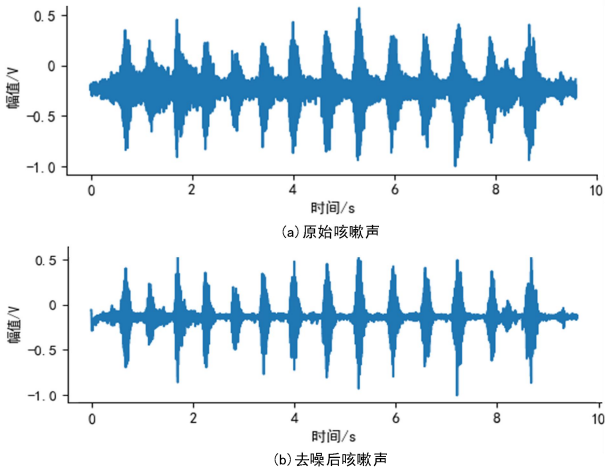
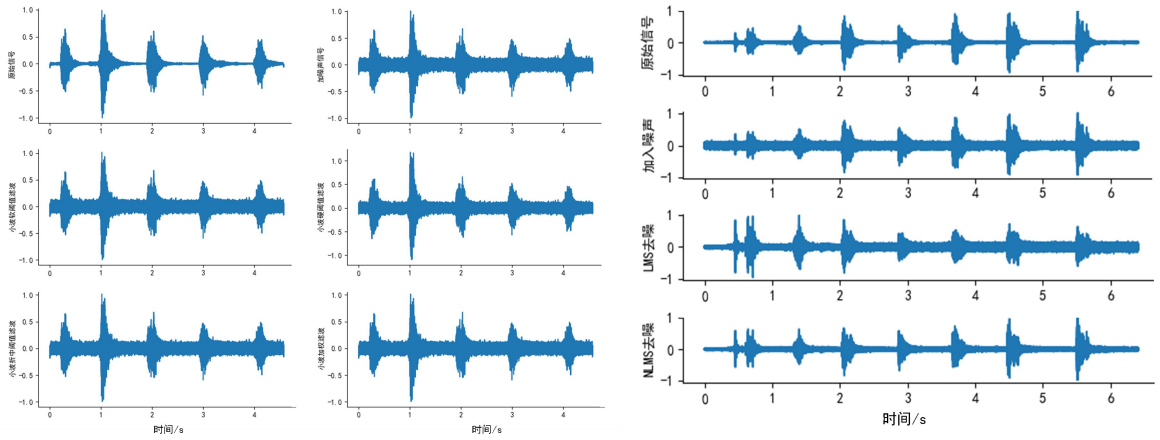


图 2-6 谱减法去噪前后猪只咳嗽声波形图

Fig.2-6 The sound waveform of pig cough before and after spectral subtraction denoising

本文还对比分析了小波去噪以及LMS和NLMS的去噪效果，如图2-7为小波去噪以及LMS和NLMS去噪前后波形对比。由波形可以看出小波去噪效果最差，NLMS相较LMS去噪后波形还原较好，但滤波效果不理想；谱减法在保持声音波形不失真的情况下滤波更彻底。



（a）小波去噪　　（b）自适应滤波器

图 2-7 小波分解与LMS以及NLMS去噪前后波形对比

Fig.2-7 The wavelet decomposition, LMS and NLMS denoising effects

2.3.3 双门限法端点检测

端点检测方法是大多声音信号处理系统的前部分操作[84]，采用手工截取方式获得

中国知网 https://www.cnki.net

的猪舍有效音频段中包含猪只咳嗽等有声段以及静默段，从接收的声音信号中准确检测出猪只声音开始和结束的端点是猪只声音识别的前提。

本文利用双门限端点检测法（短时能量和短时过零率特征作为参数）对去噪后的536段声音信号进行端点检测。第一步对信号分帧处理，谱减法去噪后的猪只声音信号为 $f(n)$，加窗分帧处理后信号如式2-11所示，式中，$f_i(m)$ 表示处理后的第 i 帧语音信号，$w(m)$ 表示窗口函数，N 表示帧长，T 表示帧移量。

$$f_i(m)=w(m)*f(iT+m) \qquad 1<m\le N \tag{2-11}$$

则该帧的能量为式2-12所示：

$$E_i=\sum_{m=1}^{N} f_i^2(m) \tag{2-12}$$

获取帧信号的短时过零率为式2-13所示，式中sgn[]表示符号函数，其定义式为式2-14所示。

$$Z_i=\sum_{m=1}^{N}\left|\mathrm{sgn}[f_i(m)]-\mathrm{sgn}[f_i(m-1)]\right| \tag{2-13}$$

$$\mathrm{sgn}[x]=\begin{cases}1 & x\ge 0\\ -1 & x<0\end{cases} \tag{2-14}$$

在短时能量值的基础上选择一个高门限（短时能量平均数的一半），声音信号的能量包络大部分落在门限上，首先进行一次初步判定。选择一个较低门限，从初判位置起点向左，终点向右进行搜索。第3次搜索时将短时过零率大于3倍的音频段加入搜索范围，即为所求的音频段[85-87]。如图2-8所示为猪只咳嗽声双门限端点检测结果图，图中黑色实心点表示有声段起始点，红色实心点表示结束点，表明该方法能准确确定非静默信号的起止点，端点检测效果较好。实验还对比分析了对数频率距离法、熵谱法、相关法等端点检测算法，如图2-9所示。其中比例法以及相关法的效果最差，不能准确检测有声段，对数频率距离和熵谱法效果相近，但仍和双门限端点检测法存在一定差距，后续研究以双门限端点检测为基础。

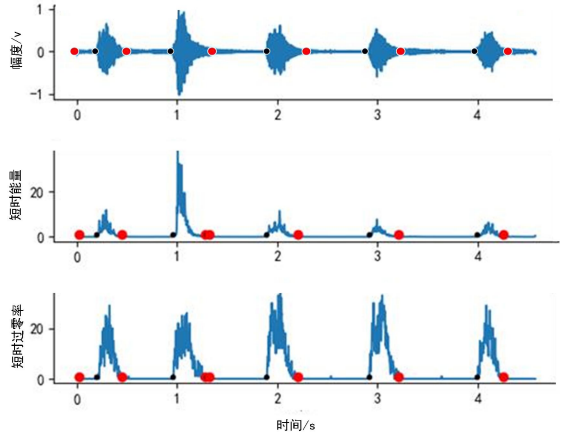


图 2-8 双门限端点检测结果图

Fig.2-8 The result of double threshold endpoint detection

中国知网 https://www.cnki.net

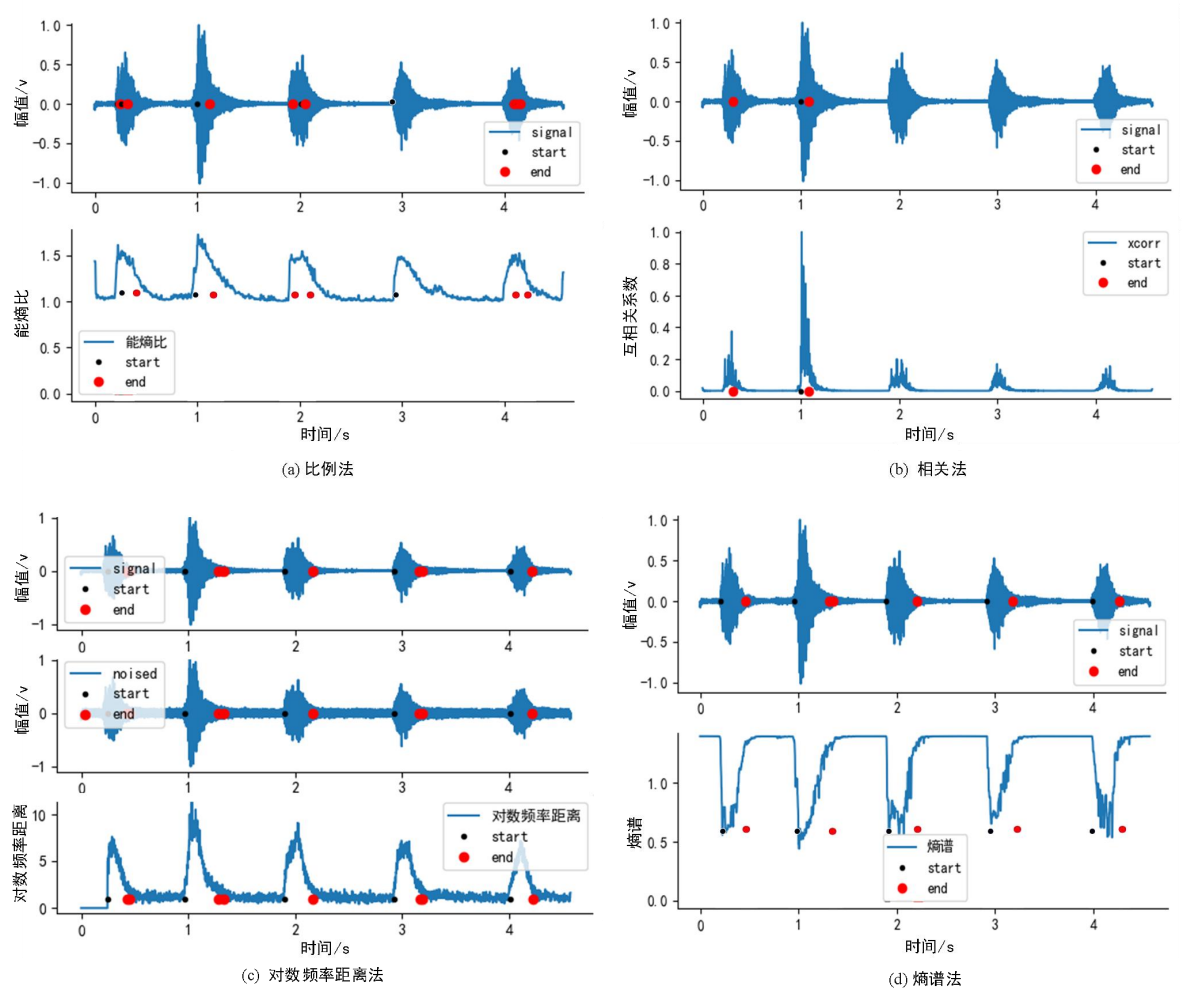


图 2-9 不同端点检测方法试验结果图

Fig.2-9 The results of different endpoint detection methods

2.4 猪只音频数据集制作

为了能更好地运用深度学习框架解决猪只咳嗽声分类识别的问题，模型设计以及训练前的首要工作就是制作满足要求的数据集，本实验模型训练使用的数据集为经过以上 2.3 小节包括谱减法去噪与双门限端点检测处理之后得到的有效音频数据。

2.4.1 数据标注

利用双门限端点检测法对谱减法去噪后的 536 段猪只声音信号进行端点检测后共得到咳嗽声样本 1058 个，其它声音样本 420 个，其中喷嚏声 184 个，鸣叫声 121 个，呼噜声 115 个，如图 2-10 为样本数据集。

中国知网 https://www.cnki.net



图 2-10 样本数据集

Fig.2-10 The graph of sound sample data set

2.4.2 数据集划分

验证和测试集数目分别设置为本类声音样本个数的 10%，每次实验随机选取，剩余样本设置为训练集，表 2-2 为数据集划分结果统计。

表 2-2 数据集划分结果

Tab.2-2 The results of data set partitioning

声音类别	声音特征	训练集样本个数	验证集样本个数	测试集样本个数	总数
咳嗽	声音短且连续，强劲有力，喉音明显	848	105	105	1058
喷嚏	声音短且快速，鼻音明显	148	18	18	184
鸣叫	声音尖锐刺耳	97	12	12	121
呼噜	声音低沉，类似哼叫	93	11	11	115

2.5 本章小结

本章详细介绍了实验音频数据采集方案，数据预处理及数据集制作方法，具体如下：

（1）介绍了实验数据的获取方法。根据猪舍实际情况，设计猪舍音频数据硬件采集装置平台，并完成音频数据的采集。

中国知网 https://www.cnki.net

（2）介绍了本文实验所需环境。在 Linux 系统中，python 版本为 3.6.10 环境中安装 Anaconda3 并搭建 PyTorch1.7.0 的 GPU 版本深度学习框架，为后续咳嗽声分类识别模型的训练作准备。

（3）实验数据预处理，数据预处理利用 AU 软件对音频数据进行有声段截帧，删除大量无效录音数据。然后利用改进后的谱减法进行去噪以及基于双门限的端点检测法进行端点检测。

（4）深度神经网络模型训练数据集制作，将猪只的每类声音数据划分为训练集、测试集和验证集 3 部分，为后续猪只咳嗽声识别模型迭代训练和性能检测及有效评价咳嗽声识别性能做准备。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第三章 基于深度学习的猪只声音特征参数提取

声音样本特征的提取直接影响深度学习模型训练的效果，为了能够准确识别咳嗽声，本章节选择声音特征提取算法中两种代表性的方法——滤波器组(Log_filter Bank, logFBank)和 Mel 频率倒谱系数(Mel Frequency Cepstral Coefficents, MFCC)特征为重点研究对象，将上文获取的猪只声音数据 100%提取特征后，按训练集 80%、验证集 10%、测试集 10%的比例划分并保存用于后续模型训练，最后通过模型训练指标判别不同特征提取方法与神经网络的适用度，选则最适合的匹配特征。

3.1 音频特征提取算法

音频信号的特征提取方法通常包括对信号的分析、提取属性、预测行为、识别信号中是否存在任何模式以及一个特定信号如何与另一个类似信号相关联等。提取的特征直接影响音频处理算法的性能，因此特征提取也是机器学习环节中不可缺少的一部分。本节简要介绍了特征提取技术，总结音频信号处理的方法。图 3-1 为音频信号特征的演化过程。

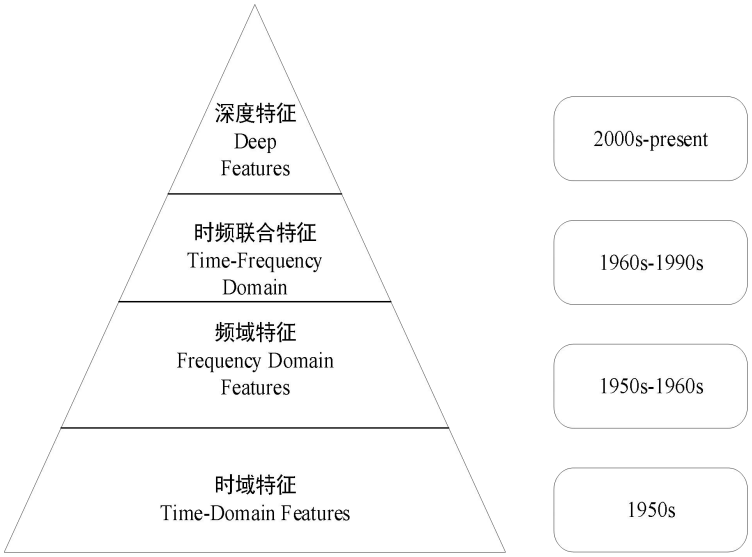


图 3-1 音频特征提取的发展

Fig.3-1 The evolution of audio feature extraction

音频特征的演化可分为时域、频域、时频域以及深度特征。时域特征于 20 世纪 50 年代后期出现[88-90]，迄今为止，其在处理音频时仍然发挥着重要作用。频域特征的出现在 20 世纪 50-60 年代[91-92]，为了分析音频信号的频谱特征，演化出了音高、共振峰等特征。20 世纪 60 年代后期，出现了时频特征提取算法[93-95]。自深度学习的出现

中国知网 https://www.cnki.net

及发展以来，深度特征从 2010 年开始被应用于图像处理、医疗卫生、交通等各种领域中[96-98]。

3.1.1 音频特征分类

音频特征可以分为时域、频域、小波域、倒谱域和时频域特征五大类。时域特征有短时能量(STE)、短时过零率(ST-ZCR)、线性预测系数(LPC)等；频域特征包括滤波器组(FBank)、Mel 谱系数(MFSC)等；小波域包括连续小波变换(CWT)、小波包分解(CWPT)、离散小波变换(DWT)、Mel 倒谱系数(MFCC)等；时频域特征包括时频分布(TFD)等；其余还有可以应用于任何领域当中的稀疏特征，稀疏性可以通过例如匹配跟踪(MP)、正交匹配跟踪等方法实现。

3.1.2 基于深度学习的特征提取算法

深度学习可从大量任务中自动学习提取特定的特征，作为模型训练的参数，具有更好的识别效果和应用前景[99]。深度特征也可从 CNNs、RNNs、DNNs、SAE、LSTM、BLSTM 等深度学习模型中提取出。例如 MFCC 或任何其他相关的音频特性可以作为输入提供给深度神经网络，然后从深度神经网络中学习并提取更深度的特征，所以深度特征提取的效果也依赖于神经网络的深度。如图 3-2 所示为深度神经网络特征提取示意图(以 MFCCs 作为输入特征)。

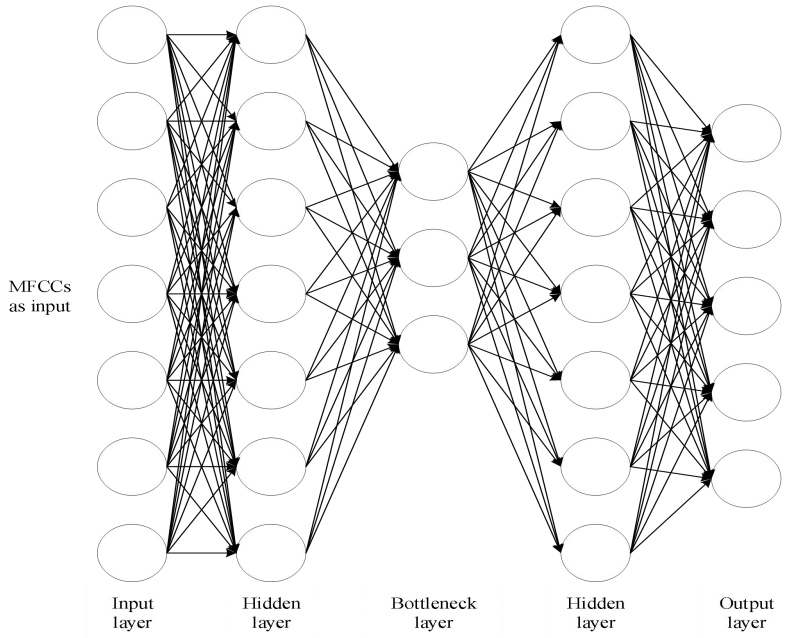


图 3-2 音频深度特征提取过程

Fig.3-2 The process of audio depth feature extraction

中国知网 https://www.cnki.net

3.2 猪只声音信号特征参数提取

在声音信号的倒谱域特征参数中，使用最多的是 MFCC 和 LPCC，本研究使用滤波器组和 Mel 频率倒谱系数来作为模型输入参数。

MFCC 原理是根据人的听觉系统分析声音的频谱特性，与频率成非线性关系[100-101]。猪只有效声音信号主要集中在低频段，MFCC 精度随频率提高后下降，常使用低频 MFCC 进行处理。logFBank 特征提取类似于 MFCC，都是在 FBank 特征提取步骤基础上，再进行一些处理。logFBank 与 MFCC 的主要区别在于，logFBank 特征提取算法是在得到 FBank 特征之后，直接作对数变换得到最终结果，MFCC 需要再进行一步 DCT 处理，logFBank 计算量相对较小，相邻滤波器组之间有重叠导致相邻近特征高度相关。随着深度学习的发展以及 DNN 和 CNN 网络的出现，FBank、logFBank 特征之间的相关性能够更好地被神经网络利用，提高语音识别的准确率和降低差错率(WER)，常常被用于深度神经网络的特征输入。如图 3-3 所示为 MFCC 与 logFBank 特征提取步骤：

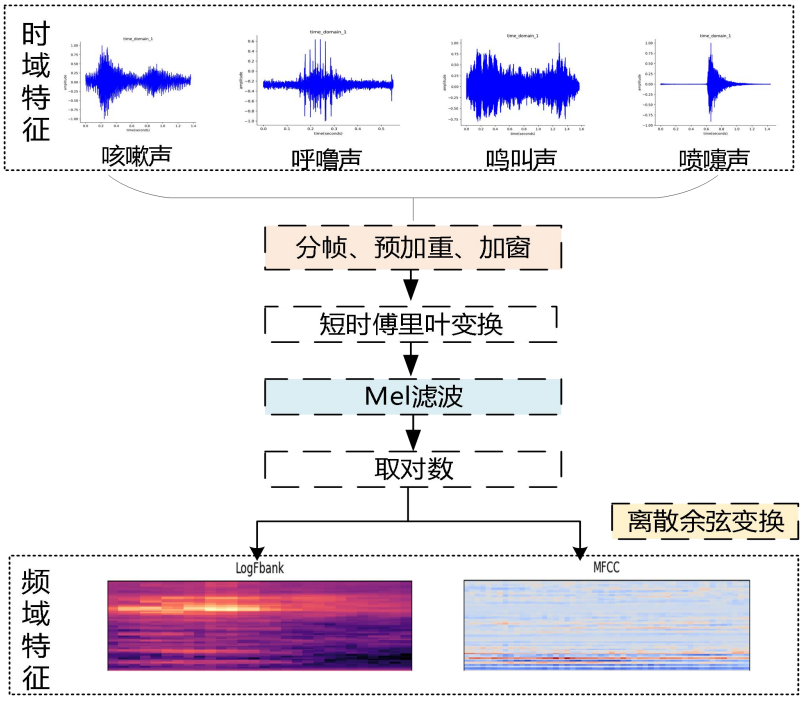


图 3-3 特征提取步骤

Fig.3-3 The steps of feature extraction

3.2.1 实验步骤

3.2.1.1 猪只声音信号预加重

快速傅里叶变换之后，高频信号减少，为了补偿高频分量的损失，需要对猪只声音信号进行预加重操作。本文采用公式 3-1 所示的一阶高通滤波器进行猪只声音信号

中国知网 https://www.cnki.net

预加重，$S(n)$ 表示 n 时刻声音采样值，$S(n\text{-}1)$ 表示 $n-1$ 时刻声音采样值，$S'(n)$ 表示预加重后的猪只声音信号，α 表示预加重的系数值，本文 α 设置为 0.97。

$$H(z)=1-\alpha\times z^{-1} \tag{3-1}$$

$$S'(n)=S(n)-\alpha S(n-1) \qquad n\in N \tag{3-2}$$

3.2.1.2 时域分帧、加窗

由于猪只原始音频样本长度不固定，而且声音信号宏观上表现不平稳，微观变为短时平稳，为了方便傅里叶变换，把猪只声音信号分为一帧一帧来处理。分帧操作将连续的声信号切分为若干片段，截断效应会产生频谱泄漏，每帧之间设置一小部分重叠区域即帧迭避免窗边界处信号遗漏。

三种常见窗函数如式 3-3、3-4、3-5 所示，式中 $W(n)$ 表示汉明窗函数值，N 表示声信号总采样点个数，n 表示各个采样点。如图 3-4 为几种窗函数示意图，本文选用汉明窗，窗口长度设置为 25ms。

矩形窗：

$$W(n)=\begin{cases}1 & 0\le n\le N-1\\ 0 & others\end{cases} \tag{3-3}$$

汉明窗：

$$W(n)=\begin{cases}0.54\text{-}0.46\times\cos\dfrac{2\pi n}{N-1} & 0\le n\le N-1\\ 0 & others\end{cases} \tag{3-4}$$

海宁窗：

$$W(n)=\begin{cases}0.5(1-\cos\dfrac{2\pi n}{N-1}) & 0\le n\le N-1\\ 0 & others\end{cases} \tag{3-5}$$

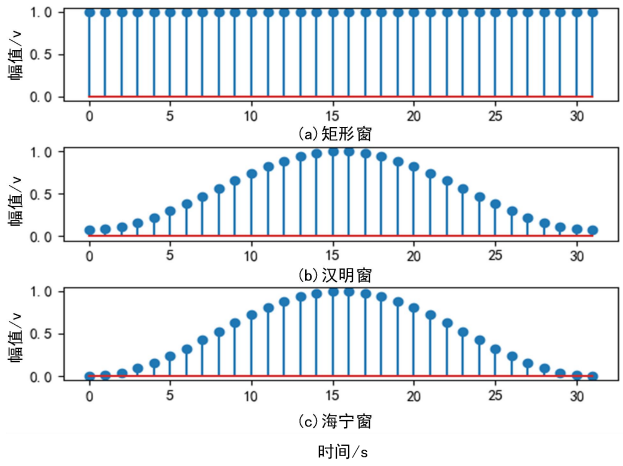


图 3-4 窗函数

Fig.3-4 Window functions

中国知网 https://www.cnki.net

为了保证猪只声音信号不失真，依据 Nyquist 采样定律，采样频率设置为 48KHz，帧长度设置为 25ms，帧迭长度设置为 10ms，用汉明窗消除每一帧信号两端不连续问题，取得高质量频谱。加窗过程为汉明窗函数与原信号作乘积变化，加窗公式为式 3-6 所示，式中 $S(n)$ 表示原始帧信号，$S^{'}(n)$ 表示加窗后的信号。如图 3-5 所示为 6s 猪只咳嗽声音信号分帧加窗效果图。

$$S^{'}(n)=W(n)\times S(n) \tag{3-6}$$

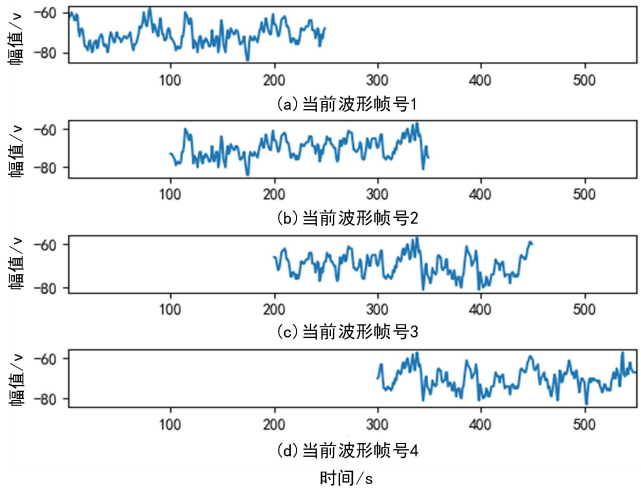


图 3-5 分帧加窗

Fig.3-5 Add window frame

3.2.1.3 帧信号快速傅里叶变换

经由上述几个步骤，得到的仍是猪只时域声音信号，进一步的声音信号特征提取将每一帧的时域信号转换到对应的频域，本文使用短时快速傅里叶变换(Short Time Fourier Transform, STFT)。每一帧进行 2048 点 STFT，公式如式 3-7 所示，角频率 $w=\frac{2\pi k}{N}$，实现离散短时傅里叶变换(DFT)，即 $X_n(e^{jw})$ 在频域的取样为式 3-8 所示：

$$X_n(e^{jw})=\sum_{m=1}^{N}x_n(m)e^{-jwm} \tag{3-7}$$

$$X_n(e^{j\frac{2\pi k}{N}})=X_n(k)=\sum_{m=1}^{N}x_n(m)e^{-j\frac{2\pi km}{N}} \qquad 1\le k\le N \tag{3-8}$$

$|X_n(k)|$ 为 $x_n(m)$ 的短时幅度谱估计，时间处频谱能量密度函数为式 3-9 所示，式中 $P_n(k)$ 表示非负实数矩阵。

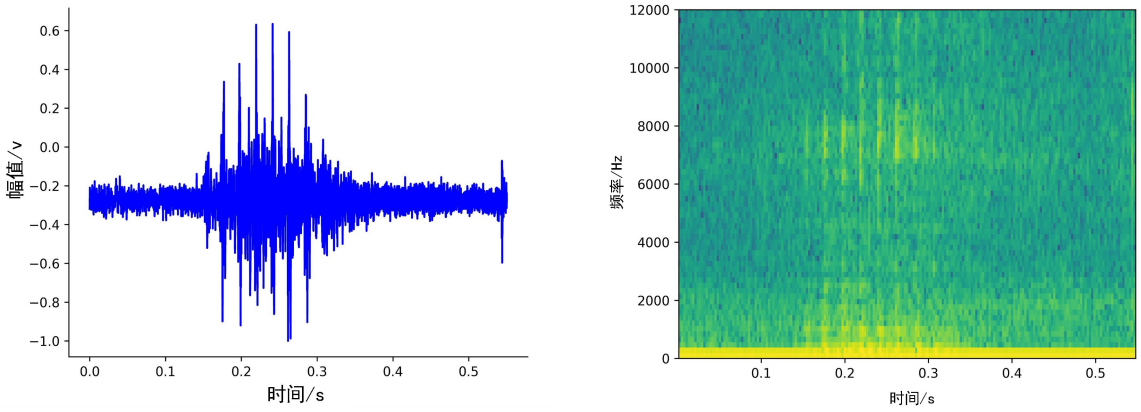
$$P_n(k)=\left|X_n(k)\right|^2 \tag{3-9}$$

以时间 n 为横坐标，k 为纵坐标，绘制出猪只声音信号的语谱图。最终将时域特征转换到频域，得到 4 种声音信号的各 2 种声音特征。如图 3-6 为时域到频域信号的转换结果图。通过对比分析 4 种声音各自的时域和频域特征图可发现不同声信号的语

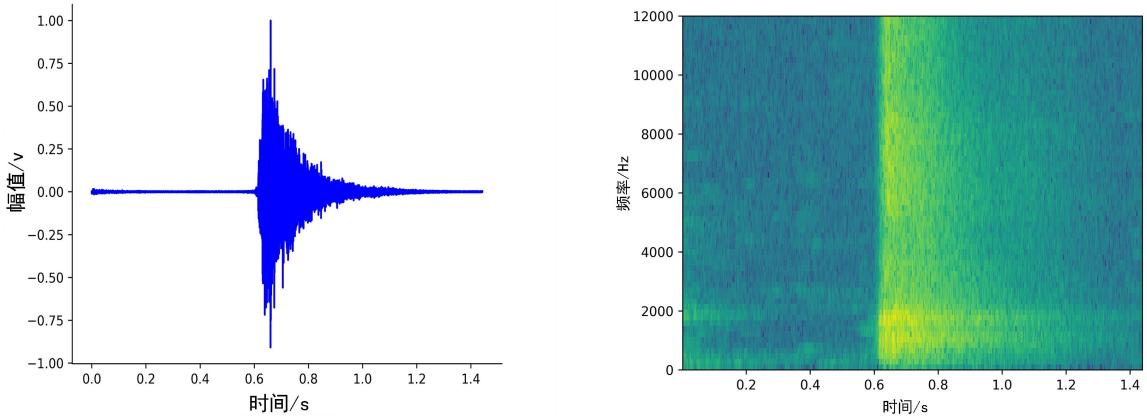
中国知网 https://www.cnki.net

谱图存在明显差异，这是本实验进行分类识别的基础。经过短时快速傅里叶变换得到的能量谱中相位谱包含的信息较少，所以选择丢弃相位谱，保留幅度谱，对每一个复数求其平方：

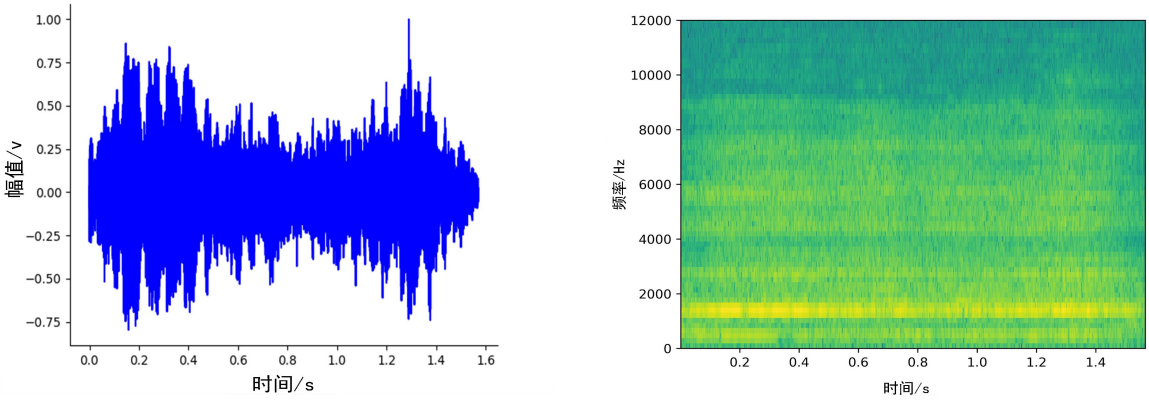
$$P'(n) = P(n)^2 \tag{3-10}$$



（a）呼噜声

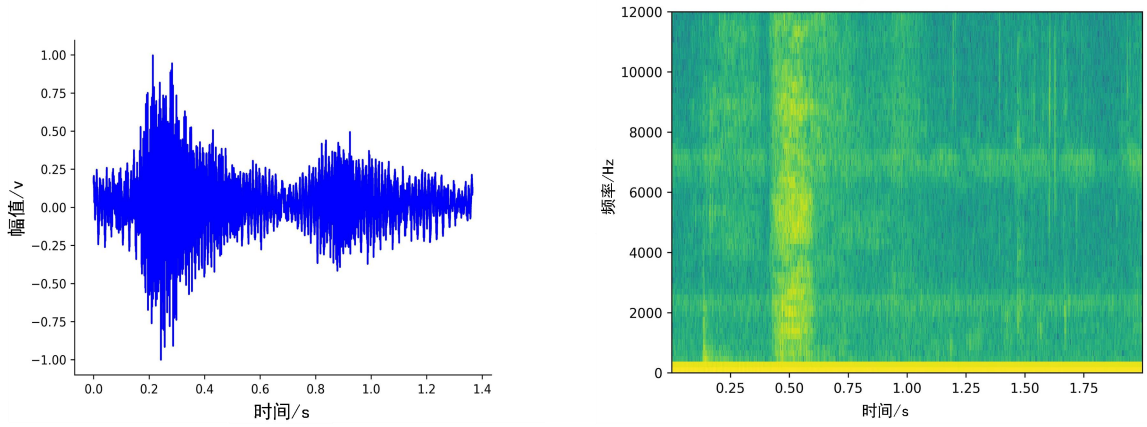


（b）喷嚏声



（c）鸣叫声

中国知网 https://www.cnki.net



（d）咳嗽声

图 3-6 猪只声音时频域特征转换

Fig.3-6 The feature conversion of pig voice in time-frequency domain

3.2.1.4 Mel 三角滤波

得到短时傅里叶变换后的频域信息后，采用 Mel 三角滤波器组进行滤波，具体关系为式 3-11 所示，式中 F_{mel} 表示感知频率，以 Mel 为单位，f 表示实际频率，以 Hz 为单位。

$$F_{mel}(f)=1125\ln(1+\frac{f}{700}) \tag{3-11}$$

Mel 滤波器组将声音信号的频率划分为三角形的滤波器序列。在声音频谱范围内设置若干个带通滤波器 $H_m(k),\quad 0\le m\le M$，M 表示滤波器个数。每个滤波器中心频率表示为 $f(m)$，滤波器等带宽，每个 $H_m(k)$ 的传递函数为式 3-12 所示，式中 $\sum_m^{M-1}H_m(k)=1$，$f(m)=\frac{N}{f_s}F_{mel}^{-1}[F_{mel}(f_l)+m\frac{F_{Mel}(f_l)-F_{Mel}(f_l)}{M+1}]$，$f_h$ 和 f_l 分别表示滤波器组最高和最低频率，f_s 表示采样频率，单位为 Hz，N 表示 FFT 变换的点数，$F_{Mel}^{-1}(b)=700(e^{\frac{b}{1125}}-1)$。

$$H_m(k)=\begin{cases}0 & k<f(m-1),k>f(m+1)\\ \dfrac{k-f(m-1)}{f(m)-f(m-1)} & f(m-1)\le k\le f(m)\\ \dfrac{f(m+1)-k}{f(m+1)-f(m)} & f(m)\le k\le f(m+1)\end{cases} \tag{3-12}$$

本文 STFT 后得到的幅度谱和每一个 Mel 滤波器进行频率相乘累加，滤波器组个数设置为 64，Mel 滤波公式为式 3-13 所示：

中国知网 https://www.cnki.net

$$E_m = \ln(\sum_{k=0}^{N-1} P(k) \times H_m(k)) \tag{3-13}$$

经过上述步骤后得到 FBank 特征，由于人耳对声音信号的感受呈对数值增长，对纵轴取对数进行缩放后，放大低能量处的能量，特征的相关性较高，存在一定缺陷，可以用 MFCC 特征弥补此缺陷。Log 操作的用途可以概括为：1) 压缩声音谱的动态变化范围；2) 频率域中乘性成份转为对数谱中加性成份，去除乘性噪声。取对数操作为式 3-14 所示：

$$LE_m = \log(E_m) \tag{3-14}$$

3.2.1.5 离散余弦变换

为了去除猪只声音不同阶信号值之间的相关性，采用 DCT 将声音信号映射到低维空间中。最有效的特征主要集中在前 12 个特征里，通常取 13 个进一步压缩数据。DCT 公式如式 3-15 所示，本文 MFCC 特征 Mel 刻度滤波器组个数设置为 128，返回倒谱数 64 个。

$$C(n) = \sum_{m=0}^{N-1} s(m) \cos(\frac{\pi n(m-0.5)}{M}) \qquad n = 1, 2, ..., L \tag{3-15}$$

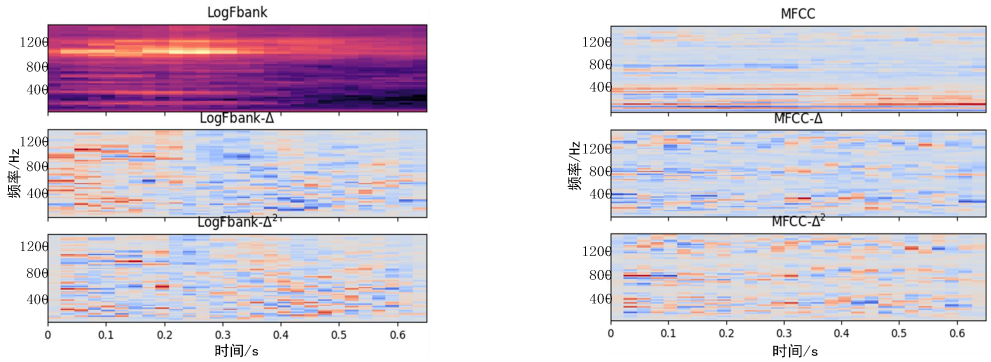
3.2.1.6 动态差分特征计算

猪只声音信号经由上述步骤处理后得到 MFCC 静态特征，动态特征通过使用静态特征的差分来表示。动静态特征相结合能有效地提高猪只声音识别模型的性能。差分参数的计算公式为式 3-16 所示，式中 d_t 表示第 t 个一阶差分的值，C_t 表示第 t 个倒谱系数的值，Q 表示倒谱系数的最大阶数值，K 表示一阶差分的时间差值，一般取 1 或 2。

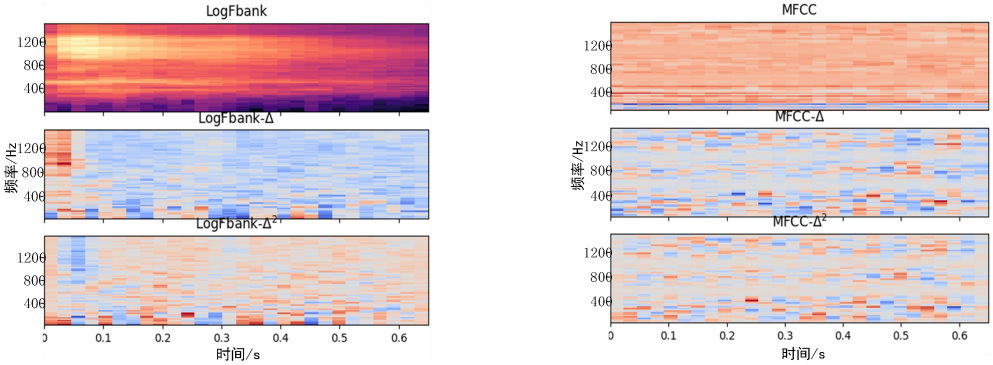
$$d_t = \begin{cases} C_{t+1} - C_t & t < k \\ \dfrac{\sum_{k=1}^{K} k(C_{t+k} - C_{t-k})}{\sqrt{2\sum_{k=1}^{K} k^2}} & other \\ C_t - C_{t-1} & t \geq Q - K \end{cases} \tag{3-16}$$

将一阶差分值再次代入上式求出二阶差分值。再将静态和动态特征的一阶、二阶差分值合并，得到 3 个特征进行零-均值标准化(Z-score)处理，转换成 3 维数组作为咳嗽声识别模型的输入。如图 3-7 为四种声音信号的 logFBank、MFCC 特征及其一阶与二阶差分，4 种声音信号的 logFBank 及 MFCC 特征存在明显差异。

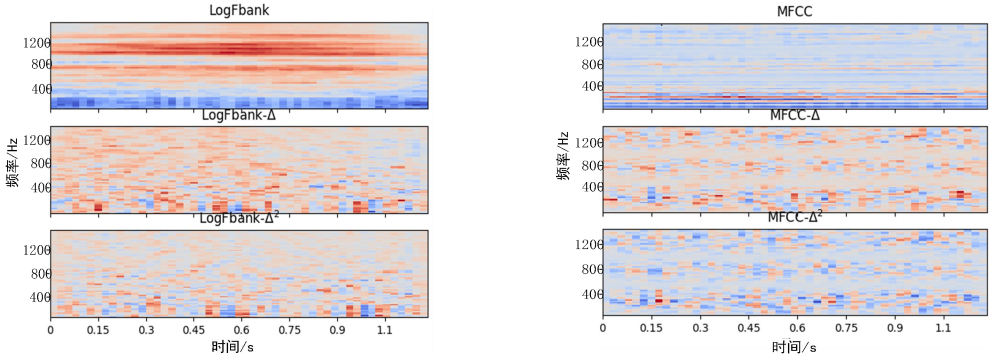
中国知网 https://www.cnki.net



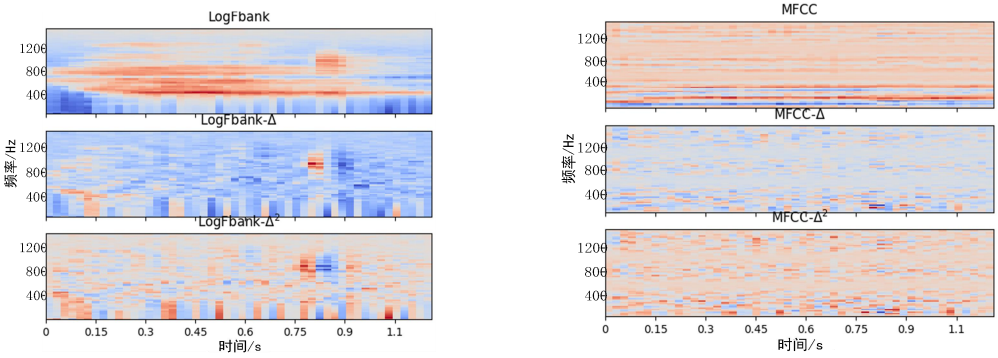
（a）呼噜声



（b）喷嚏声



（c）鸣叫声



（d）咳嗽声

图 3-7 logFBank 和 MFCC 特征及其一二阶差分

Fig.3-7 The logFBank and MFCC characteristics and their first and second order differences

中国知网 https://www.cnki.net

3.3 实验结果分析

本文特征提取算法研究的主要对象是猪只音频数据的 logFBank 特征以及 MFCC 特征。实验检测.wav 文件样本格式等信息正确后对每段音频数据进行采样等一系列处理，不限制音频长度，分别提取上述得到的猪只声音信号的 logFBank 和 MFCC 两种音频特征，分别按训练集、验证集和测试集存储所提取的特征为 npy 文件，方便后续输入深度神经网络模型进行训练。通过实验分析比较这两种声学特征对咳嗽声识别模型效果的影响，下图 3-8 为特征提取实验整体流程图。

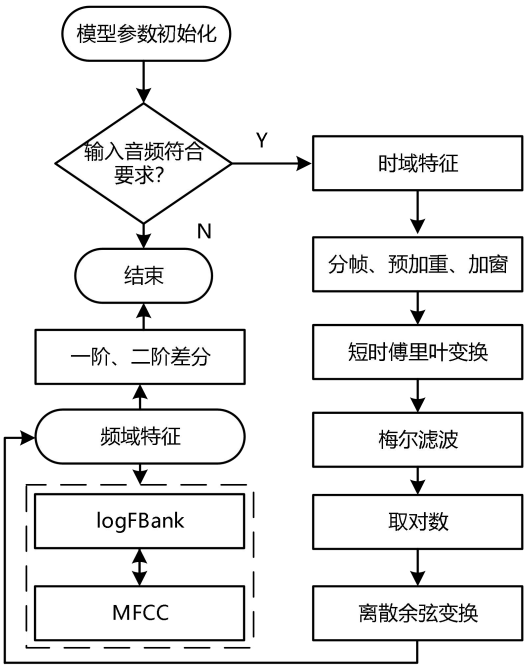


图 3-8 猪只声音特征提取流程图

Fig.3-8 The flowchart of pig voice feature extraction

本节 3.2 系统介绍了猪只声音的 logFBank 以及 MFCC 特征的提取步骤，本文在此基础上进行算法与参数设置对原始猪只声音信号进行特征分类提取与存储。将四种猪只声音信号按类别命名“咳嗽声”、“鸣叫声”、“呼噜声”、“喷嚏声”，并存储在同一个文件夹中，依次读取每个文件夹下的音频数据并记录对应名称，分别提取 MFCC 和 logFBank 特征后保存在相应文件夹中。将每个类别的特征按测试集：验证集：训练集为 1:1:8 的比例进行保存。随机选取测试集后将其从全集中舍去，同样，随机选取验证集后将其从全集中舍去，剩下即为训练集。创建的特征文件夹以 features/mfcc/train/咳嗽声方式命名，对应特征存储为 npy 文件。音频采样频率统一设置为 48k，logFBank 特征滤波器组个数设置为 64 个，进行 2048 点短时傅里叶变换。MFCC 特征提取滤波器组个数设置为 128 个，进行了 2048 点短时快速傅里叶变换，

中国知网 https://www.cnki.net

返回倒谱个数 64 个。求取 logFBank 和 MFCC 特征的一阶及二阶差分后，将数据沿水平方向堆叠为 3 维数组，方便后续输入深度神经网络模型进行训练。

本小节所用特征提取方法能够实现对猪只音频数据的两种特征自动有效提取，通过对比分析 4 种声音各自的时域和频域特征图可发现，不同猪只声信号的语谱图存在明显差异，表明 4 种声音信号的 logFBank 及 MFCC 特征也存在明显差异，为后续特征输入神经网络模型训练做准备。

3.4 本章小结

本章内容简要介绍了音频特征提取算法的发展及基于深度学习的特征提取算法，重点介绍了猪只声音的 logFBank 和 MFCC 特征提取方法。具体如下：

（1）介绍了音频特征提取算法的分类及其发展，介绍了基于深度学习的特征提取算法。

（2）进行猪只的声音信号 logFBank 和 MFCC 特征提取，分别得到猪只 4 种声音信号的 logFBank 以及 MFCC 特征，分析比较 4 种声音信号两种特征之间的差异可以发现语谱图存在明显差异，这是本实验分类识别的基础。将测试集、验证集、训练集按 1:1:8 比例特征提取并存储后，得到的 logFBank 以及 MFCC 特征与其一阶及二阶差分组成 3 维数组作为后续深度神经网络模型的输入参数。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第四章 基于深度神经网络的猪只咳嗽声识别模型

复杂场景下的猪只声音识别是精准畜牧业中动物信息获取的重要基础，为了实现猪只咳嗽声自动高效精准检测，本章研究了基于卷积神经网络(CNNs)以及深层前馈序列记忆神经网络(DFSMN)的猪只咳嗽声识别模型。通过对比不同迭代次数和特征提取方法对模型效果的影响，比较总体精确度，咳嗽声和非咳嗽声识别精确度，召回率及F1 值等评价指标，最终得到了 MFCC-CNNs 模型咳嗽声识别精确率达到 97%；设计了四分类模型并研究模型性能，研究发现四分类模型的其它声音识别准确率效果欠佳，考虑原因为样本数量不均衡或样本数量较少，后续将继续扩充数据集。

4.1 猪只咳嗽声识别模型整体设计

神经网络(Neural Networks, NNs)由神经元发展而来，美国神经生理学和控制论科学家 Warren McCulloch 和 Walter Pitts 最早提出了相较复杂的 MP 神经元模型。2006 年，学者 Hinton 首次提出深度信念网络(DBN)的概念，将利用多层神经网络学习的方法称为深度学习(Deep Learning)，随后在 ImageNet 分类竞赛中利用 CNNs 进一步证实了 Deep Learning 的优越性[102]。相较普通神经网络，深度神经网络显著特征就是网络的层数比普通的神经网络多的多，结构型式多样。神经网络的重要一部分是激活函数，表达能力引入非线性激活函数后更加强大。神经网络训练的目的就是让损失和最小，通常运用梯度下降算法计算损失关于每一个权重参数的偏导数。

猪只咳嗽声识别模型使用 LogFBank 以及 MFCC 特征与 CNNs 以及 DFSMN 组合训练，如图 4-1 所示为本文深度神经网络模型训练整体流程图。本章还将对模型结构、参数设置、训练方法以及模型优劣判定指标以及结果分析做详细介绍。

本文模型训练的整体流程可分为四大部分，第一部分为本文第二章节叙述的猪只声音数据集制作，包括谱减法去噪以及双门限端点检测两部分，得到猪只声音信号的四种标签，分别为“咳嗽声”、“呼噜声”、“鸣叫声”以及“喷嚏声”。第二部分为第三章节叙述的猪只声音信号特征提取，主要针对 logFBank 以及 MFCC 两种特征提取，将提取到的特征与各自的一阶及二阶差分组成三维数据作为后续模型训练的参数。第三部分为神经网络模型训练，为了研究出最佳猪只声音识别模型，本文利用两种神经网络模型做对比，通过对比分析两种神经网络结合不同的特征的识别性能选取最优模型用于猪只咳嗽声识别预警系统的调用模型。第四部分为实验结果分析，本文同时研究了模型的二分类及四分类识别效果，采用混淆矩阵计算查准、召回、准确率及 F1 值，最终得到了迭代次数以及最优特征模型组合。

中国知网 https://www.cnki.net

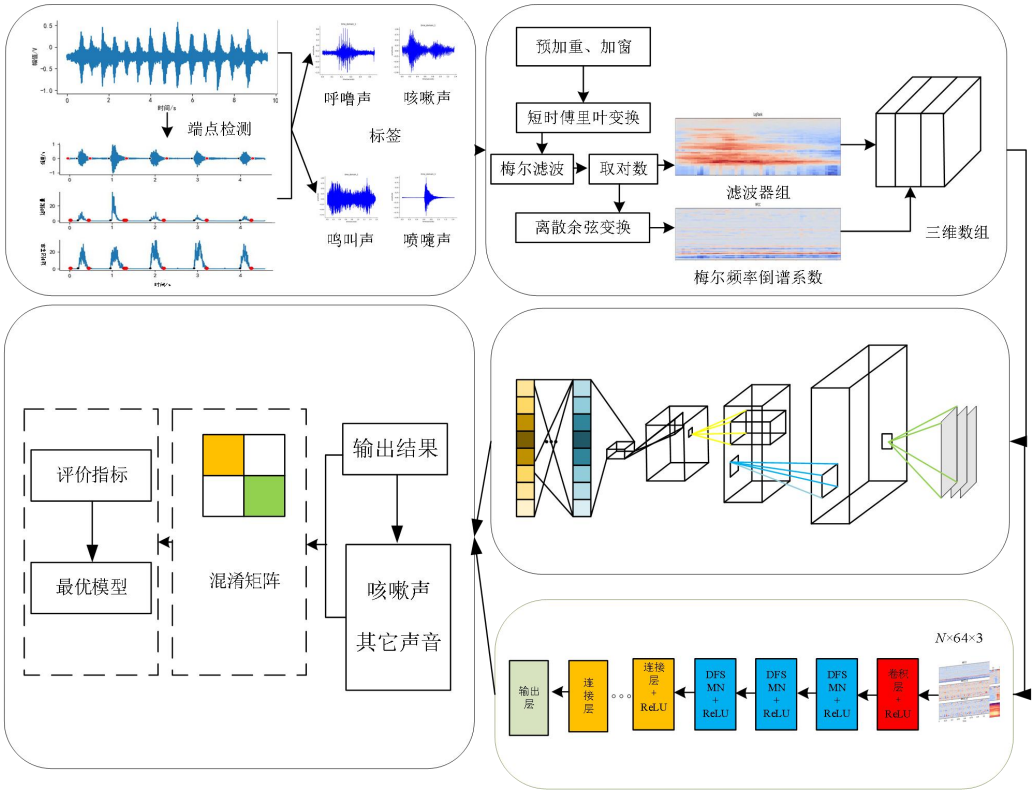


图 4-1 模型训练整体流程

Fig.4-1 The overall process of model training

4.2 基于 CNNs 算法的猪只咳嗽声识别模型

4.2.1 CNNs 模型网络结构设计

卷积神经网络在图像特征提取、语音处理等领域有着优异的效果。深层 CNNs 模型通常包含输入、卷积、激活、池化和全连接层。一个经典的卷积神经网络如图 4-2 所示：卷积层、激活函数与池化层统称为卷积模块，一个模型通常可包含 1～100 个卷积模块，一个卷积模块可以包括 1～5 个卷积层和激活函数，池化层可没有。卷积模块与全连接层称为隐藏层，全连接层可以是 0～2 个。特征值最后全部输入至 Softmax 输出层。

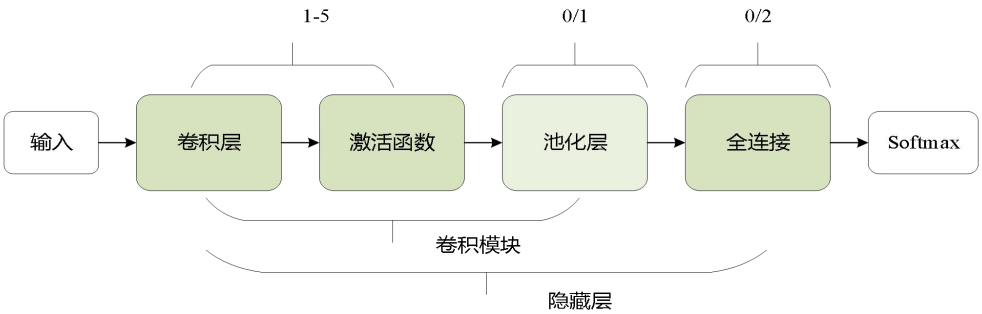


图 4-2 CNN 结构图

Fig.4-2 CNN structure

中国知网 https://www.cnki.net

设计 CNNs 神经网络过程中，卷积核参数设置影响特征参数提取的结果，所以对卷积核的大小、数量、步数(Padding)设置比较重要。如图 4-3 为卷积过程示意图。卷积操作离散形式如式 4-1 所示：

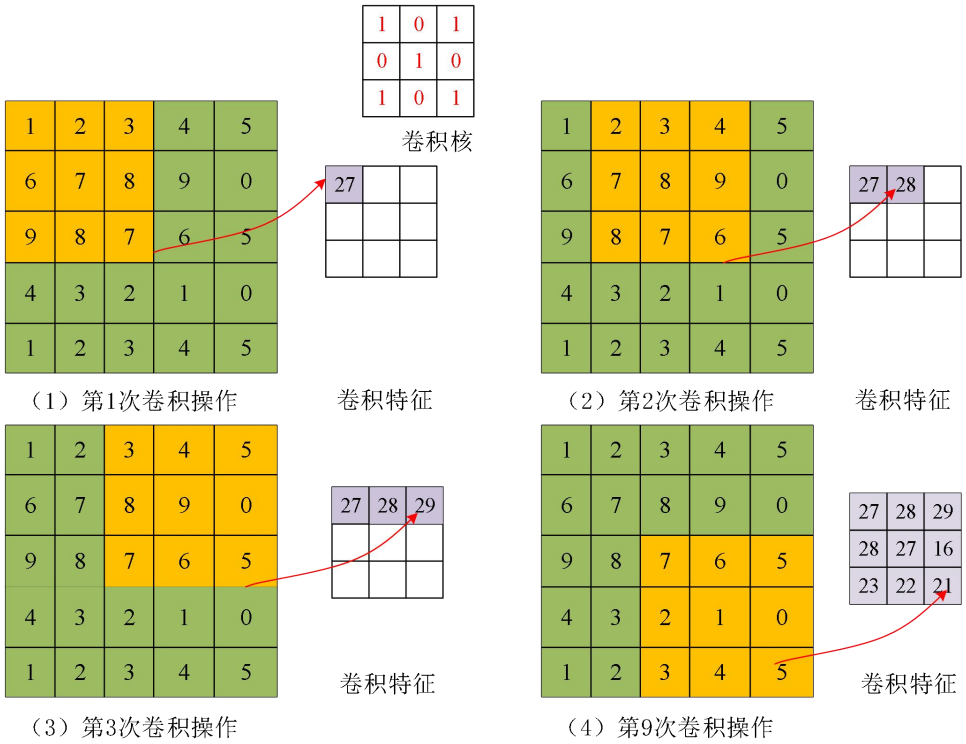


图 4-3 卷积过程示意图

Fig.4-3 The diagram of convolution process

$$y(n)=h(k)*x(k)=\sum_{k=-\infty}^{+\infty}h(k)\times(n-k) \tag{4-1}$$

加强网络的学习表达能力可以利用连续的非线性激活函数(Activation function)拟合非线性变换的问题。本文所用的激活函数为非线性矫正单元(ReLu)函数，该函数使神经网络能更好地解决复杂问题。

池化层位于各个卷积层之间，降低各个特征的维度，减少过拟合。包括最大池化处理(Max pooling)和平均池化处理(Average pooling)两种形式，Max pooling 可以消除子域内的非极大值以及降低运算复杂度，保留输入特征主要信息，即把上层结果特征元素的最大值作为输出，Average pooling 可以保留输入特征背景信息，减少由于子域大小限制产生的估值误差，即特征取平均值作为下层输入。假设池化层输入特征 $M\in Z^{X\times Y\times H}$（$X$、$Y$、$H$ 为特征的长度、宽度、深度），每一个特征 Z^d 可以划分子域 $Z_{x,y}^d,1\le x\le X,1\le y\le W$，子域内每个原始特征值为 m_i，子域经过池化层后特征值为 $F_{x,y}^d$，则最大池化计算公式为式 4-2 所示，平均池化计算公式为式 4-3 所示：

$$F_{x,y}^d=\max_{i\in Z_{x,y}^d}m_i \tag{4-2}$$

中国知网 https://www.cnki.net

$$F_{x,y}^{d}=\frac{1}{\left|Z_{x,y}^{d}\right|}\sum_{i\in Z_{x,y}^{d}}m_i \tag{4-3}$$

最大池化与平均池化过程如图 4-4 所示，本文选择最大池化。全连接层位于模型尾部，所有神经元之间由权重连接，用于特征分类。

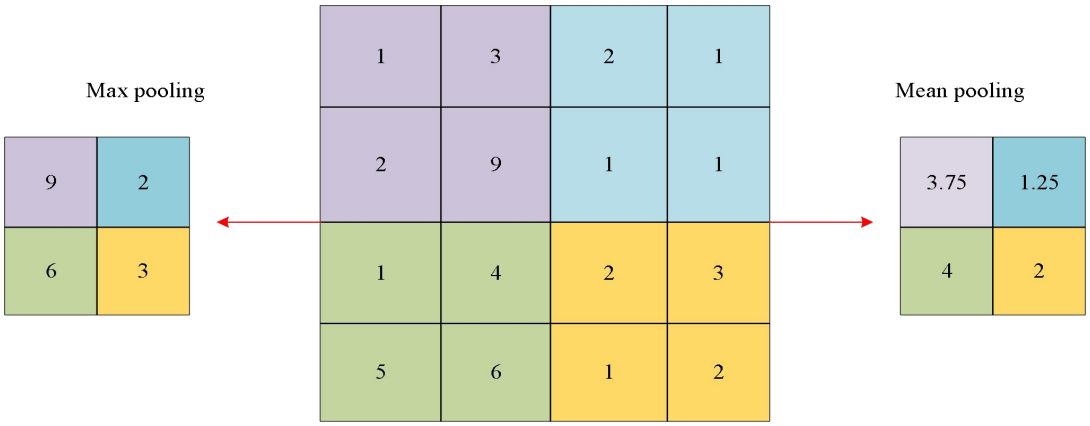


图 4-4 池化过程示意图

Fig.4-4 The diagram of the pooling process

CNNs 具有权值共享与局部连接两大特性所以效率较高。局部连接使连接数量大大减少，从而提高运算效率。权值共享是在同一个网络中使用同一个卷积核并不改变其内权系数，使得局部相邻区域高度相关，同时减少训练参数，降低网络复杂度，提高效率。模型训练过程中，CNNs 的计算方式为前向计算，参数学习方式为 BP 算法。

基于 CNNs 神经网络的结构与特点，设计了如图 4-5 所示的基于 CNNs 的猪只咳嗽声识别模型。该 CNNs 模型第一部分为输入层，输入参数为猪只声音信号特征组成的 3 维数组，第二部分隐藏层中包括 3 层卷积加最大池化层以及 3 层全连接层，用于标签分类，第三部分模型尾部为输出层，输出结果为二分类中的“咳嗽声”以及“其它声”或者四分类标签中的四种声音信号。

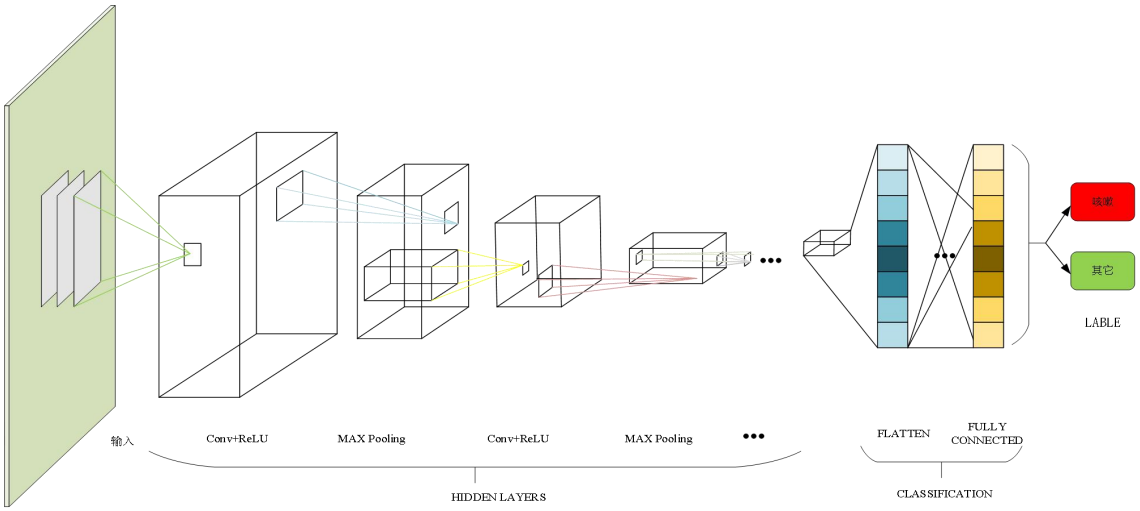


图 4-5 基于 CNNs 的咳嗽声识别模型结构

Fig.4-5 The structure of Cough recognition model based on CNNs

中国知网 https://www.cnki.net

4.2.2 CNNs 模型参数设置

本文使用的 CNNs 模型包括了 3 层卷积层，输入通道数分别为 3，32，32，输出通道数分别为 32，32，32，卷积核数(Kernel-size)均设置为 3，步长(Stride)设置默认值 1，无填充(Padding-mode)。激活层均采用 Relu 函数，利用最大池化层(MaxPool2d)提取重要信息，减少计算开销，Kernel-size 和 Stride 均为 2。全连接层输入输出通道数分别为 576×256，256×256，256×2。模型的具体结构参数如表 4-1 所示：

表 4-1 CNNs 模型结构与参数

Tab.4-1 The model structure and parameters of CNNs

类别	层序号	输出通道数	步长	窗口尺寸
卷积层	1	32	1	3×3
最大池化层	3	32	2	2×2
卷积层	4	32	1	3×3
最大池化层	6	32	2	2×2
卷积层	7	32	1	3×3
最大池化层	9	32	2	2×2
全连接层	10	256		
全连接层	12	256		
全连接层	14	4		

4.2.3 CNNs 模型损失函数

深度卷积神经网络模型训练是通过网络自身反复不断学习大量训练样本的特征实现对网络参数的不断更新，使得损失函数 Loss(Loss function)值降到最低。

本文 Loss 函数为 nn.CrossEntropyLoss()，可以用于多分类问题，也是 nn.logSoftmax()和 nn.NLLLoss()函数的整合。假设 p 为期望输出，q 为实际输出，则交叉熵 $H(p,q)$ 如式 4-4 所示：

$$H(p,q)=-\sum_x(p(x)\log q(x)+(1-p(x))\log(1-q(x))) \tag{4-4}$$

Pytorch 框架中的损失交叉熵公式如 4-5 所示，式中 p 表示样本的真实分布，q 表示模型预测的样本分布，$p(x)$ 表示期望的输出值，$q(x)$ 表示实际的输出值。本研究中的 CNNs 模型网络损失函数 Loss 优化是为了模型分类输出值与真实值的误差达到最低。且每个批次(Batch_size)计算一次损失函数。

$$H(p,q)=-\sum_x(p(x)\log q(x)) \tag{4-5}$$

4.3 基于 DFSMN 算法的猪只咳嗽声识别模型

4.3.1 DFSMN 模型网络结构设计

4.3.1.1 FSMN

FSMN(Feedforward Sequential Memory Networks)与普通前馈神经网络相比，最大

中国知网 https://www.cnki.net

的区别是在隐藏层旁边引入了记忆模块(Memory Block)。对于给定的输入 $X=\{x_1,x_2,...,x_T\}$，相关隐层的输出表示为 $H=\{h_1,h_2,...,h_T\}$，记忆模块中引入一个时延结构 h_t，该结构与其历史编码信息被同时反馈到下一个隐藏层，从而将历史信息引用至下层。记忆模块 $\tilde{h}_t$ 表达式如式 4-6 所示，式中 $f(.)$ 表示激活函数，a_i 表示对应的时不变系数，h_{t-i} 表示 $t-i$ 时刻对应层的特征，N 表示回看阶数。

$$\tilde{h}_t = f(\sum_{i=0}^{N} a_i . h_{t-i}) \tag{4-6}$$

由于记忆模块编码方式的不同，FSMN 可以分为标量编码系数和矢量编码系数两类，N 阶标量 FSMN 第 l 个隐层表达式如式 4-7 所示，式中 $a^l=\{a_0^l,a_1^l,...,a_N^l\}$ 表示 $N+1$ 个时间相关变量系数，矢量形式如式 4-8 所示，$\odot$ 表示矢量乘：

$$\tilde{h}_t^l = \sum_{i=0}^{N} a_i^l . h_{t-i}^l \tag{4-7}$$

$$\tilde{h}_t^l = \sum_{i=0}^{N} a_i^l \odot h_{t-i}^l \tag{4-8}$$

标量 FSMN 所有隐藏层可以共用同一编码系数，矢量 FSMN 隐藏层的编码系数不同使得矢量 FSMN 稳定性更好。双向的 FSMN，标量及矢量编码形式如式 4-9，4-10 所示，式中 N_1 和 N_2 分别表示回看和前看的阶数，或者利用历史和未来信息的窗口值。加大阶数或者在隐藏层中添加记忆模块可以增强 FSMN 对长时相关性的建模能力。

$$\tilde{h}_t^l = \sum_{i=0}^{N_1} a_i^l . h_{t-i}^l + \sum_{j=1}^{N_2} c_j^l . h_{t+j}^l \tag{4-9}$$

$$\tilde{h}_t^l = \sum_{i=0}^{N_1} a_i^l \odot h_{t-i}^l + \sum_{j=1}^{N_2} c_j^l \odot h_{t+j}^l \tag{4-10}$$

4.3.1.2 cFSMN

虽然 FSMN 较 RNN 性能有显著的优越性，但是神经元个数较多时，训练参数也会成倍增长，为了解决 FSMN 训练参数较多的问题，张仕良等[103]提出了 cFSMN 模型。如图 4-6 为 cFSMN 结构图，包括低纬度的线性投影层、记忆模块及记忆模块与下一个隐藏层的权重连接。

cFSMN 通过记忆模块将输出反馈给下一个隐藏层，以矢量 cFSMN 为例，其单向以及双向记忆模块表达式如式 4-11,4-12 所示，式中 $P_t^l = V^l h_t^l + b^l$ 表示第 1 个线性投影层的线性输出，激活函数如式 4-13 所示：

$$\tilde{P}_t^l = P_t^l + \sum_{i=0}^{N} a_i^l \odot P_{t-i}^l \tag{4-11}$$

$$\tilde{P}_t^l = P_t^l + \sum_{i=0}^{N_1} a_i^l \odot P_{t-i}^l + \sum_{j=0}^{N_2} c_j^l \odot P_{t+j}^l \tag{4-12}$$

中国知网 https://www.cnki.net

$$h_t^{l+1} = f(u^l \tilde{p}_t^l + b^{l+1}) \tag{4-13}$$

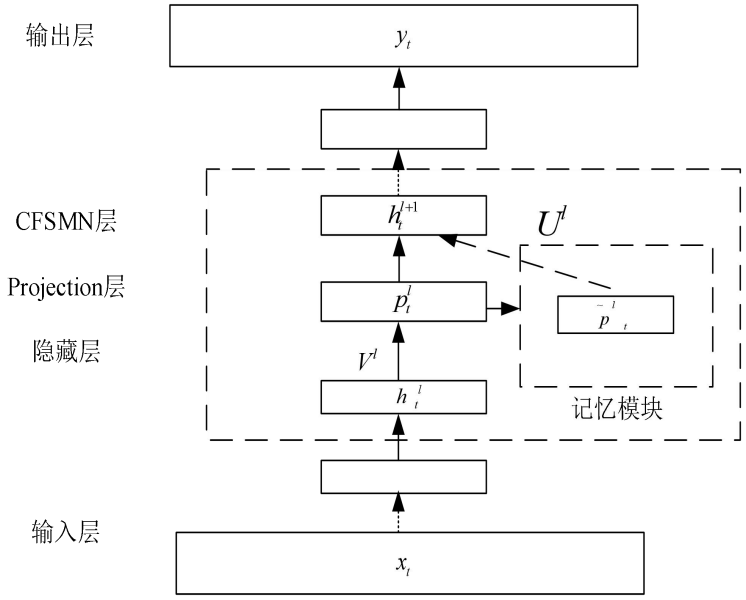


图 4-6 cFSMN 结构

Fig.4-6 The structure of cFSMN

4.3.1.3 DFSMN

DFSMN 在 cFSMN 记忆模块之间添加跳转连接(Skip connection)实现，低层记忆模块输出值累加到高层可帮助解决网络深度产生的梯度消失问题。DFSMN 记忆单元公式为式 4-14 所示。

$$\tilde{P}_t^l = H(\tilde{P}_t^{l-1}) + P_t^1 + \sum_{i=0}^{N_1^l} a_i^l \odot P_{t-s_1 i}^l + \sum_{j=1}^{N_2^l} c_i^l \odot P_{t+s_2 j}^l \tag{4-14}$$

DFSMN 将步长因子添加到记忆块中消除相邻帧信息由于帧迭产生的冗余性。总延迟计算公式如式 4-15 所示，式中 τ 表示记忆模块延迟，N_2^l 表示第 l 个记忆模块未来时间片长度，s_2 表示跨帧步长。

$$\tau = \sum_{l=1}^{L} N_2^L * S_2 \tag{4-15}$$

本文训练的 DFSMN 包括 1 个线性投影层和 2 个隐藏层，其中第 1 个隐藏层包含记忆模块，利用 20 阶的 FIR 滤波器，隐层单元使用 ReLU 函数。如图 4-7 为 DFSMN 咳嗽声识别模型网络结构，主要分为三部分，第一部分为输入层，第二部分为隐藏层，隐藏层头部为一层卷积网络结合 ReLU 激活函数层，中间部分由 3 层 DFSMN 组成，同样连接 3 个 ReLU 激活函数层，最后有 3 层全连接层，模型尾部是输出层。

中国知网 https://www.cnki.net

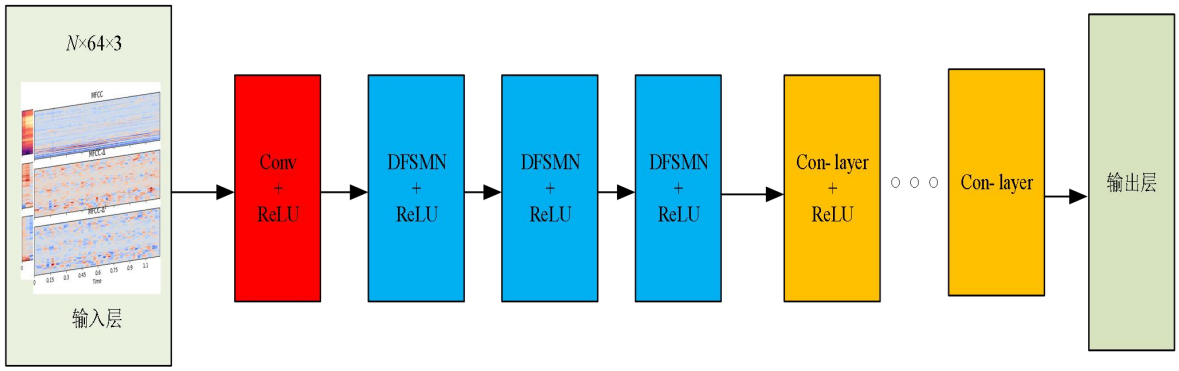


图 4-7 基于 DFSMN 的咳嗽声识别模型网络结构

Fig.4-7 Cough recognition model network structure based on DFSMN

4.3.2 DFSMN 模型参数设置

卷积层输入通道数为每种特征及其一阶和二阶差分组合，设置为 3，输出通道数依据经验值也即卷积核个数，设置为 2 的倍数 32，卷积核通道数依据输入通道数设置为 3；DFSMN 层模型输入特征维度由上层卷积运算后进行数组重新组合得到，具体输入分别为 1984，256，256 个单元，输出特征维度与下一层矩阵维度匹配，可进行矩阵运算，输出均为 256 个单元；全连接层同理，输入分别为 9728，256，256 个单元，输出为 256，256，4 个单元。如图 4-8 为基于 DFSMN 的咳嗽声识别模型框架，图中 InF、OutF 分别表示输入输出特征，In-Conv、L-Conv、R-Conv 分别表示输入、左半部分、右半部分网络的一维卷积层。

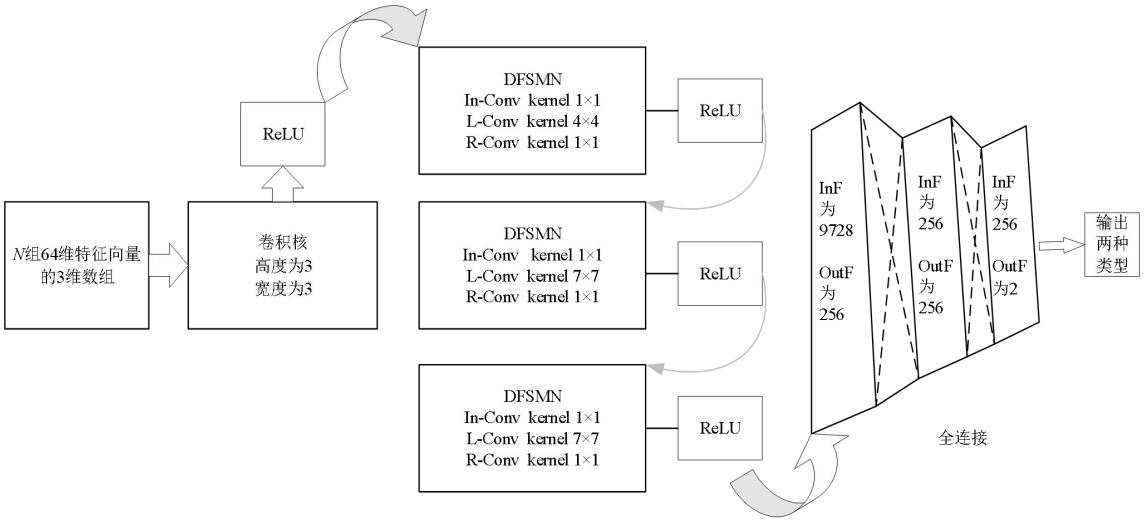


图 4-8 基于 DFSMN 的咳嗽声识别模型参数设置

Fig.4-8 Parameter setting of cough recognition model based on DFSMN

4.4 模型二分类实验结果与对比分析

4.4.1 实验步骤

中国知网 https://www.cnki.net

深度神经网络模型训练步骤通常随机生成初始模型参数，算法代入设定好的学习率和迭代次数 N；由损失函数获得计算得到损失 Loss；计算导数后由优化函数(Optimizer)得到下一次迭代的优化参数；不断迭代直至迭代次数 N。

本文神经网络模型训练步骤如下：整体网络框架构建包括训练集、验证集、测试集样本数据的加载。由于原始音频时长不一，特征提取后帧数不同，在输入模型之前需要对数据进行长度统一，取最大长度 40 帧为阈值，不足 40 部分由零值填充，超过 40 强制截取最大长度。超参数初始化，包括模型选择、有无 GPU、迭代次数设置、模型输出类别设置、所选用的特征等，读取 Label 值，二分类为“咳嗽声”和“其它声”，四分类为“咳嗽声”、“呼噜声”、“鸣叫声”、“喷嚏声”。每轮模型训练中(Epoch)，利用 shuffle 函数打乱样本顺序。训练一次取出样本数据(Bach-size)64 个，一次 Epoch 全部数据参与训练。随机梯度下降(Stochastic Gradient Descent, SGD)算法设置为优化器，初始化学习率为 0.001，学习衰减率为 0.98。设置 Cross Entropy Loss() 为损失函数。其中优化器公式为 4-16，4-17 所示，式中 θ 表示模型的参数，η 表示学习率值，g_t 表示损失关于参数的梯度，∇f 表示代价函数。

$$g_t = \nabla_{\theta_{t-1}} f(\theta_{t-1}) \tag{4-16}$$

$$\Delta\theta_t = -\eta * g_t \tag{4-17}$$

开始训练后每次迭代完成获取模型输出，计算损失值并更新参数，每 50 个 Epoch 降低一次学习率，获取模型输出结果。存储当前 Epoch 的 train/valid 的准确率和损失值，并存储当前 Epoch 模型。训练结束对比验证集和测试集的训练效果，手动调整相对应的超参数。

4.4.2 评价指标

本文通过 4 个评价指标来衡量猪只咳嗽声模型的优劣，通过混淆矩阵(Confusion Matrix)形式清楚表示分类识别结果的咳嗽声正确识别个数、咳嗽声误识别个数、其它声正确识别个数与误识别个数，进而计算各种声音识别的准确率(Accuarcy)、查准率(Precision)、召回率(Recall)和 F1 值，利用测试集的评价指标来判别模型的优劣。如表 4-2 所示的混淆矩阵进行理解。

表 4-2 混淆矩阵

Tab.4-2 Confusion Matrix

混淆矩阵(Confusion Matrix)		预测(Prediction)	
		阳性(Positive)	阴性(Negative)
实际值(Actual)	正确预测(True)	真阳性(T_p)	假阴性(F_n)
	错误预测(False)	假阳性(F_p)	真阴性(T_n)

准确率定义为正确分类的样本占总样本的比例，即识别为咳嗽声的样本中实际是

中国知网 https://www.cnki.net

咳嗽声占所有样本的比例，准确率 A 公式如 4-18 所示，式中 T_p 表示(真阳性)正例预测为正例的样本数，F_n 表示(假阴性)正例预测为反例的样本数，F_p 表示(假阳性)反例预测为正例的样本数，T_n 表示(真阴性)反例预测为反例的样本数：

$$A=\frac{T_p+T_n}{T_p+F_n+F_p+T_n} \tag{4-18}$$

查准率也叫精确率，定义为所有预测为正例的样本，即识别为咳嗽声的样本中实际是咳嗽声的样本数所占的比例，精确率 P 公式如式 4-19 所示：

$$P=\frac{T_p}{T_p+F_p} \tag{4-19}$$

召回率定义为实际正例的样本，即咳嗽声中被预测为咳嗽声的样本数所占的比例，召回率 R 公式如式 4-20 所示：

$$R=\frac{T_p}{T_p+F_n} \tag{4-20}$$

F1 值定义为查准率与查全率的调和平均，F1 值 F 公式如式 4-21 所示：

$$F=\frac{2\times P\times R}{P+R} \tag{4-21}$$

评估猪只咳嗽声分类识别任务的模型性能时主要注重整体检测的精度，探究模型优劣时需要先统计上述提到的 T_p、F_n、F_p 和 T_n 值，以此计算准确率、精确率、召回率和 F1 值，统计完所有识别结果信息后，即可画出准确率和损失变化曲线。

4.4.3 实验结果分析

4.4.3.1 不同迭代次数对模型效果影响分析

影响一个深度学习模型好坏的因素通常包括学习率、迭代次数、初始化参数等，数据集数量、迭代次数、模型深度对模型效果的影响尚未发现普遍规律。本实验对比分析了不同迭代次数对模型识别效果的影响。

实验设置从 100 轮开始每次增加 50 轮直至 250 轮，MFCC-CNNs 模型测试集准确率在 100~200 轮不断上升，在迭代次数为 200 时咳嗽声精确率达到 97%，其它声音精确率为 93%，召回率咳嗽声为 96%，其它声音为 93%，F1 值咳嗽声为 98%，其它声音为 93%，综合平均准确率为 96.71%。如下图 4-9 为迭代次数为 200 时 MFCC-CNNs 模型测试集混淆矩阵结果。随着迭代次数的继续增加，模型准确率并不会继续提高，识别准确率稳定在 91%以上。logFBank-CNNs 模型性能较稳定，测试集的准确率基本稳定在 94%左右。MFCC-DFSMN 模型最高准确率在 200 轮时为 88.35%，总体识别率较低，模型总体性能较差。logFBank-DFSMN 模型咳嗽声识别准确率稳定在 90%以上，最高达到 95.89%。

中国知网 https://www.cnki.net

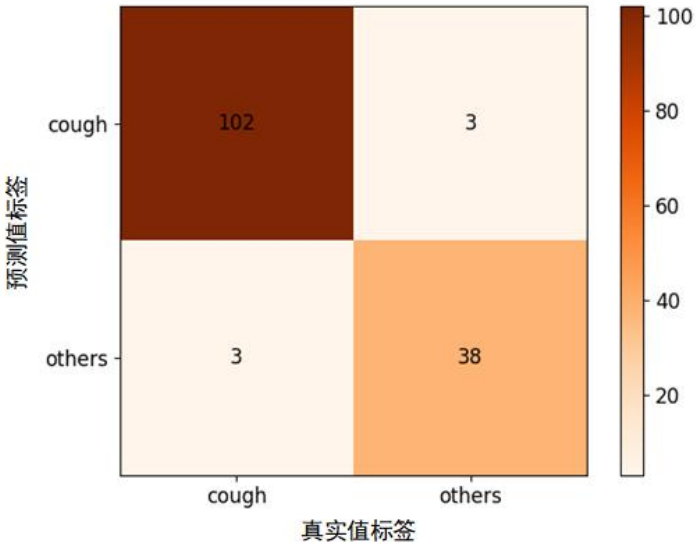


图 4-9 二分类 MFCC-CNNs 模型混淆矩阵

Fig.4-9 The confusion matrix of binary classification model of MFCC-CNNs

下表 4-3 为不同迭代次数对不同模型在验证集和测试集上咳嗽声和其它声音的识别效果对比，表中 P_1、P_2、R_1、R_2、F_1、F_2、A 分别表示咳嗽声和其它声音的精确率、召回率、F1 值以及综合平均准确率。综上分析在训练轮数为 200 时，MFCC-CNNs 模型对咳嗽声的识别效果最好。不同特征与神经网络的组合随训练次数不同，识别准确率存在上下波动情况，波动幅度不超过 4%，总体稳定性较好。

表 4-3 不同迭代次数识别效果

Tab.4-3 The experiment results of different iteration times

模型	迭代次数	数据集	P_1 / P_2	R_1 / R_2	F_1 / F_2	A
MFCC-CNNs	100	验证集	91/86	95/76	93/81	89.72
		测试集	91/87	96/88	93/85	91.78
	150	验证集	94/78	90/85	92/81	89.04
		测试集	94/78	90/87	92/85	95.89
	200	验证集	97/93	97/92	97/93	96.49
		测试集	97/93	96/93	98/93	96.71
	250	验证集	93/89	96/80	94/85	91.78
		测试集	93/89	96/82	94/86	90.41
logFBank-CNNs	100	验证集	94/92	97/83	95/87	93.15
		测试集	94/92	97/83	95/87	94.52
	150	验证集	93/87	95/80	94/84	91.09
		测试集	93/87	95/80	94/84	94.52
	200	验证集	92/86	95/78	93/82	90.41
		测试集	92/86	95/78	93/82	91.78
	250	验证集	92/86	95/78	93/82	95.89
		测试集	92/86	95/78	93/82	95.89
MFCC-DFSMN	100	验证集	88/87	96/66	92/75	87.67
		测试集	88/87	96/66	92/75	90.41
	150	验证集	93/100	99/80	96/89	94.52

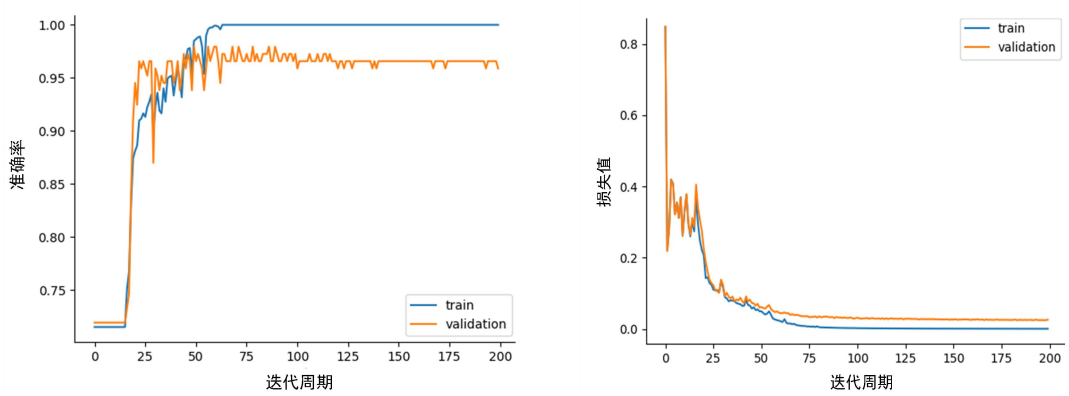
中国知网 https://www.cnki.net

续表 4-3 不同迭代次数识别效果

Tab.4-3 The experiment results of different iteration times

模型	迭代次数	数据集	P_1 / P_2	R_1 / R_2	F_1 / F_2	A
MFCC-DFSMN	150	测试集	93/100	99/80	96/89	86.98
	200	验证集	91/82	95/76	92/78	88.35
		测试集	91/82	95/76	92/78	92.46
	250	验证集	88/90	97/66	92/76	88.35
		测试集	88/90	97/66	92/76	83.56
logFBank-DFSMN	100	验证集	94/92	97/85	96/89	93.83
		测试集	94/92	97/85	96/89	91.09
	150	验证集	92/82	93/78	92/80	89.04
		测试集	92/82	93/78	92/80	95.89
	200	验证集	88/80	93/68	91/74	86.30
		测试集	88/80	93/68	91/74	91.78
	250	验证集	95/90	96/88	96/89	93.83
		测试集	95/90	96/88	96/89	90.41

如下图 4-10 所示为 MFCC-CNNs 模型训练集和验证集在迭代次数为 200 时的准确率和损失值变化曲线。训练集准确率达到 100%，验证集准确率和损失值在迭代次数为 75 时趋于平稳，波动较小，验证集精确率在 97%，损失值为 0.026。



（a）训练集和验证集准确率变化曲线　　（b）训练损失曲线

图 4-10 MFCC-CNNs 训练过程

Fig.4-10 The MFCC-CNNs training process

4.4.3.2 不同特征提取算法对模型效果影响分析

下表 4-4 和表 4-5 分别表示 2 种神经网络模型训练次数为 200 时不同特征输入下咳嗽声和其它声的精确率、召回率、F1 值和准确率的比较。模型在 2 种特征输入下，测试集和验证集的结果基本相同。

表 4-4 MFCC 特征识别效果

Tab.4-4 The recognition effect of MFCC

模型	数据集	P_1 / P_2	R_1 / R_2	F_1 / F_2	A
CNNs	验证集	97/93	97/92	97/93	96.49
	测试集	97/93	96/93	98/93	96.71
DFSMN	验证集	95/100	99/85	97/92	95.89
	测试集	95/99	99/86	97/93	88.35

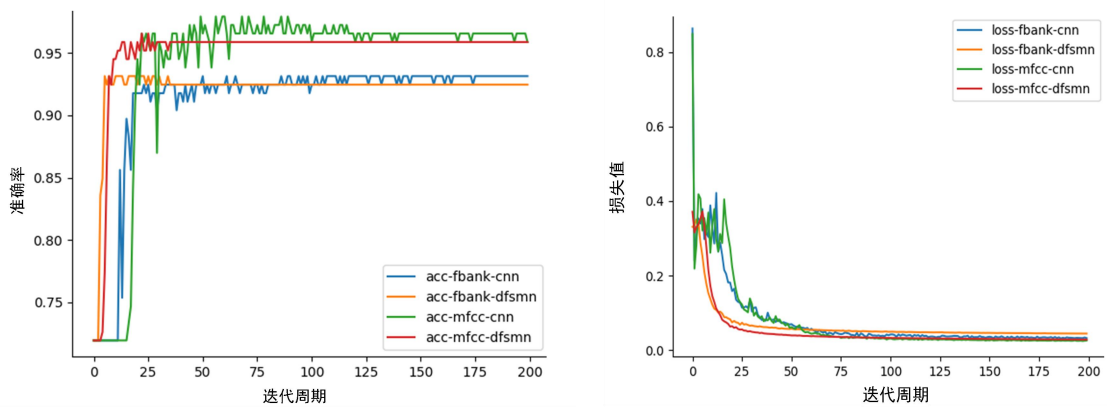
中国知网 https://www.cnki.net

表 4-5 logFBank 特征识别效果

Tab.4-5 The recognition effect of logFBank

模型	数据集	P_1 / P_2	R_1 / R_2	F_1 / F_2	A
CNNs	验证集	95/88	95/88	95/88	93.15
	测试集	95/89	95/90	95/89	94.52
DFSMN	验证集	93/92	97/80	95/86	92.47
	测试集	93/92	97/81	95/87	95.89

通过下图 4-11a 所示 4 种模型的准确率对比曲线可以明显发现以 MFCC 为特征的 2 种模型准确率均高于以 logFBank 为特征的模型，且 MFCC-CNNs 的准确率最高。通过准确率和损失值变化曲线可以看出，CNNs 模型在迭代周期为 25 时，准确率还处于上升阶段，此时损失值曲线处于不断下降状态，波动较小，而后逐渐平稳，模型收敛。DFSMN 模型准确率与损失值趋于平稳状态要早于 CNNs 模型，4 种模型验证集训练损失分别为 0.032、0.044、0.025、0.028。



（a）准确率变化曲线　　（b）损失值变化曲线

图 4-11 四种模型验证集准确率和损失值变化曲线

Fig.4-11 The accuracy and loss curve of four models

4.5 模型四分类实验结果与对比分析

猪只的咳嗽声和喷嚏声由人耳试听存在一定相似度，为了更加准确地对猪只的不同声音进行区分，在二分类的基础上将标签数量增加至 4，实验设置迭代次数从 100 开始按 50 次为间隔直至各项评价指标稳定，各种模型共训练 8 次，最终迭代次数达到 500。

4.5.1 CNNs 模型性能分析

如下表 4-6 所示为 CNNs 模型在两种特征参数下 8 次实验四种声音在验证集和测试集上的评价指标结果。表中 P_1、P_2、P_3、P_4、R_1、R_2、R_3、R_4、F_1、F_2、F_3、F_4、A 分别表示咳嗽声、呼噜声、鸣叫声和喷嚏声的精确率、召回率、F1 值以及综合平均

中国知网 https://www.cnki.net

准确率。

表 4-6 CNNs 模型识别效果

Tab.4-6 The recognition effect of CNNs model

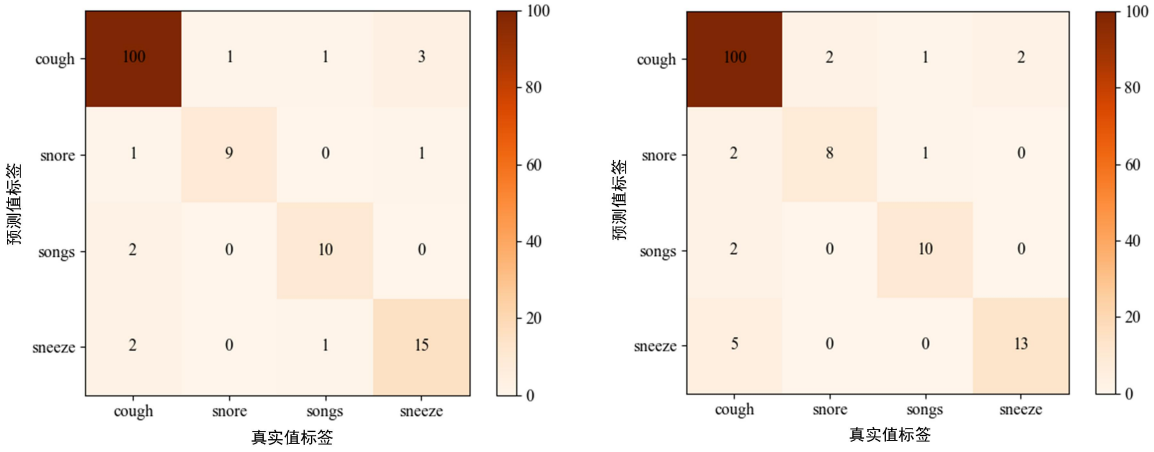
模型	迭代次数	数据集	P_1 / P_2 / P_3 / P_4	R_1 / R_2 / R_3 / R_4	F_1 / F_2 / F_3 / F_4	A
MFCC-CNNs	100	验证集	92/64/99/93	95/82/75/72	93/72/86/81	89.72
		测试集	92/64/100/93	95/82/75/72	93/72/86/81	92.47
	150	验证集	95/83/92/88	95/91/92/83	95/87/92/86	93.15
		测试集	95/83/92/88	95/91/92/83	95/87/92/86	91.78
	200	验证集	95/80/99/89	94/82/75/94	95/72/86/92	91.78
		测试集	95/80/99/89	94/82/75/94	95/72/86/92	90.41
	250	验证集	94/83/99/88	96/91/92/78	95/87/96/82	93.15
		测试集	94/83/99/88	96/91/92/78	95/87/96/82	90.41
	300	验证集	95/90/83/79	95/82/83/83	95/86/83/81	91.78
		测试集	95/90/83/79	95/82/83/83	95/86/83/81	93.84
	350	验证集	94/91/85/93	96/91/92/72	95/91/88/81	92.47
		测试集	94/91/85/93	96/91/92/72	95/91/88/81	90.41
	400	验证集	93/81/99/94	95/91/67/83	94/77/80/88	91.10
		测试集	93/81/99/94	95/91/67/83	94/77/80/88	89.73
	450	验证集	88/80/99/92	99/36/83/67	93/50/91/77	89.04
		测试集	88/80/99/92	99/36/83/67	93/50/91/77	87.67
	500	验证集	93/75/83/99	95/82/83/83	94/78/83/91	91.78
		测试集	93/75/83/99	95/82/83/83	94/78/83/91	91.78
logFBank-CNNs	100	验证集	91/88/85/85	97/64/92/61	94/74/88/71	89.71
		测试集	91/88/85/85	97/64/92/61	97/74/88/71	92.46
	150	验证集	91/55/75/87	93/55/75/72	92/55/75/79	86.30
		测试集	91/55/75/87	93/55/75/72	92/55/75/79	93.84
	200	验证集	90/70/99/87	96/64/75/72	93/67/86/79	89.04
		测试集	90/70/99/87	96/64/75/72	93/67/86/79	95.20
	250	验证集	91/64/90/86	96/64/75/67	94/64/82/75	88.36
		测试集	91/64/90/86	96/64/75/67	94/64/82/75	93.15
	300	验证集	92/80/83/87	95/73/83/72	93/76/83/79	89.73
		测试集	92/80/83/87	95/73/83/72	93/76/83/79	95.20
	350	验证集	91/54/77/86	91/64/83/67	91/58/80/75	85.62
		测试集	91/54/77/86	91/64/83/67	91/58/80/75	93.84
	400	验证集	93/58/77/87	94/64/83/72	94/61/80/79	88.36
		测试集	93/58/77/87	94/64/83/72	94/61/80/79	92.47
	450	验证集	92/69/90/76	93/82/75/72	93/75/82/74	88.36
		测试集	92/69/90/76	93/82/75/72	93/75/82/74	93.84
	500	验证集	91/58/90/87	94/64/75/72	93/61/82/79	87.67
		测试集	91/58/90/87	94/64/75/72	93/61/82/79	93.15

分析表 4-6 可知 CNNs 模型的整体识别准确率在迭代次数为 300 时最优，以下内容重点分析迭代次数为 300 时 CNNs 模型性能。

如下图 4-12 为迭代次数为 300 时两种特征下 CNNs 模型测试集混淆矩阵，表 4-7 所示为训练 300 轮后 MFCC-CNNs 模型测试集上的评价指标结果。由测试集结果可知，模型最终在测试集上综合平均准确度为 93.84%，咳嗽声识别率达到 95%，喷嚏声识别准确率为 90%，鸣叫声为 83%，呼噜声相对较低，只有 79%。相较咳嗽，其它 3 种声音召回率和 F1 值都比较低，考虑原因是样本数量不均衡或者样本数量较少导致，后续研究将继续扩充样本数量。下图 4-13 所示为 MFCC-CNNs 模型训练过程，验证

中国知网 https://www.cnki.net

集准确率和损失值在训练轮数接近 150 轮时趋于收敛平稳状态，4-13a 显示验证集准确率尚未达到训练集水平，4-13b 中损失值均随着网络迭代逐步下降，最终趋于稳定，损失分别为 0.044、0.063。



（a）MFCC-CNNs 混淆矩阵　　（b）logFBank-CNNs 混淆矩阵

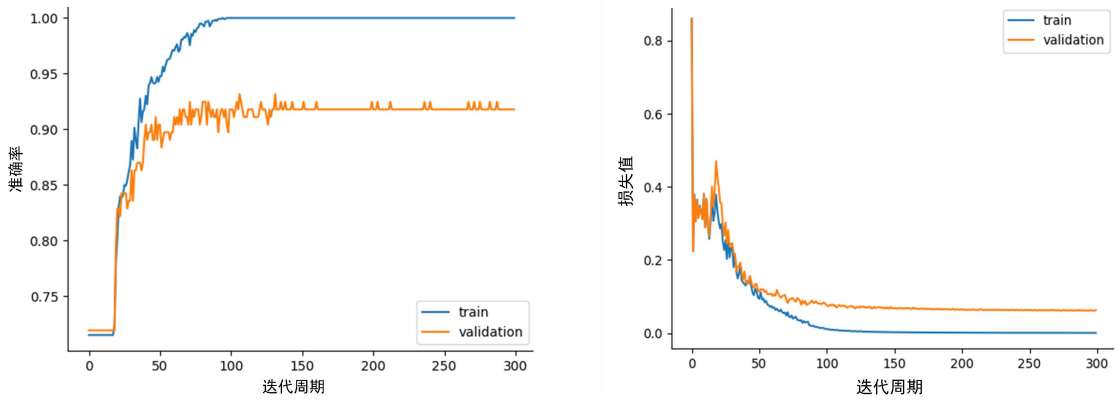
图 4-12 四分类 CNNs 模型混淆矩阵

Fig.4-12 The confusion matrix of quad-classification model of CNNs

表 4-7 MFCC-CNNs 分类效果对比

Tab.4-7 The comparison of classification effect of MFCC-CNNs

模型	迭代次数	数据集	P	R	F	A
MFCC-CNNs	300	咳嗽声	0.95	0.95	0.95	93.84
		喷嚏声	0.90	0.82	0.86	
		鸣叫声	0.83	0.83	0.83	
		呼噜声	0.79	0.83	0.81	



（a）训练集和验证集准确率变化曲线　　（b）损失值变化曲线

图 4-13 MFCC-CNNs 训练过程

Fig.4-13 The MFCC-CNNs training process

如下表 4-8 所示为迭代次数为 300 轮时 logFBank-CNNs 模型测试集上的评价指标结果。由测试集结果可知，模型综合平均准确度为 95.20%，较 MFCC-CNNs 模型提

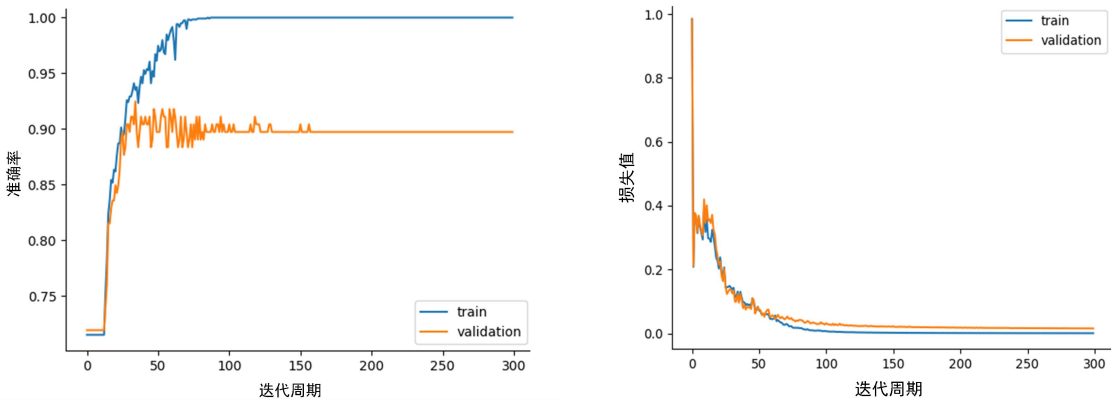
中国知网 https://www.cnki.net

高两个百分点。咳嗽声识别率为 92%，较 MFCC-CNNs 模型精度下降了 3%，喷嚏声识别准确率为 80%，较 MFCC-CNNs 模型精度下降 10%，鸣叫声为 83%，精度保持不变，呼噜声精度提高 8%。相较咳嗽和呼噜声，其它 2 种声音召回率和 F1 值都比较低。如下图 4-14 所示为 logFBank-CNNs 模型训练过程，4-14a 显示验证集整体准确率较 MFCC-CNNs 波动较小，图像较平稳，4-14b 中损失值随网络迭代次数增加逐步下降，最终验证集稳定 0.015，相较 MFCC-CNNs 损失低。综上，不同特征训练的 CNNs 模型对于咳嗽声的识别结果都优于其它声音，其它声音准确率波动较大。

表 4-8 logFBank-CNNs 分类效果对比

Tab.4-8 The comparison of classification effect of logFBank-CNNs

模型	迭代次数	数据集	P	R	F	A
logFBank-CNNs	300	咳嗽声	0.92	0.95	0.93	95.20
		喷嚏声	0.80	0.73	0.76	
		鸣叫声	0.83	0.83	0.83	
		呼噜声	0.87	0.72	0.79	



（a）训练集和验证集准确率变化曲线　　（b）损失值变化曲线

图 4-14 logFBank-CNNs 训练过程

Fig.4-14 The logFBank-CNNs training process

4.5.2 DFSMN 模型性能分析

如下表 4-9 所示为 DFSMN 模型在两种特征参数下 8 次实验四种声音信号在验证集和测试集上的评价指标结果。相较 CNNs 模型，DFSMN 模型在两种特征参数下的最佳迭代次数不同，分别出现在 100 次和 250 次。

表 4-9 DFSMN 模型识别效果

Tab.4-9 The recognition effect of DFSMN

模型	迭代次数	数据集	P_1 / P_2 / P_3 / P_4	R_1 / R_2 / R_3 / R_4	F_1 / F_2 / F_3 / F_4	A
MFCC-DFSMN	100	验证集	90/89/89/87	97/73/67/72	94/80/76/79	89.73
		测试集	90/89/89/87	97/73/67/72	94/80/76/79	90.41
	150	验证集	88/71/90/83	98/45/75/56	93/56/82/67	86.99
		测试集	88/71/90/83	98/45/75/56	93/56/82/67	86.30
	200	验证集	87/71/99/77	96/45/83/56	91/56/91/65	86.30
		测试集	87/71/99/77	96/45/83/56	91/56/91/65	86.99

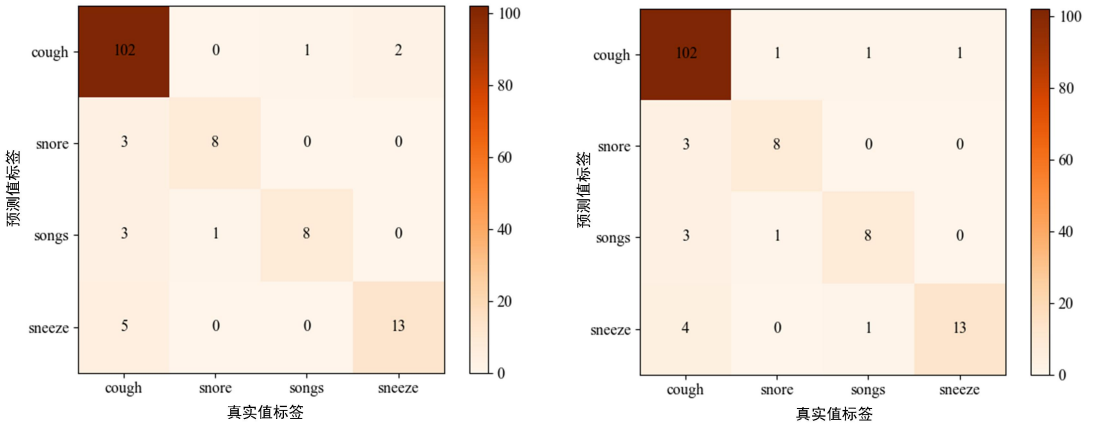
中国知网 https://www.cnki.net

续表 4-9 DFSMN 模型识别效果

Tab.4-9 The recognition effect of DFSMN

模型	迭代次数	数据集	P_1 / P_2 / P_3 / P_4	R_1 / R_2 / R_3 / R_4	F_1 / F_2 / F_3 / F_4	A
MFCC-DFSMN	250	验证集	89/83/82/87	97/45/75/72	93/59/78/79	88.36
		测试集	89/83/82/87	97/45/75/72	93/59/78/79	89.73
	300	验证集	88/83/90/99	98/45/75/72	93/59/82/84	89.04
		测试集	88/83/90/99	98/45/75/72	93/59/82/84	89.73
	350	验证集	88/78/99/91	99/64/67/56	93/70/80/69	88.36
		测试集	88/78/99/91	99/64/67/56	93/70/80/69	87.00
	400	验证集	91/88/99/93	99/64/75/78	95/74/86/85	91.78
		测试集	91/88/99/93	99/64/75/78	95/74/86/85	87.67
	450	验证集	89/82/89/96	97/46/78/73	94/60/77/78	89.70
		测试集	89/82/89/96	97/46/78/73	94/60/77/78	89.69
	500	验证集	89/99/99/85	99/45/83/61	94/62/91/71	89.73
		测试集	89/99/99/85	99/45/83/61	99/45/83/61	87.67
logFBank-DFSMN	100	验证集	90/99/83/92	98/64/83/67	94/78/83/77	90.41
		测试集	90/99/83/92	98/64/83/67	94/78/83/77	92.47
	150	验证集	90/88/69/92	96/64/75/67	93/74/92/77	88.36
		测试集	90/88/69/92	96/64/75/67	93/74/92/77	92.47
	200	验证集	89/78/73/93	95/64/67/72	92/70/70/81	87.67
		测试集	89/78/73/93	95/64/67/72	92/70/70/81	95.21
	250	验证集	91/80/80/93	97/73/67/72	94/76/73/81	89.73
		测试集	91/80/80/93	97/73/67/72	94/76/73/81	95.90
	300	验证集	89/78/78/93	96/64/58/72	92/70/67/81	87.67
		测试集	89/78/78/93	96/64/58/72	92/70/67/81	94.52
	350	验证集	89/99/73/93	97/64/67/72	93/78/70/81	89.04
		测试集	89/99/73/93	97/64/67/72	93/78/70/81	92.47
	400	验证集	90/89/82/93	96/73/75/72	93/80/78/81	89.73
		测试集	90/89/82/93	96/73/75/72	93/80/78/81	93.15
	450	验证集	92/64/91/93	96/64/83/72	94/64/87/81	89.73
		测试集	92/64/91/93	96/64/83/72	94/64/87/81	94.52
	500	验证集	90/89/70/99	98/73/58/67	94/80/64/80	89.04
		测试集	90/89/70/99	98/73/58/67	94/80/64/80	94.52

以下重点分析迭代次数为 100 轮时 MFCC-DFSMN 模型性能以及迭代次数为 250 轮时 logFBank-DFSMN 模型性能，如下图 4-15 为迭代次数为 100 和 250 时两种特征下 DFSMN 模型测试集混淆矩阵。



（a）MFCC-DFSMN 混淆矩阵　　（b）logFBank-DFSMN 混淆矩阵

图 4-15 四分类 DFSMN 模型混淆矩阵

Fig.4-15 The confusion matrix of quad-classification model of DFSMN

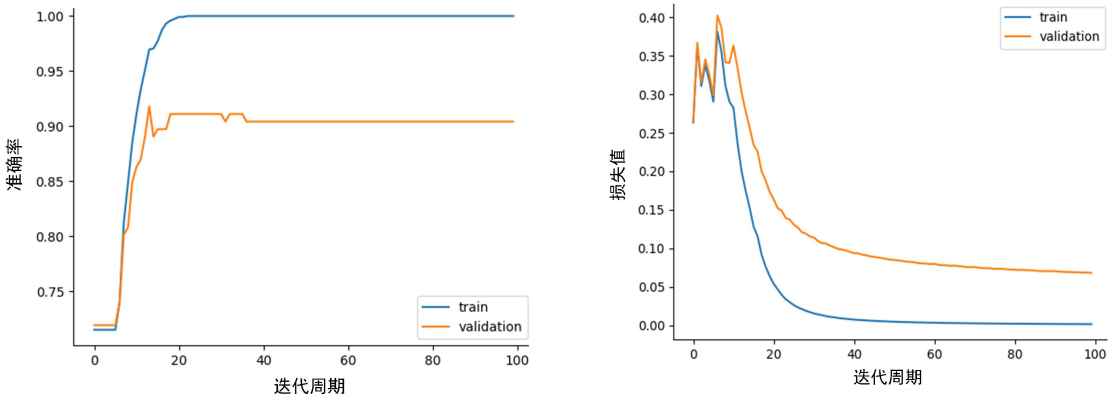
中国知网 https://www.cnki.net

如下表 4-10 所示为迭代次数为 100 轮时 MFCC-DFSMN 模型测试集上的评价指标结果。由测试集结果可知，综合平均准确度为 90.41%，相较 logFBank-DFSMN 模型总体识别精度下降 2%，在 4 种模型中综合平均准确度最低。其中咳嗽声识别率为 90%，喷嚏声识别准确率为 87%，呼噜声为 89%，相较 FBank-DFSMN 准确率下降，鸣叫声为 89%，精度提高 6%。相较咳嗽，其它 3 种声音召回率和 F1 值都比较低，其中鸣叫声的召回率下降 16%。如下图 4-16 所示为 MFCC-DFSMN 模型训练过程，4-16a 显示验证集整体准确率在迭代次数为 20 轮时基本稳定在 90%左右，迭代次数达到 40 轮时，准确率曲线平稳，4-16b 中损失值随网络迭代次数增加逐步下降，迭代次数为 40 时模型收敛，损失值最终稳定在 0.001、0.067。

表 4-10 MFCC-DFSMN 分类效果对比

Tab.4-10 The comparison of classification effect of MFCC-DFSMN

模型	迭代次数	数据集	P	R	F	A
MFCC-DFSMN	100	咳嗽声	0.90	0.97	0.94	90.41
		喷嚏声	0.87	0.72	0.79	
		鸣叫声	0.89	0.67	0.76	
		呼噜声	0.89	0.73	0.80	



（a）训练集和验证集准确率变化曲线　　（b）损失值变化曲线

图 4-16 MFCC-DFSMN 训练过程

Fig.4-16 The MFCC-DFSMN training process

如下表 4-11 所示为模型训练迭代次数为 250 时 logFBank-DFSMN 模型在测试集上的评价指标结果。由测试集结果可知，猪只各类声音识别的综合平均精确度为 95.89%，咳嗽声识别准确率为 91%，喷嚏声识别准确率为 80%，鸣叫声识别准确率为 80%，呼噜声识别准确率接近 83%。相较咳嗽声识别结果，其它 3 种声音的召回率和 F1 值都比较低。如下图 4-17 所示为 logFBank-DFSMN 模型训练过程，4-17a 显示验证集综合平均准确率在迭代次数达到 200 之后，基本稳定在 90%左右，4-17b 中损失值曲线在训练轮数为 200 时开始收敛，随着模型训练迭代次数的增加逐步下降，最终

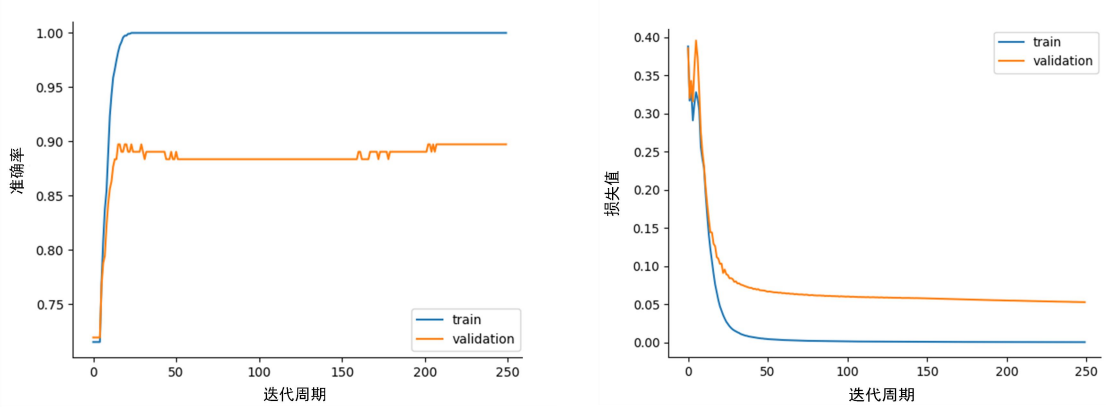
中国知网 https://www.cnki.net

损失值稳定在 0.001、0.053。

表 4-11 logFBank-DFSMN 分类效果对比

Tab.4-11 The comparison of classification effect of logFBank-DFSMN

模型	迭代次数	数据集	P	R	F	A
logFBank-DFSMN	250	咳嗽声	0.91	0.97	0.94	95.89
		喷嚏声	0.80	0.73	0.76	
		鸣叫声	0.80	0.67	0.73	
		呼噜声	0.83	0.72	0.81	



（a）训练集和验证集准确率变化曲线　　（b）损失值变化曲线

图 4-17 logFBank-DFSMN 训练过程

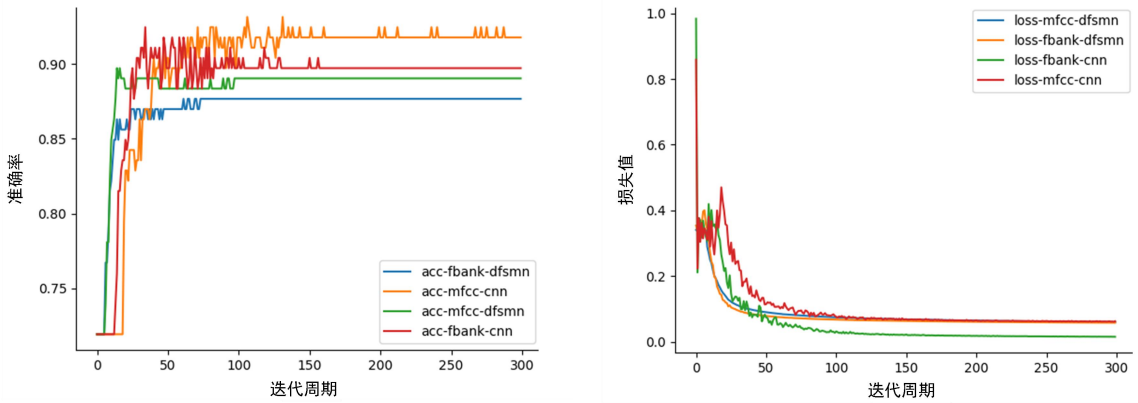
Fig.4-17 The logFBank-DFSMN training process

4.5.3 实验结果分析

由第四章以上小节的分析可以得出迭代次数为 300 时，CNNs 模型的综合平均准确率受特征算法影响不大，稳定在 93%以上，不同猪只声音的识别准确率受不同特征算法影响较大，相较于二分类模型，四分类模型中的 logFBank-CNNs 模型综合平均准确率优于 MFCC-CNNs 模型。与 CNNs 模型相比，DFSMN 模型的综合平均准确率随迭代次数的增加变化幅度相对较小，以 logFBank 为特征的 DFSMN 模型性能同样优于以 MFCC 为特征的模型。

如下图 4-18 所示为迭代次数为 300 时 4 种四分类模型验证集的准确率和损失值变化曲线，DFSMN 模型训练集和验证集的准确率变化以及损失值曲线波动较小，收敛较快；CNNs 模型收敛较慢，但随着迭代次数的增加，CNNs 模型的综合平均准确率高于 DFSMN 模型。训练过程中，比较下图 4-18b 中各个模型的损失值曲线可以发现，相较二分类模型训练的收敛速度，四分类模型训练速度明显较快，但由 4-18a 可知四分类模型的准确率相对较低，考虑此现象为样本数量不均衡所致，后续研究中将继续扩充样本数量。

中国知网 https://www.cnki.net



（a）准确率变化曲线　　（b）损失值变化曲线

图 4-18 四种模型验证集准确率和损失值变化曲线

Fig.4-18 The accuracy and loss curve of four models

4.6 本章小结

本章进行深度神经网络算法模型搭建，结合第三章提取的猪只声音信号特征参数，设计猪只咳嗽声识别模型，同时对模型的识别性能进行评估，具体如下：

（1）简要介绍了神经网络模型到深度神经网络的变化发展，组成部分以及猪只咳嗽声识别模型整体框架。

（2）利用第三章提取到的 logFBank 和 MFCC 特征作为输入信号，与 CNNs 和 DFSMN 算法结合进行猪只咳嗽声识别模型二分类训练，设置不同迭代次数以及不同特征提取算法的分析对比试验，以准确率值(Accuarcy)、查准率值(Precision)、召回率值(Recall)和 F1 值为模型评价指标。实验结果显示在迭代次数为 200 时，以 MFCC 为特征的 CNNs 咳嗽声识别模型准确率最高，咳嗽声识别精确率为 97%，召回率为 96%，F1 值为 98%，综合平均准确率为 96.71%。

（3）进行猪只的 4 种声音信号分类训练，有助于扩展系统应用性能。结果显示四分类模型准确率相对较低，考虑原因是由于样本数量较少或样本数量不均衡导致，后续研究中将继续采集猪只咳嗽声等音频数据，扩充样本数量。

（4）本文实验结果表明神经网络模型可以在较高准确率且稳定的情况下区别猪只咳嗽声及其它异常声音，不仅可以为咳嗽声识别与疾病预警提供技术支持，还可以为生猪养殖中其它情况，例如仔猪被压发出鸣叫等异常声音识别提供借鉴参考，对生猪福利养殖具有重要意义。

中国知网 https://www.cnki.net

第五章 猪只咳嗽声识别预警系统软件平台设计与实现

如何将人工智能技术应用于畜禽养殖业的实际生产环境中一直是畜牧业关注的痛点问题。本章节将基于上文研究的深度神经网络模型搭建 SpringBoot + Vue + Nginx 猪只咳嗽声识别预警系统软件平台，该系统软件同时包含 MySQL 数据库设计、数据挖掘中间件，旨在实现猪舍内环境信息监测及猪只信息展示以及猪只咳嗽声监测预警，达到提升猪只福利水平以及降低人工工作强度的目的。

5.1 猪只咳嗽声识别预警系统软件平台设计

猪只咳嗽声识别预警系统软件平台包括猪舍环境信息监测以及对猪只咳嗽声识别结果可视化展示与预警信息提示等功能，以达到监测猪只生长环境以及猪只健康状况的目的。如图 5-1 为系统平台整体架构，可分为数据采集、预处理及可视化三部分。

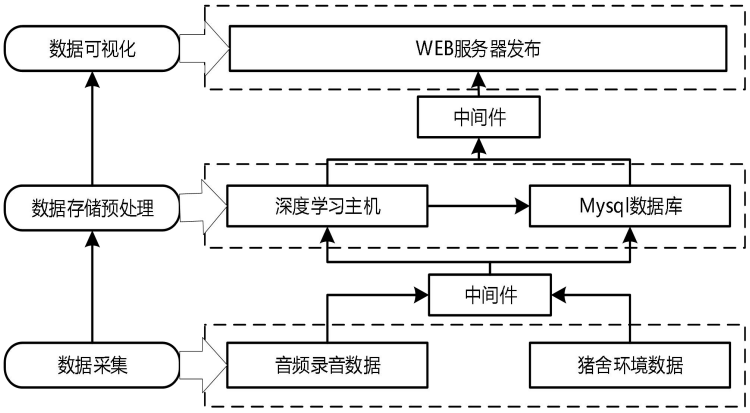


图 5-1 系统平台架构

Fig.5-1 The system platform architecture

5.1.1 系统软件平台开发环境配置

该系统软件平台前端界面使用渐进式框架 Vue.js 开发；系统平台后端使用 Java 语言统一开发，利用已有框架 SpringBoot 整合 Nginx；使用关系型数据库(MySQL)，同时使用 Navicat 进行远程数据库管理操作；平台服务器为阿里云服务器；开发工具统一使用 IntelliJ IDEA。各个工具软件版本如表 5-1 所示：

表 5-1 各工具软件版本

Tab.5-1 The version of each tool and software

软件类型	版本
JDK	1.8.0_131
MySQL	MySQL Server 5.7
SpringBoot	2.3.7.RELEASE
Nginx	1.16.1
Vue.js	2.6.11

中国知网 https://www.cnki.net

5.1.2 系统软件平台开发流程

系统软件平台的开发流程主要包括需求分析与功能模块设计、数据库设计、后端与中间件编码实现、前端界面搭建、网站部署与综合测试五部分，如图 5-2 所示，具体流程为：

（1）需求分析与功能模块设计：分析整个系统软件平台功能需求，依据需求划分具体子模块，搭建平台开发的环境。

（2）数据库设计：依据具体划分的子模块分析统计所需数据类型及数量规模以及数据间的关联性，建立数据库并设计表与表，字段之间的关系。

（3）后端与中间件编码实现：中间软件主要以实现系统功能为主，包括但不限于分析处理模型结果数据，进行系统页面与数据库交互等功能。

（4）前端界面搭建：前端主要实现界面完整性与流畅性设计，与后端开放接口交互。

（5）网站部署与综合测试：为使整个系统平台服务于生产实际，项目部署于远程服务器，享受公网的便利性，同时有利于联网状态下的整体性能测试联调。

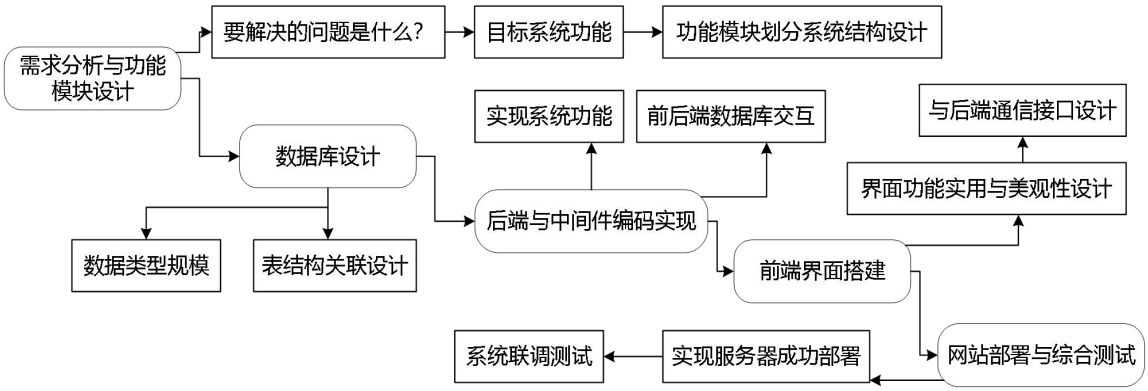


图 5-2 系统软件平台开发流程

Fig.5-2 The development process of system software platform

5.1.3 系统软件平台功能模块设计

网页版主要实现猪只个体信息记录与跟新，提供简洁直观的数据展示查询方式，方便管理。主要分为咳嗽声监测预警模块、猪只信息管理模块、管理员信息管理模块三部分，管理员信息管理模块部分展示了管理员的各种信息，并且提供密码修改及权限管理等功能，方便管理人员进行权限分配；咳嗽声监测预警模块主要展示咳嗽猪只所在栋舍以及此栋舍内咳嗽声的总次数、相关预警消息发送与否信息、检测结果存储的具体时间以及提供各个栋舍内猪只咳嗽声历史信息的查询等；猪只信息管理模块主要展示猪只个体信息、猪只所在栋舍信息、栋舍的管理人员信息等；系统其他功能包

中国知网 https://www.cnki.net

含不同权限人员登录、当前环境信息查询等，如图 5-3 所示为猪只咳嗽声识别预警系统功能模块图。

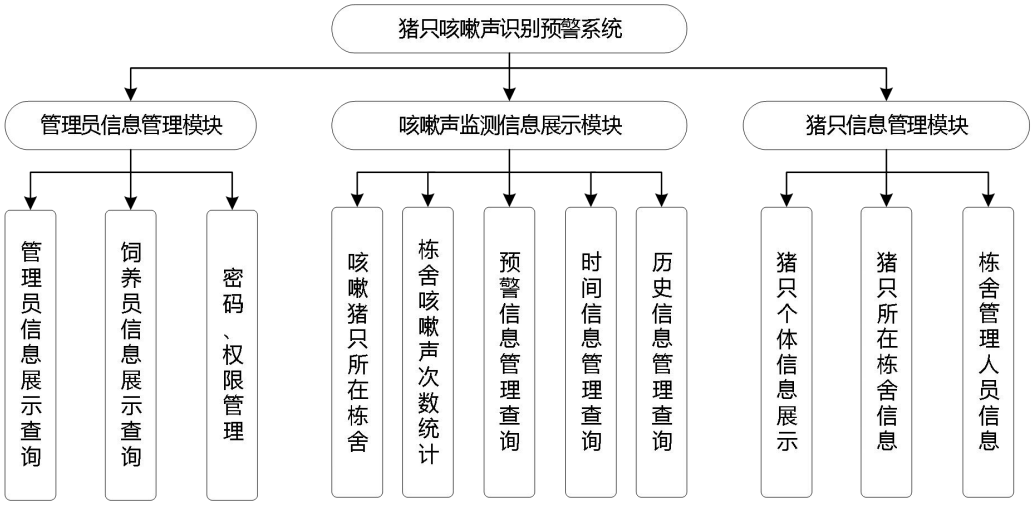


图 5-3 猪只咳嗽声识别预警系统功能模块架构图

Fig.5-3 The functional module architecture of pig cough recognition and warning system

5.2 数据库设计

根据猪场实际情况，在系统分析软件平台功能需求的基础上，前期设计数据库结构尤为重要，精简的数据库表设计能大大提高编码人员的效率与系统的整体性能，后期搭建合适的数据库对猪场环境以及猪只个体及咳嗽声数据进行管理，在满足功能需求的前提下，同时保证数据的完整性、低冗余、查询快速性。猪只咳嗽声识别与预警系统软件平台采用 MySQL 数据库，存储管理人员和用户信息、猪舍环境信息、猪只个体信息及咳嗽声识别结果与预警信息等，根据平台功能模块需求，设计了权限管理表、用户信息表、环境信息表、猪只个体信息表及咳嗽声识别预警信息表，各个数据表功能的详细说明如表 5-2 所示。

表 5-2 数据表功能

Tab.5-2 Data sheet function

名称	说明
权限管理表	存储不同用户及对应的权限
用户信息表	存储用户的基本信息
环境信息表	存储猪舍内部环境数据信息
猪只个体信息表	存储猪只生理生长信息
猪只咳嗽声识别与预警信息表	存储猪只咳嗽声识别与预警消息

各数据表的结构设计如下：

（1）权限管理表：以 autid 字段为主键，关键属性包含：权限编号、权限名称、权限描述，具体信息如表 5-3 所示。

中国知网 https://www.cnki.net

表 5-3 权限信息表

Tab.5-3 Permission information table

字段名	数据类型	数据长度	说明	备注
autid	int	10	权限编号	主键
autname	varchar	50	权限名称	不可设置为空值
autintroduction	varchar	50	权限描述	不可设置为空值

（2）用户信息表：以 id 字段为主键，关键的属性值包括：用户名、密码、邮箱、联系方式、联系地址、用户类型和注册时间等，具体信息如表 5-4 所示。

表 5-4 用户信息表

Tab.5-4 User Information table

字段名	说明	数据类型	数据长度	备注
id	编号	int	10	主键
username	用户名	varchar	20	不可设置为空值
password	密码	varchar	50	不可设置为空值
tel	联系方式	varchar	20	不可设置为空值
Email	邮箱	varchar	20	不可设置为空值
address	联系地址	varchar	20	不可设置为空值
userauth	用户权限	int	20	外键
time	注册时间	timestamp	0	不可设置为空值

（3）环境信息表：在该表中以编号 id 字段为主键，关键属性包含：环境采集节点编号、猪舍温湿度、光照等信息，具体信息如表 5-5 所示。

表 5-5 环境信息表

Tab.5-5 Environmental information table

字段	数据类型	数据长度	说明	备注
id	int	10	编号	主键
Gateway	varchar	20	环境采集节点编号	不可设置为空值
Temp	varchar	20	猪舍温度	不可设置为空值
Humi	varchar	20	猪舍湿度	不可设置为空值
GZ	varchar	20	猪舍光照度	不可设置为空值
CO_2	varchar	20	猪舍 CO_2 浓度	不可设置为空值
NH_3	varchar	20	猪舍 NH_3 浓度	不可设置为空值
H_2S	varchar	20	猪舍 H_2S 浓度	不可设置为空值
time	timestamp	0	环境数据存储时间	不可设置为空值

（4）猪只个体信息表：在该表中以编号 id 字段为主键，关键属性包含：猪舍编号、猪只编号、管理人员编号、猪只体重信息和数据存入时间信息等，具体信息如表 5-6 所示。

中国知网 https://www.cnki.net

表 5-6 猪只个体信息表

Tab.5-6 Individual pig information table

字段	数据类型	数据长度	说明	备注
id	int	10	编号	主键
pigId	varchar	20	猪只编号	不可设置为空值
piggrId	varchar	20	猪舍编号	不可设置为空值
managerId	varchar	20	管理人员编号	不可设置为空值
weight	int	10	猪只体重信息	不可设置为空值
time	timestamp	0	数据存入时间	不可设置为空值

（5）咳嗽声识别与预警信息表：在该表中以猪只编号 id 字段为主键，关键属性包含：猪只编号、咳嗽猪只所在栋舍、猪只咳嗽声次数、检测时间、是否预警、是否处理以及猪舍养殖人员编号等信息，具体信息如表 5-7 所示。

表 5-7 咳嗽声识别与预警信息表

Tab.5-7 Cough recognition and warning information table

字段	数据类型	数据长度	说明	备注
id	int	10	猪只编号	主键
block	int	10	咳嗽猪只所在栋舍	不可设置为空值
count	int	10	猪只咳嗽声次数	不可设置为空值
alert	boolean	10	是否发送预警消息	不可设置为空值
flag	boolean	10	是否已处理	不可设置为空值
adminId	int	10	猪舍养殖人员编号	不可设置为空值
time	timestamp	0	数据录入时间	不可设置为空值

5.3 中间件设计

本项目中所用的中间件主要任务是利用 Socket/TCP/IP/HTTP 网络传输协议完成整个系统内不同数据的传输与处理，建立起软硬件系统之间的连接，实现整个数据的管理。

5.3.1 中间件功能分析

中间件在本系统软件平台中主要功能包括：

（1）监听并读取猪舍环境节点以及网络拾音器采集的数据，并对较长音频实现固定长度分割，便于后续模型处理；

（2）调用猪只咳嗽声识别模型对采集的猪舍内猪只声音信号进行分类识别处理后，对接模型输出的数据；

中国知网 https://www.cnki.net

（3）将采集到的猪舍环境信息数据及猪只咳嗽声识别结果等数据存入 MySQL 数据库中；

（4）分析数据库数据并把环境信息及咳嗽声等相关数据信息反馈至客户端进行可视化展示。

中间件程序的设计框图如图 5-4 所示。

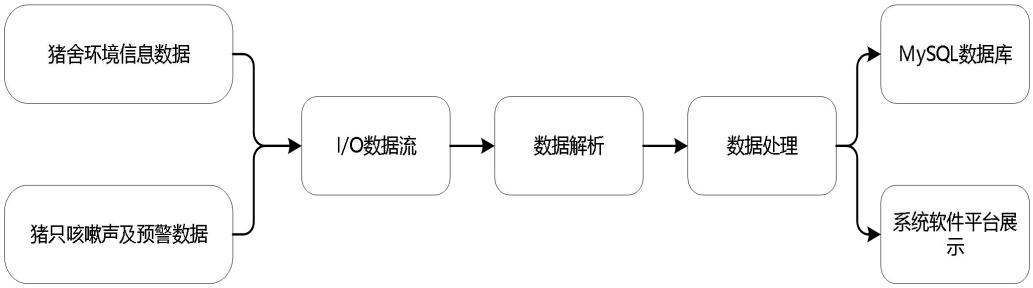


图 5-4 中间件程序设计框图

Fig.5-4 The block diagram of middleware program design

5.3.2 中间件功能实现

利用 Java 编程的线程池中自带的函数，固定线程数的线程池(newFixedThreadPool)开启所需数量的线程，每个线程通过内置类监听保存音频信号的文件夹，当文件夹中有新的音频增加时按固定长度切割音频并保存，利用训练好的咳嗽声识别模型处理切割后的音频数据，将咳嗽声检测结果以固定格式存储至云服务器的 MySQL 数据库中，而后中间件主要实现与数据库、网站后台交互，收发相关数据等信息，以及调用短消息服务接口发送咳嗽声预警消息等功能，如图 5-5 所示为部分预警消息发送代码编程实现。

```
37          conn = DriverManager.getConnection(DB_URL,USER,PASS);
38          // 执行查询
39          stmt = conn.createStatement();
40          ResultSet rs = stmt.executeQuery(sql);
41          // 展开结果集数据库
42          while(rs.next()){
43              // 通过字段检索
44              String smallpig = rs.getString("smallpig");
45              String num = rs.getString("num");
46              String flag = rs.getString("flag");
47              System.out.print("发送标识位"+flag);
48              int id = rs.getInt("id");
49              // 输出数据
50               int i = Integer.valueOf(smallpig);
51               if("True".equals(flag)){
52                  AlertHttpClientUtil httpclientutil = new AlertHttpClientUtil();
53                  try {
54                      String message = num + "号第" + smallpig + "头猪咳嗽";
55                      System.out.println(message);
56                      //以下
57                      String ALERT ="'"+num+"'号猪只咳嗽，请及时处理！";
58                      System.out.println(ALERT);
59                      Main sendAPP = new Main(ALERT);
60                      sendAPP.sendApp();
61                      //以上
62                      httpclientutil.send(message);
63                      System.out.println("发送报警短信成功");
64                      String upSql = "update alert t set t.flag='false' where t.id = "+id+"";
65                      JDBC jdbc = new JDBC();
66                      jdbc.write(upSql);
67                  } catch (Exception e) {
68                      // TODO Auto-generated catch block
69                      e.printStackTrace();
70                  }
```

图 5-5 预警消息发送代码实现

Fig.5-5 The implementation of early warning message sending code

中国知网 https://www.cnki.net

5.4 猪只咳嗽声识别预警系统软件平台实现

5.4.1 WEB 设计与实现

猪只咳嗽声识别与预警系统软件平台包括的主要模块有平台注册登录界面、猪舍环境信息监测展示界面、猪只栋舍咳嗽声监测与预警结果展示界面以及猪只个体信息管理界面等。平台软件登录系统设置较高安全级别，分权限管理，方便不同人员查看猪舍、猪只状况，用户体验感升级。系统软件平台设计了登录注册功能，采用用户名和密码及用户身份登录模式，先注册信息，再验证登录，后台验证信息完善并且访问安全即授予登录权限，保证登录用户有查看权限的同时保证数据更安全，该系统的注册以及登录界面如图 5-6 所示。



（a）用户注册界面



（b）用户登录界面

图 5-6 系统软件平台注册、登录界面图

Fig.5-6 The interface of system software platform registration and login

中国知网 https://www.cnki.net

猪只咳嗽声识别与预警系统包含的主要界面为猪只栋舍咳嗽声监测与展示以及预警消息发送展示界面，如图 5-7 所示，该界面主要方便管理人员查看栋舍内猪只的咳嗽声次数、查看是否已经向相关管理人员发送预警消息以及管理人员是否作出相应处理等信息，同时有专门的栋舍历史月份咳嗽声次数统计信息，方便管理人员有针对性地管理不同栋舍猪只。

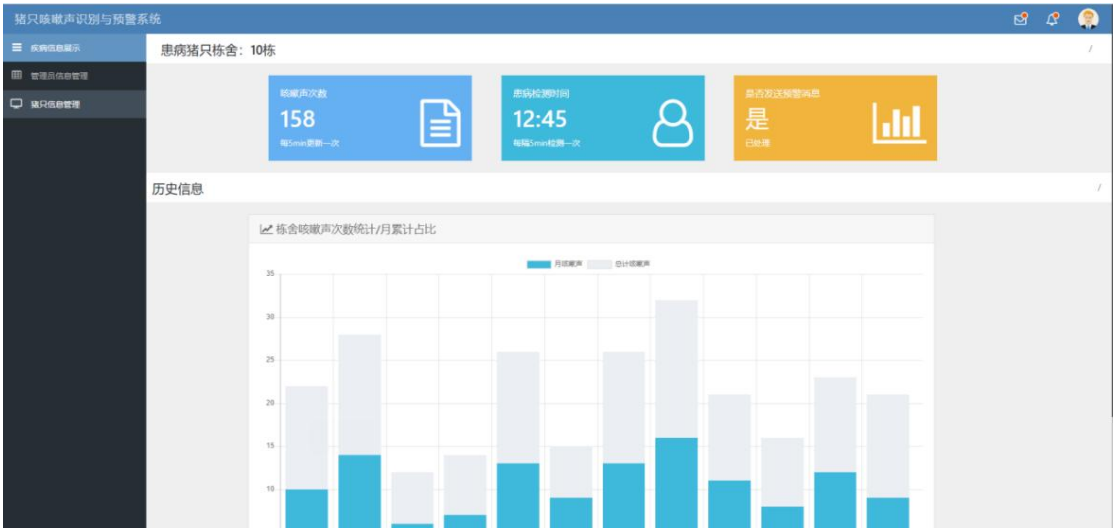
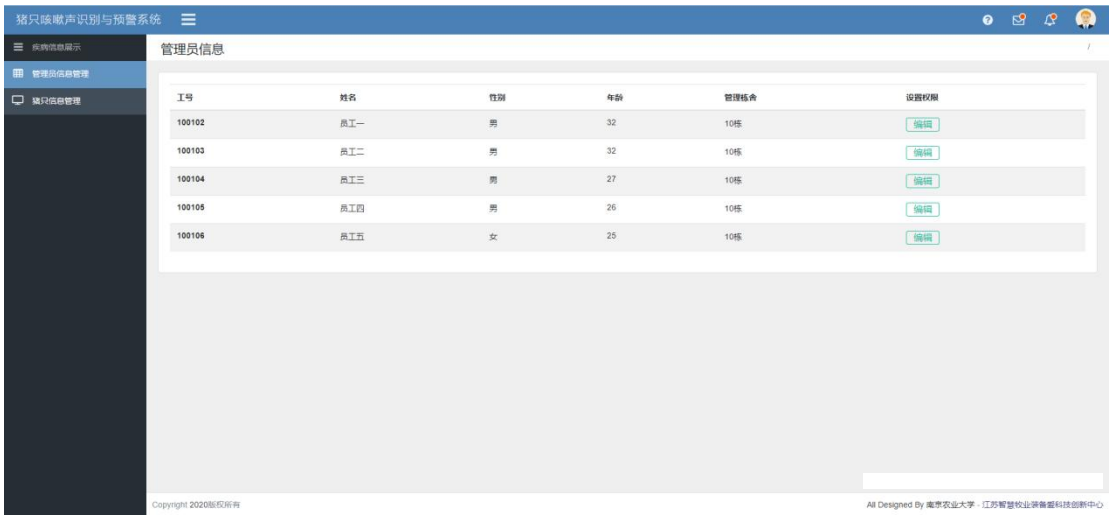


图 5-7 猪只咳嗽声识别预警展示界面图

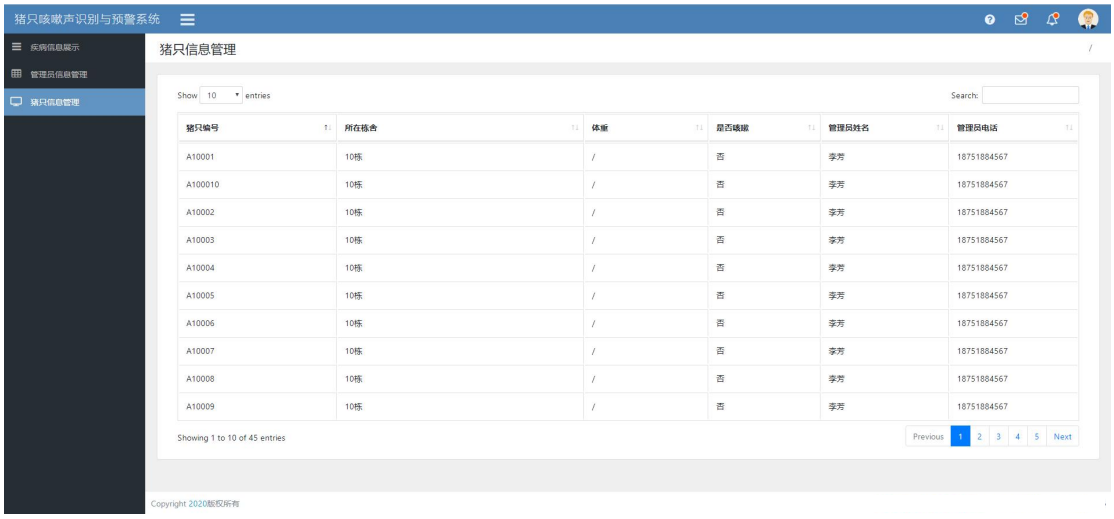
Fig.5-7 The interface of pig cough sound recognition and early warning display

管理人员信息以及猪只个体信息展示界面如图 5-8 所示，此部分界面分别展示了管理人员的工号、姓名、性别、年龄等基本信息；猪只信息管理界面主要展示了猪只的编号、所在栋舍、体重以及养殖人员信息、联系方式等，该部分为养殖场提供更加便捷的信息管理服务，有助于养殖产业信息化发展。



（a）管理人员信息展示界面

中国知网 https://www.cnki.net



（b）猪只个体信息展示界面

图 5-8 管理人员及猪只信息管理界面

Fig.5-8 The interface of management personnel information and pig information

5.4.2 WEB 后台研发集成

猪只咳嗽声识别与预警系统基于 SpringBoot 框架开发。SpringBoot 同时具有 Spring 框架的依赖注入和面向切面编程两大优势，依赖注入使得大量 Bean 不需要程序员手动导入，面向切面编程又使得程序可扩展性大大增强，使用 Configuration 简化繁琐 XML 配置，提供例如内嵌 tomcat 等多种 starter 依赖，不需要依赖外部程序，使得使用 SpringBoot 在 WEB 端后台开发更加方便快捷。

本课题中将猪只咳嗽声识别与预警系统软件平台划分为管理员信息管理模块、猪只个体信息管理模块、咳嗽声识别与预警模块，实现了不同身份权限登录以及管理查看内容分配以及猪场有效数据便捷式管理，最重要的是实现了猪只咳嗽声监测与预警功能。系统研发过程分模块、分节点，严格遵守阿里巴巴官方 JAVA 代码规范，对包名、类名、函数名及变量名等规范命名，并对代码关键部分进行注释，提高代码可阅读性以及系统的可扩展可维护性。

5.4.3 系统功能测试

5.4.3.1 MySQL 数据库性能测试

本次测试采用 MySQL 自带工具 mysqlslap 进行数据库性能测试，通过模拟多个客户端请求进行数据库压力测试，同时还可以对服务器的硬件资源能够承受的访问压力进行测试。方法为在命令提示符下找到并进入 MySQL 安装目录下的 bin 文件夹，依次进行 MySQL 数据库的自动测试、单表查询性能测试以及多表查询性能测试语句，如表 5-8 为测试命令参数说明。

中国知网 https://www.cnki.net

表 5-8 mysqlslap 命令参数说明

Tab.5-8 The mysqlslap command parameter description

参数名称	设定值	说明
--concurrency	100	并发连接数量
--number-of-queries	1000	MySQL 并发查询总量
--create-schema	-	指定查询数据库名称
--query	db-cough	自定义测试 sql 语句
--delimiter	;	测试 sql 语句分隔符

（1）数据库性能自动测试。如图 5-9 所示为 MySQL 性能自测结果图，分析结果可知当数据库一次承受 1000 次客户端请求时，执行所有 sql 语句的平均用时为 2.547s，该种测试方式可对不同养殖场实际服务器选型提供借鉴与参考，从而方便根据养殖场的规模大小及数据库响应时间确定合适的服务器类型。

```
C:\Program Files (x86)\MySQL\mysql-5.7.29-winx64\bin>mysqlslap -uroot -p123456 --concurrency=100 --number-of-quer
ies=1000 --auto-generate-sql
mysqlslap: [Warning] Using a password on the command line interface can be insecure.
Benchmark
        Average number of seconds to run all queries: 2.547 seconds
        Minimum number of seconds to run all queries: 2.547 seconds
        Maximum number of seconds to run all queries: 2.547 seconds
        Number of clients running queries: 100
        Average number of queries per client: 10
```

图 5-9 数据库性能测试

Fig.5-9 The database performance testing

（2）猪只咳嗽声识别预警系统数据库单表查询性能测试。数据库性能自动测试可以作为服务器选型参考，对于具体系统而言，应该针对每个系统数据库以及系统数据表进行压力测试。本系统中以单表为主，主要进行单表查询性能测试。如图 5-10 所示，客户端查询人数为 500，查询次数为 10 次时，查询总耗时 0.888s，可以满足正常业务需求。

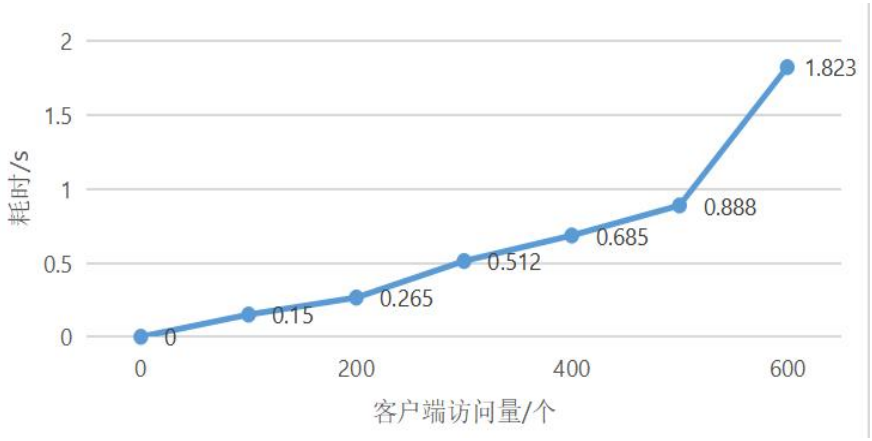


图 5-10 单表性能测试

Fig.5-10 The performance test of single table

中国知网 https://www.cnki.net

（3）猪只咳嗽声识别预警系统数据库多表查询性能测试。本系统多表查询主要用于权限管理，主要运用 sql 查询语句中的 delimiter 进行语句分割。如图 5-11 所示为多表查询测试结果，客户端访问量达到 5000 时平均为耗时 0.956s，相较单表查询时间有所增加。测试结果表明猪只咳嗽声识别预警系统可同时承受 500 个客户端查询，且延时不超过 1s。

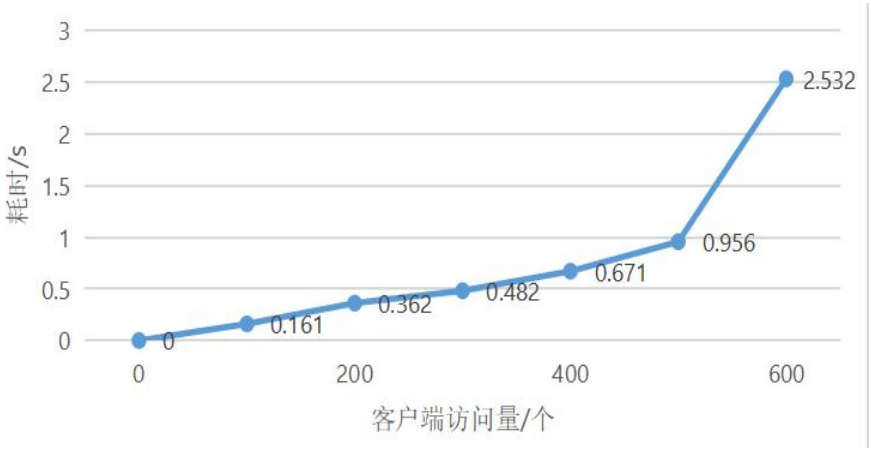


图 5-11 多表性能测试

Fig.5-11 The performance test of Multi-table

5.4.3.2 中间件性能测试

本文中间件用于监听文件夹中新增的音频文件并对其进行分割处理以及调用模型并上传咳嗽声检测结果数据，中间件性能的优劣主要体现在多线程操作过程中的耗用时间长短，本次测试开启监听线程数设置为 1、10、20、40、50。调用程序记录并打印中间件开始执行到结束的时间，如表 5-9 为不同线程数量下中间件执行耗时。单任务执行耗时 2.152s，多线程并发处理随着线程数量增多耗时逐渐增加，并发量为 50 时，总耗时 49.369s，本系统中间件可满足实际猪场应用需求。

表 5-9 中间件耗时统计

Tab.5-9 The statistics of middleware execution time

线程数量	执行时间/s
1	2.152
10	16.235
20	24.341
40	36.735
50	49.369

5.4.3.3 WEB 平台接口与压力测试

为保证项目上线后 WEB 平台接口访问正常，需要在系统正式部署前由测试人员设计测试用例，对平台进行接口访问及压力测试，减少系统上线后出现故障的几率，本文使用 Springboot + Vue 进行项目开发做到了前后端分离。前端段分离优点之一为

中国知网 https://www.cnki.net

前后端人员可以分别完成基本的单元测试，提升开发的效率。本项目中使用 Postman 进行后端接口测试，并全部通过检测。Postman 模拟客户端用户发起各类 HTTP 等请求(如:get/post/delete/put)，获得后端服务端返回的响应结果，比较结果是否和预期值匹配，保证后端开发人员及时发现并处理接口中的漏洞，确保系统上线运行后的稳定性和安全性。如图 5-12 为接口之一的登录接口测试成功示意图。

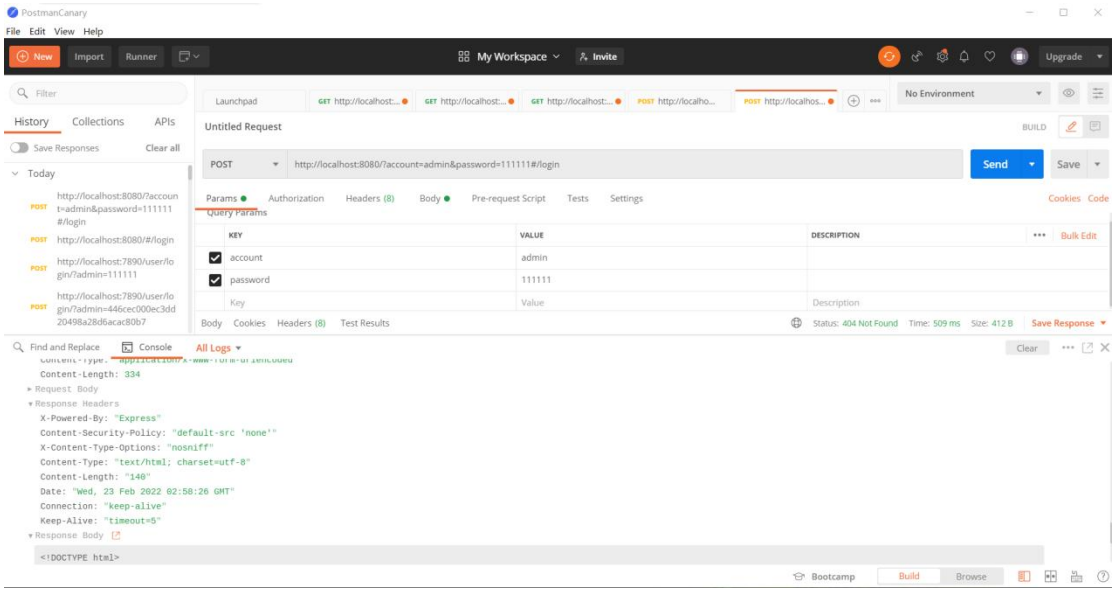


图 5-12 登录接口测试成功结果

Fig.5-12 The result of the interface test for login functionality

应用系统正式发布前通常需要进行访问接口的压力测试，同样使用 Postman 进行本系统的压力测试，模拟当系统承受较大访问量时的性能，以系统处理访问请求的平均响应时间作为系统性能的评价指标。

使用 Postman 中的 Runner 并发测试功能，设置并发数量分别为 100、500、1000、5000、10000 且访问间隔设置为 1ms。如表 5-10 所示为接口压力测试的平均响应时间统计结果，分析表中数据可知随着并发量的增多，系统响应的平均时间逐渐增加，当系统在 1ms 内访问量达到 5000 次时，系统平均响应时间在 1.6s 左右，响应时间正常且系统稳定运行，表明该系统可以满足中小规模猪场使用。

表 5-10 并发访问测试结果

Tab.5-10 The concurrent access to test results

并发量	平均响应时间/ms
100	18
500	152
1000	324
5000	1633
10000	3875

中国知网 https://www.cnki.net

5.4.4 系统服务器端部署

猪只咳嗽声识别与预警系统前后端研发成功后，将该项目部署于阿里云远程服务器中。首先使用编程工具 IDEA 分别将 SpringBoot 和 Vue 打包成可执行文件，前端打包使用命令 npm run build，后端打包需要在 pom.xml 中配置 maven 打包插件后使用 IDEA 自带打包快捷键即可将项目导出，此步骤为后续将项目部署于服务器上做准备。

云服务器上安装了反向代理服务器 Ngnix，方便对不同 WEB 项目进行管理。Ngnix 接收到新的客户端请求时，根据路由调度算法自动获取需要连接服务的 IP 地址，然后创建一个新的上游连接来连接指定的服务，当监听到客户端有新的数据发送时，Nginx 立即读取数据并将数据发送至上游连接，如图 5-13 为云服务器上 Nginx 安装成功结果图与 Ngnix 核心文件配置图。

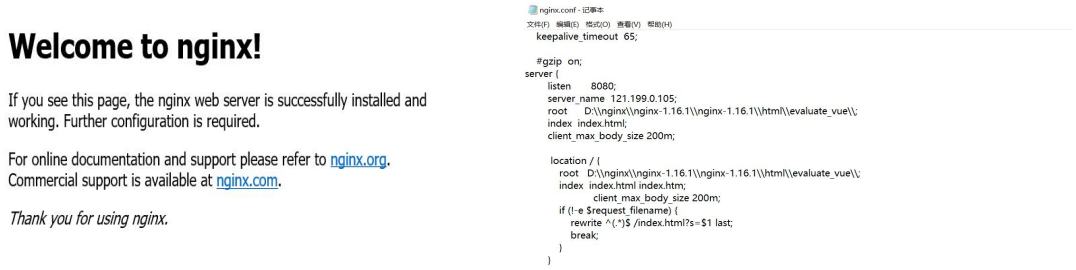


图 5-13 Nginx 安装成功与核心配置图

Fig.5-13 The diagram of Nginx successfully installed and the core configuration

Nginx 安装成功后在其 html 文件夹中放入 Vue.js 打包的前端界面，而后启动 Nginx.exe，最后通过“java -jar 【jar 名称】”指令启动打成 jar 包的后端程序，系统网页实现远程正常访问。如图 5-14 为系统启动成功界面。

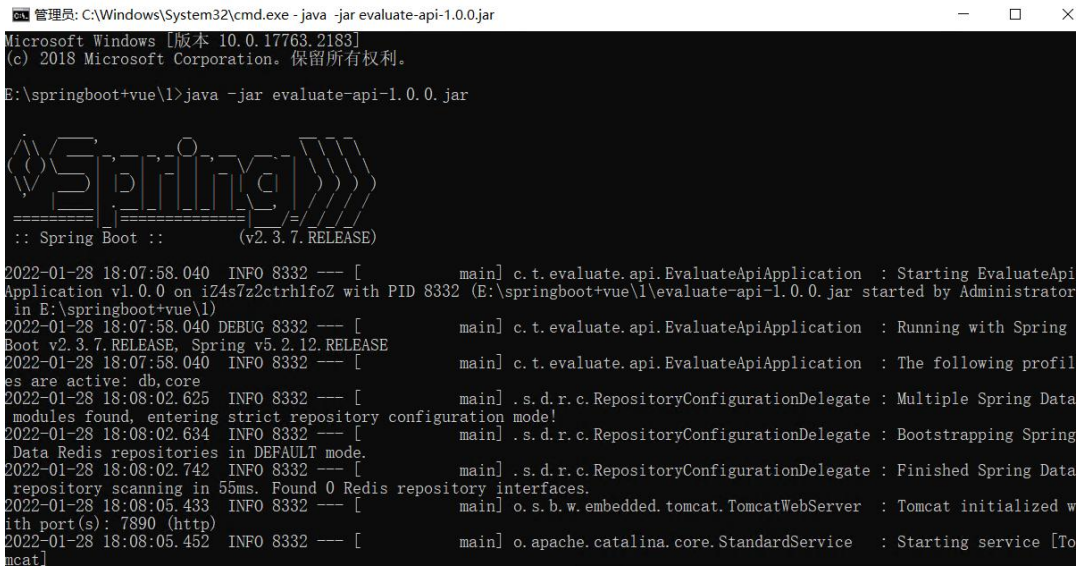


图 5-14 系统成功启动界面

Fig.5-14 The system started successfully

中国知网 https://www.cnki.net

5.5 本章小结

本章主要阐述了猪只咳嗽声识别预警平台的设计，猪只栋舍内环境信息的监测以及猪只咳嗽声识别结果可视化展示与预警发布相关内容。针对系统软件平台的整体设计、功能模块划分、数据库和中间件设计与实现、系统功能测试以及部署等方面进行详细介绍。具体如下：

（1）猪舍环境信息监测系统设计，采用各类环境传感器获取栋舍环境数据，通过 NBIOT 结合串口服务器的通讯方式，将环境参数上传至 MySQL 数据库存储，实现对栋舍内的温湿度、光照强度、氨气浓度、二氧化碳浓度等环境信息的全天候监测。

（2）猪只咳嗽声识别预警系统设计，通过网络拾音器采集猪舍内音频数据，调用猪只咳嗽声识别模型实现猪只咳嗽声识别与数据导出，同时将结果存入 MySQL 数据库，并搭建 WEB 界面实现数据可视化。

（3）系统软件平台设计描述了软件平台的整体架构及开发流程。平台按功能划分为养殖人员信息管理模块、猪舍环境信息监测模块、猪只咳嗽声识别预警模块。采用数据库管理系统 MySQL，设计了用户信息表、猪舍环境信息表、猪只咳嗽声信息表等。设计了与硬件交互、与数据库建立连接，实现 HTTP 通信等功能的中间件。

（4）系统软件平台的集成描述了前端界面设计、后台研发测试及部署等内容；软件平台面向猪场管理人员和养殖人员等相关用户群体，展示猪舍内环境信息和咳嗽声识别结果等重要信息，通过良好的人机交互界面实现数据形象化需求，提供信息化服务。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 总结

近年来，在生猪养殖产业的规模化发展同时，猪只的呼吸道疾病已成为各大养猪场内最常见且危害最严重的疾病之一。为了在猪只产生呼吸道疾病的初期通过监测识别猪只咳嗽声进行自动疾病预警，提出了一种基于深度神经网络的对猪只咳嗽声进行识别的方法，同时设计并搭建了可与生产实际相结合的猪只咳嗽声识别预警系统软件平台。本文所研究的猪只咳嗽声识别方法改善了因为模型本身的问题导致的咳嗽声识别率低下问题，可以较高准确率识别猪只咳嗽声，为后续猪只咳嗽声识别定位分析研究提供了技术支撑，同时软件平台也为养殖人员获取猪只信息、掌握猪只的健康状况及生长规律、及时地发现异常状况及深入开展猪只的福利养殖提供了一个新思路。主要研究内容包括：

（1）研究了猪只声音信号的预处理方法。采用人工标记的方法将采集到的猪场音频数据截取听音后由专业饲养人员将音频划分为 4 大类，接着分析了猪只不同声音和噪声信号的时频特征，采用基于多窗谱的谱减法对声音信号进行去噪处理，同时对比了小波去噪以及 LMS 和 NLMS 的去噪效果，结合波形可知小波去噪效果最差，NLMS 相较 LMS 去噪后波形还原较好，但滤波效果不理想，谱减法在保持波形不失真的情况下，滤波更彻底。选用将声音信号的短时能量和短时过零率作为特征参量的双门限端点检测法对去噪后的 536 段录音信号进行端点检测，还分析比较了对数频率距离法、比例法、熵谱法、相关法等端点检测算法，其中比例法以及相关法的效果最差，不能准确检测有声段，对数频率距离和熵谱法效果相近，但相较双门限端点检测仍有差距，双门限端点检测法最优。

（2）研究了猪只声音信号的特征处理方法。简要介绍了声音提取算法的发展史及其分类以及基于深度学习的特征提取算法，研究使用了目前使用最为广泛的 logFBank 和 MFCC 特征提取方法进行猪只声音信号特征提取，详细说明各个参数设置。处理过程中预加重系数设置为 0.97；加窗时采样频率设置为 48KHz、帧长设置为 25ms、帧移设置为 10ms；每一帧进行了 2048 点短时傅里叶变换；FBank 滤波器组个数设置为 64；MFCC 特征的 Mel 刻度滤波器组个数设置为 128。得到 4 种声音信号的各 2 种声音特征，分别再对其求一阶差分和二阶差分，得到 3 个特征进行零-均值标准化(z-score)处理，转换成 3 维数组作为咳嗽声识别模型的输入。将获取的音频数据 100%提取特征后，按训练集 80%、测试集 10%、验证集 10%的比例划分并保存用于后续模

中国知网 https://www.cnki.net

型训练。

（3）研究了基于深度神经网络的咳嗽声识别算法模型。简要介绍了神经网络的发展，利用提取到的 logFBank 和 MFCC 特征分别作为 CNNs 和 DFSMN 两种分类识别模型的输入，进行猪只咳嗽声识别二分类训练，设置不同迭代次数以及不同特征提取算法的分析对比试验，以准确率(Accuarcy)、查准率(Precision)、召回率(Recall)和 F1 值为评价指标。实验结果显示在迭代次数为 200 时，以 MFCC 为特征的 CNNs 咳嗽声识别模型准确率最高，咳嗽声识别精确率为 97%，召回率为 96%，F1 值为 98%，综合平均准确率为 96.71%。在迭代次数为 100 的基础上设计四分类识别模型训练，结果显示四分类模型准确率相对较低，考虑由于样本数量不均衡导致，后续研究中将继续扩充样本数量。

（4）设计并搭建猪只咳嗽声识别预警系统软件平台。该系统软件平台通过部署于云服务器的 Springboot + Vue + Ngnix 以及中间件和数据库完成猪舍环境信息以及猪只咳嗽与预警信息的数据管理、存储以及展示。系统运行效率提高，稳定性增强，简洁美观的 WEB 网页界面为猪场管理人员提供观察、管理平台，减少人畜共处的同时大大节省劳动力，提高生产效率。

6.2 展望

本文研究了基于深度神经网络的猪只咳嗽声识别方法，猪只咳嗽声识别预警系统在经过测试后，工作性能稳定，但仍存在一些不足之处及其它环节需要进一步研究：

（1）在非洲猪瘟以及新冠双重疫情的影响下，人员进出养殖场严格受限，获取多种并且有效的养殖场景下的数据较为困难。本文的研究仅仅针对特定场景中采集到的猪只声音数据，为了进一步提高本研究的实际应用效果，后续研究中需要采集数量更多、场景更加复杂的音频材料，提高模型的泛化能力。

（2）咳嗽声猪只的定位功能实现可有效提高系统效率，后续可以针对声源定位问题进一步研究，同时结合边缘端硬件设备提高系统的精简度，进一步优化猪只咳嗽声识别预警系统性能。

（3）目前研究仅仅停留在咳嗽声识别层面，如何通过咳嗽声相关信息直接判断疾病类别将成为今后的研究热点问题。

中国知网 https://www.cnki.net

参考文献

[1] 熊学振,杨春,马晓萍.我国畜牧业发展现状与高质量发展策略选择[J].中国农业科技导报,2022,24(03):1-10.

[2] 农业部关于促进现代畜禽种业发展的意见[J].四川畜牧兽医,2016,43(10):15-16+18.

[3] 陈伟生,关龙,黄瑞林,等.论我国畜牧业可持续发展[J].中国科学院院刊,2019,34(02):135-144.

[4] 印遇龙.关于促进畜牧业高质量发展的意见[J].兽医导刊,2021(03):1.

[5] 史文昕.规模化生猪养殖中的问题及改进措施[J].兽医导刊,2021(19):73-74.

[6] 任灵肖,刘佩,裴志勤,等.中小规模养猪场如何提高养猪效益[J].现代农村科技,2021(11):48.

[7] 郭惠武.中国猪肉消费现状和趋势分析[J].今日养猪业,2018(04):60-67.

[8] 钞贺森,田旭,于晓华.肉类消费结构、饲料安全和粮食安全——农业“供给侧改革”的一个参照系[J].农业现代化研究,2017,38(05):737-745.

[9] 崇兴福.猪呼吸道疾病发生的原因与防治措施[J].畜禽业,2021,32(11):106+108.

[10] 李园园.猪呼吸道疾病的流行与综合防控[J].兽医导刊,2021(03):21.

[11] 龚永杰,黎煊,高云,等.基于矢量量化的猪咳嗽声识别[J].华中农业大学学报,2017,36(03):119-124.

[12] 任道柱,陈瑞荣.畜牧养殖业的发展方向与科学管理[J].吉林畜牧兽医,2021,42(08):108-109.

[13] 李佳琪,许世峰,韦春波.“互联网+养殖业”精准扶贫模式的探究[J].山东畜牧兽医,2021,42(05):63-64.

[14] 陈龙宇.新时期传统型养殖业转型路径探究[J].畜禽业,2021,32(03):71-72.

[15] 舒畅,乔娟.新冠肺炎疫情防控对畜禽养殖业的影响及对策建议——基于全国786份畜禽养殖场(户)调查问卷分析[J].中国畜牧杂志,2020,56(03):120-125.

[16] 陈慧.物联网计算机网络安全与远程控制技术分析[J].网络安全技术与应用,2021(11):19-20.

[17] 叶长友,宋晓威.农业企业基于大数据的数字化协同管理创新研究[J].今日财富,2020(04):133-134.

[18] 毛学伟,王海芹,吴昊,等.江苏省数字农业农村发展现状及对策[J].安徽农业科学,2021,49(01):240-242.

[19] 沈明霞,太猛,CEDRIC Okinda,等.基于深层卷积神经网络的初生仔猪目标实时检测方法[J].农业机械学报,2019,50(08):270-279.

[20] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[21] Jeeva J B. A Computer Aided Diagnosis for detection and classification of lung nodules[C]//2015

中国知网 https://www.cnki.net

IEEE 9th International Conference on Intelligent Systems and Control (ISCO). IEEE, 2015: 1-5.

[22] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.

[23] Yin Y, Wu J M, Zheng H X. Ncfm: Accurate handwritten digits recognition using convolutional neural networks[C]//2016 International Joint Conference on Neural Networks (IJCNN). IEEE, 2016: 525-531.

[24] 苍岩,罗顺元,乔玉龙.基于深层神经网络的猪声音分类[J].农业工程学报,2020,36(09):195-204.

[25] Xie J, Zhu M. Handcrafted features and late fusion with deep learning for bird sound classification[J]. Ecological Informatics, 2019, 52: 74-81.

[26] Seung Ju Lim, Seong Jin Jang, Jee Young Lim, et al. Classification of snoring sound based on a recurrent neural network[J]. Expert Systems with Applications, 2019, 123:237-245.

[27] 李志忠,滕光辉.基于改进 MFCC 的家禽发声特征提取方法[J].农业工程学报,2008(11):202-205.

[28] Zhao X, Wei Y. Speaker Recognition Based on Deep Learning[C]//2019 IEEE International Conference on Real-time Computing and Robotics (RCAR). IEEE, 2019: 283-287.

[29] 王海坤,潘嘉,刘聪.语音识别技术的研究进展与展望[J].电信科学,2018,34(02):1-11.

[30] Chedad A, Moshou D, Aerts J M, et al. AP—animal production technology: recognition system for pig cough based on probabilistic neural networks[J]. Journal of agricultural engineering research, 2001, 79(4): 449-457.

[31] Ramaiah N P, Ijjina E P, Mohan C K. Illumination invariant face recognition using convolutional neural networks[C]//2015 IEEE International Conference on Signal Processing, Informatics, Communication and Energy Systems (SPICES). IEEE, 2015: 1-4.

[32] Carpentier L, Vranken E, Berckmans D, et al. Development of sound-based poultry health monitoring tool for automated sneeze detection[J]. Computers and electronics in agriculture, 2019, 162: 573-581.

[33] Aydin A, Berckmans D. Using sound technology to automatically detect the short-term feeding behaviours of broiler chickens[J]. Computers and electronics in agriculture, 2016, 121: 25-31.

[34] 曹晏飞,滕光辉,余礼根,等.含风机噪声的蛋鸡声音信号去噪方法比较[J].农业工程学报,2014,30(02):212-218.

[35] 张铁民,黄俊端.基于音频特征和模糊神经网络的禽流感病鸡检测[J].农业工程学报,2019,35(02):168-174.

[36] Rizwan M, Carroll B T, Anderson D V, et al. Identifying rale sounds in chickens using audio signals for early disease detection in poultry[C]//2016 IEEE Global Conference on Signal and Information Processing (GlobalSIP). IEEE, 2016: 55-59.

[37] Huang J, Wang W, Zhang T. Method for detecting avian influenza disease of chickens based on

中国知网 https://www.cnki.net

sound analysis[J]. Biosystems Engineering, 2019, 180: 16-24.

[38] 秦伏亮,沈明霞,刘龙申,等.基于音频技术的白羽肉鸡咳嗽识别算法研究[J].南京农业大学学报,2020,43(02):372-378.

[39] 杨稷,沈明霞,刘龙申,等.基于音频技术的肉鸡采食量检测方法研究[J].华南农业大学学报,2018,39(05):118-124.

[40] Clapham W M, Fedders J M, Beeman K, et al. Acoustic monitoring system to quantify ingestive behavior of free-grazing cattle[J]. Computers and Electronics in Agriculture, 2011, 76(1): 96-104.

[41] Laca E A, WallisDeVries M F. Acoustic measurement of intake and grazing behaviour of cattle[J]. 2000.

[42] Vandermeulen J, Bahr C, Johnston D, et al. Early recognition of bovine respiratory disease in calves using automated continuous monitoring of cough sounds[J]. Computers and Electronics in Agriculture, 2016, 129: 15-26.

[43] Ferrari S, Piccinini R, Silva M, et al. Cough sound description in relation to respiratory diseases in dairy calves[J]. Preventive veterinary medicine, 2010, 96(3-4): 276-280.

[44] Meen G H, Schellekens M A, Slegers M H M, et al. Sound analysis in dairy cattle vocalisation as a potential welfare monitor[J]. Computers and Electronics in Agriculture, 2015, 118: 111-115.

[45] BISHOP J C, FALZON G, TROTTER M, et al. Livestock vocalisation classification in farm soundscapes[J]. Computers and Electronics in Agriculture, 2019, 162:531-542.

[46] Yajuvendra S, Lathwal S S, Rajput N, et al. Effective and accurate discrimination of individual dairy cattle through acoustic sensing[J]. Applied Animal Behaviour Science, 2013, 146(1-4): 11-18.

[47] CHUNG Y, LEE J, OH S, et al. Automatic detection of cow's oestrus in audio surveillance system[J]. Asian-australasian Journal of Animal Sciences, 2013, 26(7):1030-1037.

[48] Yeon S C, Jeon J H, Houpt K A, et al. Acoustic features of vocalizations of Korean native cows (Bos taurus coreanea) in two different conditions[J]. Applied animal behaviour science, 2006, 101(1-2): 1-9.

[49] 刘艳秋,武佩,宣传忠,等.母羊 3 种应激行为下叫声信号的对比分析[J].中国农业大学学报,2016,21(11):57-63.

[50] 宣传忠,武佩,张丽娜,等.羊咳嗽声的特征参数提取与识别方法[J].农业机械学报,2016,47(03):342-348.

[51] 宣传忠,武佩,马彦华,等.基于功率谱和共振峰的母羊发声信号识别[J].农业工程学报,2015,31(24):219-224.

[52] 王诗佳.基于深度学习的声音事件识别研究[D].东南大学,2018.

[53] 赵建.基于深度学习的猪咳嗽声识别[D].华中农业大学,2019.

中国知网 https://www.cnki.net

[54] 柴进.声音特征提取和识别算法研究及 FPGA 实现[D].电子科技大学,2021.

[55] 张一杨,姚明林.基于自适应稀疏分解的声音识别算法[J].计算机应用与软件,2021,38(06):161-165.

[56] Zhao X, Wei Y. Speaker Recognition Based on Deep Learning[C]//2019 IEEE International Conference on Real-time Computing and Robotics (RCAR). IEEE, 2019: 283-287.

[57] 王海坤,潘嘉,刘聪.语音识别技术的研究进展与展望[J].电信科学,2018,34(02):1-11.

[58] 张海林.梅山猪连续咳嗽声监测系统设计与实现[D].南京农业大学,2020.

[59] Ramaiah N P, Ijjina E P, Mohan C K. Illumination invariant face recognition using convolutional neural networks[C]//2015 IEEE International Conference on Signal Processing, Informatics, Communication and Energy Systems (SPICES). IEEE, 2015: 1-4.

[60] 刘晓峰,宋文爱,陈小东,等.基于多核卷积融合网络的 BLSTM-CTC 语音识别[J].计算机应用与软件,2021,38(11):167-173.

[61] 薛佳俐,杨曙明.生猪福利养殖系统的研究进展[J].农产品质量与安全,2020(02):64-69+89.

[62] Exadaktylos V, Silva M, Aerts J M, et al. Real-time recognition of sick pig cough sounds[J]. Computers and electronics in agriculture, 2008, 63(2): 207-214.

[63] Silva M, Ferrari S, Costa A, et al. Cough localization for the detection of respiratory diseases in pig houses[J]. Computers and Electronics in Agriculture, 2008, 64(2): 286-292.

[64] Silva M, Exadaktylos V, Ferrari S, et al. The influence of respiratory disease on the energy envelope dynamics of pig cough sounds[J]. Computers and electronics in agriculture, 2009, 69(1): 80-85.

[65] Tokozume Y, Ushiku Y, Harada T. Learning from between-class examples for deep sound recognition[J]. arXiv preprint arXiv:1711.10282, 2017.

[66] Ferrari S, Silva M, Guarino M, et al. Cough sound analysis to identify respiratory infection in pigs[J]. Computers and electronics in agriculture, 2008, 64(2): 318-325.

[67] Chung Y, Oh S, Lee J, et al. Automatic detection and recognition of pig wasting diseases using sound data in audio surveillance systems[J]. Sensors, 2013, 13(10): 12929-12942.

[68] 徐亚妮,沈明霞,闫丽,等.待产梅山母猪咳嗽声识别算法的研究[J].南京农业大学学报,2016,39(4):681-687.

[69] 刘振宇,赫晓燕,桑静,等.基于隐马尔可夫模型的猪咳嗽声音识别的研究[C]//中国畜牧兽医学会信息技术分会第十届学术研讨会论文集,2015:107-112.

[70] 马辉栋,刘振宇.语音端点检测算法在猪咳嗽检测中的应用研究[J].山西农业大学学报(自然科学版),2016,36(06):445-449.

[71] 董红松,刘振宇,马辉栋,等.语音增强在去除猪咳嗽噪声中的应用研究[J].山西农业大学学报(自

中国知网 https://www.cnki.net

然科学版),2017,37(11):831-836.

[72] 赵建,黎煊,刘望宏,等.基于 DNN-HMM 声学模型的连续猪咳嗽声识别[J].农业工程技术,2020,40(30):93.

[73] 龚永杰,黎煊,高云,等.基于矢量量化的猪咳嗽声识别[J].华中农业大学学报,2017,36(03):119-124.

[74] 张振华,田建艳,王芳,等.猪咳嗽声特征参数提取与识别的研究[J].黑龙江畜牧兽医,2017(23):18-22.

[75] 黎煊,赵建,高云,雷明刚,刘望宏,龚永杰.基于深度信念网络的猪咳嗽声识别[J].农业机械学报,2018,49(03):179-186.

[76] 黎煊,赵建,高云,等.基于连续语音识别技术的猪连续咳嗽声识别[J].农业工程学报,2019,35(06):174-180.

[77] Yin Y, Tu D, Shen W, et al. Recognition of sick pig cough sounds based on convolutional neural network in field situations[J]. Information Processing in Agriculture, 2021, 8(3): 369-379.

[78] Shen W, Tu D, Yin Y, et al. A new fusion feature based on convolutional neural network for pig cough recognition in field situations[J]. Information Processing in Agriculture, 2020.

[79] 赵建.基于深度学习的猪咳嗽声识别[D].华中农业大学,2019.

[80] 苑文续,贾明娜,陈吴,等.基于谱减法与小波分析的电缆局部放电信号降噪方法[J].现代电子技术,2021,44(19):71-75.

[81] 金薛冬,李东新.基于谱减法的语音信号降噪改进算法[J].国外电子测量技术,2018,37(05):63-67.

[82] 苑文续,贾明娜,陈吴,等.基于谱减法与小波分析的电缆局部放电信号降噪方法[J].现代电子技术,2021,44(19):71-75.

[83] 高萌萌.基于声音检测的白羽肉鸡异常鸣叫声识别[D].黑龙江大学,2021.

[84] 曾剑飞.低信噪比条件下的语音端点检测算法研究[D].华南理工大学,2019.

[85] 聂勤,周妙琪,李军成.声源定位中双门限语音端点检测算法的改进[J].电子测试,2021(15):47-50.

[86] 王晓波.面向语音端点检测的关键电路优化设计[D].东南大学,2019.

[87] 夏令祥.低信噪比环境下语音端点检测方法的研究[D].中国矿业大学,2019.

[88] Smith C P. A phoneme detector[J]. The Journal of the Acoustical Society of America, 1951, 23(4): 446-451.

[89] Goldman-Eisler F. Speech analysis and mental processes[J]. Language and speech, 1958, 1(1): 59-75.

[90] Stevens K N. Autocorrelation analysis of speech sounds[J]. The Journal of the Acoustical Society of America, 1950, 22(6): 769-771.

[91] Howard C G. Speech Analysis-Synthesis Scheme Using Continuous Parameters[J]. The Journal of

中国知网 https://www.cnki.net

the Acoustical Society of America, 1956, 28(6): 1091-1098.

[92] Stevens K N. Autocorrelation analysis of speech sounds[J]. The Journal of the Acoustical Society of America, 1950, 22(6): 769-771.

[93] Potter R K, Steinberg J C. Toward the specification of speech[J]. The Journal of the Acoustical Society of America, 1950, 22(6): 807-820.

[94] Gambardella G. A contribution to the theory of short-time spectral analysis with nonuniform bandwidth filters[J]. IEEE Transactions on Circuit Theory, 1971, 18(4): 455-460.

[95] Rihaczek A. Signal energy distribution in time and frequency[J]. IEEE Transactions on information Theory, 1968, 14(3): 369-374.

[96] Gambardella G. Time Scaling and Short-Time Spectral Analysis[J]. The Journal of the Acoustical Society of America, 1968, 44(6): 1745-1747.

[97] Li Y, Zhang X, Jin H, et al. Using multi-stream hierarchical deep neural network to extract deep audio feature for acoustic event detection[J]. Multimedia Tools and Applications, 2018, 77(1): 897-916.

[98] Li Y, Li X, Zhang Y, et al. Acoustic scene classification using deep audio feature and BLSTM network[C]//2018 International Conference on Audio, Language and Image Processing (ICALIP). IEEE, 2018: 371-374.

[99] 胡博振.基于深度学习时空特征提取的红外缺陷检测研究[D].电子科技大学,2021.

[100] 林玮,杨莉莉,徐柏龄.基于修正MFCC参数汉语耳语音的话者识别[J].南京大学学报(自然科学版),2006(01):54-62.

[101] 李志忠,滕光辉.基于改进MFCC的家禽发声特征提取方法[J].农业工程学报,2008(11):202-205.

[102] 赵杰.基于深度学习的危险声音检测技术研究[D].电子科技大学,2020.

[103] 张仕良.基于深度神经网络的语音识别模型研究[D].中国科学技术大学,2017.

中国知网 https://www.cnki.net