中图分类号 S828　　学校代码 10224
密　　级 公开　　学　　号 S211401019

东北农业大学

硕士学位论文

复杂环境下基于多分类器融合的猪咳嗽声自动检测方法研究

作　　者 王锡鹏　　导　　师 沈维政　教授
学位类别 工学硕士　　所在学院 电气与信息学院
一级学科 计算机科学与技术　　二级学科 计算机科学与技术

二〇二四年六月

中国知网 https://www.cnki.net

Classified Index：S828 Code：10224
Confidential (yes/no)：no No. S211401019

Dissertation for the Master Degree

Research on automatic detection method of pig cough sound based on multi-classifier fusion in a complex environment

Candidate: Wang Xipeng

Supervisor: Prof. Shen Weizheng

Degree Category: Master of Science in Engineering

College: College of Electrical Engineering and Information

First level discipline: Computer Science and Technology

Second level discipline: Computer Science and Technology

Harbin China

June 2024

中国知网 https://www.cnki.net

目　录

1. 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 端点检测研究现状.....2
1.2.2 猪咳嗽声识别研究现状.....3
1.2.3 当前研究存在的问题.....6
1.3 研究内容与技术路线.....6
1.4 论文结构与章节安排.....8
2. 复杂猪舍环境内连续声音数据集的建立.....10
2.1 复杂猪舍环境内声音数据的采集.....10
2.2 连续复杂声音数据集的建立和标注.....11
2.3 数据分析与描述.....12
2.3.1 数据的复杂性说明.....12
2.3.2 数据的时频统计特征分析.....13
2.4 猪咳嗽声自动检测评价指标.....17
2.4.1 端点检测评价指标.....18
2.4.2 分类评价指标.....18
2.4.3 连咳识别评价指标.....19
2.5 本章小结.....19
3. 复杂猪舍环境内声音端点检测方法研究.....20
3.1 双门限端点检测方法.....20
3.1.1 端点检测特征.....20
3.1.2 双门限端点检测方法流程.....21
3.2 基于自适应动态门限的多重端点检测算法.....22
3.3 实验结果与分析.....24
3.3.1 实验参数设置.....24
3.3.2 不同端点检测方法的性能对比.....24
3.3.3 简单环境下不同端点检测方法的性能分析.....25
3.3.4 复杂环境下不同端点检测方法的性能分析.....27
3.3.5 本文端点检测方法的漏检原因分析.....29
3.4 本章小结.....30
4. 用于多分类器融合的基分类器的构建.....31
4.1 数据增强方法研究.....31
4.1.1 图像增强.....31

中国知网　https://www.cnki.net

4.1.2 声音增强.....32
4.2 特征提取.....33
4.2.1 声学特征.....33
4.2.2 图像特征.....34
4.2.3 原始波形特征.....35
4.3 分类模型.....35
4.3.1 传统机器学习模型.....36
4.3.2 一维卷积神经网络.....36
4.3.3 二维卷积神经网络.....38
4.3.4 长短时记忆网络.....40
4.4 基分类器的构建.....40
4.5 实验结果与分析.....41
4.5.1 实验参数设置.....41
4.5.2 不同数据增强方法的性能对比.....42
4.5.3 不同分类模型的性能对比.....43
4.5.4 不同基分类器的性能对比.....46
4.6 本章小结.....47
5. 复杂环境下基于多分类器融合的猪咳嗽声识别.....48
5.1 多分类器融合架构.....48
5.1.1 基于声学特征和深度特征的同构分类器融合架构.....48
5.1.2 基于多分类器选择的异构分类器融合架构.....49
5.2 多分类器选择方法.....49
5.2.1 基分类器的准确性与多样性度量.....49
5.2.2 基于准确性与多样性度量的多分类器选择方法.....51
5.3 多分类器融合方法.....51
5.4 单咳与连咳的判定.....52
5.5 实验结果与分析.....53
5.5.1 同构分类器融合架构的性能.....53
5.5.2 异构分类器融合架构的性能.....53
5.5.3 连咳识别结果与分析.....55
5.6 本章小结.....56
6. 结论与展望.....57
6.1 结论.....57
6.2 展望.....58
参考文献.....59

中国知网 https://www.cnki.net

摘 要

群发性呼吸道疾病是集约化生猪养殖模式下的高发疾病之一，生猪群发性呼吸道疾病具有传染性强、死亡率高等特点，若不能及时发现，很容易引起大规模传染，严重影响经济效益。传统的通过人工巡检的方式监测效率低，容易发生漏检。借助于非接触式声学智能感知技术，监测猪舍内声音并对猪咳嗽声进行识别，可以实现生猪群发性呼吸道疾病的预警，对提高生猪产量、实现生猪健康养殖具有重要意义。

实际猪舍的声音环境非常复杂，包括环控设备、饲喂机器等多种强噪声的干扰，同时，多头猪的叫声和猪咳嗽声可能叠加在一起，这给高精度的猪咳嗽声检测带来了很大的挑战。目前已有方法多建立在人工分割好的单个声音数据集下，且未考虑多个声音叠加的复杂情况，虽然取得了较好的分类效果，但是与实际猪舍环境下的检测结果仍然存在一定的差距。针对此问题，本文研究了复杂环境下基于多分类器融合的猪咳嗽声自动检测方法，建立了复杂环境下的连续声音数据集，并针对猪舍环境的复杂性，研究了基于自适应动态门限的多重端点检测算法和基于多分类器融合的分类算法。本文主要工作如下：

（1）建立了复杂猪舍环境下的连续声音数据集，包括连续咳嗽片段和连续非咳嗽片段。连续咳嗽每段 7-40 秒，共 316 段。连续非咳嗽片段共 25 段，每段 10 分钟。数据集共包含咳嗽 3408 个，非咳嗽 3133 个。在专家的帮助下，对数据集中所有咳嗽的开始时间和结束时间进行标注。最后，对该数据集的时频特性进行统计分析，并对数据的复杂性进行说明。该数据集为后续的研究提供数据支持。

（2）构建了基于自适应动态门限的多重端点检测算法。实际猪舍的噪声环境复杂多变，且经常出现声音叠加的情况，导致传统的端点检测方法表现出明显的局限性。为此提出了一种新的端点检测算法，可以根据具体的复杂情况、单个有声段的信噪比以及单个有声段的持续时间自适应的调整端点检测的次数和门限值。实验结果表明，本文提出的方法取得了 97.6% 的咳嗽检出率，明显高于传统端点检测方法的 75.8%。

（3）构建了基于多分类器融合的猪咳嗽声识别方法。考虑到咳嗽声音数据的复杂性以及非咳嗽声音数据的不平衡性，研究数据增强方法以增加数据的多样性，从声音和图像特征两个角度对数据进行增强，结果表明声音数据增强和图像数据增强的效果接近，加噪的效果最好，可以使准确率提升约 1%。为解决复杂环境下的声音分类问题，构建基于多分类器融合的分类模型以提升分类精度。多分类器融合的关键是构建一组性能良好且具有一定差异性的基分类器模型，本文通过研究多个不同域的特征和多个不同类型的分类模型，构建了多个基分类器模型，并提出了基于准确性-多样性度量的多分类器选择算法，来对所有的基分类器进行优化筛选，选出最优的基分类器融合方案。实验结果表明，通过数据增强和多分类器融合，可以有效提升模型在复杂环境下的分类精度，整体准确率可以达到 96.0%。最后，针对猪咳嗽声自动检测的结果，提出了一种连咳判定算法，实现了对连咳的识别。

综上，本文通过构建基于自适应动态门限的多重端点检测算法，实现了连续声音中有声段的高精度自动检测与分割，通过构建多分类器融合算法，实现了复杂环境下的高精度咳嗽

中国知网 https://www.cnki.net

分类。本研究为实际猪舍环境下的猪咳嗽自动检测提供了技术手段，为生猪健康养殖提供了有效的监测手段和技术解决方案。

关键词：生猪；咳嗽声识别；音频检测；集成学习；健康养殖

中国知网 https://www.cnki.net

Research on automatic detection method of pig cough sound based on multi-classifier fusion in a complex environment

Abstract

Respiratory disease is one of the most common of diseases in intensive pig breeding mode. Pig respiratory diseases have the characteristics of strong infectivity and high mortality. If they cannot be detected in time, it is easy to cause large-scale infection and seriously affect economic benefits. The traditional way of manual inspection is inefficient and prone to missed detection. With the help of contactless acoustic intelligent perception technology, monitoring the sound in the pig house and recognizing the cough sound of pigs can realize the early warning of pig respiratory diseases, which is of great significance to improve pig production and realize healthy pig breeding.

The sound environment of the real pig house is very complex, including the interferences of environmental control equipment, feeding machines and other strong noises. At the same time, multiple pig screams and pig coughs may be overlapped, which brings great challenges to high-precision pig cough detection. At present, most of the existing methods base on manually segmented single sound dataset, and do not consider the complex situations such as the overlap of multiple sounds. Although good classification results are achieved, there is still a certain gap between them and the detection results in the real pig house environment. To solve this problem, this paper studied the pig cough automatic detection method based on multi-classifier fusion in a complex environment, established a continuous sound dataset in a complex environment, and studied the multiple voice activity detection algorithm based on adaptive dynamic threshold and the classification algorithm based on multi-classifier fusion for the complexity of pig house environment. The main work of this paper is as follows:

(1) A continuous sound dataset in a complex piggery environment is established, including continuous cough segments and continuous noncough segments. There are 316 continuous cough segments, 7-40 seconds per segment, and 25 continuous noncough segments, 10 minutes per segment. The dataset contains a total of 3408 coughs and 3133 noncoughs. With the help of veterinarians, the onset and offset of all coughs in the dataset are annotated. Finally, the time-frequency features of this dataset are statistically analyzed, and the complexity of the data is explained. This dataset provides data support for subsequent research.

(2) A multiple voice activity detection algorithm based on adaptive dynamic threshold is constructed. The noise environment of the real pig house is complex and changeable, and the sound overlap often occurs, which leads to the obvious limitations of the traditional voice activity detection

中国知网 https://www.cnki.net

method. In this paper, a new voice activity detection algorithm is proposed, which can adaptively adjust the number of voice activity detection and its threshold value according to the specific complex situation, the signal to noise ratio of single voice segments and the duration of single voice segments. The experimental results show that the proposed method achieves a cough detection rate of 97.6%, which is significantly higher than that of the traditional voice activity detection method of 75.8%.

(3) The pig cough sound recognition method based on multi-classifier fusion is constructed. Considering the complexity of cough sound data and the imbalance of noncough sound data, the data augmentation method is studied to increase the diversity of data. The data is augmented from the perspectives of sound and image features. The results show that the performance of sound data augmentation and image data augmentation are close, and the performance of noise addition is the best, which can improve the accuracy by about 1%. To solve the problem of sound classification in a complex environment, a classification model based on multi-classifier fusion is constructed to improve the classification accuracy. The key to multi-classifier fusion method is to construct a set of base classifiers with good performance and certain diversity. In this paper, multiple base classifiers are constructed by studying the features of multiple different domains and multiple different types of classification models. A multi-classifier selection algorithm based on accuracy-diversity metrics is proposed to optimize the selection of all base classifiers and select the optimal base classifier fusion scheme. The experimental results show that through data augmentation and multi-classifier fusion, the classification accuracy of the model in a complex environment can be effectively improved, and the accuracy can reach 96.0%. Finally, for the results of automatic detection of pig cough sound, a continuous cough judgment algorithm is proposed to realize the recognition of continuous cough.

In summary, this paper constructs a multiple voice activity detection algorithm based on adaptive dynamic threshold to achieve high-precision automatic detection and segmentation of the vocal segment in continuous sound, and constructs a multi-classifier fusion algorithm to achieve high-precision cough classification in a complex environment. This study provides technical means for the automatic detection of pig cough in the real pig house environment, and provides effective monitoring means and technical solutions for healthy pig breeding.

Key words: Pig, Cough sound recognition, Audio detection, Ensemble learning, Healthy breeding

Candidate: Wang Xipeng
Speciality: Computer Science and Technology
Supervisor: Prof. Shen Weizheng

中国知网 https://www.cnki.net

1. 绪论

1.1 研究背景与意义

猪肉是中国消耗最多的肉类。中国农村农业部在《中国农业展望报告》中指出，2022 年我国的猪肉产量是 5541 万吨，占所有肉类产量的一半以上，且未来十年，猪肉的产量和需求量将会持续增加[1,2]。猪肉需求量的持续增加加快了生猪养殖行业的转型，促使生猪养殖行业朝着标准化、集约化、规模化的方向发展[3]。而规模化的养殖方式也带来了一些问题，其中包括疾病的防控问题。近些年国家多次发布生猪疫病防控相关的政策，指出疫病防控是生猪健康养殖的重中之重。呼吸道疾病是影响我国生猪健康养殖、制约生猪养殖产业发展的三大系统性疾病之一，也是规模化猪场内发病频率较高的系统性疾病。呼吸道疾病在一年四季均可发生，在秋末、冬季和春季的发病率最高，可高达 30%-70%，病死率约为 10%-30%。呼吸道疾病可导致生猪采食量降低，生长速度变慢，如果不及时治疗甚至可能会导致猪只的死亡[4]。同时由于养殖规模化和集约化的影响，导致如果不及时发现患病个体，则很容易出现大规模的感染，严重影响经济效益。

及时发现生猪的呼吸道疾病，进而采取相应的措施并预防其大规模爆发，是生猪养殖过程中亟待解决的问题。当前规模化猪场中的呼吸道疾病监测方式仍以不定时的人工巡视为主，该方式耗时费力，无法实现连续实时的监测，尤其是在夜间，很容易发生漏检。同时人工巡视容易引起生猪应激反应和人畜交叉感染。为此，我们迫切的需要一种非接触式、客观、准确、实时性强的呼吸道疾病监测方式，来实现生猪养殖的智能化监测和管理。生猪呼吸道疾病最显著的临床特征之一是咳嗽，并且有研究证明生猪的咳嗽与呼吸道疾病之间具有强相关性[5]，因此可以通过监测咳嗽声音来实现非接触式、快速、有效的呼吸道疾病预警。

连续声音中咳嗽的自动检测技术包括端点检测和分类两个步骤，通过研究端点检测算法和咳嗽分类算法可实现非接触式、连续、实时的咳嗽声音监测。然而实际猪舍的声音环境较为复杂，背景噪声复杂多变，且存在较多的声音叠加的情况，使得很多传统的端点检测和分类算法很难取得较高的精度。因此，如何实现实际复杂猪舍环境下咳嗽声音的高精度自动检测，是目前亟待解决的问题。

为此，本文针对实际猪舍中采集到的连续声音数据，构建了复杂环境下的咳嗽声音自动检测模型，可实现实际猪舍环境中咳嗽声音的监测，具有非接触式、实时性强、准确率高等优点，同时可以克服人工监测主观性强、容易漏检、生猪应激反应等缺点，有利于提高生猪养殖的数字化和智能化水平，满足未来生猪养殖集约化、规模化的发展需求。

本研究在黑龙江省自然科学基金优青项目《基于端到端的复杂环境下生猪咳嗽与疾病关联模型研究》（项目编号：YQ2023C012）以及国家自然科学基金项目《生猪异常状态与声学感知模型构建及预警方法研究》（项目编号：32172784）资助下完成。

中国知网 https://www.cnki.net

1.2 国内外研究现状

猪咳嗽声自动检测的关键步骤包括端点检测和猪咳嗽声识别，下面分别对端点检测和猪咳嗽声识别的研究现状进行阐述，为本文的研究提供基础。

1.2.1 端点检测研究现状

声音的端点检测方法整体上可以分为两种:基于特征参数的方法和基于模式匹配的方法。下面分别介绍这两类方法在近几年的研究现状，然后介绍端点检测在猪咳嗽自动检测领域的应用现状。

基于特征参数的方法指的是选取某种特征，然后设置门限阈值来确定有声段的位置。柏顺等人将梅尔频率倒谱系数（MFCC）的前三个维度相加，然后与短时能量相除，得到梅尔能量比，以此作为双门限端点检测的特征，并使用模糊 C 聚类算法（FCM）自适应的确定两条门限[6]。蔡诚等人将对数能量除以自相关函数主副峰值和过零率的乘积，以此作为特征对语音信号进行双门限端点检测[7]。吕昊等人将对数能量以及自相关函数余弦角值之比作为双门限法的特征[8]。毛强等人使用小波包分解得到 BARK 子带，然后求出每一帧信号的子带方差和谱熵，计算二者的比值并以此作为双门限法的特征[9]。张子丞等人计算了语音信号和噪声信号在高低两个频带的对数能量谱比值，以此作为双门限法的特征，然后根据最大似然估计的原则得到有声段和噪声段对数能量谱比的统计分布，并根据贝叶斯决策的原则得到了最佳阈值[10]。陈锡锻研究了基于短时能量和短时自相关函数的双门限法[11]。罗思洋等人分别提取了声音信号的子带谱熵、MFCC 和 Gammatone 频率倒谱系数（GFCC），并将子带谱熵、MFCC 的投影特征以及 GFCC 的第一维融合，以此作为双门限法的特征，并使用 FCM 算法估计门限阈值[12]。聂勤等人研究了基于短时 Teager 能量和频谱质心特征的双门限法[13]。陈航等人提取了声音的分形维数和自相关函数特征，以此来进行双门限端点检测[14]。张洪德等人提取了自适应子带对数能量和谱熵特征，然后以能熵积作为特征，使用双门限法进行端点检测[15, 16]。王静宇等人将鸟鸣声信号的频域划分为 24 个梅尔子带，并选取能量最高的梅尔子带能量作为特征，以此来进行双门限端点检测[17]。杨昱皞等人为实现海豚声音的端点检测，提取了声音的能量、频谱质心和谱质心二阶偏移率特征，并通过对海豚的声音特性进行分析来设置门限阈值[18]。孙静等人对声音信号进行经验模态分解，得到本征模态分量，以此来重构信号，然后将能量和过零率的比值作为特征，并提出了一种自适应门限计算方法，来对气体泄漏的声音进行端点检测[19]。高磊等人将功率归一化倒谱系数的第一维作为特征，以此来进行双门限端点检测[20]。陈锡锻等人研究了基于多正弦窗子带谱熵的端点检测方法[21]。朱敏研究了基于能量和过零率的双门限法[22]。上述研究主要集中在特征提取上，通过提取不同的特征，实现了某种任务下的高精度端点检测。然而上述研究对检测方法和门限的选取关注较少，检测方法以双门限法为主，门限选取考虑的因素不够充分，当声音环境较为复杂时可能会表现出较差的效果。

基于模式匹配的方法指的是使用机器学习或深度学习模型实现声音端点的识别。陈爱华等人分别采用 Gammatone 滤波、Gabor 滤波和 LTSV 滤波算法提取了声音的三种不同特征，

中国知网 https://www.cnki.net

然后将三个特征融合，使用深度神经网络（DNN）得到端点检测的结果[23]。Khalid Hasam 等人提出了一种基于单类残差连接的变分自编码器，通过该方法，只需要使用有限数量的语音数据进行训练，就可以实现不同噪声背景下的高精度语音端点检测，包括训练集中不存在的噪声背景[24]。Mihalache Serban 等人研究了多层感知机（MLPs）、循环神经网络（RNN）和卷积神经网络（CNN），然后将 CNN 和 MLPs 结合，实现了高精度端点检测[25]。Li Shu 等人研究了基于长短时记忆网络（LSTM）的端点检测方法，并使用局部注意力和全局注意力机制提高了检测准确率[26, 27]。Zhang Xiaolei 等人研究了基于前馈神经网络和 LSTM 的端点检测方法，并通过最大化 ROC 曲线下的面积来提升检测性能[28]。杜晗等人研究了基于常数 Q 变换（CQT）和 DNN 的端点检测方法[29, 30]。单蒙等人提出了一种基于原型网络的小样本学习算法，可以显著减少端点检测的数据准备工作量和系统数据量[31]。Korkmaz Yunus 等人提取了声音的能量、过零率和 MFCC 等特征，然后分别使用 LSTM 和门限法得到两个判决结果，最后将两个判决结果融合，得到检测结果[32]。Mu Wenpeng 等人将自适应宽度注意力学习机制融入 Transformer 框架，提高了检测精度[33]。Sharma Shilpa 等人将人工神经网络（ANN）和 K 均值聚类算法结合，提高了检测精度[34, 35]。Heo Youngjun 等人将声音数据增强方法和监督对比学习训练策略应用到语音的端点检测[36]。程涛等人研究了基于深层 CNN 的通信信号端点检测方法[37]。王中正等人将 MFCC 和 GFCC 的第一维融合，然后将该融合特征与能熵比特征作为朴素贝叶斯分类器的输入，得到端点检测结果[38]。Li Nan 等人根据人耳听觉系统的特性，研究了听觉启发调制特征作为深度学习编码器的设计，并纳入掩蔽机制来对编码器进行增强，最后，将注意力机制应用于深度学习模型，提高了端点检测准确率[39]。Zhang Weiwei 等人研究了基于残差网络的端点检测方法，并通过使用注意力机制，提高了端点检测精度[40]。与基于特征参数的端点检测方法相比，基于模式匹配的方法复杂度较高，需要较多的数据进行训练，且对于训练集中不存在的噪声环境，可能会取得较差的检测效果。

为实现猪咳嗽声的自动检测，有学者研究了猪舍声音环境下的端点检测算法。马辉栋等人以生猪个体为采样对象，采集了清晰、信噪比较高的连咳声音段，然后研究了基于能量和过零率的双门限端点检测算法，检出率在 96%以上[41]。熊梓奥在采集数据时，尽可能地将手机贴近发声猪，然后剔除了叠加、噪声污染严重以及人耳无法分辨的声音，构建了数据集。基于该数据集，对比了三种不同的端点检测算法，包括双门限法、基于支持向量机（SVM）的方法和基于 LSTM 的方法，结果表明基于 LSTM 的端点检测算法效果最好。然后研究了基于循环神经网络的猪咳嗽声识别模型。最后基于端点检测算法和孤立词识别算法，设计并实现了基于 Web 应用的猪咳嗽声音监测系统[42]。整体来说，对于猪咳嗽自动检测领域，端点检测相关研究较少，且现有研究所用的数据无法反映实际猪舍的复杂环境。

1.2.2 猪咳嗽声识别研究现状

早期，有学者对猪咳嗽声识别方法进行了初步的探讨，他们将猪放置在单独的实验装置里，以此来采集单头猪的叫声，然后使用传统的功率谱密度特征和机器学习方法来实现猪咳嗽声识别。D Moshou，A V Hirtum 等人将单个猪只放置到单独的实验装置中，使用雾化的柠檬酸诱导猪只发生咳嗽，并采集了咳嗽、咕噜声、金属碰撞声等多种声音。为实现咳嗽声音

中国知网 https://www.cnki.net

的识别，他们提取了声音的功率谱密度（PSD）特征，并分别构建了混合感知机[43]、概率神经网络（PNN）[44]和 FCM[45]。随后，他们将猪的数量增加到 12 只，并研究了由氨气、粉尘和湿度三种不同因素引起的咳嗽的识别，使用之前的数据采集装置以及先前构建的 FCM 算法[45]，取得了 94%的平均正确识别率[46]。随后，V Exadaktylos 等人使用人工注射病菌的方式诱导生猪患病，并使用上述装置[43-46]采集实验数据，然后分析了不同声音的频率特征，并提出了一种特征匹配算法，通过计算声音信号与参考信号之间的功率谱密度的平方欧氏距离来确定该信号的类别，用于识别患病猪的咳嗽，取得了 85%的整体识别准确率[47]。由于实验室环境比较简单，且采集对象为单头猪，因此上述研究整体上取得了较高的识别准确率。

随后，越来越多的学者开始研究实际猪舍中咳嗽的识别方法，这些方法仍以传统的声学特征和机器学习算法为主。Guarino M 等人在一个商业猪场中的一个猪舍中采集数据，猪舍包含前后相接的多个猪栏，每个猪栏包括 22 头猪，尺寸为 5 米*6 米，他们将麦克风放置在猪栏中，以此采集了 44 头猪的声音，其中共包括 159 个咳嗽声音和 433 个其他声音。基于该数据集，研究了声音的能量、时间导数能量和功率谱密度特征，以及动态时间规整（DTW）算法，用于咳嗽声音的识别，准确率为 90%[48, 49]。Y Chung 等人将 22 头患有呼吸道疾病的猪安置在一个 1.8 米*4.8 米的围栏中，并采集患病猪只的咳嗽声，此外，他们在实际养猪场中的一个密闭猪舍内采集其它猪叫声，包括非感染性咳嗽、尖叫、咕噜声等，采用人工标注的方式共截取了 300 个患病猪的咳嗽声音以及 200 个正常的声音。基于该数据集，提取了声音的 MFCC 特征，并使用支持向量数据描述（SVDD）作为分类器，对咳嗽进行识别，识别准确率为 94%。然后使用稀疏表示分类器（SRC）作为分类器，将识别出的咳嗽进一步分类为由三种原因引起的咳嗽，三种原因分别为断奶仔猪多系统衰竭综合症、繁殖与呼吸综合症病毒和猪肺炎支原体，分类准确率为 91%[50]。尽管实验环境为实际猪舍，然而上述研究所用数据较为简单，导致仅用很少的几百条数据就取得了较高的准确率。随着猪舍环境复杂性的增加，训练模型所需的数据量也将明显增加。

近些年的研究中，有学者对传统的声学特征和机器学习模型做了更进一步的研究，用于实现咳嗽的识别，其中，声学特征以 MFCC 和 PSD 为主，机器学习模型包括隐马尔可夫模型（HMM）、FCM、SVM、DTW 等。刘振宇等人研究了 HMM，用于咳嗽声音的识别[51]。徐亚妮设计了母猪声音采集室，用来收集单只母猪的叫声，采集室长 2.5 米，宽 1.2 米，高 1.5 米，采集声音时，不考虑室内外环境因素以及喂食等情况。在饲养员的帮助下，截取了咳嗽、尖叫、叮当声等多种声音。基于该数据集，分析了母猪声音信号的功率谱密度特征，并设计了改进的 FCM 算法，用于咳嗽声音的识别，然后基于该算法设计了母猪咳嗽声音检测系统[52]。张振华等人在实验室环境下进行实验，并在饲养员的帮助下使用录音笔近距离采集猪咳嗽声。为实现猪咳嗽声识别，对比了 MFCC 和线性预测倒谱系数（LPCC）的性能，并以 HMM 作为分类器，结果表明将 MFCC 与一阶差分 MFCC 融合可取得最好的咳嗽声音识别效果，总识别率为 93%[53, 54]。龚永杰等人在专家的帮助下，截取了 1640 个声音样本，包括中咳嗽 820 个、进食声 150 个，甩耳朵 120 个、哼哼声 100 个、尖叫声 90 个、喷嚏声 360 个。为实现猪咳嗽识别，他们将 MFCC 和差分 MFCC 融合，然后研究了矢量量化(VQ)、SVM 和 HMM 模型，通过将 HMM 和 SVM 串联构建了 HMM-SVM 模型，并使用粒子群算法对 HMM-SVM 进行优化，最后使用软投票的方式将上述四个模型进行融合，明显的提高了咳嗽的识别精度，

中国知网 https://www.cnki.net

综合识别率达到了 94.21%[55, 56]。韩磊磊将录音笔放到养猪场中的猪舍中，每个猪舍尺寸为 6 米*8 米，包含 6-8 头猪，以此来采集实验数据，然后从数据中挑选了 1095 个清晰、无重叠的声音，包括 375 个咳嗽、308 个惊骇声以及 412 个其他声音，其他声音包括通风机噪声、生猪吃草料声、哼哼声和碰栏杆声。基于此数据集，使用 MFCC 和一阶差分 MFCC 作为特征，使用 SVM 和 SVDD 的组合模型作为分类器，用于咳嗽声和惊骇声的识别，并设计了生猪异常状态监测系统[57]。孙浩楠等人在 2.1 米*3.2 米的猪舍内采集了 10 头猪的叫声，包括咳嗽、打呼噜、尖叫、咆哮和哼哼声，共 1560 个样本，其中咳嗽 780 个。然后将人工神经网络、SVM 和 DTW 用于咳嗽的识别，识别准确率在 85%以上[58, 59]。可见，传统的声学特征和机器学习模型在猪咳嗽识别领域仍具有一定的优势。然而上述研究使用的数据较为理想，只选取了清晰、无叠加的声音，非咳嗽只包含有限的几种，无法反映实际猪舍的复杂环境。

随着深度学习的发展，有学者通过使用常见的深度神经网络框架，或者自己搭建的深度学习模型，实现了更高精度的猪咳嗽识别。黎煊、赵建等人将 10 头猪分开放置在相邻的两个猪栏，每个猪栏 5 头，使用录音笔共采集了 30 小时的数据，然后从中截取了 1400 个声音样本，包括咳嗽、打喷嚏、吃食、尖叫、哼哼、甩耳朵，其中咳嗽样本 594 个。基于该数据集，构建了一个 5 层的深度信念网络模型，用于咳嗽的识别，总识别率为 94.29%[60]。然后建立了包含咳嗽、打喷嚏、吃食、尖叫、哼哼、甩耳朵以及环境噪声在内的连续声音数据集，基于该数据集构建了双向长短时记忆网络-连接时序分类（BiLSTM-CTC）模型和深度神经网络-隐马尔可夫模型（DNN-HMM），实现了连续咳嗽声音的识别，总识别率为 93.24%[61-63]。张海林、沈明霞等人将 5 只患有呼吸道疾病的猪和 5 只健康猪分别放置在两个单独的猪舍内，经数据采集和预处理得到了 283 段连续咳嗽、1058 个单次咳嗽、376 个喷嚏声、195 个鸣叫声和 296 个噜噜声。基于该数据集，首先对比了最小二乘支持向量机（LS-SVM）和 BiLSTM-CTC 的性能，结果表明 BiLSTM-CTC 效果更好，并基于该算法设计了连续咳嗽声音监测系统[64]。然后，他们构建了 CNN 模型和和深层前馈序列记忆神经网络模型，结果表明 CNN 的效果更好，取得了 96.71%的整体识别准确率[65]。宋航等人采集了 6 头患有呼吸道疾病的猪的叫声，每头猪饲养于 2.1 米*3.2 米的猪栏内，在兽医的帮助下，采集并挑选了 4334 个清晰、无额外噪声、无叠加情况的猪叫声样本，包括 1353 个咳嗽和 2981 个非咳嗽。他们对比了 VGG16，ResNet34，DenseNet121 等 CNN 框架，然后使用注意力机制对 DenseNet121 模型进行改进，取得了 93.8%的识别准确率[66-68]。通过深度学习方法的构建，使得识别准确率进一步提升，然而上述研究同样存在数据层面的问题：使用的数据较为理想，只选取了清晰、无叠加的声音，非咳嗽只包含有限的几种，无法反映实际猪舍的复杂环境。

为进一步提升猪咳嗽识别准确率，有学者通过将不同域特征进行融合，实现了高精度的识别。本课题组在商业猪场中采集数据，猪场包括 21 个猪栏，共 128 头猪，将麦克风放置到其中一个猪栏里进行采集，在专家的帮助下，标注并截取了 4551 个清晰、信噪比较高、无叠加情况的声音样本，其中咳嗽 2744 个，非咳嗽 1807 个。基于该数据集，涂鼎等人首先将多帧 MFCC 与多个单层 CNN 融合，结合 Softmax 和 SVM 分类器，整体识别准确率为 96.6%，然后提取了声音信号的语谱图特征，并使用微调的 AlexNet 对语谱图进行分类，整体识别准确率为 95.4%[69-71]。紧接着，纪楠等人进一步研究了不同域特征的融合方法，提取了声音的时域、频域、倒谱域特征。然后将声音信号转化为语谱图和 CQT 谱图，并分别提取了图像的

中国知网 https://www.cnki.net

视觉特征和深度特征，其中，视觉特征包括方向梯度直方图和局部二值模式，深度特征为使用自建的浅层卷积神经网络提取的特征。通过将声学特征、视觉特征和深度特征进行特征融合，实现了高精度的咳嗽声音识别，识别准确率为 97.57%[72-74]。最后，基于上述的研究成果，Yin 等人以 MFCC 和 LPCC 作为声学特征，使用微调的 AlexNet 从语谱图、梅尔语谱图和 CQT 图中提取深度特征，然后进一步对比了特征融合和分类器融合的性能，结果表明使用软投票的方式将声学特征和深度特征进行融合时效果最好，识别准确率为 99.2%[75]。Wang Buyu 等人在实际猪场环境下分别采集了声音信号和热源图信号，然后将声音信息和热源图信息结合，提取了声音信号的声学特征和深度特征，以及热源图信号的深度特征，通过声音信号和热源图信号的特征融合，实现了高精度的咳嗽声音识别，识别准确率为 99.77%[76, 77]。上述研究主要通过不同域特征的融合，在数据集较为简单的条件下取得了很高的准确率。然而文献[75]指出，使用不同域特征进行分类器融合可取得 99.2%的准确率，优于特征融合，然而除文献[75]之外，尚未有研究在猪咳嗽识别领域对不同域特征的分类器融合方法进行进一步的研究，另外，特征和分类器的类别较少，有待进一步挖掘。

1.2.3 当前研究存在的问题

尽管现有研究取得了一定的进展，但是仍存在一些不足，主要表现为以下几点：

（1）现有研究所用的数据集主要以人工手动标记好的单个声音片段为主，缺乏连续声音数据集。同时现有的数据集无法充分反映实际猪舍的复杂性，数据集较为简单，咳嗽声一般为无干扰的、信噪比相对较高的信号，非咳嗽声信号仅包含有限的几个种类。然而实际猪舍的环境较为复杂，主要表现为以下两点：首先，猪舍内声音源非常复杂，常常多种不同声音叠加或重叠在一起。比如人说话声、风机噪声、饲喂机器声音、工人清粪声、多头猪尖叫声与咳嗽声的叠加。通过对本文数据集中所有的咳嗽进行统计，发现与其他声音叠加的咳嗽占比接近 1/5。其次，非咳嗽种类很多，多达数十种，且非咳嗽声数量存在严重的不平衡，某些类型的非咳嗽声数量较少，且不易分辨和标注。若不充分考虑这些复杂情况，则会极大的降低咳嗽的检测准确率，加大患病猪只漏检的风险。

（2）端点检测方法研究较少，且传统方法无法适应于复杂的猪舍环境。现有研究主要集中在孤立词识别算法上，只有少部分研究对传统的端点检测算法进行了简单的实验。然而本文的研究结果表明，传统的端点检测算法在复杂环境下的准确率很低，无法满足复杂环境下咳嗽声音自动检测的需求。

（3）现有研究考虑的特征和分类器种类有限，无法充分提取和挖掘声音不同层面的信息。同时，现有研究主要以传统方法、特征融合、以及深度学习模型的构建为主，分类器融合方法的研究相对较少，且现有的分类器融合方法都是经验性的选取部分基分类器进行融合，缺少基分类器的优化筛选，导致融合的结果可能不是最优。

1.3 研究内容与技术路线

针对上述存在的问题，本文针对实际猪舍的复杂环境，研究复杂环境下的猪咳嗽声自动检测方法，整体技术路线如图 1-1 所示。首先建立复杂环境下的连续声音数据集，基于该数

中国知网 https://www.cnki.net

据集，分别研究端点检测方法和基于多分类器融合的分类方法，实现咳嗽的自动检测，最后对检测结果中的连咳进行判定。本文的主要研究内容概括如下：

（1）建立复杂环境下的连续声音数据集。采集大规模商业猪场中的声音数据，在专家的帮助下，对数据进行截取和标注，然后对数据的复杂性和时频特征进行分析和说明。该数据集用于后续猪咳嗽声自动检测方法的研究。

（2）复杂环境下端点检测方法的研究。为实现复杂环境下的高精度端点检测，首先研究基于不同特征的双门限检测方法，并对结果进行分析，指出双门限法在复杂环境下的局限性。针对双门限法的局限性，设计基于自适应动态门限的多重端点检测算法，根据具体的复杂情况自适应的调整并设置多个门限，实现高精度的端点检测。

（3）用于多分类器融合的基分类器的构建。首先，研究不同的图像增强和声音增强方法，以此来提升模型的精度和数据多样性。其次，为表达和挖掘声音更多的信息，研究了多种特征和分类模型，特征包括多种声学特征、图像特征和原始波形，分类模型包括多种机器学习模型、LSTM 以及基于不同迁移学习方法的一维卷积神经网络和二维卷积神经网络。最后，从性能和特征多样性的角度选取特征和分类模型，构建基分类器。

（4）复杂环境下基于多分类器融合的猪咳嗽声识别。分别研究同构分类器融合方法和异构分类器融合方法，研究异构分类器的准确性与多样性度量，并基于该度量设计基分类器选择算法，以此来选出最优的基分类器融合方案，研究基于软投票的融合方法，得到融合结果。研究连咳识别方法，来对检测结果中的单咳和连咳进行进一步的判定。

中国知网 https://www.cnki.net

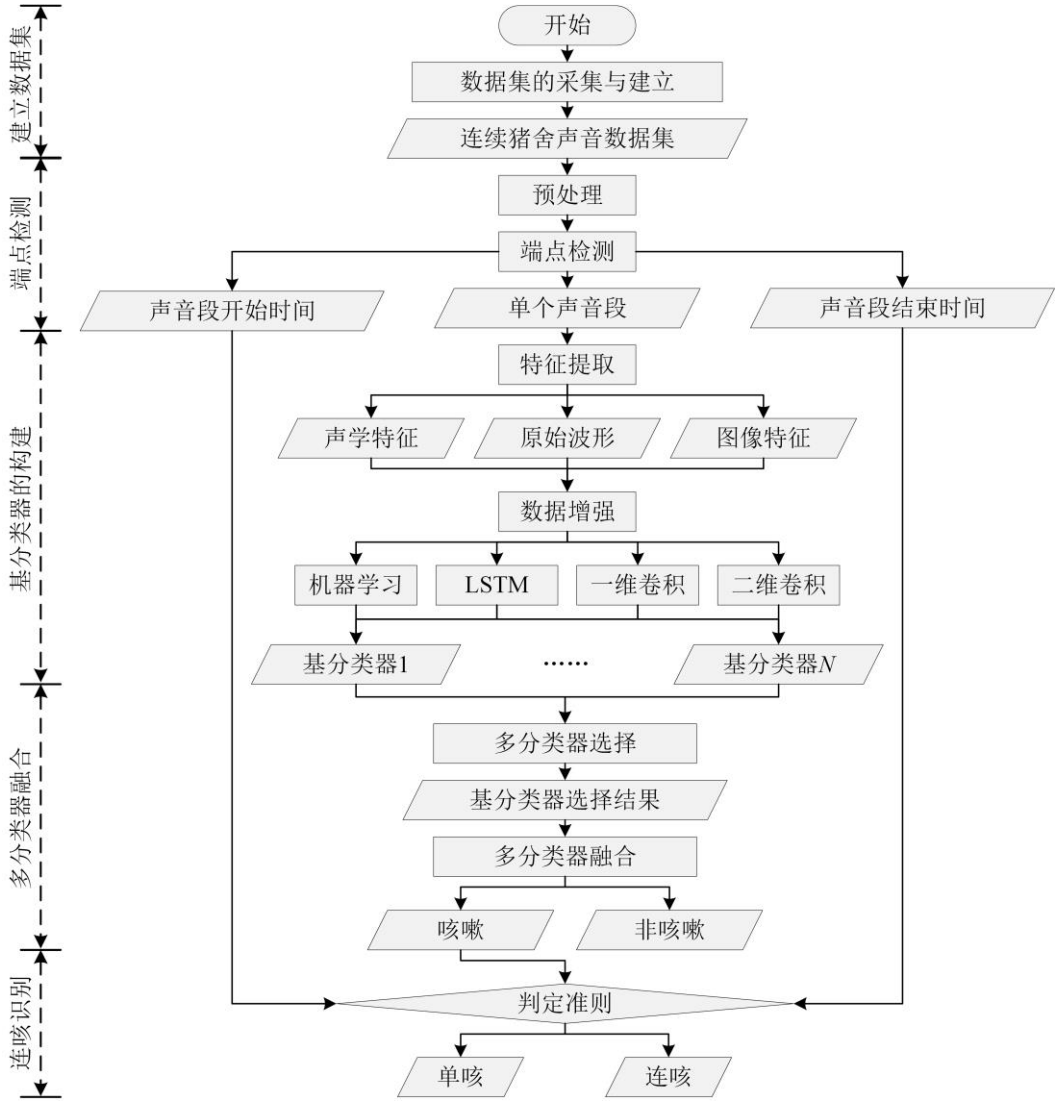


图 1-1 技术路线图

Fig.1-1 Schematic diagram of the technical flow

1.4 论文结构与章节安排

本文共分为六个章节，每个章节的内容，以及各个章节之间的联系如图 1-2 所示。各个章节的内容如下：

第一章是绪论部分。本章首先阐述了猪咳嗽声音自动检测的研究目的与意义，然后总结了国内外相关的研究现状，包括端点检测和猪咳嗽声识别的研究现状，并指出了现有研究存在的问题，引出了本文的主要研究内容与技术路线。最后介绍了本文的结构与章节安排。

第二章是复杂猪舍环境内连续声音数据集的建立。本章首先详细介绍了猪舍内声音的采集过程和数据集的建立过程，然后对数据集进行分析，包括数据的时频特征分析和复杂性说明。最后阐述了模型的评价指标，包括端点检测、分类和连咳识别的评价指标。

中国知网 https://www.cnki.net

第三章是复杂猪舍环境内端点检测方法研究。首先介绍了基于不同特征的双门限端点检测方法，然后介绍了本文提出的基于自适应动态门限的多重端点检测算法，并将本文方法与多种双门限法进行对比分析。

第四章是用于多分类器融合的基分类器的构建。首先探讨了不同声音数据增强和图像数据增强方法的影响。然后为构建精度更高的基分类器，本章对比了多种不同域特征的性能，以及多种不同类型的分类模型的性能，同时还探讨了不同迁移学习方式的影响。最后阐述了基分类器的构建流程。

第五章是复杂环境下基于多分类器融合的猪咳嗽声识别。首先介绍了两种不同的多分类器融合架构，包括同构分类器融合架构和异构分类器融合架构。然后介绍了异构分类器融合架构中的准确性与多样性度量，以及基于该度量的多分类器选择算法，然后介绍了多分类器融合方法，并对比分析。最后介绍了本文提出的连咳判定方法。

第六章是结论与展望。主要是对本文结论的总结，以及对未来研究方向的展望和讨论。

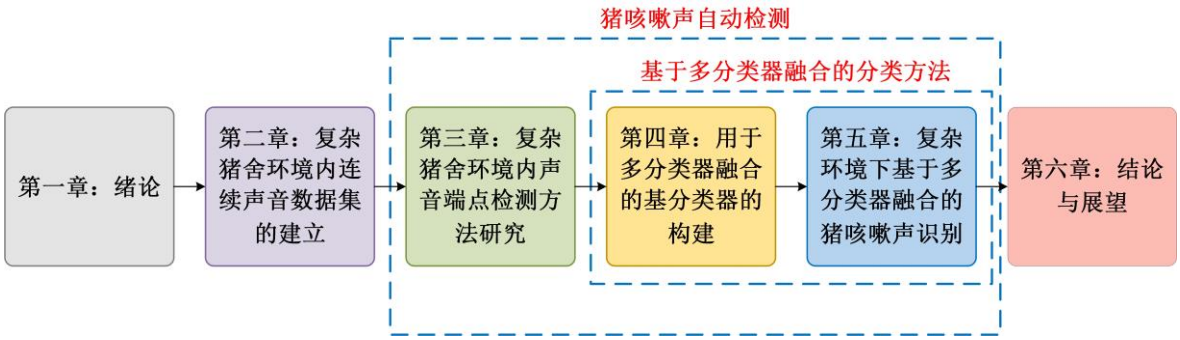


图 1-2 本文的章节与内容安排

Fig.1-2 Research content and arrangement of sections

中国知网 https://www.cnki.net

2. 复杂猪舍环境内连续声音数据集的建立

2.1 复杂猪舍环境内声音数据的采集

数据的采集时间为呼吸道疾病频发的 4 月份，采集地点为黑龙江省哈尔滨市阿城区的某大型商业猪场中的一个猪舍，猪舍的布局如图 2-1 所示。猪舍长 27.5 米，宽 12.8 米，高 3.2 米，由 12 个大猪栏和 9 个小猪栏组成。其中大猪栏长 4.15 m，宽 3.6 m，小猪栏长 3.6 m，宽 2.75 m。猪舍采用机械化通风和自动化饲喂方式，地板是漏缝的混凝土地板。猪舍内有两个直径为 1.35 米的风机，风机每隔两小时开始一次，每次开启时间为 15 分钟，风机开启时会有较大的噪音。工人们每天用铁锹和水清理粪便，上午和下午各清理一次。128 头猪较为均匀地分布在 12 个大猪栏里。采集数据时，每个猪栏里均有不等数量的猪呈现不同程度的咳嗽，对于咳嗽较为严重的两头猪放在靠近门口的 13 号猪栏中。

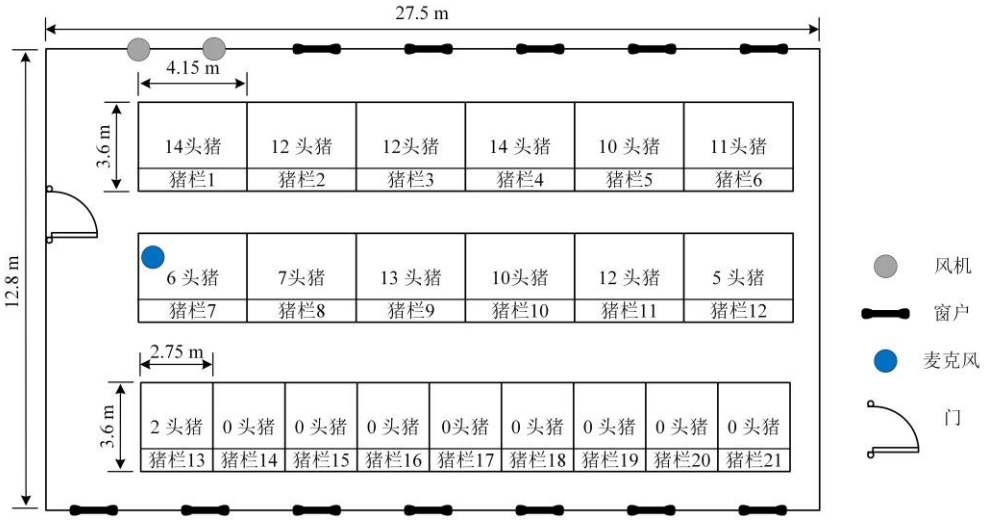


图 2-1 猪舍分布图

Fig.2-1 Distribution map of piggery

将麦克风(LIQI LM320E，心型驻极体麦克风)连接到带声卡(Conexant Smart Audio HD)的笔记本电脑上进行录音。将麦克风固定在靠近门的 7 号猪栏上，麦克风距离地面约 1.4 米，距离猪背部约 0.8 米。将音频采样率设置为 44100 Hz，分辨率设置为 16 bit，声音以“.wav”格式保存。整个数据采集过程一共持续了 7 天，采集到的数据每隔 10 分钟保存一次。图 2-2 展示了设备的布置和猪舍的环境，其中子图(a)表示麦克风的放置位置，子图(b)和子图(c) 展示了猪舍内部的环境，子图(d)和子图(e)展示了患有呼吸道疾病的猪，子图(f)展示了数据的采集过程和使用的软件。

中国知网 https://www.cnki.net

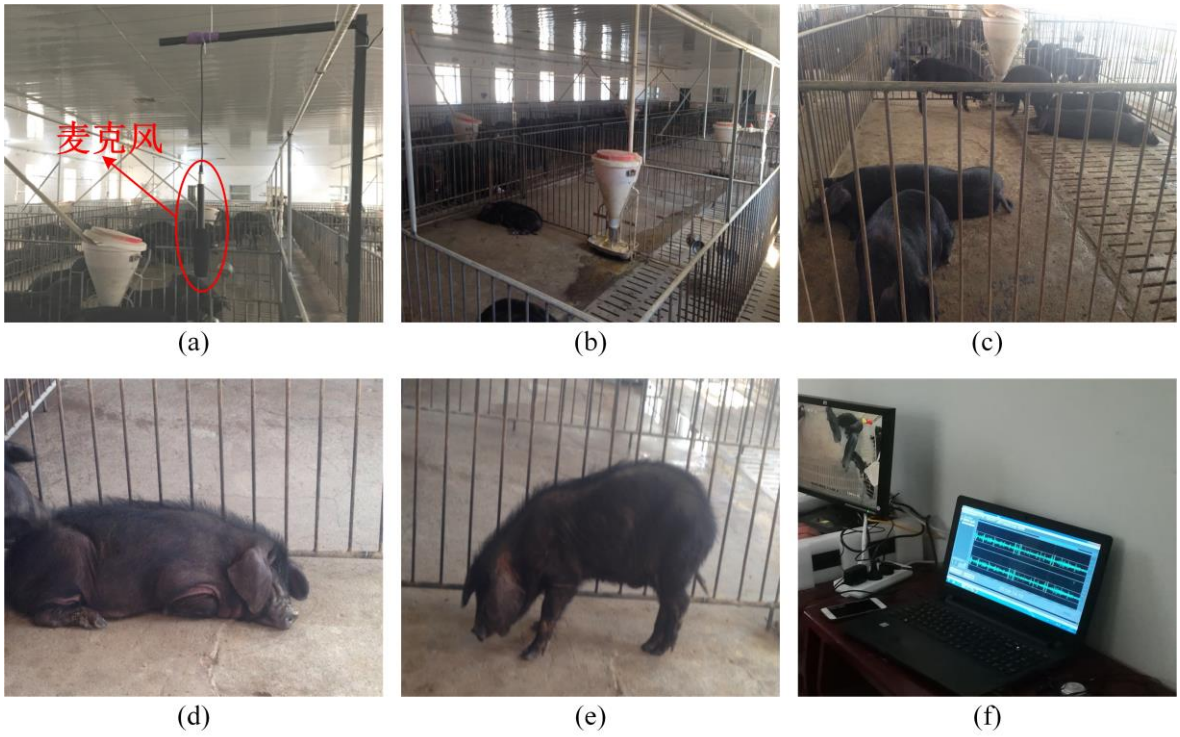


图 2-2 猪舍环境及设备的布置

Fig.2-2 Pig house environment and equipment layout

2.2 连续复杂声音数据集的建立和标注

在兽医的帮助下，使用“Cool Edit Pro 2.1”软件从原始的音频文件中手动分割并截取连续声音片段，然后进一步的标注每个咳嗽的开始时间和结束时间。数据集的组成如表 2-1 所示。数据集由两部分组成，第一部分为连续咳嗽片段，每段声音 7-40 秒，共 316 段，包括大量的咳嗽和少量的非咳嗽。第二部分是从上午、下午、傍晚、夜间随机且均匀的挑选的连续声音片段，每段 10 分钟，共 25 段，包括大量的非咳嗽和少量的咳嗽。这两部分声音共包含 3408 个咳嗽和 3133 个非咳嗽，其中的 2898 个单咳共构成连咳 332 段。复杂咳嗽（与其他声音叠加的咳嗽）的占比约为五分之一。非咳嗽包括各种猪叫声、打鼾声、打喷嚏声、人说话声、工人清粪声等多种声音。

表 2-1 数据集的组成

Tab.2-1 Composition of the dataset

数据集	声音段的总数	每个声音段的时间长度	单个咳嗽的总数	单个非咳嗽的总数	连咳的总数
第一部分	316	7–40 s	3155	768	313
第二部分	25	10 min	253	2365	19
总计	341	--	3408	3133	332

中国知网 https://www.cnki.net

2.3 数据分析与描述

2.3.1 数据的复杂性说明

图 2-3 展示了两段正常情况的连续咳嗽声音波形图，其中，子图(a)包含 7 个咳嗽，子图(b)包含 11 个咳嗽，咳嗽的位置如图中红色数字所示。子图(a)表示的声音信号距离麦克风较近，咳嗽声音强度较高，信噪比较高。子图(b)表示的声音信号距离麦克风较远，咳嗽声音强度较低，信噪比较低。尽管这两段声音信号的信噪比有高有低，但是由于咳嗽声音信号较为规则，且无声音叠加的情况，因此很容易取得较高的检测准确率。

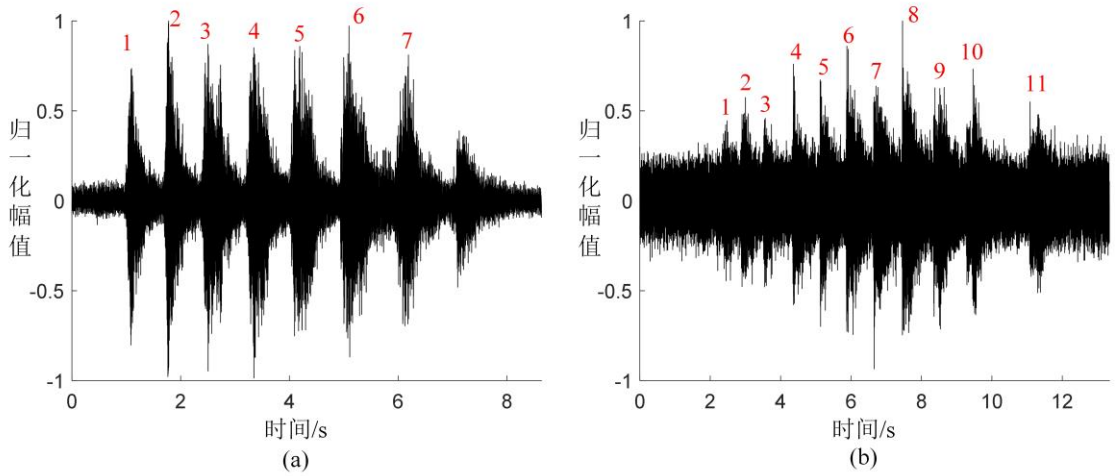
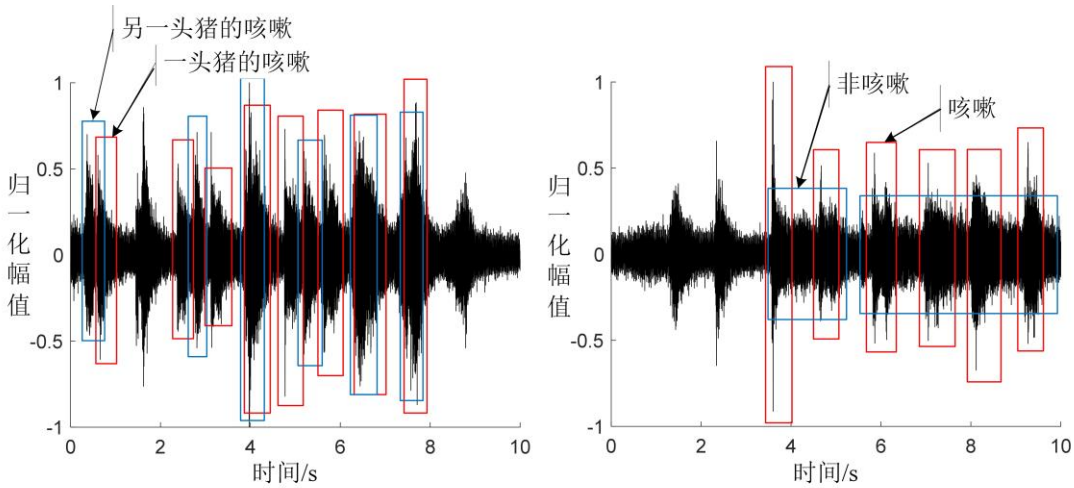


图 2-3 正常情况下猪连续咳嗽波形图

Fig.2-3 Waveform of pig continuous coughs in normal condition

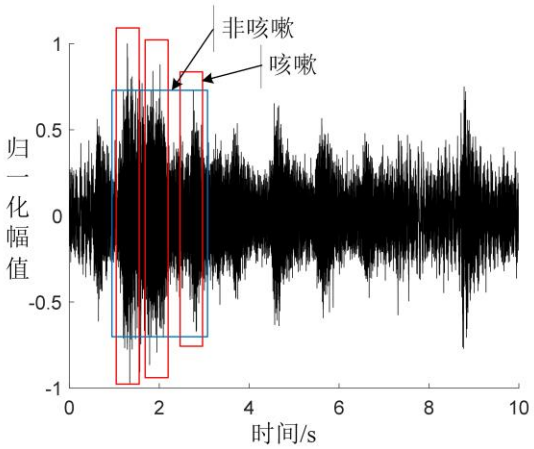
大型猪舍的养殖密度较高，生猪数量较多。猪的发声频率较高，经常会发出各种不同的声音，同时经常因撕咬和打斗而尖叫。同时，猪舍的机械噪声也比较大。复杂的猪舍环境给猪咳嗽识别带来了很大的挑战。猪咳嗽的复杂情况整体来说包括三种，如图 2-4 所示。其中，子图(a)表示两头猪连续咳嗽声音的叠加，图中红色方框表示一头猪的咳嗽，蓝色方框表示另一头猪的咳嗽。此时，相邻的两个咳嗽很容易被检测为一个咳嗽，导致咳嗽的漏检。子图(b)表示咳嗽和强度较弱的非咳嗽的叠加，图中红色方框表示咳嗽，蓝色方框表示非咳嗽。根据咳嗽叠加区域的不同可分为部分叠加和完全叠加两种情况，且可能会叠加各种不同的非咳嗽声音。此时，传统的端点检测算法可能会导致咳嗽的漏检。同时，声音的叠加也会影响咳嗽的分类准确率。子图(c)表示咳嗽和强度较强的非咳嗽的叠加。这种情况下的检测较为困难，当咳嗽的叠加区域为完全叠加且非咳嗽的强度远大于咳嗽时，很难成功检测。

中国知网 https://www.cnki.net



（a）两头猪连续咳嗽的叠加
(a) Overlap of two pigs' continuous coughs

（b）咳嗽和强度较弱的非咳嗽的叠加
(b) Overlap of coughs and weak noncoughs



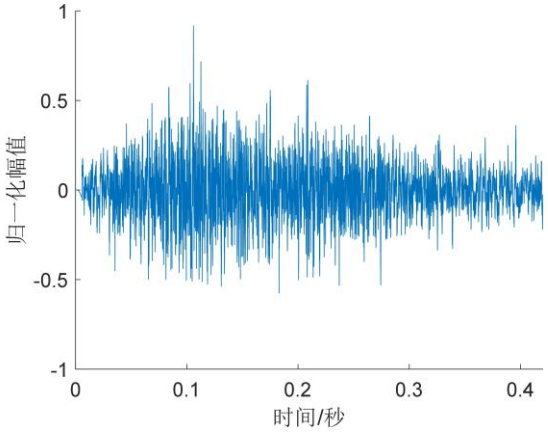
（c）咳嗽和强度较强的非咳嗽的叠加
(c) Overlap of coughs and strong noncoughs

图 2-4 复杂猪咳嗽声示例
Fig.2-4 Examples of complex pig coughs

2.3.2 数据的时频统计特征分析

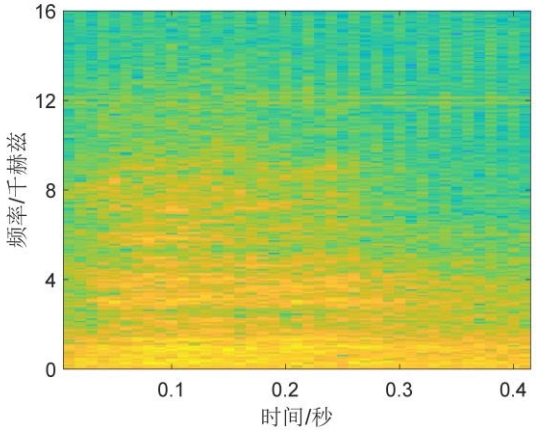
为更好的描述数据，本文对单个声音片段的时频统计特征进行了分析。部分声音的波形图和语谱图如图 2-5 所示，其中，语谱图的横坐标为时间，纵坐标为频率，颜色的深浅表示功率的大小，可以反映声音信号的时域和频域信息。由于非咳嗽种类众多，因此这里只选取了几个比较常见的非咳嗽进行展示，包括呻吟、尖叫和敲击声。

中国知网 https://www.cnki.net



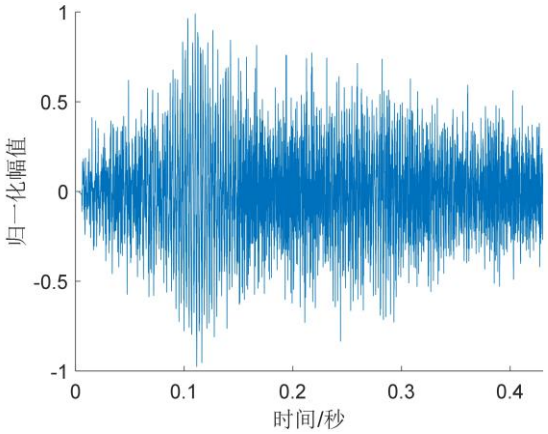
（a_1）咳嗽声音波形图

(a_1) The waveform of cough



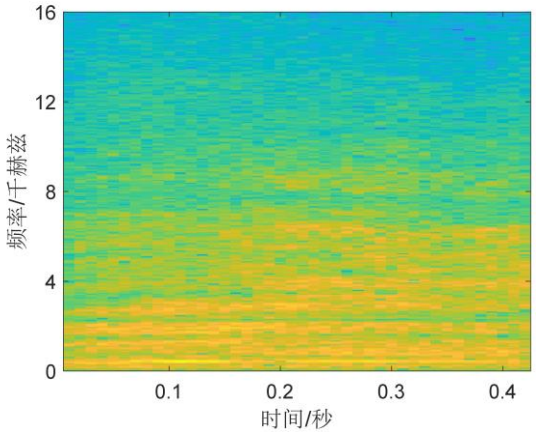
（a_2）咳嗽声音语谱图

(a_2) The spectrogram of cough



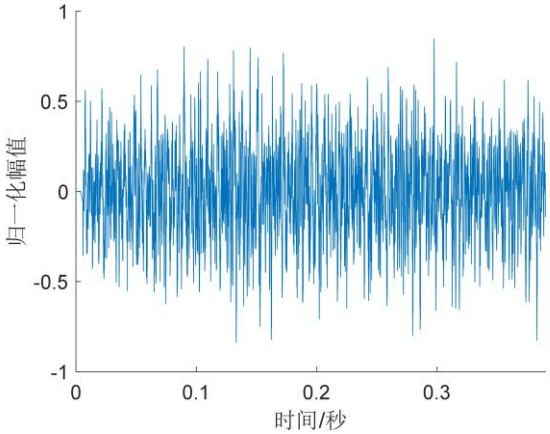
（b_1）复杂咳嗽声音波形图

(b_1) The waveform of complex cough



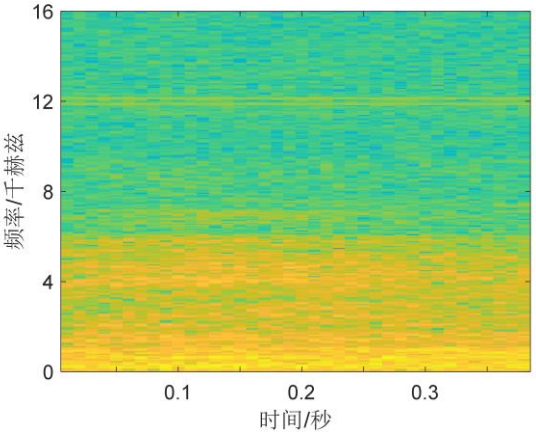
（b_2）复杂咳嗽声音语谱图

(b_2) The spectrogram of complex cough



（c_1）呻吟声音波形图

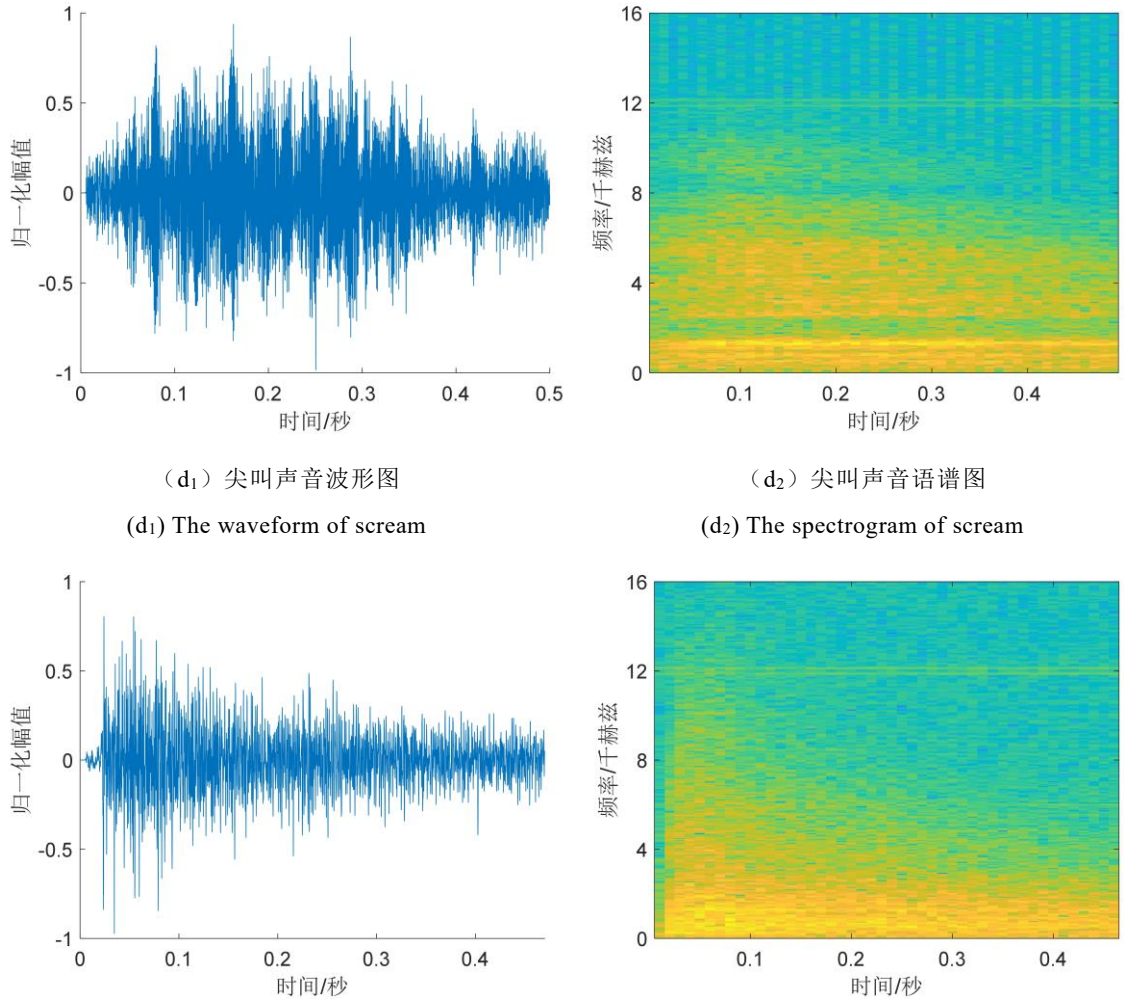
(c_1) The waveform of groan



（c_2）呻吟声音语谱图

(c_2) The spectrogram of groan

中国知网 https://www.cnki.net



（d_1）尖叫声音波形图

(d_1) The waveform of scream

（d_2）尖叫声音语谱图

(d_2) The spectrogram of scream

（e_1）敲击声音波形图

(e_1) The waveform of knocking

（e_2）敲击声音语谱图

(e_2) The spectrogram of knocking

图 2-5 部分声音的波形图和语谱图示例

Fig.2-5 Examples of waveform and spectrogram of partial sound

根据现有研究的方法，本文对声音数据进行了统计分析，统计特征包括持续时间和峰值频率的最大值（Max）、最小值（Min）、均值（Mean）和标准差（S.D.）[78, 79]。为避免带外噪声的干扰，首先对声音进行滤波，然后在进行统计分析，滤波器带宽为 100-16000 Hz。统计结果如表 2-2 和图 2-6 所示，其中，“咳嗽”和“非咳嗽”表示手动标记的所有的咳嗽和非咳嗽，图 2-6 中的蓝色柱体为均值，黑色竖线为标准差，表示数据的整体波动范围。根据统计结果可以得知，不同种类的声音在时域和频域上存在一定的差异与重合。咳嗽的持续时间相对较低，均值仅为 0.48 秒，明显低于非咳嗽，但与敲击声有较大的重合。尖叫声的持续时间和峰值频率在多种声音中均为最高。敲击声的持续时间和峰值频率相对较低，与咳嗽的重合度较高。整体来说，咳嗽与不同非咳嗽峰值频率的重合度较高，与某些种类的非咳嗽持续时间也存在很高的重合度。

中国知网 https://www.cnki.net

表 2-2 不同声音的时频特征统计结果

Tab.2-2 Statistical results of time-frequency features of different sounds

声音的	持续时间				峰值频率			
种类	Min(s)	Max(s)	Mean(s)	S. D.	Min(Hz)	Max(Hz)	Mean(Hz)	S. D.
咳嗽	0.22	0.97	0.48	0.13	139.97	4478.91	613.56	424.41
非咳嗽	0.19	1.79	0.88	0.40	139.97	6933.69	823.21	654.09
呻吟	0.20	1.63	0.90	0.38	139.97	1453.49	541.17	319.58
尖叫	0.26	1.76	1.02	0.44	215.33	3090.01	1368.35	494.11
敲击声	0.19	1.62	0.59	0.31	150.73	2971.58	569.09	473.17

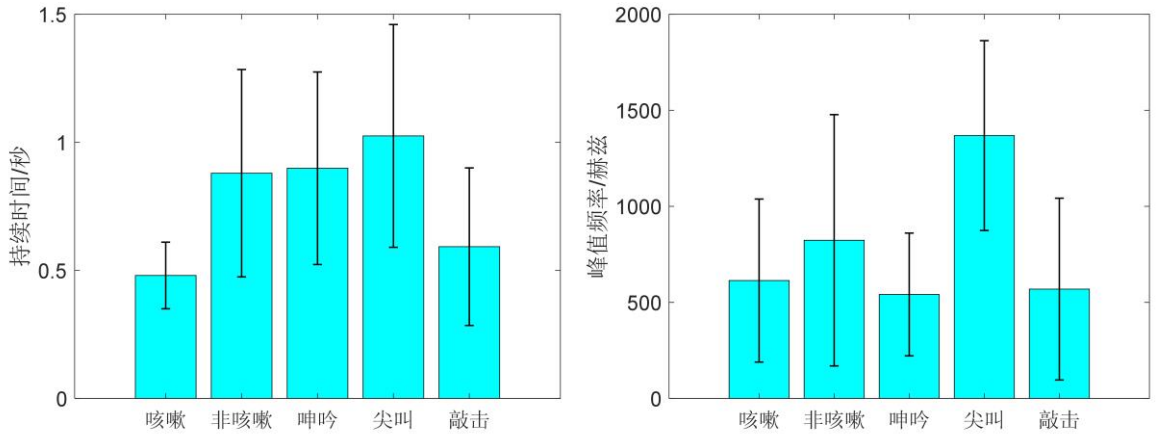


图 2-6 不同声音的时频特征统计结果

Fig.2-6 Statistical results of time-frequency features of different sounds

为进一步了解咳嗽和非咳嗽时频特征的具体分布情况，本文对其进行了统计，统计结果如图 2-7 所示。根据持续时间的分布情况可以得知，咳嗽的分布范围较小，数据分布较为集中，而非咳嗽的数据分布较为分散。咳嗽的持续时间主要集中在 0.2-0.8 秒之间，该区间内的咳嗽占咳嗽总数的 97.2%，对应的，位于该区间内的非咳嗽数量占非咳嗽总数的 48.7%，另外，咳嗽持续时间的最大值为 0.97 秒，也即，在进行咳嗽声音自动检测时可以通过判断持续时间来剔除部分非咳嗽，然而对于 0.2-0.97 秒之间的声音段则无法通过持续时间进行区分。根据峰值频率的分布情况可以得知，咳嗽的峰值频率主要集中在 200-600 赫兹之间，该区间内的咳嗽占总数的 65.5%，而非咳嗽的峰值频率较为分散，其中，在 200-600 赫兹之间占比为 38.3%。整体上，咳嗽的峰值频率分布更为集中，非咳嗽的分布相对较为分散，然而咳嗽和非咳嗽的峰值频率在不同区间均有着不同程度的重合，因此无法通过判断峰值频率来区分咳嗽和非咳嗽。

中国知网 https://www.cnki.net

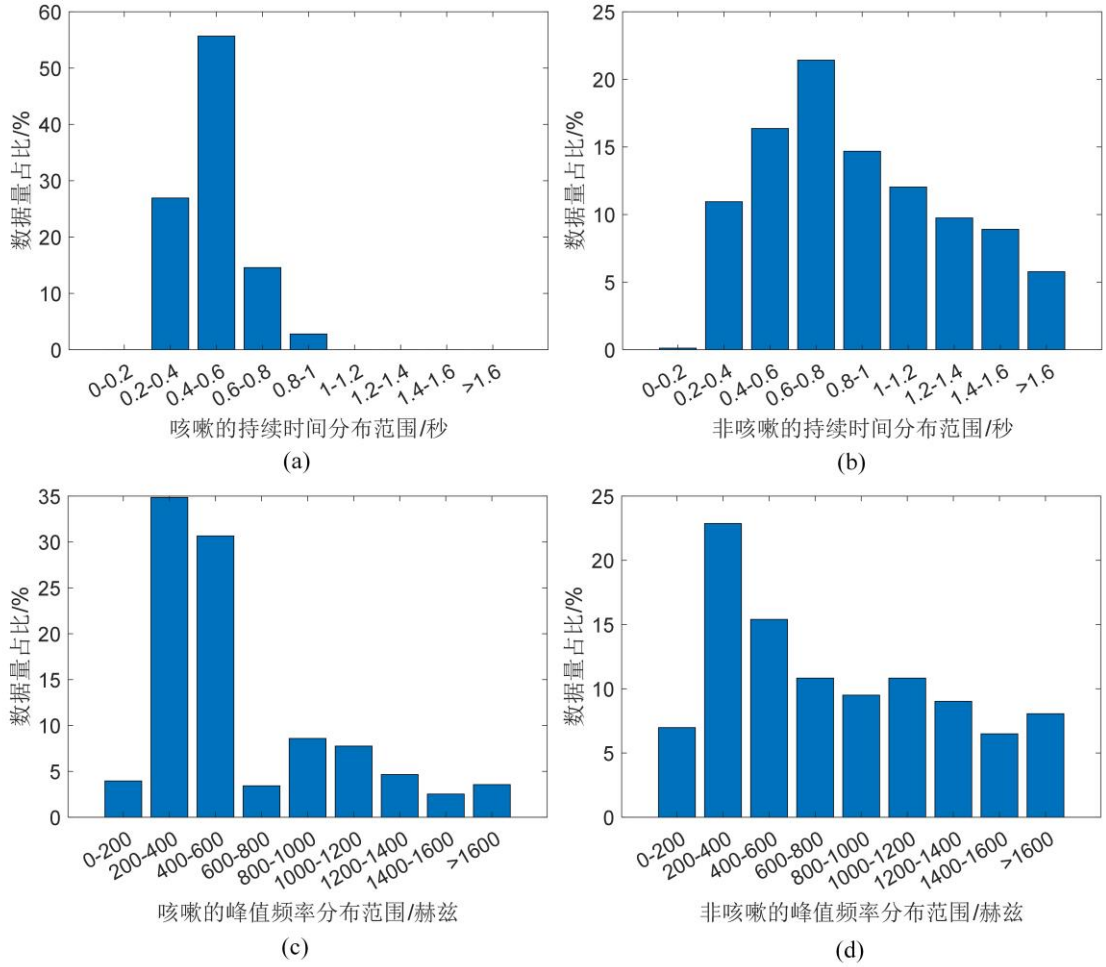


图 2-7 咳嗽和非咳嗽统计特征的数据分布情况

Fig.2-7 Data distribution of statistical features of cough and noncough

2.4 猪咳嗽声自动检测评价指标

猪咳嗽声自动检测评价指标结构图如图 2-8 所示。猪咳嗽声自动检测的步骤包括端点检测和分类，因此分别使用端点检测评价指标和分类评价指标对其进行评价。此外，本文在自动检测结果的基础上进一步区分了单咳和连咳，因此评价指标还包括连咳识别的评价指标，连咳识别评价指标同时考虑了端点检测的误检和分类的误识别。

中国知网 https://www.cnki.net

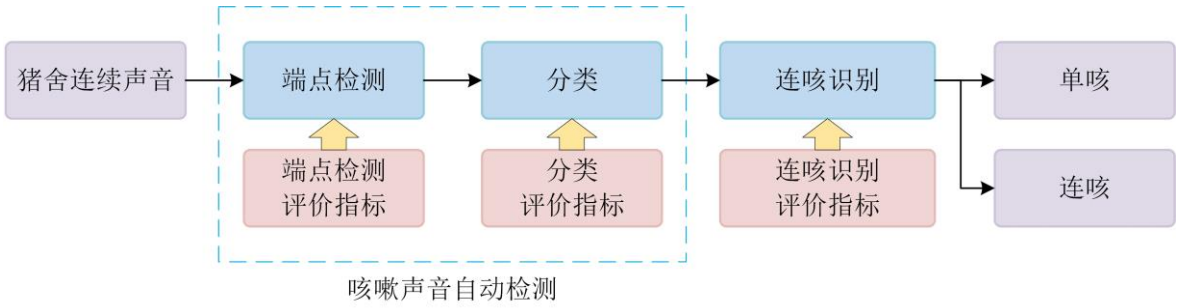


图 2-8 评价指标结构图

Fig.2-8 The structure diagram of evaluation metrics

2.4.1 端点检测评价指标

本文使用咳嗽检出率（P_{wd}）、漏帧率（P_{miss}）、误帧率（P_{false}）和帧准确率（P_{d}）对端点检测性能进行评价。令 N_f 表示所有咳嗽声音段的总帧数，N_{miss} 表示咳嗽的漏帧数，N_{false} 表示咳嗽的误帧数，则 P_{miss}，P_{false} 和 P_d 的定义如下：

$$P_{miss} = N_{miss}/N_f \tag{2-1}$$

$$P_{false} = N_{false}/N_f \tag{2-2}$$

$$P_d = 1 - P_{miss} - P_{false} \tag{2-3}$$

除此之外，使用咳嗽检出率用来评价单个咳嗽的准确率。令 N_{wd} 表示检出咳嗽的个数，N_w 表示连续声音数据中咳嗽的总个数，则 P_{wd} 定义如下：

$$P_{wd} = N_{wd}/N_w \tag{2-4}$$

2.4.2 分类评价指标

使用四个常见的指标来对分类性能进行评价，包括准确率（accuracy），召回率（recall），精确率（precision）和 F1 分数（F1_score）。令咳嗽被正确识别为咳嗽的个数为 TP，非咳嗽被正确识别为非咳嗽的个数为 TN，咳嗽被误识别为非咳嗽的个数为 FN，非咳嗽被误识别为咳嗽的个数为 FP，则四个指标的定义如下：

$$Accuracy = (TP + TN)/(TP + TN + FP + FN) \tag{2-5}$$

$$Recall = TP/(TP + FN) \tag{2-6}$$

$$Precision = TP/(TP + FP) \tag{2-7}$$

$$F1_score = 2 \times (Precision \times Recall)/(Precision + Recall) \tag{2-8}$$

中国知网 https://www.cnki.net

2.4.3 连咳识别评价指标

本文使用连续语音识别中常用的指标词错误率（*WER*）来对连咳识别进行评价。假定有一段连咳的标记为（咳嗽，咳嗽，咳嗽，咳嗽），如果检测结果为（咳嗽，咳嗽，咳嗽，咳嗽，咳嗽），则表明有一个插入错误，如果检测结果为（咳嗽，咳嗽，非咳嗽，咳嗽），则表明有一个替代错误，若检测结果为（咳嗽，咳嗽，咳嗽），则表明有一个删除错误。令 S 表示替代次数，I 表示插入次数，D 表示删除次数，N_c 表示连咳中单个咳嗽的总个数，则 *WER* 定义如下：

$$WER = (S + I + D)/N_c \tag{2-9}$$

此外，本文还定义了连咳的漏检率（P_{mc}）、误检率（P_{fc}）以及检测准确率（P_{dc}），来评价连咳的识别性能。本文假定，在一段连咳中即使一个或多个单咳识别错误，只要这段连咳被正确检测，则认为识别成功。例如：假设有一段连咳标记为（咳嗽，咳嗽，咳嗽，咳嗽，咳嗽，咳嗽，咳嗽），如果这段连咳被错误检测为（咳嗽，咳嗽，咳嗽，咳嗽，非咳嗽，非咳嗽），尽管只检测出了前四个咳嗽，本文仍假定这段连咳识别正确。令 N_{cc} 表示连咳的总数，N_{mc} 表示漏检的连咳个数，N_{fc} 表示误检的连咳个数，则连咳评价指标的定义如下：

$$P_{mc} = N_{mc}/N_{cc} \tag{2-10}$$

$$P_{fc} = N_{fc}/N_{cc} \tag{2-11}$$

$$P_{dc} = 1 - P_{mc} - P_{fc} \tag{2-12}$$

2.5 本章小结

本章分别介绍了数据的采集过程和猪舍环境、数据集的构建和标注、数据的分析以及模型的评价指标。

（1）详细介绍了原始数据的采集过程，并对猪舍环境和数据采集相关的参数进行了详细的阐述。

（2）构建了包含 3408 个咳嗽和 3133 个非咳嗽的连续声音数据集，该数据集用于后续端点检测算法和分类算法的研究。

（3）对数据进行了细致的分析，包括复杂性分析和时频特征分析。首先分析了数据的复杂性，对不同复杂情况可能会引起的技术难点进行了分析。然后分析了数据的时频特征，统计了数据的持续时间和峰值频率，统计结果表明咳嗽与非咳嗽的持续时间和峰值频率具有一定的差异性，但是也具有较高的重叠。

（4）介绍了模型的评价指标，包括端点检测、分类和连咳识别的评价指标。

中国知网 https://www.cnki.net

3. 复杂猪舍环境内声音端点检测方法研究

端点检测是猪咳嗽声自动检测的第一步，目的是确定一段连续声音中每个有声段的开始位置和结束位置，然后将其截取出来，为后续的分类做准备。本章的目的是实现复杂环境下的高精度端点检测，为实现这个目的，分别研究基于不同特征的双门限法，对比不同特征的性能，然后提出了基于自适应动态门限的多重端点检测算法，根据实际猪舍环境的复杂性自适应的设置多个门限，实现复杂环境下的高精度端点检测。下面分别介绍双门限法和本文提出的基于自适应动态门限的多重端点检测算法。

3.1 双门限端点检测方法

双门限端点检测方法的基本流程是对声音信号进行分帧，并提取每一帧信号的某种特征，基于该特征选取一个高门限和一个低门限，根据这两个门限确定有声段和噪声段。下面详细介绍双门限法常用的特征和双门限法的方法流程。

3.1.1 端点检测特征

常见的双门限法所用的特征有很多，包括能量、过零率、能零比、能熵比、谱距离等[80, 81]，然而由于猪舍声音信号的多变性和非平稳性，导致很多特征无法适用于复杂的猪舍环境。经研究，本文选取了 6 种特征用于双门限端点检测，分别为能量、频带方差、MFCC 倒谱距离、MFCC 的第一维、频谱通量和频谱斜率，下面分别介绍这几种特征。

3.1.1.1 能量

能量是声音信号中的一个非常经典的特征，能够反映声音幅值的大小。设声音信号分帧时每帧的时间长度为 L，声音信号第 i 帧的序列为 $y_i(n)$，则第 i 帧的短时能量 E_i 的计算公式如下：

$$E_i = \sum_{n=1}^{L} y_i^2(n) \tag{3-1}$$

3.1.1.2 频带方差

有声段和噪声段在频域中的差异较大，一般来说，噪声段的能量数值较小，不同频带的能量分布较为均匀，而有声段的能量数值较大，不同频带的能量分布差异较大、波动较大，因此可以通过计算频带的方差来区分有声段和噪声段。设声音信号经过分帧后第 i 帧的序列为 $y_i(n)$，首先对这一帧声音信号进行傅里叶变换，得到其频谱 $Y_i(n)$，设 $Y_i(n)=\{Y_i(1), Y_i(2), \dots, Y_i(N)\}$，则这一帧信号幅值的均值为：

$$E_i = \frac{1}{N}\sum_{k=1}^{N} |Y_i(k)| \tag{3-2}$$

中国知网 https://www.cnki.net

则频带方差为：

$$D_i = \frac{1}{N-1}\sum_{k=1}^{N}[|Y_i(k)| - E_i]^2 \tag{3-3}$$

3.1.1.3 MFCC 倒谱距离

MFCC 是经典的声学特征之一，MFCC 倒谱距离的原理如下：对声音信号进行分帧后，提取每一帧信号的 MFCC 特征，以噪声帧的 MFCC 特征为基准，计算每一帧声音信号与噪声帧 MFCC 的距离，距离较大的即为有声段，而距离较小的为噪声段。

3.1.1.4 MFCC 的第一维

与 MFCC 其它维的特征相比，第一维特征能够更好的追踪有声段，对有声段和噪声段具有更好的区分性[12]。MFCC 的第一维特征与能量有一定的相似之处，在有声段中数值较大，而在噪声段中数值较小。

3.1.1.5 频谱通量

频谱通量表示相邻两帧信号的频谱的差异。噪声段较为平稳，频谱随时间的波动较小，相邻两帧频谱的差异较小，对应的频谱通量较小。而有声段的波动较大，频谱随时间的波动较为明显，相邻两帧的差异较大，对应的频谱通量较大。设声音信号经过分帧后第 i 帧的序列为 $y_i(n)$，首先对这一帧声音信号进行傅里叶变换，得到其频谱 $Y_i(n)$，设 $Y_i(n)=\{Y_i(1), Y_i(2), \dots, Y_i(N)\}$，则这一帧信号的频谱通量为：

$$F_i = \sqrt{\sum_{k=1}^{N}\left(Y_i(k) - Y_{i-1}(k)\right)^2} \tag{3-4}$$

3.1.1.6 频谱斜率

频谱斜率表示声音在频谱上的能量随频率变化的速率或趋势，描述了声音信号在频域上的斜率或变化率。噪声段较为平稳，声音的能量在不同频带的分布较为均匀，能量随频带的变化较小。而有声段的能量在不同频带的分布较为分散，多集中在某个或某几个频带区间，能量随频带的变化较为明显。设声音信号经过分帧后第 i 帧的序列为 $y_i(n)$，首先对这一帧声音信号进行傅里叶变换，得到其频谱 $Y_i(n)$，设 $Y_i(n)=\{Y_i(1), Y_i(2), \dots, Y_i(N)\}$，对应的频率为 $\{f_i(1), f_i(2), \dots, f_i(N)\}$，$Y_i(n)$的均值为 E_y，频率的均值为 E_f，则这一帧信号的频谱斜率为：

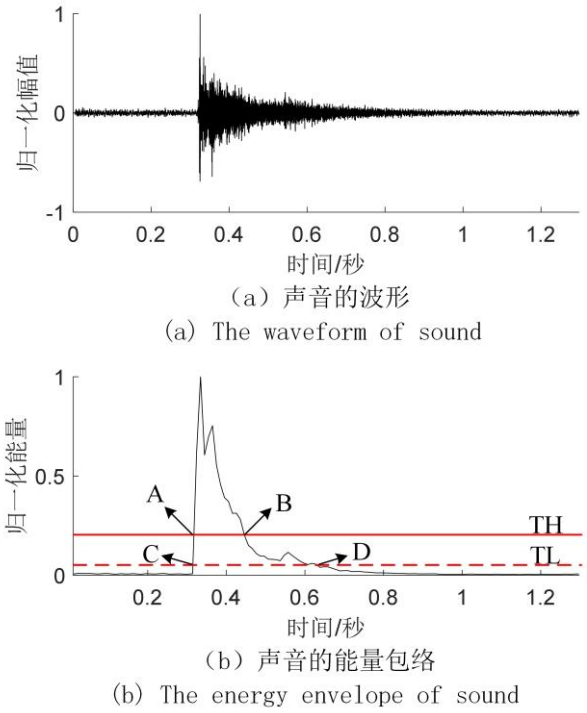
$$S_i = \frac{\sum_{k=1}^{N}\left(f_k - E_f\right)\left(Y_k - E_y\right)}{\sum_{k=1}^{N}\left(f_k - E_f\right)^2} \tag{3-5}$$

3.1.2 双门限端点检测方法流程

为清晰直观的阐述双门限端点检测算法的流程，本文以基于能量的双门限法为例，选取了一个较为简单的声音信号来进行阐述，方法流程如图 3-1 所示，其中，子图(a)是该声音信号的原始波形图，子图(b)表示该信号分帧后计算每帧能量得到的能量包络图。传统方法需要

中国知网 https://www.cnki.net

设置两个门限，高门限 TH，以及低门限 TL，如子图(b)所示。首先通过高门限对声音信号进行一次粗判，高于高门限的一定是有声段，经过这次粗判，可以得到 A、B 两个端点。然后从 A，B 分别往两端搜索，直至到达低门限所在的位置，也就是图中的 C、D 两点，C 和 D 就是该有声段的起始位置和结束位置[80]。



（a）声音的波形
(a) The waveform of sound

（b）声音的能量包络
(b) The energy envelope of sound

图 3-1 双门限端点检测方法示意图

Fig.3-1 Schematic diagram of double threshold voice activity detection method

3.2 基于自适应动态门限的多重端点检测算法

尽管传统的双门限法在正常情况下能够取得较好的效果，但是复杂环境下该方法具有两个非常明显的局限性：（1）实际猪舍内的噪声是非稳态的，且噪声环境经常发生变化，导致有声段信号的信噪比随时间的波动较大。（2）一段连续咳嗽中相邻两个咳嗽之间的静音段很短，受叠加情况的影响会导致这段静音段的幅值明显高于背景噪声。这可能会导致两种结果：（1）设置较高的门限可能会导致部分低信噪比声音的漏检。（2）设置较低的门限可能会导致连续的多个声音段被检测为一个有声段。

为解决以上问题，本文提出了基于自适应动态门限的多重端点检测算法，算法流程如图 3-2 所示。图中 K 用来记录双门限端点检测的总次数，i 用来记录当前是第几次双门限端点检测，P_K 表示门限搜索指标，TH_i 和 TL_i 分别表示第 i 次端点检测的高门限和低门限，对应的 b_i 和 a_i 表示 TH_i 和 TL_i 的门限参数，T 表示单个声音段的时间长度，T_{max} 是一个统计量，表示单个咳嗽的最大时间长度。下面详细介绍该算法。

中国知网 https://www.cnki.net

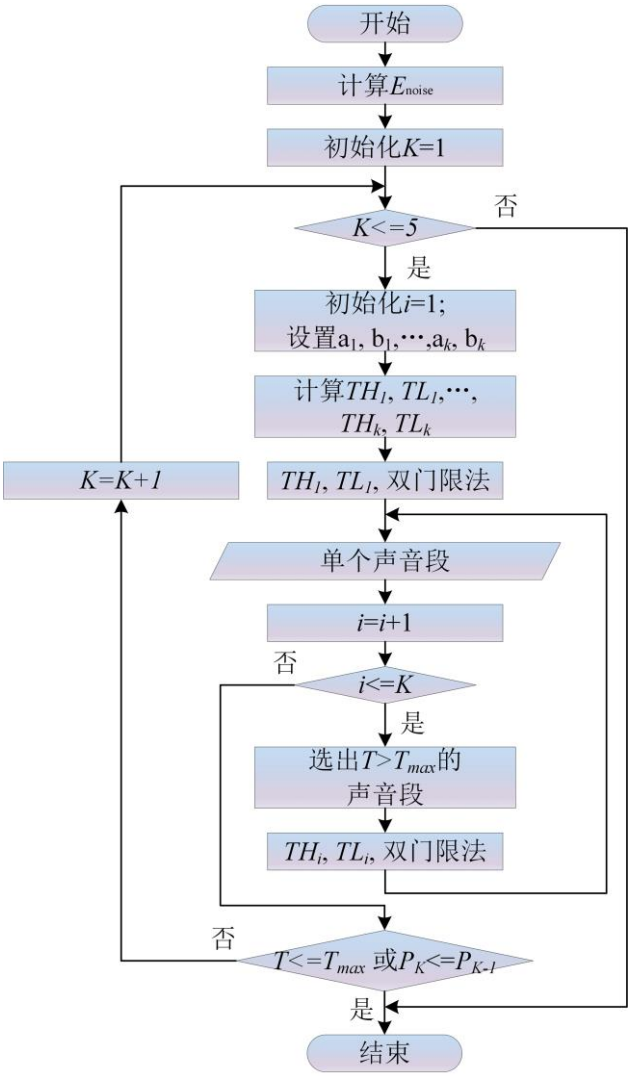


图 3-2 本文端点检测方法的算法流程

Fig.3-2 The algorithm flow of proposed voice activity detection method

传统的双门限法需要设置两个门限，高门限 *TH* 和低门限 *TL*，实际应用中一般采用动态门限的方式来确定 *TH* 和 *TL*。令前 *N* 帧背景噪声特征（如能量）的平均值为 E_{noise}，则：

$$TH = b \times E_{noise} \tag{3-6}$$

$$TL = a \times E_{noise} \tag{3-7}$$

其中 a 和 b 为门限参数。首先设置较低的门限参数 a_1 和 b_1，对连续声音进行第一次双门限端点检测，得到单个声音片段。判断每个声音片段的时长，如果所有声音片段的时长都小于 T_{max}，则结束。否则重新设置更高的门限参数 a_2 和 b_2，并对持续时间大于 T_{max} 的声音段进行第二次双门限端点检测，如果端点检测准确率有所提高，则继续上述步骤，直到所有声音片段的时长都小于 T_{max} 或端点检测的次数大于 5。其中，T_{max} 为单个咳嗽的最大持续时间，根据表 2-2 可知 T_{max} 为 0.97 秒。本文使用线性搜索法来优化所有门限参数 a 和 b。

经过研究，发现漏帧对分类效果的影响远高于误帧，因此本文希望端点检测能够尽可能

中国知网 https://www.cnki.net

的保证较低的漏帧率，并允许存在一定的误帧率，使用帧准确率 P_{d} 作为门限参数搜索指标无法准确反映有声段的漏帧和误帧情况。因此，本文针对门限参数的搜索定义了一个新的指标，计算公式如下：

$$P_0 = 1 - P_{miss} - 0.2 * P_{false} \tag{3-8}$$

其中 P_{miss} 和 P_{false} 分别表示漏帧率和误帧率，如公式 2-1 和 2-2 所示。由于实际猪舍中的背景噪声是一直在变化的，因此需要对噪声帧的特征值 E_{noise} 进行实时的更新，令当前噪声帧的特征值为 E，则 E_{noise} 更新为：

$$E_{noise} = \alpha \times E_{noise} + (1 - \alpha) \times E \tag{3-9}$$

其中α表示更新速率，一般取值为[0.9, 0.98]，α越小表示更新速率越快。

3.3 实验结果与分析

本小节对实验的结果进行分析。首先对不同端点检测方法的性能进行分析，然后通过举例，详细介绍了简单情况和复杂情况下每种端点检测方法的识别效果，以此来说明传统方法的局限性，以及本文方法在复杂环境下的优势。最后通过举例，对本文方法漏检的原因进行分析。

3.3.1 实验参数设置

本文取前 50 帧噪声段的特征值作为 E_{noise} 的初始值，公式 3-9 中的更新速率α取 0.92。提取端点检测特征之后，对特征进行最大值归一化以及 5 点中值滤波平滑处理。根据表 2-2 中的统计结果可以得知，咳嗽的时间长度为 0.22-0.97 秒，考虑到猪舍环境的复杂性，本文将有效时间长度设置为 0.2-1.1 秒，并剔除端点检测结果中不在此范围内的声音段。

3.3.2 不同端点检测方法的性能对比

不同端点检测方法的检测结果如表 3-1 所示。对比双门限法的结果可以得知，传统的双门限法在复杂环境下均表现出非常明显的局限性，咳嗽检出率非常低，其中效果最好的特征为能量，咳嗽检出率为 75.8%，效果最差的为 MFCC 的第一维（MFCC(1)），咳嗽检出率仅为 62.0%，其余方法的咳嗽检出率在 69.2%-75.3%之间。基于此结论，选取能量作为本文基于自适应动态门限的多重端点检测方法的特征，经过实验，得到了三组门限值：（2，2.4），（5，5.5）和（15，16）。本文提出的方法实现了 97.6%的咳嗽检出率，明显高于传统方法。所提方法虽然误帧率略高，但漏帧率大大降低，帧检测准确率可以达到 66.7%。

中国知网 https://www.cnki.net

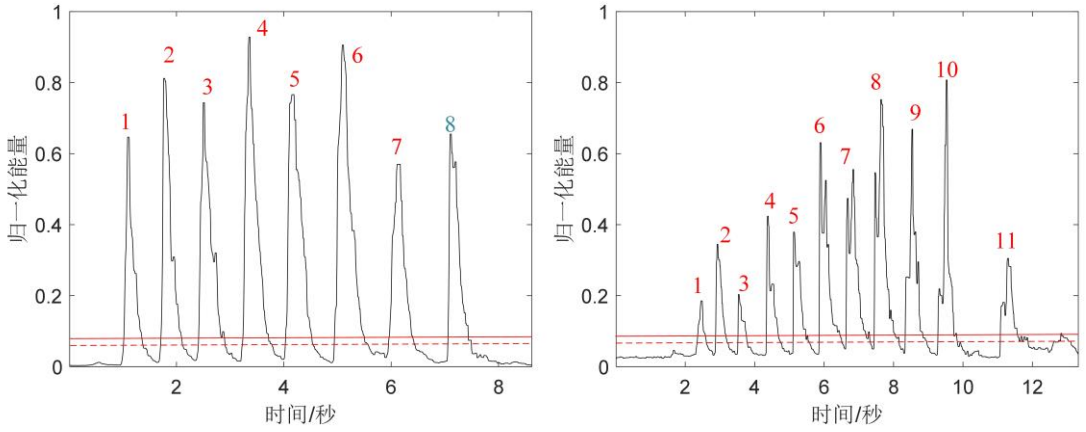
表 3-1 不同端点检测方法的性能对比

Tab.3-1 Performance comparison of different voice activity detection methods

方法	特征	P_{wd}	P_{miss}	P_{false}	P_d
双门限法	能量	75.8%	33.7%	13.0%	53.3%
双门限法	频带方差	75.3%	34.3%	12.5%	53.2%
双门限法	MFCC 倒谱距离	69.2%	43.3%	12.0%	44.7%
双门限法	MFCC(1)	62.0%	47.4%	14.9%	37.7%
双门限法	频谱通量	74.7%	37.0%	12.0%	51.0%
双门限法	频谱斜率	72.1%	35.5%	14.6%	49.9%
本文方法	能量	97.6%	13.3%	20.0%	66.7%

3.3.3 简单环境下不同端点检测方法的性能分析

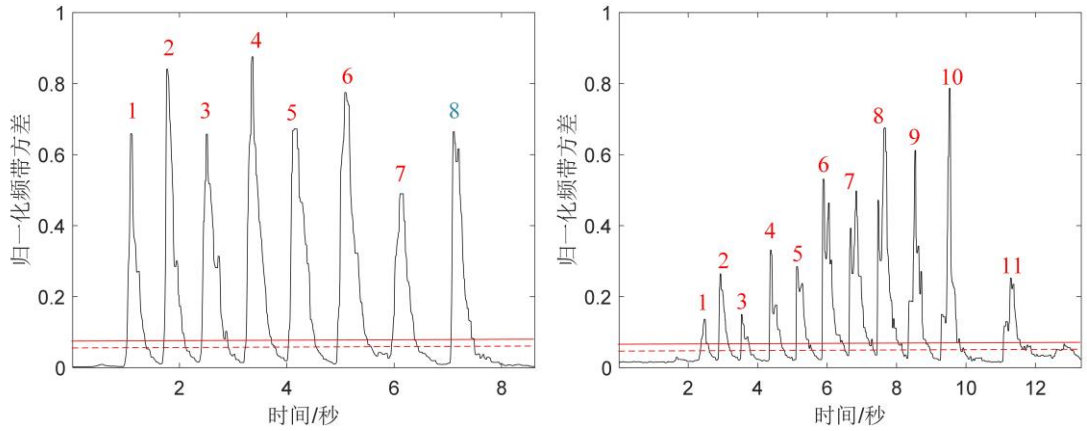
为进一步分析传统双门限法准确率低的原因，以及本文方法的优势，本章首先列举了简单环境下部分声音的检测效果。图 3-3 列举了图 2-3 对应的两段声音信号的特征图，其中左图表示的声音信噪比较高，右图较低，特征包括能量、频带方差、MFCC 倒谱距离、MFCC(1)、频谱通量和频谱斜率。图中展示了不同双门限法在简单环境下的检测效果，图中数字表示有声段的位置，其中红色数字表示咳嗽，蓝色数字表示非咳嗽，红色实线和红色虚线分别表示双门限法中的高门限和低门限。为更清晰的进行表述，图中使用直线表示门限值，不体现公式 3-9 中对门限值的实时更新，同时，在左图的 0.5 秒和右图的 12.5 秒左右有一段音量极低的有声段，本文不考虑这种极端情况。根据图中可以看出，尽管两段声音的信噪比有高有低，但是由于环境噪声较为平稳，且无声音叠加的情况，因此所有的双门限法均取得了较好的检测效果，图中所有的有声段均能成功检出。由此可知，在简单环境下，使用传统的双门限法即可取得很好的检测效果。



（a）基于能量的双门限法检测效果

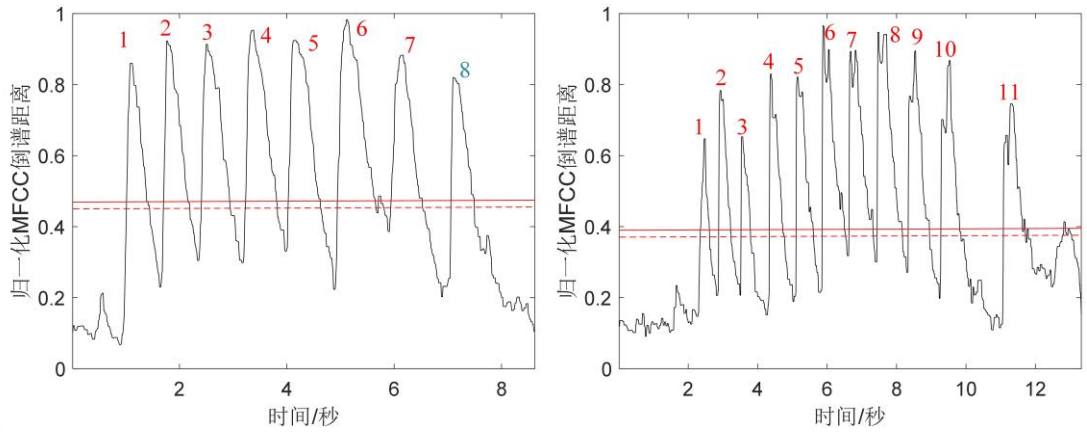
(a) Detection effect of double threshold method based on energy

中国知网 https://www.cnki.net



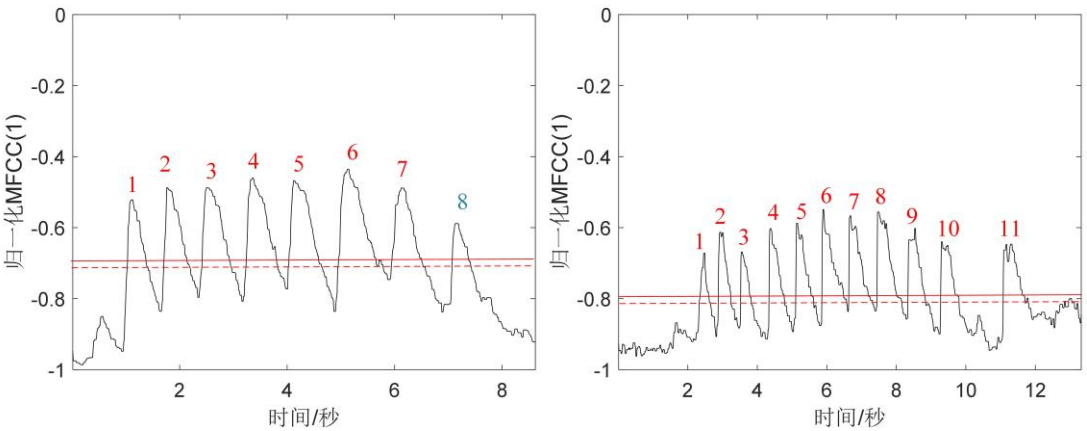
（b）基于频带方差的双门限法检测效果

(b) Detection effect of double threshold method based on frequency band variance



（c）基于 MFCC 倒谱距离的双门限法检测效果

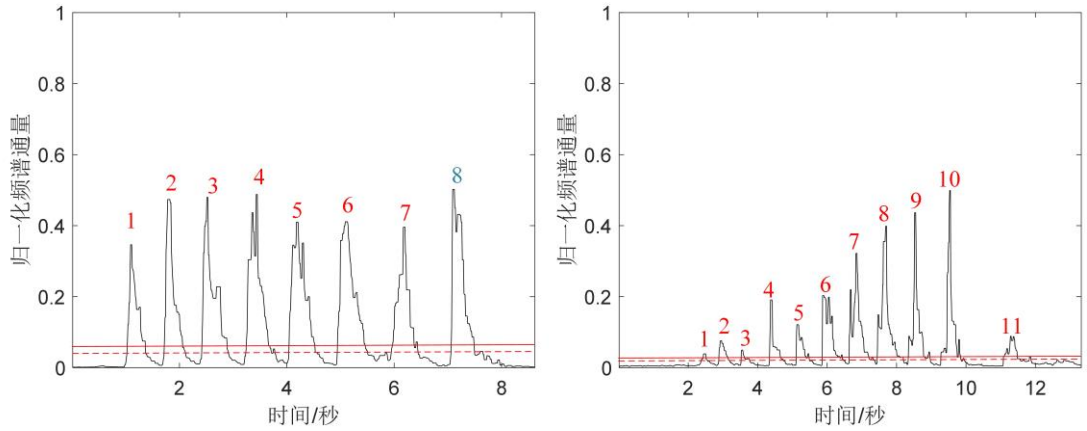
(c) Detection effect of double threshold method based on MFCC inverse spectral distance



（d）基于 MFCC(1)的双门限法检测效果

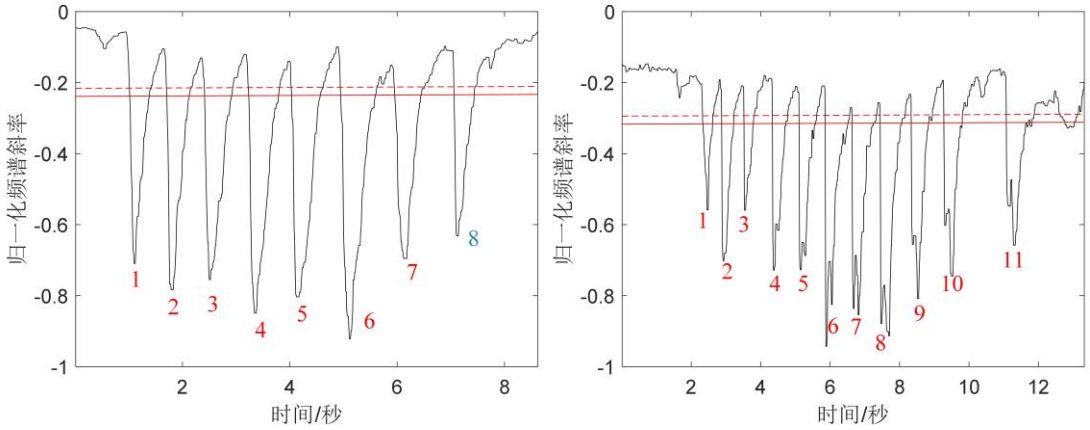
(d) Detection effect of double threshold method based on MFCC(1)

中国知网 https://www.cnki.net



（e）基于频谱通量的双门限法检测效果

(e) Detection effect of double threshold method based on spectral flux



（f）基于频谱斜率的双门限法检测效果

(f) Detection effect of double threshold method based on spectral slope

图 3-3 简单环境下不同端点检测方法的效果

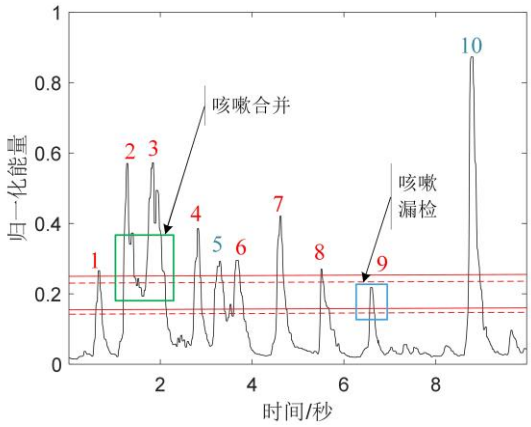
Fig.3-3 The effect of different voice activity detection methods in simple environment

3.3.4 复杂环境下不同端点检测方法的性能分析

为进一步验证复杂环境下不同端点检测方法的性能，这里选取了一段复杂音频作为示例，图 3-4 所示为不同端点检测方法在复杂环境下的检测效果，图中数字表示有声段的位置，其中红色数字表示咳嗽，蓝色数字表示非咳嗽，红色实线和红色虚线分别表示双门限法中的高门限和低门限。无论对于哪种特征，传统的双门限法只能选取一组门限，根据图中可以看出，较低的门限会导致多个声音被检测为一体，如图中绿色方框所示，较高的门限则会导致部分声音片段的漏检，如蓝色方框所示。而本文提出的端点检测方法可以根据复杂情况自适应的设置多个门限，来解决这一冲突，提高检测准确率。以子图(a)为例，首先设置一对较低的门限进行双门限法端点检测，此时 2、3 号有声段会检测为一体，其余有声段全部检出。2、3 号有声段构成的整体持续时间较长，长于咳嗽数据中的最大时长，因此针对该有声段，设置较

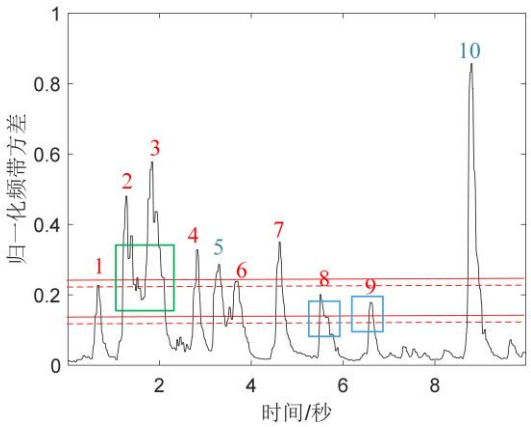
中国知网 https://www.cnki.net

高的门限对其进行第二次端点检测，将 2、3 号有声段分离，得到检测结果。



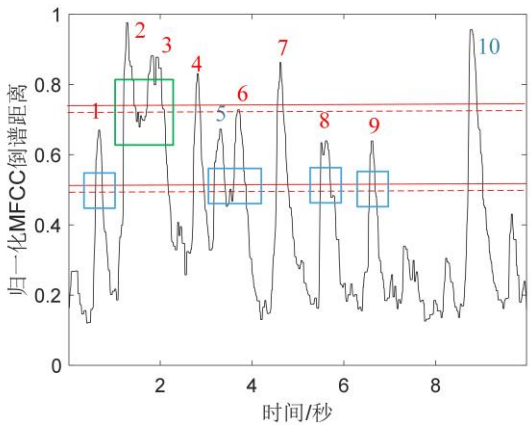
（a）基于能量的双门限法检测效果

(a) Detection effect of double threshold method based on energy



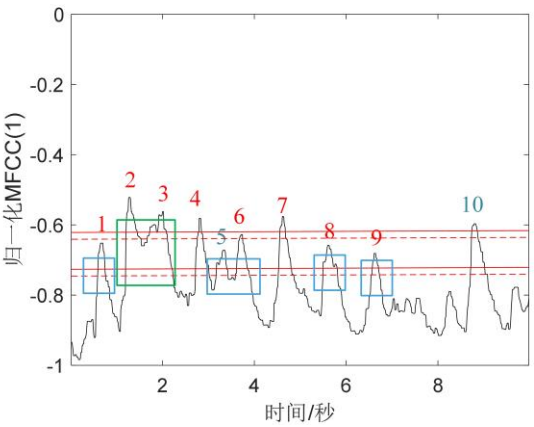
（b）基于频带方差的双门限法检测效果

(b) Detection effect of double threshold method based on frequency band variance



（c）基于 MFCC 倒谱距离的双门限法检测效果

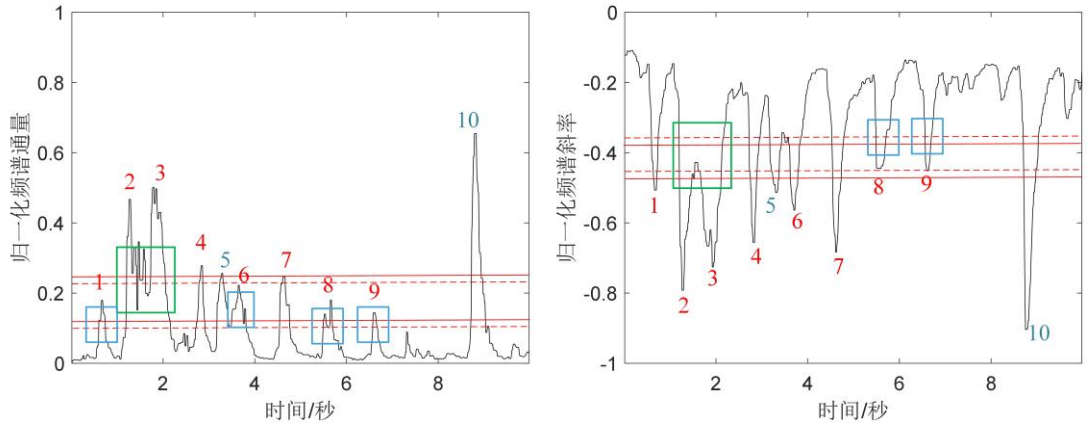
(c) Detection effect of double threshold method based on MFCC inverse spectral distance



（d）基于 MFCC(1)的双门限法检测效果

(d) Detection effect of double threshold method based on MFCC(1)

中国知网 https://www.cnki.net



（e）基于频谱通量的双门限法检测效果

(e) Detection effect of double threshold method based on spectral flux

（f）基于频谱斜率的双门限法检测效果

(f) Detection effect of double threshold method based on spectral slope

图 3-4 复杂环境下不同端点检测方法的效果

Fig.3-4 The effect of different voice activity detection methods in complex environment

3.3.5 本文端点检测方法的漏检原因分析

本文的端点检测方法取得了 97.6%的咳嗽检出率，为进一步分析该方法咳嗽漏检的原因，本文对端点检测的结果进行了观察和分析，漏检的情况示例如图 3-5 所示，图中红色方框表示漏检的咳嗽位置，蓝色方框表示叠加的非咳嗽位置。这两段声音有一个共同点：与咳嗽叠加的非咳嗽均为剧烈的、音量很高的非咳嗽，该种情况属于极端复杂情况，以现有的手段还无法处理此种情况，且就算成功检测，后续的识别模型也很难将其分类正确。经过观察，未成功检出的咳嗽绝大部分属于图 3-5 类似的极端复杂情况。

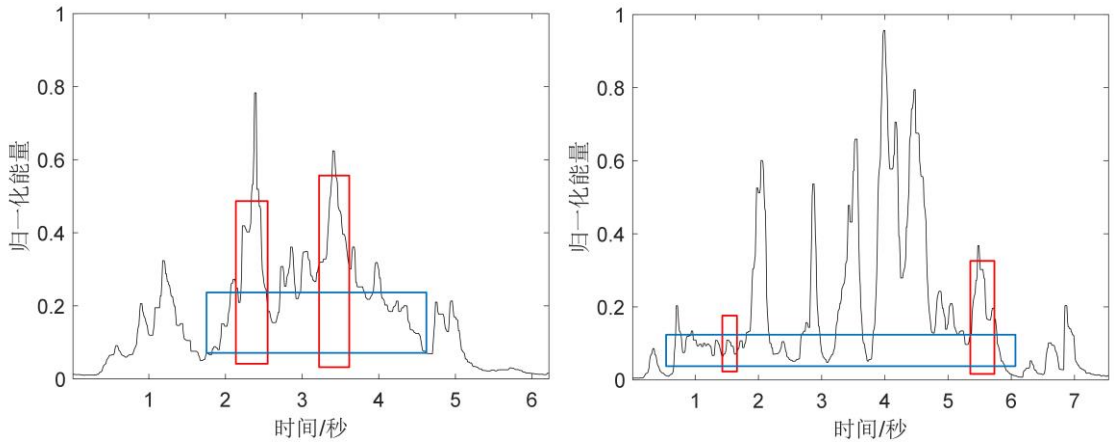


图 3-5 本文端点检测方法的漏检原因示例

Fig.3-5 Example of the cause of missed detection of proposed voice activity detection method

中国知网 https://www.cnki.net

3.4 本章小结

本章分别介绍了传统的双门限端点检测方法和本文提出的端点检测方法。

（1）介绍了传统的双门限端点检测方法，并介绍了双门限法所用的多种特征，实验结果表明基于能量的双门限法可取得最好的效果，咳嗽检出率为 75.8%。然后通过分析表明，传统的双门限法在简单环境下可取得很好的效果，但是在复杂环境下具有非常明显的局限性。

（2）介绍了本文提出的基于自适应动态门限的多重端点检测算法，结果表明，该方法可以很好的解决传统方法在复杂环境下的局限性，并取得了 97.6%的咳嗽检出率，明显高于传统双门限法的 75.8%。通过对结果进行分析得知，除极端复杂情况之外，其余的咳嗽基本可以全部检出。

中国知网 https://www.cnki.net

4. 用于多分类器融合的基分类器的构建

猪舍内声音信号的分类（或猪咳嗽声识别）是实现猪咳嗽声自动检测的第二步，目的是进一步确定端点检测的结果是否为咳嗽。第四章和第五章描述了基于多分类器融合的猪咳嗽声识别方法，本章的目的构建基分类器，用于后续的多分类器融合。本文将参与分类器融合的单个分类器称为基分类器，例如：以 MFCC 作为特征，以 SVM 作为分类器，此时的声音识别模型就是一种基分类器。基分类器的构建是实现多分类器融合的先决条件，并直接决定了后续的分类器融合效果。为构建复杂环境下性能较好、互补性较强的一组基分类器，本章研究了多种不同域特征和多种不同类型的分类模型，通过数据增强方法提高了数据的多样性和模型的性能，并讨论了不同迁移学习方法的影响。下面分别阐述数据增强、特征提取、分类模型和基分类器的构建。

4.1 数据增强方法研究

数据增强通过对训练数据做出的一系列随机性的改变，来产生相似的训练样本，以扩展数据的规模，同时这种随机性的改变可以减少模型对特定属性的依赖，从而提升模型的泛化能力。与大规模的 ImageNet 或 AudioSet 数据集相比，本文使用的数据集规模很小，且不同种类的非咳嗽数量不平衡，某些类型非咳嗽的数量较少，这可能会对分类性能产生一定的限制。因此，本文使用数据增强来增加数据的数量和多样性，提高分类性能[82]。本文考虑了两种数据增强方式：图像增强和声音增强，并对比了多种不同的数据增强方法，以此来确定最适合于本文任务的数据增强方法。

4.1.1 图像增强

图像增强是针对语谱图、梅尔语谱图等图像特征做的数据增强。本文考虑的图像增强方法包括平移、旋转、随机剪裁、合成模糊、合成噪声、色相抖动。图像增强的方法示例如图 4-1 所示，具体介绍如下：（1）剪裁：从上下左右中的某个方向随机的裁剪掉部分像素，如子图(b)所示。（2）平移：从水平方向或者竖直方向随机的平移一定的距离，移走的区域用空白填充，如子图(c)所示。与剪裁相比，平移不会改变图像的尺寸。（3）旋转：将图像按照顺时针或者逆时针随机的旋转一定的角度，如子图(d)所示。（4）合成模糊：将图像按照某种规则进行随机模糊处理，子图(e)表示的应用高斯模糊后的图像。（5）合成噪声：在图像中随机的添加某种噪声，子图(f)表示的是添加椒盐噪声后的图像。（6）色相抖动：随机改变图像的色调，如子图(g)所示。

中国知网 https://www.cnki.net

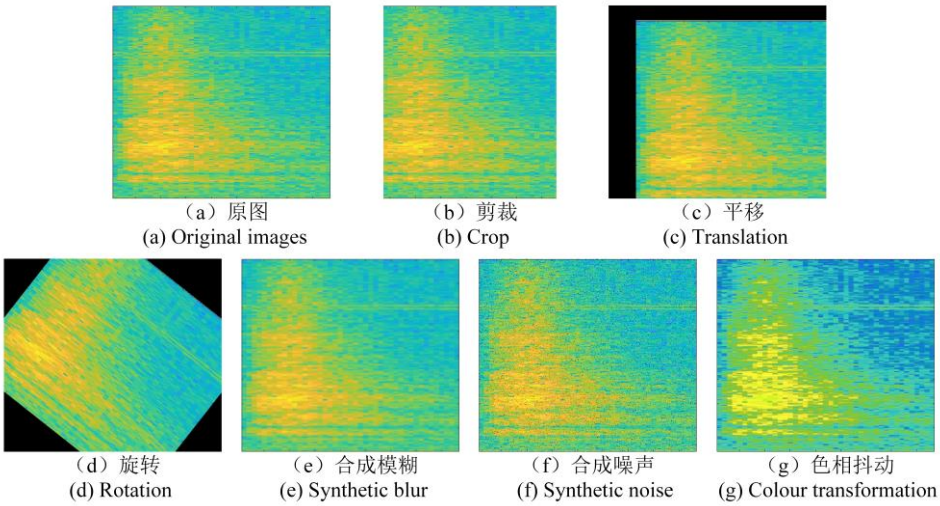


图 4-1 图像增强方法示例

Fig.4-1 Examples of image augmentation methods

4.1.2 声音增强

声音增强指的是对原始的声音波形做的数据增强。本文考虑的声音增强方法包括时间拉伸、改变音调、添加噪声、音量控制和时移[83]。选取一段音频，使用不同的声音增强方式对该音频进行变换，然后绘制语谱图，每种声音增强方法的效果示例如图 4-2 所示，具体介绍如下：（1）时间拉伸：将这段音频的时间长度随机拉长或者缩短为原来的多少倍，如子图(b)所示。（2）改变音调：将音频的音高随机的调高或调低一定值，如子图(c)所示。（3）音量控制：将这段音频的音量随机增加或减少一定值，如子图(d)所示。（4）添加噪声：在这段音频中随机的添加一定强度的某种噪声，子图(e)表示的是添加高斯白噪声后的效果。（5）时移：将这段音频随机的向左或向右移动一定的时间长度，如子图(f)所示。

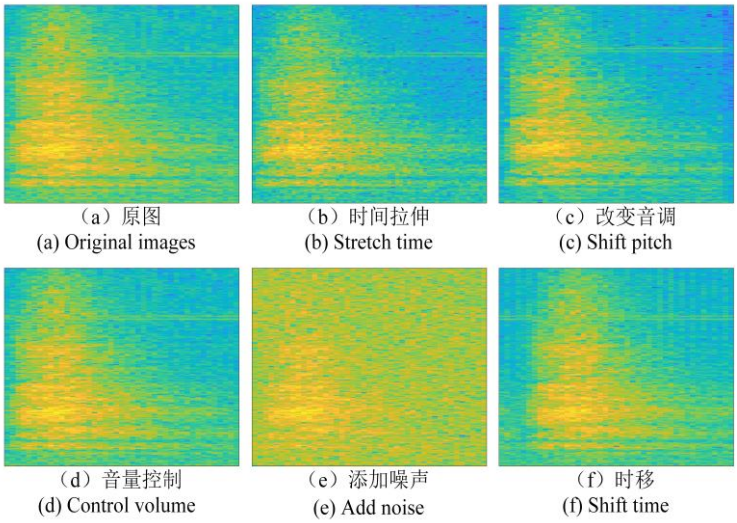


图 4-2 声音增强方法示例

Fig.4-2 Examples of sound augmentation methods

中国知网 https://www.cnki.net

4.2 特征提取

不同的特征可以从不同的角度描述声音的特性，为提高复杂猪舍内声音的特征表达能力，充分利用不同特征的优势以及多个特征之间的互补性，本文研究了不同域的多种特征，包括原始波形特征，声学特征和图像特征。其中，声学特征包括 MFCC 和 PSD，图像特征包括语谱图、梅尔语谱图、CQT 图、二维 MFCC 颜色矩阵图和连续小波基图。下面分别详细介绍每种特征。

4.2.1 声学特征

声学特征包括时域特征、频域特征和倒谱域特征。时域特征可以反映信号随时间的变化规律，是声音信号最基本、最直观的表达形式。但是时域特征较为简单，无法反映声音更深层次的特性，因此大部分声音识别相关的研究主要以频域和倒谱域特征为主。本文使用两个应用较为广泛的声学特征来进行猪咳嗽识别，分别为梅尔频率倒谱系数和功率谱密度。

4.2.1.1 梅尔频率倒谱系数

梅尔频率倒谱系数是声音信号处理领域常用的声学特征，在猪咳嗽声识别领域也有着较为广泛的应用，且表现出了良好的性能。梅尔频率倒谱系数根据人耳的听觉感知特性设计，将实际频率转化为人耳感知频率。梅尔频率倒谱系数的提取流程如图 4-3 所示。首先对声音信号进行预处理，包括滤波、预加重、分帧和加窗，然后通过快速傅里叶变换（FFT）将预处理后的声音信号由时域转化为频域，得到信号的频谱。计算功率谱，并将功率谱通过一组梅尔滤波器进行滤波。最后进行对数运算和离散余弦变换，得到梅尔频率倒谱系数。本文使用 MATLAB R2023b 环境下的函数“mfcc”来提取梅尔频率倒谱系数。

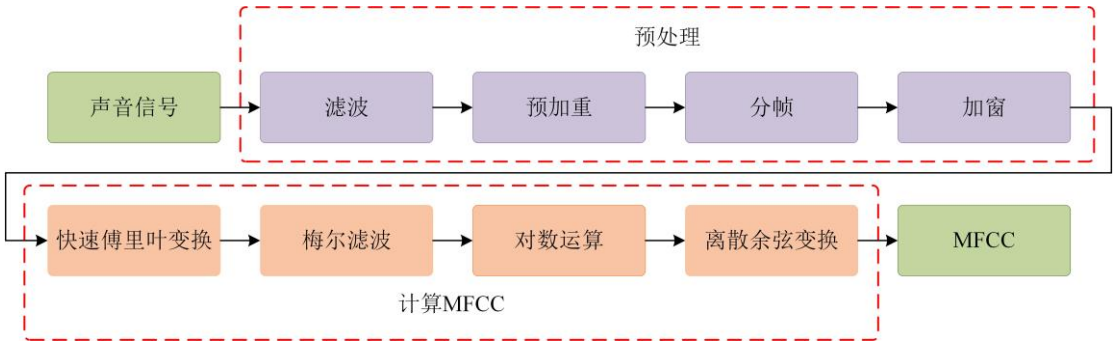


图 4-3 MFCC 提取流程

Fig.4-3 Extraction process of MFCC

4.2.1.2 功率谱密度

功率谱密度反映了声音信号的功率与频率之间的关系。功率谱密度的提取方法主要包括自相关函数法、周期图法和平均周期图法，其中最常用的方法是平均周期图法，即将声音平均分成多个段，使用周期图法计算每个段的功率谱密度，最后将所有段的功率谱密度取均值。设 L 是分段后每个段的长度，则第 i 段信号$x_i(n)$的功率谱密度可由以下公式计算：

中国知网 https://www.cnki.net

$$P(\omega) = \frac{1}{L} |fft(window(x_i(n)))|^2 \quad (4\text{-}1)$$

其中，*window* 和 *fft* 分别表示对声音信号进行加窗和快速傅里叶变换。本文使用 MATLAB R2023b 环境下的函数“pwelch”来提取功率谱密度。

4.2.2 图像特征

图像特征可以将声音的某些特性以图像的形式展现出来，进而用图像处理和图像识别相关的技术进行下一步的分析。与时域或者频域特征相比，图像特征可以同时表达声音的时域信息和频域信息，并且可以充分利用卷积神经网络在图像识别领域的优势，因此提取图像特征的方法已经成为声音识别领域最有潜力的发展趋势。本文提取的图像特征包括语谱图、梅尔语谱图、CQT 图、MFCC 颜色矩阵图和连续小波基图。

4.2.2.1 语谱图

语谱图是声音信号频谱的图像表现形式，能够表示声音频谱随时间的变化。语谱图的提取过程如下：首先对声音信号进行分帧，然后对每一帧信号进行快速傅里叶变换，得到每一帧信号的频谱，根据频谱计算每一帧信号的功率谱，然后以横坐标表示时间，纵坐标表示频率，用颜色的深浅表示功率的大小，以此绘制成一张图。本文使用 MATLAB R2023b 环境下的函数“spectrogram”来提取语谱图。

4.2.2.2 梅尔语谱图

梅尔语谱图是在语谱图的基础上进行梅尔滤波得到的，能够表示以人耳感知频率为基准的频谱随时间的变化。首先对声音分别进行分帧、快速傅里叶变换、功率谱的计算，然后将每一帧信号的功率谱通过一组梅尔滤波器进行梅尔滤波，得到每一帧信号的梅尔频谱，最后以横坐标表示时间，纵坐标表示梅尔频率，颜色的深浅表示功率的大小，以此绘制成图像，得到梅尔语谱图。本文使用 MATLAB R2023b 环境下的函数“melSpectrogram”来提取梅尔语谱图。

4.2.2.3 CQT 图

CQT 图是在语谱图的基础上进行常数 Q 变换得到的，主要用于对音乐信号的分析。CQT 是一个滤波器组，其中心频率以指数的形式分布，滤波器带宽不同，但是中心频率与带宽的比值为常数 Q。Q 的表达式如下：

$$Q = \frac{f_k}{\delta f_k} = \frac{f_k}{f_{k+1} - f_k} = \frac{1}{2^{\frac{1}{B}} - 1}, \quad k = 0,1, \dots K-1 \quad (4\text{-}2)$$

其中，$f_k = f_1 2^{\frac{k-1}{B}}$，$f_1$和$f_k$分别表示最低频带和第 k 个滤波器的中心频率，B 决定每八度的滤波器数。CQT 的表达式如下：

$$X^{CQT}(k) = \frac{1}{N_k} \sum_{n=0}^{N_k-1} x(n) \omega_{N_k}(n) e^{-\frac{j2\pi Q}{N_k} n} \quad (4\text{-}3)$$

中国知网 https://www.cnki.net

其中，$N_k = Q\frac{f_s}{f_k},\ k = 0,1,\ldots,K-1$，表示窗口长度，$f_s$表示采样频率，$\omega_{N_k}(n)$表示长度为$N_k$的窗口函数。本文使用 MATLAB R2023b 环境下的函数“cqt”来提取 CQT 图。

4.2.2.4 MFCC 颜色矩阵图

MFCC 颜色矩阵图是将提取到梅尔频率倒谱系数特征以图像的形式展现出来，使用颜色的深度表示数字的大小，得到颜色矩阵图，进而可以利用图像识别和图像处理相关的技术，提取到更多不同于原始梅尔频率倒谱系数的信息，为后续的分类器融合提供更多的多样性。本文使用 MATLAB 中的函数“imagesc”来将梅尔频率倒谱系数转化为颜色矩阵图。

4.2.2.5 连续小波基图

在对声音信号进行时频分析时，通常需要通过短时傅里叶变换得到信号的频谱，也就是首先将声音分成相同长度的多个帧，然后对每一帧进行快速傅里叶变换和时频分析，此时时频分析窗口的大小是固定的。然而，猪舍内的声音是非平稳信号，对于非平稳信号，很多时候需要时频窗口具有可调性，在声音的高频部分具有更高的时间分辨率，而在声音的低频部分具有更高的频率分辨率，为此引入了连续小波变换。若函数$\psi(t) \in L^2(R)$，且满足以下公式：

$$\int_{-\infty}^{\infty} \frac{\left|\psi_f(w)\right|^2}{|w|} dw < \infty \tag{4-4}$$

式中$\psi_f(w)$表示$\psi(t)$的傅里叶变换，则函数$\psi(t)$可以作为基小波函数，或称为母小波函数，公式 4-4 为小波的容许条件。对于连续声音信号$f(t)$，其连续小波变换定义为：

$$W_f(a,b) = \langle f(t), \psi_{a,b}(t) \rangle = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} f(t)\psi^*\left(\frac{t-b}{a}\right) dt \tag{4-5}$$

式中ψ^*表示ψ的共轭复数。a 表示尺度因子，反映函数的宽度。b 表示平移因子，反映函数在时间轴上的平移位置。本文使用 MATLAB R2023b 环境下的函数“cwtfilterbank”来创建连续小波变换滤波器组，然后使用函数“wt”来进行连续小波变换，最后使用函数“imagesc”将连续小波变换的结果转化为连续小波基图。

4.2.3 原始波形特征

原始的声音波形包含大量的样本点，直接根据原始波形进行分类会导致巨大的计算量，因此目前的研究主要基于特征级，也就是先提取某种特征，然后在对特征进行分类。随着卷积神经网络模型的发展，为提高声音识别的精度，有学者构建了直接作用于原始声音波形的一维卷积神经网络，可以用于提取声音的原始波形特征并进行分类[84-86]。本文在现有研究的基础上，进一步研究了原始波形特征在猪咳嗽识别领域的性能。

4.3 分类模型

不同的分类模型可以从不同的角度挖掘声音的信息，为提高复杂猪舍声音的信息挖掘能

中国知网 https://www.cnki.net

力，充分利用不同分类模型的优势，本文研究了不同类型的多种分类模型，包括机器学习模型、一维卷积神经网络、二维卷积神经网络和 LSTM。其中，机器学习模型包括支持向量机、K 近邻算法（KNN）和随机森林（RF），一维卷积神经网络包括自己搭建的两个模型和基于 AudioSet 迁移学习的模型，二维卷积神经网络包括多个基于 ImageNet 和 AudioSet 迁移学习的模型。下面分别介绍每种分类模型。

4.3.1 传统机器学习模型

传统的机器学习算法在很多领域有着较为广泛的应用，且取得了较好的效果。本文选取了几个比较经典的机器学习模型，分别为 SVM、KNN 和 RF。

4.3.1.1 支持向量机

SVM 是在 20 世纪 90 年代提出的一种机器学习方法[87]，其主要思想是根据最大间隔的原则来构造一个超平面，并根据数据在超平面的哪一侧来判定该数据的类别。SVM 可以通过核函数将输入数据映射到高维特征空间，进而将非线性问题转化为线性问题，常见的核函数包括线性核函数、高斯核函数、多项式核函数等。SVM 基于结构风险最小化原则，泛化能力强，并且最终决策函数只由部分支持向量决定，使其具有较低的计算复杂度和较高的鲁棒性。

4.3.1.2 K 近邻算法

KNN 最初是由 Cover 和 Hart 提出[88]，其算法思想是计算测试样本到每个训练样本的距离，并根据距离最近的 K 个样本的类别进行投票，根据票数来判定该数据的类别。计算距离的方式包括欧几里得距离和曼哈顿距离等。K 值是 KNN 算法中的一个很重要的超参数，K 值过小会导致对噪声的敏感性变大，容易过拟合，K 值过大会导致容易受到样本均衡性的影响，容易欠拟合，因此需根据具体情况对 K 值进行调优。KNN 算法简单，无需训练，且不易受异常值的影响。

4.3.1.3 随机森林

RF 是一种基于随机子空间方法[89]的机器学习算法，由 Breiman 完善并推广[90]。RF 的算法思想是从训练集中有放回的随机重复抽取多个样本来生成多个新的样本集，每个样本集构造一棵决策树，测试数据的分类结果由每棵决策树分类结果投票来决定。RF 通过随机子空间的方式减少了每颗决策树之间的相关性，具有较强的抗干扰能力和抗过拟合能力。

4.3.2 一维卷积神经网络

本文使用的一维卷积神经网络包括自主搭建的网络框架以及基于 AudioSet 数据集的迁移学习模型。迁移学习指的是将某种任务下训练好的模型迁移到一个新的任务，并使用新的数据对该模型进行微调，可以提升模型的性能和学习效率。一维卷积神经网络用来提取声音的原始波形特征。

中国知网 https://www.cnki.net

4.3.2.1 自建的一维卷积模型

本文参考了现有研究中的一维卷积网络模型[84, 85]，并结合本文的分类任务，搭建了两个一维卷积网络框架，分别为 1D-CNN 和 1D-CNN-LSTM，其网络结构如表 4-1 所示。图中 Cov1D 表示一维卷积层，Maxpool 表示最大池化层，FC 表示全连接层，*k* 表示卷积核尺寸，*c* 表示输出通道数，*s* 表示步长，*p* 表示填充，*d* 表示膨胀因子。1D-CNN 包含五个一维卷积层、四个最大池化层、一个全局平均池化层以及两个全连接层，一维卷积层后采用层归一化和 ReLU 激活函数，最后使用 Softmax 得到分类结果。1D-CNN-LSTM 的结构与 1D-CNN 类似，只是将第五层一维卷积层替换为 BiLSTM 层，并将后续的结构修改为一个 Dropout 层和一个全连接层，最后使用 Softmax 得到输出结果。

表 4-1 自主搭建的一维卷积神经网络框架

Tab.4-1 Self-built one-dimensional convolutional neural network framework

1D-CNN	1D-CNN-LSTM
输入	输入
Cov1D (*k*=11, *c*=64, *s*=5, *p*=5)	Cov1D (*k*=11, *c*=64, *s*=5, *p*=5)
层归一化	层归一化
Cov1D (*k*=3, *c*=64, *s*=1, *p*=2, *d*=2)	Cov1D (*k*=3, *c*=64, *s*=1, *p*=2, *d*=2)
层归一化，ReLU	层归一化，ReLU
Maxpool (*k*=4, *s*=4)	Maxpool (*k*=4, *s*=4)
Cov1D (*k*=3, *c*=128, *s*=1, *p*=2, *d*=2)	Cov1D (*k*=3, *c*=128, *s*=1, *p*=2, *d*=2)
层归一化，ReLU	层归一化，ReLU
Maxpool (*k*=4, *s*=4)	Maxpool (*k*=4, *s*=4)
Cov1D (*k*=3, *c*=256, *s*=1, *p*=2, *d*=2)	Cov1D (*k*=3, *c*=256, *s*=1, *p*=2, *d*=2)
层归一化，ReLU	层归一化，ReLU
Maxpool (*k*=4, *s*=4)	Maxpool (*k*=4, *s*=4)
Cov1D (*k*=3, *c*=512, *s*=1, *p*=2, *d*=2)	BiLSTM (隐藏层神经元个数：200)
层归一化，ReLU	Dropout (50%)
Maxpool (*k*=4, *s*=4)	FC (2)
全局平均池化	Softmax
FC (512)	输出
FC (2)	
Softmax	
输出	

4.3.2.2 基于 AudioSet 数据集的迁移学习模型

AudioSet 是由 Google 团队提供的一个大规模音频数据集[91]，其中包括日常生活、自然环境、城市生活等场景下的多种声音，共 527 个声音类别，总时长超过 5000 小时，可以用于声音事件分类方法的研究。文献[86]中使用 AudioSet 数据集训练了多个一维卷积网络模型，本文选取其中两个效果较好的模型作为预训练模型，分别为 Res1dNet31 和 Res1dNet51。在

中国知网 https://www.cnki.net

迁移学习过程中，保留预训练网络模型的参数，并将最后一层全连接的输出类别改为 2，然后使用本文构建的数据集重新训练网络，并得到分类结果。

Res1dNet 是在 LeeNet[85]的基础上进行改进得到的。LeeNet 的网络深度为 11 层，在波形上使用长度为 3 的卷积核，由多个一维卷积层组成，每个卷积层后接一个大小为 2 的下采样层。在此基础上，将 LeeNet 中的卷积层替换为残差块，其中每个残差块由两个尺寸为 3 的卷积层组成，卷积块第一层卷积和第二层卷积的膨胀因子分别为 1 和 2，以增加相应残差块的感受野，在每个残差块之后进行下采样。通过使用 14 和 24 个残差块，分别得到 Res1dNet31 和 Res1dNet51。

4.3.3 二维卷积神经网络

二维卷积神经网络用来对声音的图像特征进行分类，本文对比了两种不同的迁移学习模型，分别为基于 ImageNet 的迁移学习模型和基于 AudioSet 的迁移学习模型。

4.3.3.1 基于 ImageNet 数据集的迁移学习模型

ImageNet 是一个大规模的图像数据集，现有的预训练神经网络主要基于 ImageNet 中的一个子集：ImageNet Large-Scale Visual Recognition Challenge (ILSVRC)[92]，该子集包含 1000 个类别，例如键盘、铅笔、各种动物等，总共 100 多万张图像。本文选取了多个比较常见的二维卷积神经网络框架作为预训练模型，包括：AlexNet[93]、GoogLeNet[94]、Vgg16[95]、Vgg19[95]、InceptionV3[96]、ResNet18[97]、ResNet50[97]、SqueezeNet[98]、Xception[99]、DenseNet201[100]以及 MobileNetV2[101]。这些模型在卷积层数、卷积核尺寸和模型深度等方面各有不同，ImageNet 上的准确率随着网络深度的加深而逐渐提升。本文通过对这些模型进行对比，找到最适合于猪咳嗽识别任务的网络框架。

（1）AlexNet 是第一个在 ImageNet 数据集中取得显著优势的神经网络，采用了 8 层的网络结构，包括 5 层卷积层和 3 层全连接层。AlexNet 采用 ReLU 激活函数，以及 Dropout 技术，提高了模型的性能和抗过拟合能力，同时可以利用 GPU 进行高效计算，为后续卷积神经网络的发展奠定了基础。

（2）GoogLeNet（又称 InceptionV1）的网络深度为 22 层，没有全连接层。GoogLeNet 最大的创新点是引入了 Inception 模块，通过并行的连接多个不同大小的卷积核和池化层，在提高模型深度的同时，降低了模型的参数量和计算复杂度。

（3）Vgg 的结构较为简单，主要的特点是使用 3*3 的卷积核代替较大的卷积核，以此降低了模型的参数量，同时具有非常深的结构，根据网络层数的不同可分为 Vgg16、Vgg19 等。Vgg 网络的结构简单，使其更容易训练和调整，具有较强的通用性，缺点是模型较大，参数量较高。

（4）InceptionV3 是 Google 开发的 Inception 系列网络的第三个版本，网络深度为 48 层。与之前的版本相比，InceptionV3 引入了 Batch Normalization 和辅助分类器等技术，提升了模型的训练速度和性能表现。

（5）ResNet 引入了残差块和跳跃连接技术，通过跳跃连接将输入与输出相加，将学习的内容与原始内容进行了有效结合，很好的缓解了训练过程中的梯度消失和梯度爆炸问题，

中国知网 https://www.cnki.net

同时可以实现更深的网络结构。根据深度的不同，ResNet 可以分为 ResNet18、ResNet50 等。

（6）SqueezeNet 是一种轻量化网络模型，通过紧凑的网络结构和提出的 Fire 模块实现了高效的参数利用率，在保证了准确率的同时，极大的降低了模型的参数量和计算复杂度，更有利于在资源受限的设备上部署。

（7）Xception 网络基于 InceptionV3，并在其基础上，采用具有残差连接的深度可分离卷积层，引入了沿着通道维度的解耦合，在基本不增加复杂度的前提下提高了模型的性能。

（8）DenseNet201 属于 DenseNet 系列，网络深度为 201 层，主要的特点为密集连接，即网络中的每一层都与之前的所有层直接连接，每一层输入在包含上一层输出的同时，也包含之前所有层的输出，可以更充分的利用和传递更多的信息。

（9）MobileNetV2 属于轻量化网络模型，通过使用深度可分离卷积、倒置残差和线性瓶颈等结构，在保持较高准确率的同时降低了模型的复杂度，有利于在嵌入式设备、移动端设备等资源受限的设备上部署。

4.3.3.2 基于 AudioSet 数据集的迁移学习模型

文献[86]中使用 AudioSet 数据集训练了多个二维卷积网络模型，本文选取其中几个效果比较好的模型作为预训练模型，包括：CNN10、CNN14、ResNet22、ResNet38、MobileNetV1 和 MobileNetV2。这些模型具有不同的网络结构，以梅尔语谱图作为特征，以 mixup[102]作为数据增强方式。除此之外，本文研究了文献[86]中提出的 Wavegram-CNN 模型和 Wavegram-Logmel-CNN 模型，这两个模型将一维卷积和二维卷积结合，在 AudioSet 数据集中取得了较好的效果。

（1）CNN10 和 CNN14 的设计灵感来源于 Vgg，网络深度分别为 10 层和 14 层。CNN10 和 CNN14 分别由 4 个卷积块和 6 个卷积块构成，其中每个卷积块包含两个卷积层，卷积核尺寸为 3*3。每个卷积层之间应用 Batch Normalization 和 ReLU 激活，每个卷积块后接 2*2 的平均池化层进行降采样。最后一个卷积块之后包括一层全局池化层和两层全连接层，最后使用 Sigmoid 函数进行输出。其中，全局池化包括全局平均池化和全局最大池化，并以两者的和作为全局池化的结果。每个降采样层和全连接层后应用 Dropout，以防止过拟合。

（2）ResNet22 和 ResNet38 是在传统 ResNet 结构的基础上进行修改得到的，网络深度分别为 22 层和 38 层。ResNet22 和 ResNet38 分别包含 8 个和 16 个 ResNet 基本块，每个基本块由两个卷积层以及输入和输出之间的快捷连接构成，卷积核尺寸为 3*3。在此之前，首先应用两个卷积层和一个 2*2 的平均池化层，以减小梅尔语谱图的大小。在最后一个基本块之后包括两层卷积层、一层全局池化层和两层全连接层，最后使用 Sigmoid 函数进行输出。

（3）MobileNetV1 和 MobileNetV2 的结构与传统的 MobileNet 基本一致，只是在其基础上进行适当的调整，使其适应于 AudioSet 数据集，因此不再过多介绍。

（4）Wavegram-CNN 的输入为原始波形，首先通过一维卷积框架，提取声音的波图特征，然后将该特征输入二维卷积框架，得到识别结果。其中，一维卷积框架从一个长度为 11、步幅为 5 的一维卷积层开始，后接三个一维卷积块，每个卷积块由两个卷积层组成，膨胀因子分别为 1 和 2，每个卷积块后接步幅为 4 的最大池化层进行降采样。改变一维卷积框架结果的维度结构，得到波图特征，然后将其输入二维卷积框架，文献[86]中选取的二维卷积框架是

中国知网 https://www.cnki.net

CNN14，本文与其保持一致。

（5）Wavegram-Logmel-CNN 在 Wavegram-CNN 的基础上，使用一个二维卷积块提取梅尔语谱图中的特征，将该特征与 Wavegram-CNN 中一维卷积框架提取的波图特征融合，然后将融合特征输入后续的二维卷积框架进行分类。

4.3.4 长短时记忆网络

LSTM 使用门机制对时序信息的流通和损失进行控制，很好的缓解了传统 RNN 方法的长距离依赖问题，在时序分类问题上有着较为明显的优势[103]。LSTM 引入了三个门：输入门 i_t，遗忘门 f_t，输出门 o_t，以及表示长期记忆的细胞态C_t和等待存入长期记忆的候选态$\tilde{C}$。其中，三个门都是当前时刻的输入 x_t 以及上个时刻的短期记忆 h_{t-1} 的函数，分别表示为：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \tag{4-6}$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{4-7}$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \tag{4-8}$$

三个公式中的 W 和 b 为待训练的参数矩阵和偏置项，σ表示 sigmoid 函数。定义 h_t 为记忆体，表示短期记忆，也即 t 时刻的隐藏状态，其表达式如下：

$$h_t = o_t * tanh(C_t) \tag{4-9}$$

候选态$\tilde{C}$表示归纳出的待存入细胞态的新的知识，其表达式如下：

$$\tilde{C}_t = tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \tag{4-10}$$

细胞态C_t表示长期记忆，其计算公式如下：

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \tag{4-11}$$

4.4 基分类器的构建

本章的目的是构建一组性能较好且多样性较强的基分类器，用于后续的多分类器融合。为此，首先对比不同的数据增强方法，找到最适合于每种特征的数据增强方法，以此来提升模型的性能和多样性。另外，本章研究了多种特征和多种分类模型，相比较而言，不同特征之间具有更多的多样性和互补性，而不同分类模型可提供的多样性相对较少，因此，本文从特征多样性的角度，对不同的分类模型进行初步筛选，通过对比，得到最适合于每种特征的分类模型，以此构建多个基分类器。图 4-4 所示为基分类器的构建过程。首先以声学特征作为特征，以机器学习模型和 LSTM 模型作为分类器，对比不同分类器的性能，得到第一组基分类器。然后以图像特征作为特征，以二维卷积神经网络作为分类模型，对比不同迁移学习方式的多个模型的性能，得到第二组基分类器。最后以原始波形特征作为特征，以一维卷积神经网络作为分类器，对比多个自建模型和迁移学习模型的性能，得到第三组基分类器。这三组基分类器就是本文构建的所有基分类器。

中国知网 https://www.cnki.net

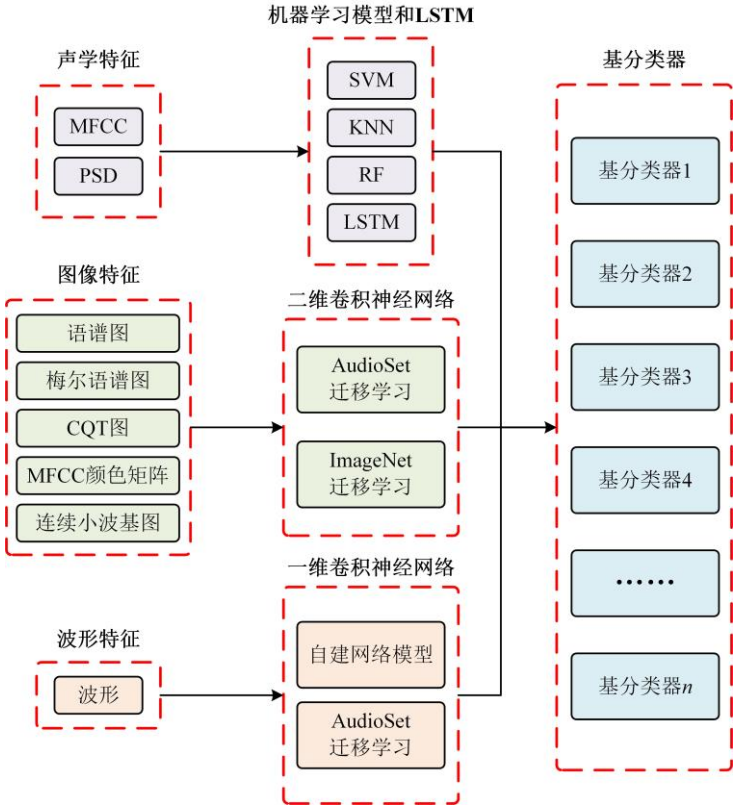


图 4-4 基分类器的构建流程

Fig.4-4 The construction process of base classifiers

4.5 实验结果与分析

本小节对基分类器的构建过程和结果进行分析。首先阐述相关实验参数的设置；然后阐述不同数据增强方法的性能对比，确定最优的数据增强方法；然后阐述不同分类模型的性能对比，包括多种机器学习模型、LSTM、一维卷积神经网络和二维卷积神经网络的性能对比，确定最优的分类模型；最后对不同特征的性能进行对比。

4.5.1 实验参数设置

本文所用的 CPU 和 GPU 的配置为 Intel Core i7-14700HX 和 NVIDIA GeForce RTX 4060，CPU 的运行频率为 5.5GHz，运行内存为 16GB，显卡的显存为 8GB。本文的实验环境为 MATLAB R2023b 和 Pytorch 1.13.0。

AudioSet 迁移学习模型的数据增强参数与文献[86]一致。其余图像数据增强的参数设置如下：平移的范围是水平方向上的-30 到 30 像素，旋转角度的范围是-30° 到 30°，裁剪的范围是水平方向上的-100 到 100 像素，合成模糊的类型为高斯模糊，加噪的类型为椒盐噪声，色相抖动的范围是‘jitterColorHSV’函数中的 0 到 0.1。声音增强的参数设置如下：时间拉伸的加速比为 0.75-1.25 倍，改变音调的范围是-1 到 1 个半音，音量控制中的音量增益范围是-1 到 1 分贝，加噪的类型为高斯白噪声，噪声信噪比范围是 0 到 2 分贝，时移的范围是-5 到 5 毫

中国知网 https://www.cnki.net

秒。

AudioSet 迁移学习模型的预处理和特征提取参数与文献[86]一致。其余的预处理参数设置如下：预加重系数为 0.9375；滤波器带宽为 100-16000 赫兹；分帧时每帧时间长度为 20 毫秒，重叠 10 毫秒，加汉明窗。特征提取的参数如下：MFCC 和 PSD 的维数分别为 13 和 513；提取语谱图时 FFT 点数为 882；提取梅尔语谱图时梅尔滤波器个数为 64；提取连续小波基图时小波函数为“bump”，“VoicesPerOctave”设置为 12。机器学习模型的参数设置如下：SVM 的核函数为“RBF”且“kernelScale”设置为“auto”；KNN 的超参数均设置为“auto”；RF 的决策树棵数为 100。

训练深度学习模型时，损失函数设置为交叉熵，优化器为“Adam”，其余参数设置如下：BiLSTM：隐藏层神经元个数为 200，BatchSize 为 64，学习率为 0.001，epoch 为 300；自建的一维卷积网络模型：BatchSize 为 128，学习率为 0.0001，epoch 为 200；ImageNet 迁移学习模型：BatchSize 为 128，学习率为 0.0001，epoch 为 30；AudioSet 迁移学习模型：BatchSize 为 16，学习率为 0.0001，epoch 为 50。

4.5.2 不同数据增强方法的性能对比

本文选取梅尔语谱图作为特征，选取 AlexNet 作为分类模型，对不同数据增强方法进行对比分析，结果如表 4-2 和表 4-3 所示。表 4-2 所示为不同图像增强方法的性能对比，根据表 4-2 可以得知，大部分图像增强方法均有一定的效果提升，合成模糊、合成噪声以及色相抖动的提升较为明显，准确率大约提升了 1%。与这几种方法相比，传统的几何变换方法的效果提升幅度较小，其中效果最好的是旋转，准确率大约提升了 0.5%。表 4-3 所示为不同声音增强方法的性能对比，相比于图像增强，声音增强方法整体的性能提升幅度较小，除加噪外，其余方法均无明显提升，甚至时移增强方法会导致准确率有略微的下降。加噪在声音增强和图像增强中均有着较好的表现，本文选取声音加噪的方式进行数据增强。

表 4-2 不同图像增强方法的性能

Tab.4-2 Performance of different image augmentation methods

增强方法	准确率	召回率	精确率	F1 分数
无	93.0%	93.4%	90.7%	92.0%
平移	93.2%	93.3%	91.0%	92.1%
旋转	93.5%	93.2%	91.9%	92.5%
剪裁	93.3%	94.8%	90.1%	92.4%
合成模糊	94.0%	93.3%	92.7%	93.0%
合成噪声	94.0%	92.9%	93.1%	93.0%
色相抖动	93.8%	93.9%	91.9%	92.9%

中国知网 https://www.cnki.net

表 4-3 不同声音增强方法的性能

Tab.4-3 Performance of different sound augmentation methods

增强方法	准确率	召回率	精确率	F1 分数
时间拉伸	93.2%	93.6%	90.8%	92.2%
改变音调	93.3%	93.0%	91.5%	92.2%
添加噪声	94.0%	93.3%	92.7%	93.0%
音量控制	93.3%	94.2%	90.6%	92.4%
时移	92.6%	93.1%	90.1%	91.6%

为进一步验证数据增强的效果，本文选取多个模型，对数据增强前后的性能进行对比，如表 4-4 和表 4-5 所示。由于声学特征和波形特征无法进行图像增强，因此表 4-5 中展示的是声音增强的结果。可以得知，数据增强对图像特征有明显的效果提升，但是对声学特征和波形特征不仅没有效果提升，反而会使准确率下降，MFCC 输入 SVM 时准确率下降了约 0.6%，波形输入一维卷积时准确率下降了约 1.3%。因此声音增强方法无法适用于声学特征和波形特征，因此在后续的研究中，不再对声学特征和波形特征进行数据增强，只对图像特征进行数据增强。

表 4-4 数据增强前模型的性能

Tab.4-4 Performance of the model before data augmentation

特征	分类器	准确率	召回率	精确率	F1 分数
MFCC	SVM	90.1%	89.3%	88.0%	88.6%
波形	1D-CNN-LSTM	90.8%	91.8%	87.4%	89.5%
梅尔语谱图	AlexNet	93.0%	93.4%	90.7%	92.0%
连续小波基图	AlexNet	93.5%	94.6%	90.6%	92.6%

表 4-5 数据增强后模型的性能

Tab.4-5 The performance of the model after data augmentation

特征	分类器	准确率	召回率	精确率	F1 分数
MFCC	SVM	89.5%	89.8%	86.3%	88.0%
波形	1D-CNN-LSTM	89.5%	88.3%	87.5%	87.9%
梅尔语谱图	AlexNet	94.0%	93.3%	92.7%	93.0%
连续小波基图	AlexNet	94.1%	94.8%	91.8%	93.3%

4.5.3 不同分类模型的性能对比

4.5.3.1 不同机器学习模型的性能对比

不同机器学习模型的性能对比如表 4-6 所示。可以得知，相同特征输入不同机器学习模型时的性能差距很大。对于 MFCC 特征来说，性能最好的机器学习模型是 SVM，准确率为 90.1%，RF 的性能与 SVM 相近，性能最差的是 KNN，准确率仅为 86.6%。对于 PSD 来说，性能最好的是 RF，准确率为 89.1%，KNN 和 SVM 的性能较差，受非咳嗽识别准确率的影

中国知网 https://www.cnki.net

响，SVM 的准确率仅为 81.0%。因此，本文使用 SVM 作为 MFCC 的分类器，使用 RF 作为 PSD 的分类器。

表 4-6 不同机器学习模型的性能

Tab.4-6 Performance of different machine learning models

特征	分类器	准确率	召回率	精确率	F1 分数
MFCC	SVM	90.1%	89.3%	88.0%	88.6%
MFCC	KNN	86.6%	90.2%	80.8%	85.2%
MFCC	RF	89.7%	91.2%	85.7%	88.3%
PSD	SVM	81.0%	94.1%	71.0%	81.0%
PSD	KNN	84.1%	83.4%	80.5%	81.9%
PSD	RF	89.1%	93.5%	83.2%	88.1%

4.5.3.2 LSTM 模型的性能对比

将声学特征输入 LSTM 时的性能如表 4-7 所示。可以得知，PSD 的准确率为 89.6%，优于 MFCC。整体来说，LSTM 的性能略微低于表 4-6 中最优的机器学习模型，但是由于 LSTM 可以学习声音的序列特征，为后续的多分类器融合提供一定的多样性，因此本文保留表 4-7 中的两个基分类器。

表 4-7 LSTM 模型的性能

Tab.4-7 Performance of the LSTM model

特征	分类器	准确率	召回率	精确率	F1 分数
MFCC	LSTM	88.9%	90.1%	85.3%	87.6%
PSD	LSTM	89.6%	90.3%	86.4%	88.3%

4.5.3.3 一维卷积神经网络模型的性能对比

一维卷积神经网络模型的性能对比如表 4-8 所示。可以看出，基于 AudioSet 迁移学习的 Res1dNet31 和 Res1dNet51 模型性能明显优于自建的 1D-CNN 和 1D-CNN-LSTM。1D-CNN-LSTM 的准确率约为 90.8%，优于 1D-CNN。Res1dNet31 的准确率和 Res1dNet51 基本一致，准确率约为 93.3%，但是文献[86]中指出，Res1dNet31 模型的深度更浅，复杂度更低，因此本文使用基于 AudioSet 迁移学习的 Res1dNet31 来提取声音的波形特征。

表 4-8 不同一维卷积神经网络模型的性能

Tab.4-8 Performance of different one-dimensional convolutional neural network models

一维卷积模型	准确率	召回率	精确率	F1 分数
1D-CNN	90.0%	90.3%	87.2%	88.5%
1D-CNN-LSTM	90.8%	91.8%	87.4%	89.5%
Res1dNet31	93.3%	89.7%	94.5%	92.0%
Res1dNet51	93.2%	89.0%	94.7%	91.8%

4.5.3.4 二维卷积神经网络模型的性能对比

使用梅尔语谱图作为特征，并进行数据增强，基于 ImageNet 和 AudioSet 的迁移学习模

中国知网 https://www.cnki.net

型的性能分别如表 4-9 和表 4-10 所示。整体来说，基于 AudioSet 的迁移学习模型略微优于基于 ImageNet 的模型，但是两种模型的最高准确率均为 94%左右。基于 AudioSet 模型的性能波动较小，准确率均在 93%以上，且其中的大部分模型的准确率在 93.8%左右，包括 CNN14、ResNet38、MobileNetV1、MobileNetV2 和 Wavegram-Logmel-CNN。而基于 ImageNet 模型的性能波动较大，虽然最高准确率为 94.0%，但是最低准确率仅为 91.4%，且不同网络模型之间性能差距较大，其中，浅层网络 AlexNet 的性能最好，明显优于其它模型。Squeezenet 和 MobileNet 是两个轻量化模型，但是这两个模型在 ImageNet 迁移学习方法中的性能不如 AlexNet，而基于 AudioSet 的预训练模型只能使用梅尔语谱图作为迁移学习的特征，无法使用连续小波变换等其他特征，因此，本文使用基于 ImageNet 迁移学习的 AlexNet 来对声音的图像特征进行分类。通过与表 4-6、4-7、4-8 对比，可以得知，二维卷积神经网络的性能明显优于机器学习模型、LSTM 模型以及一维卷积神经网络。

表 4-9 基于 ImageNet 迁移学习模型的性能

Tab.4-9 Performance of ImageNet-based transfer learning model

框架	准确率	召回率	精确率	F1 分数	参数量(M)	FLOPs(G)
AlexNet	94.0%	93.3%	92.7%	93.0%	61.1	0.72
GoogLenet	92.5%	92.1%	90.6%	91.3%	7	1.51
Vgg16	92.1%	89.9%	91.7%	90.7%	138.36	15.5
Vgg19	91.4%	89.6%	90.5%	90.0%	143.67	19.67
Inceptionv3	93.2%	94.3%	90.4%	92.3%	27.16	5.73
Resnet18	93.2%	92.0%	92.2%	92.1%	11.69	1.82
Resnet50	91.7%	89.7%	90.9%	90.3%	25.56	4.12
Squeezenet	93.0%	92.4%	91.3%	91.9%	1.24	0.36
Xception	92.8%	93.0%	90.7%	91.8%	22.86	8.42
DenseNet201	93.0%	92.1%	91.7%	91.9%	20.01	4.37
MobileNetV2	91.8%	89.7%	91.0%	90.4%	3.5	0.31

表 4-10 基于 AudioSet 迁移学习模型的性能

Tab.4-10 Performance of AudioSet-based transfer learning model

框架	准确率	召回率	精确率	F1 分数	参数量	FLOPs(G)
CNN10	93.3%	89.8%	94.4%	92.0%	5.22	13.07
CNN14	93.8%	91.1%	94.3%	92.6%	80.8	20.1
ResNet22	93.4%	89.4%	94.9%	92.0%	63.68	14.03
ResNet38	93.7%	90.3%	94.6%	92.4%	73.78	23.47
MobileNetV1	93.8%	92.7%	92.9%	92.8%	4.8	0.80
MobileNetV2	93.9%	93.6%	92.3%	92.9%	4.08	0.38
Wavegram-CNN	93.0%	90.9%	92.7%	91.7%	80.99	22.12
Wavegram-Logmel-CNN	93.8%	90.4%	94.8%	92.6%	81.07	25.75

4.5.3.5 迁移学习模型的复杂度分析

中国知网 https://www.cnki.net

不同迁移学习模型的精度和复杂度如表 4-8、4-9、4-10，以及图 4-5 所示，本文使用参数量和 FLOPs 对模型的复杂度进行评价，其中，参数量表示模型参数的个数，能够反映模型的空间复杂度，FLOPs 表示模型在运行过程中的运算次数，能够反映模型的时间复杂度。图 4-5 中的蓝色圆圈表示基于 ImageNet 的迁移学习模型，黄色圆圈表示基于 AudioSet 的迁移学习模型，圆圈的面积表示模型的参数量，横坐标表示模型的 FLOPs，纵坐标表示模型的准确率。除 MobileNet 和 VGG 之外，其余 AudioSet 迁移学习模型的复杂度高于 ImageNet。Res1dNet51 的复杂度远高于 Res1dNet31，但精度和 Res1dNet31 相似。二维卷积神经网络中，AlexNet 取得了最高的准确率，且复杂度相对较低，低于大部分模型。

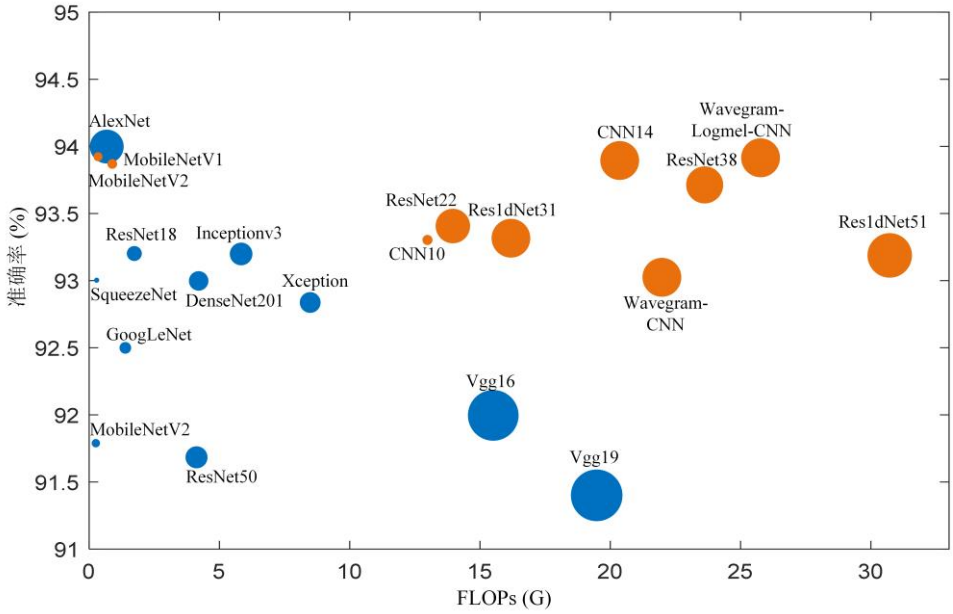


图 4-5 不同迁移学习模型的精度和复杂度

Fig.4-5 Precision and complexity of different transfer learning models

4.5.4 不同基分类器的性能对比

根据上述实验，选出了每种特征最优的数据增强方法，并通过多种分类模型的对比，选出了每种特征最优的分类模型，完成了基分类器的构建，表 4-11 所示为不同基分类器的性能对比。可以看出，图像特征输入 AlexNet 可以取得最好的效果，其中准确率最高的特征是梅尔语谱图和连续小波基图，约为 94%，其余图像特征的准确率在 92%-93%左右。其次是原始波形特征输入 Res1dNet31，准确率约为 93.3%，略低于梅尔语谱图和连续小波基图，但是高于其它图像特征。效果最差的是传统的声学特征，输入不同模型时最高准确率仅为 90.1%，其余准确率均低于 90%，明显低于图像特征和波形特征。一方面，这是因为传统的声学特征无法使用本文的迁移学习和数据增强方法，另一方面，这说明图像特征、波形特征以及卷积神经网络模型在猪咳嗽识别任务中更具有优势。

中国知网 https://www.cnki.net

表 4-11 不同基分类器的性能

Tab.4-11 Performance of different base classifiers

特征	分类器	准确率	召回率	精确率	F1 分数
MFCC	SVM	90.1%	89.3%	88.0%	88.6%
PSD	RF	89.1%	93.5%	83.2%	88.1%
MFCC	LSTM	88.9%	90.1%	85.3%	87.6%
PSD	LSTM	89.6%	90.3%	86.4%	88.3%
语谱图	AlexNet	93.1%	93.7%	90.6%	92.1%
梅尔语谱图	AlexNet	94.0%	93.3%	92.7%	93.0%
CQT 图	AlexNet	92.5%	93.2%	89.7%	91.4%
MFCC 颜色矩阵图	AlexNet	91.8%	91.0%	90.0%	90.5%
连续小波基图	AlexNet	94.1%	94.8%	91.8%	93.3%
原始波形	Res1dNet31	93.3%	89.7%	94.5%	92.0%

4.6 本章小结

本章介绍了基分类器的构建，包括数据增强、不同域特征和不同种分类模型。

（1）介绍了多种图像数据增强和声音数据增强方法，实验结果表明，数据增强可以明显的提高图像特征的分类精度，声音加噪和图像加噪等方法可以使精度提升约 1%，但是数据增强会降低声学特征和波形特征的分类精度。

（2）介绍了多种分类模型，包括多种机器学习模型、一维卷积神经网络、二维卷积神经网络和 LSTM 模型。首先介绍了机器学习模型，包括 SVM、KNN 和 RF，实验结果表明 MFCC 输入 SVM、PSD 输入 RF 时效果最好，准确率分别为 90.1%和 89.1%。然后介绍了 LSTM 模型，实验结果表明，当使用 MFCC 和 PSD 特征时准确率分别为 88.9%和 89.6%。然后介绍了多种一维卷积神经网络，包括自建的模型和基于 AudioSet 迁移学习的模型，实验结果表明基于 AudioSet 迁移学习的 Res1dNet31 模型效果最好，准确率为 93.3%。最后介绍了多种二维卷积神经网络，包括基于 ImageNet 和 AudioSet 的迁移学习模型，实验结果表明基于 ImageNet 迁移学习的 AlexNet 性能最好，当输入特征为梅尔语谱图时准确率可达到 94.0%。

（3）介绍了多种不同域特征，包括多种声学特征、图像特征和波形特征。实验结果表明图像特征的效果最好，其中梅尔语谱图和连续小波基图效果最好，准确率约为 94%。声学特征的效果明显低于图像特征和波形特征，准确率最高仅为 90.1%。

（4）介绍了基分类器的构建流程。

中国知网 https://www.cnki.net

5. 复杂环境下基于多分类器融合的猪咳嗽声识别

第四章构建了多个基分类器，本章基于这些基分类器，进一步研究基于多分类器融合的猪咳嗽声识别方法，结合端点检测方法，实现咳嗽声音的自动检测。本章提出了两种多分类器融合架构，分别为基于声学特征和深度特征的同构分类器融合架构和基于多分类器选择的异构分类器架构。取得好的分类器融合效果的关键，是从多个基分类器中准确的选出最优的基分类器融合方案，为此，本章重点研究了多分类器选择与融合方法。最后，针对猪咳嗽声自动检测的结果，设计了连咳判定方法，进一步实现了连咳的识别。下面分别介绍本文的多分类器融合架构以及连咳识别方法。

5.1 多分类器融合架构

多分类器融合分为同构分类器融合与异构分类器融合，同构分类器融合即将不同的特征输入多个相同类型的分类器中进行融合，异构分类器融合即将相同的或者不同的特征输入多个不同类型的分类器中进行融合。本文构建了两种多分类器融合架构，一个是基于声学特征和深度特征的同构分类器融合架构，另一个是基于多分类器选择的异构分类器融合架构，本文主要讨论两种分类器融合架构的特点和性能。

5.1.1 基于声学特征和深度特征的同构分类器融合架构

基于声学特征和深度特征的同构分类器融合架构如图 5-1 所示。首先对声音信号进行预处理，然后分别提取声音的声学特征和深度特征，并研究不同的数据增强方法，分别将声学特征和深度特征输入 SVM，并对分类结果进行融合，得到最终的识别结果。其中，深度特征指的是使用微调的 CNN 从图像特征中提取的特征。

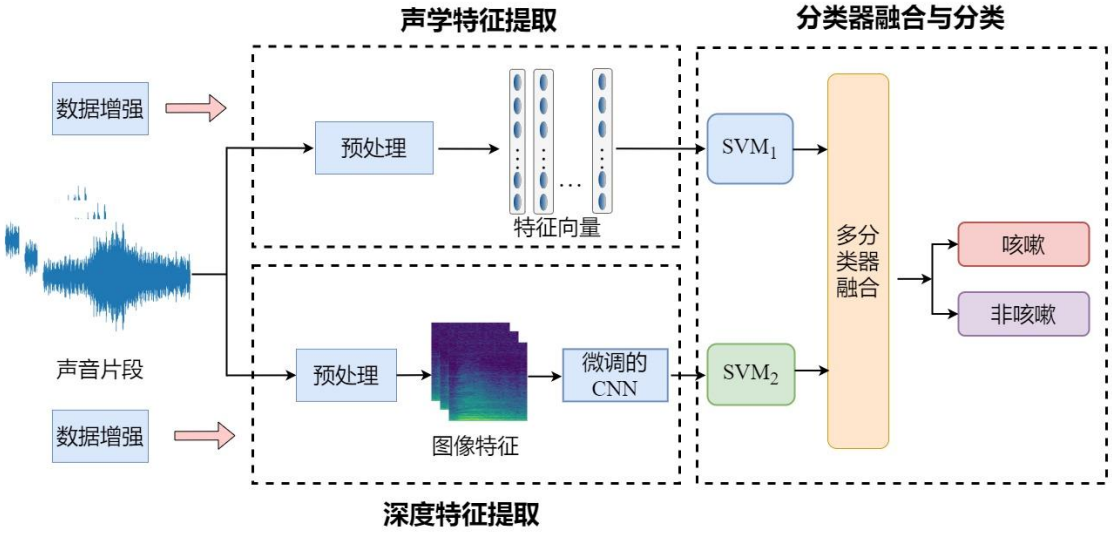


图 5-1 基于声学特征和深度特征的同构分类器融合架构

Fig.5-1 Homogeneous classifier fusion architecture based on acoustic features and depth features

中国知网 https://www.cnki.net

5.1.2 基于多分类器选择的异构分类器融合架构

基于多分类器选择的异构分类器融合架构如图 5-2 所示。首先对声音信号进行预处理，然后分别提取多种不同域的特征，并研究不同的数据增强方法，将提取的特征输入多种不同类型的分类模型，得到多个基分类器，使用本文提出的多分类器选择算法对所有的基分类器组合进行优化筛选，最后对选出的基分类器组合进行融合，得到识别结果。其中，数据增强、特征、分类模型以及基分类器构建流程在第四章有详细的阐述，此处不再过多说明。

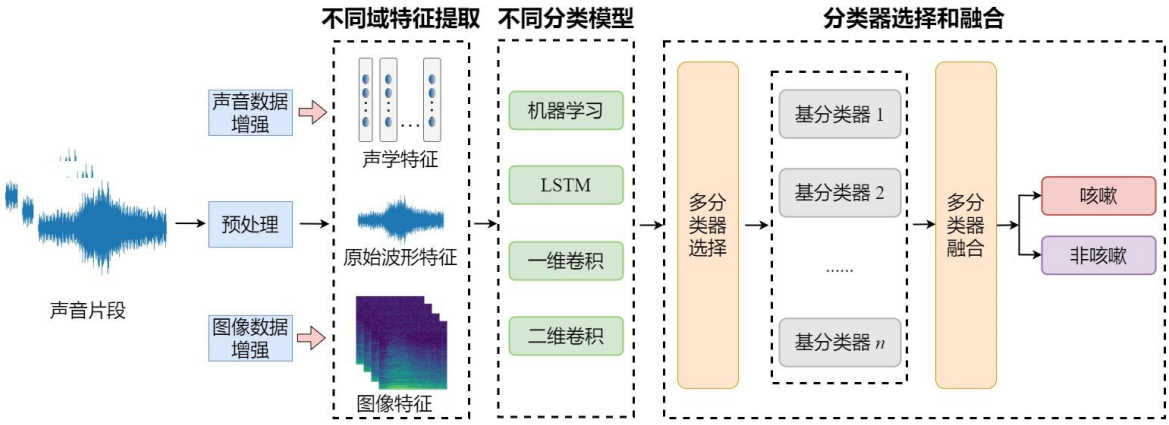


图 5-2 基于多分类器选择的异构分类器融合架构

Fig.5-2 Heterogeneous classifier fusion architecture based on multi-classifier selection

5.2 多分类器选择方法

第四章筛选出了 10 个基分类器，这 10 个基分类器之间可以构成很多种组合，经验性的选取其中的部分组合可能会导致融合结果不是最优，计算所有组合的融合结果又会导致较大的计算复杂度。因此，如何高效、准确的选出融合效果最好的基分类器组合，是异构分类器融合架构取得好的融合效果的关键。

5.2.1 基分类器的准确性与多样性度量

要想取得较为理想的多分类器融合效果，参与融合的基分类器应该“好而不同”，也就是说，每个基分类器应该具有较高的准确性，同时基分类器之间也应具有一定的多样性[104, 105]。图 5-3 所示为分类器融合效果的一个示例，图中√表示分类正确，×表示分类错误，C_1-C_3 表示三个基分类器，例 1-例 3 表示三个测试例，融合方法为多数投票法。其中，子图(a)表示一组“好而不同”的基分类器，融合之后性能明显提升。子图(b)表示一组“好而相同”的基分类器，由于分类错误的样本相同，投票之后仍然会分类错误，导致融合不起作用。子图(c)表示一组“差而不同”的基分类器，融合之后性能反而下降。因此，分类器选择算法的准则应该包括两个方面：准确性和多样性。

中国知网 https://www.cnki.net

	例1	例2	例3
C_1	√	√	×
C_2	×	√	√
C_3	√	×	√
融合	√	√	√

（a）融合提高性能

	例1	例2	例3
C_1	√	√	×
C_2	√	√	×
C_3	√	√	×
融合	√	√	×

（b）融合不起作用

	例1	例2	例3
C_1	√	×	×
C_2	×	√	×
C_3	×	×	√
融合	×	×	×

（c）融合起负作用

图 5-3 分类器融合效果示例

Fig.5-3 Example of classifier fusion effect

为此，本文定义了基分类器的准确性-多样性（*AD*）度量，用于后续的分类器选择。其中，准确性度量可以用准确率来表示。常用的多样性度量包括 Q 统计量（*Q*）、相关系数（ρ）、不合度量（*dis*）和双错度量（*df*）[106]。对于二分类任务，设两个基分类器 C_i 和 C_j 的分类结果为：

表 5-1 分类结果示例

Tab.5-1 Example of classification result

	C_i 分类正确	C_i 错误分类
C_j 正确分类	*a*	*c*
C_j 错误分类	*b*	*d*

其中 *a* 表示 C_i 分类正确且 C_j 分类正确的数据个数，*b*、*c*、*d* 以此类推。则四个多样性度量的定义如下：

$$Q_{ij} = \frac{ad - bc}{ad + bc} \tag{5-1}$$

$$\rho_{ij} = \frac{ad - bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}} \tag{5-2}$$

$$dis_{ij} = \frac{b + c}{a + b + c + d} \tag{5-3}$$

$$df_{ij} = \frac{d}{a + b + c + d} \tag{5-4}$$

令 *Acc* 表示单个基分类器的准确率，*Dv* 表示两个基分类器之间的多样性度量，为上述四个度量之一，则两个基分类器之间的准确性-多样性度量定义为：

$$AD_{ij} = \left(Acc_i + Acc_j\right)/2 \pm \beta * Dv_{ij} \tag{5-5}$$

若 *Dv* 越大表示多样性越低，则公式 5-5 中用减号，反之则用加号。其中，β是一个权重参数，用来保证准确性和多样性拥有相同的决定权。令所有基分类器中准确率的最大值和最小值分别为 Acc_{max} 和 Acc_{min}，多样性度量的最大值和最小值分别为 Dv_{max} 和 Dv_{min}，则β的计算公式为：

$$\beta = \frac{Acc_{max} - Acc_{min}}{Dv_{max} - Dv_{min}} \tag{5-6}$$

中国知网 https://www.cnki.net

5.2.2 基于准确性与多样性度量的多分类器选择方法

复杂的猪舍环境导致数据样本具有较高的多样性，使得基分类器之间的多样性会有一定的波动，这可能会导致简单的分类器选择算法的结果不可靠。因此，设计分类器选择算法时不仅要保证其高效性，还应保证其稳定性和可靠性。本文提出的分类器选择算法的算法流程如图 5-4 所示。假设有 n 个基分类器 C_1-C_n，分别以每一个基分类器为起点，计算该基分类器与其它所有基分类器的 AD 指标，根据 AD 指标选出第二个基分类器。然后分别计算剩余基分类器与这两个基分类器之间的 AD 的平均值，根据 AD 指标选出第三个基分类器。循环此过程，直至选出 n 个基分类器。最后，对选出的所有基分类器组合进行评估，选取最优的组合作为最终的融合方案。与融合所有的组合相比，该方法的高效性明显提高。

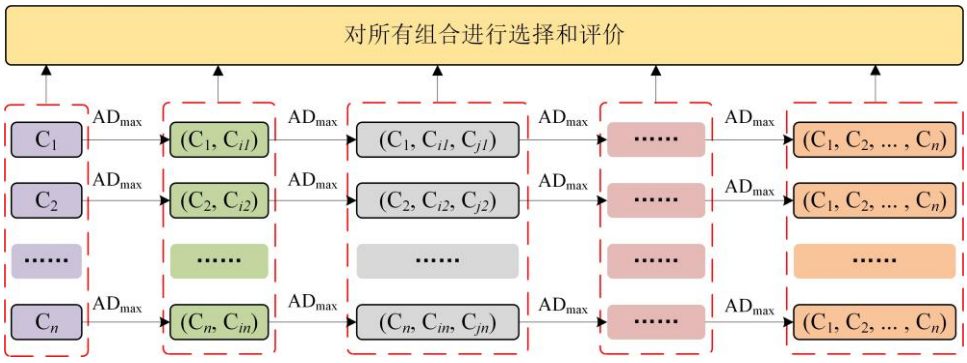


图 5-4 分类器选择算法流程

Fig.5-4 The algorithm flow of classifier selection

5.3 多分类器融合方法

常见的分类器融合方法包括硬投票和软投票等。其中，硬投票指的是采用“少数服从多数”的原则直接对每个基分类器的决策结果进行投票，软投票指的先输出每个基分类器的软判决结果，也就是属于每种类别的概率，然后对概率进行投票。一般来说，软投票的性能优于硬投票，因此本文使用软投票的方法对基分类器组合进行融合。对于基分类器组合（C_1，C_2，…，C_n），设每个基分类器输出的某个样本为咳嗽的概率分别为（P_1，P_2，…，P_n），则融合之后该样本属于咳嗽的概率为：

$$P = \frac{1}{n}\sum_{i=1}^{n} P_n \tag{5-7}$$

为进一步提高融合效果，本文使用数据样本扰动的方法，来对基分类器组合进行多样性增强[107]。也就是在每次训练基分类器时，都将数据随机打乱，以此来保证每个基分类器的训练数据都有所不同，以此来增加不同基分类器之间分类结果的多样性。

中国知网 https://www.cnki.net

5.4 单咳与连咳的判定

患有呼吸道疾病的猪在咳嗽时，常常表现为连续、多次的咳嗽[108, 109]，因此与单咳相比，连咳更能反映猪的患病情况。然而现有研究主要集中在孤立词识别，丢失了连续声音中的时间间隔等信息，导致无法实现连咳的判定，只有很少数研究实现了连咳的识别。为此，本文在实现猪咳嗽声自动检测的基础上，对单咳和连咳做进一步的判定。

连咳判定方法流程如图 5-5 所示，图中 M 表示对连续声音进行端点检测之后单个声音段的个数，K 用来对单个声音段进行计数，N 用来对连续的咳嗽个数进行计数，D_{ij} 表示相邻两个咳嗽之间的时间间隔，$D_{\max}$ 是一个统计量，表示连咳中相邻咳嗽之间的最大时间间隔。对于一段连续声音段，首先对其进行端点检测，得到多个声音段，并记录每个声音段的开始时间和结束时间。然后对每个声音段进行分类，若分类结果为非咳嗽，则继续进行分类。若检测出的咳嗽数量大于等于 3 且相邻咳嗽之间的时间间隔均小于 $D_{\max}$，则判定为一段连咳，否则判定为单咳。

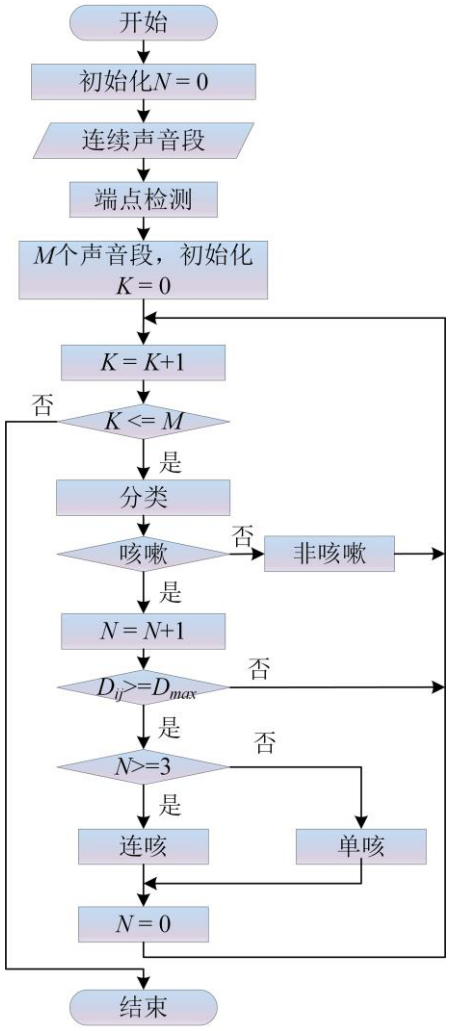


图 5-5 连咳判定方法流程

Fig.5-5 The method flow of continuous cough determination

中国知网 https://www.cnki.net

5.5 实验结果与分析

本章对实验过程和结果进行阐述，首先分别阐述两种多分类器融合架构（后续分别简称为“同构分类器融合架构”和“异构分类器融合架构”）的性能，然后阐述连咳的识别结果。

5.5.1 同构分类器融合架构的性能

根据第四章的实验结果，选取 MFCC 作为声学特征，选取梅尔语谱图和连续小波基图作为图像特征，并使用微调的 AlexNet 提取深度特征，数据增强方法为声音加噪，同构分类器融合架构的性能如表 5-2 所示。根据表 5-2 可以得知，单独使用深度特征可取得 94.1%的整体准确率，然而由于声学特征的性能较差，导致融合后的性能提升不明显，MFCC 和梅尔语谱图融合时的整体准确率为 94.5%，与单独使用深度特征相比仅仅提升了 0.4%。因此，该架构在复杂环境下的表现较为一般。

表 5-2 同构分类器融合架构的性能

Tab.5-2 Performance of homogeneous classifier fusion architecture

声学特征	图像特征	准确率	召回率	精确率	F1 分数
MFCC	--	90.1%	89.3%	88.0%	88.6%
--	梅尔语谱图	94.0%	93.3%	92.7%	93.0%
--	连续小波基图	94.1%	94.8%	91.8%	93.3%
MFCC	梅尔语谱图	94.5%	94.5%	92.8%	93.6%
MFCC	连续小波基图	94.4%	95.4%	91.9%	93.6%

5.5.2 异构分类器融合架构的性能

使用不同多样性指标的多分类器选择结果如图 5-6 所示，图中横坐标表示融合的基分类器的数量，纵坐标表示所选的最优基分类器组合的精度。可以得知，每种多样性度量选择结果的精度差距不大，整体来说，Q 统计量的效果略微优于其余指标。为进一步验证分类器选择算法的效果，本文研究了所有基分类器组合的融合精度，发现当使用 Q 统计量作为多样性度量时，选出的组合基本为实际的最优组合。因此，后续的实验结果均基于使用 Q 统计量时的选择结果。

中国知网 https://www.cnki.net

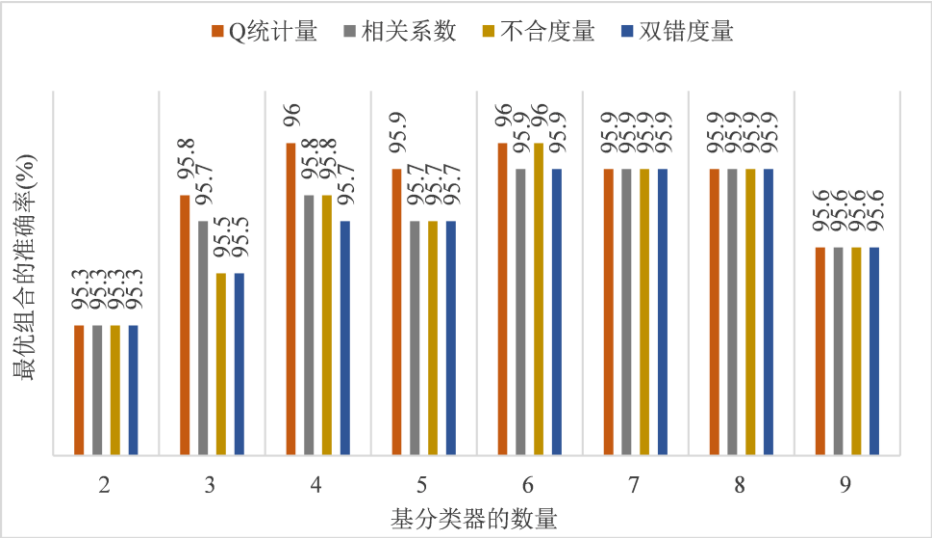


图 5-6 每种多样性度量的选择结果

Fig.5-6 The selection results of each diversity metrics

异构分类器融合架构的性能如表 5-3 所示。对比表 5-2 可以得知，同构分类器融合架构研究的特征和分类模型种类有限，且只是经验性的选取了部分基分类器组合进行融合，导致该架构的提升较小，在复杂环境下只取得了 94.5%的整体准确率。而异构分类器融合架构充分的研究了多种不同类型的特征和分类模型，并通过多分类器选择算法选出了最优的基分类器融合方案，同样为融合两个基分类器，异构分类器融合架构的准确率为 95.3%，高于同构分类器融合架构。当融合 4 个基分类器时，异构分类器融合架构的识别准确率达到了 96.0%，明显高于单个基分类器的 94.1%。

表 5-3 异构分类器融合架构的性能

Tab.5-3 Performance of heterogeneous classifier fusion architecture

基分类器的个数	准确率	召回率	精确率	F1 分数
1	94.1%	94.8%	91.8%	93.3%
2	95.3%	95.2%	94.0%	94.6%
3	95.8%	95.2%	94.9%	95.1%
4	96.0%	96.0%	94.9%	95.4%
5	95.9%	95.5%	95.0%	95.2%
6	96.0%	95.7%	95.0%	95.4%
7	95.9%	96.6%	94.1%	95.3%
8	95.9%	96.4%	94.1%	95.3%
9	95.6%	96.8%	93.3%	95.0%
10	95.4%	96.4%	93.1%	94.7%

异构分类器融合架构中，分类器融合性能随基分类器数量的变化如表 5-2 和图 5-7 所示。可以看出，当融合的基分类器的数量小于等于 4 个时，分类精度整体呈现上升的趋势，随后趋于平稳，当基分类器数量为 9 个和 10 个时，性能略微下降。当基分类器的数量为 4 个时可取的最优的性能，此时的准确率为 96.0%，明显高于单个分类器的 94.1%。当基分类器数量

中国知网 https://www.cnki.net

为 3 个时，准确率为 95.8%，基本达到最高，此时的基分类器组合为（梅尔语谱图-AlexNet，连续小波基图-AlexNet，原始波形-Res1dNet31）。

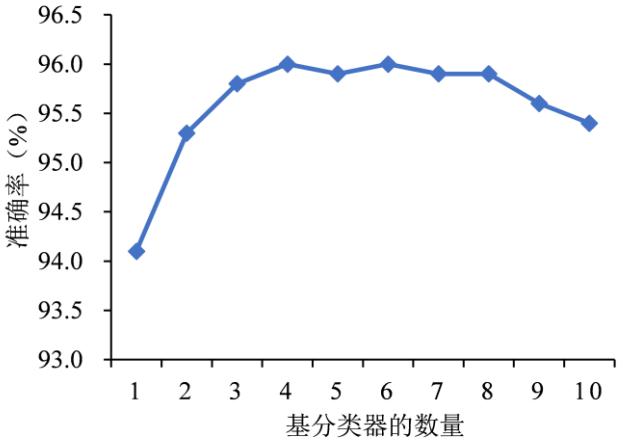


图 5-7 分类器融合性能随基分类器数量的变化

Fig.5-7 The performance of classifier fusion varies with the number of base classifiers.

5.5.3 连咳识别结果与分析

根据统计结果，连咳中相邻两个咳嗽之间的最大时间间隔 D_{max} 设置为 1.5 秒。使用不同分类器融合架构时的连咳识别结果如表 5-4 和表 5-5 所示。根据表 5-4 和表 5-5 可以得知，单个基分类器的词错误率为 9.3%，相比于单个基分类器，两种融合架构的准确率均明显提升，相比较而言，异构分类器融合架构的性能优于同构分类器融合架构，同样为融合两个基分类器，异构分类器融合架构的词错误率为 7.6%，优于同构分类器融合架构的 8.4%，但是连咳识别准确率低于同构分类器融合架构。当异构分类器融合架构的基分类器融合数量小于等于三个时，词错误率逐渐下降，当融合数量大于等于三个时，词错误率在一定范围内波动，当融合数量为 4 个时，词错误率最低，为 6.4%，明显优于单个基分类器和同构分类器融合架构。另一方面，随着基分类器数量的增加，异构分类器融合架构的连咳识别准确率整体呈上升的趋势，当融合数量为 7 个时达到最高且趋于平稳，此时的连咳识别准确率为 92.9%。

表 5-4 同构分类器融合架构的连咳识别结果

Tab.5-4 The continuous cough recognition results of homogeneous classifier fusion architecture

声学特征	图像特征	P_{dc}	P_{mc}	P_{fc}	*WER*
MFCC	梅尔语谱图	90.3%	2.5%	7.2%	8.6%
MFCC	连续小波基图	91.1%	2.4%	6.5%	8.4%

中国知网 https://www.cnki.net

表 5-5 异构分类器融合架构的连咳识别结果

Tab.5-5 The continuous cough recognition results of heterogeneous classifier fusion architecture

基分类器的个数	P_{dc}	P_{mc}	P_{fc}	*WER*
1	88.1%	4.2%	7.7%	9.3%
2	90.5%	2.5%	7.0%	7.6%
3	90.5%	2.4%	7.1%	7.2%
4	91.6%	3.0%	5.4%	6.4%
5	92.4%	2.4%	5.2%	7.0%
6	92.3%	2.2%	5.5%	7.0%
7	92.9%	2.3%	4.8%	6.7%
8	92.8%	2.2%	5.0%	6.8%
9	92.7%	2.5%	4.8%	7.2%
10	92.8%	2.3%	4.9%	7.3%

5.6 本章小结

本章主要介绍了多分类器融合方法。首先介绍了两种多分类器融合架构，然后分别介绍了本文的多分类器选择方法和多分类器融合方法，最后介绍了一种连咳判定方法。

（1）介绍了两种多分类器融合架构，分别为基于声学特征和深度特征的同构分类器融合架构，以及基于多分类器选择的异构分类器融合架构。实验结果表明，异构分类器融合架构最高可以取得 96.0%的准确率，明显高于同构分类器融合架构的 94.5%，以及单个基分类器的 94.1%。

（2）针对异构分类器融合架构，介绍了分类器融合的原则，即“好而不同”，并以此定义了基分类器之间的准确性与多样性度量，然后提出了基于该指标的分类器选择算法。实验结果表明，该算法可以精准且高效的选出最优的基分类器组合。

（3）介绍了一种连咳判定方法，可以准确的对连咳进行识别，词错误率最低可达 6.4%。

中国知网 https://www.cnki.net

6. 结论与展望

6.1 结论

本文针对实际猪舍的复杂环境，构建了复杂环境下的连续声音数据集，并基于该数据集，研究了复杂环境下的生猪咳嗽声音自动检测方法，具体研究了端点检测算法和声音信号分类算法。首先从实际猪舍环境的复杂性角度出发，构建了能够适应于复杂环境的端点检测算法。然后从多角度、多方面考虑，构建了多种不同类型的基分类器，并通过多分类器融合算法，将这些基分类器高效结合，实现了高精度的分类。本文的主要结论如下：

（1）针对现有研究缺乏连续声音数据集，且数据集未充分考虑实际猪舍复杂环境的问题，建立了复杂环境下的连续声音数据集。该数据集包括 316 段连续咳嗽和 25 段连续非咳嗽，连续咳嗽每段时长为 7-40 秒，连续非咳嗽每段时长为 10 分钟，其中共包含 3408 个咳嗽和 3133 个非咳嗽。据统计，受叠加情况影响的咳嗽约占咳嗽总数的五分之一，非咳嗽包含实际猪舍中可能出现的各种声音，且不同声音在数量上不均衡。该数据集可以很好的反映实际猪舍的复杂环境。

（2）构建了基于自适应动态门限的多重端点检测算法。通过分析得知，双门限端点检测算法虽然在较低信噪比的情况下仍能取得较好的效果，但是无法适应于多变的噪声环境，且无法处理叠加等复杂情况，导致咳嗽检出率仅为 75.8%。针对此问题，本文提出了一种新的端点检测算法，可以针对环境的复杂性自适应的设置多个门限，实现复杂环境下的高精度端点检测。结果表明，该方法可以很好的应对实际猪舍环境的复杂性，取得了 97.6%的咳嗽检出率，明显高于传统算法。

（3）构建了多个不同类型的基分类器。首先研究了不同的数据增强方法，包括图像增强和声音增强，实验结果表明，图像增强中的加噪、合成模糊和色相抖动，以及声音增强中的加噪性能最好，大约能够使图像特征的准确率提升 1%，然而数据增强会降低声学特征和波形特征的性能。其次，构建了多种分类模型，包括机器学习模型、LSTM、一维卷积神经网络和二维卷积神经网络。实验结果表明，机器学习模型最高可取得 90.1%的准确率，LSTM 模型可取得 89.6%的准确率。相比较而言，一维卷积神经网络和二维卷积神经网络的效果更好，基于 AudioSet 迁移学习的 Res1dNet31 模型可取得 93.3%的准确率，明显高于传统机器学习模型、LSTM 以及自建的一维卷积网络。基于 ImageNet 和 AudioSet 迁移学习的二维卷积神经网络性能接近，性能最好的模型包括基于 ImageNet 迁移学习的 AlexNet、基于 AudioSet 迁移学习的 CNN14 等，最高可取得 94%左右的准确率。最后，根据特征多样性等原则构建了多个基分类器，基分类器所用的特征包括声学特征、图像特征和原始波形特征。实验结果表明，图像特征的性能最好，其次为波形特征和声学特征。性能最好的特征为梅尔语谱图和连续小波基图，准确率约为 94%，原始波形输入 Res1dNet31 时准确率约为 93.3%，略微低于性能最优的图像特征，性能最差的为声学特征，最高识别准确率仅为 90.1%。

（4）构造了多分类器融合算法。构建了两种多分类器融合架构，分别为基于声学特征和深度特征的同构分类器融合架构，以及基于多分类器选择的异构分类器融合架构，实验结果

中国知网 https://www.cnki.net

表明异构分类器融合架构可取得 96.0%的准确率，高于同构分类器融合架构的 94.5%。针对异构分类器融合架构，首先分析了影响基分类器融合效果的因素，指出参与融合的基分类器应“好而不同”，为此定义了基分类器之间的准确性-多样性度量，并提出了基于该指标的基分类器选择算法。其中，多样性度量包括 Q 统计量、相关系数、不合度量和双错度量，实验结果表明使用 Q 统计量时的选择效果略微优于其他指标的选择效果。然后介绍了软投票融合方法，使用软投票的方法对选出的基分类器组合进行融合，融合性能随基分类器数量的变化而变化，当融合的基分类器数量为 4 时可取得最优的结果，此时的准确率为 96.0%，明显优于单个基分类器的 94.1%。最后，针对猪咳嗽声自动检测的结果，提出了一种连咳判定方法，实验结果表明，本文的异构分类器融合架构取得了 6.4%的词错误率。

6.2 展望

本文从实际应用的角度出发，充分考虑了实际猪舍中可能出现的多方面问题，实现了复杂环境下的高精度咳嗽检测。但是仍存在一定的不足，需要进一步研究：

（1）研究不同类型的咳嗽与疾病的关联模型

现有的研究主要集中在咳嗽的检测，缺乏咳嗽与疾病的关联模型。引起咳嗽的原因有很多，包括由粉尘、氨气等原因引起的咳嗽，以及由各种不同的呼吸道疾病引起的咳嗽等。不同的呼吸道疾病会表现出不同的咳嗽类型，而不同类型的咳嗽也会反映出不同的病理状态，比如，肺结核、支气管炎等常表现为干咳，咽喉炎、异物性肺炎等常表现为湿咳，急性喉炎、支气管炎等常表现为连咳。不同疾病的类型、不同的发病周期需要的治疗手段有所不同，只有将咳嗽与疾病进行关联，才能做到对症下药。为此，不同类型咳嗽与疾病的关联模型是后续研究的一个重点。

（2）研究基于麦克风阵列的声源定位方法

现有研究主要针对猪舍群体中咳嗽的检测，无法实现患病猪只个体的定位，这会对工作人员后续的管理和治疗产生很大的限制，为此需要进一步研究声源定位方法。然而猪舍环境属于非常复杂的混响环境，生猪叫声是非平稳带宽信号，传播模型为近场模型，导致传统的麦克风阵列方法很难取得较好的定位效果。因此如何设计麦克风阵列，并结合深度学习技术，实现高精度的定位，是后续研究的另一个重点。

中国知网 https://www.cnki.net

参考文献

[1] 《中国农业展望报告(2023—2032)》摘要[J]. 中国农村科技，2023，(06)：7-11.

[2] 毛绪强. 十年农业展望 稳产保供强农——《中国农业展望报告(2023-2032)》正式发布[J]. 农村工作通讯，2023，(09)：31-32.

[3] NORTON T，CHEN C，LARSEN M L V，et al. Review：precision livestock farming：building ‘digital representations’ to bring the animals closer to the farmer[J]. Animal，2019，13(12)：3009-3017.

[4] Baumann B，Bilkei G. Emergency-culling and mortality in growing/fattening pigs in a large Hungarian “farrow-to-finish” production unit[J]. Dtw Deutsche Tierärztliche Wochenschrift，2002，109(1)：26-33.

[5] BENJAMIN M，YIK S. Precision livestock farming in swine welfare：a review for swine practitioners[J]. Animals，2019，9(4)：133.

[6] 柏顺，颜夕宏，张生平，等. 基于梅尔频率倒谱系数与短时能量的低信噪比语音端点检测[J]. 南京师大学报(自然科学版)，2021，44 (02)：117-120.

[7] 蔡诚，章小兵，吕昊. 基于传统能零比和自相关函数主副峰结合的端点检测法[J]. 电子测试，2021，(04)：25-28.

[8] 吕昊，章小兵，蔡诚. 一种低信噪比下语音端点检测的改进算法[J]. 皖西学院学报，2021，37(02)：45-50.

[9] 毛强，刁鸿鹊，章小兵. 基于方差和谱熵结合的语音端点检测方法[J]. 常州工学院学报，2021，34(02)：36-40+52.

[10] 张子丞，谭志苇，张晨瑞，等. 基于高低频带对数能量谱比贝叶斯决策的语音端点检测[J]. 计算机科学，2021，48(S1)：33-37.

[11] 陈锡锻. 一种双门限语音端点检测算法[J]. 浙江工贸职业技术学院学报，2021，21(02)：43-46.

[12] 罗思洋. 噪声环境下的语音端点检测方法研究[D]. 云南：昆明理工大学电子与通信工程学科硕士学位论文，2021.

[13] 聂勤，周妙琪，李军成. 声源定位中双门限语音端点检测算法的改进[J]. 电子测试, 2021，(15)：47-50.

[14] 陈航，伍子嘉，彭勇，等. 基于分形维与自相关函数绝对值均值的端点检测算法[J]. 现代信息科技，2021，5(21)：108-111.

[15] 张洪德，韩鑫怡，柳林，等. 基于谱减与自适应子带对数能熵积的端点检测[J]. 兵器装备工程学报，2022，43(02)：267-273.

[16] 张洪德，韩鑫怡. 适用于短波信号侦察的话音端点检测方法[J]. 陆军工程大学学报，2023，2(01)：63-70.

[17] 王静宇，张纯，许枫. 复杂环境下基于听觉子带能量特征的鸟鸣声端点检测[J]. 计算机应用，2022，42(S1)：310-315.

中国知网 https://www.cnki.net

[18] 杨昱皞，何瑞麟，戴阳，等. 时频特征的海豚发声端点检测方法研究[J]. 应用声学，2023，42(05)：1042-1051.

[19] 孙静，聂士明，史宝军. 基于小波和经验模态分解的气体泄漏声音端点检测算法[J]. 河北工业大学学报，2022，51(06)：10-18.

[20] 高磊，章小兵. 基于功率归一化倒谱的端点检测[J]. 无线互联科技，2023，20(06)：111-114.

[21] 陈锡锻，张恪莱. 一种低信噪比环境下的语音端点检测算法[J]. 电声技术，2023，47(04)：66-68.

[22] 朱敏. 基于改进语音信号双门限法端点检测算法的研究[J]. 湖南文理学院学报(自然科学版)，2023，35(03)：48-53.

[23] 陈爱华，张石清. 基于深度神经网络和多特征融合的语音端点检测[J]. 台州学院学报，2021，43(03)：1-6+33.

[24] Khalid H，Tariq S，Kim T S，et al. ORVAE：one-class residual variational autoencoder for voice activity detection in noisy environment[J]. Neural Processing Letters，2022，54(3)：1565-1586.

[25] Mihalache S，Burileanu D. Using voice activity detection and deep neural networks with hybrid speech feature extraction for deceptive speech detection[J]. Sensors，2022，22(3)：1228.

[26] Li S，Li Y，Feng T，et al. Voice activity detection using a local-global attention model[J]. Applied Acoustics，2022，195：108802.

[27] 李姝. 基于注意力机制的语音端点检测技术研究[D]. 山东：齐鲁工业大学计算机应用技术学科硕士学位论文，2022.

[28] Zhang X L，Xu M. AUC optimization for deep learning-based voice activity detection[J]. EURASIP Journal on Audio，Speech，and Music Processing，2022，2022(1)：27.

[29] 杜晗，张维维，张巧灵，等. 基于常 Q 变换与深度神经网络的 VDR 语音端点检测[J]. 大连海事大学学报，2022，48(02)：128-135.

[30] 杜晗. 单通道 VDR 音频数据的语音端点检测与增强[D]. 辽宁：大连海事大学信息与通信工程学科硕士学位论文，2023.

[31] 单蒙，米吉提·阿不里米提，艾斯卡尔·艾木都拉. 基于小样本学习的语音端点检测[J]. 现代电子技术，2022，45(24)：145-150.

[32] Korkmaz Y，Boyacı A. Hybrid voice activity detection system based on LSTM and auditory speech features[J]. Biomedical Signal Processing and Control，2023，80：104408.

[33] Mu W，Liu B. Voice activity detection optimized by adaptive attention span transformer[J]. IEEE Access，2023，11：31238-31243.

[34] Sharma S，Malhotra R，Sharma A，et al. Unsupervised voice activity detection with improved signal-to-noise ratio in noisy environment[J]. International Journal of Nanotechnology，2023，20(1-4)：421-432.

[35] Sharma S，Malhotra R，Sharma A. An improved model for unsupervised voice activity

中国知网 https://www.cnki.net

detection[J]. International Journal of Nanotechnology，2023，20(1-4)：235-258.

[36] Heo Y，Lee S. Supervised Contrastive Learning for Voice Activity Detection[J]. Electronics，2023，12(3)：705.

[37] 程涛，姚万华，姚克，等. 基于深度学习的噪声背景通信信号端点检测[J]. 无线互联科技，2023，19(02)：13-19.

[38] 王中正，王鉴，韩焱，等. 一种舰载低信噪比环境下的音频端点检测算法[J]. 兵器装备工程学报，2023，44(03)：197-203.

[39] Li N，Wang L，Ge M，et al. Robust voice activity detection using an auditory-inspired masked modulation encoder based convolutional attention network[J]. Speech Communication，2024，157：103024.

[40] Zhang W，Liu X，Du H，et al. Voice activity detection for audio signal of voyage data recorder using residue network and attention mechanism[J]. Ships and Offshore Structures，2024，19(2)：243-251.

[41] 马辉栋，刘振宇. 语音端点检测算法在猪咳嗽检测中的应用研究[J]. 山西农业大学学报：自然科学版，2016，36(06)：72-76.

[42] 熊梓奥. 育肥猪舍中的咳嗽声监测系统设计[D]. 黑龙江：哈尔滨工程大学信息与通信工程学科硕士学位论文，2021.

[43] D Moshou，A Chedad，A Van Hirtum，et al. An Intelligent Alarm for Early Detection of Swine Epidemics Based on Neural Networks[J]. Transactions of the ASABE，2001，44(1)：167-174.

[44] Chedad A，Moshou D，Aerts J M，et al. Recognition system for pig cough based on probabilistic neural networks[J]. journal of agricultural engineering research，2001，79(4)：449-457.

[45] A V Hirtum，D Berckmans. Fuzzy approach for improved recognition of citric acid induced piglet coughing from continuous registration[J]. Journal of Sound and Vibration，2003，266：677-686.

[46] A Van Hirtum，D Berckmans. Objective recognition of cough sound as biomarker for aerial pollutants[J]. Indoor Air，2004，14(1)：10-15.

[47] V Exadaktylos，M Silva，J M Aerts，et al. Real-time recognition of sick pig cough sounds[J]. Computers & Electronics in Agriculture，2008，63(2)：207-214.

[48] Hirtum A V，Guarino M，Costa A，et al. Automatic detection of chronic pig coughing from continuous registration in field situations[J]. Computers & Electronics in Agriculture，2004：1-20.

[49] M Guarino，P Jans，A Costa，et al. Field test of algorithm for automatic cough detection in pig houses[J]. Computers & Electronics in Agriculture，2008，62(1)：22-28.

[50] Y Chung，S Oh，J Lee，D Park，H H Chang，S Kim. Automatic Detection and Recognition of Pig Wasting Diseases Using Sound Data in Audio Surveillance Systems[J]. Sensors，2013，13：12929-12942.

中国知网 https://www.cnki.net

[51] 刘振宇，赫晓燕，桑静等. 基于隐马尔科夫模型的猪咳嗽声音识别的研究[C]. 中国畜牧兽医学会信息技术分会第十届学术研讨会论文集. 中国畜牧兽医学会信息技术分会，2015：99-104.

[52] 徐亚妮. 基于语音识别技术的母猪咳嗽监测系统研究与实现[D]. 江苏：南京农业大学检测技术与自动化装置学科硕士学位论文，2016.

[53] 张振华. 基于音频分析技术的猪异常检测[D]. 山西：太原理工大学控制工程学科硕士学位论文，2017.

[54] 张振华，田建艳，王芳等. 猪咳嗽声特征参数提取与识别的研究[J]. 黑龙江畜牧兽医，2017，(23)：18-22.

[55] 龚永杰，黎煊，高云，等. 基于矢量量化的猪咳嗽声识别[J]. 华中农业大学学报，2017，036(003)：119-124.

[56] 龚永杰. 基于声音识别技术的猪咳嗽声音识别方法的研究[D]. 湖北：华中农业大学现代农业装备工程学科硕士学位论文，2018.

[57] 韩磊磊. 基于支持向量机的生猪异常声音识别与监测系统[D]. 山西：太原理工大学控制工程学科硕士学位论文. 2019.

[58] 孙浩楠. 舍养猪咳嗽声特征参数提取与识别方法研究[D]. 黑龙江：黑龙江八一农垦大学农业电气化与自动化学科硕士学位论文，2022.

[59] 孙浩楠，仝志民，谢秋菊等. 基于 BP 神经网络猪咳嗽声识别[J]. 中国农机化学报，2022，43(02)：148-154.

[60] 黎煊，赵建，高云，等. 基于深度信念网络的猪咳嗽声识别[J]. 农业机械学报，2018，049(003)：179-186.

[61] 黎煊，赵建，高云，等. 基于连续语音识别技术的猪连续咳嗽声识别[J]. 农业工程学报，2019，35(06)：182-188.

[62] Zhao J，Li X，Liu W，et al. DNN-HMM based acoustic model for continuous pig cough sound recognition[J]. International Journal of Agricultural and Biological Engineering，2020，13(3)：186-193.

[63] 赵建. 基于深度学习的猪咳嗽声音识别[D]. 湖北：华中农业大学农业电气化与自动化学科硕士学位论文，2019.

[64] 张海林. 梅山猪连续咳嗽声监测系统设计与实现[D]. 江苏：南京农业大学控制科学与工程学科硕士学位论文，2020.

[65] 沈明霞，王梦雨，刘龙申等. 基于深度神经网络的猪咳嗽声识别方法[J]. 农业机械学报，2022，53(05)：257-266.

[66] Hang S，Bin Z，Jun H，et al. Research on Improved DenseNets Pig Cough Sound Recognition Model Based on SENets[J]. Electronics，2022，11(21)：3562-3562.

[67] 宋航，赵斌，孙浩楠等. 基于 DenseNet 模型的猪咳嗽声识别算法研究[J]. 黑龙江畜牧兽医，2022，(20)：41-44+49.

[68] 宋航. 基于梅尔频率倒谱系数和深度学习的猪咳嗽声识别模型研究[D]. 黑龙江：黑龙江八一农垦大学农业工程学科硕士学位论文，2023.

中国知网 https://www.cnki.net

[69] Weizheng S，Ding T，Yanling Y，et al. A new fusion feature based on convolutional neural network for pig cough recognition in field situations[J]. Information Processing in Agriculture，2020，8(4)：573–580.

[70] Yanling Y，Ding T，Weizheng S，et al. Recognition of sick pig cough sounds based on convolutional neural network in field situations[J]. Information Processing in Agriculture，2020，8(3)：369-379.

[71] 涂鼎. 基于音频技术的生猪咳嗽声音识别方法研究[D]. 黑龙江：东北农业大学计算机科学与技术学科硕士学位论文，2020.

[72] Weizheng S，Nan J，Yanling Y，et al. Investigation of acoustic and visual features for pig cough classification[J]. Biosystems Engineering，2022，219：281-293.

[73] Weizheng S，Nan J，Yanling Y，et al. Fusion of acoustic and deep features for pig cough sound recognition[J]. Computers and Electronics in Agriculture，2022，197：106994.

[74] 纪楠. 基于多域特征融合的生猪咳嗽声识别方法研究[D]. 黑龙江：东北农业大学农业工程学科博士学位论文，2023.

[75] Yin Y，Ji N，Wang X，et al. An investigation of fusion strategies for boosting pig cough sound recognition[J]. Computers and Electronics in Agriculture，2023，205：107645.

[76] Buyu W，Weijun D，Na L，et al. A CNN-SVM Study Based on the Fusion of Spectrogram and Thermal Imaging Heterogeneous Features for Pig Cough Recognition in Field Situation[J]. International Journal of Pattern Recognition and Artificial Intelligence，2023，37(14).

[77] Wang B，Qi J，An X，et al. Heterogeneous fusion of biometric and deep physiological features for accurate porcine cough recognition[J]. PloS one，2024，19(2)：e0297655-e0297655.

[78] S Ferrari，M Silva，M Guarino，D Berckmans. Analysis of Cough Sounds for Diagnosis of Respiratory Infections in Intensive Pig Farming[J]. Transactions of the ASABE，2008，51(3)：1051-1055.

[79] S Ferrari，M Silva，M Guarino，et al. Cough sound analysis to identify respiratory infection in pigs[J]. Computers & Electronics in Agriculture，2008，64(2)：318-325.

[80] 宋知用. MATLAB 在信号分析合成中的应用-第二版[M]. 北京：北京航空航天大学出版社，2013.

[81] Zhang T，Shao Y，Wu Y，et al. An overview of speech endpoint detection algorithms[J]. Applied Acoustics，2020，160：107133.

[82] O. O A，Robertas D，Atika Q，et al. Data Augmentation and Deep Learning Methods in Sound Classification：A Systematic Review[J]. Electronics，2022，11(22)：3795-3795.

[83] Justin S，Pablo J B. Deep Convolutional Neural Networks and Data Augmentation for Environmental Sound Classification[J]. IEEE Signal Processing Letters，2017，24(3)：279-283.

[84] Dai W，Dai C，Qu S，et al. Very deep convolutional neural networks for raw waveforms[C]. //2017 IEEE international conference on acoustics，speech and signal processing (ICASSP). 2017：421-425.

中国知网 https://www.cnki.net

[85] Lee J，Park J，Kim K L，et al. Sample-level deep convolutional neural networks for music auto-tagging using raw waveforms[J]. arXiv preprint arXiv：1703.01789，2017.

[86] Kong Q，Cao Y，Iqbal T，et al. PANNs：Large-scale pretrained audio neural networks for audio pattern recognition[J]. IEEE-ACM Transactions on Audio，Speech，and Language Processing，2020，28：2880-2894.

[87] Cortes C，Vapnik V. Support-vector networks[J]. Machine learning，1995，20：273-297.

[88] Cover T，Hart P. Nearest neighbor pattern classification[J]. IEEE transactions on information theory，1967，13(1)：21-27.

[89] Ho T K. The random subspace method for constructing decision forests[J]. IEEE transactions on pattern analysis and machine intelligence，1998，20(8)：832-844.

[90] Breiman L. Random forests[J]. Machine learning，2001，45：5-32.

[91] Gemmeke J F，Ellis D P W，Freedman D，et al. Audio Set：An ontology and human-labeled dataset for audio events[C] //2017 IEEE international conference on acoustics，speech and signal processing (ICASSP). IEEE，2017：776-780.

[92] Russakovsky O，Deng J，Su H，et al. Imagenet large scale visual recognition challenge[J]. International journal of computer vision，2015，115：211-252.

[93] Krizhevsky A，Sutskever I，Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM，2017，60(6)：84-90.

[94] Szegedy C，Liu W，Jia Y，et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015：1-9.

[95] Simonyan K，Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science，2014.

[96] Szegedy C，Vanhoucke V，Ioffe S，et al. Rethinking the inception architecture for computer vision[C] //Proceedings of the IEEE conference on computer vision and pattern recognition. 2016：2818-2826.

[97] He K，Zhang X，Ren S，et al. Deep residual learning for image recognition[C] //Proceedings of the IEEE conference on computer vision and pattern recognition. 2016：770-778.

[98] Iandola F N，Han S，Moskewicz M W，et al. SqueezeNet：AlexNet-level accuracy with 50x fewer parameters and< 0.5 MB model size[J]. arXiv preprint arXiv：1602.07360，2016.

[99] Chollet F. Xception：Deep learning with depthwise separable convolutions[C] //Proceedings of the IEEE conference on computer vision and pattern recognition. 2017：1251-1258.

[100] Huang G，Liu Z，Van Der Maaten L，et al. Densely connected convolutional networks[C] //Proceedings of the IEEE conference on computer vision and pattern recognition. 2017：4700-4708.

[101] Sandler M，Howard A，Zhu M，et al. Mobilenetv2：Inverted residuals and linear bottlenecks[C] //Proceedings of the IEEE conference on computer vision and pattern recognition. 2018：4510-4520.

[102] Zhang H，Cisse M，Dauphin Y N，et al. mixup：Beyond empirical risk minimization[J].

中国知网 https://www.cnki.net

arXiv preprint arXiv：1710.09412，2017.

[103] Schmidhuber J，Hochreiter S. Long short-term memory[J]. Neural Comput. 1997，9(8)：1735-1780.

[104] Shiue Y R，You G R，Su C T，et al. Balancing accuracy and diversity in ensemble learning using a two-phase artificial bee colony approach[J]. Applied Soft Computing，2021，105：107212

[105] Sagi O，Rokach L. Ensemble learning：A survey[J]. Wiley interdisciplinary reviews：data mining and knowledge discovery，2018, 8(4)：e1249.

[106] Kuncheva L I，Whitaker C J. Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy[J]. Machine learning，2003，51：181-207.

[107] Jiang F，Yu X，Du J，et al. Ensemble learning based on approximate reducts and bootstrap sampling[J]. Information Sciences，2021，547：797-813.

[108] 陈升科. 从中兽医学角度分析猪咳嗽气喘及治疗方案[J]. 中国动物保健，2015，17(3)：22-23.

[109] 陈润生. 猪咳嗽疾病的鉴别诊断[J]. 现代农业科技，2016(14)：269-270.

中国知网 https://www.cnki.net