



河南农业科学
Journal of Henan Agricultural Sciences
ISSN 1004-3268, CN 41-1092/S

《河南农业科学》网络首发论文

题目：基于 CNN-BiLSTM 的猪咳嗽声识别方法
作者：付小鹏，周昕，王星博，徐杏，吴越，谢荣辉，单颖，叶春林，周卫东
收稿日期：2025-10-09
网络首发日期：2025-12-19
引用格式：付小鹏，周昕，王星博，徐杏，吴越，谢荣辉，单颖，叶春林，周卫东. 基于 CNN-BiLSTM 的猪咳嗽声识别方法[J/OL]. 河南农业科学.
<https://link.cnki.net/urlid/41.1092.S.20251218.1914.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 CNN-BiLSTM 的猪咳嗽声识别方法

付小朋^{1,2}, 周 昕², 王星博², 徐 杏², 吴 越², 谢荣辉³, 单 颖⁴, 叶春林¹, 周卫东²

(1. 浙江科技大学 生物与化学工程学院, 浙江 杭州 310023; 2. 浙江省农业科学院 畜牧兽医研究所, 浙江 杭州 310021; 3. 浙江省动物疫病预防控制中心, 浙江 杭州 311119; 4. 浙江大学 动物科学学院, 浙江 杭州 310058)

摘要：呼吸道疾病是规模猪场常见高发疫病之一，及时准确发现猪呼吸道疾病典型临床症状如咳嗽声对于实现早期预警、预防至关重要。以怀孕中期母猪咳嗽、尖叫、打呼噜声音为研究对象，提出了基于卷积神经网络和双向长短期记忆网络（CNN-BiLSTM）融合的猪咳嗽声识别模型，通过四阶巴特沃斯带通滤波器降噪、一阶高通滤波器预加重、短时能量端点检测等方法预处理猪声数据，采用分帧、加窗、快速傅里叶变换等方法提取预处理后声音数据的梅尔频率倒谱系数（MFCC）特征参数并对模型识别性能进行评价。结果表明，采用四阶巴特沃斯带通滤波器降噪处理可明显降低猪咳嗽声、尖叫声和打呼噜声的背景噪音，且波形无失真，猪声信号的主要能量保留完整；一阶高通滤波器预加重可明显增强高频区域能量，减弱低频区域能量、缩小区域范围；端点检测可快速标出猪声的有效语音段，减少无关信息对识别模型的干扰；通过提取预处理声音数据的 MFCC 特征参数可较好地反映猪声的声学特性，将 MFCC 系数作为特征输入用于模型的识别。融合卷积神经网络与双向长短期记忆网络的深度神经网络（CNN-BiLSTM）模型具有良好的收敛性，混淆矩阵显示猪咳嗽声、尖叫声和打呼噜声正确识别率分别为 83.67%、85.19%和 81.58%，说明模型具有良好的泛化能力；五折交叉验证显示平均准确率为 84.03%(82.79%~85.31%)，CNN-BiLSTM 模型在测试集上的准确率为 83.93%，优于 Transformer、CNN、LSTM 和 BiLSTM 模型。由此，所提出的 CNN-BiLSTM 模型在识别猪咳嗽声上具有良好的性能，能够为猪只呼吸道疾病早期检测提供新的方法。

关键词：猪咳嗽声；CNN-BiLSTM 识别模型；特征参数；混淆矩阵；五折交叉验证

中图分类号：S126

A Pig Cough Sound Recognition Method Based on CNN-BiLSTM

FU Xiaopeng^{1,2}, ZHOU Xin², WANG Xingbo², XU Xing², WU Yue², XIE Ronghui³, SHAN Ying⁴, YE Chunlin¹, ZHOU Weidong²

(1. School of Biological & Chemical Engineering, Zhejiang University of Science and Technology, Hangzhou 310023, China; 2. Institute of Animal Husbandry and Veterinary, Zhejiang Academy of Agricultural Sciences, Hangzhou 310021, China; 3. Zhejiang Center of Animal Disease Control and Prevention, Hangzhou 311119, China; 4. College of Animal Sciences, Zhejiang University, Hangzhou 310058, China)

Abstract: Respiratory diseases are one of the common and frequently-occurring diseases in large-scale pig farms. Timely and accurate detection of typical clinical symptoms of coughing in pigs is crucial for early warning and prevention. This study took the sounds of coughing, squealing, and snoring of mid-pregnancy sows as the research object and proposed a pig cough sound recognition model based on the fusion of convolutional neural network and bidirectional long short-term memory network(CNN-BiLSTM). The pig sou

nds data was preprocessed through methods such as fourth-order Butterworth band-pass filtering for noise reduction, first-order high-pass filtering for pre-emphasis, and short-time energy endpoint detection. The Mel Frequency Cepstral Coefficients(MFCC) feature parameters of the preprocessed sound data were extracted using methods such as framing, windowing, and fast Fourier transform, and the model recognition performance is evaluated. The results showed that the fourth-order Butterworth band-pass filter for noise reduction could significantly reduce the background noise of pig coughing, squealing, and snoring sounds, without distorting the waveform and retaining the main energy of the pig sound signal. The first-order high-pass filter for pre-emphasis could significantly enhance the energy in the high-frequency region, weaken

收稿日期：2025-10-09

基金项目：浙江省重点研发计划项目（2021C02050）；浙江省农机研发制造推广一体化项目（10401110124KH5601G）

作者简介：付小朋（2001-），男，安徽阜阳人，在读硕士研究生，研究方向：畜牧农机装备。E-mail: 2171794909@qq.com

通信作者：叶春林（1969-），男，浙江金华人，教授，博士，主要从事肿瘤的靶向治疗研究。E-mail: chlye2005@126.com

周卫东（1968-），男，浙江绍兴人，研究员，博士，主要从事动物营养与饲料研究。E-mail: zhouwd@zaas.ac.cn

the energy in the low-frequency region, and narrow the frequency range. Endpoint detection could quickly mark the effective speech segments of the pig sounds and reduce the interference of irrelevant information to the recognition model. The MFCC feature parameters extracted from the preprocessed sound data can well reflect the acoustic characteristics of the pig sounds, and the MFCC coefficients could be used as feature inputs for model recognition. The established deep neural network model of CNN-BiLSTM fusion had good convergence. The confusion matrix showed that the correct recognition rates of pig coughing, squealing, and snoring sounds were 83.67%, 85.19%, and 81.58% respectively, and it has good generalization ability. The five-fold cross-validation showed that the average accuracy rate was 84.03%(82.79%-85.31%). The accuracy rate of the CNN-BiLSTM model on the test set was 83.93%, which is superior to the Transformer, CNN, LSTM, and BiLSTM models. Therefore, the CNN-BiLSTM model proposed in this study has good performance in recognizing pig coughing sounds and can provide a new method for the early detection of respiratory diseases in pigs.

Key words: Pig cough sounds; CNN-BiLSTM detection model; Characteristic parameters; Confusion matrix; Five-fold cross-validation

随着生猪养殖业规模化程度的不断提高，疫病防控面临巨大挑战。其中，蓝耳病（PRRS）、猪流感等呼吸道疾病^[1]是常见的高发疫病，每年给养猪业造成较严重的经济损失。猪咳嗽^[2-4]是猪呼吸道疾病最普遍和早期的临床症状之一，如能够及时、准确地检测出猪咳嗽声，对于实现疾病的早期预警、预防至关重要。然而，传统识别猪咳嗽声的主要方法还是依赖于人工巡查和经验判断，这种方法存在着时效性差、经验要求高、主观性强、识别率不稳定等问题。

国内外学者对猪只异常声音快速检测技术的研究取得了积极进展。VAN HIRTUM 等^[5]通过快速傅里叶变换提取频域特征并设计距离函数，将猪咳嗽声检测简化为“咳嗽”和“非咳嗽”二分类，虽然在诱导猪咳嗽的实验中准确率达到 92%，但在包含各种背景声音的场景中误识别率仍高达 21%。徐亚妮等^[6]通过提取猪咳嗽声和非咳嗽声的功率谱密度（Power spectral density,PSD）特征，并以 PSD 特征作为聚类中心，利用改进的模糊 C 均值聚类算法对猪咳嗽声和非咳嗽声进行分析识别，其中，猪咳嗽声和非咳嗽声的识别准确率分别达到 83.4%和 83.1%。熊梓奥^[7]通过在不同信噪比的风扇噪声下采用 GRU 模型对猪咳嗽声进行识别，结果表明，在信噪比为 10 dB 时，猪咳嗽声的识别效果最好，达到了 82.41%的识别准确率。但是如何通过融合不同网络模型^[8-10]，进一步提高模型对猪舍背景下的猪咳嗽声的抗噪和识别能力，仍是有待探索的问题。鉴于此，提出了基于卷积神经网络和双向长短期记忆网络（CNN-BiLSTM）的猪咳嗽声识别融合模型，以怀孕中期母猪咳嗽、尖叫、打呼噜声音为研究对象，通过降噪、预加重、端点检测方法预处理采集到的猪声数据，采用分帧、加窗、快速傅里叶变换等方法对预处理后的声音数据提取相关 MFCC 特征参数，进行模型训练与识别，以期对猪咳嗽声的识别提供一种新的方法。

1 材料和方法

1.1 数据采集

猪声音采集于浙江省金华市的某养猪场，采集时间为 2024 年 10 月。共采集 10 头体质量 70 kg、3 月龄左右怀孕中期母猪的声音。其中，5 头怀孕中期母猪感染呼吸道疾病，咳嗽明显。采集工具为卓盛 M18 录音笔，安装于栏舍正上方，距离怀孕中期母猪约 0.5 m（图 1），避免与怀孕中期母猪接触干扰。采样频率为 44 100 Hz，精度为 16 位，可连续录音 24 h，每 30 min 保存一个录音文件，保存格式为 wav。采集到的猪声音样本在猪场技术员的指导下，按照猪咳嗽声和非咳嗽声（尖叫声和打呼噜声）进行人工分类标记，共得到声音样本 1 677 个，其中猪咳嗽声样本 493 个，猪非咳嗽声样本 1 184 个（尖叫声样本 810 个，打呼噜声样本 374 个）。




图 1 猪只声音采集示意图
Fig.1 Schematic diagram of pig sound collection

1.2 预处理

1.2.1 降噪 由于猪场环境中不可避免地混杂了机械声、饲料投放声、人声等背景噪声，直接对原始音频进行特征提取会导致模型误判。为此，本研究选用巴特沃斯滤波器对猪声音样本进行带通滤波，保留咳嗽声能量集中^[11]的频段，抑制低频和高频噪声。

巴特沃斯滤波器^[12]是一种平滑频率响应的模拟滤波器，其在通带内响应尽可能平坦，无波纹，过渡带平缓。对于有限阶数的巴特沃斯带通滤波器，在通带边缘频率（设为 f_l 和 f_h ）有-3 dB 的衰减。其幅频特性可表达为：

$$|H(j\omega)| = \frac{1}{\sqrt{1 + \left(\frac{\omega^2 - \omega_0^2}{\omega\Delta}\right)^{2n}}} \quad (1)$$

式中， $\omega_0 = \sqrt{\omega_l \omega_h}$ ：中心角频率， $\Delta = \omega_h - \omega_l$ ：带宽， n ：滤波器阶数。

根据抽样分析，猪声音样本的能量主要集中在 100 ~2 000 Hz。因此，本研究设计了一个四阶巴特沃斯带通滤波器，将通带设置为 100 ~2 000 Hz，采样频率设置为 44.1 kHz。

1.2.2 预加重 由于语音与非语音生物声往往存在明显的高频能量衰减，为了在特征提取阶段更好地保留高频部分，本研究采用一阶高通滤波器^[13]对降噪后的猪声信号进行预加重。其传递函数为：

$$H(z) = 1 - \alpha z^{-1} \quad (2)$$

式中， $H(z)$ ：输出与输入的比值， α ：预加重系数，通常取值在 0.95~0.97，在本研究中 α 取值 0.97。

1.2.3 端点检测 由于猪咳嗽声往往零散分布在较长时间的录音中，为了减少无效冗余数据对模型训练的干扰，本研究对语音段落进行自动检测并截取有效声音段，采用基于短时能量(Short-time energy,STE)^[14]的端点检测方法。

首先，将预加重后的信号按 25 ms 帧长、10 ms 帧移进行分帧，选用 25 ms 的帧长和 10 ms 的帧移能够捕捉声音的瞬时变化，并保证相邻帧之间有足够的重叠，提供良好的时间分辨率。

接着使用均方根(RMS)能量作为短时能量度量，计算公式如下：

$$E(n) = \sqrt{\frac{1}{N} \sum_{m=0}^{N-1} x^2(n+m)} \quad (3)$$

式中， $E(n)$ ：第 n 帧的短时能量， N ：帧长， $x^2(n+m)$ ：预加重后的音频信号在 $n+m$ 处的平方值。同时采用自适应阈值^[15]方法计算能量阈值，公式如下：

$$T_E = \mu_E + 0.5\sigma_E \quad (4)$$

式中， T_E ：自适应能量阈值， μ_E ：能量均值， σ_E ：能量的标准差。

1.3 猪声音的特征参数提取

选择梅尔频率倒谱系数(MFCC)^[16]作为猪咳嗽声声学模型的特征输入。MFCC 不仅能够模拟人耳的听觉特性，还可以有效表征声音信号的频谱包络特征，其非线性的频率映射特性与哺乳动物听觉系统的频率响应特性相似，能够更好地捕捉猪咳嗽声中的关键声学特征。此外，MFCC 具有良好的抗噪性能，对环境噪声具有一定的鲁棒性，这对于养殖环境中的声音识别任务尤为重要。MFCC 特征提取流程如图 2 所示。




图 2 MFCC 特征提取流程图

Fig.2 Flow chart of MFCC feature extraction

在分帧处理阶段，针对猪咳嗽声的时域特性，采用帧长 25 ms、帧移 10 ms 进行分帧操作以确保相邻帧之间的平滑过渡；为解决由分帧导致的猪声信号频域中的频谱泄露问题，优化频域分析效果，选用汉明窗进行加窗，选择汉明窗的原因在于其具有较好的频谱泄露抑制特性，同时保持了相对集中的主瓣，进而在频谱平滑度与频率分辨率之间实现了良好平衡。汉明窗函数的数学表达式为：

$$w(n) = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1 \quad (5)$$

式中， N ：窗长。

分帧后的信号可表示为：

$$x_i(n) = x(n + iM)w(n), \quad 0 \leq n \leq N-1 \quad (6)$$

式中， $x_i(n)$ ：经过加窗处理后的第 i 帧信号段， M ：帧间隔， i ：帧序号。

对每一帧信号进行快速傅里叶变换^[17]，将具有时域特性的声音信号转化为频域特性。公式如下：

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j\frac{2\pi}{N}kn} \quad (7)$$

式中， N ：FFT 点数，这里取值 512， $x(n)$ ：第 n 个采样点的幅值， $X(k)$ ：频域第 k 点的复数幅值。进行 FFT 后，通过幅度谱计算得到功率谱^[18]：

$$P(k) = |X(k)|^2 = \text{Re}[X(k)]^2 + \text{Im}[X(k)]^2 \quad (8)$$

得到功率谱之后进行梅尔滤波器^[19]能量的计算，本研究采用三角滤波器组对功率谱进行加权求和。计算公式如下：

$$Y_m(k) = \sum_{n=1}^{N-1} p(k) H_m(k) \quad (9)$$

式中， $H_m(k)$ ：Mel 频率滤波器组。

在获得梅尔滤波器组输出后，进行对数变换以压缩动态范围。对数变换后的能量谱表示为：

$$S(m) = \ln\left(\sum_{n=1}^{N-1} p(k) Y_m(k)\right) \quad (10)$$

式中， $Y_m(k)$ ：第 m 个梅尔滤波器的频率响应。

最后，通过离散余弦变换（DCT）将对数梅尔频谱转换为 MFCC 系数：

$$MFCC_n = \sum_{m=0}^{M-1} S(m) \cos\left(\frac{\pi n(m+\frac{1}{2})}{M}\right), \quad 0 \leq n < L \quad (11)$$

式中， M ：滤波器组数量，这里取值 24， L ：所需的 MFCC 系数个数。

1.4 CNN-BiLSTM 猪咳嗽声识别模型

为充分挖掘猪咳嗽等声音在时频域上的深层特征，在 CNN^[20]、LSTM^[21]以及双向长短期记忆网络（BiLSTM）^[22]的基础上，通过结合 CNN 和 BiLSTM 网络模型的优势并设计新的连接架构，提出了一种融合卷积神经网络与 BiLSTM 的深度神经网络（CNN-BiLSTM）模型，用于多类猪声音的分类与识别。

模型以 MFCC 参数为输入特征，通过多层神经网络模块完成对声音片段的分类识别，CNN 部分用于捕捉输入语音特征图中的局部结构特征，并通过展平操作将 CNN 输出的特征图压缩为时序序列格式，

BiLSTM 部分则用于对展平提取的时序特征序列进行深度建模，形成端到端的猪声音识别体系。卷积层采用若干组二维卷积核，通过滑动窗口提取局部特征，配合最大池化操作实现空间维度的压缩和特征增强，每一卷积层后接 ReLU 激活函数，以增加模型的非线性表达能力。

在本模型中使用了 2 层卷积结构，第 1 层卷积核数量为 32，核尺寸为 3×3 ，第 2 层卷积核数量为 64，核尺寸同样为 3×3 ，2 层卷积分别配以 2×2 的最大池化操作，经过卷积模块提取的特征被展平并输入至 BiLSTM 模块，在时序特征提取完成后，模型通过全连接层将高维特征映射到最终分类空间，全连接层的输出维度等于类别数，最终通过 softmax 激活函数输出每一类别的概率值，实现对输入样本的分类。该模型结构如图 3 所示。




图 3 CNN-BiLSTM 猪咳嗽声识别模型结构

Fig.3 Structure of CNN-BiLSTM pig cough sound recognition model

该模型采用双向 LSTM 架构作为猪咳嗽声识别的时序推理引擎，BiLSTM 结构由正向 LSTM 和反向 LSTM 共同构成。其具体处理流程如下所示：

将 CNN 输出的空间特征 $X = [x_1, x_2, \dots, x_T]$ 作为输入序列，在时刻 t 的双向输出 h_t 由前向层 $\vec{h}_t$ 和后向层 $\overleftarrow{h}_t$ 拼接而成。前向层在时刻 t 接收输入特征 x_t 和上一时刻的隐藏状态 $\vec{h}_{t-1}$ ，并通过权重参数集 $W_{lstm}^{\rightarrow}$ 更新得到新的隐藏状态 $\vec{h}_t$ 。同理，后向层则以逆序方式从序列末端向前迭代，通过权重参数集 $W_{lstm}^{\leftarrow}$ 更新得到新的隐藏状态 $\overleftarrow{h}_t$ 。当前后层独立运行后，在时刻 t 将正向输出 $\vec{h}_t$ 与后向输出 $\overleftarrow{h}_t$ 进行拼接，得到融合前后信息的双向输出 h_t 。其公式如下所示：

$$\vec{h}_t = LSTM(X_t, \vec{h}_{t-1}; W_{lstm}^{\rightarrow}) \quad (12)$$

$$\overleftarrow{h}_t = LSTM(X_t, \overleftarrow{h}_{t+1}; W_{lstm}^{\leftarrow}) \quad (13)$$

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] \quad (14)$$

式中， $W_{lstm}^{\rightarrow}$ ：前向 LSTM 的权重参数， $W_{lstm}^{\leftarrow}$ ：后向 LSTM 的权重参数。

前向与后向传播隐层中每个 LSTM 单元处理信息流的过程如下所示：

具体地，将特征 x_t 输入到每个 LSTM 单元并通过门控机制中的输入门 i_t 、遗忘门 f_t 、输出门 o_t 来进行信息流的控制。其中，输入门主要负责调控当前时刻的新信息有多少需要被存入长期记忆中，同时利用 $\tanh$ 层创建一个新的候选值向量，进而生成候选记忆；遗忘门主要决定细胞状态中有多少比例需要被保留或者丢弃；随后将输入门输出的元素、上一个记忆状态输出的元素、遗忘门输出的元素以及候选记忆状态输出的元素进行元素之间的运算，得到更新状态下的记忆核心；输出门主要负责计算当前输入和前一时刻的隐藏状态来生成一个介于 0 至 1 之间的门控信号；最后将更新状态下的记忆核心通过 $\tanh$ 函数进行压缩然后与输出门输出的元素进行运算，最终得到当前隐藏状态下的记忆。

该 BiLSTM 层的双向结构能够更好地捕捉猪咳嗽声的物理特性，进而更好地解决猪咳嗽声片段边界模糊的问题。

1.5 模型训练

模型训练在 Python 3.10 环境下进行，深度学习框架选用 TensorFlow 2.12，主要运行平台为一台搭载 NVIDIA RTX 3 080 GPU 的工作站，操作系统为 Windows 11。

将试验采集到的 1 677 个样本数据，按照类别（猪咳嗽声/猪非咳嗽声）以 8:1:1 的比例随机划分为训练集、验证集和测试集。其中，训练集包含 1 341 个样本（猪咳嗽声 395 个，猪非咳嗽声 946 个），验证集包含 168 个样本（猪咳嗽声 49 个，猪非咳嗽声 119 个），测试集同样包含 168 个样本（猪咳嗽声 49 个，猪非咳嗽声 119 个）。

本研究使用划分的训练集样本和验证集样本进行建模，用独立的测试集样本进行测试，将测试结果作为最终的性能指标结果。同时为了验证所提 CNN-BiLSTM 模型在确定的超参数和模型架构下对不同数据划分的稳定性，选择在“训练集+验证集”的合并集样本上进行五折交叉验证，通过计算 5 次验证结果的平均值和标准差来进一步评估该模型配置对不同数据划分的稳定性。

本研究设置初始学习率为 0.001，批次大小为 32，训练轮次上限为 100 轮，选择 Adam 优化器优化迭代参数 θ 。为进一步提升模型的泛化性能并有效控制过拟合风险，训练过程中引入了 Early Stopping 策略^[23]，即训练过程中实时监控验证集损失，若其下降，则继续训练；若其在连续 k 轮内不再下降，即停止训练，并保留当前最优参数 θ 用于后续评估。

令训练集记为 $\{(X^{(i)}, y^{(i)})\}_{i=1}^N$ ，其中 N 为训练集中样本的总数，每个输入 $X^{(i)}$ 为对应音频的 MFCC 特征矩阵，输出 $y^{(i)}$ 为 One-Hot 标签向量。模型依次经过 CNN 特征提取、BiLSTM 时序建模与全连接分类三大模块。记为：

$$S^{(i)} = f_{\text{cnn}}(X^{(i)}; W_{\text{cnn}}) \quad (15)$$

$$H^{(i)} = f_{\text{BiLstm}}(S^{(i)}; W_{\text{BiLstm}}) \quad (16)$$

式中， $S^{(i)}$ ：CNN 特征提取模块对第 i 个输入 $X^{(i)}$ 输出的空间特征表示， W_{cnn} ：CNN 卷积核权重， $H^{(i)}$ ：BiLSTM 模块对 $S^{(i)}$ 输出的双向时序特征拼接结果， W_{BiLstm} ：BiLSTM 权重。

其后通过全连接层映射并经 softmax 激活得到预测概率：

$$\hat{y}^{(i)} = \text{softmax}(W_{fc}H^{(i)} + b_{fc}) \quad (17)$$

式中， $\hat{y}^{(i)}$ ：模型经过全连接层和 softmax 激活后对第 i 个样本的预测概率分布， W_{fc} ：全连接层权重， b_{fc} ：全连接层的偏置向量。

模型采用交叉熵损失衡量预测分布与真实分布的差异。在训练过程中，通过最小化交叉熵损失，可以促使模型不断优化预测结果的置信度，提高整体识别精度。对于第 i 个样本，其损失为：

$$\mathcal{L}^{(i)}(\theta) = -\sum_{c=1}^C y_c^{(i)} \log \hat{y}_c^{(i)} \quad (18)$$

式中， $\mathcal{L}^{(i)}(\theta)$ ：第 i 个样本在参数 θ 下的损失值， $y_c^{(i)}$ ：样本 i 的真实类别分布， C ：类别总数。

1.6 评价指标

通过混淆矩阵^[24]可以表示猪声分类识别结果的咳嗽声正确识别个数、非咳嗽声正确识别个数、咳嗽声被错误分类成非咳嗽声个数以及非咳嗽声被错误分类成咳嗽声个数。同时采用准确率、精确率、召回率、F1 值、模型大小和测试时间来综合衡量猪咳嗽声识别模型的性能。

准确率（Accuracy）为模型识别正确的样本数占总样本数的比例，反映了模型整体的识别能力。其公式为：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (19)$$

召回率（Recall）反映了模型对真实“咳嗽声”样本的检测能力。其公式为：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (20)$$

精确率（Precision）衡量了模型识别为“咳嗽声”时的准确程度。其公式为：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (21)$$

F1 分数（F1-score）为召回率和精确率的调和平均，用于在二者间取得平衡评价。其公式为：


$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (22)$$

式中，TP：模型正确识别为“咳嗽声”的样本数，TN：模型正确识别为“非咳嗽声”的样本数，FP：模型误识别为“咳嗽声”的非咳嗽声样本数，FN：模型误识别为“非咳嗽声”的咳嗽声样本数。

2 结果与分析

2.1 降噪效果分析

图 4 为基于巴特沃斯带通滤波器处理后猪只各类声音样本前后对比波形图。结果显示，经过巴特沃斯带通滤波后，猪咳嗽声样本在 1.0~1.2 s、猪尖叫声样本在 0.6~1.2 s、猪打呼噜声样本在 0.4~0.8 s 降噪效果明显，波形几乎没有失真且猪声信号样本的主要能量保留完整，噪声背景大幅减弱，信噪比得到明显增强，猪只各类声音特征变得更加清晰。



a、b 为猪咳嗽声降噪前后的波形图，c、d 为猪尖叫声降噪前后的波形图，e、f 为猪打呼噜声降噪前后的波形图。

a and b are the waveforms before and after noise reduction of the coughing sound of pigs, c and d are the waveforms before and after noise reduction of the screaming sound of pigs, e and f are the waveforms before and after noise reduction of the snoring sound of pigs.


图 4 猪只各类声音样本降噪前后对比波形图

Fig.4 the comparison waveforms of various sounds samples of pigs before and after noise reduction

2.2 预加重效果分析

图 5 为猪声样本经过预加重处理后的波形图。结果显示，经过预加重处理后，猪只各类声音波形图中的高频部分被增强，而低频部分被相对抑制，其中猪咳嗽声波形图在 0~0.2 s、0.4~0.6 s 和 1.0~1.2 s 时间段波形振幅变小，信号快速变化部分得到凸显，波形显得更加清晰；猪尖叫声在 0.2~1.2 s 时间段、猪打呼噜声在 0.4~0.8 s 时间段处理效果和猪咳嗽声效果相似，幅度明显减小，波形变得更加纤细。

图 6 为猪声样本经过预加重处理前后的梅尔频谱图。结果显示，经过预加重处理后，高频区域（图形上方）的能量得到明显增强，颜色变得更亮，而低频区域（图形下方）颜色变深，范围缩小，能量相对减弱。




a 为预加重后的猪咳嗽声波形图, b 为预加重后的猪尖叫声波形图, c 为预加重后的猪打呼噜声波形图。

a is the waveform diagram of the coughing sound of the pigs after pre-emphasis, b is the waveform diagram of the screaming sound of the pigs after pre-emphasis, c is the waveform diagram of the snoring sound of the pigs after pre-emphasis.

图 5 猪只各类声音样本预加重后波形图

Fig.5 Waveform diagrams of various sounds samples of pigs after pre-emphasis



a、b 为猪咳嗽声预加重前后的梅尔频谱图, c、d 为猪尖叫声预加重前后的梅尔频谱图, e、f 为猪打呼噜声预加重前后的梅尔频谱图。


a and b are the MEL spectrograms before and after the pre-emphasis of the pigs coughing sound, c and d are the MEL spectrograms before and after the pre-emphasis of the pigs screaming sound, e and f are the MEL spectrograms before and after the pre-emphasis of the pigs snoring sound.

图 6 猪只各类声音样本预加重前后对比梅尔频谱图

Fig.6 MEL spectrograms of various sounds samples of pigs before and after pre-emphasis

2.3 端点检测效果分析

当帧能量超过阈值时判定为有效语音段, 图 7 为猪声音样本经端点检测后的效果图。结果显示, 猪咳嗽声样本在 0~0.2 s、1.0~1.3 s 时间段检测出有效语音段, 并在相应的短时能量曲线中标记出猪咳嗽声有效区域; 猪尖叫声样本在 0.8~1.1 s 时间段检测出有效语音段, 并在相应的短时能量曲线中标记出猪尖叫声有效区域; 猪打呼噜声样本在 0.4~0.8 s 时间段检测出有效语音段, 并在相应的短时能量曲线中标记出猪打呼噜声有效区域。经过端点检测后, 猪只各类声音样本的有效语音段均已标出, 减少了无关信息对识别模型的干扰, 从而提高了对猪只各类声音样本识别的准确率。



a、b 分别为猪咳嗽声端点检测后的波形图以及能量曲线图，c、d 分别为猪尖叫声端点检测后的波形图以及能量曲线图，e、f 分别为猪打呼噜声端点检测后的波形图以及能量曲线图。


a and b are the waveform diagrams and energy curves of the pigs coughing sound after endpoint detection, respectively; c and d are the waveform diagrams and energy curves of the pigs screaming sound after endpoint detection, respectively; e and f are the waveform diagrams and energy curves of the pigs snoring sound after endpoint detection, respectively.

图 7 猪只各类声音样本端点检测效果图

Fig.7 the effect diagrams of endpoint detection for various sounds samples of pigs

2.4 特征参数提取效果分析

按照数值大小选取前 12 个 MFCC 系数作为特征向量，图 8 为猪只各类声音的 MFCC 特征图，其中，X 轴表示 MFCC 特征的维数，Y 轴表示猪只信号分帧的帧数，Z 轴表示猪只声音信号的 MFCC 系数。结果显示，猪咳嗽声、尖叫声和打呼噜声的静态特性前端变化较为尖锐，后端变化较为平滑，颜色深浅表示猪声信号在不同维度下的能量分布。不同维度和不同帧对应的 MFCC 系数不同，这些系数较好地反映猪只声音的声学特性，为后续模型识别奠定了基础。



a 为猪咳嗽声的 MFCC 特征图，b 为猪尖叫声的 MFCC 特征图，c 为猪打呼噜声的 MFCC 特征图。

a is the MFCC feature map of a pigs coughing sound, b is the MFCC feature map of a pigs screaming sound, c is the MFCC feature map of a pigs snoring sound.

图8 猪只各类声音样本 MFCC 特征图

Fig.8 MFCC feature maps of various sounds samples from pigs

2.5 猪咳嗽声识别效果分析

2.5.1 模型训练与验证曲线 图9所示为模型在100个训练轮次下的准确率、精确率、召回率和F1值变化曲线。由图9a可知，随着训练轮次的增加，训练损失曲线和验证损失曲线整体呈现出下降趋势，且模型训练至第70轮后训练损失值趋于稳定。同时由图9b可知，验证准确率曲线、精确率曲线、召回率曲线和F1值变化曲线在模型训练至第70轮后趋于稳定，表明模型在最小化误差方面具有良好的收敛性，验证了训练方法的合理性与 Early Stopping 策略的有效性。




图9 模型在训练集和验证集上的性能曲线

Fig.9 The performance curves of the model on the training set and validation set

2.5.2 混淆矩阵 图10所示为模型测试集混淆矩阵结果。图中从左往右的对角线表示猪声样本被正确分类的个数，混淆矩阵结果显示，猪咳嗽声正确识别率为83.67%，猪尖叫声正确识别率为85.19%，猪打呼噜声正确识别率为81.58%，总体样本的识别率达到了83.93%。可见CNN-BiLSTM模型对于猪咳嗽声识别效果良好。由于数据集中猪尖叫声样本多于猪咳嗽声和猪打呼噜声，模型对猪尖叫声的识别率更高，尽管如此，模型在识别少数类声音时仍然表现良好，说明CNN-BiLSTM模型具有良好的泛化能力。




图10 CNN-BiLSTM 模型测试集混淆矩阵

Fig.10 Confusion matrix of the CNN-BiLSTM model on test set

2.5.3 五折交叉验证 为了验证CNN-BiLSTM模型配置在不同数据划分条件下的稳定性，选择在“训练集+验证集”的合并集上进行五折交叉验证（5-fold cross-validation）^[25]。具体流程如下：（1）随机打乱合并数据集样本顺序；（2）将打乱后的数据集均匀划分成5个大小相等的子集；（3）选择其中1个子集作为验证集，其余4个子集作为训练集，循环进行5次独立训练与验证（确保每个子集仅被用作

一次验证集); (4) 每一轮验证后, 记录模型在验证集上的准确率、精确率、召回率以及 F1 值。结果如表 1 所示。在 5 次交叉验证中, 模型准确率均保持在较高水平, 波动幅度较小, 表现出良好的鲁棒性。其中, 单轮验证准确率介于 82.79%~85.31%, 最终平均准确率达到 84.03%。此外, 精确率、召回率和 F1 值同样维持了较高水平, 进一步验证了所提 CNN-BiLSTM 模型配置在不同数据集划分条件下的一致性与稳定性。

表 1 五折交叉验证结果
Tab.1 5-fold cross-validation results

批次 Batch	%			
	准确率 Accuracy	精确率 Precision	召回率 Recall	F1 值 F1-score
第 1 组 Fold 1	83.68	82.86	83.31	83.09
第 2 组 Fold 2	82.79	81.36	82.14	81.75
第 3 组 Fold 3	83.87	83.34	83.58	83.46
第 4 组 Fold 4	84.50	84.01	84.43	84.22
第 5 组 Fold 5	85.31	84.63	84.89	84.76
平均值 Average value	84.03	83.24	83.67	83.46
标准差 Standard deviation	0.84	1.12	0.95	1.03

2.5.4 不同模型识别性能比较 为了验证本研究提出的 CNN-BiLSTM 模型在猪咳嗽声音识别中的有效性, 比较研究了 CNN、LSTM、BiLSTM 和 Transformer^[26]在识别猪咳嗽声音时的性能。所有模型均采用相同的训练、验证和测试划分、特征输入, 确保实验条件的一致性。不同模型在测试集上的识别结果如表 2 所示。从表 2 可以看出, Transformer 模型具有一定的识别准确率, 达到了 83.65%, 但模型大小相对其他模型而言较大, 测试时间较长。CNN 模型虽然测试时间较短, 但是在测试集上的识别准确率最低。CNN-BiLSTM 模型相对于 BiLSTM、LSTM 和 CNN 而言, 虽然牺牲了少量的存储空间, 但是在模型识别效果上有显著提升, 识别准确率达到 83.93%, 精确率达到 83.21%, 召回率达到 83.63%, F1 值达到 83.42%。综合而言, CNN-BiLSTM 模型在其对比模型中表现最佳, 表明 CNN-BiLSTM 模型具有良好的猪咳嗽声识别性能。

表 2 不同模型在测试集上的识别性能比较
Tab.2 Comparison of recognition performance of different models on the test set

模型 Model	准确率/% Accuracy	精确率/% Precision	召回率/% Recall	F1 值/% F1-score	模型大小 /MBModel size	测试时间/s Test time
CNN-BiLSTM	83.93	83.21	83.63	83.42	3.71	0.49
Transformer	83.65	83.06	83.48	83.27	4.67	0.65
BiLSTM	81.16	80.32	80.76	80.54	3.54	0.57
LSTM	80.71	80.11	80.59	80.35	2.98	0.52
CNN	79.68	79.13	79.51	79.32	3.23	0.47

3 结论与讨论

本试验首先采用四阶巴特沃斯带通滤波器降噪、一阶高通滤波器预加重、短时能量端点检测等方法预处理猪声数据。四阶巴特沃斯带通滤波器降噪处理可明显降低猪咳嗽声、猪尖叫声和猪打呼噜声的背景噪音, 且波形无失真, 猪声信号的主要能量保留完整; 一阶高通滤波器对降噪后的猪声信号预加重, 可明显增强高频区域能量, 减弱低频区域能量、缩小区域范围; 端点检测可快速标出猪声的有效语音段, 减少无关信息对识别模型的干扰, 提高对猪只各类声音样本识别的准确率。

其次, 通过对猪声样本进行预处理得到有效的语音段后, 采用分帧、加窗、快速傅里叶变换等方法提取相关声音数据的MFCC特征参数, 猪咳嗽声、尖叫声和打呼噜声MFCC特征图的静态特性为前端变化较为尖锐, 后端变化较为平滑, 不同维度和不同帧数中对应的MFCC系数不同, 可较好地反映猪只各类声音样本的声学特性。将得到的MFCC参数作为输入特征, 并在CNN和BiLSTM网络模型的基础

上,建立了卷积神经网络与BiLSTM的深度神经网络(CNN-BiLSTM)融合模型,损失曲线整体呈现出下降趋势,准确率曲线、精确率曲线、召回率曲线和F1值变化曲线在模型训练至第70轮后趋于稳定,说明模型具有良好的收敛性;测试集混淆矩阵结果显示,猪咳嗽声、尖叫声和打呼噜声正确识别率分别为83.67%、85.19%和81.58%,说明模型具有良好的泛化能力;五折交叉验证结果显示,CNN-BiLSTM模型的平均准确率为84.03%(82.79%~85.31%),模型的识别准确率波动范围较小,说明模型配置具有良好的稳定性。

最后,比较研究了CNN、LSTM、BiLSTM、CNN-BiLSTM和Transformer模型在识别猪咳嗽声音方面的性能。结果显示,CNN-BiLSTM模型在测试集上的准确率、精确率、召回率和F1值分别达到83.93%、83.21%、83.63%和83.42%,在所有对比模型中表现最优;与此同时,虽然CNN-BiLSTM模型在大小上比BiLSTM、LSTM和CNN模型多占用了一些存储空间,但是在测试集样本的识别准确率上却明显优于BiLSTM、LSTM和CNN模型;在推理效率方面,CNN-BiLSTM模型的测试时间为0.49s,仅次于CNN模型的测试时间0.47s,优于其他模型的测试时间。

综上所述,本研究提出的CNN-BiLSTM模型在识别猪咳嗽声上具有良好的性能,能够为猪只呼吸道疾病早期检测提供新的方法。

参考文献:

- [1] 王艾晶, 杨龙峰, 王瑾. 冬季生猪常见呼吸道疾病及防控措施[J]. 现代畜牧科技, 2024(6): 94-96.
WANG A J, YANG L F, WANG J. Research on common respiratory diseases in winter and their prevention and control measures in pig farming[J]. Modern Animal Husbandry Science & Technology, 2024(6): 94-96.
- [2] 孙燕, 赵立平, 玄世豪, 等. 猪繁殖与呼吸综合征流行病学、诊断及防控措施研究[J]. 猪业科学, 2025, 42(7): 68-70.
SUN Y, ZHAO L P, XUAN S H, et al. Study on epidemiology, diagnostic methods and prevention and control measures of porcine reproductive and respiratory syndrome[J]. Swine Industry Science, 2025, 42(7): 68-70.
- [3] 陈玲, 闻兵. 猪咳嗽的病因与诊断[J]. 猪业观察, 2023(4): 40-42..
CHEN L, WEN B. Etiology and diagnosis of pig cough[J]. Swine Industry Outlook, 2023(4): 40-42.
- [4] 许亚改. 基于声音的猪常见呼吸道疾病鉴别分析[J]. 中国动物保健, 2023, 25(8): 7-8.
XU Y G. Differential analysis of common respiratory diseases in pigs based on sound[J]. China Animal Health, 2023, 25(8): 7-8.
- [5] HIRTUM A V, GUARINO M, COSTA A, et al. Automatic detection of chronic pig coughing from continuous registration in field situations[C]//Proceedings of the 5th International Workshop on Models and Analysis of Vocal Emissions for Biomedical Applications, 2003: 251-254.
- [6] 徐亚妮, 沈明霞, 闫丽, 等. 待产梅山母猪咳嗽声识别算法的研究[J]. 南京农业大学学报, 2016, 39(4): 681-687.
XU Y N, SHEN M X, YAN L, et al. Research of predelivery Meishan sow cough recognition algorithm[J]. Journal of Nanjing Agricultural University, 2016, 39(4): 681-687.
- [7] 熊梓奥. 育肥猪舍中的咳嗽声监测系统设计[D]. 哈尔滨: 哈尔滨工程大学, 2021.
XIONG Z A. Design of cough monitoring system in finishing piggery[D]. Harbin: Harbin Engineering University, 2021.
- [8] 付欣, 李晓童, 苟阳. 基于CNN的随钻声波仪器信号降噪方法研究[J]. 仪器仪表学报, 2025, 46(4): 270-282.
FU X, LI X T, GOU Y. A CNN-based noise reduction method for acoustic logging while drill instrument signal [J]. Chinese Journal of Scientific Instrument, 2025, 46(4): 270-282.
- [9] 任俊红, 詹旭, 范涛, 等. 基于多通道特征融合的CNN-SVM说话人识别研究[J]. 四川轻化工大学学报(自然科学版), 2025, 38(4): 18-27.
REN J H, ZHAN X, FAN T, et al. Speaker recognition based on multi-channel feature fusion with CNN-SVM [J]. Journal of Sichuan University of Science & Engineering(Natural Science Edition), 2025, 38(4): 18-27.
- [10] SHAH G, SHARMA A, JOSHI D, et al. A novel AVOA optimized DNN-BiLSTM-attention model for improved gesture classification using electromyography signal[J]. Results in Engineering, 2025, 27: 105648.

- [11] ZHANG H C, LI P C, JIN H Q, et al. Nonlinear wave energy dissipator with wave attenuation and energy harvesting at low frequencies[J]. *Ocean Engineering*, 2022, 266: 112935.
- [12] JIMÉNEZ-ZACARÍAS L L, CAMPOS-CANTÓN I. Lorenz system manufacturing with a butter worth filter[J]. *Integration*, 2025, 103: 102386.
- [13] KUMAR A, MAKHDOOMI B S, KUSHWAHA A K. Tunable current-mode first-order resistorless multifunction filter using CMOS DX-MOCCII[J]. *Russian Microelectronics*, 2024, 53(1): S54-S62.
- [14] XU W Z, MO H Q, TIAN L F, et al. An endpoint-detection algorithm of surface electromyography insensitive to electrocardiogram interference[J]. *Journal of Biomedical Engineering*, 2018, 35(6): 953-958.
- [15] SAKTHIVEL K M, NANDHINI V. Adaptive threshold selection for extreme value analysis to predict return levels of ozone layer depletion[J]. *Natural Hazards*, 2025, 121(11): 12741-12766.
- [16] SENATORI T, NARDONE D, GIUDICE L M, et al. Explainable instrument classification: From MFCC mean-vector models to CNNs on MFCC and mel-spectrograms with T-SNE and GRAD-CAM insights[J]. *Information*, 2025, 16(10): 864-864.
- [17] AMIRIAN B, BRAHME A, LEBENSOHN R A, et al. A generalizable machine learning-assisted fast Fourier transform algorithm to simulate the large strain phenomena in polycrystalline materials[J]. *International Journal of Plasticity*, 2025, 192: 104404.
- [18] JIANG Y, WANG X, ZHAO N, et al. Random vibration analysis of linear structures under time-varying coherent nonstationary excitations: An enhanced evolutionary spectral method[J]. *Mechanical Systems and Signal Processing*, 2025, 237: 113062.
- [19] 廖华, 申晓杰, 潘勇斌, 等. 基于梅尔滤波器的变电站开关故障监测仿真[J]. *计算机仿真*, 2024, 41(11): 123-126.
LIAO H, SHEN X J, PAN Y B, et al. Simulation of substation switch fault monitoring based on Mel filter[J]. *Computer Simulation*, 2024, 41(11): 123-126.
- [20] ZHANG S Y, AN W T, LAN T L, et al. An analysis of the effects of various polarimetric features and decomposition algorithms on PolSAR image classification through CNN[J]. *Results in Engineering*, 2025, 28: 107225.
- [21] LIU W, SHEN H, HU Y, et al. Polar ship trajectory prediction based on Kolmogorov-Arnold networks and LSTM[J]. *Ocean Engineering*, 2025, 336: 121702.
- [22] LI X L, HUO T M, ZHU L Q, et al. Modified BiLSTM network for interval prediction based on Aerospace Load System[J]. *Neurocomputing*, 2025, 651: 130887.
- [23] TOGKOUSIDIS A, STAMATAKIS A, GASCUEL O. Accelerating maximum likelihood phylogenetic inference via early stopping to evade (over-) optimization[J]. *Systematic Biology*, 2025: syaf043.
- [24] CHOI J. Efficient prompt optimization for relevance evaluation via LLM-based confusion matrix feedback[J]. *Applied Sciences*, 2025, 15(9): 5198.
- [25] TEODORESCU V, OBREJA BRAȘOVEANU L. Assessing the validity of k-fold cross-validation for model selection: Evidence from bankruptcy prediction using random forest and XGBoost[J]. *Computation*, 2025, 13(5): 127.
- [26] AHN J M, JEONG W, LEE H, et al. Hyperspectral imaging-based land use classification using a hybrid Convolutional Neural network-vision transformer model[J]. *Environmental Technology & Innovation*, 2025, 39: 104317.